FRM® Part I · Quantitative Analysis

Book 2

Quantitative Analysis

L'analyse quantitative

Le socle statistique de la mesure du risque

Approfondissement complet

Cours · 50 études de cas · 12 exercices corrigés · conseils méthodologiques · 150 QCM commentés

Support d'étude — questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel — pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
2.1 Fondements des probabilités . . . 3
2.2 Variables aléatoires et moments . . . 3
2.3 Distributions usuelles . . . 4
2.4 Variables multivariées, covariance et corrélation . . . 5
2.5 Échantillonnage, estimation et théorème central limite . . . 6
2.6 Tests d'hypothèses . . . 6
2.7 Régression linéaire simple . . . 7
2.8 Régression multiple . . . 8
2.9 Diagnostics de régression . . . 8
2.10 Séries temporelles stationnaires . . . 9
2.11 Séries temporelles non stationnaires . . . 9
2.12 Volatilité et corrélation . . . 10
2.13 Simulation de Monte-Carlo et bootstrap . . . 11
2.14 Introduction au machine learning . . . 11

Partie B — 50 études de cas **13**
B.1 Probabilités et théorème de Bayes (cas 1 à 8) . . . 13
B.2 Distributions et moments (cas 9 à 17) . . . 13
B.3 Estimation, échantillonnage et tests d'hypothèses (cas 18 à 26) . . . 14
B.4 Régression simple et multiple (cas 27 à 35) . . . 15
B.5 Séries temporelles (cas 36 à 42) . . . 15
B.6 Volatilité, simulation et machine learning (cas 43 à 50) . . . 16

Partie C — Exercices d'application corrigés **17**
Exercice 1 — Probabilité de défaut a posteriori (Bayes) . . . 17
Exercice 2 — Espérance et variance d'une variable aléatoire . . . 17
Exercice 3 — Loi de Poisson (pertes opérationnelles) . . . 17
Exercice 4 — Loi normale et VaR . . . 18
Exercice 5 — Variance d'un portefeuille à deux actifs . . . 18
Exercice 6 — Intervalle de confiance . . . 18
Exercice 7 — Test d'hypothèse sur une moyenne . . . 19
Exercice 8 — Régression linéaire simple . . . 19
Exercice 9 — Mise à jour de volatilité EWMA . . . 19
Exercice 10 — Modèle GARCH(1,1) . . . 19
Exercice 11 — Précision d'une simulation de Monte-Carlo . . . 20
Exercice 12 — Processus AR(1) . . . 20

Partie D — Conseils méthodologiques **21**
D.1 Comment aborder une question quantitative . . . 21
D.2 Les grands thèmes : compétences et pièges . . . 21
D.3 Les pièges classiques à l'examen . . . 21
D.4 Mémoriser efficacement . . . 22
D.5 Méthode sur les QCM quantitatifs . . . 22

Partie E — 150 questions à choix multiple **23**
E.1 Probabilités et théorème de Bayes (Q1 à Q15) . . . 23

E.2 Variables aléatoires et moments (Q16 à Q28) . . . 25
E.3 Distributions usuelles (Q29 à Q43) . . . 27
E.4 Variables multivariées, covariance et corrélation (Q44 à Q52) . . . 30
E.5 Estimation, échantillonnage et TCL (Q53 à Q64) . . . 31
E.6 Tests d'hypothèses (Q65 à Q80) . . . 33
E.7 Régression linéaire simple (Q81 à Q92) . . . 36
E.8 Régression multiple (Q93 à Q104) . . . 38
E.9 Diagnostics de régression (Q105 à Q112) . . . 40
E.10 Séries temporelles stationnaires (Q113 à Q122) . . . 41
E.11 Séries temporelles non stationnaires (Q123 à Q130) . . . 43
E.12 Volatilité : EWMA et GARCH (Q131 à Q142) . . . 44
E.13 Simulation et bootstrap (Q143 à Q147) . . . 46
E.14 Introduction au machine learning (Q148 à Q150) . . . 47

Partie F — Corrigé commenté **49**
F.1 Corrigé — Q1 à Q15 (probabilités et théorème de Bayes) . . . 49
F.2 Corrigé — Q16 à Q28 (variables aléatoires et moments) . . . 49
F.3 Corrigé — Q29 à Q43 (distributions usuelles) . . . 50
F.4 Corrigé — Q44 à Q52 (covariance et corrélation) . . . 50
F.5 Corrigé — Q53 à Q64 (estimation et TCL) . . . 50
F.6 Corrigé — Q65 à Q80 (tests d'hypothèses) . . . 51
F.7 Corrigé — Q81 à Q92 (régression linéaire simple) . . . 51
F.8 Corrigé — Q93 à Q104 (régression multiple) . . . 52
F.9 Corrigé — Q105 à Q112 (diagnostics de régression) . . . 52
F.10 Corrigé — Q113 à Q122 (séries temporelles stationnaires) . . . 52
F.11 Corrigé — Q123 à Q130 (séries temporelles non stationnaires) . . . 53
F.12 Corrigé — Q131 à Q142 (volatilité : EWMA et GARCH) . . . 53
F.13 Corrigé — Q143 à Q147 (simulation et bootstrap) . . . 53
F.14 Corrigé — Q148 à Q150 (machine learning) . . . 54

Partie A — Cours approfondi

Le Book 2 — *Quantitative Analysis* pèse **20 %** de la Partie I. Il fournit la **boîte à outils statistique** sur laquelle repose toute la mesure du risque : sans elle, ni la VaR, ni le backtesting, ni la modélisation du crédit ou de la volatilité ne seraient possibles. Ce book est **très calculatoire**, mais la tendance 2026 privilégie l'**interprétation appliquée** — savoir lire une sortie de régression, poser un diagnostic, choisir le bon test — plutôt que le calcul brut. Ce cours parcourt l'ensemble du programme, des fondements probabilistes jusqu'à l'introduction au machine learning.

2.1 Fondements des probabilités

La théorie des probabilités formalise l'incertitude. Un **événement** est un sous-ensemble de l'espace des résultats possibles ; sa **probabilité** est un nombre entre 0 et 1. Deux règles de base structurent les calculs : la **règle d'addition** pour l'union d'événements et la **règle de multiplication** pour leur intersection.

Probabilité conditionnelle

La probabilité de A *sachant* B est $P(A \mid B) = \dfrac{P(A \cap B)}{P(B)}$, définie pour $P(B) > 0$. Elle réévalue la vraisemblance de A une fois l'information B acquise. Deux événements sont **indépendants** si $P(A \cap B) = P(A)\,P(B)$, c'est-à-dire si $P(A \mid B) = P(A)$: connaître B n'apprend rien sur A.

La **loi des probabilités totales** décompose la probabilité d'un événement selon une partition $\{B_1, \dots, B_n\}$ de l'espace : $P(A) = \sum_i P(A \mid B_i)\,P(B_i)$. Elle est le préalable au résultat le plus important du chapitre.

Théorème de Bayes

Le théorème de Bayes *inverse* le conditionnement : $P(A \mid B) = \dfrac{P(B \mid A)\,P(A)}{P(B)}$. Il permet de passer de la probabilité d'un symptôme sachant la cause à celle de la cause sachant le symptôme. $P(A)$ est la probabilité **a priori**, $P(A \mid B)$ la probabilité **a posteriori**, et $P(B \mid A)$ la **vraisemblance**.

$$P(A \cap B) = P(A \mid B)\,P(B) \qquad P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A) = \sum_{i=1}^{n} P(A \mid B_i)\,P(B_i) \qquad P(A \mid B) = \frac{P(B \mid A)\,P(A)}{\sum_i P(B \mid A_i)\,P(A_i)}$$

Point d'examen Bayes est un classique d'examen, souvent habillé en problème de test diagnostique (fiabilité d'un signal, faux positifs/négatifs). Réflexe : identifier la probabilité a priori, la vraisemblance, puis appliquer la formule. Attention à ne pas confondre $P(A \mid B)$ et $P(B \mid A)$ — c'est le piège récurrent.

2.2 Variables aléatoires et moments

Une **variable aléatoire** (VA) associe un nombre à chaque résultat. Une VA **discrète** prend des valeurs isolées, décrites par une **fonction de masse** (PMF) $P(X = x)$; une VA **continue** est décrite par une **densité** (PDF) $f(x)$. Dans les deux cas, la **fonction de répartition** (CDF) $F(x) = P(X \le x)$ cumule la probabilité.

Espérance et variance

L'**espérance** $E[X]$ est la moyenne pondérée par les probabilités : $E[X] = \sum_x x\,P(X = x)$ (discret) ou $E[X] = \int x f(x)\,dx$ (continu). La **variance** $\mathrm{Var}(X) = E[(X-\mu)^2] = E[X^2] - (E[X])^2$ mesure la dispersion autour de la moyenne ; sa racine est l'**écart-type** σ.

Les **moments** caractérisent la forme de la distribution. Les deux premiers sont l'espérance (moment d'ordre 1) et la variance (moment centré d'ordre 2). Les deux suivants décrivent la forme des queues.

Asymétrie et kurtosis

L'**asymétrie** (*skewness*) $S = \dfrac{E[(X-\mu)^3]}{\sigma^3}$ mesure la dissymétrie : positive, la queue droite est plus longue. La **kurtosis** $K = \dfrac{E[(X-\mu)^4]}{\sigma^4}$ mesure l'épaisseur des queues ; pour une loi normale $K = 3$. L'**excès de kurtosis** $K - 3 > 0$ signale des **queues épaisses** (*leptokurtique*) — situation typique des rendements financiers.

$$E[aX+b] = a\,E[X] + b \qquad \mathrm{Var}(aX+b) = a^2\,\mathrm{Var}(X)$$

$$\mathrm{Var}(X) = E[X^2] - \big(E[X]\big)^2 \qquad S = \frac{E[(X-\mu)^3]}{\sigma^3} \qquad K = \frac{E[(X-\mu)^4]}{\sigma^4}$$

Point d'examen Retiens que $\mathrm{Var}(aX+b) = a^2\mathrm{Var}(X)$: une constante additive ne change pas la dispersion, un facteur multiplicatif l'affecte au carré. Les queues épaisses (excès de kurtosis positif) sont un thème transversal : elles expliquent pourquoi la loi normale sous-estime les pertes extrêmes.

2.3 Distributions usuelles

Le programme exige de reconnaître **quelle distribution s'applique** à un problème et d'en connaître les paramètres. Les lois **discrètes** modélisent des comptages ; les lois **continues** des grandeurs mesurées.

Lois discrètes fondamentales

La loi de **Bernoulli** décrit un essai binaire (succès/échec) de paramètre p. La loi **binomiale** $B(n,p)$ compte les succès sur n essais indépendants : $E[X] = np$, $\mathrm{Var}(X) = np(1-p)$. La loi de **Poisson** de paramètre λ compte des événements rares sur un intervalle : $E[X] = \mathrm{Var}(X) = \lambda$.

Parmi les lois continues, la **loi normale** est centrale : symétrique, entièrement décrite par sa moyenne μ et sa variance σ^2. On la **standardise** par $z = (x-\mu)/\sigma$ pour utiliser la table de la loi normale centrée réduite. La **loi lognormale** (dont le logarithme est normal) modélise les **prix d'actifs**, toujours positifs et asymétriques à droite.

Lois d'échantillonnage : t, chi-deux, F

La loi de **Student** t ressemble à la normale mais avec des **queues plus épaisses** ; elle sert pour les **petits échantillons** ou quand la variance est estimée. La loi du **chi-deux** χ^2 (somme de carrés de normales) sert aux tests sur la **variance** et d'ajustement. La loi de **Fisher** F (rapport de deux χ^2 normalisés) sert à comparer des **variances** et au test global de régression.

$$B(n,p):\ E[X]=np,\ \ \mathrm{Var}(X)=np(1-p) \qquad \text{Poisson}(\lambda):\ E[X]=\mathrm{Var}(X)=\lambda$$

$$z=\frac{x-\mu}{\sigma} \qquad \text{si } \ln(X)\sim N(\mu,\sigma^2) \text{ alors } X\sim \text{Lognormale}$$

La **loi exponentielle** de paramètre λ modélise les **temps d'attente** entre événements de Poisson (durée jusqu'au prochain défaut, par exemple) ; son espérance est $1/\lambda$. Les **lois mélangées** combinent plusieurs régimes (par exemple un mélange de deux normales) et produisent naturellement des queues épaisses.

Point d'examen Associe vite loi et usage : **binomiale** pour un nombre de défauts, **Poisson** pour des événements rares (pertes opérationnelles), **normale** pour des rendements agrégés, **lognormale** pour des prix, **Student** pour les petits échantillons, **exponentielle** pour un temps jusqu'au défaut. Le rôle des queues épaisses (Student, mélanges) revient constamment.

2.4 Variables multivariées, covariance et corrélation

Deux variables aléatoires sont décrites conjointement par leur **loi jointe**. On en déduit les **lois marginales** (comportement de chaque variable prise seule) et les **lois conditionnelles** (comportement de l'une sachant l'autre). Le lien entre deux variables se mesure par la covariance et la corrélation.

Covariance et corrélation

La **covariance** $\mathrm{Cov}(X,Y)=E[XY]-E[X]\,E[Y]$ mesure la tendance de deux variables à varier ensemble ; son signe indique le sens, mais son échelle dépend des unités. La **corrélation** $\rho_{X,Y}=\dfrac{\mathrm{Cov}(X,Y)}{\sigma_X\,\sigma_Y}$ normalise cette mesure entre -1 et $+1$: elle capture la force de la relation **linéaire**.

L'indépendance entraîne une covariance nulle, mais la **réciproque est fausse** : une covariance nulle n'exclut pas une dépendance non linéaire. C'est un point conceptuel testé. La variance d'une combinaison de variables fait intervenir la covariance.

$$\mathrm{Cov}(X,Y)=E[XY]-E[X]\,E[Y] \qquad \rho_{X,Y}=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\,\sigma_Y}\in[-1,1]$$

$$\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)+2\,\mathrm{Cov}(X,Y)$$

$$\mathrm{Var}\Big(\sum_i w_iX_i\Big)=\sum_i w_i^2\sigma_i^2+\sum_{i\neq j} w_iw_j\,\mathrm{Cov}(X_i,X_j)$$

Point d'examen La formule de la variance d'une somme est le pont vers la théorie du portefeuille (Book 1) et la VaR de portefeuille (Book 4). Retiens que corrélation nulle $\neq$ indépendance, et que seule une relation *linéaire* est captée par ρ — d'où l'intérêt des copules (Book 1 Partie II) pour les dépendances de queue.

2.5 Échantillonnage, estimation et théorème central limite

En pratique, on ne connaît pas les paramètres de la population : on les **estime** à partir d'un échantillon. La **moyenne empirique** $\bar{X}$ estime μ ; la **variance empirique** s^2 estime σ^2 en divisant par $n-1$ (correction de Bessel, qui rend l'estimateur non biaisé). Un bon **estimateur** est **non biaisé** (espérance égale au paramètre), **efficace** (variance minimale) et **convergent** (précision croissante avec n).

Théorème central limite

Quelle que soit la loi de la population (de variance finie), la moyenne d'un échantillon de taille n suit *approximativement* une loi normale dès que n est grand : $\bar{X} \approx N(\mu,\ \sigma^2/n)$. L'**erreur-type** $\mathrm{SE} = \sigma/\sqrt{n}$ décroît en $1/\sqrt{n}$: quadrupler l'échantillon divise l'erreur par deux. C'est le fondement de l'inférence statistique.

L'**estimation par intervalle** fournit une fourchette de valeurs plausibles pour le paramètre, assortie d'un **niveau de confiance**. Pour la moyenne, l'intervalle utilise la loi normale si σ est connu (ou n grand), la loi de Student sinon.

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \qquad s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

$$\mathrm{SE} = \frac{\sigma}{\sqrt{n}} \qquad \mathrm{IC}_{1-\alpha} = \bar{X} \pm z_{\alpha/2}\,\frac{\sigma}{\sqrt{n}} \quad (\text{ou } t_{\alpha/2}\,\tfrac{s}{\sqrt{n}})$$

Point d'examen Le TCL justifie l'emploi de la loi normale même pour des données non normales, à condition d'agréger. Points testés : l'erreur-type décroît en $1/\sqrt{n}$; on utilise la loi **t** (et non z) quand σ est estimé sur un petit échantillon ; un IC à 95 % n'est pas « 95 % de chance que le paramètre soit dans l'intervalle » mais une propriété de la procédure.

2.6 Tests d'hypothèses

Le test d'hypothèses est la démarche centrale de l'inférence — et la **zone la plus testée** du book. On oppose une **hypothèse nulle** H_0 (statu quo) à une **alternative** H_1. On calcule une **statistique de test** à partir de l'échantillon, puis on décide de rejeter ou non H_0.

Erreurs de type I et II

L'**erreur de type I** consiste à rejeter H_0 alors qu'elle est vraie (faux positif) ; sa probabilité est le **seuil de signification** α. L'**erreur de type II** consiste à ne pas rejeter H_0 alors qu'elle est fausse (faux négatif) ; sa probabilité est β. La **puissance** du test est $1-\beta$. À taille d'échantillon donnée, réduire α augmente β : c'est un arbitrage.

La décision s'opère de deux façons équivalentes : comparer la statistique à une **valeur critique** (région de rejet), ou comparer la **p-value** au seuil α. La **p-value** est la probabilité d'observer une statistique au moins aussi extrême que celle obtenue, si H_0 était vraie : si $\mathrm{p} < \alpha$, on rejette H_0. Le test est **unilatéral** ou **bilatéral** selon la forme de H_1.

Statistiques de test usuelles

Pour une **moyenne** : $t = \dfrac{\bar{X} - \mu_0}{s/\sqrt{n}}$, comparé à la loi de Student. Pour une **variance** : une statistique en χ^2. Pour comparer **deux variances** ou tester globalement une régression : une statistique de **Fisher** F. Le choix du test dépend du paramètre et des hypothèses sur la population.

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \qquad \text{décision : rejeter } H_0 \text{ si } |t| > t_{\text{crit}} \text{ ou si p} < \alpha$$

Point d'examen Maîtriser les tests « les yeux fermés » : poser H_0/H_1, choisir la bonne statistique, lire une p-value, distinguer erreurs I/II. Pièges fréquents : confondre les deux erreurs, oublier le caractère uni/bilatéral (qui double ou non le seuil), et interpréter une non-rejet comme une « preuve » de H_0 (c'est seulement une absence de preuve du contraire).

2.7 Régression linéaire simple

La **régression** modélise une variable expliquée Y en fonction d'une variable explicative X : $Y = \beta_0 + \beta_1 X + \varepsilon$, où ε est le terme d'erreur. La méthode des **moindres carrés ordinaires** (MCO) choisit les coefficients qui minimisent la somme des carrés des résidus.

Estimateurs des moindres carrés

La pente estimée est $\hat{\beta}_1 = \dfrac{\text{Cov}(X,Y)}{\text{Var}(X)} = \dfrac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$ et l'ordonnée à l'origine $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. La pente s'interprète comme la variation moyenne de Y pour une unité de X. La droite passe toujours par le point moyen $(\bar{x}, \bar{y})$.

La qualité de l'ajustement se mesure par le **coefficient de détermination** R^2, part de la variance de Y expliquée par le modèle. La **significativité** de la pente se teste par un test t sur $\hat{\beta}_1$. Les hypothèses de **Gauss-Markov** (linéarité, exogénéité, homoscédasticité, non-autocorrélation) garantissent que le MCO est le meilleur estimateur linéaire non biaisé (BLUE).

$$\hat{\beta}_1 = \frac{\text{Cov}(X,Y)}{\text{Var}(X)} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{SSR}}{\text{TSS}} \qquad t_{\hat{\beta}_1} = \frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)}$$

Point d'examen Sais interpréter chaque sortie : la pente (effet marginal), le R^2 (qualité d'ajustement, entre 0 et 1), le t de significativité (comparé à ≈ 2 pour 5 %). Le R^2 mesure l'ajustement, pas la causalité. En 2026, l'accent est sur la *lecture* d'un tableau de régression plutôt que sur le calcul manuel des coefficients.

2.8 Régression multiple

La **régression multiple** étend le modèle à plusieurs variables explicatives : $Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \varepsilon$. Chaque coefficient β_j s'interprète *toutes choses égales par ailleurs* : l'effet marginal de X_j sur Y à autres variables constantes. C'est cette interprétation **ceteris paribus** qui fait la puissance — et la fragilité — du modèle.

Biais de variable omise

Omettre une variable pertinente qui est *à la fois* corrélée à une variable incluse *et* déterminante de Y biaise les coefficients estimés : le modèle attribue à tort à X_j l'effet de la variable manquante. C'est l'un des pièges les plus graves de la modélisation, car il fausse l'interprétation causale.

La **multicolinéarité** apparaît quand des variables explicatives sont fortement corrélées entre elles : les coefficients deviennent instables et imprécis. Son symptôme typique est un R^2 **élevé accompagné de coefficients individuellement non significatifs**. Le R^2 **ajusté** pénalise l'ajout de variables inutiles, contrairement au R^2 simple qui ne peut que croître. Le **test F** évalue la significativité globale du modèle.

R-deux ajusté et test F

Le R^2 **ajusté** corrige le R^2 du nombre de régresseurs : $\bar{R}^2 = 1 - (1 - R^2)\dfrac{n-1}{n-k-1}$. Il peut *diminuer* si une variable ajoutée n'apporte rien. Le **test F** teste l'hypothèse que *tous* les coefficients de pente sont nuls simultanément : un F significatif indique que le modèle explique conjointement une part de la variance.

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \varepsilon \qquad \bar{R}^2 = 1 - (1 - R^2)\,\frac{n-1}{n-k-1}$$

Les **variables muettes** (*dummies*, valant 0 ou 1) intègrent des effets qualitatifs (secteur, régime, saison). Avec m modalités, on inclut $m - 1$ muettes pour éviter la colinéarité parfaite (piège de la variable muette).

Point d'examen Distingue bien les deux pathologies : le **biais de variable omise** (mauvaise *interprétation*, coefficients faux) et la **multicolinéarité** (mauvaise *précision*, coefficients instables mais globalement significatifs). Le R^2 ajusté est l'outil de sélection ; le test F l'outil de significativité globale.

2.9 Diagnostics de régression

Un modèle n'est fiable que si ses **hypothèses** sont vérifiées. Les diagnostics détectent les violations qui invalident l'inférence.

Hétéroscédasticité

L'**hétéroscédasticité** désigne une variance des erreurs *non constante* (par exemple croissante avec le niveau de X). Les coefficients MCO restent non biaisés mais leurs erreurs-types sont fausses, ce qui invalide les tests. On la détecte par les tests de **White** ou de **Breusch-Pagan**, et on la corrige par des **erreurs-types robustes** (White).

L'**autocorrélation** des résidus (erreurs corrélées dans le temps, fréquente en séries temporelles) fausse aussi les erreurs-types ; on la détecte par la statistique de **Durbin-Watson** (proche de 2 = pas d'autocorrélation) ou de Breusch-Godfrey. Les erreurs de **spécification** (forme fonctionnelle inadaptée, variable omise) et les **points influents** (observations atypiques pesant excessivement sur l'estimation) complètent le tableau des diagnostics.

$$\text{DW} \approx 2\,(1-\hat{\rho}) \quad \Rightarrow \quad \text{DW} \approx 2 : \text{pas d'autocorrélation}, \;\; \text{DW} \to 0 : \text{autocorrélation positive}$$

Point d'examen Reconnais les symptômes : hétéroscédasticité (résidus en éventail), autocorrélation (Durbin-Watson éloigné de 2). Retiens que ces violations n'affectent pas le *caractère non biaisé* des coefficients mais faussent les **erreurs-types** — donc les tests. La correction passe par des erreurs-types robustes. En 2026, savoir *diagnostiquer* à partir d'une sortie est prioritaire.

2.10 Séries temporelles stationnaires

Une **série temporelle** est une suite d'observations ordonnées dans le temps. La modélisation suppose souvent la **stationnarité**.

Stationnarité et bruit blanc

Une série est **stationnaire** (au sens faible) si sa moyenne, sa variance et ses autocovariances sont *constantes dans le temps*. Le **bruit blanc** est une série stationnaire sans structure : espérance nulle, variance constante, autocorrélations nulles. La stationnarité est la condition qui permet d'estimer et de prévoir de façon fiable.

La structure de dépendance temporelle se lit dans l'**autocorrélation** (ACF) et l'**autocorrélation partielle** (PACF). Trois familles de modèles la capturent : les modèles **autorégressifs** AR (la valeur dépend de ses propres passés), **moyenne mobile** MA (la valeur dépend des chocs passés), et leur combinaison **ARMA**.

Modèles AR, MA, ARMA

Un **AR(1)** s'écrit $x_t = c + \phi\, x_{t-1} + \varepsilon_t$: stationnaire si $|\phi| < 1$, avec **retour à la moyenne** d'autant plus rapide que $|\phi|$ est petit. Un **MA(1)** s'écrit $x_t = \mu + \varepsilon_t + \theta\, \varepsilon_{t-1}$. Un **ARMA(p,q)** combine p termes autorégressifs et q termes de moyenne mobile.

$$x_t = c + \phi\, x_{t-1} + \varepsilon_t \quad (\text{AR}(1),\ |\phi| < 1) \qquad E[x_t] = \frac{c}{1-\phi}$$

$$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} \quad (\text{MA}(q))$$

Point d'examen Retiens la condition de stationnarité d'un AR(1) : $|\phi| < 1$. La moyenne de long terme d'un AR(1) est $c/(1-\phi)$. L'ACF décroît exponentiellement pour un AR, se coupe nettement pour un MA : c'est la clé d'identification du modèle. Le retour à la moyenne est un concept transversal (taux d'intérêt, volatilité).

2.11 Séries temporelles non stationnaires

Beaucoup de séries financières (prix, indices) sont **non stationnaires** : leur moyenne ou leur variance dérive. Les traiter comme stationnaires conduit à des **régressions fallacieuses** (corrélations illusoires entre séries sans lien réel).

Marche aléatoire et racine unitaire

Une **marche aléatoire** $x_t = x_{t-1} + \varepsilon_t$ est le cas limite d'un AR(1) avec $\phi = 1$: elle possède une **racine unitaire**, sa variance croît sans borne et elle ne revient jamais à une moyenne. Le **test de Dickey-Fuller** (et

sa version augmentée, ADF) teste précisément la présence d'une racine unitaire (H_0 : racine unitaire, donc non-stationnarité).

La solution usuelle est la **différenciation** : une série intégrée d'ordre 1, notée $I(1)$, devient stationnaire après une différence première. On distingue les tendances **déterministes** (fonction du temps, corrigées par régression) des tendances **stochastiques** (racine unitaire, corrigées par différenciation). La **saisonnalité** ajoute une périodicité régulière. La **cointégration** décrit deux séries non stationnaires dont une combinaison linéaire est stationnaire : elles partagent une tendance commune (concept clé en trading de paires et en modélisation de spreads).

$$x_t = x_{t-1} + \varepsilon_t \quad \text{(marche aléatoire)} \qquad \Delta x_t = x_t - x_{t-1} \quad \text{(différenciation)}$$

Point d'examen Sais reconnaître une racine unitaire (série qui « erre » sans revenir), l'enjeu des régressions fallacieuses, et la différenciation comme remède. Le test de Dickey-Fuller a pour H_0 la **non-stationnarité** : ne pas rejeter signifie qu'on garde l'hypothèse de racine unitaire. La cointégration relie deux séries $I(1)$ par une relation d'équilibre stationnaire.

2.12 Volatilité et corrélation

La **volatilité** — l'écart-type des rendements — est la grandeur centrale du risque de marché. On distingue la volatilité **réalisée** (calculée sur des rendements passés) et les modèles qui la font **évoluer dans le temps**. Les rendements financiers présentent un **regroupement de volatilité** (*volatility clustering*) : les périodes agitées succèdent aux périodes agitées.

EWMA — moyenne mobile exponentiellement pondérée

L'EWMA estime la variance en pondérant davantage les observations récentes : $\sigma_t^2 = \lambda\,\sigma_{t-1}^2 + (1-\lambda)\,r_{t-1}^2$. Le paramètre de lissage $\lambda \in (0,1)$ règle la mémoire (RiskMetrics retient $\lambda = 0{,}94$ en données quotidiennes). Un λ élevé lisse davantage ; un λ faible réagit vite aux chocs.

GARCH(1,1)

Le modèle GARCH(1,1) ajoute à l'EWMA un terme de **variance de long terme** : $\sigma_t^2 = \omega + \alpha\,r_{t-1}^2 + \beta\,\sigma_{t-1}^2$. La **persistance** $\alpha+\beta$ (contrainte < 1 pour la stationnarité) mesure la durée de mémoire des chocs. La **variance de long terme** vaut $\omega/(1-\alpha-\beta)$: la volatilité y revient (*mean reversion*). L'EWMA en est le cas particulier $\omega = 0$, $\alpha = 1-\lambda$, $\beta = \lambda$.

$$\sigma_t^2 = \lambda\,\sigma_{t-1}^2 + (1-\lambda)\,r_{t-1}^2 \qquad \text{(EWMA)}$$

$$\sigma_t^2 = \omega + \alpha\,r_{t-1}^2 + \beta\,\sigma_{t-1}^2 \qquad \text{persistance} = \alpha+\beta \qquad \sigma_{\text{LT}}^2 = \frac{\omega}{1-\alpha-\beta}$$

L'estimation des **corrélations** entre actifs suit une logique analogue (EWMA de covariance, GARCH multivarié). Les corrélations ne sont **pas stables** : elles ont tendance à augmenter en période de stress, ce qui réduit les bénéfices de diversification au pire moment.

Point d'examen EWMA et GARCH(1,1) sont des **favoris d'examen**. Sais calculer la variance mise à jour, la persistance $\alpha + \beta$ et la variance de long terme $\omega/(1-\alpha-\beta)$. Retiens le lien EWMA–GARCH ($\omega = 0$) et l'instabilité des corrélations en stress (transversal avec la VaR et les copules).

2.13 Simulation de Monte-Carlo et bootstrap

Quand un problème n'a pas de solution analytique, la **simulation de Monte-Carlo** l'approche numériquement : on génère un grand nombre de scénarios aléatoires, puis on estime la grandeur cherchée par la moyenne des résultats. C'est l'une des trois méthodes de calcul de la VaR (Book 4).

Simulation de Monte-Carlo

La méthode consiste à : **(1)** spécifier le processus stochastique des facteurs de risque, **(2)** générer un grand nombre N de trajectoires aléatoires, **(3)** évaluer la grandeur d'intérêt sur chaque trajectoire et agréger (moyenne, quantile). L'**erreur d'estimation** décroît en $1/\sqrt{N}$: améliorer la précision d'un facteur 10 exige 100 fois plus de simulations.

Pour accélérer la convergence, on emploie des techniques de **réduction de variance** : les **variables antithétiques** (utiliser un tirage et son symétrique) et les **variables de contrôle** (exploiter une grandeur voisine à espérance connue). Le **bootstrap** est une approche complémentaire : au lieu de supposer une loi, on **rééchantillonne avec remise** les données observées, ce qui préserve leurs propriétés empiriques (queues épaisses, asymétrie) sans hypothèse paramétrique.

$$\text{erreur} \propto \frac{1}{\sqrt{N}} \qquad \hat{\theta} = \frac{1}{N}\sum_{i=1}^{N} g(X_i)$$

Point d'examen Retiens la convergence en $1/\sqrt{N}$ (coûteuse) et le rôle des techniques de réduction de variance (antithétiques, contrôle). Le **bootstrap** ne suppose aucune loi : il rééchantillonne les données réelles — atout pour capturer les queues épaisses. Distingue Monte-Carlo (loi supposée, scénarios générés) et simulation historique (données passées rejouées, Book 4).

2.14 Introduction au machine learning

Le programme s'ouvre désormais sur le **machine learning**, dont la logique diffère de la statistique classique : l'accent est mis sur la **prédiction** plutôt que sur l'inférence causale.

Apprentissage supervisé vs non supervisé

En apprentissage **supervisé**, l'algorithme apprend une relation entre des entrées et une sortie *étiquetée* (régression pour une cible continue, classification pour une cible catégorielle). En apprentissage **non supervisé**, il n'y a pas d'étiquette : l'algorithme découvre une structure (*clustering*, réduction de dimension). Le premier prédit ; le second explore.

Le danger central est le **surapprentissage** (*overfitting*) : un modèle trop complexe épouse le bruit des données d'entraînement et généralise mal. Pour l'éviter, on partitionne les données en jeux d'**entraînement**, de **validation** (réglage des hyperparamètres) et de **test** (évaluation finale impartiale). Le **compromis biais-variance** formalise l'arbitrage : trop simple, le modèle est biaisé ; trop complexe, il est instable.

Compromis biais-variance

L'erreur de prédiction se décompose en **biais** (erreur systématique d'un modèle trop rigide, *sous-apprentissage*) et **variance** (sensibilité excessive aux données, *surapprentissage*). Réduire l'un accroît souvent l'autre ; l'objectif est le compromis qui minimise l'erreur *hors échantillon*. La **régularisation** (ridge, lasso) pénalise la complexité pour contenir la variance.

Point d'examen Distingue supervisé (étiquettes, prédiction) et non supervisé (structure, exploration). Le **surapprentissage** et la partition **entraînement/validation/test** sont les points testables essentiels, avec le compromis **biais-variance**. Le ML se connecte au risque de modèle (Book 3 Partie II) : un modèle sur-ajusté est un risque opérationnel.

Partie B — 50 études de cas

Ces cas illustrent l'application concrète des outils quantitatifs. Chacun renvoie à la section de cours correspondante. Ils sont pensés pour ancrer les réflexes que les questions d'examen mobilisent.

B.1 Probabilités et théorème de Bayes (cas 1 à 8)

Cas 1 — Le test de défaut. Un modèle de détection signale 90 % des entreprises qui font défaut, mais génère 8 % de faux positifs ; les défauts sont rares (2 % de la population). Un analyste conclut qu'un signal positif implique un défaut quasi certain. *Enseignement* : sans appliquer Bayes, on ignore le taux de base ; la probabilité a posteriori réelle reste modeste. Confondre $P(\text{signal} \mid \text{défaut})$ et $P(\text{défaut} \mid \text{signal})$ est l'erreur classique. (§2.1)

Cas 2 — L'indépendance supposée. Un gérant traite les défauts de deux emprunteurs d'un même secteur comme indépendants pour calculer la probabilité de double défaut. *Enseignement* : la corrélation sectorielle rend l'hypothèse d'indépendance fausse et sous-estime le risque joint ; $P(A \cap B) \neq P(A)P(B)$ dès qu'il y a dépendance. (§2.1)

Cas 3 — La probabilité totale. Une banque évalue la probabilité de perte selon trois régimes de marché (haussier, neutre, baissier) de probabilités connues. *Enseignement* : la loi des probabilités totales agrège les scénarios : $P(\text{perte}) = \sum_i P(\text{perte} \mid \text{régime}_i) P(\text{régime}_i)$. (§2.1)

Cas 4 — La révision bayésienne. Après une dégradation de notation, un analyste veut réviser sa probabilité de défaut a priori. *Enseignement* : Bayes fournit le cadre exact pour passer de l'a priori à l'a posteriori en intégrant la nouvelle information (la vraisemblance de la dégradation). (§2.1)

Cas 5 — Les faux positifs coûteux. Un système anti-fraude déclenche de nombreuses alertes ; l'équipe conformité est saturée. *Enseignement* : quand l'événement est rare, même un test précis produit surtout des faux positifs (valeur prédictive positive faible) — conséquence directe du théorème de Bayes. (§2.1)

Cas 6 — L'événement conjoint. Un trader calcule la probabilité que deux conditions de marché surviennent le même jour. *Enseignement* : $P(A \cap B) = P(A \mid B)P(B)$; il faut la probabilité conditionnelle, pas le simple produit, sauf indépendance avérée. (§2.1)

Cas 7 — Le conditionnement inversé. Un rapport indique la probabilité d'une baisse de marché sachant une hausse des taux ; la direction veut l'inverse. *Enseignement* : inverser un conditionnement exige Bayes et la connaissance des probabilités marginales — on ne peut pas simplement « retourner » la probabilité. (§2.1)

Cas 8 — L'arbre de décision. Une exposition dépend d'une séquence d'événements (défaut, puis recouvrement partiel). *Enseignement* : décomposer en probabilités conditionnelles successives (règle de multiplication en chaîne) structure proprement le calcul de l'espérance de perte. (§2.1)

B.2 Distributions et moments (cas 9 à 17)

Cas 9 — La mauvaise loi. Un analyste modélise le nombre de défauts annuels d'un petit portefeuille par une loi normale. *Enseignement* : un comptage d'événements rares suit une loi de **Poisson** (ou binomiale), pas une normale ; le choix de loi conditionne toute la suite. (§2.3)

Cas 10 — Les queues sous-estimées. Un modèle de VaR suppose des rendements normaux ; les pertes extrêmes réelles sont bien plus fréquentes. *Enseignement* : les rendements ont un **excès de kurtosis** positif (queues épaisses) ; la loi normale sous-estime les événements extrêmes. (§2.2, §2.3)

Cas 11 — Le prix négatif impossible. Un modèle de prix d'action autorise des valeurs négatives. *Enseignement* : un prix se modélise par une loi **lognormale** (toujours positive, asymétrique à droite), pas par une normale. (§2.3)

Cas 12 — La variance de la mise à l'échelle. Un analyste multiplie une position par 3 et s'étonne que le risque

soit multiplié par 9. *Enseignement* : $\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$; la variance croît au carré du facteur, l'écart-type linéairement. (§2.2)

Cas 13 — L'asymétrie ignorée. Une stratégie affiche des gains fréquents et modestes, avec de rares pertes massives. *Enseignement* : l'**asymétrie négative** (skewness < 0) n'apparaît ni dans la moyenne ni dans la variance ; ignorer les moments d'ordre supérieur masque le vrai profil de risque. (§2.2)

Cas 14 — Le petit échantillon. On teste une moyenne sur 12 observations avec variance inconnue en utilisant la loi normale. *Enseignement* : pour un petit échantillon à variance estimée, la loi de **Student** (queues plus épaisses) est requise, sinon les seuils sont trop optimistes. (§2.3, §2.5)

Cas 15 — La somme de risques. Un desk agrège les pertes de plusieurs lignes supposées indépendantes. *Enseignement* : la loi de la somme dépend des corrélations ; sous indépendance, les variances s'additionnent, mais la corrélation modifie le résultat. (§2.3, §2.4)

Cas 16 — Le temps jusqu'au défaut. Un modèle de crédit décrit la durée avant défaut. *Enseignement* : cette durée suit typiquement une loi **exponentielle** de paramètre l'intensité λ, avec espérance $1/\lambda$ — lien direct avec les modèles à intensité (Book 2 Partie II). (§2.3)

Cas 17 — Le mélange de régimes. Les rendements semblent normaux en période calme mais très dispersés en crise. *Enseignement* : un **mélange** de deux normales (calme/stress) génère des queues épaisses même si chaque composante est gaussienne. (§2.3)

B.3 Estimation, échantillonnage et tests d'hypothèses (cas 18 à 26)

Cas 18 — L'erreur-type oubliée. Un analyste rapporte une moyenne de rendement sans indiquer sa précision. *Enseignement* : l'**erreur-type** $\sigma/\sqrt{n}$ quantifie l'incertitude de l'estimation ; une moyenne sans erreur-type est ininterprétable. (§2.5)

Cas 19 — La taille d'échantillon. Pour halver l'incertitude d'une estimation, on double la taille de l'échantillon. *Enseignement* : l'erreur décroît en $1/\sqrt{n}$; **quadrupler** l'échantillon (pas doubler) divise l'erreur-type par deux. (§2.5)

Cas 20 — L'intervalle mal interprété. Un rapport affirme « 95 % de chance que le vrai paramètre soit dans l'intervalle ». *Enseignement* : un intervalle de confiance est une propriété de la *procédure* (95 % des intervalles construits contiendraient le paramètre), non une probabilité sur un intervalle donné. (§2.5)

Cas 21 — Les deux erreurs. Un modèle de détection est réglé pour ne presque jamais manquer un défaut, au prix de nombreuses fausses alertes. *Enseignement* : réduire l'**erreur de type II** augmente l'**erreur de type I** à taille d'échantillon fixe ; c'est un arbitrage, pas un réglage gratuit. (§2.6)

Cas 22 — La p-value mal lue. Une p-value de 0,04 est interprétée comme « 4 % de chance que H_0 soit vraie ». *Enseignement* : la p-value est $P(\text{données aussi extrêmes} \mid H_0)$, pas $P(H_0 \mid \text{données})$; l'inversion est fausse. (§2.6)

Cas 23 — L'unilatéral et le bilatéral. Un analyste teste si un rendement est « différent de zéro » mais applique un seuil unilatéral. *Enseignement* : une alternative bilatérale répartit le seuil α des deux côtés ; confondre uni/bilatéral fausse la valeur critique. (§2.6)

Cas 24 — La non-rejet surinterprétée. Ne pas rejeter H_0 est présenté comme « la preuve que H_0 est vraie ». *Enseignement* : l'absence de rejet est une absence de preuve du contraire, pas une confirmation ; la puissance du test conditionne cette lecture. (§2.6)

Cas 25 — Le test de variance. Un risk manager veut vérifier si la volatilité d'un actif a changé. *Enseignement* : un test sur la variance mobilise la loi du **chi-deux** ; comparer deux variances mobilise la loi de **Fisher**. (§2.3,

§2.6)

Cas 26 — Le biais d'estimation. Un analyste divise la somme des carrés des écarts par n et obtient une variance systématiquement trop faible. *Enseignement* : la variance empirique non biaisée divise par $n-1$ (correction de Bessel) ; diviser par n sous-estime la dispersion. (§2.5)

B.4 Régression simple et multiple (cas 27 à 35)

Cas 27 — Le R-deux trompeur. Un modèle affiche un R^2 de 0,95 et l'analyste conclut à une relation causale forte. *Enseignement* : le R^2 mesure l'**ajustement**, pas la **causalité** ; une corrélation élevée peut refléter une variable commune omise. (§2.7, §2.8)

Cas 28 — La variable omise. Un modèle reliant rendement et taille omet le secteur, pourtant corrélé aux deux. *Enseignement* : le **biais de variable omise** fausse le coefficient de la taille, qui capte à tort l'effet du secteur. (§2.8)

Cas 29 — La multicolinéarité. Deux régresseurs très corrélés (taux court et taux long) donnent des coefficients instables et non significatifs, malgré un bon R^2. *Enseignement* : symptôme typique de **multicolinéarité** ; le modèle explique bien globalement mais ne sépare pas les effets individuels. (§2.8)

Cas 30 — Le sur-ajout de variables. Un analyste ajoute des régresseurs jusqu'à maximiser le R^2. *Enseignement* : le R^2 ne peut que croître ; c'est le R^2 **ajusté** qui pénalise les variables inutiles et guide la sélection. (§2.8)

Cas 31 — Le coefficient mal interprété. Dans une régression multiple, un coefficient est lu sans la clause « toutes choses égales par ailleurs ». *Enseignement* : chaque coefficient mesure l'effet marginal **à autres variables constantes** ; l'oublier fausse l'interprétation. (§2.8)

Cas 32 — La variable muette piégée. Un modèle à quatre saisons inclut quatre muettes plus la constante. *Enseignement* : avec m modalités, il faut $m-1$ muettes ; en inclure m crée une **colinéarité parfaite** (piège de la variable muette). (§2.8)

Cas 33 — Le test t de significativité. Un coefficient a un t de 1,2 ; l'analyste le juge significatif. *Enseignement* : à 5 %, la valeur critique est proche de 2 ; un t de 1,2 ne permet pas de rejeter la nullité du coefficient. (§2.7)

Cas 34 — La prévision hors domaine. Un modèle calibré sur des taux de 2 à 5 % sert à prévoir à 12 %. *Enseignement* : l'**extrapolation** hors du domaine des données est hasardeuse ; l'intervalle de prévision s'élargit fortement loin de la moyenne des X. (§2.7)

Cas 35 — La causalité inversée. Un modèle régresse les ventes sur la publicité, mais la publicité dépend aussi des ventes anticipées. *Enseignement* : l'**endogénéité** (variable explicative corrélée à l'erreur) biaise le MCO ; le sens de causalité doit être justifié. (§2.8, §2.9)

B.5 Séries temporelles (cas 36 à 42)

Cas 36 — La régression fallacieuse. Deux séries de prix non stationnaires apparaissent fortement corrélées sans lien économique. *Enseignement* : régresser des séries **non stationnaires** produit des corrélations **illusoires** ; il faut d'abord vérifier la stationnarité. (§2.11)

Cas 37 — La racine unitaire. Un analyste modélise un indice boursier comme stationnaire autour d'une moyenne. *Enseignement* : un indice suit souvent une **marche aléatoire** (racine unitaire) ; le test de Dickey-Fuller le vérifie, et la différenciation le stationnarise. (§2.11)

Cas 38 — L'AR(1) explosif. Un modèle AR(1) est estimé avec $\phi = 1{,}05$. *Enseignement* : la stationnarité exige $|\phi| < 1$; un $\phi \geq 1$ rend la série non stationnaire (explosive ou marche aléatoire). (§2.10)

Cas 39 — L'identification ACF/PACF. Une série montre une ACF qui décroît lentement et une PACF qui se coupe après le rang 1. *Enseignement* : ce profil signe un **AR(1)** ; l'inverse (ACF coupée, PACF décroissante) signerait un MA. (§2.10)

Cas 40 — Le retour à la moyenne. Un spread de taux s'écarte fortement de sa moyenne historique. *Enseignement* : si le processus est stationnaire (AR à $|\phi| < 1$), il tend à **revenir vers sa moyenne** $c/(1-\phi)$ — fondement des stratégies de convergence. (§2.10)

Cas 41 — La saisonnalité négligée. Un modèle de flux ignore une forte composante trimestrielle. *Enseignement* : la **saisonnalité** non modélisée laisse une structure dans les résidus (autocorrélation) et dégrade les prévisions. (§2.11)

Cas 42 — La cointégration. Deux actifs non stationnaires ont un spread stable dans le temps. *Enseignement* : ils sont **cointégrés** — une combinaison linéaire est stationnaire ; c'est la base rigoureuse du trading de paires. (§2.11)

B.6 Volatilité, simulation et machine learning (cas 43 à 50)

Cas 43 — Le clustering de volatilité. Une période de forte volatilité en précède d'autres, mais le modèle suppose une volatilité constante. *Enseignement* : le **regroupement de volatilité** exige un modèle dynamique (EWMA, GARCH) ; supposer σ constant sous-estime le risque après un choc. (§2.12)

Cas 44 — La persistance GARCH. Un GARCH(1,1) est estimé avec $\alpha + \beta = 0{,}995$. *Enseignement* : une **persistance** proche de 1 signale des chocs très durables et un retour à la moyenne très lent ; proche de 1, la variance de long terme devient instable. (§2.12)

Cas 45 — EWMA vs GARCH. Un analyste hésite entre EWMA et GARCH pour estimer la volatilité. *Enseignement* : l'EWMA est le cas particulier du GARCH sans variance de long terme ($\omega = 0$) ; le GARCH ajoute le **retour à la moyenne** de la volatilité. (§2.12)

Cas 46 — Le lambda mal choisi. Un EWMA avec λ très élevé réagit trop lentement aux chocs récents. *Enseignement* : λ règle la mémoire ; trop élevé, l'estimation est lisse mais lente ; trop faible, elle est réactive mais bruitée (RiskMetrics : $\lambda = 0{,}94$). (§2.12)

Cas 47 — La précision Monte-Carlo. Pour diviser par 10 l'erreur d'une simulation, on multiplie par 10 le nombre de tirages. *Enseignement* : l'erreur décroît en $1/\sqrt{N}$; il faut multiplier N par **100** (et non 10) pour diviser l'erreur par 10. (§2.13)

Cas 48 — Le bootstrap salvateur. Les rendements ont des queues épaisses mal captées par une loi paramétrique. *Enseignement* : le **bootstrap** rééchantillonne les données réelles avec remise, préservant queues épaisses et asymétrie sans hypothèse de loi. (§2.13)

Cas 49 — Le surapprentissage. Un modèle de ML atteint 99 % de précision en entraînement mais échoue en test. *Enseignement* : c'est du **surapprentissage** ; le modèle a mémorisé le bruit. La partition entraînement/validation/test et la régularisation le préviennent. (§2.14)

Cas 50 — Le biais-variance. Un modèle trop simple sous-performe partout ; un modèle trop complexe est instable. *Enseignement* : c'est le **compromis biais-variance** ; l'objectif est de minimiser l'erreur *hors échantillon*, pas l'erreur d'entraînement. (§2.14)

Partie C — Exercices d'application corrigés

Douze exercices calculatoires, corrigés pas à pas, couvrant les compétences numériques les plus testées du book.

Exercice 1 — Probabilité de défaut a posteriori (Bayes)

Énoncé. Un modèle détecte 90 % des entreprises qui feront défaut (sensibilité) et génère 5 % de faux positifs. Le taux de défaut de base est de 2 %. Quelle est la probabilité qu'une entreprise signalée fasse réellement défaut ?

Solution. On applique Bayes. La probabilité d'un signal positif est, par la loi des probabilités totales :

$$P(\text{signal}) = 0{,}90 \times 0{,}02 + 0{,}05 \times 0{,}98 = 0{,}018 + 0{,}049 = 0{,}067$$

$$P(\text{défaut} \mid \text{signal}) = \frac{0{,}90 \times 0{,}02}{0{,}067} = \frac{0{,}018}{0{,}067} \approx 0{,}269$$

La probabilité réelle n'est que de **26,9 %**, malgré un test précis — car les défauts sont rares. C'est l'effet contre-intuitif du taux de base.

Exercice 2 — Espérance et variance d'une variable aléatoire

Énoncé. Un investissement rapporte -10, 0 ou $+20$ (en unités) avec probabilités respectives $0{,}3$, $0{,}5$ et $0{,}2$. Calculez l'espérance et l'écart-type.

Solution.

$$E[X] = -10 \times 0{,}3 + 0 \times 0{,}5 + 20 \times 0{,}2 = -3 + 4 = 1$$

$$E[X^2] = 100 \times 0{,}3 + 0 + 400 \times 0{,}2 = 30 + 80 = 110$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 110 - 1 = 109 \qquad \sigma = \sqrt{109} \approx 10{,}44$$

L'espérance est de **1** et l'écart-type d'environ **10,44** : le risque domine largement le rendement moyen.

Exercice 3 — Loi de Poisson (pertes opérationnelles)

Énoncé. Le nombre de pertes opérationnelles suit une loi de Poisson de moyenne $\lambda = 3$ par an. Quelle est la probabilité d'observer exactement 5 pertes ? Aucune perte ?

Solution. La loi de Poisson donne $P(X = k) = e^{-\lambda}\lambda^k / k!$.

$$P(X = 5) = \frac{e^{-3}\, 3^5}{5!} = \frac{0{,}0498 \times 243}{120} \approx 0{,}101$$

$$P(X = 0) = e^{-3} \approx 0{,}0498$$

Soit **10,1 %** de chance d'exactement 5 pertes et **4,98 %** d'aucune perte.

Exercice 4 — Loi normale et VaR

Énoncé. Le rendement annuel d'un portefeuille suit $N(\mu = 8\%, \sigma = 15\%)$. Quelle est la probabilité d'un rendement inférieur à -10% ? Quelle est la VaR à 95 % (1 an) ?

Solution. On standardise :

$$z = \frac{-10 - 8}{15} = -1{,}20 \qquad P(Z < -1{,}20) \approx 0{,}115$$

Pour la VaR à 95 %, on utilise le quantile $z_{0{,}05} = 1{,}645$:

$$\text{VaR}_{95\%} = -(\mu - 1{,}645\,\sigma) = -(8 - 1{,}645 \times 15) = -(8 - 24{,}675) \approx 16{,}7\%$$

Il y a **11,5 %** de chance de perdre plus de 10 %, et la VaR à 95 % est d'environ **16,7 %**.

Exercice 5 — Variance d'un portefeuille à deux actifs

Énoncé. Deux actifs ont pour volatilités $\sigma_A = 20\%$ et $\sigma_B = 30\%$, une corrélation $\rho = 0{,}4$, et des poids 60% / 40%. Calculez la volatilité du portefeuille.

Solution.

$$\sigma_p^2 = 0{,}6^2 \times 0{,}20^2 + 0{,}4^2 \times 0{,}30^2 + 2 \times 0{,}6 \times 0{,}4 \times 0{,}4 \times 0{,}20 \times 0{,}30$$

$$\sigma_p^2 = 0{,}0144 + 0{,}0144 + 0{,}01152 = 0{,}04032 \qquad \sigma_p = \sqrt{0{,}04032} \approx 20{,}1\%$$

La volatilité du portefeuille est d'environ **20,1 %**, inférieure à la moyenne pondérée des volatilités (24 %) grâce à la diversification.

Exercice 6 — Intervalle de confiance

Énoncé. Sur 36 mois, le rendement mensuel moyen est de $1{,}2\%$ avec un écart-type de 4%. Construisez l'intervalle de confiance à 95 % de la moyenne.

Solution.

$$\text{SE} = \frac{\sigma}{\sqrt{n}} = \frac{4}{\sqrt{36}} = \frac{4}{6} \approx 0{,}667\%$$

$$\text{IC}_{95\%} = 1{,}2 \pm 1{,}96 \times 0{,}667 = 1{,}2 \pm 1{,}31 = [-0{,}11\%,\ 2{,}51\%]$$

L'intervalle $[-0{,}11\%;\ 2{,}51\%]$ contient zéro : on ne peut pas conclure que le rendement moyen diffère significativement de zéro à ce seuil.

Exercice 7 — Test d'hypothèse sur une moyenne

Énoncé. Un fonds affiche sur 25 mois un rendement moyen de $0{,}8\%$ avec un écart-type de 2%. Testez, au seuil de 5 % bilatéral, l'hypothèse que son rendement moyen est nul.

Solution. Hypothèses : $H_0 : \mu = 0$ contre $H_1 : \mu \neq 0$. On calcule la statistique de test :

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} = \frac{0{,}8 - 0}{2/\sqrt{25}} = \frac{0{,}8}{0{,}4} = 2{,}0$$

La valeur critique de la loi de Student à 24 degrés de liberté (5 % bilatéral) est $\approx 2{,}064$. Comme $|t| = 2{,}0 < 2{,}064$, on **ne rejette pas** H_0 — de justesse : le rendement n'est pas significativement différent de zéro à ce seuil.

Exercice 8 — Régression linéaire simple

Énoncé. Pour une régression de Y sur X, on a $\mathrm{Cov}(X,Y) = 0{,}006$, $\mathrm{Var}(X) = 0{,}004$, $\mathrm{Var}(Y) = 0{,}010$, avec $\bar{x} = 5\%$ et $\bar{y} = 8\%$. Calculez la pente, l'ordonnée à l'origine et le R^2.

Solution.

$$\hat{\beta}_1 = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} = \frac{0{,}006}{0{,}004} = 1{,}5 \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 8 - 1{,}5 \times 5 = 0{,}5\%$$

Le R^2 est le carré de la corrélation :

$$\rho = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}} = \frac{0{,}006}{\sqrt{0{,}004 \times 0{,}010}} \approx 0{,}949 \qquad R^2 \approx 0{,}90$$

La droite est $\hat{Y} = 0{,}5 + 1{,}5\,X$; le modèle explique environ **90 %** de la variance de Y.

Exercice 9 — Mise à jour de volatilité EWMA

Énoncé. Avec $\lambda = 0{,}94$, la volatilité quotidienne estimée hier était de 2% et le rendement d'hier de -3%. Quelle est la nouvelle estimation de volatilité ?

Solution.

$$\sigma_t^2 = \lambda\,\sigma_{t-1}^2 + (1-\lambda)\,r_{t-1}^2 = 0{,}94 \times 0{,}02^2 + 0{,}06 \times 0{,}03^2$$

$$\sigma_t^2 = 0{,}000376 + 0{,}000054 = 0{,}00043 \qquad \sigma_t = \sqrt{0{,}00043} \approx 2{,}07\%$$

La volatilité passe à environ **2,07 %** : le choc de -3% l'a légèrement relevée.

Exercice 10 — Modèle GARCH(1,1)

Énoncé. Un GARCH(1,1) a pour paramètres $\omega = 0{,}000002$, $\alpha = 0{,}05$, $\beta = 0{,}93$. Hier, $\sigma_{t-1} = 1{,}5\%$ et $r_{t-1} = 2\%$. Calculez la volatilité mise à jour, la persistance et la volatilité de long terme.

Solution.

$$\sigma_t^2 = \omega + \alpha\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2 = 0{,}000002 + 0{,}05 \times 0{,}02^2 + 0{,}93 \times 0{,}015^2$$

$$\sigma_t^2 = 0{,}000002 + 0{,}00002 + 0{,}00020925 = 0{,}00023125 \qquad \sigma_t \approx 1{,}52\%$$

$$\text{persistance} = \alpha + \beta = 0{,}98 \qquad \sigma_{\text{LT}} = \sqrt{\frac{\omega}{1-\alpha-\beta}} = \sqrt{\frac{0{,}000002}{0{,}02}} = \sqrt{0{,}0001} = 1{,}0\%$$

La volatilité mise à jour est de **1,52 %**, la persistance de **0,98** (chocs durables), et la volatilité de long terme de **1,0 %**.

Exercice 11 — Précision d'une simulation de Monte-Carlo

Énoncé. Une simulation avec $N = 10\,000$ tirages donne une erreur-type de $0{,}5\%$. Combien de tirages faut-il pour ramener l'erreur-type à $0{,}1\%$?

Solution. L'erreur décroît en $1/\sqrt{N}$, donc le rapport des erreurs est l'inverse du rapport des racines :

$$\frac{0{,}5}{0{,}1} = 5 = \sqrt{\frac{N_{\text{nouveau}}}{10\,000}} \quad \Rightarrow \quad N_{\text{nouveau}} = 25 \times 10\,000 = 250\,000$$

Il faut **250 000** tirages : diviser l'erreur par 5 exige de multiplier N par $5^2 = 25$.

Exercice 12 — Processus AR(1)

Énoncé. Une série suit $x_t = 0{,}6 + 0{,}4\, x_{t-1} + \varepsilon_t$. Est-elle stationnaire ? Quelle est sa moyenne de long terme ?

Solution. La stationnarité d'un AR(1) exige $|\phi| < 1$. Ici $\phi = 0{,}4$, donc la série **est stationnaire**. Sa moyenne de long terme est :

$$E[x] = \frac{c}{1-\phi} = \frac{0{,}6}{1-0{,}4} = \frac{0{,}6}{0{,}6} = 1{,}0$$

La série est stationnaire et **revient vers une moyenne de 1,0** ; avec $\phi = 0{,}4$ modéré, le retour à la moyenne est relativement rapide.

Partie D — Conseils méthodologiques

D.1 Comment aborder une question quantitative

Une question de Quant se traite en quatre temps. **Identifier** d'abord la nature du problème (probabilité, distribution, test, régression, série temporelle, volatilité) — le vocabulaire de l'énoncé est le meilleur indice. **Choisir** ensuite l'outil : la bonne formule, le bon test, la bonne loi. **Calculer** proprement, en surveillant les unités (quotidien vs annuel, variance vs écart-type). **Interpréter** enfin le résultat dans le contexte : un chiffre sans lecture ne vaut rien, et l'examen 2026 valorise précisément cette étape.

D.2 Les grands thèmes : compétences et pièges

Les deux tableaux ci-dessous synthétisent, pour chaque thème du book, la notion maîtresse et le piège le plus fréquent.

Thème	Notion / formule maîtresse	Piège à éviter
Probabilités et Bayes	$P(A \mid B) = P(B \mid A)P(A)/P(B)$	Inverser le conditionnement.
Variables et moments	$\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$; kurtosis > 3 = queues épaisses	Ignorer asymétrie et kurtosis.
Distributions	Poisson $E = \mathrm{Var} = \lambda$; lognormale pour les prix	Utiliser la normale pour un comptage ou un prix.
Estimation et TCL	SE $= \sigma/\sqrt{n}$	Oublier le $1/\sqrt{n}$ (quadrupler n).
Tests d'hypothèses	$t = (\bar{X} - \mu_0)/(s/\sqrt{n})$; p $<$ α = rejet	Confondre erreurs I/II et uni/bilatéral.
Régression simple	$\hat{\beta}_1 = \mathrm{Cov}/\mathrm{Var}$; $R^2 = 1 - \mathrm{SSR}/\mathrm{SST}$	Confondre R^2 et causalité.
Régression multiple	R^2 ajusté ; test F global	Confondre variable omise et multicolinéarité.

Thème	Notion / formule maîtresse	Piège à éviter
Diagnostics	Durbin-Watson ≈ 2 = pas d'autocorrélation	Croire les coefficients biaisés (ce sont les erreurs-types).
Séries stationnaires	AR(1) stationnaire si $\lvert\phi\rvert < 1$; moyenne $c/(1-\phi)$	Traiter $\phi \geq 1$ comme stationnaire.
Séries non stationnaires	Dickey-Fuller (H_0 : racine unitaire)	Régression fallacieuse sur séries non stationnaires.
Volatilité	EWMA ; GARCH persistance $\alpha + \beta$, var. LT $\omega/(1-\alpha-\beta)$	Oublier la contrainte $\alpha + \beta < 1$.
Simulation	Erreur $\propto 1/\sqrt{N}$; bootstrap sans hypothèse de loi	Sous-estimer le coût ($\times 100$ pour diviser l'erreur par 10).
Machine learning	Partition entraînement/validation/test ; biais-variance	Surapprentissage (mémoriser le bruit).

D.3 Les pièges classiques à l'examen

Cinq erreurs reviennent le plus souvent. **Confondre $P(A \mid B)$ et $P(B \mid A)$** dans les problèmes de Bayes. **Oublier la correction $1/\sqrt{n}$** de l'erreur-type (quadrupler l'échantillon, pas doubler). **Mélanger les erreurs de type I et II** ou le caractère unilatéral/bilatéral d'un test. **Prendre un R^2 élevé pour une preuve de causalité**. **Confondre variance et écart-type**, ou grandeurs quotidiennes et annuelles (la variance se met à l'échelle par le temps, l'écart-type par sa racine).

D.4 Mémoriser efficacement

Aucune feuille de formules n'étant fournie, quelques blocs doivent être **automatiques** : Bayes ; l'espérance et la variance ($\text{Var}(X) = E[X^2] - (E[X])^2$) ; l'erreur-type et l'intervalle de confiance ; la statistique t ; la pente et le R^2 d'une régression ; l'EWMA et le GARCH(1,1) avec persistance et variance de long terme ; la convergence en $1/\sqrt{N}$ de Monte-Carlo. Reconstruire chaque formule à la main plusieurs fois vaut mieux que la relire.

D.5 Méthode sur les QCM quantitatifs

Sur un QCM calculatoire, lire d'abord la **question posée** (souvent un seul chiffre), repérer les **données utiles** dans l'énoncé, et vérifier les **unités** avant de calculer. Les distracteurs sont conçus pour piéger : ils correspondent souvent à une erreur classique (écart-type au lieu de variance, conditionnement inversé, oubli du $1/\sqrt{n}$). Sur un QCM conceptuel, se méfier des formulations absolues et privilégier la réponse la plus nuancée et rigoureuse.

Point d'examen La discipline du candidat quantitatif : **identifier** le type de problème, **surveiller les unités**, **interpréter** le résultat. En 2026, savoir *lire* une sortie de régression ou un diagnostic prime sur le calcul brut — entraîne-toi sur des sorties commentées, pas seulement sur des formules isolées.

Partie E — 150 questions à choix multiple

Questions originales de style examen, réparties par thème. Le corrigé commenté figure en Partie F, avec renvoi à la section de cours, au cas ou à l'exercice pertinent.

E.1 Probabilités et théorème de Bayes (Q1 à Q15)

Q1 Le théorème de Bayes permet essentiellement de —

(A) inverser un conditionnement entre deux événements

(B) additionner des probabilités d'événements indépendants

(C) calculer directement une variance

(D) ajuster une régression linéaire

Q2 La probabilité conditionnelle $P(A \mid B)$ est définie comme —

(A) $P(A)\,P(B)$

(B) $P(A \cap B)/P(B)$

(C) $P(A) + P(B)$

(D) $P(B \mid A)$

Q3 Deux événements sont indépendants si et seulement si —

(A) $P(A \cap B) = 0$

(B) ils sont mutuellement exclusifs

(C) $P(A \cap B) = P(A)\,P(B)$

(D) $P(A \mid B) = 0$

Q4 La loi des probabilités totales sert à —

(A) inverser le théorème de Bayes

(B) calculer une corrélation

(C) tester une hypothèse

(D) décomposer une probabilité selon une partition d'événements

Q5 Dans un test diagnostique portant sur un événement rare, un résultat positif —

(A) est fréquemment un faux positif

(B) implique l'événement avec quasi-certitude

(C) a toujours une valeur prédictive élevée

(D) est mathématiquement impossible

Q6 L'intersection $P(A \cap B)$ vaut —

(A) $P(A) + P(B)$

(B) $P(A \mid B)\, P(B)$

(C) $P(A)/P(B)$

(D) $P(A \mid B) + P(B)$

Q7 Dans le cadre bayésien, la probabilité a priori est —

(A) la probabilité après observation

(B) la vraisemblance de la donnée

(C) la probabilité avant toute observation

(D) toujours égale à 0,5

Q8 Confondre $P(A \mid B)$ et $P(B \mid A)$ constitue —

(A) une opération sans conséquence

(B) une simplification autorisée

(C) une application de la règle d'addition

(D) une erreur d'inférence classique

Q9 Pour des événements dépendants, le calcul de $P(A \cap B)$ requiert —

(A) la probabilité conditionnelle

(B) la seule probabilité $P(A)$

(C) la somme des probabilités

(D) leur différence

Q10 Deux événements mutuellement exclusifs vérifient —

(A) qu'ils sont indépendants

(B) $P(A \cap B) = 0$

(C) $P(A) = P(B)$

(D) qu'ils sont corrélés positivement

Q11 Dans le théorème de Bayes, la vraisemblance correspond à —

(A) $P(A)$

(B) $P(A \mid B)$

(C) $P(B \mid A)$

(D) $P(B)$

Q12 Un taux de base très faible d'un événement —

(A) n'a aucun effet sur la valeur prédictive

(B) augmente la certitude d'un test positif

(C) est ignoré par le théorème de Bayes

(D) réduit la valeur prédictive positive d'un test

Q13 La règle d'addition donne $P(A \cup B) =$

(A) $P(A) + P(B) - P(A \cap B)$

(B) $P(A) + P(B)$ en toutes circonstances

(C) $P(A)\,P(B)$

(D) $P(A \mid B)$

Q14 Si $P(A \mid B) = P(A)$, alors —

(A) A et B sont dépendants

(B) A et B sont indépendants

(C) A implique B

(D) $P(B) = 0$

Q15 La règle de multiplication en chaîne sert à —

(A) calculer une probabilité unique

(B) estimer une régression

(C) décomposer la probabilité d'une séquence d'événements

(D) réaliser un test F

E.2 Variables aléatoires et moments (Q16 à Q28)

Q16 L'espérance $E[X]$ d'une variable aléatoire est —

(A) sa médiane

(B) son mode

(C) sa variance

(D) sa moyenne pondérée par les probabilités

Q17 La variance se calcule par —

(A) $E[X^2] - (E[X])^2$

(B) $E[X^2] + E[X]$

(C) $E[X] - E[X^2]$

(D) $(E[X])^2$

Q18 La variance d'une transformation affine $aX + b$ vaut —

(A) $a\,\mathrm{Var}(X) + b$

(B) $a^2\,\mathrm{Var}(X)$

(C) $a^2\,\mathrm{Var}(X) + b^2$

(D) $a\,\mathrm{Var}(X)$

Q19 Un excès de kurtosis positif indique —

(A) une distribution parfaitement symétrique

(B) des queues plus fines que la normale

(C) des queues plus épaisses que la normale

(D) une variance nulle

Q20 L'asymétrie (skewness) mesure —

(A) la dispersion

(B) la moyenne

(C) l'épaisseur des queues

(D) la dissymétrie de la distribution

Q21 Pour une loi normale, la kurtosis vaut —

(A) 3

(B) 0

(C) 1

(D) l'infini

Q22 La fonction de répartition (CDF) $F(x)$ donne —

(A) la densité au point x

(B) $P(X \leq x)$

(C) $P(X = x)$

(D) l'espérance de X

Q23 Une asymétrie négative signale —

(A) une queue droite plus longue

(B) une distribution symétrique

(C) une queue gauche plus longue

(D) une variance nécessairement élevée

Q24 L'espérance d'une transformation affine $E[aX + b]$ vaut —

(A) $a\,E[X]$

(B) $E[X] + b$

(C) $a^2\,E[X] + b$

(D) $a\,E[X] + b$

Q25 L'écart-type est —

(A) la racine carrée de la variance

(B) le carré de la variance

(C) la moyenne des écarts

(D) la kurtosis

Q26 Une fonction de masse (PMF) décrit —

(A) une variable continue

(B) une variable discrète

(C) une régression

(D) une série temporelle

Q27 Les rendements financiers présentent typiquement —

(A) une kurtosis exactement égale à 3

(B) des queues plus fines que la normale

(C) un excès de kurtosis positif

(D) une variance nulle

Q28 Le moment centré d'ordre 2 est —

(A) l'espérance

(B) l'asymétrie

(C) la kurtosis

(D) la variance

E.3 Distributions usuelles (Q29 à Q43)

Q29 Le nombre de défauts sur n prêts indépendants suit —

(A) une loi binomiale

(B) une loi normale

(C) une loi lognormale

(D) une loi exponentielle

Q30 Pour une loi de Poisson de paramètre λ —

(A) l'espérance dépasse la variance

(B) l'espérance égale la variance, toutes deux valant λ

(C) l'espérance est inférieure à la variance

(D) la variance est nulle

Q31 Le prix d'une action se modélise le plus souvent par —

(A) une loi normale

(B) une loi de Poisson

(C) une loi lognormale

(D) une loi binomiale

Q32 Pour un petit échantillon dont la variance est estimée, on utilise —

(A) la loi normale

(B) la loi de Poisson

(C) la loi binomiale

(D) la loi de Student

Q33 La standardisation d'une variable normale s'écrit —

(A) $z = (x - \mu)/\sigma$

(B) $z = (x - \sigma)/\mu$

(C) $z = x\mu/\sigma$

(D) $z = (x + \mu)/\sigma$

Q34 Pour une binomiale $B(n, p)$, la variance vaut —

(A) np

(B) $np(1 - p)$

(C) $n^2 p$

(D) $p(1 - p)$

Q35 La loi du chi-deux sert principalement aux tests portant sur —

(A) la moyenne

(B) la corrélation

(C) la variance

(D) la pente d'une régression

Q36 La loi exponentielle modélise typiquement —

(A) un comptage d'événements

(B) un prix d'actif

(C) un rendement

(D) un temps d'attente entre événements

Q37 La loi de Fisher (F) sert à —

(A) comparer deux variances

(B) tester une moyenne unique

(C) calculer une covariance

(D) standardiser une variable

Q38 Un mélange de deux lois normales produit —

(A) une distribution uniforme

(B) des queues épaisses

(C) une variance nulle

(D) une symétrie parfaite garantie

Q39 Les pertes opérationnelles (événements rares) se modélisent souvent par —

(A) une loi normale

(B) une loi lognormale

(C) une loi de Poisson

(D) une loi uniforme

Q40 La loi normale est entièrement décrite par —

(A) sa seule moyenne

(B) sa seule variance

(C) sa médiane

(D) sa moyenne et sa variance

Q41 Comparée à la loi normale, la loi de Student a —

(A) des queues plus épaisses

(B) des queues plus fines

(C) exactement la même forme

(D) une variance nulle

Q42 L'espérance d'une loi exponentielle de paramètre λ est —

(A) λ

(B) $1/\lambda$

(C) λ^2

(D) 0

Q43 La loi de Bernoulli décrit —

(A) n essais successifs

(B) un comptage continu

(C) un unique essai binaire

(D) un temps d'attente

E.4 Variables multivariées, covariance et corrélation (Q44 à Q52)

Q44 La covariance $\mathrm{Cov}(X, Y)$ se calcule par —

(A) $E[X]\,E[Y]$

(B) $E[X] + E[Y]$

(C) $\rho\,\sigma_X\sigma_Y$, toujours positif

(D) $E[XY] - E[X]\,E[Y]$

Q45 Le coefficient de corrélation est borné entre —

(A) -1 et $+1$

(B) 0 et 1

(C) 0 et $+\infty$

(D) $-\infty$ et $+\infty$

Q46 Une covariance nulle implique —

(A) l'indépendance des variables

(B) l'absence de relation linéaire

(C) une corrélation égale à 1

(D) une variance nulle

Q47 La variance d'une somme $\mathrm{Var}(X + Y)$ vaut —

(A) $\mathrm{Var}(X) + \mathrm{Var}(Y)$ en toutes circonstances

(B) $\mathrm{Var}(X)\,\mathrm{Var}(Y)$

(C) $\mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X, Y)$

(D) $\mathrm{Var}(X) - \mathrm{Var}(Y)$

Q48 Le coefficient de corrélation ne capte que —

(A) les relations quadratiques

(B) l'indépendance

(C) la variance

(D) les relations linéaires

Q49 L'indépendance de deux variables entraîne —

(A) une covariance nulle

(B) une corrélation égale à 1

(C) une covariance négative

(D) une variance nulle

Q50 La corrélation normalise la covariance en la divisant par —

(A) la somme des moyennes

(B) le produit des écarts-types

(C) la variance totale

(D) le nombre d'observations

Q51 Deux variables corrélées positivement —

(A) varient en sens opposés

(B) sont nécessairement indépendantes

(C) tendent à varier dans le même sens

(D) ont une covariance nulle

Q52 Une corrélation nulle entre deux variables —

(A) prouve leur indépendance

(B) implique une relation quadratique

(C) est mathématiquement impossible

(D) n'exclut pas une dépendance non linéaire

E.5 Estimation, échantillonnage et TCL (Q53 à Q64)

Q53 Le théorème central limite affirme que la moyenne d'un grand échantillon tend vers —

(A) une loi normale

(B) une loi de Poisson

(C) une loi uniforme

(D) une loi lognormale

Q54 L'erreur-type de la moyenne vaut —

(A) σ/n

(B) $\sigma/\sqrt{n}$

(C) σ^2/n

(D) $\sigma\sqrt{n}$

Q55 Pour diviser l'erreur-type par deux, il faut —

(A) doubler la taille de l'échantillon

(B) tripler la taille de l'échantillon

(C) quadrupler la taille de l'échantillon

(D) réduire la taille de l'échantillon

Q56 La variance empirique non biaisée divise la somme des carrés par —

(A) n

(B) $n+1$

(C) n^2

(D) $n-1$

Q57 Un estimateur non biaisé a une espérance —

(A) égale au paramètre estimé

(B) toujours nulle

(C) toujours supérieure au paramètre

(D) infinie

Q58 Un intervalle de confiance à 95 % se lit correctement comme —

(A) 95 % de chance que le paramètre soit dans cet intervalle précis

(B) une procédure qui capture le paramètre dans 95 % des cas

(C) un intervalle faux 95 % du temps

(D) un résultat indépendant de la taille d'échantillon

Q59 Le théorème central limite s'applique —

(A) uniquement à des données déjà normales

(B) uniquement pour $n < 30$

(C) quelle que soit la loi de la population, pour n grand

(D) jamais aux rendements financiers

Q60 L'erreur-type décroît avec la taille d'échantillon en —

(A) $1/n$

(B) $1/n^2$

(C) une constante

(D) $1/\sqrt{n}$

Q61 Un estimateur efficace possède —

(A) la plus faible variance parmi les estimateurs non biaisés

(B) le plus fort biais

(C) une variance infinie

(D) une espérance nulle

Q62 Lorsque σ est inconnu et l'échantillon petit, l'intervalle de confiance utilise —

(A) la loi normale

(B) la loi de Student

(C) la loi de Poisson

(D) la loi binomiale

Q63 Un estimateur convergent —

(A) diverge quand n croît

(B) est toujours biaisé

(C) gagne en précision quand n croît

(D) ne dépend pas des données

Q64 La correction de Bessel rend la variance empirique —

(A) biaisée à la hausse

(B) nulle

(C) systématiquement trop grande

(D) non biaisée

E.6 Tests d'hypothèses (Q65 à Q80)

Q65 L'erreur de type I consiste à —

(A) rejeter H_0 alors qu'elle est vraie

(B) ne pas rejeter H_0 alors qu'elle est fausse

(C) ne jamais rejeter H_0

(D) augmenter la puissance

Q66 La probabilité de l'erreur de type I est —

(A) β

(B) le seuil de signification α

(C) la puissance

(D) égale à 1

Q67 L'erreur de type II consiste à —

(A) rejeter H_0 vraie

(B) rejeter H_0 fausse

(C) ne pas rejeter H_0 alors qu'elle est fausse

(D) fixer le seuil α

Q68 La puissance d'un test est —

(A) α

(B) β

(C) $1 - \alpha$

(D) $1 - \beta$

Q69 À taille d'échantillon fixe, réduire α —

(A) augmente β

(B) réduit β

(C) n'affecte pas β

(D) annule β

Q70 La p-value est —

(A) la probabilité que H_0 soit vraie

(B) la probabilité d'observer une statistique aussi extrême si H_0 est vraie

(C) la probabilité que H_1 soit vraie

(D) toujours égale à 0,05

Q71 On rejette H_0 si —

(A) $\text{p} > \alpha$

(B) $\text{p} = 1$

(C) $\text{p} < \alpha$

(D) la moyenne est nulle

Q72 La statistique de test d'une moyenne s'écrit —

(A) $(\bar{X} - \mu_0)\sqrt{n}$

(B) $(\bar{X} - \mu_0)/n$

(C) $\bar{X}/s$

(D) $(\bar{X} - \mu_0)/(s/\sqrt{n})$

Q73 Un test bilatéral répartit le seuil —

(A) des deux côtés de la distribution

(B) d'un seul côté

(C) au centre uniquement

(D) nulle part

Q74 Ne pas rejeter H_0 signifie —

(A) que H_0 est prouvée vraie

(B) une absence de preuve du contraire

(C) que H_1 est prouvée

(D) que le test a échoué

Q75 Comparer deux variances mobilise —

(A) la loi de Student

(B) la loi normale

(C) la loi de Fisher

(D) la loi de Poisson

Q76 La valeur critique d'un test dépend —

(A) de la seule moyenne

(B) de la seule variance

(C) d'aucun paramètre

(D) du seuil α et de la distribution de référence

Q77 Interpréter la p-value comme $P(H_0 \mid \text{données})$ est —

(A) une erreur d'inversion

(B) parfaitement correct

(C) sans importance

(D) la règle standard

Q78 Une statistique t de 2,0 avec une valeur critique de 2,064 conduit à —

(A) rejeter H_0

(B) ne pas rejeter H_0

(C) une erreur de type I certaine

(D) une p-value nulle

Q79 Le seuil de signification α représente —

(A) la puissance du test

(B) la p-value

(C) la probabilité tolérée d'erreur de type I

(D) la variance

Q80 Confondre les erreurs de type I et II est —

(A) sans effet

(B) une simplification autorisée

(C) une convention admise

(D) une erreur conceptuelle fréquente

E.7 Régression linéaire simple (Q81 à Q92)

Q81 La pente estimée par les moindres carrés vaut —

(A) $\text{Cov}(X,Y)/\text{Var}(X)$

(B) $\text{Var}(X)/\text{Cov}(X,Y)$

(C) $\text{Cov}(X,Y)/\text{Var}(Y)$

(D) $\bar{y}/\bar{x}$

Q82 L'ordonnée à l'origine estimée vaut —

(A) $\bar{y} + \hat{\beta}_1 \bar{x}$

(B) $\bar{y} - \hat{\beta}_1 \bar{x}$

(C) $\bar{x} - \hat{\beta}_1 \bar{y}$

(D) 0

Q83 Le R^2 mesure —

(A) la causalité

(B) la pente

(C) la part de variance de Y expliquée par le modèle

(D) l'erreur-type

Q84 Un R^2 de 0,95 —

(A) prouve une relation causale

(B) est mathématiquement impossible

(C) indique une pente de 0,95

(D) indique un bon ajustement, mais pas une causalité

Q85 La droite de régression passe toujours par —

(A) le point moyen $(\bar{x}, \bar{y})$

(B) l'origine

(C) le point de valeur maximale

(D) aucun point particulier

Q86 La significativité de la pente se teste par —

(A) un test F uniquement

(B) un test t sur le coefficient

(C) le R^2

(D) la covariance

Q87 Sous les hypothèses de Gauss-Markov, le MCO est —

(A) biaisé

(B) inefficace

(C) le meilleur estimateur linéaire non biaisé

(D) non linéaire

Q88 Le R^2 est compris entre —

(A) -1 et 1

(B) $-\infty$ et $+\infty$

(C) 0 et 100 exactement

(D) 0 et 1

Q89 La pente s'interprète comme —

(A) la variation moyenne de Y pour une unité de X

(B) la valeur de Y quand $X = 0$

(C) la corrélation

(D) la variance de Y

Q90 Un t de significativité proche de 2 au seuil de 5 % signifie —

(A) que le coefficient est certainement nul

(B) que le coefficient est à la limite de la significativité

(C) que le R^2 vaut 2

(D) que le test est invalide

Q91 Extrapoler une régression hors du domaine des données est —

(A) recommandé

(B) sans aucun risque

(C) hasardeux, avec un intervalle de prévision élargi

(D) mathématiquement impossible

Q92 L'ordonnée à l'origine représente —

(A) la pente

(B) la corrélation

(C) la variance

(D) la valeur prédite de Y quand $X = 0$

E.8 Régression multiple (Q93 à Q104)

Q93 Le biais de variable omise survient lorsque la variable manquante est —

(A) corrélée à un régresseur inclus et déterminante de Y

(B) sans aucun lien avec Y

(C) indépendante de tout

(D) une simple constante

Q94 La multicolinéarité se manifeste typiquement par —

(A) un R^2 faible

(B) un R^2 élevé accompagné de coefficients non significatifs

(C) une pente nulle

(D) une erreur-type nulle

Q95 Le R^2 ajusté, contrairement au R^2 simple —

(A) croît toujours quand on ajoute des variables

(B) est toujours négatif

(C) peut diminuer si une variable inutile est ajoutée

(D) ignore le nombre de régresseurs

Q96 Le test F en régression multiple teste —

(A) un seul coefficient

(B) la normalité des résidus

(C) l'hétéroscédasticité

(D) la nullité simultanée de tous les coefficients de pente

Q97 Dans une régression multiple, un coefficient s'interprète —

(A) toutes choses égales par ailleurs

(B) sans aucune condition

(C) comme une corrélation brute

(D) comme la moyenne de Y

Q98 Avec m modalités qualitatives, on inclut —

(A) m variables muettes

(B) $m-1$ variables muettes

(C) $m+1$ variables muettes

(D) une seule variable muette

Q99 Le biais de variable omise affecte —

(A) uniquement l'erreur-type

(B) la seule constante

(C) l'estimation (le biais) des coefficients

(D) rien du tout

Q100 La multicolinéarité affecte surtout —

(A) le caractère non biaisé des coefficients

(B) la moyenne de Y

(C) le R^2 global

(D) la précision (la stabilité) des coefficients

Q101 Le R^2 ajusté sert principalement à —

(A) la sélection de modèle, en pénalisant les variables inutiles

(B) tester une moyenne

(C) mesurer la causalité

(D) standardiser les variables

Q102 Inclure m muettes en plus de la constante crée —

(A) un modèle bien spécifié

(B) une colinéarité parfaite

(C) une amélioration du R^2

(D) une réduction du biais

Q103 L'endogénéité (régresseur corrélé au terme d'erreur) —

(A) est sans conséquence

(B) améliore l'estimation

(C) biaise l'estimateur MCO

(D) réduit la variance

Q104 Le coefficient d'un régresseur mesure son effet —

(A) global et inconditionnel

(B) causal garanti

(C) sur la constante

(D) marginal, à autres variables constantes

E.9 Diagnostics de régression (Q105 à Q112)

Q105 L'hétéroscédasticité désigne —

(A) une variance des erreurs non constante

(B) des erreurs corrélées entre elles

(C) une moyenne non nulle des erreurs

(D) une colinéarité entre régresseurs

Q106 En présence d'hétéroscédasticité, les coefficients MCO restent —

(A) biaisés

(B) non biaisés, mais avec des erreurs-types faussées

(C) nuls

(D) infinis

Q107 La statistique de Durbin-Watson détecte —

(A) l'hétéroscédasticité

(B) la multicolinéarité

(C) l'autocorrélation des résidus

(D) la non-normalité

Q108 Une valeur de Durbin-Watson proche de 2 indique —

(A) une forte autocorrélation positive

(B) une autocorrélation négative

(C) de l'hétéroscédasticité

(D) l'absence d'autocorrélation

Q109 On corrige l'hétéroscédasticité par —

(A) des erreurs-types robustes

(B) la suppression de la variable Y

(C) l'ajout de bruit aléatoire

(D) aucune action possible

Q110 L'autocorrélation des résidus est particulièrement fréquente en —

(A) données transversales

(B) séries temporelles

(C) échantillons purement aléatoires

(D) données binaires

Q111 Une erreur de spécification correspond à —

(A) une variance non constante

(B) une multicolinéarité

(C) une forme fonctionnelle inadaptée ou une variable omise

(D) une erreur-type robuste

Q112 Un point influent est —

(A) une variable muette

(B) un régresseur colinéaire

(C) une erreur-type robuste

(D) une observation atypique pesant excessivement sur l'estimation

E.10 Séries temporelles stationnaires (Q113 à Q122)

Q113 Une série stationnaire (au sens faible) présente —

(A) une moyenne, une variance et des autocovariances constantes

(B) une tendance croissante

(C) une variance infinie

(D) une racine unitaire

Q114 Un bruit blanc se caractérise par —

(A) une forte autocorrélation

(B) des autocorrélations nulles, une moyenne nulle et une variance constante

(C) une tendance déterministe

(D) une racine unitaire

Q115 Un AR(1) est stationnaire si —

(A) $\phi > 1$

(B) $\phi = 1$

(C) $|\phi| < 1$

(D) $\phi = 0$ obligatoirement

Q116 La moyenne de long terme d'un AR(1) $x_t = c + \phi x_{t-1} + \varepsilon_t$ vaut —

(A) c

(B) ϕ

(C) $c\,\phi$

(D) $c/(1-\phi)$

Q117 Un modèle MA(1) exprime la valeur en fonction —

(A) du choc courant et du choc précédent

(B) de la seule valeur précédente

(C) d'une tendance déterministe

(D) d'une racine unitaire

Q118 Pour un AR(1), la fonction d'autocorrélation (ACF) —

(A) se coupe nettement après le rang 1

(B) décroît exponentiellement

(C) est constante

(D) est identiquement nulle

Q119 Le retour à la moyenne d'un AR(1) est d'autant plus rapide que —

(A) ϕ est proche de 1

(B) c est grand

(C) $|\phi|$ est petit

(D) la variance est grande

Q120 Un ARMA(p, q) combine —

(A) p tendances

(B) q racines unitaires

(C) p et q composantes saisonnières

(D) p termes autorégressifs et q termes de moyenne mobile

Q121 L'autocorrélation partielle (PACF) d'un AR(1) —

(A) se coupe après le rang 1

(B) décroît lentement

(C) est toujours nulle

(D) est constante

Q122 Un AR(1) avec $|\phi| = 1$ est —

(A) fortement stationnaire

(B) non stationnaire (marche aléatoire)

(C) un bruit blanc

(D) sans aucune mémoire

E.11 Séries temporelles non stationnaires (Q123 à Q130)

Q123 Une marche aléatoire $x_t = x_{t-1} + \varepsilon_t$ —

(A) est stationnaire

(B) revient à une moyenne fixe

(C) possède une racine unitaire et une variance croissante

(D) a une autocorrélation nulle

Q124 Le test de Dickey-Fuller teste —

(A) l'hétéroscédasticité

(B) la normalité

(C) l'autocorrélation

(D) la présence d'une racine unitaire

Q125 Régresser deux séries non stationnaires sans précaution risque de produire —

(A) une régression fallacieuse (corrélation illusoire)

(B) un R^2 nul

(C) une pente nulle

(D) aucun problème

Q126 Pour stationnariser une série intégrée d'ordre 1, on applique —

(A) une exponentielle

(B) une différenciation première

(C) un logarithme obligatoire

(D) une standardisation

Q127 L'hypothèse nulle du test de Dickey-Fuller est —

(A) la stationnarité

(B) l'absence de tendance

(C) la présence d'une racine unitaire (non-stationnarité)

(D) la normalité des résidus

Q128 Deux séries non stationnaires dont une combinaison linéaire est stationnaire sont —

(A) indépendantes

(B) un bruit blanc

(C) hétéroscédastiques

(D) cointégrées

Q129 Une tendance déterministe se corrige par —

(A) une régression sur le temps

(B) une différenciation obligatoire

(C) l'ajout d'une racine unitaire

(D) aucune méthode

Q130 La cointégration fournit la base rigoureuse —

(A) du calcul de la VaR paramétrique

(B) du trading de paires

(C) de la simulation de Monte-Carlo

(D) du test t de Student

E.12 Volatilité : EWMA et GARCH (Q131 à Q142)

Q131 L'EWMA estime la variance en pondérant —

(A) également toutes les observations

(B) davantage les observations anciennes

(C) davantage les observations récentes

(D) uniquement la toute dernière observation

Q132 Dans l'EWMA, un paramètre de lissage λ élevé —

(A) réagit très vite aux chocs

(B) ignore totalement le passé

(C) rend l'estimation instable

(D) lisse davantage l'estimation

Q133 Dans un GARCH(1,1), la persistance vaut —

(A) $\alpha + \beta$

(B) $\alpha - \beta$

(C) ω

(D) $\alpha \times \beta$

Q134 La variance de long terme d'un GARCH(1,1) vaut —

(A) ω

(B) $\omega/(1 - \alpha - \beta)$

(C) $\alpha + \beta$

(D) 0

Q135 La condition de stationnarité d'un GARCH(1,1) est —

(A) $\alpha + \beta > 1$

(B) $\alpha + \beta = 1$

(C) $\alpha + \beta < 1$

(D) $\omega = 0$

Q136 L'EWMA est le cas particulier du GARCH(1,1) obtenu avec —

(A) $\alpha = 0$

(B) $\beta = 0$

(C) $\omega > 0$

(D) $\omega = 0$

Q137 Le regroupement de volatilité (*clustering*) signifie que —

(A) les périodes agitées succèdent aux périodes agitées

(B) la volatilité est constante dans le temps

(C) les chocs sont strictement indépendants

(D) la variance est nulle

Q138 Une persistance $\alpha + \beta$ proche de 1 implique —

(A) un retour à la moyenne très rapide

(B) des chocs de volatilité très durables

(C) une volatilité constante

(D) une variance nulle

Q139 La valeur de λ retenue par RiskMetrics en données quotidiennes est —

(A) $0{,}50$

(B) $0{,}80$

(C) $0{,}94$

(D) $1{,}00$

Q140 En période de stress, les corrélations entre actifs tendent à —

(A) disparaître

(B) rester parfaitement stables

(C) devenir systématiquement négatives

(D) augmenter, réduisant les bénéfices de diversification

Q141 La volatilité réalisée se calcule à partir —

(A) des rendements passés observés

(B) d'une hypothèse a priori

(C) du seul prix courant

(D) de la moyenne des prix

Q142 Un GARCH, contrairement à un EWMA, intègre —

(A) uniquement le dernier rendement

(B) un retour vers une variance de long terme

(C) aucune mémoire

(D) une variance strictement constante

E.13 Simulation et bootstrap (Q143 à Q147)

Q143 L'erreur d'une estimation de Monte-Carlo décroît en —

(A) $1/N$

(B) $1/N^2$

(C) $1/\sqrt{N}$

(D) une constante

Q144 Pour diviser l'erreur de Monte-Carlo par 10, il faut multiplier N par —

(A) 10

(B) 5

(C) 2

(D) 100

Q145 Les variables antithétiques servent à —

(A) réduire la variance de l'estimation

(B) augmenter le biais

(C) accélérer l'apparition du biais

(D) supprimer des tirages

Q146 Le bootstrap consiste à —

(A) supposer une loi normale

(B) rééchantillonner les données observées avec remise

(C) calculer une simple moyenne

(D) tester une hypothèse

Q147 L'avantage principal du bootstrap est de —

(A) exiger une loi paramétrique

(B) ignorer les données observées

(C) préserver les propriétés empiriques (queues épaisses) sans hypothèse de loi

(D) réduire la taille de l'échantillon

E.14 Introduction au machine learning (Q148 à Q150)

Q148 L'apprentissage supervisé se caractérise par —

(A) l'absence totale de données

(B) le *clustering*

(C) la réduction de dimension

(D) une sortie étiquetée à prédire

Q149 Le surapprentissage (*overfitting*) se produit quand un modèle —

(A) épouse le bruit des données d'entraînement et généralise mal

(B) est trop simple

(C) ignore les données

(D) présente un biais élevé

Q150 Le compromis biais-variance vise à —

(A) maximiser l’erreur d’entraînement

(B) minimiser l’erreur hors échantillon

(C) supprimer l’étape de validation

(D) ignorer le jeu de test

Partie F — Corrigé commenté

Chaque réponse renvoie à la section de cours et, le cas échéant, à l'exercice ou au cas correspondant.

F.1 Corrigé — Q1 à Q15 (probabilités et théorème de Bayes)

Q1 — **A** *§2.1* Bayes **inverse un conditionnement** : passer de $P(B \mid A)$ à $P(A \mid B)$.

Q2 — **B** *§2.1* Par définition, $P(A \mid B) = P(A \cap B)/P(B)$.

Q3 — **C** *§2.1* L'indépendance équivaut à $P(A \cap B) = P(A)\,P(B)$.

Q4 — **D** *§2.1* La loi des probabilités totales **décompose** une probabilité selon une partition.

Q5 — **A** *§2.1 · ex. 1* Événement rare : un test positif est **souvent un faux positif** (valeur prédictive faible).

Q6 — **B** *§2.1* Règle de multiplication : $P(A \cap B) = P(A \mid B)\,P(B)$.

Q7 — **C** *§2.1* La probabilité a priori est celle **avant toute observation**.

Q8 — **D** *§2.1* Confondre $P(A \mid B)$ et $P(B \mid A)$ est une **erreur d'inférence** classique.

Q9 — **A** *§2.1* Pour des événements dépendants, il faut la **probabilité conditionnelle**.

Q10 — **B** *§2.1* Mutuellement exclusifs signifie $P(A \cap B) = 0$.

Q11 — **C** *§2.1* La vraisemblance est $P(B \mid A)$.

Q12 — **D** *§2.1* Un taux de base faible **réduit la valeur prédictive positive** d'un test.

Q13 — **A** *§2.1* Règle d'addition : $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Q14 — **B** *§2.1* $P(A \mid B) = P(A)$ caractérise l'**indépendance**.

Q15 — **C** *§2.1* La règle de multiplication en chaîne **décompose une séquence** d'événements.

F.2 Corrigé — Q16 à Q28 (variables aléatoires et moments)

Q16 — **D** *§2.2* L'espérance est la **moyenne pondérée** par les probabilités.

Q17 — **A** *§2.2* $\mathrm{Var}(X) = E[X^2] - (E[X])^2$.

Q18 — **B** *§2.2* $\mathrm{Var}(aX + b) = a^2\,\mathrm{Var}(X)$: la constante additive n'affecte pas la dispersion.

Q19 — **C** *§2.2* Un excès de kurtosis positif signale des **queues plus épaisses** que la normale.

Q20 — **D** *§2.2* La skewness mesure l'**asymétrie** de la distribution.

Q21 — **A** *§2.2* Pour une loi normale, la kurtosis vaut 3.

Q22 — **B** *§2.2* La CDF donne $P(X \leq x)$.

Q23 — **C** *§2.2* Une skewness négative signale une **queue gauche** plus longue.

Q24 — **D** *§2.2* $E[aX + b] = a\,E[X] + b$.

Q25 — **A** *§2.2* L'écart-type est la **racine carrée** de la variance.

Q26 — **B** *§2.2* Une PMF décrit une variable **discrète**.

Q27 — **C** *§2.2* Les rendements financiers ont un **excès de kurtosis positif**.

Q28 — **D** *§2.2* Le moment centré d'ordre 2 est la **variance**.

F.3 Corrigé — Q29 à Q43 (distributions usuelles)

Q29 — **A** *§2.3* Le nombre de défauts sur n prêts indépendants suit une loi **binomiale**.

Q30 — **B** *§2.3* Pour une loi de Poisson, $E = \text{Var} = \lambda$.

Q31 — **C** *§2.3* Un prix d'action se modélise par une loi **lognormale** (toujours positive).

Q32 — **D** *§2.3* Petit échantillon à variance estimée : loi de **Student**.

Q33 — **A** *§2.3* Standardisation : $z = (x - \mu)/\sigma$.

Q34 — **B** *§2.3* Pour une binomiale $B(n, p)$, $\text{Var} = np(1 - p)$.

Q35 — **C** *§2.3* La loi du chi-deux sert aux tests sur la **variance**.

Q36 — **D** *§2.3* La loi exponentielle modélise un **temps d'attente** entre événements.

Q37 — **A** *§2.3* La loi de Fisher sert à **comparer deux variances**.

Q38 — **B** *§2.3* Un mélange de normales produit des **queues épaisses**.

Q39 — **C** *§2.3* Les pertes opérationnelles rares suivent une loi de **Poisson**.

Q40 — **D** *§2.3* La loi normale est entièrement décrite par sa **moyenne et sa variance**.

Q41 — **A** *§2.3* La loi de Student a des **queues plus épaisses** que la normale.

Q42 — **B** *§2.3* L'espérance d'une loi exponentielle de paramètre λ est $1/\lambda$.

Q43 — **C** *§2.3* La loi de Bernoulli décrit un **unique essai binaire**.

F.4 Corrigé — Q44 à Q52 (covariance et corrélation)

Q44 — **D** *§2.4* $\text{Cov}(X, Y) = E[XY] - E[X]\,E[Y]$.

Q45 — **A** *§2.4* La corrélation est bornée entre -1 et $+1$.

Q46 — **B** *§2.4* Une covariance nulle signale l'**absence de relation linéaire**, non l'indépendance.

Q47 — **C** *§2.4* $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\,\text{Cov}(X, Y)$.

Q48 — **D** *§2.4* La corrélation ne capte que les relations **linéaires**.

Q49 — **A** *§2.4* L'indépendance entraîne une **covariance nulle**.

Q50 — **B** *§2.4* La corrélation divise la covariance par le **produit des écarts-types**.

Q51 — **C** *§2.4* Deux variables corrélées positivement varient **dans le même sens**.

Q52 — **D** *§2.4* Une corrélation nulle **n'exclut pas une dépendance non linéaire**.

F.5 Corrigé — Q53 à Q64 (estimation et TCL)

Q53 — **A** *§2.5* Le TCL : la moyenne d'échantillon tend vers une loi **normale**.

Q54 — **B** *§2.5* L'erreur-type vaut $\sigma/\sqrt{n}$.

Q55 — **C** *§2.5* Diviser l'erreur-type par 2 exige de **quadrupler** l'échantillon.

Q56 — **D** *§2.5* La variance empirique non biaisée divise par $n - 1$.

Q57 — **A** *§2.5* Un estimateur non biaisé a une espérance **égale au paramètre**.

Q58 — **B** *§2.5* Un IC à 95 % résulte d'une procédure qui capture le paramètre dans **95 % des cas**.

Q59 — **C** *§2.5* Le TCL vaut **quelle que soit la loi** de la population, pour n grand.

Q60 — **D** *§2.5* L'erreur-type décroît en $1/\sqrt{n}$.

Q61 — **A** *§2.5* Un estimateur efficace a la **plus faible variance** parmi les non biaisés.

Q62 — **B** *§2.5* σ inconnu et n petit : on utilise la loi de **Student**.

Q63 — **C** *§2.5* Un estimateur convergent **gagne en précision** quand n croît.

Q64 — **D** *§2.5* La correction de Bessel rend la variance empirique **non biaisée**.

F.6 Corrigé — Q65 à Q80 (tests d'hypothèses)

Q65 — **A** *§2.6* L'erreur de type I consiste à **rejeter H_0 alors qu'elle est vraie**.

Q66 — **B** *§2.6* Sa probabilité est le **seuil** de signification α.

Q67 — **C** *§2.6* L'erreur de type II consiste à **ne pas rejeter H_0 fausse**.

Q68 — **D** *§2.6* La puissance vaut $1 - \beta$.

Q69 — **A** *§2.6* À n fixe, réduire α **augmente** β.

Q70 — **B** *§2.6* La p-value : probabilité d'une statistique **aussi extrême** sous H_0.

Q71 — **C** *§2.6* On rejette H_0 si $p < \alpha$.

Q72 — **D** *§2.6 · ex. 7* Statistique : $t = (\bar{X} - \mu_0)/(s/\sqrt{n})$.

Q73 — **A** *§2.6* Un test bilatéral répartit le seuil **des deux côtés**.

Q74 — **B** *§2.6* Ne pas rejeter H_0 est une **absence de preuve du contraire**.

Q75 — **C** *§2.6* Comparer deux variances mobilise la loi de **Fisher**.

Q76 — **D** *§2.6* La valeur critique dépend du **seuil α et de la distribution**.

Q77 — **A** *§2.6* Lire la p-value comme $P(H_0 \mid \text{données})$ est une **erreur d'inversion**.

Q78 — **B** *§2.6 · ex. 7* $|t| = 2{,}0 < 2{,}064$: on **ne rejette pas** H_0.

Q79 — **C** *§2.6* α est la probabilité tolérée d'**erreur de type I**.

Q80 — **D** *§2.6* Confondre les erreurs I et II est une **erreur conceptuelle** fréquente.

F.7 Corrigé — Q81 à Q92 (régression linéaire simple)

Q81 — **A** *§2.7 · ex. 8* La pente MCO vaut $\text{Cov}(X, Y)/\text{Var}(X)$.

Q82 — **B** *§2.7 · ex. 8* L'ordonnée à l'origine vaut $\bar{y} - \hat{\beta}_1 \bar{x}$.

Q83 — **C** *§2.7* Le R^2 mesure la part de **variance de Y expliquée** par le modèle.

Q84 — **D** *§2.7* Un R^2 élevé indique un bon ajustement, **pas une causalité**.

Q85 — **A** *§2.7* La droite de régression passe toujours par le **point moyen**.

Q86 — **B** *§2.7* La significativité de la pente se teste par un **test t**.

Q87 — **C** *§2.7* Sous Gauss-Markov, le MCO est le **meilleur estimateur linéaire non biaisé**.

Q88 — **D** *§2.7* Le R^2 est compris entre **0 et 1**.

Q89 — **A** *§2.7* La pente est la variation moyenne de Y pour **une unité de** X.

Q90 — **B** *§2.7* Un $t \approx 2$ à 5 % place le coefficient à la **limite de significativité**.

Q91 — **C** *§2.7* Extrapoler hors du domaine est **hasardeux** (intervalle de prévision élargi).

Q92 — **D** *§2.7* L'ordonnée à l'origine est la valeur prédite de Y quand $X = 0$.

F.8 Corrigé — Q93 à Q104 (régression multiple)

Q93 — **A** *§2.8* Le biais de variable omise vient d'une variable **corrélée à un régresseur et déterminante de** Y.

Q94 — **B** *§2.8* La multicolinéarité donne un R^2 élevé avec des coefficients **non significatifs**.

Q95 — **C** *§2.8* Le R^2 ajusté **peut diminuer** si l'on ajoute une variable inutile.

Q96 — **D** *§2.8* Le test F teste la **nullité simultanée** des coefficients de pente.

Q97 — **A** *§2.8* Un coefficient s'interprète **toutes choses égales par ailleurs**.

Q98 — **B** *§2.8* Avec m modalités, on inclut $m - 1$ **muettes**.

Q99 — **C** *§2.8* Le biais de variable omise fausse l'**estimation** des coefficients.

Q100 — **D** *§2.8* La multicolinéarité affecte la **stabilité** (précision) des coefficients.

Q101 — **A** *§2.8* Le R^2 ajusté sert à la **sélection de modèle**.

Q102 — **B** *§2.8* Inclure m muettes plus la constante crée une **colinéarité parfaite**.

Q103 — **C** *§2.9* L'endogénéité **biaise l'estimateur MCO**.

Q104 — **D** *§2.8* Un coefficient mesure l'effet **marginal, à autres variables constantes**.

F.9 Corrigé — Q105 à Q112 (diagnostics de régression)

Q105 — **A** *§2.9* L'hétéroscédasticité est une **variance des erreurs non constante**.

Q106 — **B** *§2.9* Les coefficients restent **non biaisés**, mais les erreurs-types sont faussées.

Q107 — **C** *§2.9* La statistique de Durbin-Watson détecte l'**autocorrélation** des résidus.

Q108 — **D** *§2.9* Un Durbin-Watson proche de 2 indique l'**absence d'autocorrélation**.

Q109 — **A** *§2.9* On corrige l'hétéroscédasticité par des **erreurs-types robustes**.

Q110 — **B** *§2.9* L'autocorrélation des résidus est fréquente en **séries temporelles**.

Q111 — **C** *§2.9* Une erreur de spécification est une **forme fonctionnelle inadaptée** ou une variable omise.

Q112 — **D** *§2.9* Un point influent est une **observation atypique** pesant excessivement sur l'estimation.

F.10 Corrigé — Q113 à Q122 (séries temporelles stationnaires)

Q113 — **A** *§2.10* Une série stationnaire a moyenne, variance et autocovariances **constantes**.

Q114 — **B** *§2.10* Un bruit blanc a des autocorrélations **nulles** et une variance constante.

Q115 — **C** *§2.10* Un AR(1) est stationnaire si $|\phi| < 1$.

Q116 — **D** *§2.10 · ex. 12* La moyenne de long terme d'un AR(1) vaut $c/(1-\phi)$.

Q117 — **A** *§2.10* Un MA(1) dépend du choc courant et du **choc précédent**.

Q118 — **B** *§2.10* L'ACF d'un AR(1) **décroît exponentiellement**.

Q119 — **C** *§2.10* Le retour à la moyenne est plus rapide quand $|\phi|$ est **petit**.

Q120 — **D** *§2.10* Un ARMA combine termes autorégressifs et termes de **moyenne mobile**.

Q121 — **A** *§2.10* La PACF d'un AR(1) **se coupe après le rang 1**.

Q122 — **B** *§2.10* Un AR(1) avec $|\phi| = 1$ est une **marche aléatoire** (non stationnaire).

F.11 Corrigé — Q123 à Q130 (séries temporelles non stationnaires)

Q123 — **C** *§2.11* Une marche aléatoire possède une **racine unitaire** et une variance croissante.

Q124 — **D** *§2.11* Le test de Dickey-Fuller teste la présence d'une **racine unitaire**.

Q125 — **A** *§2.11* Régresser des séries non stationnaires produit une régression **fallacieuse**.

Q126 — **B** *§2.11* On stationnarise une série $I(1)$ par une **différenciation** première.

Q127 — **C** *§2.11* L'hypothèse nulle de Dickey-Fuller est la **non-stationnarité** (racine unitaire).

Q128 — **D** *§2.11* Deux séries dont une combinaison linéaire est stationnaire sont **cointégrées**.

Q129 — **A** *§2.11* Une tendance déterministe se corrige par une **régression sur le temps**.

Q130 — **B** *§2.11* La cointégration est la base rigoureuse du **trading de paires**.

F.12 Corrigé — Q131 à Q142 (volatilité : EWMA et GARCH)

Q131 — **C** *§2.12* L'EWMA pondère davantage les observations **récentes**.

Q132 — **D** *§2.12* Un λ élevé **lisse** davantage l'estimation.

Q133 — **A** *§2.12 · ex. 10* Dans un GARCH(1,1), la persistance est $\alpha + \beta$.

Q134 — **B** *§2.12 · ex. 10* La variance de long terme vaut $\omega/(1-\alpha-\beta)$.

Q135 — **C** *§2.12* La stationnarité d'un GARCH(1,1) exige $\alpha + \beta < 1$.

Q136 — **D** *§2.12* L'EWMA est le GARCH(1,1) avec $\omega = 0$.

Q137 — **A** *§2.12* Le clustering signifie que les périodes agitées **se succèdent**.

Q138 — **B** *§2.12* Une persistance proche de 1 implique des chocs **durables**.

Q139 — **C** *§2.12 · ex. 9* RiskMetrics retient $\lambda = 0{,}94$ en données quotidiennes.

Q140 — **D** *§2.12* En stress, les corrélations **augmentent**, réduisant la diversification.

Q141 — **A** *§2.12* La volatilité réalisée se calcule sur les **rendements passés observés**.

Q142 — **B** *§2.12* Un GARCH intègre un retour vers une variance de **long terme**.

F.13 Corrigé — Q143 à Q147 (simulation et bootstrap)

Q143 — **C** *§2.13 · ex. 11* L'erreur de Monte-Carlo décroît en $1/\sqrt{N}$.

Q144 — **D** *§2.13 · ex. 11* Diviser l'erreur par 10 exige de multiplier N par **100**.

Q145 — **A** *§2.13* Les variables antithétiques servent à **réduire la variance**.

Q146 — **B** *§2.13* Le bootstrap rééchantillonne les données **avec remise**.

Q147 — **C** *§2.13* Le bootstrap préserve les propriétés empiriques **sans hypothèse de loi**.

F.14 Corrigé — Q148 à Q150 (machine learning)

Q148 — **D** *§2.14* L'apprentissage supervisé se caractérise par une sortie **étiquetée** à prédire.

Q149 — **A** *§2.14 · cas 49* Le surapprentissage épouse le bruit et **généralise mal**.

Q150 — **B** *§2.14 · cas 50* Le compromis biais-variance vise à minimiser l'erreur **hors échantillon**.

Fin du Book 2 — Quantitative Analysis

Cours (14 sections) · 50 études de cas · 12 exercices corrigés · méthodologie · 150 QCM commentés