FRM® Part I · Quantitative Analysis

Book 2 · Chapitre 7

Linear Regression

La régression linéaire simple

Expliquer, ajuster, tester une relation

Approfondissement quantitatif complet

Cours illustré · définitions · démonstrations · 200 études de cas · conseils méthodologiques · 200 QCM commentés

Support d'étude — questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel — pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
7.1 — Le modèle de régression linéaire . . . 3
7.2 — L'estimation par les moindres carrés ordinaires (MCO) . . . 4
7.3 — Les hypothèses de Gauss–Markov et le théorème BLUE . . . 4
7.4 — La décomposition de la variance et le coefficient de détermination . . . 5
7.5 — L'erreur-type de la régression et des coefficients . . . 6
7.6 — Tester la significativité des coefficients . . . 6
7.7 — Intervalles de confiance et de prévision . . . 7
7.8 — Le test F de significativité globale . . . 7
7.9 — L'interprétation des coefficients : bêta, alpha et au-delà . . . 8
7.10 — Les violations d'hypothèses et leurs conséquences . . . 8
7.11 — Aperçu de la régression multiple et du R^2 ajusté . . . 9
7.12 — Synthèse : la régression de bout en bout . . . 10

Partie B — 200 études de cas pratiques **11**
Bloc 1 — Le modèle de régression et sa terminologie . . . 11
Bloc 2 — Estimation par les moindres carrés (MCO) . . . 12
Bloc 3 — Hypothèses de Gauss–Markov et BLUE . . . 14
Bloc 4 — Décomposition de la variance et R^2 . . . 15
Bloc 5 — Erreurs-types de la régression et des coefficients . . . 17
Bloc 6 — Tests de significativité des coefficients . . . 18
Bloc 7 — Intervalles de confiance et de prévision . . . 19
Bloc 8 — Test F de significativité globale . . . 21
Bloc 9 — Violations d'hypothèses et diagnostics . . . 22
Bloc 10 — Régression multiple, R^2 ajusté et synthèse . . . 23

Partie C — Méthodologie, formulaire et astuces **25**
C.1 — Formulaire de la régression . . . 25
C.2 — Population vs échantillon en régression . . . 25
C.3 — Carte de décision : quel outil pour quelle question ? . . . 25
C.4 — Glossaire bilingue . . . 26
C.5 — Méthode d'analyse en sept étapes . . . 27
C.6 — Les dix pièges classiques . . . 27
C.7 — Astuces de calcul rapide . . . 27

Partie D — 200 questions à choix multiple **28**
Thème 1 — Le modèle de régression et sa terminologie . . . 28
Thème 2 — Estimation par les moindres carrés (MCO) . . . 31
Thème 3 — Hypothèses de Gauss–Markov et BLUE . . . 34
Thème 4 — Décomposition de la variance et R^2 . . . 37
Thème 5 — Erreurs-types de la régression et des coefficients . . . 40
Thème 6 — Tests de significativité des coefficients . . . 43
Thème 7 — Intervalles de confiance et de prévision . . . 46
Thème 8 — Test F de significativité globale . . . 49
Thème 9 — Violations d'hypothèses et diagnostics . . . 51
Thème 10 — Régression multiple, R^2 ajusté et synthèse . . . 54

Partie E — Corrigé commenté des 200 QCM **58**
Thème 1 — Le modèle de régression et sa terminologie . . . 58
Thème 2 — Estimation par les moindres carrés (MCO) . . . 58
Thème 3 — Hypothèses de Gauss–Markov et BLUE . . . 59
Thème 4 — Décomposition de la variance et R^2 . . . 59
Thème 5 — Erreurs-types de la régression et des coefficients . . . 60
Thème 6 — Tests de significativité des coefficients . . . 61

Thème 7 — Intervalles de confiance et de prévision 61
Thème 8 — Test F de significativité globale 62
Thème 9 — Violations d'hypothèses et diagnostics 62
Thème 10 — Régression multiple, R^2 ajusté et synthèse 63
Grille récapitulative des réponses 63

Partie A --- Cours approfondi

Le chapitre 6 testait des hypothèses sur un paramètre isolé. Le chapitre 7 franchit un pas décisif : modéliser la **relation** entre deux variables. Comment le rendement d'une action dépend-il de celui du marché ? Un spread de crédit varie-t-il avec la notation ? La **régression linéaire** est l'outil universel pour quantifier, ajuster et tester de telles relations — la brique de base de l'économétrie financière, du calcul du bêta au modèle à facteurs.

La régression répond à trois besoins distincts : **décrire** (résumer un nuage de points par une droite), **expliquer** (mesurer combien de la variabilité d'une variable est capturée par une autre) et **prévoir** (estimer une valeur non observée). Le chapitre articule le modèle de population, la méthode d'estimation par **moindres carrés ordinaires** (MCO), les conditions qui rendent cette estimation optimale (**Gauss–Markov, BLUE**), la mesure d'ajustement ($\mathbf{R^2}$), et surtout l'**inférence** — tests t sur les coefficients, test F global, intervalles de confiance et de prévision — qui prolonge directement l'appareil du chapitre 6.

Le fil rouge financier : le bêta

L'application phare de la régression en finance est le **bêta de marché**. En régressant les rendements excédentaires d'un actif sur ceux du marché, la **pente** estimée est le bêta (sensibilité systématique) et l'**ordonnée à l'origine** est l'alpha de Jensen (surperformance). Tout ce chapitre peut se lire à travers ce prisme : estimer le bêta (MCO), mesurer la qualité de l'ajustement (R^2), et tester si l'alpha est significativement positif (test t).

7.1 --- Le modèle de régression linéaire

La régression pose une relation linéaire entre une variable à expliquer et une variable explicative, entachée d'un aléa.

Modèle de régression linéaire simple

Le **modèle de population** relie la variable **dépendante** Y (expliquée, régressande) à la variable **indépendante** X (explicative, régresseur) :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \qquad i = 1, \dots, n,$$

où β_0 est l'**ordonnée à l'origine** (intercept), β_1 la **pente** (slope), et ε_i le **terme d'erreur** (aléa) captant tout ce que X n'explique pas.

Interprétation des coefficients

$$\beta_1 = \frac{\partial\, \mathbb{E}[Y \mid X]}{\partial X} \quad \text{(variation de } Y \text{ pour une unité de } X\text{)}; \qquad \beta_0 = \mathbb{E}[Y \mid X = 0].$$

$$\mathbb{E}[Y \mid X] = \beta_0 + \beta_1 X \quad \text{(la droite de régression est l'espérance conditionnelle)}.$$

Population vs échantillon — la distinction clé

Comme au chapitre 5, il faut distinguer les **vrais** paramètres β_0, β_1 (inconnus, de population) de leurs **estimations** $\hat{\beta}_0, \hat{\beta}_1$ (calculées sur l'échantillon). Le modèle estimé s'écrit $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ (valeurs ajustées, *fitted*), et les **résidus** $e_i = Y_i - \hat{Y}_i$ estiment les erreurs inobservables ε_i. Confondre erreur (population) et résidu (échantillon) est un contresens fréquent.

7.2 --- L'estimation par les moindres carrés ordinaires (MCO)

Parmi toutes les droites possibles, les MCO choisissent celle qui minimise la somme des carrés des écarts verticaux aux points.

Moindres carrés ordinaires

La méthode des **moindres carrés ordinaires** (MCO, *OLS*) estime $\hat{\beta}_0, \hat{\beta}_1$ en minimisant la **somme des carrés des résidus** :

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{b_0, b_1} \sum_{i=1}^{n} \left(Y_i - b_0 - b_1 X_i\right)^2.$$

Estimateurs MCO

$$\hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2} = \frac{s_{XY}}{s_X^2} = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)} = r_{XY} \frac{s_Y}{s_X};$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Démonstration

Dérivation par les conditions du premier ordre. On annule les dérivées partielles de $S(b_0, b_1) = \sum_i (Y_i - b_0 - b_1 X_i)^2$.

$\frac{\partial S}{\partial b_0} = -2 \sum_i (Y_i - b_0 - b_1 X_i) = 0 \Rightarrow \sum_i e_i = 0 \Rightarrow \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}$ (la droite passe par le point moyen $(\bar{X}, \bar{Y})$).

$\frac{\partial S}{\partial b_1} = -2 \sum_i X_i (Y_i - b_0 - b_1 X_i) = 0 \Rightarrow \sum_i X_i e_i = 0.$

En substituant $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$ dans la seconde équation et en réarrangeant, on obtient $\hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}$.

Les deux **équations normales** imposent des résidus de somme nulle et non corrélés avec X.

La pente comme covariance standardisée

La formule $\hat{\beta}_1 = s_{XY} / s_X^2$ éclaire le lien avec le chapitre 5 : la pente est la **covariance** entre X et Y rapportée à la **variance** de X. En finance, régresser le rendement d'un actif sur celui du marché donne directement $\hat{\beta} = \mathrm{Cov}(R_a, R_m) / \mathrm{Var}(R_m)$ — la définition même du bêta. Noter la relation $\hat{\beta}_1 = r_{XY} (s_Y / s_X)$: la pente combine la corrélation et le rapport des dispersions.

7.3 --- Les hypothèses de Gauss--Markov et le théorème BLUE

Les MCO ne sont optimaux que sous certaines conditions ; les connaître, c'est savoir quand faire confiance à une régression.

Hypothèses de Gauss–Markov

Les MCO reposent sur : **(H1) linéarité** des paramètres ; **(H2) exogénéité** $\mathbb{E}[\varepsilon_i \mid X] = 0$ (l'erreur est en moyenne nulle et non liée à X) ; **(H3) homoscédasticité** $\mathrm{Var}(\varepsilon_i) = \sigma^2$ constante ; **(H4) absence d'autocorrélation** $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$; **(H5) variabilité** de X (non constant). Pour l'*inférence*, on ajoute souvent **(H6) normalité** des erreurs.

Théorème de Gauss–Markov

Sous les hypothèses (H1)–(H5), les estimateurs MCO sont **BLUE** : *Best Linear Unbiased Estimators* — de tous les estimateurs linéaires et sans biais de β_0, β_1, ils ont la **variance minimale**.

$$\mathbb{E}[\hat{\beta}_1] = \beta_1 \text{ (sans biais)}; \qquad \mathrm{Var}(\hat{\beta}_1) \text{ minimale parmi les estimateurs linéaires sans biais.}$$

Le rôle de chaque hypothèse

Chaque hypothèse protège une propriété. L'**exogénéité** (H2) est la plus critique : sa violation (variable omise corrélée à X, causalité inverse) rend $\hat{\beta}_1$ **biaisé** — c'est le péché capital de l'économétrie. L'**homoscédasticité** (H3) et l'**absence d'autocorrélation** (H4) ne biaisent pas $\hat{\beta}_1$ mais faussent ses **erreurs-types**, donc les tests. La **normalité** (H6) n'est requise que pour la validité exacte des tests t et F à petit échantillon (le TCL prend le relais à grand n).

7.4 --- La décomposition de la variance et le coefficient de détermination

Une régression « explique » une partie de la variabilité de Y. Quantifier cette part est l'objet du R^2.

Décomposition de la somme des carrés

La variabilité totale de Y se décompose en une part expliquée par la régression et une part résiduelle :

$$\underbrace{\sum_i (Y_i - \bar{Y})^2}_{\text{TSS (totale)}} = \underbrace{\sum_i (\hat{Y}_i - \bar{Y})^2}_{\text{ESS (expliquée)}} + \underbrace{\sum_i (Y_i - \hat{Y}_i)^2}_{\text{RSS (résiduelle)}}.$$

Démonstration

Pourquoi la décomposition tient. Écrivons $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + (Y_i - \hat{Y}_i) = (\hat{Y}_i - \bar{Y}) + e_i$. En élevant au carré et en sommant :

$$\mathrm{TSS} = \mathrm{ESS} + \mathrm{RSS} + 2\sum_i (\hat{Y}_i - \bar{Y}) e_i.$$

Le terme croisé s'annule : $\sum_i (\hat{Y}_i - \bar{Y}) e_i = \hat{\beta}_1 \sum_i (X_i - \bar{X}) e_i = 0$ en vertu des équations normales ($\sum_i X_i e_i = 0$ et $\sum_i e_i = 0$). D'où l'orthogonalité parfaite entre valeurs ajustées et résidus, et la décomposition additive.

Coefficient de détermination R^2

Le $\mathbf{R^2}$ est la fraction de la variance de Y expliquée par la régression :

$$R^2 = \frac{\mathrm{ESS}}{\mathrm{TSS}} = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}} \in [0, 1].$$

R^2 en régression simple

$$R^2 = r_{XY}^2 \qquad \text{(le carré de la corrélation entre } X \text{ et } Y\text{)}.$$

$R^2 = 1$: ajustement parfait (points alignés); $\qquad R^2 = 0$: aucun pouvoir explicatif.

Lire un R^2 en finance

Un R^2 de $0{,}64$ signifie que $64\,\%$ de la variance des rendements de l'actif est expliquée par le marché ; les $36\,\%$ restants sont du risque **spécifique** (idiosyncratique, diversifiable). En régression simple, $R^2 = r^2$: une corrélation de $0{,}8$ donne un R^2 de $0{,}64$. Attention : un R^2 élevé n'implique ni causalité, ni bonne spécification, ni absence de biais — c'est une mesure d'**ajustement**, pas de validité. Un R^2 faible est d'ailleurs normal et acceptable pour des rendements d'actifs individuels.

7.5 --- L'erreur-type de la régression et des coefficients

Les estimateurs $\hat{\beta}$ sont des variables aléatoires ; leur variabilité se mesure par des erreurs-types, prérequis de tout test.

Erreur-type de la régression

L'**erreur-type de la régression** (SER, ou écart-type des résidus) estime σ, l'écart-type des erreurs :

$$s_e = \text{SER} = \sqrt{\frac{\text{RSS}}{n-2}} = \sqrt{\frac{\sum_i e_i^2}{n-2}}.$$

Le diviseur est $n-2$: deux degrés de liberté sont consommés par l'estimation de β_0 et β_1.

Erreurs-types des coefficients

$$\text{SE}(\hat{\beta}_1) = \frac{s_e}{\sqrt{\sum_i (X_i - \bar{X})^2}} = \frac{s_e}{s_X\sqrt{n-1}}; \qquad \text{SE}(\hat{\beta}_0) = s_e\sqrt{\frac{1}{n} + \frac{\bar{X}^2}{\sum_i (X_i - \bar{X})^2}}.$$

Ce qui rend $\hat{\beta}_1$ précis

$\text{SE}(\hat{\beta}_1)$ diminue quand : (1) les résidus sont petits (s_e faible, bon ajustement) ; (2) X est très dispersé ($\sum (X_i - \bar{X})^2$ grand) ; (3) l'échantillon est grand (n). Intuition : une pente s'estime d'autant mieux que les points couvrent un large éventail de X — régresser sur un X quasi constant donne une pente très incertaine. C'est pourquoi un bêta estimé sur une période de marché calme (faible dispersion des rendements) est moins fiable.

7.6 --- Tester la significativité des coefficients

Le cœur de l'inférence : le coefficient est-il significativement différent de zéro ? On applique l'appareil du chapitre 6.

Test de significativité d'un coefficient

Pour tester $H_0 : \beta_1 = 0$ (le régresseur n'a aucun effet) contre $H_1 : \beta_1 \neq 0$, la statistique est

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2} \quad \text{sous } H_0.$$

Plus généralement, pour $H_0 : \beta_1 = \beta_1^*$: $t = (\hat{\beta}_1 - \beta_1^*)/\,\text{SE}(\hat{\beta}_1)$.

Décision et lien avec le chapitre 6

Rejeter H_0 si $|t| > t_{n-2;\,1-\alpha/2}$ (valeur critique), ou si $p \le \alpha$.

Degrés de liberté : $n-2$ (deux paramètres estimés).

Tester l'alpha et le bêta d'un fonds

On régresse les rendements excédentaires d'un fonds sur ceux du marché : $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$. **Tester l'alpha** : $H_0 : \beta_0 = 0$ — l'ordonnée à l'origine est-elle significativement positive (surperformance) ? **Tester le bêta** : souvent $H_0 : \beta_1 = 1$ (le fonds a-t-il le même risque systématique que le marché ?), soit $t = (\hat{\beta}_1 - 1)/\,\mathrm{SE}(\hat{\beta}_1)$ — noter que la valeur testée est 1, pas 0. Un $\hat{\beta}_1 = 1{,}2$ avec $\mathrm{SE} = 0{,}15$ donne $t = (1{,}2-1)/0{,}15 = 1{,}33$: le bêta ne diffère pas significativement de 1 à 5 %.

7.7 --- Intervalles de confiance et de prévision

La régression sert à prévoir ; encore faut-il quantifier l'incertitude de la prévision, qui a deux composantes.

Intervalle de confiance d'un coefficient

$$\mathrm{IC}_{1-\alpha}(\beta_1) = \hat{\beta}_1 \pm t_{n-2;\,1-\alpha/2} \cdot \mathrm{SE}(\hat{\beta}_1).$$

Par dualité (chapitre 6), $H_0 : \beta_1 = \beta_1^*$ est rejetée ssi β_1^* est hors de cet intervalle.

Intervalle de confiance vs intervalle de prévision

L'**intervalle de confiance de la moyenne** encadre $\mathbb{E}[Y \mid X = x_0]$ (la position de la droite). L'**intervalle de prévision** encadre une *nouvelle observation* Y_0 en x_0 : il est **plus large**, car il ajoute la variabilité individuelle σ^2 à l'incertitude sur la droite.

Largeurs comparées (en x_0)

$$\text{IC de la moyenne} : \hat{Y}_0 \pm t \cdot s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2}};$$

$$\text{IC de prévision} : \hat{Y}_0 \pm t \cdot s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2}} \quad (\text{le } +1 \text{ ajoute l'aléa individuel}).$$

L'incertitude croît en s'éloignant du centre

Les deux intervalles sont les plus **étroits** en $x_0 = \bar{X}$ et s'**élargissent** à mesure que x_0 s'éloigne de la moyenne des X (le terme $(x_0 - \bar{X})^2$). Conséquence pratique : **extrapoler** loin du domaine observé des X est dangereux — la prévision devient très imprécise, et la linéarité supposée n'est plus garantie. Prévoir un rendement pour un mouvement de marché extrême, jamais observé dans l'échantillon d'estimation, relève de l'extrapolation hasardeuse.

7.8 --- Le test F de significativité globale

Au-delà de chaque coefficient, on teste si la régression a globalement un pouvoir explicatif — via le test F du chapitre 6.

Test F de significativité globale

Le **test F** teste H_0 : « tous les coefficients de pente sont nuls » (le modèle n'explique rien) contre H_1 : « au moins un est non nul ». Il compare la variance expliquée à la variance résiduelle :

$$F = \frac{\text{ESS}/k}{\text{RSS}/(n-k-1)} \sim F_{k,\,n-k-1} \quad \text{sous } H_0,$$

où k est le nombre de régresseurs ($k = 1$ en régression simple).

F en régression simple et lien avec R^2

En régression simple : $F = \dfrac{\text{ESS}}{\text{RSS}/(n-2)} = t^2$ (le F est le carré de la statistique t de la pente).

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)} \quad \text{(expression via le } R^2\text{)}.$$

Pourquoi $F = t^2$ en régression simple

Avec un seul régresseur, tester la significativité globale (F) équivaut à tester la pente (t) : la relation $F = t^2$ le confirme (par exemple $t = 2{,}5 \Rightarrow F = 6{,}25$). Le test F ne devient réellement utile qu'en régression **multiple**, où il teste la significativité *conjointe* de plusieurs coefficients — un modèle peut avoir chaque coefficient individuellement non significatif mais être globalement significatif (colinéarité), ou l'inverse. Le F répond à « le modèle sert-il à quelque chose ? », les t à « quelle variable compte ? ».

7.9 --- L'interprétation des coefficients : bêta, alpha et au-delà

Estimer ne suffit pas ; il faut interpréter correctement — la source d'erreurs la plus insidieuse.

Le bêta de marché et l'alpha de Jensen

En régressant l'excès de rendement d'un actif $R_a - R_f$ sur l'excès de rendement du marché $R_m - R_f$ (modèle de marché) : la **pente** est le **bêta** β (risque systématique — $\beta > 1$: plus volatil que le marché ; $\beta < 1$: défensif) et l'**ordonnée à l'origine** est l'**alpha de Jensen** α (rendement anormal, hors compensation du risque de marché). Un α significativement positif signale une surperformance ajustée du risque ; c'est la mesure de performance la plus citée. Le R^2 indique la part de risque **systématique** ; $1 - R^2$ la part **spécifique**.

Corrélation, causalité et variable omise

Une pente significative établit une **association**, jamais une **causalité**. Trois pièges : (1) la **causalité inverse** (Y influence X autant que l'inverse) ; (2) la **variable omise** — un facteur Z influençant X et Y crée une corrélation fallacieuse (violation d'exogénéité, $\hat{\beta}_1$ biaisé) ; (3) la **corrélation fortuite** (spurious) sur séries temporelles tendancielles. En finance, régresser deux prix qui montent tous deux avec le temps produit un R^2 élevé sans lien réel — d'où la préférence pour les **rendements** (séries stationnaires) plutôt que les niveaux.

7.10 --- Les violations d'hypothèses et leurs conséquences

Savoir diagnostiquer les défaillances d'une régression distingue l'analyste averti de l'utilisateur naïf.

Les trois violations majeures

Violation	Effet sur $\hat{\beta}$	Effet sur SE / tests
Hétéroscédasticité	Sans biais	**SE biaisées** $\Rightarrow$ tests faussés
Autocorrélation	Sans biais	**SE biaisées** (souvent sous-estimées)
Endogénéité (H2 violée)	**Biaisé** et non consistant	Inférence invalide

Hétéroscédasticité et autocorrélation en finance

L'**hétéroscédasticité** (variance des erreurs non constante) est omniprésente : la volatilité des rendements varie dans le temps (clustering). L'**autocorrélation** (erreurs corrélées dans le temps) apparaît sur données à haute fréquence ou mal spécifiées. Ni l'une ni l'autre ne biaise $\hat{\beta}$, mais toutes deux **faussent les erreurs-types**, invalidant les tests t et F (souvent en les rendant trop optimistes). Remèdes : erreurs-types **robustes** (White pour l'hétéroscédasticité, Newey–West pour l'autocorrélation), qui corrigent les SE sans changer $\hat{\beta}$. L'**endogénéité** est plus grave : elle biaise $\hat{\beta}$ lui-même et exige des méthodes avancées (variables instrumentales, hors programme).

Diagnostics visuels et formels

Le **graphique des résidus** (résidus contre valeurs ajustées ou contre X) est le premier diagnostic : un nuage sans structure valide les hypothèses ; un motif en entonnoir révèle l'hétéroscédasticité ; une ondulation révèle une non-linéarité ; une dérive révèle l'autocorrélation. Des tests formels existent (Breusch–Pagan pour l'hétéroscédasticité, Durbin–Watson pour l'autocorrélation), mais l'inspection graphique reste le réflexe premier. Vérifier aussi la **normalité des résidus** (Jarque–Bera, chapitre 6) pour la validité des tests à petit échantillon.

7.11 --- Aperçu de la régression multiple et du R^2 ajusté

La régression simple se généralise à plusieurs régresseurs — le cadre réel des modèles à facteurs.

Modèle de régression multiple

Avec k variables explicatives :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i.$$

Chaque coefficient β_j mesure l'effet de X_j sur Y **toutes choses égales par ailleurs** (les autres régresseurs maintenus constants) — l'effet *partiel*.

L'interprétation « toutes choses égales par ailleurs »

La nuance capitale de la régression multiple : β_j isole l'effet **propre** de X_j, purgé de l'influence des autres variables. Dans un modèle à trois facteurs (marché, taille, valeur) expliquant un rendement, le coefficient du facteur « taille » mesure son effet à exposition marché et valeur constantes. C'est ce qui permet de démêler des facteurs corrélés — mais une forte corrélation entre régresseurs (**multicolinéarité**) gonfle les erreurs-types et rend les coefficients instables, sans les biaiser.

R^2 ajusté

Ajouter un régresseur ne peut qu'augmenter le R^2 (même un régresseur inutile). Le **R^2 ajusté** pénalise cette inflation en tenant compte du nombre de régresseurs :

$$\bar{R}^2 = 1 - \frac{\text{RSS}/(n-k-1)}{\text{TSS}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}.$$

R^2 vs R^2 ajusté

R^2 ne décroît jamais quand on ajoute un régresseur; $\bar{R}^2$ peut décroître si le régresseur n'apporte rien.

$\bar{R}^2 \leq R^2$ toujours; $\bar{R}^2$ sert à comparer des modèles de tailles différentes.

Le surajustement (overfitting)

Empiler les régresseurs pour maximiser le R^2 conduit au **surajustement** : le modèle épouse le bruit de l'échantillon et prévoit mal hors échantillon. Le $\bar{R}^2$, en pénalisant la complexité, offre un garde-fou ; d'autres critères (AIC, BIC) vont plus loin. La leçon rejoint le chapitre 6 : un modèle riche testé sur les mêmes données produit des relations fallacieuses. Un modèle parcimonieux, validé hors échantillon, est préférable à un modèle sur-paramétré au R^2 flatteur.

7.12 --- Synthèse : la régression de bout en bout

Étape	Outil	Question / interprétation
Modèle	$Y = \beta_0 + \beta_1 X + \varepsilon$	Quelle relation ?
Estimation	MCO : $\hat{\beta}_1 = s_{XY}/s_X^2$	Meilleure droite (BLUE si G–M)
Ajustement	$R^2 = \text{ESS}/\text{TSS} = r^2$	Part de variance expliquée
Précision	$\text{SE}(\hat{\beta}_1) = s_e/(s_X\sqrt{n-1})$	Fiabilité de la pente
Test coefficient	$t = \hat{\beta}_1/\text{SE} \sim t_{n-2}$	Effet significatif ?
Test global	$F = t^2 \sim F_{1,n-2}$	Modèle utile ?
Prévision	IC moyenne vs IC prévision	Incertitude (droite / individu)
Diagnostics	Résidus, White, Newey–West	Hypothèses respectées ?

Les six réflexes du chapitre

(1) Distinguer paramètres β (population), estimations $\hat{\beta}$, erreurs ε et résidus e. **(2)** MCO minimise $\sum e_i^2$; $\hat{\beta}_1 = \text{Cov}(X,Y)/\text{Var}(X)$; la droite passe par $(\bar{X}, \bar{Y})$. **(3)** $R^2 = r^2 = \text{ESS}/\text{TSS}$: ajustement, pas causalité ni validité. **(4)** Test de pente : $t = \hat{\beta}_1/\text{SE}$ sur $n-2$ ddl ; pour le bêta, tester souvent $H_0 : \beta = 1$. **(5)** Hétéroscédasticité et autocorrélation ne biaisent pas $\hat{\beta}$ mais faussent les SE (remèdes robustes) ; l'endogénéité biaise $\hat{\beta}$. **(6)** $\bar{R}^2$ pénalise les régresseurs inutiles ; se méfier du surajustement et de l'extrapolation.

Partie B --- 200 études de cas pratiques

Chaque cas propose un contexte chiffré, une question et une solution détaillée. Régressions, R^2, erreurs-types, statistiques t et F, intervalles de confiance et de prévision sont calculés exactement (numpy/scipy). Travaillez crayon en main : cachez la solution, résolvez, comparez.

Bloc 1 --- Le modèle de régression et sa terminologie

Cas 1 — Modèle de régression — écriture. Écrire le modèle de régression linéaire simple de population et nommer ses éléments.

Solution. $Y_i=\beta_0+\beta_1 X_i+\varepsilon_i$: Y variable **dépendante** (expliquée), X **indépendante** (explicative), β_0 **ordonnée à l'origine**, β_1 **pente**, ε **terme d'erreur**.

Cas 2 — Interprétation de la pente. Que représente β_1 dans $Y=\beta_0+\beta_1 X+\varepsilon$?

Solution. La **variation de Y pour une hausse d'une unité de X** : $\beta_1=\partial E[Y|X]/\partial X$ (dérivée de l'espérance conditionnelle).

Cas 3 — Interprétation de l'ordonnée à l'origine. Que représente β_0 ?

Solution. L'espérance de Y quand $X=0$: $\beta_0=E[Y|X=0]$. Attention, elle n'a de sens que si $X=0$ est dans le domaine pertinent.

Cas 4 — Erreur vs résidu. Distinguer le terme d'erreur ε_i et le résidu e_i.

Solution. ε_i (population, **inobservable**) est l'écart au vrai modèle ; $e_i=Y_i-\hat{Y}_i$ (échantillon, **observable**) estime ε_i. Confondre les deux est un contresens fréquent.

Cas 5 — Paramètre vs estimation. Différence entre β_1 et $\hat{\beta}_1$?

Solution. β_1 est le **vrai** paramètre (population, inconnu) ; $\hat{\beta}_1$ est son **estimation** MCO sur l'échantillon (variable aléatoire).

Cas 6 — La droite de régression. Que vaut $E[Y|X]$ dans le modèle linéaire ?

Solution. $E[Y|X]=\beta_0+\beta_1 X$: la droite de régression **est** l'espérance conditionnelle de Y sachant X.

Cas 7 — Valeur ajustée. Qu'est-ce que $\hat{Y}_i$?

Solution. La **valeur ajustée** (fitted) : $\hat{Y}_i=\hat{\beta}_0+\hat{\beta}_1 X_i$, la prédiction du modèle pour l'observation i.

Cas 8 — Rôle du terme d'erreur. Que capte le terme d'erreur ε ?

Solution. **Tout ce que X n'explique pas** : autres facteurs, aléa, erreurs de mesure. Sa présence rend Y non déterministe.

Cas 9 — Variable dépendante en finance. Dans le modèle de marché $R_a-R_f=\beta_0+\beta_1(R_m-R_f)+\varepsilon$, qui est Y ?

Solution. Y=**excès de rendement de l'actif** (R_a-R_f) ; X=excès de rendement du marché. La pente est le bêta.

Cas 10 — Linéarité — de quoi ?. La « linéarité » de la régression porte sur quoi exactement ?

Solution. Sur les **paramètres** β, pas nécessairement sur X : $Y=\beta_0+\beta_1 X^2+\varepsilon$ reste « linéaire » (en β) et estimable par MCO.

Cas 11 — Sens de la régression. Régresser Y sur X donne-t-il la même droite que X sur Y ?

Solution. **Non** : les deux régressions minimisent des écarts différents (verticaux vs horizontaux) et donnent des pentes différentes (sauf ajustement parfait).

Cas 12 — Trois usages de la régression. Citer les trois objectifs d'une régression.

Solution. **Décrire** (résumer un nuage), **expliquer** (part de variance capturée), **prévoir** (estimer Y non observé).

Cas 13 — Bêta comme pente. Pourquoi le bêta de marché est-il une pente de régression ?

Solution. Il mesure la sensibilité du rendement de l'actif à celui du marché : $\beta = \mathrm{Cov}(R_a, R_m)/\mathrm{Var}(R_m)$, exactement la pente MCO.

Cas 14 — Alpha comme ordonnée. Que représente l'ordonnée à l'origine dans le modèle de marché ?

Solution. L'**alpha de Jensen** : le rendement anormal de l'actif, hors compensation du risque systématique (β·prime de marché).

Cas 15 — Modèle déterministe vs stochastique. Pourquoi ajoute-t-on ε au lieu d'écrire $Y = \beta_0 + \beta_1 X$?

Solution. Parce que la relation n'est pas exacte : ε capte l'aléa. Sans ε, tous les points seraient parfaitement alignés (irréaliste).

Cas 16 — Régresseur et régressande. Nommer autrement X et Y.

Solution. X : régresseur, variable explicative, indépendante ; Y : régressande, variable expliquée, dépendante.

Cas 17 — Domaine de validité. Peut-on interpréter β_0 si $X = 0$ est hors du domaine observé ?

Solution. Avec prudence : β_0 est alors une **extrapolation**. Ex. régresser la consommation sur le revenu — un revenu nul est hors échantillon.

Cas 18 — Unités des coefficients. Si Y est en % et X en %, quelle est l'unité de β_1 ? de β_0 ?

Solution. β_1 est **sans dimension** (%/% : variation de Y en points de % par point de % de X) ; β_0 est en **%** (valeur de Y).

Cas 19 — Effet d'un changement d'unité de X. On exprime X en pb au lieu de % (×100). Effet sur β_1 ?

Solution. β_1 est **divisé par 100** (même variation de Y pour une variation de X 100× plus petite en nombre). β_0 inchangé.

Cas 20 — Ce que la régression ne prouve pas. Une pente non nulle prouve-t-elle que X cause Y ?

Solution. **Non** : elle établit une association. Causalité inverse, variable omise ou corrélation fortuite peuvent l'expliquer.

Bloc 2 --- Estimation par les moindres carrés (MCO)

Cas 21 — Estimation MCO — pente et ordonnée. Données (X et Y) : X=[1, 2, 3, 4, 5], Y=[2, 4, 5, 4, 6]. Estimer β_1 et β_0 par les MCO.

Solution. $\bar{x}=3$, $\bar{y}=4{,}2$; $\Sigma(x_i-\bar{x})(y_i-\bar{y})=8$, $\Sigma(x_i-\bar{x})^2=10$; $\beta_1 = \mathrm{Sxy}/\mathrm{Sxx} = \mathbf{0{,}8}$; $\beta_0 = \bar{y} - \beta_1\bar{x} = \mathbf{1{,}8}$.

Cas 22 — Estimation MCO — pente et ordonnée. Données (relation exacte) : X=[1, 2, 3, 4], Y=[3, 5, 7, 9]. Estimer β_1 et β_0 par les MCO.

Solution. $\bar{x}=2{,}5$, $\bar{y}=6$; $\Sigma(x_i-\bar{x})(y_i-\bar{y})=10$, $\Sigma(x_i-\bar{x})^2=5$; $\beta_1 = \mathrm{Sxy}/\mathrm{Sxx} = \mathbf{2}$; $\beta_0 = \bar{y} - \beta_1\bar{x} = \mathbf{1}$.

Cas 23 — Estimation MCO — pente et ordonnée. Données (tendance croissante) : X=[2, 4, 6, 8, 10], Y=[5, 8, 10, 14, 15]. Estimer β_1 et β_0 par les MCO.

Solution. $\bar{x}=6$, $\bar{y}=10{,}4$; $\Sigma(x_i-\bar{x})(y_i-\bar{y})=52$, $\Sigma(x_i-\bar{x})^2=40$; $\beta_1 = \mathrm{Sxy}/\mathrm{Sxx} = \mathbf{1{,}3}$; $\beta_0 = \bar{y} - \beta_1\bar{x} = \mathbf{2{,}6}$.

Cas 24 — Estimation MCO — pente et ordonnée. Données (forme en U) : X=[-2, -1, 0, 1, 2], Y=[4, 2, 1, 2, 4]. Estimer β_1 et β_0 par les MCO.

Solution. $\bar{x}=0$, $\bar{y}=2{,}6$; $\Sigma(x_i-\bar{x})(y_i-\bar{y})=0$, $\Sigma(x_i-\bar{x})^2=10$; $\beta_1 = \mathrm{Sxy}/\mathrm{Sxx} = \mathbf{0}$; $\beta_0 = \bar{y} - \beta_1\bar{x} = \mathbf{2{,}6}$.

Cas 25 — Critère des moindres carrés. Que minimisent les MCO ?

Solution. La **somme des carrés des résidus** $\Sigma(Y_i-\beta_0-\beta_1X_i)^2 = \Sigma e_i^2$: la somme des écarts verticaux au carré.

Cas 26 — Pente comme covariance standardisée. Exprimer β_1 à l'aide de la covariance et de la variance.

Solution. $\beta_1 = \mathrm{Cov}(X,Y)/\mathrm{Var}(X) = s_{XY}/s_X^2$: la pente est la covariance rapportée à la variance de X.

Cas 27 — Pente via corrélation. Relier β_1 à la corrélation r et aux écarts-types.

Solution. $\beta_1 = r\cdot(s_Y/s_X)$: la pente combine la corrélation et le rapport des dispersions de Y et X.

Cas 28 — La droite passe par le point moyen. Quelle propriété géométrique la première équation normale impose-t-elle ?

Solution. La droite MCO passe par $(\bar{x}, \bar{y})$: $\bar{y}=\beta_0+\beta_1\bar{x}$ (conséquence de $\Sigma e_i=0$).

Cas 29 — Somme des résidus. Que vaut la somme des résidus MCO (avec ordonnée) ?

Solution. $\mathbf{\Sigma e_i=0}$: première équation normale. Les résidus se compensent en moyenne.

Cas 30 — Résidus non corrélés à X. Que vaut $\Sigma X_i e_i$ dans une régression MCO ?

Solution. **0** : seconde équation normale. Les résidus sont orthogonaux au régresseur (aucune info linéaire restante dans X).

Cas 31 — Calcul de β_1 — bêta de marché. $\mathrm{Cov}(R_a,R_m)=0{,}0018$, $\mathrm{Var}(R_m)=0{,}0012$. Estimer le bêta.

Solution. $\beta=\mathrm{Cov}/\mathrm{Var}=0{,}0018/0{,}0012=\mathbf{1{,}5}$: l'actif amplifie les mouvements du marché de 50 %.

Cas 32 — Reconstituer β_0. $\beta_1=0{,}8$, $\bar{x}=5$ %, $\bar{y}=6$ %. Calculer β_0.

Solution. $\beta_0=\bar{y}-\beta_1\bar{x}=6\ \%-0{,}8\times5\ \%=6\ \%-4\ \%=\mathbf{2\ \%}$.

Cas 33 — Prédiction ponctuelle. $\hat{Y}=2+0{,}8X$. Prédire Y pour $X=10$.

Solution. $\hat{Y}=2+0{,}8\times10=\mathbf{10}$.

Cas 34 — Résidu d'une observation. $\hat{Y}=2+0{,}8X$. Pour $X=10$, Y observé=11. Calculer le résidu.

Solution. $e=Y-\hat{Y}=11-(2+8)=11-10=\mathbf{+1}$: le modèle sous-estime cette observation d'une unité.

Cas 35 — Pente nulle — signification. Que signifie $\beta_1=0$?

Solution. Aucune relation linéaire estimée : la meilleure prédiction de Y est $\bar{y}$, indépendamment de X (droite horizontale).

Cas 36 — Signe de la pente. Que dit le signe de β_1 ?

Solution. Le **sens** de la relation linéaire : $\beta_1>0$ relation croissante, $\beta_1<0$ décroissante. Même signe que $\mathrm{Cov}(X,Y)$ et que r.

Cas 37 — MCO minimise-t-il les écarts absolus ?. Les MCO minimisent-ils $\Sigma|e_i|$?

Solution. **Non** : ils minimisent Σe_i^2 (carrés). Minimiser $\Sigma|e_i|$ est une autre méthode (régression LAD, plus robuste aux extrêmes).

Cas 38 — Sensibilité aux points aberrants. Pourquoi un point extrême affecte-t-il fortement la droite MCO ?

Solution. Parce que les **carrés** amplifient les grands écarts : un point aberrant tire fortement la droite pour réduire son résidu au carré.

Cas 39 — Point de levier. Qu'est-ce qu'un point à fort levier (leverage) ?

Solution. Une observation avec un X **très éloigné de $\bar{x}$** : elle exerce une forte influence sur la pente estimée.

Cas 40 — Reconstituer une prédiction financière. Modèle de marché : $\hat{\alpha}=0{,}2$ %, $\beta=1{,}2$. Prédire le rendement de l'actif si le marché fait +5 %.

Solution. $\hat{Y}=0{,}2\ \%+1{,}2\times5\ \%=0{,}2\ \%+6\ \%=\mathbf{6{,}2\ \%}$.

Cas 41 — Équations normales. Combien d'équations normales pour une régression simple, et qu'expriment-elles ?

Solution. **Deux** : $\Sigma e_i=0$ et $\Sigma X_i e_i=0$. Elles définissent les deux estimateurs β_0 et β_1.

Cas 42 — Pente et échelle de Y. On exprime Y en pb au lieu de % (×100). Effet sur β_1 et β_0 ?

Solution. Les deux sont **multipliés par 100** (Y change d'échelle). La relation reste la même.

Cas 43 — MCO et moyenne. Que devient β_1 si X est constant ?

Solution. **Indéfini** : $\mathrm{Var}(X)=0$ au dénominateur. Sans variabilité de X, la pente ne peut être estimée (hypothèse H5).

Cas 44 — MCO — vérifier une estimation. $\bar{x}=3$, $\bar{y}=7$, $\Sigma(x_i-\bar{x})(y_i-\bar{y})=20$, $\Sigma(x_i-\bar{x})^2=10$. Calculer β_1 et β_0.

Solution. $\beta_1=20/10=2$; $\beta_0=\bar{y}-\beta_1\bar{x}=7-2\times3=7-6=\mathbf{1} \Longrightarrow \hat{Y}=1+2X$.

Bloc 3 --- Hypothèses de Gauss--Markov et BLUE

Cas 45 — Théorème de Gauss–Markov. Qu'affirme le théorème de Gauss–Markov ?

Solution. Sous ses hypothèses, les estimateurs MCO sont **BLUE** : Best Linear Unbiased Estimators — variance minimale parmi les estimateurs linéaires sans biais.

Cas 46 — Les cinq hypothèses de Gauss–Markov. Énumérer les hypothèses de Gauss–Markov.

Solution. (H1) linéarité en β ; (H2) exogénéité $E[\varepsilon|X]=0$; (H3) homoscédasticité $\mathrm{Var}(\varepsilon)=\sigma^2$; (H4) absence d'autocorrélation ; (H5) variabilité de X.

Cas 47 — Hypothèse d'exogénéité. Énoncer l'hypothèse d'exogénéité et son rôle.

Solution. $E[\varepsilon_i|X]=0$: l'erreur est en moyenne nulle et **non liée à X**. C'est la condition clé de l'**absence de biais** de β.

Cas 48 — Hypothèse d'homoscédasticité. Que signifie l'homoscédasticité ?

Solution. $\mathrm{Var}(\varepsilon_i)=\sigma^2$ **constante** pour toute observation : la dispersion des erreurs ne dépend pas de X.

Cas 49 — Absence d'autocorrélation. Qu'exige l'hypothèse d'absence d'autocorrélation ?

Solution. $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0$ pour $i\neq j$: les erreurs de deux observations distinctes sont non corrélées.

Cas 50 — BLUE — signification de chaque lettre. Décomposer l'acronyme BLUE.

Solution. **B**est (variance minimale), **L**inear (linéaire en Y), **U**nbiased (sans biais), **E**stimator.

Cas 51 — Hypothèse la plus critique. Quelle violation d'hypothèse est la plus grave et pourquoi ?

Solution. La violation de l'**exogénéité** (H2) : elle **biaise** β (variable omise, causalité inverse). Les autres n'affectent que les erreurs-types.

Cas 52 — Homoscédasticité violée — conséquence. L'hétéroscédasticité biaise-t-elle β_1 ?

Solution. **Non** : β_1 reste sans biais et consistant. Elle **fausse les erreurs-types**, invalidant les tests.

Cas 53 — Normalité — quand est-elle requise ?. L'hypothèse de normalité des erreurs est-elle nécessaire à l'absence de biais de β ?

Solution. **Non** : β est sans biais sans normalité. La normalité n'est requise que pour la **validité exacte des tests t/F** à petit n (le TCL prend le relais à grand n).

Cas 54 — Sans biais de β_1. Que signifie $E[\beta_1]=\beta_1$?

Solution. En moyenne sur tous les échantillons, l'estimateur MCO **tombe juste** sur le vrai paramètre : il est sans biais.

Cas 55 — Consistance de β_1. β_1 est-il consistant ?

Solution. Oui sous Gauss–Markov : $\beta_1\to\beta_1$ quand $n\to\infty$ (sa variance tend vers 0). Sous endogénéité, il ne l'est **pas**.

Cas 56 — Efficacité des MCO. Que signifie « variance minimale » dans BLUE ?

Solution. Parmi tous les estimateurs **linéaires sans biais**, aucun n'a une variance plus faible que les MCO : ils sont les plus **efficaces** de cette classe.

Cas 57 — Variable omise — mécanisme du biais. Comment une variable omise Z crée-t-elle un biais ?

Solution. Si Z influence Y et est corrélée à X, son effet est capté par β_1 (via ε corrélé à X) : $E[\varepsilon|X]\neq0$, exogénéité violée, β_1 biaisé.

Cas 58 — Causalité inverse. Qu'est-ce que la causalité inverse et son effet ?

Solution. Y influence X autant que X influence Y : X est alors corrélé à ε, exogénéité violée, β_1 biaisé (endogénéité).

Cas 59 — Homoscédasticité en finance. Pourquoi l'homoscédasticité est-elle souvent violée sur des rendements ?

Solution. La **volatilité varie dans le temps** (clustering) : la variance des erreurs n'est pas constante $\Longrightarrow$ hétéroscédasticité fréquente.

Cas 60 — Variabilité de X requise. Pourquoi X doit-il varier (H5) ?

Solution. Sans variabilité (X constant), $\Sigma(X_i-\bar{x})^2=0$: la pente n'est pas définie. Une pente s'estime à partir de la co-variation.

Cas 61 — Estimateurs linéaires. En quel sens les MCO sont-ils « linéaires » ?

Solution. β est une **combinaison linéaire des Y_i** (à X_i donnés) : $\beta_1=\Sigma w_i Y_i$ avec des poids w_i dépendant des X.

Cas 62 — Sous quelles conditions faire confiance aux tests ?. Quelles hypothèses garantissent la validité des tests t/F d'une régression ?

Solution. Gauss–Markov (pour des SE correctes) **et** normalité des erreurs (ou n grand par le TCL). Hétéroscédasticité/autocorrélation faussent les SE.

Cas 63 — Remède sans changer β. Comment corriger des erreurs-types faussées sans modifier β ?

Solution. Utiliser des **erreurs-types robustes** (White pour l'hétéroscédasticité, Newey–West pour l'autocorrélation) : elles recalculent les SE, β reste inchangé.

Cas 64 — Endogénéité — remède avancé. Quel type de méthode traite l'endogénéité ?

Solution. Les **variables instrumentales** (et 2SLS) : elles isolent une variation de X non corrélée à ε (hors programme de ce chapitre).

Bloc 4 --- Décomposition de la variance et R^2

Cas 65 — Décomposition TSS = ESS + RSS. Données (X et Y) : X=[1, 2, 3, 4, 5], Y=[2, 4, 5, 4, 6]. Calculer TSS, ESS, RSS et vérifier la décomposition.

Solution. $TSS=\Sigma(y_i-\bar{y})^2=8{,}8$; $ESS=\Sigma(\hat{y}_i-\bar{y})^2=6{,}4$; $RSS=\Sigma e_i^2=2{,}4$; ESS+RSS=8,8=TSS ✓.

Cas 66 — Décomposition TSS = ESS + RSS. Données (relation exacte) : X=[1, 2, 3, 4], Y=[3, 5, 7, 9]. Calculer TSS, ESS, RSS et vérifier la décomposition.

Solution. $TSS=\Sigma(y_i-\bar{y})^2=20$; $ESS=\Sigma(\hat{y}_i-\bar{y})^2=20$; $RSS=\Sigma e_i^2=0$; ESS+RSS=20=TSS ✓.

Cas 67 — Décomposition TSS = ESS + RSS. Données (tendance croissante) : X=[2, 4, 6, 8, 10], Y=[5, 8, 10, 14, 15]. Calculer TSS, ESS, RSS et vérifier la décomposition.

Solution. $TSS=\Sigma(y_i-\bar{y})^2=69{,}2$; $ESS=\Sigma(\hat{y}_i-\bar{y})^2=67{,}6$; $RSS=\Sigma e_i^2=1{,}6$; ESS+RSS=69,2=TSS ✓.

Cas 68 — Décomposition TSS = ESS + RSS. Données (forme en U) : X=[-2, -1, 0, 1, 2], Y=[4, 2, 1, 2, 4]. Calculer TSS, ESS, RSS et vérifier la décomposition.

Solution. $TSS=\Sigma(y_i-\bar{y})^2=7{,}2$; $ESS=\Sigma(\hat{y}_i-\bar{y})^2=0$; $RSS=\Sigma e_i^2=7{,}2$; ESS+RSS=7,2=TSS ✓.

Cas 69 — Coefficient de détermination R^2. Données (X et Y) : X=[1, 2, 3, 4, 5], Y=[2, 4, 5, 4, 6]. Calculer le R^2.

Solution. R^2=ESS/TSS=6,4/8,8=**0,7273** (72,7 % de la variance de Y expliquée).

Cas 70 — Coefficient de détermination R^2. Données (relation exacte) : X=[1, 2, 3, 4], Y=[3, 5, 7, 9]. Calculer le R^2.

Solution. R^2=ESS/TSS=20/20=**1** (100 % de la variance de Y expliquée).

Cas 71 — Coefficient de détermination R^2. Données (tendance croissante) : X=[2, 4, 6, 8, 10], Y=[5, 8, 10, 14, 15]. Calculer le R^2.

Solution. R^2=ESS/TSS=67,6/69,2=**0,9769** (97,7 % de la variance de Y expliquée).

Cas 72 — Coefficient de détermination R^2. Données (forme en U) : X=[-2, -1, 0, 1, 2], Y=[4, 2, 1, 2, 4]. Calculer le R^2.

Solution. R^2=ESS/TSS=0/7,2=**0** (0 % de la variance de Y expliquée).

Cas 73 — Définition du R^2. Définir le coefficient de détermination.

Solution. R^2=ESS/TSS=1−RSS/TSS : la **fraction de la variance de Y expliquée** par la régression, entre 0 et 1.

Cas 74 — R^2 et corrélation. Quel lien entre R^2 et corrélation en régression simple ?

Solution. $\mathbf{R^2=r^2}$: le R^2 est le carré de la corrélation entre X et Y. Ex. r=0,8 $\Longrightarrow$ R^2=0,64.

Cas 75 — Interpréter R^2=0,64. Un R^2 de 0,64 dans un modèle de marché : que signifie-t-il ?

Solution. **64 %** de la variance des rendements de l'actif est expliquée par le marché (risque systématique) ; 36 % est du risque **spécifique** (diversifiable).

Cas 76 — R^2=1. Que signifie R^2=1 ?

Solution. **Ajustement parfait** : RSS=0, tous les points sont sur la droite. Rare et souvent suspect (surajustement, identité).

Cas 77 — R^2=0. Que signifie R^2=0 ?

Solution. **Aucun pouvoir explicatif** : ESS=0, la régression ne fait pas mieux que $\bar{y}$. β_1=0.

Cas 78 — Trois sommes de carrés. Nommer TSS, ESS, RSS.

Solution. **TSS** (total) : variabilité de Y ; **ESS** (expliquée) : captée par la droite ; **RSS** (résiduelle) : non expliquée.

Cas 79 — Terme croisé nul. Pourquoi TSS = ESS + RSS sans terme croisé ?

Solution. Le terme croisé $2\Sigma(\hat{y}_i-\bar{y})e_i=0$ par les équations normales ($\Sigma X_i e_i=0$, $\Sigma e_i=0$) : orthogonalité ajustées–résidus.

Cas 80 — R^2 élevé et causalité. Un R^2 élevé prouve-t-il une relation causale ?

Solution. **Non** : R^2 mesure l'ajustement, pas la causalité ni la validité. Une corrélation fortuite peut donner un R^2 élevé.

Cas 81 — R^2 faible acceptable ?. Un R^2 de 0,15 sur des rendements d'action individuelle est-il rédhibitoire ?

Solution. Non : un R^2 faible est **normal** pour un actif individuel (fort risque spécifique). L'utilité dépend de l'objectif.

Cas 82 — Calcul de R^2 depuis les sommes. TSS=200, RSS=50. Calculer le R^2.

Solution. R^2=1−RSS/TSS=1−50/200=1−0,25=**0,75**.

Cas 83 — ESS depuis R^2 et TSS. R^2=0,6, TSS=500. Calculer ESS et RSS.

Solution. ESS=R^2·TSS=0,6×500=**300** ; RSS=TSS−ESS=**200**.

Cas 84 — R^2 et risque systématique. Comment R^2 se relie-t-il au partage risque systématique / spécifique ?

Solution. R^2 = part de variance **systématique** (expliquée par le marché) ; 1−R^2 = part **spécifique** (idiosyncratique).

Cas 85 — R^2 ne mesure pas la pente. Un fort R^2 implique-t-il une forte pente ?

Solution. **Non** : R^2 mesure la qualité de l'alignement, pas la magnitude de β_1. Une petite pente peut avoir un R^2 élevé si le bruit est faible.

Cas 86 — Corrélation depuis R^2. R^2=0,49 en régression simple. Quelle est la corrélation (en valeur absolue) ?

Solution. $|r|=\sqrt{R^2}=\sqrt{0,49}=$**0,7**. Le signe de r est celui de la pente β_1.

Cas 87 — R^2 négatif ?. Le R^2 peut-il être négatif en MCO avec ordonnée ?

Solution. **Non** en régression MCO avec constante : $R^2 \in [0,1]$. (Il peut l'être hors échantillon ou sans constante.)

Cas 88 — Comparer deux modèles par R^2. Deux modèles sur les mêmes Y : $R^2=0{,}4$ vs 0,7. Lequel ajuste mieux ?

Solution. Celui à $\mathbf{R^2=0{,}7}$ ajuste mieux (plus de variance expliquée) — à nombre de régresseurs égal. Sinon, comparer le R^2 ajusté.

Bloc 5 --- Erreurs-types de la régression et des coefficients

Cas 89 — Erreur-type de la régression (SER). Données (X et Y) : RSS=2,4, n=5. Calculer l'erreur-type de la régression s_e.

Solution. $s_e=\sqrt{(RSS/(n-2))}=\sqrt{(2{,}4/3)}=\mathbf{0{,}8944}$: écart-type des résidus ($n-2$ ddl).

Cas 90 — Erreur-type de la régression (SER). Données (relation exacte) : RSS=0, n=4. Calculer l'erreur-type de la régression s_e.

Solution. $s_e=\sqrt{(RSS/(n-2))}=\sqrt{(0/2)}=\mathbf{0}$: écart-type des résidus ($n-2$ ddl).

Cas 91 — Erreur-type de la régression (SER). Données (tendance croissante) : RSS=1,6, n=5. Calculer l'erreur-type de la régression s_e.

Solution. $s_e=\sqrt{(RSS/(n-2))}=\sqrt{(1{,}6/3)}=\mathbf{0{,}7303}$: écart-type des résidus ($n-2$ ddl).

Cas 92 — Erreur-type de la régression (SER). Données (forme en U) : RSS=7,2, n=5. Calculer l'erreur-type de la régression s_e.

Solution. $s_e=\sqrt{(RSS/(n-2))}=\sqrt{(7{,}2/3)}=\mathbf{1{,}5492}$: écart-type des résidus ($n-2$ ddl).

Cas 93 — Erreur-type de la pente. Données (X et Y) : $s_e=0{,}8944$, $\Sigma(x_i-\bar{x})^2=10$. Calculer $SE(\beta_1)$.

Solution. $SE(\beta_1)=s_e/\sqrt{\Sigma(x_i-\bar{x})^2}=0{,}8944/\sqrt{10}=\mathbf{0{,}2828}$.

Cas 94 — Erreur-type de la pente. Données (relation exacte) : $s_e=0$, $\Sigma(x_i-\bar{x})^2=5$. Calculer $SE(\beta_1)$.

Solution. $SE(\beta_1)=s_e/\sqrt{\Sigma(x_i-\bar{x})^2}=0/\sqrt{5}=\mathbf{0}$.

Cas 95 — Erreur-type de la pente. Données (tendance croissante) : $s_e=0{,}7303$, $\Sigma(x_i-\bar{x})^2=40$. Calculer $SE(\beta_1)$.

Solution. $SE(\beta_1)=s_e/\sqrt{\Sigma(x_i-\bar{x})^2}=0{,}7303/\sqrt{40}=\mathbf{0{,}1155}$.

Cas 96 — Erreur-type de la pente. Données (forme en U) : $s_e=1{,}5492$, $\Sigma(x_i-\bar{x})^2=10$. Calculer $SE(\beta_1)$.

Solution. $SE(\beta_1)=s_e/\sqrt{\Sigma(x_i-\bar{x})^2}=1{,}5492/\sqrt{10}=\mathbf{0{,}4899}$.

Cas 97 — Diviseur $n-2$. Pourquoi divise-t-on RSS par $n-2$ pour l'erreur-type de la régression ?

Solution. Deux degrés de liberté sont consommés par l'estimation de $\boldsymbol{\beta_0}$ **et** $\boldsymbol{\beta_1}$: il reste $n-2$ résidus libres.

Cas 98 — Ce qui rend β_1 précis. Citer trois facteurs réduisant $SE(\beta_1)$.

Solution. (1) résidus petits (s_e faible) ; (2) X très dispersé ($\Sigma(x_i-\bar{x})^2$ grand) ; (3) n grand. Plus X couvre un large éventail, mieux la pente s'estime.

Cas 99 — Dispersion de X et précision. Pourquoi un bêta estimé en marché calme est-il moins fiable ?

Solution. Faible dispersion des rendements de marché $\Longrightarrow$ $\Sigma(x_i-\bar{x})^2$ petit $\Longrightarrow$ $\mathbf{SE(\beta_1)}$ **grande** : la pente est mal identifiée.

Cas 100 — Erreur-type de $\boldsymbol{\beta_0}$. De quoi dépend $SE(\beta_0)$?

Solution. $SE(\beta_0)=s_e\sqrt{(1/n+\bar{x}^2/\Sigma(x_i-\bar{x})^2)}$: elle croît avec $\bar{x}^2$ (l'ordonnée est mal estimée si les X sont loin de 0).

Cas 101 — SER et qualité d'ajustement. Que traduit une petite erreur-type de régression ?

Solution. Des **résidus faibles** en moyenne : les points sont proches de la droite, bon ajustement (lié à un R^2 élevé).

Cas 102 — SER en unités de Y. Dans quelle unité s'exprime l'erreur-type de la régression ?

Solution. Dans l'**unité de Y** : c'est un écart-type de résidus. Si Y est en %, s_e est en %.

Cas 103 — Effet de n sur SE(β_1). Comment SE(β_1) évolue-t-elle quand n augmente (autres choses égales) ?

Solution. Elle **diminue** : $\Sigma(x_i-\bar{x})^2$ croît avec n $\Longrightarrow$ pente plus précise. La précision s'améliore avec la taille d'échantillon.

Cas 104 — Calcul complet SE(β_1). s_e=2, $\Sigma(x_i-\bar{x})^2$=50. Calculer SE(β_1).

Solution. SE(β_1)=2/$\sqrt{50}$=2/7,071=**0,283**.

Cas 105 — Erreur-type et intervalle de confiance. À quoi sert SE(β_1) dans l'inférence ?

Solution. Elle est le **dénominateur du test t** (t=β_1/SE) et la demi-largeur de l'IC ($\beta_1 \pm$t·SE). Elle quantifie l'incertitude sur la pente.

Cas 106 — SER vs écart-type de Y. Différence entre l'erreur-type de la régression s_e et l'écart-type de Y ?

Solution. s_Y mesure la dispersion **totale** de Y ; s_e mesure la dispersion **résiduelle** (après retrait de l'effet de X). $s_e \leq$ s_Y.

Cas 107 — SER et R^2. Quel lien qualitatif entre l'erreur-type de la régression et le R^2 ?

Solution. Un s_e **faible** correspond à un R^2 **élevé** : peu de variance résiduelle $\Longrightarrow$ forte part expliquée. Les deux mesurent l'ajustement, différemment.

Cas 108 — SE(β_1) et test t. s_e=3, $\Sigma(x_i-\bar{x})^2$=36, β_1=1,5. Calculer SE(β_1) puis la statistique t (H_0:β_1=0).

Solution. SE(β_1)=3/$\sqrt{36}$=3/6=0,5 ; t=1,5/0,5=**3,0** : significatif si |t|>valeur critique.

Bloc 6 --- Tests de significativité des coefficients

Cas 109 — Test de significativité d'un coefficient. β_1=1,5, SE(β_1)=0,15, n=42. Tester H_0 : β=1 (bêta) à 5 %.

Solution. t=(β_1−1)/SE=(1,5−1)/0,15=**3,333** sur 40 ddl ; p=0,0019 $\Longrightarrow$ **rejet** de H_0.

Cas 110 — Test de significativité d'un coefficient. β_1=0,8, SE(β_1)=0,2, n=30. Tester H_0 : β=0 à 5 %.

Solution. t=(β_1−0)/SE=(0,8−0)/0,2=**4** sur 28 ddl ; p=0,0004 $\Longrightarrow$ **rejet** de H_0.

Cas 111 — Test de significativité d'un coefficient. β_1=2, SE(β_1)=0,5, n=25. Tester H_0 : β=0 à 5 %.

Solution. t=(β_1−0)/SE=(2−0)/0,5=**4** sur 23 ddl ; p=0,0006 $\Longrightarrow$ **rejet** de H_0.

Cas 112 — Test de significativité d'un coefficient. β_1=1,2, SE(β_1)=0,15, n=50. Tester H_0 : β=1 (bêta) à 5 %.

Solution. t=(β_1−1)/SE=(1,2−1)/0,15=**1,333** sur 48 ddl ; p=0,1887 $\Longrightarrow$ **non-rejet** de H_0.

Cas 113 — Test de significativité d'un coefficient. β_1=-0,5, SE(β_1)=0,2, n=22. Tester H_0 : β=0 à 5 %.

Solution. t=(β_1−0)/SE=(-0,5−0)/0,2=**-2,5** sur 20 ddl ; p=0,0212 $\Longrightarrow$ **rejet** de H_0.

Cas 114 — Statistique de test de la pente. Donner la statistique pour tester H_0 : β_1=0.

Solution. t=β_1/SE(β_1) ~ t_{n−2} sous H_0. On rejette si |t| dépasse la valeur critique (ou si p≤α).

Cas 115 — Degrés de liberté du test. Combien de degrés de liberté pour tester un coefficient en régression simple, n=42 ?

Solution. n−2=**40 ddl** (deux paramètres estimés, β_0 et β_1).

Cas 116 — Tester le bêta contre 1. Pourquoi teste-t-on souvent H_0 : β=1 pour un bêta plutôt que β=0 ?

Solution. Parce que β=1 correspond au **risque de marché** : on teste si l'actif est plus/moins volatil que le marché. t=(β−1)/SE, pas (β−0)/SE.

Cas 117 — Tester l'alpha. Comment tester si un fonds a un alpha significativement positif ?

Solution. H_0 : $\beta_0 \leq 0$ contre H_1 : $\beta_0 > 0$ (unilatéral) ; t=β_0/SE(β_0) sur n−2 ddl. Un t élevé $\Longrightarrow$ surperformance significative.

Cas 118 — Bêta non significativement différent de 1. β=1,2, SE=0,15, n grand. Le bêta diffère-t-il de 1 à 5 % ?

Solution. t=(1,2−1)/0,15=**1,33** < 1,96 ⟹ **non** : le bêta n'est pas significativement différent de 1.

Cas 119 — Coefficient significatif mais faible. Une pente est significative (t=5) mais vaut 0,02. Est-elle importante ?

Solution. Significative statistiquement, mais l'**ampleur** (0,02) peut être négligeable. Significativité ≠ matérialité (chapitre 6).

Cas 120 — t de la pente et taille d'échantillon. À β_1 et SE de la régression fixés, comment le t évolue-t-il avec n ?

Solution. SE(β_1) décroît avec n ⟹ |t| **augmente** : un même coefficient devient plus significatif sur un plus grand échantillon.

Cas 121 — Interpréter un t=0,9. Un coefficient a t=0,9 (test bilatéral, seuil 2,0). Conclusion ?

Solution. |0,9|<2,0 ⟹ **ne pas rejeter** H_0 : β_1 n'est pas significativement différent de 0 (le régresseur n'a pas d'effet détecté).

Cas 122 — Lien test t et erreurs-types faussées. Pourquoi l'hétéroscédasticité invalide-t-elle le test t de la pente ?

Solution. Elle **fausse SE($\hat{\beta}_1$)** (souvent sous-estimée) ⟹ t artificiellement grand ⟹ faux rejets. β_1 reste correct, mais le test ment.

Cas 123 — Valeur critique du test de coefficient. Régression avec n=22. Valeur critique t bilatérale à 5 % pour tester un coefficient ?

Solution. df=n−2=20 ; $t_{20;0,975}$=**2,086** : rejeter H_0 si |t|>2,086.

Cas 124 — Test unilatéral de l'alpha — calcul. $\hat{\alpha}$=0,3 %, SE($\hat{\alpha}$)=0,12 %, n=40. Tester H_0:$\alpha \leq 0$ contre H_1:$\alpha > 0$ à 5 %.

Solution. t=0,3/0,12=2,5 sur 38 ddl ; $t_{38;0,95} \approx 1,686$; 2,5>1,686 ⟹ **rejet** : alpha significativement positif.

Cas 125 — Coefficient non significatif — interprétation. Un régresseur a β=0,05, t=0,4. Faut-il le conserver ?

Solution. Non détecté comme significatif (|0,4|<2) : le régresseur n'apporte pas de pouvoir explicatif mesurable ; envisager de le retirer.

Cas 126 — Signe attendu d'un coefficient. Le coefficient d'un facteur de risque ressort négatif alors qu'on l'attendait positif. Que soupçonner ?

Solution. Une **variable omise** ou de la **multicolinéarité** : le signe contre-intuitif est un signal d'alerte sur la spécification.

Cas 127 — Test de deux coefficients simultanément. Comment tester si deux coefficients sont conjointement nuls (multiple) ?

Solution. Par un **test F partiel** (F emboîté), pas par deux tests t séparés : le F teste la nullité **conjointe** en contrôlant le risque global.

Cas 128 — t de la pente et dispersion de X. Deux échantillons, même β_1 et s_e, mais X plus dispersé dans le second. Où le t est-il plus grand ?

Solution. Dans le **second** : X plus dispersé ⟹ SE(β_1) plus petite ⟹ |t| plus grand ⟹ pente plus significative.

Bloc 7 --- Intervalles de confiance et de prévision

Cas 129 — Intervalle de confiance d'un coefficient. β_1=1,5, SE=0,15, n=42. IC à 95 % pour β_1 ?

Solution. t_{40;0,975}=2,021 ; IC=$\beta_1 \pm t \cdot SE = 1,5 \pm 2,021 \times 0,15 =$ **[1,197 ; 1,803]**.

Cas 130 — Intervalle de confiance d'un coefficient. β_1=0,8, SE=0,2, n=30. IC à 95 % pour β_1 ?

Solution. t_{28;0,975}=2,048 ; IC=$\beta_1 \pm t \cdot SE = 0,8 \pm 2,048 \times 0,2 =$ **[0,39 ; 1,21]**.

Cas 131 — Intervalle de confiance d'un coefficient. β_1=1,2, SE=0,15, n=50. IC à 99 % pour β_1 ?

Solution. t_{48;0,995}=2,682 ; IC=$\beta_1 \pm t \cdot SE = 1,2 \pm 2,682 \times 0,15 =$ **[0,798 ; 1,602]**.

Cas 132 — Intervalle de confiance d'un coefficient. β_1=2, SE=0,5, n=25. IC à 90 % pour β_1 ?

Solution. t_{23;0,95}=1,714 ; IC=$\beta_1 \pm$t·SE=2$\pm$1,714×0,5=**[1,143 ; 2,857]**.

Cas 133 — Dualité IC–test pour un coefficient. IC à 95 % pour β_1 = [0,9 ; 2,1]. β_1 diffère-t-il de 0 ? de 1 ?

Solution. 0 est **hors** de l'IC $\Longrightarrow$ β_1 significatif ($\neq$0) ; 1 est **dans** l'IC $\Longrightarrow$ β_1 non significativement différent de 1.

Cas 134 — IC de la moyenne vs IC de prévision. Distinguer l'IC de la moyenne $E[Y|x_0]$ et l'IC de prévision d'une nouvelle observation.

Solution. L'IC de la **moyenne** encadre la position de la droite ; l'IC de **prévision** encadre une observation individuelle Y_0 — il est **plus large** (ajoute la variabilité individuelle σ^2).

Cas 135 — Le +1 de l'intervalle de prévision. D'où vient le terme « +1 » dans l'IC de prévision ?

Solution. Il ajoute la **variance de l'aléa individuel** ε_0 (σ^2) à l'incertitude sur la droite : $\sqrt{(1+1/n+(x_0-\bar{x})^2/\Sigma(x_i-\bar{x})^2)}$.

Cas 136 — Incertitude et éloignement du centre. Où les intervalles sont-ils les plus étroits, et pourquoi s'élargissent-ils ?

Solution. Les plus étroits en $\mathbf{x_0=\bar{x}}$; ils s'élargissent quand x_0 s'éloigne de $\bar{x}$ (terme $(x_0-\bar{x})^2$) : l'estimation de la droite est moins sûre aux extrémités.

Cas 137 — Danger de l'extrapolation. Pourquoi extrapoler loin du domaine des X est-il risqué ?

Solution. L'IC de prévision **explose** loin de $\bar{x}$, et la linéarité supposée n'est plus garantie hors du domaine observé. Prédire un rendement pour un choc jamais observé est hasardeux.

Cas 138 — IC de prévision — largeur relative. Pour un grand n, l'IC de prévision se réduit-il à zéro ?

Solution. **Non** : même à $n\to\infty$, il garde la largeur $\pm t\cdot s_e\sqrt{1}$ (l'aléa individuel σ^2 ne disparaît pas). Seul l'IC de la **moyenne** tend vers 0.

Cas 139 — Construire un IC de coefficient. β_1=0,5, SE=0,1, n grand ($t\approx1,96$). IC à 95 % ?

Solution. IC=0,5$\pm$1,96×0,1=0,5$\pm$0,196=**[0,304 ; 0,696]**.

Cas 140 — IC ne contenant pas zéro. IC à 95 % pour une pente = [0,2 ; 0,8]. Le régresseur est-il significatif ?

Solution. **Oui** : 0 est hors de l'IC $\Longrightarrow$ rejet de H_0:β_1=0 à 5 % (dualité test–IC).

Cas 141 — Prévision ponctuelle vs intervalle. Pourquoi accompagner une prévision $\hat{Y}_0$ d'un intervalle ?

Solution. $\hat{Y}_0$ seul ignore l'**incertitude** : l'intervalle indique la plage plausible, essentielle pour la décision (gestion du risque).

Cas 142 — Effet du niveau de confiance sur l'IC. Passer de 95 % à 99 % pour un IC de coefficient : effet ?

Solution. L'IC **s'élargit** (valeur critique t plus grande) : plus de confiance $\Longrightarrow$ intervalle plus large, à données fixées.

Cas 143 — IC de la moyenne à $\bar{x}$. Que vaut la demi-largeur de l'IC de la moyenne en $x_0=\bar{x}$?

Solution. $t\cdot s_e\cdot\sqrt{(1/n)}$: le terme $(x_0-\bar{x})^2$ s'annule. C'est le point le plus **précis** de la droite.

Cas 144 — Largeur relative des deux intervalles. En un même x_0, lequel est le plus large : IC de la moyenne ou IC de prévision ?

Solution. L'**IC de prévision** (terme +1 supplémentaire sous la racine) : il englobe l'aléa individuel en plus de l'incertitude sur la droite.

Cas 145 — IC de prévision — composantes de l'incertitude. Quelles deux sources d'incertitude l'IC de prévision combine-t-il ?

Solution. (1) l'incertitude d'**estimation** de la droite ($1/n + (x_0-\bar{x})^2/\Sigma$...) ; (2) la **variabilité individuelle** de la nouvelle observation (le +1).

Cas 146 — Prévision au centre vs aux extrêmes. La prévision d'un rendement est-elle aussi fiable pour un marché à +1 % que pour un marché à +15 % (jamais observé) ?

Solution. Non : à +15 % (loin de $\bar{x}$, hors domaine), l'intervalle **explose** et la linéarité n'est plus garantie. Extrapolation risquée.

Cas 147 — Confiance vs prévision — objectif. Quand vise-t-on l'IC de la moyenne plutôt que l'IC de prévision ?

Solution. IC de la **moyenne** : pour situer la relation moyenne $E[Y|x_0]$; IC de **prévision** : pour encadrer une observation future individuelle.

Cas 148 — Effet de n sur les deux intervalles. Quand $n \to \infty$, que deviennent l'IC de la moyenne et l'IC de prévision ?

Solution. L'IC de la **moyenne** tend vers 0 (droite parfaitement estimée) ; l'IC de **prévision** garde une largeur $\pm t \cdot s_e$ (l'aléa σ^2 subsiste).

Bloc 8 --- Test F de significativité globale

Cas 149 — Test F de significativité globale. R^2=0,64, k=1 régresseur, n=42. Calculer la statistique F.

Solution. $F=(R^2/k)/((1-R^2)/(n-k-1))=(0{,}64/1)/(0{,}36/40)=$**71,111** sur (1,40) ddl (p=0 $\Longrightarrow$ modèle significatif).

Cas 150 — Test F de significativité globale. R^2=0,36, k=1 régresseur, n=30. Calculer la statistique F.

Solution. $F=(R^2/k)/((1-R^2)/(n-k-1))=(0{,}36/1)/(0{,}64/28)=$**15,75** sur (1,28) ddl (p=0,0005 $\Longrightarrow$ modèle significatif).

Cas 151 — Test F de significativité globale. R^2=0,81, k=1 régresseur, n=25. Calculer la statistique F.

Solution. $F=(R^2/k)/((1-R^2)/(n-k-1))=(0{,}81/1)/(0{,}19/23)=$**98,053** sur (1,23) ddl (p=0 $\Longrightarrow$ modèle significatif).

Cas 152 — Test F de significativité globale. R^2=0,25, k=1 régresseur, n=50. Calculer la statistique F.

Solution. $F=(R^2/k)/((1-R^2)/(n-k-1))=(0{,}25/1)/(0{,}75/48)=$**16** sur (1,48) ddl (p=0,0002 $\Longrightarrow$ modèle significatif).

Cas 153 — Hypothèse nulle du test F. Que teste le test F de significativité globale ?

Solution. H_0 : **tous les coefficients de pente sont nuls** (le modèle n'explique rien) contre H_1 : au moins un est non nul.

Cas 154 — F = t^2 en régression simple. Quel lien entre le test F global et le test t de la pente en régression simple ?

Solution. **$F=t^2$** : avec un seul régresseur, les deux tests sont équivalents. Ex. t=2,5 $\Longrightarrow$ F=6,25.

Cas 155 — Formule F via sommes de carrés. Exprimer F avec ESS et RSS.

Solution. $F=(ESS/k)/(RSS/(n-k-1))$: rapport de la variance expliquée (par ddl) à la variance résiduelle (par ddl).

Cas 156 — Utilité du test F en régression multiple. Pourquoi le test F est-il vraiment utile en régression multiple ?

Solution. Il teste la significativité **conjointe** de plusieurs coefficients — un modèle peut être globalement significatif même si chaque coefficient pris isolément ne l'est pas (colinéarité).

Cas 157 — F élevé — interprétation. Un F très supérieur à sa valeur critique signifie quoi ?

Solution. On **rejette H_0** : le modèle a un pouvoir explicatif significatif (au moins un régresseur compte).

Cas 158 — F et R^2. Comment F se relie-t-il au R^2 ?

Solution. $F=(R^2/k)/((1-R^2)/(n-k-1))$: F croît avec R^2 et avec n. Un R^2 élevé et un grand n donnent un F élevé.

Cas 159 — F vs t — quelle question ?. Que répond le F et que répondent les t ?

Solution. Le **F** : « le modèle sert-il globalement ? » ; les **t** : « quelle variable compte individuellement ? ».

Cas 160 — Calcul de F depuis t. La pente a t=3,0 en régression simple. Que vaut F ?

Solution. $F=t^2=3{,}0^2=$**9,0** sur $(1, n-2)$ ddl.

Cas 161 — Valeur critique du test F. Régression simple, n=42. Valeur critique F à 5 % pour la significativité globale ?

Solution. F_{1,40;0,95}=**4,085** ; noter que $\sqrt{4{,}08}\approx 2{,}02\approx t_{40;0{,}975}$ (car $F=t^2$).

Cas 162 — Décision par le test F. F=12 sur (1,40) ddl, valeur critique 4,08. Décision ?

Solution. $12>4{,}08 \Longrightarrow$ **rejet de H_0** : le modèle a un pouvoir explicatif globalement significatif.

Cas 163 — F et n dans le test global. À R^2 fixé, comment F évolue-t-il avec n ?

Solution. F **augmente** avec n (facteur $(n-k-1)$) : un même R^2 devient globalement significatif sur un plus grand échantillon.

Cas 164 — Numérateur et dénominateur du F. Que représentent le numérateur et le dénominateur de $F=(ESS/k)/(RSS/(n-k-1))$?

Solution. Numérateur : variance **expliquée** par ddl ; dénominateur : variance **résiduelle** par ddl ($\approx s_e^2$). Un rapport grand $\Longrightarrow$ modèle utile.

Bloc 9 --- Violations d'hypothèses et diagnostics

Cas 165 — Hétéroscédasticité — définition et effet. Qu'est-ce que l'hétéroscédasticité et quel est son effet ?

Solution. Variance des erreurs **non constante** (dépend de X). Elle ne biaise **pas** β mais **fausse les erreurs-types** $\Longrightarrow$ tests invalides.

Cas 166 — Autocorrélation — définition et effet. Qu'est-ce que l'autocorrélation des erreurs et son effet ?

Solution. Erreurs **corrélées entre observations** ($\mathrm{Cov}(\varepsilon_i,\varepsilon_j)\neq 0$). Ne biaise pas β mais **fausse les SE** (souvent sous-estimées).

Cas 167 — Endogénéité — définition et effet. Qu'est-ce que l'endogénéité et pourquoi est-elle grave ?

Solution. X corrélé à l'erreur ($E[\varepsilon|X]\neq 0$). Elle **biaise β** et le rend non consistant : l'inférence est invalide. La plus grave des violations.

Cas 168 — Hétéroscédasticité en finance. Pourquoi les rendements présentent-ils souvent de l'hétéroscédasticité ?

Solution. Le **clustering de volatilité** : la variance des rendements (donc des erreurs) varie dans le temps (périodes calmes/agitées).

Cas 169 — Remède à l'hétéroscédasticité. Comment corriger l'hétéroscédasticité sans changer β ?

Solution. Erreurs-types **robustes de White** (heteroskedasticity-consistent) : elles recalculent les SE ; β reste inchangé.

Cas 170 — Remède à l'autocorrélation. Quel correctif pour l'autocorrélation des erreurs ?

Solution. Erreurs-types **de Newey–West** (HAC) : robustes à l'hétéroscédasticité **et** à l'autocorrélation. β inchangé.

Cas 171 — Graphique des résidus — usage. À quoi sert le graphique des résidus ?

Solution. Premier diagnostic : un nuage **sans structure** valide les hypothèses ; un **entonnoir** signale l'hétéroscédasticité ; une **ondulation** signale la non-linéarité.

Cas 172 — Motif en entonnoir. Que révèle un graphique de résidus en forme d'entonnoir ?

Solution. De l'**hétéroscédasticité** : la dispersion des résidus croît (ou décroît) avec X ou avec $\hat{Y}$.

Cas 173 — Détecter la non-linéarité. Comment repérer une relation non linéaire mal modélisée ?

Solution. Une **structure systématique** (courbe, ondulation) dans le graphique des résidus contre X : le linéaire ne capte pas tout.

Cas 174 — Test de Durbin–Watson. Que teste la statistique de Durbin–Watson ?

Solution. L'**autocorrélation d'ordre 1** des résidus. Une valeur proche de 2 suggère l'absence d'autocorrélation ; loin de 2, sa présence.

Cas 175 — Test de Breusch–Pagan. À quoi sert le test de Breusch–Pagan ?

Solution. À détecter l'**hétéroscédasticité** : H_0 = variance constante. Un rejet signale une hétéroscédasticité.

Cas 176 — Normalité des résidus. Pourquoi et comment tester la normalité des résidus ?

Solution. Pour la validité **exacte** des tests t/F à petit n. On utilise **Jarque–Bera** (chapitre 6) sur les résidus.

Cas 177 — Corrélation fallacieuse (spurious). Qu'est-ce qu'une régression fallacieuse et quand survient-elle ?

Solution. Un R^2 élevé **sans lien réel**, typique de deux séries **tendancielles** (non stationnaires) régressées en niveaux. Remède : travailler sur les rendements/différences.

Cas 178 — Pourquoi régresser les rendements ?. Pourquoi préfère-t-on régresser des rendements plutôt que des prix ?

Solution. Les rendements sont ~**stationnaires** ; les prix sont tendanciels et produisent des corrélations fallacieuses (spurious).

Cas 179 — Variable omise — diagnostic. Comment soupçonner une variable omise pertinente ?

Solution. Signes : résidus structurés, coefficients au signe contre-intuitif, instabilité selon l'échantillon. Test théorique : un facteur connu influençant X et Y est-il absent ?

Cas 180 — Multicolinéarité — effet. Quel est l'effet de la multicolinéarité en régression multiple ?

Solution. Forte corrélation entre régresseurs $\Longrightarrow$ **erreurs-types gonflées** et coefficients instables, sans biais. Les t individuels chutent alors que le F reste significatif.

Cas 181 — Point aberrant vs point à levier. Distinguer un point aberrant (outlier) d'un point à fort levier.

Solution. **Aberrant** : grand résidu (Y loin de la droite) ; **levier** : X loin de $\bar{x}$ (influence forte sur la pente). Un point à la fois aberrant et à fort levier est le plus dangereux.

Cas 182 — Robustesse de β vs des SE. Résumer l'effet des violations sur β et sur les SE.

Solution. Hétéroscédasticité et autocorrélation : β **sans biais**, SE **faussées**. Endogénéité : β **biaisé**. D'où les remèdes robustes (SE) vs variables instrumentales (biais).

Cas 183 — Inspection avant conclusion. Quel réflexe adopter avant d'interpréter les tests d'une régression ?

Solution. **Examiner les résidus** (graphique) et vérifier les hypothèses : sans cela, les t et F peuvent être trompeurs.

Cas 184 — Transformer pour corriger la non-linéarité. Le graphique des résidus révèle une courbure. Quelle piste simple ?

Solution. **Transformer** les variables (log, carré) ou ajouter un terme quadratique X^2 : le modèle reste linéaire en β tout en captant la courbure.

Bloc 10 --- Régression multiple, R^2 ajusté et synthèse

Cas 185 — Modèle de régression multiple. Écrire un modèle de régression multiple à k régresseurs.

Solution. $Y=\beta_0+\beta_1X_1+\beta_2X_2+...+\beta_k\ X_k+\varepsilon$. Chaque β_j mesure l'effet de X_j **toutes choses égales par ailleurs**.

Cas 186 — Interprétation « toutes choses égales par ailleurs ». Que mesure un coefficient en régression multiple ?

Solution. L'effet **partiel** de X_j sur Y, les autres régresseurs maintenus **constants** : l'effet propre, purgé des autres variables.

Cas 187 — R^2 ajusté — définition. Définir le R^2 ajusté et son rôle.

Solution. $\bar{R}^2=1-(RSS/(n-k-1))/(TSS/(n-1))=1-(1-R^2)(n-1)/(n-k-1)$: il **pénalise l'ajout de régresseurs** pour éviter l'inflation du R^2.

Cas 188 — R^2 vs R^2 ajusté. Quelle différence de comportement entre R^2 et R^2 ajusté quand on ajoute un régresseur ?

Solution. Le **R^2 ne décroît jamais** (même régresseur inutile) ; le **R^2 ajusté peut décroître** si le régresseur n'apporte rien. $\bar{R}^2 \leq R^2$.

Cas 189 — R^2 ajusté — calcul. R^2=0,7, n=50, k=3. Calculer le R^2 ajusté.

Solution. $\bar{R}^2 = 1-(1-0{,}7)(49/46) = 1-0{,}3\times 1{,}065 = 1-0{,}3196 = \mathbf{0{,}6804}$.

Cas 190 — À quoi sert le R^2 ajusté. Pourquoi utiliser le R^2 ajusté plutôt que le R^2 brut ?

Solution. Pour **comparer des modèles de tailles différentes** (nombre de régresseurs) sans favoriser mécaniquement le plus complexe.

Cas 191 — Surajustement (overfitting). Qu'est-ce que le surajustement et comment s'en prémunir ?

Solution. Un modèle qui épouse le **bruit** de l'échantillon et prévoit mal hors échantillon. Remèdes : $\bar{R}^2$, critères AIC/BIC, validation hors échantillon, parcimonie.

Cas 192 — Multicolinéarité — définition. Qu'est-ce que la multicolinéarité ?

Solution. Une **forte corrélation entre régresseurs**. Elle gonfle les erreurs-types et rend les coefficients instables, sans les biaiser.

Cas 193 — F significatif, t non significatifs. Comment un modèle peut-il avoir un F significatif mais des t individuels non significatifs ?

Solution. Par **multicolinéarité** : les régresseurs corrélés se « partagent » l'explication (t faibles) tout en expliquant conjointement Y (F élevé).

Cas 194 — Effet partiel vs effet total. Le coefficient d'une variable en multiple égale-t-il celui de la même variable seule ?

Solution. **Pas en général** : en multiple, il est purgé de l'effet des autres régresseurs (effet partiel), différent de l'effet marginal simple.

Cas 195 — Parcimonie. Pourquoi préférer un modèle parcimonieux ?

Solution. Moins de régresseurs $\Longrightarrow$ moins de surajustement, coefficients plus stables, meilleure prévision hors échantillon et interprétation plus claire.

Cas 196 — Chaîne Ch6 → Ch7. Comment le chapitre 6 se prolonge-t-il dans la régression ?

Solution. Les tests t et F du chapitre 6 s'appliquent aux **coefficients** (t) et à la significativité **globale** (F) du modèle : la régression est de l'inférence appliquée à une relation.

Cas 197 — Résumé de la démarche. Résumer les étapes d'une analyse de régression.

Solution. Modèle $\longrightarrow$ estimation MCO $\longrightarrow$ ajustement (R^2) $\longrightarrow$ précision (SE) $\longrightarrow$ tests (t, F) $\longrightarrow$ prévision (IC) $\longrightarrow$ diagnostics (résidus).

Cas 198 — R^2 ajusté peut-il être négatif ?. Le R^2 ajusté peut-il devenir négatif ?

Solution. **Oui** : si les régresseurs n'expliquent quasiment rien (R^2 très faible avec beaucoup de régresseurs), $\bar{R}^2$ peut passer sous 0.

Cas 199 — Choisir entre deux modèles emboîtés. Comment décider si un régresseur supplémentaire mérite d'être gardé ?

Solution. Vérifier sa **significativité** (test t), l'évolution du **R^2 ajusté**, et la performance **hors échantillon** — pas le seul R^2 brut.

Cas 200 — La phrase de synthèse du chapitre. Résumer la régression linéaire en une phrase.

Solution. La régression estime par MCO la droite qui relie Y à X ($\beta_1 = \mathrm{Cov}/\mathrm{Var}$), mesure son ajustement ($R^2 = r^2$) et teste ses coefficients (t, F) — un outil de description, d'explication et de prévision, valable sous les hypothèses de Gauss–Markov.

Partie C --- Méthodologie, formulaire et astuces

Condensé de révision : toutes les formules de la régression, un glossaire bilingue, la démarche en étapes et les pièges classiques.

C.1 --- Formulaire de la régression

Modèle et estimation MCO

$$\text{Modèle : } Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i; \qquad \text{Ajusté : } \hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i; \qquad \text{Résidu : } e_i = Y_i - \hat{Y}_i.$$

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{\text{Cov}(X,Y)}{\text{Var}(X)} = r\frac{s_Y}{s_X}; \qquad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Décomposition et ajustement

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{\text{TSS}} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{\text{ESS}} + \underbrace{\sum e_i^2}_{\text{RSS}}; \qquad R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}} = r^2.$$

Erreurs-types et inférence

$$s_e = \sqrt{\frac{\text{RSS}}{n-2}}; \qquad \text{SE}(\hat{\beta}_1) = \frac{s_e}{\sqrt{\sum (X_i - \bar{X})^2}}; \qquad t = \frac{\hat{\beta}_1 - \beta_1^*}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2}.$$

$$\text{IC}(\beta_1) = \hat{\beta}_1 \pm t_{n-2} \cdot \text{SE}(\hat{\beta}_1); \qquad F = \frac{\text{ESS}/k}{\text{RSS}/(n-k-1)} = t^2 \ (\text{si } k = 1).$$

Prévision et régression multiple

$$\text{IC moyenne : } \pm t\, s_e \sqrt{\tfrac{1}{n} + \tfrac{(x_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2}}; \qquad \text{IC prévision : } \pm t\, s_e \sqrt{1 + \tfrac{1}{n} + \tfrac{(x_0 - \bar{X})^2}{\sum (X_i - \bar{X})^2}}.$$

$$\bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1} \ (\text{R}^2 \text{ ajusté}).$$

C.2 --- Population vs échantillon en régression

Concept	Population (vrai)	Échantillon (estimé)
Pente	β_1	$\hat{\beta}_1$
Ordonnée	β_0	$\hat{\beta}_0$
Aléa / écart	Erreur ε_i (inobservable)	Résidu $e_i = Y_i - \hat{Y}_i$
Prédiction	$\mathbb{E}[Y \mid X] = \beta_0 + \beta_1 X$	$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$
Dispersion des erreurs	σ	$s_e = \sqrt{\text{RSS}/(n-2)}$

C.3 --- Carte de décision : quel outil pour quelle question ?

Question	Outil	Loi / repère
Quelle est la meilleure droite ?	MCO : $\hat{\beta}_1 = s_{XY}/s_X^2$	BLUE si Gauss–Markov
Quelle part de Y est expliquée ?	$R^2 = \text{ESS}/\text{TSS} = r^2$	$\in [0,1]$
La pente est-elle significative ?	$t = \hat{\beta}_1/\text{SE}$	t_{n-2}
Le bêta diffère-t-il de 1 ?	$t = (\hat{\beta}_1 - 1)/\text{SE}$	t_{n-2}
L'alpha est-il positif ?	$t = \hat{\beta}_0/\text{SE}$ (unilat.)	t_{n-2}
Le modèle est-il globalement utile ?	$F = t^2$	$F_{k,n-k-1}$
Où se situe la vraie droite ?	IC de la moyenne	$\pm t\, s_e\sqrt{\dots}$
Quelle valeur future pour Y_0 ?	IC de prévision	$+1$ sous la racine
Les hypothèses tiennent-elles ?	Graphe des résidus, White, DW	Diagnostics

C.4 --- Glossaire bilingue

Français	Anglais	Repère
Régression linéaire	Linear regression	$Y = \beta_0 + \beta_1 X + \varepsilon$
Variable dépendante	Dependent variable	Y (expliquée)
Variable indépendante	Independent variable	X (explicative)
Moindres carrés ordinaires	Ordinary least squares (OLS)	Minimise $\sum e_i^2$
Pente	Slope	$\hat{\beta}_1 = \text{Cov} \,/\, \text{Var}$
Ordonnée à l'origine	Intercept	$\hat{\beta}_0$
Terme d'erreur	Error term	ε (population)
Résidu	Residual	$e_i = Y_i - \hat{Y}_i$
Valeur ajustée	Fitted value	$\hat{Y}_i$
Exogénéité	Exogeneity	$\mathbb{E}[\varepsilon \mid X] = 0$
Homoscédasticité	Homoskedasticity	$\text{Var}(\varepsilon) = \sigma^2$
Hétéroscédasticité	Heteroskedasticity	Variance non constante
Autocorrélation	Autocorrelation	$\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$
Endogénéité	Endogeneity	X corrélé à ε
Coefficient de détermination	Coefficient of determination	$R^2 = \text{ESS}/\text{TSS}$
Somme des carrés totale	Total sum of squares (TSS)	$\sum (Y_i - \bar{Y})^2$
Somme des carrés expliquée	Explained sum of squares (ESS)	$\sum (\hat{Y}_i - \bar{Y})^2$
Somme des carrés résiduelle	Residual sum of squares (RSS)	$\sum e_i^2$
BLUE	Best Linear Unbiased Estimator	Gauss–Markov
Multicolinéarité	Multicollinearity	Régresseurs corrélés
R^2 ajusté	Adjusted R^2	Pénalise k
Surajustement	Overfitting	Épouse le bruit
Bêta / Alpha de Jensen	Beta / Jensen's alpha	Pente / ordonnée du modèle de marché
Intervalle de prévision	Prediction interval	Ajoute l'aléa individuel

C.5 --- Méthode d'analyse en sept étapes

1. **Spécifier le modèle.** Choisir Y (expliquée) et X (explicative) ; en finance, souvent des *rendements* (stationnaires), pas des niveaux.
2. **Estimer par MCO.** $\hat{\beta}_1 = \mathrm{Cov}(X,Y)/\mathrm{Var}(X)$, $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X}$. La droite passe par $(\bar{X},\bar{Y})$.
3. **Mesurer l'ajustement.** $R^2 = \mathrm{ESS}/\mathrm{TSS} = r^2$: part de variance expliquée (systématique) ; $1-R^2$ = spécifique.
4. **Évaluer la précision.** $s_e = \sqrt{\mathrm{RSS}/(n-2)}$, puis $\mathrm{SE}(\hat{\beta}_1)$ — d'autant plus petite que X est dispersé et n grand.
5. **Tester.** Coefficient : $t = \hat{\beta}_1/\mathrm{SE} \sim t_{n-2}$ (pour un bêta, tester $H_0 : \beta = 1$). Global : $F = t^2$.
6. **Prévoir avec incertitude.** Distinguer IC de la moyenne (position de la droite) et IC de prévision (observation individuelle, plus large) ; ne pas extrapoler hors du domaine des X.
7. **Diagnostiquer.** Examiner le graphe des résidus (entonnoir $\to$ hétéroscédasticité, courbure $\to$ non-linéarité, dérive $\to$ autocorrélation) ; corriger par SE robustes (White, Newey–West) sans changer $\hat{\beta}$.

C.6 --- Les dix pièges classiques

À éviter absolument

(1) Confondre erreur ε (population, inobservable) et résidu e (échantillon, observable).
(2) Écrire $\hat{\beta}_1 = \mathrm{Var}\,/\,\mathrm{Cov}$ au lieu de $\mathrm{Cov}\,/\,\mathrm{Var}$.
(3) Croire que $R^2 = r^2$ en régression *multiple* (vrai seulement en simple).
(4) Tester un bêta contre 0 au lieu de 1 quand la question est le risque de marché.
(5) Penser que l'hétéroscédasticité ou l'autocorrélation *biaisent* $\hat{\beta}$ (elles ne faussent que les SE).
(6) Oublier que l'endogénéité (variable omise, causalité inverse) *biaise* $\hat{\beta}$.
(7) Confondre le rôle du F ($F = t^2$ en simple, utile surtout en multiple) et des t individuels.
(8) Conclure à la *causalité* à partir d'un R^2 élevé ou d'une pente significative.
(9) Extrapoler loin du domaine des X (l'IC de prévision explose ; linéarité non garantie).
(10) Oublier que l'IC de prévision est *plus large* que l'IC de la moyenne (terme $+1$).

C.7 --- Astuces de calcul rapide

- **Bêta express** : $\hat{\beta} = \mathrm{Cov}(R_a,R_m)/\mathrm{Var}(R_m)$; se lit directement d'une sortie covariance/variance.
- **Ordonnée** : $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X}$; la droite passe toujours par $(\bar{X},\bar{Y})$.
- **Corrélation depuis R^2** : $|r| = \sqrt{R^2}$; signe donné par celui de $\hat{\beta}_1$.
- **Décomposition** : $\mathrm{RSS} = \mathrm{TSS}(1-R^2)$; $\mathrm{ESS} = \mathrm{TSS}\cdot R^2$.
- $F = t^2$: en régression simple, $t = 3 \Rightarrow F = 9$; $\sqrt{F} = |t|$.
- **ddl** : toujours $n-2$ pour les tests de coefficients (deux paramètres estimés).
- **Test du bêta** : $t = (\hat{\beta}_1 - 1)/\mathrm{SE}$; un bêta de 1,2 avec SE 0,15 donne $t = 1{,}33$ (non significatif vs 1).
- **SE de la pente** : $\mathrm{SE}(\hat{\beta}_1) = s_e/\sqrt{\sum(X_i-\bar{X})^2}$; plus X est dispersé, plus la pente est précise.
- **R^2 ajusté** : $\bar{R}^2 = 1-(1-R^2)\frac{n-1}{n-k-1}$; utile pour comparer des modèles de tailles différentes.

Partie D --- 200 questions à choix multiple

200 questions de style examen, par thème et de difficulté croissante. Une seule réponse correcte. Corrigé commenté en Partie E.

Thème 1 --- Le modèle de régression et sa terminologie

Q1. Le modèle de régression linéaire simple s'écrit :

- (a) $Y=\beta_0+\beta_1 X+\varepsilon$
- (b) $Y=\beta_1 X$
- (c) $Y=\beta_0+\varepsilon$
- (d) $Y=\beta_0 X+\beta_1$

Q2. Dans $Y=\beta_0+\beta_1 X+\varepsilon$, β_1 représente :

- (a) la valeur de Y quand $X=0$
- (b) la variation de Y pour +1 unité de X
- (c) le terme d'erreur
- (d) la corrélation

Q3. β_0 représente :

- (a) la pente
- (b) la variance de Y
- (c) $E[Y|X=0]$
- (d) le résidu moyen

Q4. Le terme d'erreur ε capte :

- (a) seulement les erreurs de mesure
- (b) la pente
- (c) la moyenne de Y
- (d) tout ce que X n'explique pas

Q5. La variable dépendante est :

- (a) Y (expliquée, régressande)
- (b) X (explicative)
- (c) ε
- (d) β_1

Q6. Le résidu e_i est :

- (a) ε_i (inobservable)
- (b) $Y_i-\hat{Y}_i$ (observable)
- (c) $\hat{\beta}_1$
- (d) $X_i-\bar{X}$

Q7. La différence entre ε_i et e_i :

- (a) ce sont des synonymes
- (b) ε est observé, e non
- (c) ε est de population (inobservable), e est le résidu observé
- (d) aucune

Q8. β_1 (paramètre) vs $\hat{\beta}_1$ (estimation) :

- (a) ce sont les mêmes
- (b) $\hat{\beta}_1$ est la population
- (c) β_1 est aléatoire
- (d) β_1 est le vrai paramètre inconnu, $\hat{\beta}_1$ son estimation

Q9. La droite de régression $E[Y|X]$ vaut :

- (a) $\beta_0+\beta_1 X$
- (b) $\hat{\beta}_0+\hat{\beta}_1 X$ uniquement
- (c) $\beta_1 X$
- (d) $\bar{y}$

Q10. La valeur ajustée $\hat{Y}_i$ est :

- (a) $Y_i - e_i$ seulement par définition inverse
- (b) $\hat{\beta}_0+\hat{\beta}_1 X_i$
- (c) ε_i
- (d) $\bar{X}$

Q11. En finance, dans le modèle de marché, la pente est :

- (a) l'alpha
- (b) le R^2
- (c) le bêta
- (d) la volatilité

Q12. L'ordonnée à l'origine du modèle de marché est :

- (a) le bêta
- (b) le R^2
- (c) le résidu
- (d) l'alpha de Jensen

Q13. La « linéarité » de la régression porte sur :

- (a) les paramètres β
- (b) nécessairement X
- (c) Y uniquement
- (d) les résidus

Q14. Régresser Y sur X vs X sur Y donne :

- (a) la même droite
- (b) des pentes différentes en général
- (c) toujours des pentes inverses
- (d) le même R^2 et la même pente

Q15. Les trois usages de la régression sont :

- (a) estimer, biaiser, tester
- (b) trier, moyenner, coller
- (c) décrire, expliquer, prévoir
- (d) additionner, multiplier, diviser

Q16. Une pente non nulle prouve :

- (a) une causalité certaine
- (b) l'indépendance
- (c) la normalité
- (d) une association, pas une causalité

Q17. Si X passe de % à pb (×100), $\hat{\beta}_1$ est :

- (a) divisé par 100
- (b) multiplié par 100
- (c) inchangé
- (d) annulé

Q18. Pourquoi ajoute-t-on ε au modèle ?

- (a) pour biaiser
- (b) car la relation n'est pas exacte (aléa)
- (c) pour aligner les points
- (d) par convention inutile

Q19. Le régresseur est :

- (a) Y
- (b) ε
- (c) X (variable explicative)
- (d) β_0

Q20. Interpréter β_0 quand X=0 est hors du domaine observé :

- (a) est toujours fiable
- (b) est interdit par principe
- (c) donne la pente
- (d) relève de l'extrapolation (prudence)

Thème 2 --- Estimation par les moindres carrés (MCO)

Q21. Les MCO minimisent :

- (a) la somme des carrés des résidus Σe_i^2
- (b) $\Sigma|e_i|$
- (c) Σe_i
- (d) le R^2

Q22. L'estimateur MCO de la pente est :

- (a) $\mathrm{Var}(X)/\mathrm{Cov}(X,Y)$
- (b) $\mathrm{Cov}(X,Y)/\mathrm{Var}(X)$
- (c) $\mathrm{Cov}(X,Y)$
- (d) r

Q23. β_0 vaut :

- (a) $\bar{x}-\beta_1\bar{y}$
- (b) $\bar{y}$
- (c) $\bar{y}-\beta_1\bar{x}$
- (d) $\beta_1\bar{x}$

Q24. La droite MCO passe toujours par :

- (a) (0,0)
- (b) ($\bar{x}$,0)
- (c) (0,$\bar{y}$)
- (d) ($\bar{x}$, $\bar{y}$)

Q25. La somme des résidus MCO (avec ordonnée) vaut :

- (a) 0
- (b) 1
- (c) n
- (d) $\bar{y}$

Q26. La somme $\Sigma X_i e_i$ vaut :

- (a) Σe_i
- (b) 0
- (c) n
- (d) β_1

Q27. β_1 via la corrélation :

- (a) r·(s_X/s_Y)
- (b) r
- (c) r·(s_Y/s_X)

- (d) r^2

Q28. Cov(R_a,R_m)=0,0018, Var(R_m)=0,0012. Le bêta vaut :

- (a) 0,67
- (b) 2,4
- (c) 0,0015
- (d) 1,5

Q29. β_1=0,8, $\bar{x}$=5 %, $\bar{y}$=6 %. β_0 vaut :

- (a) 2 %
- (b) 1 %
- (c) 11 %
- (d) −2 %

Q30. $\hat{Y}$=2+0,8X. Prédiction pour X=10 :

- (a) 8
- (b) 10
- (c) 2
- (d) 0,8

Q31. $\hat{Y}$=2+0,8X, Y observé=11 pour X=10. Le résidu vaut :

- (a) −1
- (b) 0
- (c) +1
- (d) 10

Q32. β_1=0 signifie :

- (a) relation parfaite
- (b) forte corrélation
- (c) X constant
- (d) aucune relation linéaire (droite horizontale)

Q33. Le signe de β_1 est celui de :

- (a) la covariance (et de r)
- (b) la variance de X
- (c) toujours positif
- (d) $\bar{y}$

Q34. Les MCO minimisent-ils $\Sigma|e_i|$?

- (a) Oui
- (b) Non, ils minimisent Σe_i^2
- (c) Oui à petit n

- (d) Oui si normal

Q35. Un point aberrant affecte fortement la droite car :

- (a) il est ignoré
- (b) il annule la pente
- (c) les carrés amplifient les grands écarts
- (d) les résidus s'annulent

Q36. Un point à fort levier a :

- (a) un Y très éloigné de $\bar{y}$
- (b) un résidu nul
- (c) une forte covariance
- (d) un X très éloigné de $\bar{x}$

Q37. $\hat{\alpha}$=0,2 %, β=1,2. Rendement prédit si marché +5 % :

- (a) 6,2 %
- (b) 5,2 %
- (c) 6 %
- (d) 1,2 %

Q38. Combien d'équations normales en régression simple ?

- (a) 1
- (b) 2 ($\Sigma e_i=0$ et $\Sigma X_i e_i=0$)
- (c) 3
- (d) n

Q39. Si X est constant, β_1 est :

- (a) nul
- (b) infini toujours
- (c) indéfini ($\mathrm{Var}(X)=0$)
- (d) égal à $\bar{y}$

Q40. $\bar{x}=3$, $\bar{y}=7$, $\Sigma(x_i-\bar{x})(y_i-\bar{y})=20$, $\Sigma(x_i-\bar{x})^2=10$. β_1 vaut :

- (a) 0,5
- (b) 20
- (c) 10
- (d) 2

Q41. Avec les données précédentes, β_0 vaut :

- (a) 1
- (b) 7
- (c) 3

- (d) -1

Q42. Régresser deux prix qui montent tous deux dans le temps donne souvent :

- (a) une causalité prouvée
- (b) une corrélation fallacieuse (spurious)
- (c) $\beta_1=0$
- (d) un R^2 nul

Thème 3 --- Hypothèses de Gauss--Markov et BLUE

Q43. Le théorème de Gauss–Markov affirme que les MCO sont :

- (a) biaisés
- (b) non consistants
- (c) BLUE (variance minimale, sans biais, linéaires)
- (d) toujours normaux

Q44. L'hypothèse d'exogénéité s'écrit :

- (a) $\mathrm{Var}(\varepsilon)=\sigma^2$
- (b) $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0$
- (c) $E[X]=0$
- (d) $E[\varepsilon|X]=0$

Q45. L'homoscédasticité signifie :

- (a) $\mathrm{Var}(\varepsilon_i)=\sigma^2$ constante
- (b) $E[\varepsilon|X]=0$
- (c) erreurs corrélées
- (d) X constant

Q46. L'absence d'autocorrélation s'écrit :

- (a) $\mathrm{Var}(\varepsilon)=\sigma^2$
- (b) $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0$ pour $i\neq j$
- (c) $E[\varepsilon]=0$
- (d) $\beta_1=0$

Q47. Dans BLUE, le « B » signifie :

- (a) Biased
- (b) Bounded
- (c) Best (variance minimale)
- (d) Bayesian

Q48. La violation la plus grave est celle de :

- (a) l'homoscédasticité

- (b) l'autocorrélation
- (c) la variabilité de X
- (d) l'exogénéité (biaise β)

Q49. L'hétéroscédasticité :

- (a) ne biaise pas β mais fausse les SE
- (b) biaise β
- (c) rend β non défini
- (d) annule β

Q50. La normalité des erreurs est requise pour :

- (a) l'absence de biais de β
- (b) la validité exacte des tests t/F à petit n
- (c) le calcul de β
- (d) le R^2

Q51. $E[\beta_1]=\beta_1$ signifie :

- (a) β_1 est biaisé
- (b) β_1 est constant
- (c) β_1 est sans biais
- (d) β_1 est nul

Q52. Sous endogénéité, β_1 est :

- (a) sans biais
- (b) BLUE
- (c) efficace
- (d) biaisé et non consistant

Q53. « Variance minimale » dans BLUE signifie :

- (a) le plus efficace parmi les estimateurs linéaires sans biais
- (b) le plus biaisé
- (c) le plus grand n
- (d) le plus simple

Q54. Une variable omise Z crée un biais si :

- (a) Z est indépendante de tout
- (b) Z influence Y et est corrélée à X
- (c) Z n'influence que ε
- (d) Z=X

Q55. La causalité inverse provoque :

- (a) de l'hétéroscédasticité

- (b) un R^2 nul
- (c) de l'endogénéité (β biaisé)
- (d) aucun effet

Q56. Pourquoi X doit-il varier (H5) ?

- (a) pour normaliser Y
- (b) pour annuler le biais
- (c) pour réduire ε
- (d) sinon $\Sigma(X_i - \bar{x})^2 = 0$ et β_1 n'est pas défini

Q57. Les MCO sont « linéaires » car β est :

- (a) une combinaison linéaire des Y_i
- (b) une fonction de β^2
- (c) non linéaire en Y
- (d) indépendant de Y

Q58. Pour des tests valides, il faut :

- (a) seulement n=10
- (b) Gauss–Markov + normalité (ou n grand)
- (c) aucune hypothèse
- (d) β biaisé

Q59. Corriger des SE faussées sans changer β :

- (a) ré-estimer par LAD
- (b) supprimer des points
- (c) erreurs-types robustes (White, Newey–West)
- (d) changer Y

Q60. L'endogénéité se traite par :

- (a) erreurs-types de White
- (b) un plus grand α
- (c) le R^2 ajusté
- (d) variables instrumentales

Q61. β_1 consistant signifie :

- (a) $\beta_1 \to \beta_1$ quand $n \to \infty$
- (b) $\beta_1 = \beta_1$ à n fini
- (c) Var constante
- (d) biais constant

Q62. Les MCO sont BLUE :

- (a) seulement si normal

- (b) sans hypothèse de normalité
- (c) seulement si n>30
- (d) jamais

Thème 4 --- Décomposition de la variance et R^2

Q63. La décomposition fondamentale est :

- (a) $TSS = ESS - RSS$
- (b) $RSS = ESS + TSS$
- (c) $TSS = ESS + RSS$
- (d) $ESS = TSS \times RSS$

Q64. Le R^2 vaut :

- (a) RSS/TSS
- (b) TSS/ESS
- (c) ESS/RSS
- (d) $ESS/TSS = 1 - RSS/TSS$

Q65. En régression simple, R^2 égale :

- (a) r^2 (carré de la corrélation)
- (b) r
- (c) 2r
- (d) 1−r

Q66. Un R^2=0,64 dans un modèle de marché signifie :

- (a) 64 % de rendement
- (b) 64 % de variance expliquée par le marché
- (c) corrélation 0,64
- (d) bêta 0,64

Q67. R^2=1 signifie :

- (a) aucun ajustement
- (b) β_1=0
- (c) ajustement parfait (RSS=0)
- (d) corrélation nulle

Q68. R^2=0 signifie :

- (a) ajustement parfait
- (b) forte pente
- (c) RSS=0
- (d) aucun pouvoir explicatif (β_1=0)

Q69. TSS mesure :

- (a) la variabilité totale de Y
- (b) la variabilité expliquée
- (c) les résidus
- (d) la variance de X

Q70. Pourquoi pas de terme croisé dans TSS=ESS+RSS ?

- (a) par hypothèse arbitraire
- (b) $\Sigma(\hat{y}_i - \bar{y})e_i = 0$ (équations normales)
- (c) car ESS=0
- (d) car RSS=0

Q71. Un R^2 élevé prouve-t-il la causalité ?

- (a) Oui
- (b) Oui si n grand
- (c) Non (mesure d'ajustement)
- (d) Oui si $\beta_1 > 0$

Q72. TSS=200, RSS=50. R^2 vaut :

- (a) 0,25
- (b) 0,5
- (c) 4
- (d) 0,75

Q73. R^2=0,6, TSS=500. ESS vaut :

- (a) 300
- (b) 200
- (c) 0,6
- (d) 833

Q74. R^2 se relie au risque par :

- (a) R^2 = part spécifique
- (b) R^2 = part systématique, $1-R^2$ = part spécifique
- (c) R^2 = volatilité totale
- (d) $1-R^2$ = bêta

Q75. Un fort R^2 implique-t-il une forte pente ?

- (a) Oui
- (b) Oui toujours
- (c) Non (R^2 mesure l'alignement, pas la magnitude)
- (d) Oui si r>0

Q76. R^2=0,49 en régression simple. |r| vaut :

- (a) 0,49
- (b) 0,24
- (c) 0,98
- (d) 0,7

Q77. Le R^2 peut-il être négatif en MCO avec constante ?

- (a) Non ($R^2 \in [0,1]$)
- (b) Oui souvent
- (c) Oui si $\beta_1 < 0$
- (d) Oui à petit n

Q78. Deux modèles sur les mêmes Y, R^2=0,4 vs 0,7. Le meilleur ajustement :

- (a) R^2=0,4
- (b) R^2=0,7
- (c) indéterminé
- (d) ni l'un ni l'autre

Q79. ESS représente :

- (a) la variabilité résiduelle
- (b) la variabilité totale
- (c) la variabilité expliquée par la droite
- (d) la variance de X

Q80. RSS représente :

- (a) la variabilité expliquée
- (b) la variabilité totale
- (c) le R^2
- (d) la variabilité résiduelle (non expliquée)

Q81. Un R^2=0,15 sur une action individuelle est :

- (a) normal (fort risque spécifique)
- (b) rédhibitoire
- (c) impossible
- (d) preuve d'erreur

Q82. R^2=0,81 en régression simple. La corrélation vaut :

- (a) 0,81
- (b) 0,9 en valeur absolue
- (c) 0,66
- (d) 0,45

Q83. Comparer des modèles de tailles différentes exige :

- (a) le R^2 brut
- (b) la pente
- (c) le R^2 ajusté
- (d) la corrélation

Q84. Le R^2 mesure :

- (a) la causalité
- (b) la validité du modèle
- (c) l'absence de biais
- (d) la qualité d'ajustement

Thème 5 --- Erreurs-types de la régression et des coefficients

Q85. L'erreur-type de la régression s_e vaut :

- (a) $\sqrt{(RSS/(n-2))}$
- (b) $\sqrt{(RSS/n)}$
- (c) $RSS/(n-2)$
- (d) $\sqrt{(TSS/n)}$

Q86. Pourquoi diviser RSS par $n-2$?

- (a) un seul paramètre
- (b) deux paramètres estimés (β_0, β_1)
- (c) n paramètres
- (d) aucun paramètre

Q87. $SE(\beta_1)$ vaut :

- (a) $s_e \cdot \sqrt{\Sigma(X_i - \bar{x})^2}$
- (b) s_e/n
- (c) $s_e/\sqrt{\Sigma(X_i - \bar{x})^2}$
- (d) $s_e{}^2/n$

Q88. Trois facteurs réduisant $SE(\beta_1)$:

- (a) s_e grand, X constant, n petit
- (b) seulement n
- (c) seulement α
- (d) s_e faible, X très dispersé, n grand

Q89. Un bêta estimé en marché calme est :

- (a) moins fiable (X peu dispersé)
- (b) plus fiable

- (c) sans erreur
- (d) biaisé

Q90. $SE(\beta_0)$ croît avec :

- (a) $\bar{y}$
- (b) $\bar{x}^2$ (les X loin de 0)
- (c) le R^2
- (d) β_1

Q91. Une petite erreur-type de régression traduit :

- (a) une forte pente
- (b) un X dispersé
- (c) des résidus faibles (bon ajustement)
- (d) un biais

Q92. L'erreur-type de la régression s'exprime en :

- (a) unité de X
- (b) sans dimension
- (c) unité de Y^2
- (d) unité de Y

Q93. Quand n augmente, $SE(\beta_1)$:

- (a) diminue
- (b) augmente
- (c) reste constante
- (d) s'annule

Q94. $s_e=2$, $\Sigma(X_i-\bar{x})^2=50$. $SE(\beta_1)$ vaut :

- (a) 0,04
- (b) 0,283
- (c) 2
- (d) 7,07

Q95. $SE(\beta_1)$ sert de :

- (a) numérateur du R^2
- (b) estimation de β_1
- (c) dénominateur du test t et demi-largeur de l'IC
- (d) valeur critique

Q96. s_e vs écart-type de Y :

- (a) $s_e \geq s_Y$ toujours
- (b) ce sont les mêmes

- (c) s_e mesure X
- (d) s_e mesure la dispersion résiduelle, s_Y la totale ($s_e \le s_Y$)

Q97. Un s_e faible correspond à un R^2 :

- (a) élevé
- (b) faible
- (c) nul
- (d) négatif

Q98. $s_e=3$, $\Sigma(X_i-\bar{x})^2=36$, $\beta_1=1{,}5$. La statistique t ($H_0:\beta_1=0$) vaut :

- (a) 0,5
- (b) 3,0
- (c) 1,5
- (d) 6

Q99. $SE(\beta_1)$ diminue quand X est :

- (a) constant
- (b) proche de 0
- (c) plus dispersé
- (d) normal

Q100. La précision de β_1 dépend surtout de :

- (a) la valeur de $\bar{y}$
- (b) le signe de β_0
- (c) α
- (d) la dispersion de X et de la taille d'échantillon

Q101. L'erreur-type de la régression estime :

- (a) σ, l'écart-type des erreurs
- (b) β_1
- (c) le R^2
- (d) la corrélation

Q102. $s_e=4$, $\Sigma(X_i-\bar{x})^2=64$. $SE(\beta_1)$ vaut :

- (a) 0,0625
- (b) 0,5
- (c) 4
- (d) 8

Q103. Un intervalle de confiance de β_1 utilise :

- (a) $\beta_1 \pm z \cdot s_Y$
- (b) $\beta_1 \pm SE(\beta_0)$

- (c) $\beta_1 \pm t \cdot SE(\beta_1)$
- (d) $\beta_1 \pm s_e$

Q104. Deux régressions, même s_e et β_1, X plus dispersé dans l'une : $SE(\beta_1)$ y est :

- (a) plus grande
- (b) identique
- (c) nulle
- (d) plus petite

Thème 6 --- Tests de significativité des coefficients

Q105. Pour tester $H_0:\beta_1=0$, la statistique est :

- (a) $t=\beta_1/SE(\beta_1) \sim t_{n-2}$
- (b) $z=\beta_1/\sigma$
- (c) $F=\beta_1$
- (d) $t=\beta_1/SE \sim t_n$

Q106. Combien de ddl pour tester un coefficient, n=42 ?

- (a) 42
- (b) 40
- (c) 41
- (d) 38

Q107. Pour un bêta, on teste souvent :

- (a) $H_0:\beta=0$ uniquement
- (b) $H_0:\beta=-1$
- (c) $H_0:\beta=1$ (risque de marché)
- (d) $H_0:\beta=R^2$

Q108. $\beta=1{,}2$, SE=0,15. La stat pour $H_0:\beta=1$ vaut :

- (a) 8
- (b) 2
- (c) 0,8
- (d) 1,33

Q109. $\beta=1{,}2$, SE=0,15 : le bêta diffère-t-il de 1 à 5 % ?

- (a) Non ($t=1{,}33<1{,}96$)
- (b) Oui
- (c) exactement à la borne
- (d) indéterminé

Q110. Tester l'alpha d'un fonds :

- (a) H_0:β_1=0
- (b) H_0:$\beta_0 \leq 0$ contre H_1:$\beta_0 > 0$, t=$\hat{\beta}_0$/SE
- (c) H_0:β_0=1
- (d) H_0:R^2=0

Q111. Une pente significative (t=5) mais valant 0,02 est :

- (a) très importante
- (b) non significative
- (c) peu importante (significativité ≠ matérialité)
- (d) biaisée

Q112. À β_1 et s_e fixés, |t| augmente quand :

- (a) n diminue
- (b) X est constant
- (c) σ augmente
- (d) n augmente

Q113. Un coefficient a t=0,9 (seuil 2,0). Conclusion :

- (a) ne pas rejeter H_0 (non significatif)
- (b) rejeter H_0
- (c) $\beta_1 \neq 0$
- (d) accepter H_1

Q114. L'hétéroscédasticité invalide le test t car :

- (a) elle biaise $\hat{\beta}_1$
- (b) elle fausse SE($\hat{\beta}_1$)
- (c) elle annule le t
- (d) elle change $\bar{y}$

Q115. Valeur critique t bilatérale à 5 %, n=22 (20 ddl) ≈ :

- (a) 1,96
- (b) 2,528
- (c) 2,086
- (d) 1,725

Q116. $\hat{\alpha}$=0,3 %, SE=0,12 %, n=40, unilatéral. t vaut :

- (a) 1,0
- (b) 0,4
- (c) 3,6
- (d) 2,5

Q117. Un régresseur $\hat{\beta}$=0,05, t=0,4 : faut-il le garder ?

- (a) Non (non significatif)
- (b) Oui absolument
- (c) Oui si R^2 monte
- (d) indéterminé

Q118. Un coefficient au signe contre-intuitif suggère :

- (a) un bon modèle
- (b) variable omise ou multicolinéarité
- (c) une causalité
- (d) un R^2=1

Q119. Tester deux coefficients conjointement nuls (multiple) se fait par :

- (a) deux tests t séparés
- (b) un test z
- (c) un test F partiel
- (d) le R^2

Q120. Deux échantillons, même β_1 et s_e, X plus dispersé dans l'un : |t| y est :

- (a) plus petit
- (b) identique
- (c) nul
- (d) plus grand

Q121. La statistique t d'un coefficient suit :

- (a) t_{n−2}
- (b) N(0,1) toujours
- (c) χ^2
- (d) F

Q122. Pour H_0:$\beta_1=\beta_1^*$ (valeur non nulle), t vaut :

- (a) β_1/SE
- (b) $(\beta_1-\beta_1^*)/SE(\beta_1)$
- (c) $(\beta_1-0)/SE$
- (d) β_1^*/SE

Q123. Un t=3,0 en régression simple correspond à F :

- (a) 3,0
- (b) 1,73
- (c) 9,0
- (d) 6

Q124. Le test de significativité d'un coefficient prolonge :

- (a) le test de Jarque–Bera
- (b) la LGN
- (c) le calcul du R^2
- (d) le test t du chapitre 6

Thème 7 --- Intervalles de confiance et de prévision

Q125. L'IC d'un coefficient est :

- (a) $\beta_1 \pm t \cdot SE(\beta_1)$
- (b) $\beta_1 \pm z \cdot \sigma$
- (c) $\beta_1 \pm s_e$
- (d) $\beta_1 \pm SE(\beta_0)$

Q126. IC à 95 % pour $\beta_1 = [0{,}9 ; 2{,}1]$. β_1 diffère-t-il de 0 ?

- (a) Non
- (b) Oui (0 hors IC)
- (c) exactement à la borne
- (d) indéterminé

Q127. Avec le même IC $[0{,}9 ; 2{,}1]$, β_1 diffère-t-il de 1 ?

- (a) Oui
- (b) exactement à la borne
- (c) Non (1 dans l'IC)
- (d) indéterminé

Q128. L'IC de prévision est, par rapport à l'IC de la moyenne :

- (a) plus étroit
- (b) identique
- (c) toujours nul
- (d) plus large

Q129. Le terme « +1 » de l'IC de prévision représente :

- (a) la variance de l'aléa individuel ε_0
- (b) l'erreur d'estimation de la droite
- (c) le biais
- (d) le R^2

Q130. Les intervalles sont les plus étroits en :

- (a) $x_0 = 0$
- (b) $x_0 = \bar{x}$
- (c) x_0 maximal
- (d) x_0 minimal

Q131. Extrapoler loin du domaine des X est risqué car :

- (a) l'intervalle rétrécit
- (b) β devient nul
- (c) l'intervalle explose et la linéarité n'est plus garantie
- (d) le R^2 monte

Q132. Quand $n \to \infty$, l'IC de prévision :

- (a) tend vers 0
- (b) devient infini
- (c) disparaît
- (d) garde une largeur $\pm t \cdot s_e$ (aléa individuel persiste)

Q133. $\beta_1 = 0{,}5$, SE = 0,1, n grand ($t \approx 1{,}96$). IC à 95 % :

- (a) [0,304 ; 0,696]
- (b) [0,4 ; 0,6]
- (c) [0,3 ; 0,7] exactement 0,2
- (d) [0,49 ; 0,51]

Q134. IC à 95 % pour une pente = [0,2 ; 0,8]. Le régresseur est :

- (a) non significatif
- (b) significatif (0 hors IC)
- (c) indéterminé
- (d) biaisé

Q135. Accompagner $\hat{Y}_0$ d'un intervalle sert à :

- (a) augmenter β_1
- (b) prouver la causalité
- (c) exprimer l'incertitude de la prévision
- (d) réduire le biais

Q136. Passer de 95 % à 99 % pour un IC de coefficient :

- (a) rétrécit l'IC
- (b) ne change rien
- (c) l'annule
- (d) élargit l'IC

Q137. En $x_0 = \bar{x}$, la demi-largeur de l'IC de la moyenne vaut :

- (a) $t \cdot s_e \cdot \sqrt{(1/n)}$
- (b) $t \cdot s_e \cdot \sqrt{(1+1/n)}$
- (c) $t \cdot s_e$
- (d) 0

Q138. L'IC de la moyenne encadre :

- (a) une observation individuelle
- (b) $E[Y|X=x_0]$ (la position de la droite)
- (c) β_1
- (d) le résidu

Q139. L'IC de prévision encadre :

- (a) la moyenne $E[Y|x_0]$
- (b) la pente
- (c) une nouvelle observation Y_0 en x_0
- (d) le R^2

Q140. Les deux sources d'incertitude de l'IC de prévision :

- (a) biais + variance de X
- (b) $\alpha + \beta$
- (c) $R^2 + s_e$
- (d) estimation de la droite + variabilité individuelle

Q141. La prévision d'un rendement pour un choc jamais observé relève de :

- (a) l'extrapolation hasardeuse
- (b) l'interpolation fiable
- (c) l'estimation sans biais
- (d) la description

Q142. IC à 95 % pour un bêta = [0,8 ; 1,3]. β diffère-t-il de 1 ?

- (a) Oui
- (b) Non (1 dans l'IC)
- (c) exactement à la borne
- (d) indéterminé

Q143. Un IC plus étroit pour β_1 reflète :

- (a) un effet plus fort
- (b) une plus grande confiance sur un tirage
- (c) une estimation plus précise
- (d) un biais

Q144. Où l'incertitude de prévision est-elle maximale ?

- (a) au centre $\bar{x}$
- (b) partout identique
- (c) en $x_0=0$ toujours
- (d) aux extrémités du domaine des X

Thème 8 --- Test F de significativité globale

Q145. Le test F global teste :

- (a) H_0 : tous les coefficients de pente sont nuls
- (b) H_0 : $\beta_0=0$
- (c) H_0 : $R^2=1$
- (d) la normalité

Q146. En régression simple, F égale :

- (a) t
- (b) t^2 (carré du t de la pente)
- (c) 2t
- (d) $\sqrt{t}$

Q147. La statistique F vaut :

- (a) ESS/RSS
- (b) (RSS/k)/(ESS/...)
- (c) (ESS/k)/(RSS/(n−k−1))
- (d) TSS/ESS

Q148. Le test F est vraiment utile en :

- (a) régression simple uniquement
- (b) tests de normalité
- (c) calcul du R^2
- (d) régression multiple (significativité conjointe)

Q149. Un F très supérieur à sa valeur critique signifie :

- (a) rejet de H_0 (modèle significatif)
- (b) non-rejet
- (c) $\beta_1=0$
- (d) $R^2=0$

Q150. F se relie au R^2 par :

- (a) $F=R^2$
- (b) $F=(R^2/k)/((1-R^2)/(n-k-1))$
- (c) $F=1-R^2$
- (d) $F=R^2\cdot n$

Q151. Le F répond à « le modèle sert-il ? » et les t à :

- (a) « quel est le R^2? »
- (b) « β_0 est-il nul? »
- (c) « quelle variable compte ? »

- (d) « ε est-il normal? »

Q152. La pente a t=3,0. F vaut :

- (a) 3,0
- (b) 1,73
- (c) 6
- (d) 9,0

Q153. R^2=0,64, k=1, n=42. F vaut environ :

- (a) 71,1
- (b) 4,08
- (c) 1,78
- (d) 36

Q154. Régression simple, n=42. Valeur critique F à 5 % ≈ :

- (a) 1,96
- (b) 4,08
- (c) 5,99
- (d) 9,21

Q155. F=12 sur (1,40), valeur critique 4,08. Décision :

- (a) non-rejet
- (b) indéterminé
- (c) rejet de H_0 (modèle significatif)
- (d) $\hat{\beta}_1$=0

Q156. À R^2 fixé, F évolue avec n en :

- (a) diminuant
- (b) restant constant
- (c) s'annulant
- (d) augmentant

Q157. Le numérateur de F représente :

- (a) la variance expliquée par ddl
- (b) la variance résiduelle
- (c) le R^2
- (d) la pente

Q158. Le dénominateur de F représente :

- (a) la variance expliquée
- (b) la variance résiduelle par ddl ($\approx s_e^2$)
- (c) TSS

- (d) β_1

Q159. Un modèle peut avoir F significatif mais t non significatifs à cause de :

- (a) l'homoscédasticité
- (b) un R^2=1
- (c) la multicolinéarité
- (d) β_0=0

Q160. La relation $F=t^2$ est valable :

- (a) en régression multiple
- (b) jamais
- (c) seulement si R^2=1
- (d) en régression simple (k=1)

Thème 9 --- Violations d'hypothèses et diagnostics

Q161. L'hétéroscédasticité :

- (a) ne biaise pas β mais fausse les SE
- (b) biaise β
- (c) annule β
- (d) rend β non défini

Q162. L'autocorrélation des erreurs :

- (a) biaise β
- (b) ne biaise pas β mais fausse les SE (souvent sous-estimées)
- (c) augmente le R^2
- (d) annule la pente

Q163. L'endogénéité :

- (a) ne fausse que les SE
- (b) augmente le R^2
- (c) biaise β et le rend non consistant
- (d) est sans effet

Q164. L'hétéroscédasticité est fréquente sur les rendements car :

- (a) les rendements sont constants
- (b) β est biaisé
- (c) X est normal
- (d) la volatilité varie dans le temps (clustering)

Q165. Corriger l'hétéroscédasticité sans changer β :

- (a) erreurs-types de White

- (b) ré-estimer par LAD
- (c) supprimer X
- (d) augmenter α

Q166. Corriger l'autocorrélation :

- (a) erreurs-types de White seules
- (b) erreurs-types de Newey–West
- (c) le R^2 ajusté
- (d) un test t

Q167. Le graphique des résidus sert à :

- (a) calculer β_1
- (b) prouver la causalité
- (c) diagnostiquer les violations (structure, entonnoir)
- (d) estimer le R^2

Q168. Un graphique de résidus en entonnoir révèle :

- (a) de la normalité
- (b) une pente nulle
- (c) une causalité
- (d) de l'hétéroscédasticité

Q169. Une structure courbe dans les résidus révèle :

- (a) une non-linéarité mal modélisée
- (b) de l'homoscédasticité
- (c) un bon ajustement
- (d) un R^2=1

Q170. La statistique de Durbin–Watson teste :

- (a) l'hétéroscédasticité
- (b) l'autocorrélation d'ordre 1 des résidus
- (c) la normalité
- (d) la multicolinéarité

Q171. Le test de Breusch–Pagan détecte :

- (a) l'autocorrélation
- (b) la non-normalité
- (c) l'hétéroscédasticité
- (d) l'endogénéité

Q172. Tester la normalité des résidus se fait par :

- (a) Durbin–Watson

- (b) Breusch–Pagan
- (c) le test F
- (d) Jarque–Bera

Q173. Une régression fallacieuse (spurious) survient avec :

- (a) deux séries tendancielles régressées en niveaux
- (b) des rendements stationnaires
- (c) un R^2 nul
- (d) une pente nulle

Q174. On régresse des rendements plutôt que des prix car :

- (a) les prix sont plus précis
- (b) les rendements sont ~stationnaires
- (c) les rendements sont normaux
- (d) β est alors nul

Q175. La multicolinéarité (multiple) :

- (a) biaise β
- (b) annule le F
- (c) gonfle les SE, rend les coefficients instables, sans biais
- (d) augmente les t

Q176. Un point aberrant a un grand :

- (a) X éloigné de $\bar{x}$
- (b) R^2
- (c) β_1
- (d) résidu (Y loin de la droite)

Q177. Un point à fort levier a un :

- (a) X éloigné de $\bar{x}$
- (b) grand résidu
- (c) R^2 nul
- (d) β_1 nul

Q178. Résumé : hétéroscédasticité et autocorrélation affectent :

- (a) β, pas les SE
- (b) les SE, pas β (sans biais)
- (c) ni l'un ni l'autre
- (d) le R^2 seulement

Q179. Avant d'interpréter t et F, le réflexe est :

- (a) maximiser le R^2

- (b) ajouter des régresseurs
- (c) examiner les résidus
- (d) ignorer les hypothèses

Q180. Une courbure dans les résidus se corrige par :

- (a) supprimer Y
- (b) ignorer
- (c) augmenter α
- (d) transformer les variables (log, X^2)

Thème 10 --- Régression multiple, R^2 ajusté et synthèse

Q181. Un modèle de régression multiple s'écrit :

- (a) $Y=\beta_0+\beta_1X_1+...+\beta_k\ X_k+\varepsilon$
- (b) $Y=\beta_0+\beta_1X$
- (c) $Y=\beta_1X_1X_2$
- (d) $Y=\Sigma\beta_j$

Q182. En multiple, β_j mesure :

- (a) l'effet total de X_j
- (b) l'effet partiel de X_j, autres variables constantes
- (c) la corrélation X_j–Y
- (d) le R^2

Q183. Le R^2 ajusté :

- (a) augmente toujours avec les régresseurs
- (b) ignore n
- (c) pénalise l'ajout de régresseurs
- (d) égale r^2

Q184. Quand on ajoute un régresseur, le R^2 brut :

- (a) décroît toujours
- (b) reste constant
- (c) devient négatif
- (d) ne décroît jamais

Q185. Le R^2 ajusté, lui :

- (a) peut décroître si le régresseur n'apporte rien
- (b) augmente toujours
- (c) est toujours négatif
- (d) égale le R^2

Q186. R^2=0,7, n=50, k=3. Le R^2 ajusté vaut ≈ :

- (a) 0,7
- (b) 0,68
- (c) 0,72
- (d) 0,65

Q187. Le R^2 ajusté sert surtout à :

- (a) prouver la causalité
- (b) calculer β_1
- (c) comparer des modèles de tailles différentes
- (d) tester la normalité

Q188. Le surajustement (overfitting) :

- (a) améliore la prévision
- (b) réduit le R^2
- (c) élimine le biais
- (d) épouse le bruit et prévoit mal hors échantillon

Q189. La multicolinéarité désigne :

- (a) une forte corrélation entre régresseurs
- (b) une corrélation X–Y forte
- (c) des erreurs corrélées
- (d) un R^2 nul

Q190. Un F significatif avec des t non significatifs s'explique par :

- (a) l'hétéroscédasticité
- (b) la multicolinéarité
- (c) un R^2=1
- (d) β_0=0

Q191. Le coefficient d'une variable en multiple vs seule :

- (a) est toujours identique
- (b) est toujours plus grand
- (c) diffère en général (effet partiel)
- (d) est nul

Q192. Un modèle parcimonieux est préféré car :

- (a) il a toujours un R^2 plus élevé
- (b) il ignore les données
- (c) il n'a pas d'erreur
- (d) moins de surajustement, plus stable, meilleure prévision

Q193. Le chapitre 6 se prolonge dans la régression via :

- (a) les tests t (coefficients) et F (global)
- (b) la LGN
- (c) le calcul de la médiane
- (d) les quantiles

Q194. La démarche de régression est :

- (a) prévision → modèle → MCO
- (b) modèle → MCO → R^2 → SE → tests → prévision → diagnostics
- (c) tests → R^2 → modèle
- (d) aucune séquence

Q195. Le R^2 ajusté peut-il être négatif ?

- (a) Non jamais
- (b) Seulement si n<10
- (c) Oui (régresseurs quasi inutiles)
- (d) Seulement si $\beta_1<0$

Q196. Garder un régresseur supplémentaire se décide sur :

- (a) le seul R^2 brut
- (b) le signe de β_0
- (c) la valeur de $\bar{y}$
- (d) significativité (t), R^2 ajusté, performance hors échantillon

Q197. La pente MCO s'écrit :

- (a) $\beta_1=\mathrm{Cov}(X,Y)/\mathrm{Var}(X)$
- (b) $\beta_1=\mathrm{Var}(X)/\mathrm{Cov}$
- (c) $\beta_1=r$
- (d) $\beta_1=\bar{y}/\bar{x}$

Q198. En régression simple, R^2 égale :

- (a) r
- (b) r^2
- (c) $1-r$
- (d) 2r

Q199. Les MCO sont optimaux (BLUE) sous :

- (a) la seule normalité
- (b) n>1000
- (c) les hypothèses de Gauss–Markov
- (d) aucune condition

Q200. La régression est un outil de :

- (a) seulement prévision
- (b) seulement description
- (c) causalité garantie
- (d) description, explication et prévision

Partie E --- Corrigé commenté des 200 QCM

Réponse correcte en gras suivie de l'explication. Distribution équilibrée (50 a, 50 b, 50 c, 50 d).

Thème 1 --- Le modèle de régression et sa terminologie

Q1 — (a) $Y=\beta_0+\beta_1X+\varepsilon$. β_0 ordonnée, β_1 pente, ε erreur.

Q2 — (b) la variation de Y pour +1 unité de X. Pente = dérivée de $E[Y|X]$.

Q3 — (c) $E[Y|X=0]$. Ordonnée à l'origine.

Q4 — (d) tout ce que X n'explique pas. Aléa + facteurs omis.

Q5 — (a) Y (expliquée, régressande). Y est prédite à partir de X.

Q6 — (b) $Y_i-\hat{Y}_i$ (observable). Estime l'erreur ; observable sur l'échantillon.

Q7 — (c) ε est de population (inobservable), e est le résidu observé. Contresens fréquent.

Q8 — (d) β_1 est le vrai paramètre inconnu, β_1 son estimation. Population vs échantillon.

Q9 — (a) $\beta_0+\beta_1X$. Espérance conditionnelle.

Q10 — (b) $\beta_0+\beta_1X_i$. Prédiction du modèle pour i.

Q11 — (c) le bêta. Sensibilité au marché.

Q12 — (d) l'alpha de Jensen. Rendement anormal.

Q13 — (a) les paramètres β. $Y=\beta_0+\beta_1X^2$ reste linéaire en β.

Q14 — (b) des pentes différentes en général. Écarts minimisés différents (le R^2 est le même, pas la pente).

Q15 — (c) décrire, expliquer, prévoir. Objectifs classiques.

Q16 — (d) une association, pas une causalité. Causalité inverse / variable omise possibles.

Q17 — (a) divisé par 100. Même variation de Y pour un X 100× plus petit.

Q18 — (b) car la relation n'est pas exacte (aléa). Sans ε, alignement parfait irréaliste.

Q19 — (c) X (variable explicative). X explique Y.

Q20 — (d) relève de l'extrapolation (prudence). X=0 peut être hors échantillon.

Thème 2 --- Estimation par les moindres carrés (MCO)

Q21 — (a) la somme des carrés des résidus Σe_i^2. Écarts verticaux au carré.

Q22 — (b) $Cov(X,Y)/Var(X)$. $\beta_1=s_XY/s_X^2$.

Q23 — (c) $\bar{y}-\beta_1\bar{x}$. La droite passe par $(\bar{x},\bar{y})$.

Q24 — (d) $(\bar{x}, \bar{y})$. Première équation normale.

Q25 — (a) 0. $\Sigma e_i=0$.

Q26 — (b) 0. Résidus orthogonaux à X (2e équation normale).

Q27 — (c) $r\cdot(s_Y/s_X)$. Pente = corrélation × rapport des écarts-types.

Q28 — (d) 1,5. 0,0018/0,0012.

Q29 — (a) 2 %. 6−0,8×5.

Q30 — (b) 10. 2+8.

Q31 — (c) +1. 11−10.

Q32 — (d) aucune relation linéaire (droite horizontale). Meilleure prédiction = $\bar{y}$.

Q33 — (a) la covariance (et de r). Sens de la relation.

Q34 — (b) Non, ils minimisent Σe_i^2. LAD minimise $\Sigma|e_i|$.

Q35 — (c) les carrés amplifient les grands écarts. MCO sensible aux extrêmes.

Q36 — (d) un X très éloigné de $\bar{x}$. Forte influence sur la pente.

Q37 — (a) 6,2 %. 0,2+1,2×5.

Q38 — (b) 2 ($\Sigma e_i=0$ et $\Sigma X_i e_i=0$). Définissent β_0 et β_1.

Q39 — (c) indéfini ($\mathrm{Var}(X)=0$). Hypothèse de variabilité violée.

Q40 — (d) 2. 20/10.

Q41 — (a) 1. 7−2×3.

Q42 — (b) une corrélation fallacieuse (spurious). Séries tendancielles $\Longrightarrow$ préférer les rendements.

Thème 3 --- Hypothèses de Gauss--Markov et BLUE

Q43 — (c) BLUE (variance minimale, sans biais, linéaires). Best Linear Unbiased Estimators.

Q44 — (d) $E[\varepsilon|X]=0$. Erreur non liée à X.

Q45 — (a) $\mathrm{Var}(\varepsilon_i)=\sigma^2$ constante. Dispersion des erreurs constante.

Q46 — (b) $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0$ pour $i\neq j$. Erreurs non corrélées entre observations.

Q47 — (c) Best (variance minimale). Le plus efficace des estimateurs linéaires sans biais.

Q48 — (d) l'exogénéité (biaise β). Endogénéité $\Longrightarrow$ β biaisé.

Q49 — (a) ne biaise pas β mais fausse les SE. Tests invalidés, β correct.

Q50 — (b) la validité exacte des tests t/F à petit n. Le TCL supplée à grand n.

Q51 — (c) β_1 est sans biais. Tombe juste en moyenne.

Q52 — (d) biaisé et non consistant. Exogénéité violée.

Q53 — (a) le plus efficace parmi les estimateurs linéaires sans biais. Efficacité.

Q54 — (b) Z influence Y et est corrélée à X. $E[\varepsilon|X]\neq 0$.

Q55 — (c) de l'endogénéité (β biaisé). X corrélé à ε.

Q56 — (d) sinon $\Sigma(X_i-\bar{x})^2=0$ et β_1 n'est pas défini. Pas de co-variation $\Longrightarrow$ pas de pente.

Q57 — (a) une combinaison linéaire des Y_i. $\beta_1=\Sigma w_i Y_i$.

Q58 — (b) Gauss–Markov + normalité (ou n grand). SE correctes + loi des statistiques.

Q59 — (c) erreurs-types robustes (White, Newey–West). Recalculent les SE.

Q60 — (d) variables instrumentales. Isolent une variation exogène de X.

Q61 — (a) $\beta_1\to\beta_1$ quand $n\to\infty$. Convergence en probabilité.

Q62 — (b) sans hypothèse de normalité. Gauss–Markov n'exige pas la normalité.

Thème 4 --- Décomposition de la variance et R^2

Q63 — (c) TSS = ESS + RSS. Total = expliqué + résiduel.

Q64 — (d) ESS/TSS = 1 − RSS/TSS. Fraction de variance expliquée.

Q65 — (a) r^2 (carré de la corrélation). Ex. $r=0{,}8 \Longrightarrow R^2=0{,}64$.

Q66 — (b) 64 % de variance expliquée par le marché. 36 % de risque spécifique.

Q67 — (c) ajustement parfait (RSS=0). Tous les points sur la droite.

Q68 — (d) aucun pouvoir explicatif ($\beta_1=0$). ESS=0.

Q69 — (a) la variabilité totale de Y. $\Sigma(Y_i-\bar{y})^2$.

Q70 — (b) $\Sigma(\hat{y}_i-\bar{y})e_i=0$ (équations normales). Orthogonalité ajustées–résidus.

Q71 — (c) Non (mesure d'ajustement). Corrélation fortuite possible.

Q72 — (d) 0,75. $1-50/200$.

Q73 — (a) 300. $0{,}6\times500$.

Q74 — (b) R^2 = part systématique, $1-R^2$ = part spécifique. Partage du risque.

Q75 — (c) Non (R^2 mesure l'alignement, pas la magnitude). Petite pente possible avec R^2 élevé.

Q76 — (d) 0,7. $\sqrt{0{,}49}$.

Q77 — (a) Non ($R^2\in[0,1]$). Borné entre 0 et 1.

Q78 — (b) $R^2=0{,}7$. À nombre de régresseurs égal.

Q79 — (c) la variabilité expliquée par la droite. $\Sigma(\hat{y}_i-\bar{y})^2$.

Q80 — (d) la variabilité résiduelle (non expliquée). Σe_i^2.

Q81 — (a) normal (fort risque spécifique). Acceptable selon l'objectif.

Q82 — (b) 0,9 en valeur absolue. $\sqrt{0{,}81}$; signe = celui de β_1.

Q83 — (c) le R^2 ajusté. Pénalise le nombre de régresseurs.

Q84 — (d) la qualité d'ajustement. Ni causalité ni validité.

Thème 5 --- Erreurs-types de la régression et des coefficients

Q85 — (a) $\sqrt{(RSS/(n-2))}$. Écart-type des résidus, $n-2$ ddl.

Q86 — (b) deux paramètres estimés (β_0, β_1). $n-2$ résidus libres.

Q87 — (c) $s_e/\sqrt{\Sigma(X_i-\bar{x})^2}$. Décroît si X dispersé.

Q88 — (d) s_e faible, X très dispersé, n grand. Précision de la pente.

Q89 — (a) moins fiable (X peu dispersé). $\Sigma(X_i-\bar{x})^2$ petit $\Longrightarrow$ SE grande.

Q90 — (b) $\bar{x}^2$ (les X loin de 0). $\sqrt{(1/n+\bar{x}^2/\Sigma(X_i-\bar{x})^2)}$.

Q91 — (c) des résidus faibles (bon ajustement). Points proches de la droite.

Q92 — (d) unité de Y. Écart-type de résidus.

Q93 — (a) diminue. $\Sigma(X_i-\bar{x})^2$ croît.

Q94 — (b) 0,283. $2/\sqrt{50}$.

Q95 — (c) dénominateur du test t et demi-largeur de l'IC. Quantifie l'incertitude de la pente.

Q96 — (d) s_e mesure la dispersion résiduelle, s_Y la totale ($s_e\le s_Y$). Résiduel après retrait de X.

Q97 — (a) élevé. Peu de variance résiduelle.

Q98 — (b) 3,0. SE=3/6=0,5 ; t=1,5/0,5.

Q99 — (c) plus dispersé. Large éventail de X $\Longrightarrow$ pente précise.

Q100 — (d) la dispersion de X et de la taille d'échantillon. Et de s_e (ajustement).

Q101 — (a) σ, l'écart-type des erreurs. SER $\approx\sigma$.

Q102 — (b) 0,5. $4/\sqrt{64}=4/8$.

Q103 — (c) $\beta_1 \pm t \cdot SE(\beta_1)$. t sur n−2 ddl.

Q104 — (d) plus petite. $\Sigma(X_i-\bar{x})^2$ plus grand.

Thème 6 --- Tests de significativité des coefficients

Q105 — (a) $t=\beta_1/SE(\beta_1) \sim t_{n-2}$. Deux paramètres estimés $\Longrightarrow$ n−2 ddl.

Q106 — (b) 40. n−2.

Q107 — (c) $H_0:\beta=1$ (risque de marché). $t=(\beta-1)/SE$.

Q108 — (d) 1,33. (1,2−1)/0,15.

Q109 — (a) Non ($t=1{,}33<1{,}96$). Non significatif.

Q110 — (b) $H_0:\beta_0\leq 0$ contre $H_1:\beta_0>0$, $t=\beta_0/SE$. Surperformance = alpha significativement >0.

Q111 — (c) peu importante (significativité ≠ matérialité). Ampleur négligeable.

Q112 — (d) n augmente. $SE(\beta_1)$ décroît.

Q113 — (a) ne pas rejeter H_0 (non significatif). |0,9|<2,0.

Q114 — (b) elle fausse $SE(\beta_1)$. β_1 correct, SE faussée.

Q115 — (c) 2,086. $t_{20;0{,}975}$.

Q116 — (d) 2,5. 0,3/0,12 $\Longrightarrow$ rejet (alpha significatif).

Q117 — (a) Non (non significatif). Pas de pouvoir explicatif mesurable.

Q118 — (b) variable omise ou multicolinéarité. Signal d'alerte de spécification.

Q119 — (c) un test F partiel. Contrôle du risque global.

Q120 — (d) plus grand. SE plus petite $\Longrightarrow$ t plus grand.

Q121 — (a) t_{n-2}. Loi de Student, n−2 ddl.

Q122 — (b) $(\beta_1-\beta_1^*)/SE(\beta_1)$. On centre sur la valeur testée.

Q123 — (c) 9,0. $F=t^2$.

Q124 — (d) le test t du chapitre 6. Inférence appliquée à β.

Thème 7 --- Intervalles de confiance et de prévision

Q125 — (a) $\beta_1 \pm t \cdot SE(\beta_1)$. t sur n−2 ddl.

Q126 — (b) Oui (0 hors IC). Dualité : rejet de $\beta_1=0$.

Q127 — (c) Non (1 dans l'IC). Non-rejet de $\beta_1=1$.

Q128 — (d) plus large. Ajoute la variabilité individuelle σ^2.

Q129 — (a) la variance de l'aléa individuel ε_0. σ^2 de la nouvelle observation.

Q130 — (b) $x_0=\bar{x}$. Terme $(x_0-\bar{x})^2$ nul.

Q131 — (c) l'intervalle explose et la linéarité n'est plus garantie. Prévision imprécise et modèle incertain.

Q132 — (d) garde une largeur $\pm t \cdot s_e$ (aléa individuel persiste). Seul l'IC de la moyenne tend vers 0.

Q133 — (a) [0,304 ; 0,696]. $0{,}5 \pm 1{,}96 \times 0{,}1$.

Q134 — (b) significatif (0 hors IC). Rejet de $\beta_1=0$.

Q135 — (c) exprimer l'incertitude de la prévision. Plage plausible pour la décision.

Q136 — (d) élargit l'IC. t plus grand.

Q137 — (a) $t \cdot s_e \cdot \sqrt{(1/n)}$. Terme $(x_0 - \bar{x})^2$ annulé.

Q138 — (b) $E[Y|X=x_0]$ (la position de la droite). Incertitude sur la droite.

Q139 — (c) une nouvelle observation Y_0 en x_0. Ajoute l'aléa individuel.

Q140 — (d) estimation de la droite + variabilité individuelle. $1/n + (x_0 - \bar{x})^2/\Sigma\ldots$ plus le $+1$.

Q141 — (a) l'extrapolation hasardeuse. Hors domaine des X.

Q142 — (b) Non (1 dans l'IC). Non-rejet de $\beta=1$.

Q143 — (c) une estimation plus précise. Précision, pas ampleur.

Q144 — (d) aux extrémités du domaine des X. Terme $(x_0 - \bar{x})^2$ maximal.

Thème 8 --- Test F de significativité globale

Q145 — (a) H_0 : tous les coefficients de pente sont nuls. Modèle globalement inutile ?

Q146 — (b) t^2 (carré du t de la pente). Ex. $t=2{,}5 \Longrightarrow F=6{,}25$.

Q147 — (c) (ESS/k)/(RSS/(n−k−1)). Variance expliquée / résiduelle par ddl.

Q148 — (d) régression multiple (significativité conjointe). Teste plusieurs coefficients à la fois.

Q149 — (a) rejet de H_0 (modèle significatif). Au moins un régresseur compte.

Q150 — (b) $F=(R^2/k)/((1-R^2)/(n-k-1))$. Croît avec R^2 et n.

Q151 — (c) « quelle variable compte ? ». Global vs individuel.

Q152 — (d) 9,0. $F=t^2$.

Q153 — (a) 71,1. $(0{,}64/1)/(0{,}36/40)$.

Q154 — (b) 4,08. $F(1,40)$; $\sqrt{4{,}08} \approx 2{,}02 = t$.

Q155 — (c) rejet de H_0 (modèle significatif). $12 > 4{,}08$.

Q156 — (d) augmentant. Facteur $(n-k-1)$.

Q157 — (a) la variance expliquée par ddl. ESS/k.

Q158 — (b) la variance résiduelle par ddl ($\approx s_e^2$). RSS/(n−k−1).

Q159 — (c) la multicolinéarité. Régresseurs corrélés.

Q160 — (d) en régression simple (k=1). Un seul régresseur.

Thème 9 --- Violations d'hypothèses et diagnostics

Q161 — (a) ne biaise pas β mais fausse les SE. Tests invalidés.

Q162 — (b) ne biaise pas β mais fausse les SE (souvent sous-estimées). Tests trop optimistes.

Q163 — (c) biaise β et le rend non consistant. La plus grave des violations.

Q164 — (d) la volatilité varie dans le temps (clustering). Variance des erreurs non constante.

Q165 — (a) erreurs-types de White. HC-robustes.

Q166 — (b) erreurs-types de Newey–West. HAC-robustes.

Q167 — (c) diagnostiquer les violations (structure, entonnoir). Premier réflexe.

Q168 — (d) de l'hétéroscédasticité. Dispersion croissante.

Q169 — (a) une non-linéarité mal modélisée. Le linéaire ne capte pas tout.

Q170 — (b) l'autocorrélation d'ordre 1 des résidus. ≈ 2 : pas d'autocorrélation.

Q171 — (c) l'hétéroscédasticité. H_0 : variance constante.

Q172 — (d) Jarque–Bera. Pour les tests exacts à petit n.

Q173 — (a) deux séries tendancielles régressées en niveaux. R^2 élevé sans lien réel.

Q174 — (b) les rendements sont ~stationnaires. Évite le spurious.

Q175 — (c) gonfle les SE, rend les coefficients instables, sans biais. t faibles, F significatif.

Q176 — (d) résidu (Y loin de la droite). Distinct du levier.

Q177 — (a) X éloigné de $\bar{x}$. Forte influence sur la pente.

Q178 — (b) les SE, pas β (sans biais). Remèdes robustes.

Q179 — (c) examiner les résidus. Sinon tests trompeurs.

Q180 — (d) transformer les variables (log, X^2). Reste linéaire en β.

Thème 10 --- Régression multiple, R^2 ajusté et synthèse

Q181 — (a) $Y=\beta_0+\beta_1X_1+...+\beta_k\ X_k+\varepsilon$. k régresseurs.

Q182 — (b) l'effet partiel de X_j, autres variables constantes. Toutes choses égales par ailleurs.

Q183 — (c) pénalise l'ajout de régresseurs. $\bar{R}^2 \leq R^2$.

Q184 — (d) ne décroît jamais. Même un régresseur inutile.

Q185 — (a) peut décroître si le régresseur n'apporte rien. Garde-fou anti-inflation.

Q186 — (b) 0,68. $1-0{,}3\times 49/46$.

Q187 — (c) comparer des modèles de tailles différentes. Pénalise la complexité.

Q188 — (d) épouse le bruit et prévoit mal hors échantillon. Remède : parcimonie, $\bar{R}^2$, validation.

Q189 — (a) une forte corrélation entre régresseurs. SE gonflées, coefficients instables.

Q190 — (b) la multicolinéarité. Régresseurs se partagent l'explication.

Q191 — (c) diffère en général (effet partiel). Purgé des autres régresseurs.

Q192 — (d) moins de surajustement, plus stable, meilleure prévision. Simplicité utile.

Q193 — (a) les tests t (coefficients) et F (global). Inférence appliquée.

Q194 — (b) modèle → MCO → R^2 → SE → tests → prévision → diagnostics. Enchaînement logique.

Q195 — (c) Oui (régresseurs quasi inutiles). R^2 très faible + beaucoup de régresseurs.

Q196 — (d) significativité (t), R^2 ajusté, performance hors échantillon. Pas le R^2 brut seul.

Q197 — (a) $\beta_1=\mathrm{Cov}(X,Y)/\mathrm{Var}(X)$. Covariance standardisée.

Q198 — (b) r^2. Carré de la corrélation.

Q199 — (c) les hypothèses de Gauss–Markov. H1–H5.

Q200 — (d) description, explication et prévision. Sous les hypothèses de Gauss–Markov.

Grille récapitulative des réponses

1:a · 2:b · 3:c · 4:d · 5:a · 6:b · 7:c · 8:d · 9:a · 10:b

11:c · 12:d · 13:a · 14:b · 15:c · 16:d · 17:a · 18:b · 19:c · 20:d

21:a · 22:b · 23:c · 24:d · 25:a · 26:b · 27:c · 28:d · 29:a · 30:b

31:c · 32:d · 33:a · 34:b · 35:c · 36:d · 37:a · 38:b · 39:c · 40:d

41:a · 42:b · 43:c · 44:d · 45:a · 46:b · 47:c · 48:d · 49:a · 50:b

51:c · 52:d · 53:a · 54:b · 55:c · 56:d · 57:a · 58:b · 59:c · 60:d

61:a · 62:b · 63:c · 64:d · 65:a · 66:b · 67:c · 68:d · 69:a · 70:b

71:c · 72:d · 73:a · 74:b · 75:c · 76:d · 77:a · 78:b · 79:c · 80:d

81:a · 82:b · 83:c · 84:d · 85:a · 86:b · 87:c · 88:d · 89:a · 90:b

91:c · 92:d · 93:a · 94:b · 95:c · 96:d · 97:a · 98:b · 99:c · 100:d

101:a · 102:b · 103:c · 104:d · 105:a · 106:b · 107:c · 108:d · 109:a · 110:b

111:c · 112:d · 113:a · 114:b · 115:c · 116:d · 117:a · 118:b · 119:c · 120:d

121:a · 122:b · 123:c · 124:d · 125:a · 126:b · 127:c · 128:d · 129:a · 130:b

131:c · 132:d · 133:a · 134:b · 135:c · 136:d · 137:a · 138:b · 139:c · 140:d

141:a · 142:b · 143:c · 144:d · 145:a · 146:b · 147:c · 148:d · 149:a · 150:b

151:c · 152:d · 153:a · 154:b · 155:c · 156:d · 157:a · 158:b · 159:c · 160:d

161:a · 162:b · 163:c · 164:d · 165:a · 166:b · 167:c · 168:d · 169:a · 170:b

171:c · 172:d · 173:a · 174:b · 175:c · 176:d · 177:a · 178:b · 179:c · 180:d

181:a · 182:b · 183:c · 184:d · 185:a · 186:b · 187:c · 188:d · 189:a · 190:b

191:c · 192:d · 193:a · 194:b · 195:c · 196:d · 197:a · 198:b · 199:c · 200:d