FRM® Part I · Quantitative Analysis

Book 2 · Chapitre 8

Regression with Multiple Explanatory Variables

La régression linéaire multiple

Plusieurs facteurs, un effet à la fois

Approfondissement quantitatif complet

Cours illustré · définitions · démonstrations · 200 études de cas · conseils méthodologiques · 200 QCM commentés

Support d'étude — questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel — pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
8.1 — Le modèle de régression multiple . . . 3
8.2 — L'estimation par les moindres carrés en dimension multiple . . . 4
8.3 — Hypothèses de Gauss–Markov et biais de variable omise . . . 4
8.4 — Ajustement : R^2, R^2 ajusté et compromis biais–variance . . . 5
8.5 — Tests de significativité individuelle . . . 6
8.6 — Test F global et tests F conjoints . . . 7
8.7 — La multicolinéarité . . . 7
8.8 — Les variables indicatrices (dummies) . . . 8
8.9 — Termes d'interaction et effets non linéaires . . . 9
8.10 — Violations d'hypothèses et erreurs-types robustes . . . 9
8.11 — La spécification du modèle . . . 10
8.12 — Synthèse : la régression multiple de bout en bout . . . 10

Partie B — 200 études de cas pratiques **12**
Bloc 1 — Le modèle multiple et l'effet partiel . . . 12
Bloc 2 — Estimation MCO en dimension multiple . . . 13
Bloc 3 — Gauss–Markov et biais de variable omise . . . 14
Bloc 4 — R^2, R^2 ajusté et compromis biais–variance . . . 16
Bloc 5 — Tests de significativité individuelle . . . 17
Bloc 6 — Test F global et tests F conjoints . . . 19
Bloc 7 — Multicolinéarité et VIF . . . 20
Bloc 8 — Variables indicatrices et interactions . . . 22
Bloc 9 — Violations d'hypothèses et robustesse . . . 24
Bloc 10 — Spécification du modèle et synthèse . . . 25

Partie C — Méthodologie, formulaire et astuces **27**
C.1 — Formulaire de la régression multiple . . . 27
C.2 — Simple vs multiple : ce qui change . . . 27
C.3 — Carte de décision : quel outil pour quelle question ? . . . 27
C.4 — Glossaire bilingue . . . 28
C.5 — Méthode d'analyse en huit étapes . . . 29
C.6 — Diagnostic : biais ou précision ? . . . 29
C.7 — Les dix pièges classiques . . . 29
C.8 — Astuces de calcul rapide . . . 30

Partie D — 200 questions à choix multiple **31**
Thème 1 — Le modèle multiple et l'effet partiel . . . 31
Thème 2 — Estimation MCO en dimension multiple . . . 34
Thème 3 — Gauss–Markov et biais de variable omise . . . 36
Thème 4 — R^2, R^2 ajusté et compromis biais–variance . . . 39
Thème 5 — Tests de significativité individuelle . . . 43
Thème 6 — Test F global et tests F conjoints . . . 45
Thème 7 — Multicolinéarité et VIF . . . 49
Thème 8 — Variables indicatrices et interactions . . . 52
Thème 9 — Violations d'hypothèses et robustesse . . . 55
Thème 10 — Spécification du modèle et synthèse . . . 58

Partie E — Corrigé commenté des 200 QCM **61**
Thème 1 — Le modèle multiple et l'effet partiel . . . 61
Thème 2 — Estimation MCO en dimension multiple . . . 61
Thème 3 — Gauss–Markov et biais de variable omise . . . 62
Thème 4 — R^2, R^2 ajusté et compromis biais–variance . . . 62
Thème 5 — Tests de significativité individuelle . . . 63

Thème 6 — Test F global et tests F conjoints 64
Thème 7 — Multicolinéarité et VIF 64
Thème 8 — Variables indicatrices et interactions 65
Thème 9 — Violations d'hypothèses et robustesse 66
Thème 10 — Spécification du modèle et synthèse 66
Grille récapitulative des réponses 67

Partie A --- Cours approfondi

Le chapitre 7 modélisait une relation à une seule variable explicative. Mais le monde financier est **multifactoriel** : un rendement dépend du marché, mais aussi de la taille, de la valorisation, du momentum ; un spread de crédit dépend de la notation, du secteur, de la maturité, de la liquidité. La **régression multiple** est l'outil qui démêle ces influences simultanées — le socle des modèles à facteurs (Fama–French), du calcul de sensibilités multiples et de l'attribution de performance.

Le saut conceptuel tient en une expression : « **toutes choses égales par ailleurs** » (ceteris paribus). Chaque coefficient mesure désormais l'effet **propre** d'un régresseur, une fois neutralisée l'influence des autres — ce qu'une simple corrélation ne peut faire. Le chapitre reprend la structure du Ch7 en l'étendant : estimation MCO, hypothèses de Gauss–Markov (avec le **biais de variable omise** au premier plan), ajustement ($\mathbf{R^2}$ **ajusté**), inférence (tests t individuels, **test** F **conjoint**), et les enjeux propres au cadre multiple — **multicolinéarité**, **variables indicatrices**, **interactions**, **spécification**.

Le fil rouge : le modèle à facteurs

L'application phare est le **modèle multifactoriel**. En régressant le rendement excédentaire d'un fonds sur plusieurs facteurs ($R - R_f = \alpha + \beta_1\,\text{MKT} + \beta_2\,\text{SMB} + \beta_3\,\text{HML} + \varepsilon$), chaque β_j est l'**exposition** du fonds au facteur j, *à exposition constante aux autres facteurs*, et α est la surperformance résiduelle. Tout le chapitre se lit à travers ce prisme : estimer les expositions, tester leur significativité (individuelle et conjointe), et juger de la spécification du modèle.

8.1 --- Le modèle de régression multiple

La régression multiple relie une variable dépendante à plusieurs variables explicatives par une relation linéaire dans les paramètres.

Modèle de régression linéaire multiple

Avec k variables explicatives et n observations, le **modèle de population** s'écrit

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i, \qquad i = 1, \dots, n,$$

où β_0 est l'**ordonnée à l'origine**, chaque β_j le **coefficient partiel** de X_j, et ε_i le terme d'erreur.

Interprétation « toutes choses égales par ailleurs »

$$\beta_j = \frac{\partial\, \mathbb{E}[Y \mid X_1, \dots, X_k]}{\partial X_j} \quad \text{(effet d'une unité de } X_j\text{, } \textbf{les autres } X \text{ maintenus constants)}.$$

$$\beta_0 = \mathbb{E}[Y \mid X_1 = \cdots = X_k = 0] \quad \text{(valeur de } Y \text{ quand tous les régresseurs sont nuls)}.$$

L'effet partiel, cœur de la régression multiple

La différence capitale avec la régression simple : β_j isole l'effet **propre** de X_j, purgé de l'influence des autres régresseurs. Dans un modèle expliquant le salaire par l'éducation *et* l'expérience, le coefficient de l'éducation mesure son effet **à expérience égale** — il répond à « deux personnes de même expérience, l'une ayant un an d'études de plus, diffèrent de combien ? ». Une régression simple de salaire sur éducation confondrait cet effet avec celui de l'expérience si les deux sont corrélées. C'est ce pouvoir de **contrôle statistique** qui fait toute la valeur du cadre multiple.

Effet partiel vs effet marginal simple

Le coefficient de X_j en régression multiple n'égale **pas**, en général, la pente de la régression simple de Y sur X_j seul. Ils ne coïncident que si X_j est *non corrélé* aux autres régresseurs. L'écart entre les deux mesure précisément ce que « contrôler pour les autres variables » modifie — et c'est souvent considérable. Ajouter un régresseur pertinent corrélé peut même **changer le signe** d'un coefficient (paradoxe de Simpson).

8.2 --- L'estimation par les moindres carrés en dimension multiple

Le principe des MCO est inchangé — minimiser la somme des carrés des résidus — mais l'algèbre passe en dimension $k+1$.

MCO en régression multiple

Les estimateurs $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ minimisent la somme des carrés des résidus :

$$\min_{b_0,\dots,b_k} \sum_{i=1}^{n} \left(Y_i - b_0 - b_1 X_{1i} - \cdots - b_k X_{ki}\right)^2.$$

La solution vérifie $k+1$ **équations normales** (une par paramètre), et s'exprime matriciellement par $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$.

Forme matricielle

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \qquad \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

où $\mathbf{X}$ est la matrice $n \times (k+1)$ des régresseurs (première colonne de 1 pour l'ordonnée), $\mathbf{y}$ le vecteur des Y_i, et $\hat{\beta}$ le vecteur des $k+1$ coefficients.

Pourquoi la forme matricielle ?

En régression simple, une formule scalaire suffisait ($\hat{\beta}_1 = \text{Cov} / \text{Var}$). En multiple, chaque coefficient dépend de *tous* les régresseurs et de leurs corrélations mutuelles : la notation matricielle $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ encapsule ce système. Le point crucial est l'**inversibilité** de $\mathbf{X}^\top \mathbf{X}$: elle exige qu'aucun régresseur ne soit une combinaison linéaire exacte des autres (absence de **colinéarité parfaite**). L'examen ne demande pas de calculer l'inverse à la main, mais de comprendre ce que représente $\hat{\beta}$ et quand l'estimation échoue.

Valeurs ajustées et résidus

Comme en simple : les **valeurs ajustées** sont $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \cdots + \hat{\beta}_k X_{ki}$ et les **résidus** $e_i = Y_i - \hat{Y}_i$. Les équations normales imposent encore $\sum_i e_i = 0$ et $\sum_i X_{ji} e_i = 0$ pour *chaque* régresseur j : les résidus sont orthogonaux à **tous** les régresseurs. La droite (désormais un *hyperplan*) passe par le point moyen $(\bar{X}_1, \dots, \bar{X}_k, \bar{Y})$.

8.3 --- Hypothèses de Gauss--Markov et biais de variable omise

Les hypothèses du Ch7 s'étendent au cadre multiple, avec une nouvelle exigence — l'absence de colinéarité parfaite — et une conséquence centrale : le biais de variable omise.

Hypothèses de Gauss–Markov (cas multiple)

(H1) linéarité en les paramètres ; **(H2) exogénéité** $\mathbb{E}[\varepsilon_i \mid X_1, \dots, X_k] = 0$; **(H3) homoscédasticité** $\mathrm{Var}(\varepsilon_i) = \sigma^2$; **(H4) absence d'autocorrélation** $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0$; **(H5) absence de colinéarité parfaite** (aucun régresseur combinaison linéaire exacte des autres). Pour l'inférence, on ajoute **(H6) normalité** des erreurs.

Théorème de Gauss–Markov étendu

Sous (H1)–(H5), les estimateurs MCO $\hat{\beta}_0, \dots, \hat{\beta}_k$ sont **BLUE** : de tous les estimateurs linéaires sans biais, ils ont la variance minimale. Chaque $\hat{\beta}_j$ est un estimateur sans biais de l'effet partiel β_j.

Biais de variable omise

Si une variable pertinente Z (influençant Y) est **omise** du modèle et qu'elle est **corrélée** à un régresseur inclus X_j, alors $\hat{\beta}_j$ est **biaisé**. Le sens du biais dépend des signes :

$$\text{Biais}(\hat{\beta}_j) \;\propto\; (\text{effet de } Z \text{ sur } Y) \times (\text{corrélation de } Z \text{ et } X_j).$$

Le mécanisme du biais de variable omise

C'est la violation d'exogénéité la plus fréquente. Si Z est omise, son effet se déverse dans le terme d'erreur ; comme Z est corrélée à X_j, l'erreur devient corrélée à X_j, et $\mathbb{E}[\varepsilon \mid X_j] \neq 0$. Exemple financier : régresser le rendement d'un fonds sur le seul facteur marché, en omettant le facteur « taille » alors que le fonds est chargé en petites capitalisations, biaise le bêta de marché estimé. La règle : les deux conditions (Z influence Y **et** Z corrélée à X_j) doivent être réunies pour qu'il y ait biais. Si l'une manque, $\hat{\beta}_j$ reste sans biais — omettre une variable non corrélée aux régresseurs inclus ne biaise pas leurs coefficients (mais réduit la précision).

Signe du biais — le tableau de raisonnement

Deux signes déterminent le sens du biais. Si Z a un effet *positif* sur Y et est *positivement* corrélée à X_j, le biais est **positif** (surestimation de β_j) ; deux signes opposés donnent un biais négatif ; même logique multiplicative pour les autres cas. Cette analyse permet, même sans données sur Z, d'anticiper la *direction* de l'erreur — une compétence attendue à l'examen.

8.4 --- Ajustement : R^2, R^2 ajusté et compromis biais--variance

Le R^2 se généralise, mais devient trompeur en multiple ; le R^2 ajusté le corrige, illustrant un compromis fondamental.

R^2 et R^2 ajusté en régression multiple

Comme en simple, $R^2 = \text{ESS/TSS} = 1 - \text{RSS/TSS}$. Le **$R^2$ ajusté** pénalise le nombre de régresseurs :

$$\bar{R}^2 = 1 - \frac{\text{RSS}/(n-k-1)}{\text{TSS}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}.$$

Propriétés comparées

R^2 ne décroît **jamais** quand on ajoute un régresseur (même inutile);

$\bar{R}^2$ augmente ssi le régresseur ajouté a un $|t| > 1$; il peut **décroître**. $\bar{R}^2 \leq R^2$.

Pourquoi le R^2 brut trompe en multiple

Le R^2 mécanique croît à chaque régresseur ajouté, car les MCO exploitent toujours un peu de variance supplémentaire, fût-ce du bruit. Maximiser le R^2 conduit donc à empiler les variables et à **surajuster**. Le $\bar{R}^2$ introduit une pénalité : il n'augmente que si le gain d'ajustement dépasse le coût d'un degré de liberté perdu (règle pratique : ajout justifié si le $|t|$ du nouveau régresseur dépasse 1). C'est pourquoi on compare des modèles par le $\bar{R}^2$, jamais par le R^2 brut.

Le compromis biais–variance

Sous-spécifier (omettre une variable pertinente) introduit un **biais** ; sur-spécifier (inclure des variables inutiles) gonfle la **variance** des estimateurs (erreurs-types plus grandes, coefficients instables) sans biais. La bonne spécification navigue entre ces deux écueils : assez de variables pour éviter le biais d'omission, pas trop pour préserver la précision. Ce **compromis biais–variance** irrigue toute la modélisation quantitative, de la régression à l'apprentissage statistique. Le $\bar{R}^2$, les critères AIC/BIC et la validation hors échantillon sont les instruments de cet arbitrage.

8.5 --- Tests de significativité individuelle

Chaque coefficient partiel se teste comme au Ch7, mais avec les degrés de liberté du cadre multiple et une interprétation « toutes choses égales par ailleurs ».

Test t d'un coefficient partiel

Pour tester $H_0 : \beta_j = 0$ (le régresseur X_j n'a pas d'effet propre) contre $H_1 : \beta_j \neq 0$, la statistique est

$$t = \frac{\hat{\beta}_j - 0}{\mathrm{SE}(\hat{\beta}_j)} \sim t_{n-k-1} \quad \text{sous } H_0.$$

Les degrés de liberté sont $n - k - 1$: $k + 1$ paramètres estimés (les k pentes et l'ordonnée).

Décision et degrés de liberté

Rejeter H_0 si $|t| > t_{n-k-1;\,1-\alpha/2}$ ou si $p \leq \alpha$.

ddl $= n - k - 1$ (contre $n - 2$ en régression simple, où $k = 1$).

Ce que teste — et ne teste pas — le t individuel

Le test t de β_j évalue la significativité de X_j **en présence des autres régresseurs**. Un coefficient peut devenir non significatif simplement parce qu'un régresseur corrélé capte une part de son effet (multicolinéarité, §8.7). Ainsi, « β_j non significatif » ne signifie pas « X_j sans lien avec Y », mais « X_j n'apporte pas d'information *additionnelle* une fois les autres variables incluses ». C'est une nuance décisive : la significativité est *conditionnelle* au modèle.

8.6 --- Test F global et tests F conjoints

Le test F prend toute sa dimension en régression multiple : il teste des hypothèses portant sur *plusieurs* coefficients à la fois — ce que des tests t séparés ne peuvent faire correctement.

Test F de significativité globale

Le **test F global** teste $H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$ (aucun régresseur n'explique Y) contre H_1 : au moins un $\beta_j \neq 0$:

$$F = \frac{\text{ESS}/k}{\text{RSS}/(n-k-1)} = \frac{R^2/k}{(1-R^2)/(n-k-1)} \sim F_{k,\,n-k-1}.$$

Test F conjoint sur des restrictions

Pour tester q restrictions simultanées (par exemple $H_0 : \beta_2 = \beta_3 = 0$), on compare le modèle **contraint** (restrictions imposées) au modèle **non contraint** :

$$F = \frac{(\text{RSS}_c - \text{RSS}_{nc})/q}{\text{RSS}_{nc}/(n-k-1)} \sim F_{q,\,n-k-1},$$

où RSS_c et RSS_{nc} sont les sommes des carrés résiduelles des modèles contraint et non contraint, et q le nombre de restrictions.

Cas particuliers et logique

$q = k$ (toutes les pentes) $\Rightarrow$ test F global; $\quad q = 1 \Rightarrow F = t^2$ (équivaut au test t).

Rejeter H_0 si $F > F_{q,\,n-k-1;\,1-\alpha}$ (le F est toujours unilatéral droit).

Pourquoi ne pas enchaîner des tests t ?

Tester $H_0 : \beta_2 = \beta_3 = 0$ par deux tests t séparés est **incorrect** pour deux raisons : (1) cela ne contrôle pas le risque global de type I (multiplicité des tests, chapitre 6) ; (2) cela ignore la **corrélation** entre $\hat{\beta}_2$ et $\hat{\beta}_3$. Le test F conjoint traite les coefficients *simultanément* et fournit une décision unique valide. C'est indispensable pour tester, par exemple, si un **groupe** de facteurs (secteurs, maturités) est collectivement pertinent.

F significatif, t individuels non significatifs — le signal de colinéarité

Une configuration classique et déroutante : le test F global rejette H_0 (le modèle explique Y), mais *aucun* test t individuel n'est significatif. La cause est presque toujours la **multicolinéarité** : des régresseurs fortement corrélés se « partagent » le pouvoir explicatif, gonflant chaque erreur-type au point de rendre les t individuels faibles, alors que leur effet *conjoint* est net (F élevé). Le diagnostic : ne pas conclure à l'inutilité des variables sur la seule foi des t, mais examiner le F et la structure de corrélation des régresseurs.

8.7 --- La multicolinéarité

Propre au cadre multiple, la multicolinéarité est la corrélation entre régresseurs — un problème de précision, non de biais, qu'il faut savoir détecter et interpréter.

Multicolinéarité

La **multicolinéarité** désigne une forte corrélation linéaire entre deux ou plusieurs régresseurs. Elle est **parfaite** si un régresseur est une combinaison linéaire exacte des autres (alors $\mathbf{X}^\top\mathbf{X}$ n'est pas inversible et les

MCO échouent), **imparfaite** (le cas usuel) si la corrélation est forte mais non exacte.

Facteur d'inflation de la variance (VIF)

Pour le régresseur X_j, en notant R_j^2 le R^2 de la régression de X_j sur *tous les autres* régresseurs :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \qquad \text{SE}(\hat{\beta}_j) \text{ croît avec } \sqrt{\text{VIF}_j}.$$

Règle usuelle : VIF > 5 (parfois 10) signale une multicolinéarité problématique.

Symptômes et conséquences

La multicolinéarité imparfaite **ne biaise pas** $\hat{\beta}$ (les MCO restent BLUE), mais elle **gonfle les erreurs-types**, avec des symptômes caractéristiques : coefficients *instables* (changent fortement si l'on ajoute/retire une observation ou une variable), t individuels *faibles* malgré un F global significatif et un R^2 élevé, et parfois des *signes* contre-intuitifs. Intuition : si deux régresseurs varient presque ensemble, les données peinent à attribuer l'effet à l'un plutôt qu'à l'autre — d'où l'imprécision. Le VIF $= 1/(1-R_j^2)$ quantifie ce phénomène : un $R_j^2 = 0{,}9$ donne un VIF de 10, multipliant l'erreur-type par $\sqrt{10} \approx 3{,}2$.

Que faire face à la multicolinéarité ?

Les remèdes dépendent de l'objectif. Si le but est la **prévision**, la multicolinéarité est souvent bénigne : le modèle prédit bien même si les coefficients individuels sont imprécis. Si le but est l'**interprétation** des effets partiels, on peut : retirer un des régresseurs redondants, les combiner (indice composite, composantes principales — PCA), ou collecter plus de données. À ne **pas** faire : conclure hâtivement qu'une variable est inutile sur la seule foi d'un t faible, alors qu'elle est peut-être seulement colinéaire. La colinéarité parfaite, elle, doit être éliminée (elle empêche toute estimation — cf. le piège des variables indicatrices, §8.8).

8.8 --- Les variables indicatrices (dummies)

Les régresseurs qualitatifs (secteur, notation, période) s'introduisent via des variables indicatrices, avec une règle stricte pour éviter la colinéarité parfaite.

Variable indicatrice

Une **variable indicatrice** (dummy) vaut 1 si une condition est remplie, 0 sinon. Pour une variable qualitative à m modalités, on introduit $m - 1$ indicatrices, l'une des modalités servant de **catégorie de référence** (baseline).

Interprétation et piège de la colinéarité

$$Y = \beta_0 + \beta_1 D + \dots, \quad D \in \{0,1\} : \ \beta_1 = \text{écart moyen de } Y \text{ entre la catégorie } D{=}1 \text{ et la référence.}$$

Piège des dummies : inclure les m indicatrices $+$ l'ordonnée $\Rightarrow$ colinéarité parfaite.

La trappe des variables indicatrices

Pour une variable à m modalités, inclure *toutes* les m indicatrices **en plus** de l'ordonnée crée une colinéarité parfaite : la somme des m dummies vaut toujours 1, exactement la colonne de l'ordonnée. $\mathbf{X}^\top\mathbf{X}$ devient sin-

gulière et les MCO échouent — c'est la « **dummy variable trap** ». Solution : omettre une modalité (référence) et n'inclure que $m-1$ indicatrices. Chaque coefficient s'interprète alors comme l'écart moyen *par rapport à la référence*. Exemple : pour quatre secteurs, trois dummies suffisent ; le coefficient « secteur bancaire » mesure l'écart de rendement moyen entre les banques et le secteur de référence, toutes choses égales par ailleurs.

8.9 --- Termes d'interaction et effets non linéaires

La régression multiple capte des effets conditionnels (interactions) et des courbures (termes polynomiaux), tout en restant linéaire dans les paramètres.

Terme d'interaction

Un **terme d'interaction** X_1X_2 (produit de deux régresseurs) permet à l'effet de X_1 de dépendre de la valeur de X_2 :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 X_2) + \varepsilon \;\Rightarrow\; \frac{\partial \mathbb{E}[Y]}{\partial X_1} = \beta_1 + \beta_3 X_2.$$

Lire une interaction

Sans interaction, l'effet de X_1 est constant (β_1). Avec le terme $\beta_3 X_1 X_2$, cet effet devient $\beta_1 + \beta_3 X_2$: il **varie selon** X_2. Le coefficient β_3 mesure de combien l'effet de X_1 change quand X_2 augmente d'une unité. Exemple : l'effet d'un facteur de risque peut différer selon le régime de marché (haussier/baissier) — une dummy de régime croisée avec le facteur capte cette modulation. Attention à l'interprétation : en présence d'interaction, β_1 seul n'est plus l'« effet de X_1 », mais l'effet de X_1 *lorsque* $X_2 = 0$.

Effets non linéaires par termes polynomiaux

Une relation courbe se modélise en ajoutant X^2 : $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$. Le modèle reste **linéaire dans les paramètres** (estimable par MCO), bien que non linéaire en X. L'effet marginal $\partial \mathbb{E}[Y]/\partial X = \beta_1 + 2\beta_2 X$ dépend alors du niveau de X. C'est ainsi qu'on capte des rendements décroissants, des relations en U (comme la convexité obligataire), ou des seuils. La « linéarité » de la régression a toujours porté sur les β, jamais sur la forme en X — d'où sa grande flexibilité.

8.10 --- Violations d'hypothèses et erreurs-types robustes

Les violations du Ch7 persistent en multiple, avec les mêmes conséquences et les mêmes remèdes robustes — un rappel structurant appliqué au cadre multifactoriel.

Récapitulatif des violations (cas multiple)

Violation	Effet sur $\hat{\beta}$	Remède
Hétéroscédasticité	Sans biais, SE faussées	Erreurs-types de White (HC)
Autocorrélation	Sans biais, SE faussées	Erreurs-types de Newey–West (HAC)
Variable omise (endogénéité)	**Biaisé**	Inclure la variable / instruments
Multicolinéarité	Sans biais, SE gonflées	Retirer/combiner régresseurs

La distinction cardinale : biais vs précision

Un principe unifie tout le diagnostic. L'**hétéroscédasticité**, l'**autocorrélation** et la **multicolinéarité** n'affectent que la **précision** (les erreurs-types), laissant $\widehat{\beta}$ *sans biais* — on les corrige par des SE robustes ou en ajustant la spécification, sans toucher aux coefficients. La **variable omise** (endogénéité) affecte le **biais** — elle fausse $\widehat{\beta}$ lui-même, et aucune correction d'erreur-type n'y remédie : il faut inclure la variable ou recourir à des instruments. Savoir ranger chaque problème dans la bonne colonne — biais ou précision — est la compétence de diagnostic la plus testée.

Diagnostics en régression multiple

Les outils du Ch7 s'appliquent : graphe des résidus (contre les valeurs ajustées ou chaque régresseur), test de Breusch–Pagan (hétéroscédasticité), Durbin–Watson (autocorrélation d'ordre 1), Jarque–Bera sur les résidus (normalité). S'y ajoutent les diagnostics propres au multiple : les **VIF** (multicolinéarité) et l'examen de la **matrice de corrélation** des régresseurs. En pratique, on rapporte des erreurs-types robustes par défaut sur données financières, tant l'hétéroscédasticité et l'autocorrélation y sont la norme.

8.11 --- La spécification du modèle

Choisir les bons régresseurs est l'art central de la régression multiple — un équilibre entre biais d'omission et sur-paramétrage, guidé par la théorie autant que par les critères statistiques.

Critères de sélection de modèle

Au-delà du $\bar{R}^2$, on compare les modèles par des critères pénalisant la complexité :

$$\text{AIC} = n\ln(\text{RSS}/n) + 2(k+1), \qquad \text{BIC} = n\ln(\text{RSS}/n) + (k+1)\ln n.$$

On préfère le modèle à **AIC ou BIC minimal**. Le BIC pénalise plus lourdement les paramètres (facteur $\ln n$), favorisant des modèles plus parcimonieux.

Les principes d'une bonne spécification

Quatre principes guident le choix des régresseurs. **(1) La théorie d'abord** : inclure les variables que la finance ou l'économie désignent comme pertinentes (éviter le data mining aveugle). **(2) Parcimonie** : à pouvoir explicatif comparable, préférer le modèle le plus simple (compromis biais–variance). **(3) Éviter le biais d'omission** : ne pas exclure une variable pertinente corrélée aux régresseurs inclus. **(4) Validation hors échantillon** : juger un modèle sur sa capacité à prévoir des données non utilisées pour l'estimer, pas sur son R^2 en échantillon. Le $\bar{R}^2$, l'AIC/BIC et la validation croisée opérationnalisent cet arbitrage.

Le danger du surajustement, revisité

Empiler les régresseurs pour maximiser le R^2 produit un modèle qui **épouse le bruit** de l'échantillon : coefficients instables, excellente performance en échantillon, médiocre hors échantillon. Le fléau rejoint celui du chapitre 6 (tests multiples) : chercher exhaustivement le « meilleur » modèle sur les mêmes données garantit de trouver des relations fallacieuses. La parcimonie, la pénalisation de la complexité (AIC/BIC, $\bar{R}^2$) et surtout la **validation hors échantillon** sont les seules protections fiables. En gestion des risques, un modèle sur-paramétré donne une fausse confiance — le pire des défauts.

8.12 --- Synthèse : la régression multiple de bout en bout

Étape	Outil	Question / interprétation
Modèle	$Y = \beta_0 + \sum_j \beta_j X_j + \varepsilon$	Quels facteurs ?
Estimation	MCO : $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	Effets partiels (BLUE si G–M)
Effet partiel	β_j à autres X constants	Contrôle statistique
Ajustement	$\bar{R}^2$ (pas R^2 brut)	Comparer des modèles
Test individuel	$t = \hat{\beta}_j / \text{SE} \sim t_{n-k-1}$	Effet propre significatif ?
Test conjoint	F (global ou restrictions)	Groupe de variables utile ?
Colinéarité	VIF $= 1/(1 - R_j^2)$	Précision des coefficients
Qualitatif	$m - 1$ indicatrices	Écarts à la référence
Non-linéarité	Interactions, X^2	Effets conditionnels / courbes
Robustesse	White / Newey–West	SE valides malgré violations
Spécification	$\bar{R}^2$, AIC/BIC, hors échantillon	Biais–variance, parcimonie

Les sept réflexes du chapitre

(1) Chaque β_j est un effet *partiel* (« toutes choses égales par ailleurs »), différent de la pente simple si les régresseurs sont corrélés. **(2)** Le biais de variable omise exige *deux* conditions : Z influence Y *et* Z corrélée à un régresseur inclus. **(3)** Comparer les modèles par le $\bar{R}^2$ (le R^2 brut croît toujours) ; arbitrer le compromis biais–variance. **(4)** Tests : t sur $n - k - 1$ ddl pour chaque coefficient, F pour les hypothèses conjointes ($q = k$: global ; $q = 1$: $F = t^2$). **(5)** Multicolinéarité : ne biaise pas $\hat{\beta}$ mais gonfle les SE (VIF) ; signal typique = F significatif, t faibles. **(6)** Dummies : $m - 1$ indicatrices (éviter la trappe) ; interactions et X^2 pour les effets conditionnels et non linéaires, sans quitter la linéarité en β. **(7)** Distinguer biais (variable omise) et précision (hétéroscédasticité, autocorrélation, colinéarité) ; privilégier parcimonie et validation hors échantillon.

Partie B --- 200 études de cas pratiques

Chaque cas propose un contexte chiffré, une question et une solution détaillée. Régressions multiples, effets partiels, R^2 ajusté, VIF, tests t et F (globaux et conjoints) sont calculés exactement (numpy/scipy). Travaillez crayon en main : cachez la solution, résolvez, comparez.

Bloc 1 --- Le modèle multiple et l'effet partiel

Cas 1 — Modèle de régression multiple. Écrire le modèle de régression multiple à k régresseurs et nommer ses éléments.

Solution. $Y=\beta_0+\beta_1X_1+...+\beta_k\ X_k+\varepsilon$: β_0 **ordonnée**, chaque β_j **coefficient partiel** de X_j, ε **terme d'erreur**.

Cas 2 — Interprétation d'un coefficient partiel. Que mesure β_j en régression multiple ?

Solution. L'effet d'une hausse d'une unité de X_j sur Y, **les autres régresseurs maintenus constants** (effet partiel, ceteris paribus).

Cas 3 — « Toutes choses égales par ailleurs ». Que signifie l'interprétation ceteris paribus d'un coefficient ?

Solution. L'effet **propre** de X_j, purgé de l'influence des autres variables : deux observations identiques sur les autres X, différant d'une unité de X_j, diffèrent de β_j sur Y.

Cas 4 — Effet partiel vs pente simple. Le coefficient de X_j en multiple égale-t-il la pente de Y sur X_j seul ?

Solution. **Pas en général** : ils ne coïncident que si X_j est non corrélé aux autres régresseurs. L'écart mesure l'effet du contrôle statistique.

Cas 5 — Ordonnée à l'origine en multiple. Que représente β_0 ?

Solution. $E[Y \mid \text{tous les } X = 0]$: la valeur moyenne de Y quand tous les régresseurs sont nuls (souvent une extrapolation).

Cas 6 — Contrôle statistique. Quel pouvoir la régression multiple offre-t-elle par rapport à une corrélation ?

Solution. Le **contrôle statistique** : isoler l'effet d'une variable en neutralisant les autres, ce qu'une corrélation bivariée ne peut faire.

Cas 7 — Salaire, éducation et expérience. Dans un modèle salaire $= \beta_0+\beta_1\cdot\text{éduc}+\beta_2\cdot\text{exp}+\varepsilon$, qu'est β_1 ?

Solution. L'effet d'une année d'éducation supplémentaire **à expérience égale** : l'effet propre de l'éducation, contrôlé pour l'expérience.

Cas 8 — Changement de signe (Simpson). Ajouter un régresseur peut-il changer le signe d'un coefficient ?

Solution. **Oui** (paradoxe de Simpson) : contrôler pour une variable corrélée peut inverser le signe de l'effet estimé d'un autre régresseur.

Cas 9 — Modèle à facteurs (Fama–French). Dans $R-R_f=\alpha+\beta_1MKT+\beta_2SMB+\beta_3HML+\varepsilon$, qu'est β_2 ?

Solution. L'**exposition au facteur taille** (SMB), à exposition constante au marché et à la valeur : la sensibilité propre au facteur taille.

Cas 10 — Linéarité en multiple. La « linéarité » de la régression multiple porte sur quoi ?

Solution. Sur les **paramètres** β. Le modèle peut inclure X^2, X_1X_2, $\log(X)$ et rester estimable par MCO (linéaire en β).

Cas 11 — Nombre de paramètres. Combien de paramètres estime un modèle à k régresseurs ?

Solution. **k+1** : les k coefficients de pente (β_1...β_k) plus l'ordonnée β_0.

Cas 12 — Valeurs ajustées en multiple. Qu'est-ce que $\hat{Y}_i$ dans un modèle à deux régresseurs ?

Solution. $\hat{Y}_i=\beta_0+\beta_1X_{1i}+\beta_2X_{2i}$: la prédiction du modèle, combinant les deux régresseurs.

Cas 13 — Résidus orthogonaux à chaque régresseur. À quoi les résidus MCO sont-ils orthogonaux en multiple ?

Solution. À **tous** les régresseurs : $\Sigma e_i=0$ et $\Sigma X_j_i e_i=0$ pour chaque j (une équation normale par paramètre).

Cas 14 — Hyperplan de régression. Que devient la « droite » de régression avec deux régresseurs ?

Solution. Un **plan** (hyperplan en dimension k) dans l'espace (X_1,X_2,Y), passant par le point moyen $(\bar{x}_1,\bar{x}_2,\bar{y})$.

Cas 15 — Interpréter deux coefficients. $\hat{Y}=3+1{,}5X_1+0{,}8X_2$. Interpréter les coefficients.

Solution. À X_2 constant, +1 sur $X_1 \Longrightarrow$ +1,5 sur Y ; à X_1 constant, +1 sur $X_2 \Longrightarrow$ +0,8 sur Y. $\beta_0=3$ est Y quand $X_1=X_2=0$.

Cas 16 — Prédiction en multiple. $\hat{Y}=3+1{,}5X_1+0{,}8X_2$. Prédire Y pour $X_1=4$, $X_2=5$.

Solution. $\hat{Y}=3+1{,}5\times4+0{,}8\times5=3+6+4=$**13**.

Cas 17 — Attribution de performance. En quoi la régression multiple sert-elle l'attribution de performance ?

Solution. Elle décompose le rendement en **contributions de facteurs** ($\beta_j\times$facteur_j) plus un alpha résiduel, isolant chaque source.

Cas 18 — Variable non corrélée omise. Omettre une variable pertinente mais non corrélée aux régresseurs inclus : effet sur β_j ?

Solution. **Aucun biais** : β_j reste sans biais. Seule la précision baisse (variance résiduelle plus élevée).

Cas 19 — Effet marginal constant ?. Dans $Y=\beta_0+\beta_1X_1+\beta_2X_2+\varepsilon$ (sans interaction), l'effet de X_1 dépend-il de X_2 ?

Solution. **Non** : l'effet de X_1 est constant (β_1), indépendant de X_2. Il faudrait un terme d'interaction X_1X_2 pour qu'il en dépende.

Cas 20 — Pourquoi plusieurs régresseurs ?. Pourquoi passer d'une régression simple à multiple en finance ?

Solution. Parce que les phénomènes sont **multifactoriels** : contrôler plusieurs influences simultanées évite le biais d'omission et affine l'interprétation.

Bloc 2 --- Estimation MCO en dimension multiple

Cas 21 — Critère MCO en multiple. Que minimisent les MCO en régression multiple ?

Solution. La **somme des carrés des résidus** $\Sigma(Y_i-\beta_0-\beta_1X_{1i}-\ldots-\beta_k\ X_k_i)^2$: même principe qu'en simple, en dimension k+1.

Cas 22 — Forme matricielle des MCO. Donner l'expression matricielle de l'estimateur MCO.

Solution. $\beta=(X^TX)^{-1}X^Ty$, où X est la matrice n×(k+1) des régresseurs (colonne de 1 pour l'ordonnée) et y le vecteur des Y_i.

Cas 23 — Condition d'inversibilité. Quelle condition rend X^TX inversible ?

Solution. **Absence de colinéarité parfaite** : aucun régresseur ne doit être combinaison linéaire exacte des autres, sinon X^TX est singulière.

Cas 24 — Nombre d'équations normales. Combien d'équations normales pour k régresseurs ?

Solution. **k+1** : une par paramètre (β_0 et les k pentes). Elles imposent $\Sigma e_i=0$ et $\Sigma X_j_i e_i=0$ pour chaque j.

Cas 25 — Estimation MCO — lecture d'une sortie. Régression de Y sur X_1 et X_2 (n=8). $\beta_0=2{,}632$, $\beta_1=1{,}471$, $\beta_2=0{,}921$. Écrire le modèle ajusté.

Solution. $\hat{Y}=2{,}632+1{,}471X_1+0{,}921X_2$ (proche du vrai modèle $3+1{,}5X_1+0{,}8X_2$).

Cas 26 — Résidus orthogonaux. Que valent Σe_i et $\Sigma X_{1i}e_i$ dans une régression multiple avec ordonnée ?

Solution. **0 tous les deux** : conséquence des équations normales. Les résidus sont orthogonaux à l'ordonnée et à chaque régresseur.

Cas 27 — Le point moyen. L'hyperplan MCO passe-t-il par un point particulier ?

Solution. Oui, par le **point moyen** $(\bar{x}_1,\ldots,\bar{x}_k,\bar{y})$: généralisation de « la droite passe par $(\bar{x},\bar{y})$ ».

Cas 28 — Pourquoi la notation matricielle. Pourquoi une formule matricielle plutôt que scalaire en multiple ?

Solution. Chaque coefficient dépend de **tous** les régresseurs et de leurs corrélations ; $(X^TX)^{-1}X^Ty$ encapsule ce système d'équations couplées.

Cas 29 — Valeurs ajustées matricielles. Comment obtient-on le vecteur des valeurs ajustées ?

Solution. $\hat{y}=X\beta=X(X^TX)^{-1}X^Ty$: projection de y sur l'espace engendré par les régresseurs (matrice chapeau H).

Cas 30 — Résidus comme projection. Que représentent géométriquement les résidus ?

Solution. La **composante de y orthogonale** à l'espace des régresseurs : $e=y-\hat{y}=(I-H)y$. $RSS=\|e\|^2$ est minimale par construction.

Cas 31 — Colinéarité parfaite — exemple. Donner un exemple de colinéarité parfaite empêchant l'estimation.

Solution. Inclure X, 2X et une ordonnée : 2X est combinaison exacte de $X \Longrightarrow X^TX$ singulière $\Longrightarrow$ MCO impossible. Autre cas : toutes les dummies + ordonnée.

Cas 32 — Effet d'un régresseur redondant. Ajouter un régresseur parfaitement corrélé à un autre : que se passe-t-il ?

Solution. Colinéarité parfaite $\Longrightarrow$ le logiciel ne peut estimer (ou en supprime un automatiquement). Les coefficients ne sont pas identifiés.

Cas 33 — Sensibilité aux données. Pourquoi les coefficients multiples peuvent-ils être instables ?

Solution. En présence de forte corrélation entre régresseurs (multicolinéarité imparfaite), de petits changements de données modifient beaucoup les coefficients (SE gonflées).

Cas 34 — Interpréter un β négatif inattendu. Un coefficient ressort négatif contre l'intuition. Première piste ?

Solution. **Multicolinéarité** ou **variable omise** : contrôler pour des variables corrélées peut inverser un signe. Examiner les VIF et la spécification.

Cas 35 — Reconstituer une prédiction factorielle. $R-R_f=0{,}2\ \%+0{,}9\cdot MKT+0{,}5\cdot SMB$. Prédire l'excès de rendement si MKT=5 %, SMB=2 %.

Solution. $0{,}2\ \%+0{,}9\times5\ \%+0{,}5\times2\ \%=0{,}2\ \%+4{,}5\ \%+1\ \%=$**5,7 %**.

Cas 36 — Contribution d'un facteur. Dans le modèle précédent, quelle est la contribution du facteur SMB si SMB=2 % ?

Solution. Contribution = $\beta\cdot$facteur = $0{,}5\times2\ \%=$**1 %** au rendement excédentaire.

Cas 37 — MCO et moyenne conditionnelle. Qu'estiment les MCO en régression multiple ?

Solution. La **moyenne conditionnelle** $E[Y|X_1,\ldots,X_k]=\beta_0+\Sigma\beta_j X_j$: le meilleur prédicteur linéaire de Y sachant les régresseurs.

Cas 38 — Degrés de liberté des résidus. Combien de degrés de liberté pour les résidus, n obs et k régresseurs ?

Solution. **$n-k-1$** : n observations moins k+1 paramètres estimés. C'est le diviseur de la variance résiduelle.

Cas 39 — Erreur-type de la régression (multiple). Comment estime-t-on σ (écart-type des erreurs) en multiple ?

Solution. $s_e=\sqrt{(RSS/(n-k-1))}$: racine de la variance résiduelle, avec $n-k-1$ ddl. Estime la dispersion des erreurs.

Cas 40 — Vérifier l'ordre de grandeur. n=8, k=2, RSS=0,166. Calculer l'erreur-type de la régression.

Solution. $s_e=\sqrt{(RSS/(n-k-1))}=\sqrt{(0{,}166/5)}=$**0,1824**.

Bloc 3 --- Gauss--Markov et biais de variable omise

Cas 41 — Hypothèses de Gauss–Markov (multiple). Énumérer les hypothèses de Gauss–Markov en régression multiple.

Solution. (H1) linéarité en β ; (H2) exogénéité E[ε|X]=0 ; (H3) homoscédasticité ; (H4) absence d'autocorrélation ; (H5) **absence de colinéarité parfaite**.

Cas 42 — La nouvelle hypothèse H5. Quelle hypothèse est propre au cadre multiple ?

Solution. L'**absence de colinéarité parfaite** : aucun régresseur combinaison linéaire exacte des autres (sinon X^TX non inversible).

Cas 43 — BLUE en multiple. Que garantit Gauss–Markov en régression multiple ?

Solution. Les MCO sont **BLUE** : chaque β_j est l'estimateur linéaire sans biais de variance minimale de l'effet partiel β_j.

Cas 44 — Biais de variable omise — définition. Qu'est-ce que le biais de variable omise ?

Solution. Le biais de β_j résultant de l'omission d'une variable Z pertinente **corrélée** à X_j : son effet se déverse dans ε, violant l'exogénéité.

Cas 45 — Les deux conditions du biais. Quelles deux conditions doivent être réunies pour un biais de variable omise ?

Solution. (1) Z **influence Y** ; (2) Z est **corrélée à un régresseur inclus** X_j. Si l'une manque, β_j reste sans biais.

Cas 46 — Signe du biais — cas positif/positif. Z a un effet positif sur Y et est positivement corrélée à X_j. Sens du biais sur β_j ?

Solution. Biais **positif** (β_j surestimé) : le produit (effet de Z sur Y)×(corr Z,X_j) est positif.

Cas 47 — Signe du biais — cas positif/négatif. Z a un effet positif sur Y mais est négativement corrélée à X_j. Sens du biais ?

Solution. Biais **négatif** (β_j sous-estimé) : le produit des deux signes est négatif.

Cas 48 — Biais d'omission — exemple financier. Régresser le rendement d'un fonds sur le seul marché, en omettant le facteur taille (fonds chargé en small caps). Effet ?

Solution. Le **bêta de marché est biaisé** : l'effet du facteur taille (omis, corrélé au marché via le style) contamine le bêta estimé.

Cas 49 — Omettre une variable non corrélée. Omettre une variable pertinente mais non corrélée aux régresseurs inclus : conséquence ?

Solution. **Pas de biais** sur les coefficients inclus ; seulement une perte de **précision** (variance résiduelle plus grande, SE plus larges).

Cas 50 — Exogénéité en multiple. Énoncer l'hypothèse d'exogénéité en régression multiple.

Solution. $E[\varepsilon_i|X_1,\ldots,X_k]=0$: l'erreur est en moyenne nulle conditionnellement à **tous** les régresseurs (non liée à aucun d'eux).

Cas 51 — Anticiper la direction du biais. Pourquoi peut-on parfois prédire le sens du biais sans données sur Z ?

Solution. Car le signe du biais = signe de (effet de Z sur Y)×(corr Z,X_j) : la théorie renseigne souvent ces deux signes, permettant d'anticiper la direction de l'erreur.

Cas 52 — Homoscédasticité — rappel. Que signifie l'homoscédasticité et affecte-t-elle le biais ?

Solution. $\mathrm{Var}(\varepsilon_i)=\sigma^2$ constante. Sa violation **ne biaise pas** β ; elle ne fausse que les erreurs-types.

Cas 53 — Normalité — quand nécessaire. La normalité des erreurs est-elle requise pour l'absence de biais en multiple ?

Solution. **Non** : β est sans biais sans normalité. Elle n'est requise que pour la validité **exacte** des tests t/F à petit n (TCL sinon).

Cas 54 — Consistance en multiple. Sous Gauss–Markov, les β_j sont-ils consistants ?

Solution. **Oui** : $\beta_j \to \beta_j$ quand $n\to\infty$. Sous endogénéité (variable omise corrélée), ils ne le sont **pas**.

Cas 55 — Remède au biais d'omission. Comment corriger un biais de variable omise ?

Solution. **Inclure la variable omise** dans le modèle (si observable), ou recourir à des **variables instrumentales** si elle ne l'est pas.

Cas 56 — Sur-contrôle (bad control). Inclure trop de variables peut-il aussi poser problème ?

Solution. Oui : contrôler pour une variable qui est un **canal de l'effet** (médiateur) ou un collider peut biaiser l'interprétation. La théorie guide le choix des contrôles.

Cas 57 — Endogénéité vs multicolinéarité. Distinguer l'effet de l'endogénéité et celui de la multicolinéarité sur β.

Solution. Endogénéité (variable omise) : β **biaisé**. Multicolinéarité : β **sans biais** mais SE gonflées. Biais vs précision — deux problèmes distincts.

Cas 58 — Estimateurs linéaires (multiple). En quel sens les MCO multiples sont-ils linéaires ?

Solution. $\beta=(X^TX)^{-1}X^Ty$ est une **combinaison linéaire des Y_i** (à X fixé) : $\beta=Wy$ avec W dépendant des régresseurs.

Cas 59 — Sans biais de chaque coefficient. Que signifie $E[\beta_j]=\beta_j$ sous Gauss–Markov ?

Solution. En moyenne sur les échantillons, β_j tombe juste sur le vrai effet partiel β_j : estimation sans biais.

Cas 60 — Conditions pour des tests valides. Quelles hypothèses garantissent des tests t/F valides en multiple ?

Solution. Gauss–Markov (SE correctes) **et** normalité des erreurs (ou n grand). Hétéroscédasticité/autocorrélation faussent les SE.

Bloc 4 --- R^2, R^2 ajusté et compromis biais--variance

Cas 61 — R^2 et R^2 ajusté — lecture. Régression (n=8, k=2) : $R^2=0{,}9987$. Calculer le R^2 ajusté.

Solution. $\bar{R}^2=1-(1-R^2)(n-1)/(n-k-1)=1-(1-0{,}9987)(7/5)=$**0,9982**.

Cas 62 — R^2 brut croît toujours. Que devient le R^2 quand on ajoute un régresseur, même inutile ?

Solution. Il **ne décroît jamais** : les MCO exploitent toujours un peu de variance supplémentaire. D'où la nécessité du R^2 ajusté.

Cas 63 — R^2 ajusté peut décroître. À quelle condition l'ajout d'un régresseur augmente-t-il le R^2 ajusté ?

Solution. Ssi le nouveau régresseur a un $|t|>1$ (gain d'ajustement > coût d'un ddl). Sinon $\bar{R}^2$ **décroît**.

Cas 64 — Comparer des modèles. Par quel critère compare-t-on des modèles de tailles différentes ?

Solution. Par le **R^2 ajusté** (ou AIC/BIC), jamais par le R^2 brut qui favorise mécaniquement le modèle le plus riche.

Cas 65 — Calcul de R^2 ajusté. $R^2=0{,}8$, n=100, k=5. Calculer le R^2 ajusté.

Solution. $\bar{R}^2=1-(1-0{,}8)(99/94)=1-0{,}2\times1{,}0532=$**0,7894**.

Cas 66 — R^2 ajusté négatif. Le R^2 ajusté peut-il être négatif ?

Solution. **Oui** : si les régresseurs n'expliquent quasiment rien (R^2 très faible, k grand), $\bar{R}^2$ peut passer sous 0.

Cas 67 — Compromis biais–variance. Décrire le compromis biais–variance en spécification.

Solution. **Sous-spécifier** (omettre une variable pertinente) $\Longrightarrow$ biais ; **sur-spécifier** (variables inutiles) $\Longrightarrow$ variance accrue (SE gonflées). La bonne spécification arbitre entre les deux.

Cas 68 — Sur-spécification — effet. Inclure des régresseurs inutiles biaise-t-il β ?

Solution. **Non** : β reste sans biais, mais la **variance** des estimateurs augmente (SE plus grandes, coefficients moins précis).

Cas 69 — Sous-spécification — effet. Omettre une variable pertinente corrélée biaise-t-il β ?

Solution. **Oui** : biais de variable omise. Le compromis biais–variance oppose ce biais à la perte de précision de la sur-spécification.

Cas 70 — Décomposition depuis R^2. R^2=0,75, TSS=400. Calculer ESS et RSS.

Solution. ESS=R^2·TSS=0,75×400=**300** ; RSS=TSS−ESS=**100**.

Cas 71 — R^2 et nombre de régresseurs. Deux modèles, R^2=0,80 (k=2) et R^2=0,82 (k=8). Lequel préférer a priori ?

Solution. Regarder le **R^2 ajusté** : le gain de R^2 (0,02) peut ne pas justifier 6 régresseurs de plus. $\bar{R}^2$ tranche en pénalisant k.

Cas 72 — Interpréter R^2=0,90 en multiple. Un R^2=0,90 signifie quoi, et faut-il s'en réjouir sans réserve ?

Solution. 90 % de la variance de Y expliquée — mais méfiance : un R^2 élevé peut refléter du **surajustement**. Vérifier le $\bar{R}^2$ et la performance hors échantillon.

Cas 73 — AIC — principe. Que pénalise le critère AIC ?

Solution. AIC=n·ln(RSS/n)+2(k+1) : il pénalise le **nombre de paramètres**. On choisit le modèle à AIC **minimal**.

Cas 74 — BIC vs AIC. En quoi le BIC diffère-t-il de l'AIC ?

Solution. BIC=n·ln(RSS/n)+(k+1)·ln n : il pénalise **plus lourdement** les paramètres (facteur ln n), favorisant la parcimonie.

Cas 75 — Surajustement — définition. Qu'est-ce que le surajustement (overfitting) ?

Solution. Un modèle qui **épouse le bruit** de l'échantillon : excellent R^2 en échantillon, mauvaise prévision hors échantillon.

Cas 76 — Protection contre le surajustement. Citer trois protections contre le surajustement.

Solution. **R^2 ajusté**, **critères AIC/BIC**, et surtout **validation hors échantillon** (ou validation croisée).

Cas 77 — R^2 ajusté et |t|=1. Un régresseur ajouté a exactement |t|=1. Effet sur le R^2 ajusté ?

Solution. $\bar{R}^2$ **inchangé** (seuil) : |t|>1 l'augmente, |t|<1 le diminue. C'est le point de bascule.

Cas 78 — Choisir entre modèles emboîtés. Comment décider si un groupe de régresseurs supplémentaires mérite d'être gardé ?

Solution. Par un **test F conjoint** (restrictions), l'évolution du **$\bar{R}^2$** et la performance **hors échantillon** — pas le R^2 brut.

Cas 79 — R^2 ne mesure pas la validité. Un R^2 élevé garantit-il un bon modèle ?

Solution. **Non** : il mesure l'ajustement en échantillon, pas la validité (biais possible), ni la causalité, ni la performance prédictive.

Cas 80 — Parcimonie. Pourquoi préférer un modèle parcimonieux à pouvoir explicatif comparable ?

Solution. Coefficients plus **stables**, moins de surajustement, meilleure prévision hors échantillon, interprétation plus claire.

Bloc 5 --- Tests de significativité individuelle

Cas 81 — Test t d'un coefficient partiel. β de X_1=1,471, SE=0,0282, n=8, k=2. Tester H_0:β=0 à 5 %.

Solution. t=β/SE=1,471/0,0282=**52,268** sur n−k−1=5 ddl ; p=0 ⟹ rejet (significatif).

Cas 82 — Test t d'un coefficient partiel. β de X_2=0,921, SE=0,0282, n=8, k=2. Tester H_0:β=0 à 5 %.

Solution. t=β/SE=0,921/0,0282=**32,731** sur n−k−1=5 ddl ; p=0 ⟹ rejet (significatif).

Cas 83 — Statistique du test t partiel. Donner la statistique pour tester H_0:β_j=0 en multiple.

Solution. t=β_j/SE(βj) ~ t\{n−k−1\} sous H_0. Rejeter si |t| dépasse la valeur critique.

Cas 84 — Degrés de liberté en multiple. Combien de ddl pour tester un coefficient, n=50, k=4 ?

Solution. n−k−1=50−4−1=**45 ddl** (k+1=5 paramètres estimés).

Cas 85 — ddl : simple vs multiple. Comparer les ddl du test t en régression simple et multiple.

Solution. Simple : n−2 (k=1). Multiple : n−k−1. Chaque régresseur supplémentaire **retire un degré de liberté**.

Cas 86 — Significativité conditionnelle. « β_j non significatif » signifie-t-il « X_j sans lien avec Y » ?

Solution. **Non** : cela signifie que X_j n'apporte pas d'info **additionnelle** une fois les autres régresseurs inclus. La significativité est conditionnelle au modèle.

Cas 87 — Coefficient rendu non significatif. Pourquoi un coefficient significatif en simple peut-il devenir non significatif en multiple ?

Solution. Un régresseur **corrélé** ajouté capte une part de son effet (multicolinéarité) : l'erreur-type gonfle, le t chute.

Cas 88 — Valeur critique t en multiple. n=30, k=3. Valeur critique t bilatérale à 5 % pour un coefficient ?

Solution. df=n−k−1=26 ; $t_{26;0,975}$=**2,056** : rejeter H_0 si |t|>2,056.

Cas 89 — Tester un coefficient contre une valeur. Comment tester H_0:β_j=1 (et pas 0) ?

Solution. t=(β_j−1)/SE(β_j) sur n−k−1 ddl : on centre sur la valeur testée. Utile pour tester un bêta contre 1.

Cas 90 — Interpréter un t=1,2 en multiple. Un coefficient a t=1,2 (seuil ≈2,0). Conclusion ?

Solution. |1,2|<2,0 ⟹ **ne pas rejeter** H_0:β_j=0 : pas d'effet propre significatif détecté (conditionnellement aux autres variables).

Cas 91 — Coefficient significatif mais faible. Un coefficient est significatif (t=6) mais vaut 0,01. Importance ?

Solution. Significatif statistiquement, mais **ampleur négligeable**. Significativité ≠ matérialité (chapitre 6).

Cas 92 — Effet de n sur le t. À β_j et SE de régression fixés, comment le t évolue-t-il avec n ?

Solution. SE(β_j) décroît avec n ⟹ |t| **augmente** : un même effet partiel devient plus significatif sur un grand échantillon.

Cas 93 — Intervalle de confiance d'un coefficient partiel. β_j=1,5, SE=0,3, n=40, k=3 (t_{36}≈2,03). IC à 95 % ?

Solution. IC=β_j±t·SE=1,5±2,03×0,3=1,5±0,609=**[0,891 ; 2,109]** (0 hors IC ⟹ significatif).

Cas 94 — Dualité IC–test partiel. IC à 95 % pour β_j = [0,2 ; 0,8]. β_j diffère-t-il de 0 ?

Solution. **Oui** : 0 est hors de l'IC ⟹ rejet de H_0:β_j=0 à 5 % (dualité test–IC).

Cas 95 — Signe et significativité. Un coefficient vaut β=−0,5 avec t=−3,0. Interprétation ?

Solution. Effet partiel **négatif et significatif** : à autres variables constantes, +1 sur X_j ⟹ −0,5 sur Y, statistiquement établi.

Cas 96 — Le t ne dit pas l'importance économique. Que faut-il rapporter à côté du t d'un coefficient ?

Solution. L'**ampleur du coefficient** et son **IC** : ils indiquent la taille de l'effet partiel, que le seul t ne révèle pas.

Cas 97 — Test t et hétéroscédasticité. Pourquoi l'hétéroscédasticité invalide-t-elle le test t d'un coefficient ?

Solution. Elle **fausse SE(β_j)** ⟹ t erroné. β_j reste sans biais, mais le test est invalide : utiliser des SE robustes (White).

Cas 98 — Test t bilatéral vs unilatéral (coefficient). Quand tester un coefficient en unilatéral plutôt qu'en bilatéral ?

Solution. Quand la théorie prédit un **signe** (ex. une prime de risque positive) : H_0:β_j≤0 contre H_1:β_j>0. La latéralité se fixe a priori.

Cas 99 — Contribution d'un régresseur à l'ajustement. Comment mesurer l'apport d'un seul régresseur au pouvoir explicatif ?

Solution. Comparer le R^2 (ou $\bar{R}^2$) avec et sans ce régresseur, ou tester son coefficient (t) : un t significatif indique un apport propre réel.

Cas 100 — Coefficient et unité de mesure. Multiplier un régresseur X_j par 100 (changement d'unité) affecte-t-il son t ?

Solution. **Non** : β_j est divisé par 100 et SE(β_j) aussi $\Longrightarrow$ le rapport t=β_j/SE est **inchangé**. La significativité ne dépend pas de l'unité.

Bloc 6 --- Test F global et tests F conjoints

Cas 101 — Test F global — lecture. Régression (n=8, k=2) : R^2=0,9987. Calculer la statistique F globale.

Solution. F=(R^2/k)/((1−R^2)/(n−k−1))=(0,9987/2)/(0,0013/5)=**1901,62** sur (2,5) ddl (p=0).

Cas 102 — Hypothèse nulle du F global. Que teste le test F de significativité globale ?

Solution. H_0 : **$\beta_1=\beta_2=...=\beta_k=0$** (aucun régresseur n'explique Y) contre H_1 : au moins un β_j≠0.

Cas 103 — Formule du F global. Donner la statistique F globale en fonction du R^2.

Solution. F=(R^2/k)/((1−R^2)/(n−k−1)) ~ F_{k,n−k−1} sous H_0. Croît avec R^2 et n.

Cas 104 — Test F conjoint — principe. Comment tester q restrictions simultanées (ex. $\beta_2=\beta_3=0$) ?

Solution. Comparer le modèle **contraint** au **non contraint** : F=((RSS_c−RSS_nc)/q)/(RSS_nc/(n−k−1)) ~ F_{q,n−k−1}.

Cas 105 — F conjoint — calcul. RSS_c=120 (contraint), RSS_nc=100 (non contraint), q=2, n=50, k=5. Calculer F.

Solution. F=((120−100)/2)/(100/(50−5−1))=(10)/(100/44)=10/2,273=**4,4** sur (2,44) ddl.

Cas 106 — Cas q=k. Que devient le test F conjoint si q=k (toutes les pentes) ?

Solution. Il coïncide avec le **test F global** : le modèle contraint est alors « $Y=\beta_0+\varepsilon$ » (RSS_c=TSS).

Cas 107 — Cas q=1. Que devient le test F conjoint si q=1 ?

Solution. Il équivaut au **test t** du coefficient concerné : **$F=t^2$**. Une seule restriction $\Longrightarrow$ test t et test F identiques.

Cas 108 — Latéralité du test F. Le test F est-il uni ou bilatéral ?

Solution. **Unilatéral droit** : on rejette H_0 pour de **grandes** valeurs de F (F≥1 par construction ; queue droite).

Cas 109 — Pourquoi pas des t séparés ?. Pourquoi tester $\beta_2=\beta_3=0$ par un F conjoint plutôt que deux tests t ?

Solution. (1) Les t séparés ne contrôlent pas le **risque global** de type I ; (2) ils ignorent la **corrélation** entre β_2 et β_3. Le F conjoint est la procédure correcte.

Cas 110 — F significatif, t non significatifs. Le F global rejette H_0 mais aucun t n'est significatif. Cause probable ?

Solution. **Multicolinéarité** : des régresseurs corrélés se partagent l'explication (t faibles) tout en expliquant conjointement Y (F élevé).

Cas 111 — Tester un groupe de facteurs. Comment tester si un groupe de facteurs sectoriels est collectivement pertinent ?

Solution. Par un **test F conjoint** de la nullité simultanée de leurs coefficients : F sur q restrictions (q = nombre de facteurs du groupe).

Cas 112 — F et R^2. Comment F se relie-t-il au R^2 et à n ?

Solution. F=(R^2/k)/((1−R^2)/(n−k−1)) : croît avec R^2 et avec n. Un R^2 modéré peut être significatif sur un grand échantillon.

Cas 113 — Décision par le F global. F=8 sur (3,46), valeur critique ≈2,8. Décision ?

Solution. 8>2,8 $\Longrightarrow$ **rejet de H_0** : le modèle a un pouvoir explicatif globalement significatif (au moins un facteur compte).

Cas 114 — F vs t — quelle question ?. Que répond le F et que répondent les t individuels ?

Solution. Le **F** : « le modèle (ou un groupe de variables) explique-t-il Y ? » ; les **t** : « quelle variable a un effet propre ? ».

Cas 115 — Valeur critique du F. n=50, k=4. Valeur critique F à 5 % pour la significativité globale ?

Solution. F_{4,45;0,95}=**2,579** : rejeter H_0 si F dépasse cette valeur.

Cas 116 — F conjoint et modèles emboîtés. Le test F conjoint compare quels modèles ?

Solution. Deux modèles **emboîtés** : le contraint (restrictions imposées) niché dans le non contraint. Il mesure la perte d'ajustement due aux contraintes.

Cas 117 — RSS contraint ≥ non contraint. Pourquoi RSS_c ≥ RSS_nc toujours ?

Solution. Imposer des contraintes ne peut qu'**augmenter** (ou laisser égal) la RSS : moins de liberté d'ajustement. Le F mesure si cette hausse est significative.

Cas 118 — Interpréter un F conjoint non significatif. Un test F conjoint sur $\beta_2=\beta_3=0$ n'est pas significatif. Conclusion ?

Solution. On **ne rejette pas** : les variables X_2 et X_3 n'apportent pas conjointement de pouvoir explicatif significatif ; on peut envisager de les retirer.

Cas 119 — F global vs somme des t. Peut-on déduire le F global de la somme des t^2 individuels ?

Solution. **Non** en général : le F global tient compte des **corrélations** entre régresseurs. $F=t^2$ seulement en régression simple (k=1).

Cas 120 — Test de restriction linéaire générale. Le test F conjoint peut-il tester $\beta_1=\beta_2$ (égalité, pas nullité) ?

Solution. **Oui** : toute restriction linéaire (ex. $\beta_1=\beta_2$, soit $\beta_1-\beta_2=0$) se teste par la comparaison contraint/non contraint (q=1 ici).

Cas 121 — Significativité globale ≠ bonne spécification. Un F global significatif garantit-il un bon modèle ?

Solution. **Non** : il indique seulement qu'au moins un régresseur compte. Le modèle peut être mal spécifié (variable omise, mauvaise forme).

Cas 122 — F et taille d'échantillon. À R^2 fixé, comment le F global évolue-t-il avec n ?

Solution. Il **augmente** avec n (facteur n−k−1) : un même R^2 devient globalement significatif sur un plus grand échantillon.

Cas 123 — Numérateur et dénominateur du F conjoint. Qu'expriment le numérateur et le dénominateur du F conjoint ?

Solution. Numérateur : **gain de RSS par restriction** (perte d'ajustement dû aux contraintes, par ddl) ; dénominateur : variance résiduelle du modèle non contraint (RSS_nc/(n−k−1)).

Cas 124 — Le F conjoint généralise. En quoi le test F conjoint généralise-t-il le F global et le test t ?

Solution. F global = F conjoint avec q=k ; test t = F conjoint avec q=1 ($F=t^2$). Le F conjoint est le cadre unifié des tests de restrictions linéaires.

Bloc 7 --- Multicolinéarité et VIF

Cas 125 — Multicolinéarité — définition. Qu'est-ce que la multicolinéarité ?

Solution. Une forte corrélation linéaire entre régresseurs. **Parfaite** si un régresseur est combinaison exacte des autres ; **imparfaite** (cas usuel) si la corrélation est forte mais non exacte.

Cas 126 — Colinéarité parfaite — conséquence. Que se passe-t-il en cas de colinéarité parfaite ?

Solution. X^TX n'est **pas inversible** : les MCO ne peuvent estimer les coefficients (non identifiés). Il faut retirer un régresseur redondant.

Cas 127 — VIF — définition et formule. Définir le facteur d'inflation de la variance (VIF).

Solution. VIF_j=1/(1−R_j^2), où R_j^2 est le R^2 de la régression de X_j sur tous les autres régresseurs. SE(β_j) croît avec $\sqrt{}$VIF_j.

Cas 128 — Calcul du VIF. Le R^2 de la régression de X_j sur les autres régresseurs vaut R_j^2=0,9. Calculer le VIF.

Solution. VIF=1/(1−0,9)=**10** $\Longrightarrow$ SE(β_j) multipliée par $\sqrt{}$10=3,16 (colinéarité forte).

Cas 129 — Calcul du VIF. Le R^2 de la régression de X_j sur les autres régresseurs vaut R_j^2=0,5. Calculer le VIF.

Solution. VIF=1/(1−0,5)=**2** $\Longrightarrow$ SE(β_j) multipliée par $\sqrt{}$2=1,41 (colinéarité modérée).

Cas 130 — Calcul du VIF. Le R^2 de la régression de X_j sur les autres régresseurs vaut R_j^2=0,8. Calculer le VIF.

Solution. VIF=1/(1−0,8)=**5** $\Longrightarrow$ SE(β_j) multipliée par $\sqrt{}$5=2,24 (colinéarité forte).

Cas 131 — Calcul du VIF. Le R^2 de la régression de X_j sur les autres régresseurs vaut R_j^2=0. Calculer le VIF.

Solution. VIF=1/(1−0)=**1** $\Longrightarrow$ SE(β_j) multipliée par $\sqrt{}$1=1 (colinéarité nulle).

Cas 132 — Seuil d'alerte du VIF. À partir de quelle valeur le VIF signale-t-il un problème ?

Solution. Règle usuelle : **VIF>5** (parfois 10) indique une multicolinéarité problématique. VIF=1 signifie aucune corrélation avec les autres.

Cas 133 — Multicolinéarité et biais. La multicolinéarité imparfaite biaise-t-elle β ?

Solution. **Non** : les MCO restent BLUE (sans biais). Elle ne fait que **gonfler les erreurs-types** (perte de précision).

Cas 134 — Symptômes de la multicolinéarité. Citer trois symptômes typiques de multicolinéarité.

Solution. (1) coefficients **instables** ; (2) **t individuels faibles** malgré F global significatif et R^2 élevé ; (3) **signes contre-intuitifs**.

Cas 135 — Intuition de l'imprécision. Pourquoi la multicolinéarité rend-elle les coefficients imprécis ?

Solution. Si deux régresseurs varient presque ensemble, les données peinent à **attribuer l'effet** à l'un plutôt qu'à l'autre $\Longrightarrow$ SE gonflées.

Cas 136 — VIF=10 — effet chiffré. Un VIF de 10 correspond à quel R_j^2 et quel facteur sur l'erreur-type ?

Solution. R_j^2=0,9 (car VIF=1/(1−R_j^2)) ; l'erreur-type est multipliée par $\sqrt{}$10$\approx$**3,2** par rapport à l'absence de colinéarité.

Cas 137 — Multicolinéarité et prévision. La multicolinéarité est-elle gênante si le but est la prévision ?

Solution. **Souvent bénigne** : le modèle prédit bien même si les coefficients individuels sont imprécis. Elle gêne surtout l'**interprétation** des effets partiels.

Cas 138 — Remèdes à la multicolinéarité. Citer trois remèdes à la multicolinéarité (objectif interprétation).

Solution. **Retirer** un régresseur redondant, les **combiner** (indice, PCA), ou **collecter plus de données**. Ne pas conclure hâtivement à l'inutilité sur un t faible.

Cas 139 — Erreur à éviter. Quelle erreur d'interprétation la multicolinéarité induit-elle ?

Solution. Conclure qu'une variable est **inutile** sur la seule foi d'un t faible, alors qu'elle est peut-être seulement colinéaire (son effet est réel mais mal identifié).

Cas 140 — Corrélation vs VIF. Une simple corrélation par paire suffit-elle à détecter la multicolinéarité ?

Solution. **Pas toujours** : la multicolinéarité peut impliquer **plusieurs** régresseurs sans forte corrélation par paire. Le VIF (régression sur tous les autres) est plus fiable.

Cas 141 — PCA contre la colinéarité. Comment l'analyse en composantes principales (PCA) aide-t-elle ?

Solution. Elle remplace des régresseurs corrélés par des **composantes orthogonales** (non corrélées), éliminant la colinéarité au prix de l'interprétabilité directe.

Cas 142 — Colinéarité parfaite vs imparfaite. Distinguer les conséquences des deux types de colinéarité.

Solution. **Parfaite** : estimation impossible (X^TX singulière). **Imparfaite** : estimation possible mais SE gonflées, coefficients instables.

Cas 143 — Effet de plus de données. Pourquoi collecter plus de données atténue-t-il la multicolinéarité ?

Solution. Plus d'observations réduisent les erreurs-types (précision $\propto 1/\sqrt{n}$), compensant en partie l'inflation due à la colinéarité.

Cas 144 — VIF minimal. Que vaut le VIF d'un régresseur non corrélé aux autres ?

Solution. **VIF=1** ($R_j^2=0$) : aucune inflation de variance. C'est le cas idéal d'orthogonalité entre régresseurs.

Bloc 8 --- Variables indicatrices et interactions

Cas 145 — Variable indicatrice — définition. Qu'est-ce qu'une variable indicatrice (dummy) ?

Solution. Une variable valant **1 si une condition est remplie, 0 sinon**, permettant d'introduire une information qualitative dans la régression.

Cas 146 — Nombre d'indicatrices. Pour une variable qualitative à m modalités, combien d'indicatrices inclure ?

Solution. **m−1** indicatrices, une modalité servant de **catégorie de référence** (baseline). Inclure les m + l'ordonnée crée une colinéarité parfaite.

Cas 147 — La trappe des dummies. Qu'est-ce que la « dummy variable trap » ?

Solution. Inclure **toutes** les m indicatrices **et** l'ordonnée : leur somme vaut 1 (= colonne de l'ordonnée) $\Longrightarrow$ colinéarité parfaite, MCO impossible.

Cas 148 — Interprétation d'un coefficient de dummy. $Y=\beta_0+\beta_1 D+\ldots$, $D\in\{0,1\}$. Qu'est β_1 ?

Solution. L'**écart moyen** de Y entre la catégorie D=1 et la catégorie de référence (D=0), toutes choses égales par ailleurs.

Cas 149 — Éviter la trappe — solution. Comment éviter la dummy variable trap ?

Solution. **Omettre une modalité** (référence) et n'inclure que m−1 indicatrices. Chaque coefficient mesure l'écart à la référence.

Cas 150 — Quatre secteurs — combien de dummies. Pour quatre secteurs, combien de variables indicatrices avec une ordonnée ?

Solution. **Trois** (4−1). Le secteur omis est la référence ; chaque coefficient mesure l'écart de son secteur à la référence.

Cas 151 — Interpréter une dummy sectorielle. Le coefficient « secteur bancaire » vaut +1,2 % (référence : industrie). Interprétation ?

Solution. À autres variables constantes, les banques ont un rendement moyen **supérieur de 1,2 %** à celui de l'industrie (référence).

Cas 152 — Changer la référence. Changer la modalité de référence modifie-t-il le modèle ?

Solution. Les **coefficients changent** (ils mesurent des écarts à une autre référence), mais les **prédictions** et le R^2 sont **identiques**. Le choix de la référence est une convention.

Cas 153 — Dummy pour une période. Comment tester un effet « avant/après » un événement (ex. crise) ?

Solution. Introduire une dummy D=1 après l'événement, 0 avant : son coefficient mesure le **changement moyen** de Y post-événement.

Cas 154 — Terme d'interaction — définition. Qu'est-ce qu'un terme d'interaction ?

Solution. Le **produit de deux régresseurs** (X_1X_2) inclus comme variable : il permet à l'effet de X_1 de **dépendre** de la valeur de X_2.

Cas 155 — Effet marginal avec interaction. Dans $Y=\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_1X_2+\varepsilon$, quel est l'effet marginal de X_1 ?

Solution. $\partial E[Y]/\partial X_1 = \boldsymbol{\beta_1 + \beta_3 X_2}$: l'effet de X_1 varie selon X_2. β_3 mesure de combien cet effet change quand X_2 augmente d'une unité.

Cas 156 — Interpréter β_1 avec interaction. En présence de $\beta_3 X_1 X_2$, que représente β_1 seul ?

Solution. L'effet de X_1 **lorsque $X_2 = 0$** (et non l'effet « moyen » de X_1). Interprétation piège fréquente.

Cas 157 — Interaction dummy × continue. Comment tester si l'effet d'un facteur diffère selon le régime de marché ?

Solution. Croiser une **dummy de régime** (haussier/baissier) avec le facteur : le coefficient d'interaction mesure la **modulation** de l'effet selon le régime.

Cas 158 — Effet non linéaire — terme quadratique. Comment modéliser une relation courbe entre X et Y ?

Solution. Ajouter $\mathbf{X^2}$: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$. Le modèle reste linéaire en β (estimable par MCO), mais non linéaire en X.

Cas 159 — Effet marginal quadratique. Dans $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$, quel est l'effet marginal de X ?

Solution. $\partial E[Y]/\partial X = \boldsymbol{\beta_1 + 2\beta_2 X}$: il dépend du niveau de X. Capte rendements décroissants, relations en U, convexité.

Cas 160 — Convexité obligataire. Comment un terme quadratique capte-t-il la convexité prix–taux d'une obligation ?

Solution. La relation prix–taux est courbe : $\text{Prix} = \beta_0 + \beta_1 \cdot \text{taux} + \beta_2 \cdot \text{taux}^2 + \varepsilon$. β_2 capte la **convexité** (courbure), au-delà de la duration (β_1).

Cas 161 — Linéarité préservée. Pourquoi X^2 et $X_1 X_2$ n'empêchent-ils pas l'usage des MCO ?

Solution. Parce que le modèle reste **linéaire dans les paramètres** β : on traite X^2 et $X_1 X_2$ comme de nouveaux régresseurs. La linéarité a toujours porté sur β, pas sur la forme en X.

Cas 162 — Tester une interaction. Comment savoir si une interaction est significative ?

Solution. Par le **test t** du coefficient d'interaction β_3 : $t = \beta_3/\text{SE}$. S'il est significatif, l'effet d'une variable dépend bien de l'autre.

Cas 163 — Dummy et pente différente. Comment permettre à la fois un intercept et une pente différents entre deux groupes ?

Solution. Inclure la **dummy** (intercept différent) **et** son **interaction avec X** (pente différente) : $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (D \cdot X) + \varepsilon$.

Cas 164 — Interpréter un modèle avec dummy et interaction. $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (D \cdot X)$. Quelle est la pente pour le groupe D=1 ?

Solution. Pente = $\boldsymbol{\beta_1 + \beta_3}$ (pour D=1) contre β_1 (pour D=0). β_3 mesure la différence de pente entre les deux groupes.

Cas 165 — Variables qualitatives ordinales. Comment traiter une variable ordinale (ex. notation AAA>AA>A) ?

Solution. Soit par **dummies** ($m-1$, sans imposer d'ordre), soit par un **score numérique** si l'ordre et les écarts ont un sens. Les dummies sont plus flexibles.

Cas 166 — Piège d'interprétation des interactions. Peut-on interpréter β_1 isolément en présence d'une interaction $X_1 X_2$?

Solution. **Non** : β_1 est l'effet de X_1 **quand $X_2 = 0$**. L'effet global $\beta_1 + \beta_3 X_2$ dépend de X_2. Interpréter les coefficients ensemble.

Cas 167 — Effet de seuil. Comment modéliser un effet qui change au-delà d'un seuil de X ?

Solution. Par une **dummy de seuil** (D=1 si X>seuil) éventuellement croisée avec X, ou un modèle par morceaux (splines). Reste linéaire en β.

Cas 168 — Centrer avant l'interaction. Pourquoi centre-t-on parfois les variables avant de créer une interaction ?

Solution. Pour **réduire la multicolinéarité** entre X_1, X_2 et X_1X_2, et rendre β_1, β_2 interprétables comme effets « au point moyen » plutôt qu'à 0.

Bloc 9 --- Violations d'hypothèses et robustesse

Cas 169 — Biais vs précision — principe. Quelle distinction unifie le diagnostic des violations ?

Solution. **Biais** (variable omise/endogénéité : β faux) vs **précision** (hétéroscédasticité, autocorrélation, multicolinéarité : SE faussées, β correct).

Cas 170 — Hétéroscédasticité en multiple. Effet de l'hétéroscédasticité sur β et remède ?

Solution. β **sans biais**, SE **faussées** $\Longrightarrow$ tests invalides. Remède : erreurs-types de **White** (HC), qui corrigent les SE sans changer β.

Cas 171 — Autocorrélation en multiple. Effet de l'autocorrélation et remède ?

Solution. β **sans biais**, SE **faussées** (souvent sous-estimées). Remède : erreurs-types de **Newey–West** (HAC), robustes aussi à l'hétéroscédasticité.

Cas 172 — Variable omise — remède. Effet d'une variable omise corrélée et remède ?

Solution. β **biaisé**. Remède : **inclure la variable** (ou un proxy), ou recourir à des **instruments**. Aucune correction de SE n'y remédie.

Cas 173 — Ranger un problème : hétéroscédasticité. L'hétéroscédasticité relève-t-elle du biais ou de la précision ?

Solution. De la **précision** : elle ne fausse que les erreurs-types. On la corrige par des SE robustes, sans toucher aux coefficients.

Cas 174 — Ranger un problème : variable omise. La variable omise relève-t-elle du biais ou de la précision ?

Solution. Du **biais** : elle fausse β lui-même. Seule l'inclusion de la variable (ou un instrument) corrige — pas les SE robustes.

Cas 175 — SE robustes par défaut. Pourquoi rapporte-t-on souvent des SE robustes par défaut sur données financières ?

Solution. Parce que l'**hétéroscédasticité et l'autocorrélation y sont la norme** (volatilité changeante, dépendance temporelle). Les SE robustes protègent l'inférence.

Cas 176 — Diagnostics du cadre multiple. Quels diagnostics s'ajoutent en régression multiple par rapport au cas simple ?

Solution. Les **VIF** (multicolinéarité) et l'examen de la **matrice de corrélation** des régresseurs, en plus du graphe des résidus, Breusch–Pagan, Durbin–Watson, Jarque–Bera.

Cas 177 — Graphe des résidus en multiple. Contre quoi trace-t-on les résidus en régression multiple ?

Solution. Contre les **valeurs ajustées** $\hat{Y}$ (et éventuellement chaque régresseur) : un nuage sans structure valide les hypothèses.

Cas 178 — Breusch–Pagan. Que teste le test de Breusch–Pagan en multiple ?

Solution. L'**hétéroscédasticité** : H_0 = variance des erreurs constante. Un rejet signale une hétéroscédasticité à corriger (SE robustes).

Cas 179 — Durbin–Watson en multiple. Que teste la statistique de Durbin–Watson ?

Solution. L'**autocorrélation d'ordre 1** des résidus. Proche de 2 : pas d'autocorrélation ; loin de 2 : présence (fréquent sur séries temporelles).

Cas 180 — Normalité des résidus en multiple. Pourquoi tester la normalité des résidus (Jarque–Bera) ?

Solution. Pour la validité **exacte** des tests t/F à petit n. À grand n, le TCL rend l'inférence robuste à la non-normalité.

Cas 181 — SE robustes changent-elles β ?. Utiliser des erreurs-types robustes modifie-t-il les coefficients estimés ?

Solution. **Non** : $\hat{\beta}$ reste identique (mêmes MCO). Seules les **erreurs-types** (et donc les t, p-valeurs, IC) sont recalculées.

Cas 182 — Endogénéité — gravité. Pourquoi l'endogénéité est-elle plus grave que l'hétéroscédasticité ?

Solution. Elle **biaise β** (estimation fausse et non consistante), alors que l'hétéroscédasticité ne fausse que la précision (corrigeable par SE robustes).

Cas 183 — Combiner les remèdes. Un modèle présente hétéroscédasticité ET une variable omise. Que faire ?

Solution. D'abord **inclure la variable omise** (corriger le biais), **puis** utiliser des SE robustes (corriger la précision). L'ordre importe : le biais prime.

Cas 184 — Inspection avant conclusion (multiple). Quel réflexe avant d'interpréter les tests d'une régression multiple ?

Solution. Examiner **résidus, VIF et matrice de corrélation**, et vérifier les hypothèses : sans cela, t et F peuvent être trompeurs.

Bloc 10 --- Spécification du modèle et synthèse

Cas 185 — Compromis biais–variance. Résumer le compromis biais–variance en spécification.

Solution. Trop peu de variables $\Longrightarrow$ **biais** d'omission ; trop de variables $\Longrightarrow$ **variance** accrue (SE gonflées). La bonne spécification arbitre entre les deux.

Cas 186 — AIC — définition. Donner la définition et l'usage de l'AIC.

Solution. $\mathrm{AIC}=n\cdot\ln(\mathrm{RSS}/n)+2(k+1)$: pénalise le nombre de paramètres. On choisit le modèle à **AIC minimal**.

Cas 187 — BIC — définition. Donner la définition et l'usage du BIC.

Solution. $\mathrm{BIC}=n\cdot\ln(\mathrm{RSS}/n)+(k+1)\cdot\ln n$: pénalise **plus** que l'AIC (facteur $\ln n$). Favorise des modèles plus parcimonieux. Minimiser le BIC.

Cas 188 — AIC vs BIC. Lequel de l'AIC ou du BIC favorise la parcimonie, et pourquoi ?

Solution. Le **BIC** : sa pénalité $(k+1)\cdot\ln n$ croît avec n, plus sévère que le $2(k+1)$ de l'AIC. Il sélectionne des modèles plus petits.

Cas 189 — Principe 1 — la théorie d'abord. Quel est le premier principe d'une bonne spécification ?

Solution. **La théorie d'abord** : inclure les variables que la finance/l'économie désigne comme pertinentes, plutôt que de chercher aveuglément (data mining).

Cas 190 — Principe 2 — parcimonie. Énoncer le principe de parcimonie.

Solution. À pouvoir explicatif comparable, préférer le **modèle le plus simple** : coefficients plus stables, meilleure généralisation.

Cas 191 — Principe 3 — éviter le biais d'omission. Pourquoi ne pas exclure une variable pertinente corrélée aux régresseurs ?

Solution. Son omission **biaise** les coefficients inclus (biais de variable omise). Le compromis biais–variance penche alors vers l'inclusion.

Cas 192 — Principe 4 — validation hors échantillon. Comment juger réellement la qualité prédictive d'un modèle ?

Solution. Par sa performance sur des **données non utilisées** pour l'estimer (validation hors échantillon / croisée), pas sur son R^2 en échantillon.

Cas 193 — Surajustement — mécanisme. Pourquoi maximiser le R^2 conduit-il au surajustement ?

Solution. Le R^2 brut croît à chaque régresseur : empiler les variables fait **épouser le bruit**, d'où d'excellentes performances en échantillon mais médiocres hors échantillon.

Cas 194 — Data mining et faux modèles. Quel lien entre le surajustement et le problème des tests multiples (chap. 6) ?

Solution. Chercher exhaustivement le « meilleur » modèle sur les mêmes données garantit de trouver des relations **fallacieuses** (faux positifs), comme tester des centaines d'hypothèses.

Cas 195 — Danger en gestion des risques. Pourquoi un modèle sur-paramétré est-il dangereux en gestion des risques ?

Solution. Il donne une **fausse confiance** : coefficients instables, mauvaise prévision hors échantillon, sous-estimation possible du risque réel.

Cas 196 — Comparer deux modèles emboîtés. Quel test pour décider d'ajouter un groupe de régresseurs ?

Solution. Un **test F conjoint** (restrictions), complété par le R^2 ajusté, l'AIC/BIC et la validation hors échantillon.

Cas 197 — Choix des régresseurs — synthèse. Sur quels critères choisir les régresseurs ?

Solution. Théorie (pertinence), parcimonie, absence de biais d'omission, et validation hors échantillon. $\bar{R}^2$ et AIC/BIC opérationnalisent l'arbitrage.

Cas 198 — Chaîne Ch7 → Ch8. Comment le chapitre 8 prolonge-t-il le chapitre 7 ?

Solution. Il **généralise** à plusieurs régresseurs : effets partiels, biais d'omission, test F conjoint, multicolinéarité, dummies, interactions — le cadre réel des modèles à facteurs.

Cas 199 — La démarche complète. Résumer les étapes d'une analyse de régression multiple.

Solution. Modèle ⟶ MCO ⟶ effets partiels ⟶ ajustement ($\bar{R}^2$) ⟶ tests (t, F conjoint) ⟶ colinéarité (VIF) ⟶ dummies/interactions ⟶ robustesse ⟶ spécification (biais–variance, hors échantillon).

Cas 200 — La phrase de synthèse du chapitre. Résumer la régression multiple en une phrase.

Solution. La régression multiple estime les effets **partiels** de plusieurs facteurs ($\beta=(X^TX)^{-1}X^Ty$), les teste individuellement (t) et conjointement (F), en gérant biais d'omission, multicolinéarité et spécification — le socle des modèles multifactoriels.

Partie C --- Méthodologie, formulaire et astuces

Condensé de révision : toutes les formules de la régression multiple, un glossaire bilingue, la démarche en étapes et les pièges classiques.

C.1 --- Formulaire de la régression multiple

Modèle et estimation

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i; \qquad \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

$$\beta_j = \frac{\partial\, \mathbb{E}[Y \mid X_1, \ldots, X_k]}{\partial X_j} \quad \text{(effet partiel, autres } X \text{ constants)}.$$

Ajustement et erreurs-types

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}; \qquad \bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}; \qquad s_e = \sqrt{\frac{\text{RSS}}{n-k-1}}.$$

Tests d'inférence

$$\text{Individuel : } t = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t_{n-k-1}; \qquad \text{Global : } F = \frac{R^2/k}{(1-R^2)/(n-k-1)} \sim F_{k,\,n-k-1}.$$

$$\text{Conjoint } (q \text{ restrictions}) : F = \frac{(\text{RSS}_c - \text{RSS}_{nc})/q}{\text{RSS}_{nc}/(n-k-1)} \sim F_{q,\,n-k-1} \quad (q{=}1 \Rightarrow F = t^2).$$

Multicolinéarité et sélection de modèle

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \ (R_j^2 : \text{R}^2 \text{ de } X_j \text{ sur les autres}); \qquad \text{SE}(\hat{\beta}_j) \propto \sqrt{\text{VIF}_j}.$$

$$\text{AIC} = n \ln(\text{RSS}/n) + 2(k+1); \qquad \text{BIC} = n \ln(\text{RSS}/n) + (k+1) \ln n \quad \text{(minimiser)}.$$

C.2 --- Simple vs multiple : ce qui change

Aspect	Régression simple	Régression multiple
Coefficient	Pente marginale	Effet **partiel** (ceteris paribus)
Degrés de liberté	$n-2$	$n-k-1$
Ajustement	$R^2 = r^2$	$R^2 \neq r^2$; utiliser $\bar{R}^2$
Test global	$F = t^2$	F sur k pentes (ou conjoint)
Nouvelle hypothèse	—	Pas de colinéarité parfaite
Nouveau risque	—	Multicolinéarité, biais d'omission
Nouveaux outils	—	VIF, dummies, interactions

C.3 --- Carte de décision : quel outil pour quelle question ?

Question	Outil	Loi / repère
Effet propre d'un facteur ?	$t = \hat{\beta}_j / \text{SE}$	t_{n-k-1}
Le modèle explique-t-il Y ?	F global	$F_{k,n-k-1}$
Un groupe de variables est-il utile ?	F conjoint (q restrictions)	$F_{q,n-k-1}$
Comparer deux modèles ?	$\bar{R}^2$, AIC, BIC	Minimiser AIC/BIC
Régresseurs corrélés ?	VIF $= 1/(1-R_j^2)$	> 5 : problème
Variable qualitative ?	$m-1$ indicatrices	Écarts à la référence
Effet conditionnel ?	Interaction $X_1 X_2$	$\partial Y/\partial X_1 = \beta_1 + \beta_3 X_2$
Relation courbe ?	Terme X^2	$\partial Y/\partial X = \beta_1 + 2\beta_2 X$
Biais ou imprécision ?	Diagnostic biais/précision	Cf. tableau C.6

C.4 --- Glossaire bilingue

Français	Anglais	Repère
Régression multiple	Multiple regression	Plusieurs régresseurs
Effet partiel	Partial effect	Autres X constants
Toutes choses égales par ailleurs	Ceteris paribus	Contrôle statistique
Coefficient partiel	Partial coefficient	β_j
Biais de variable omise	Omitted variable bias	Z influence Y et corrélée à X_j
Variable de contrôle	Control variable	Neutralise une influence
Colinéarité parfaite	Perfect collinearity	$\mathbf{X}^\top\mathbf{X}$ non inversible
Multicolinéarité	Multicollinearity	Régresseurs corrélés
Facteur d'inflation de la variance	Variance inflation factor (VIF)	$1/(1-R_j^2)$
R^2 ajusté	Adjusted R^2	Pénalise k
Compromis biais–variance	Bias–variance tradeoff	Sous/sur-spécification
Test F conjoint	Joint F-test	Restrictions simultanées
Modèle contraint / non contraint	Restricted / unrestricted model	$\text{RSS}_c \geq \text{RSS}_{nc}$
Variable indicatrice	Dummy variable	$0/1$
Catégorie de référence	Reference / baseline category	Modalité omise
Trappe des indicatrices	Dummy variable trap	m dummies + ordonnée
Terme d'interaction	Interaction term	$X_1 X_2$
Terme quadratique	Quadratic term	X^2
Surajustement	Overfitting	Épouse le bruit
Parcimonie	Parsimony	Modèle le plus simple
Critère d'information	Information criterion	AIC, BIC
Validation hors échantillon	Out-of-sample validation	Test prédictif
Erreurs-types robustes	Robust standard errors	White, Newey–West

C.5 --- Méthode d'analyse en huit étapes

1. **Spécifier le modèle.** Choisir Y et les régresseurs *guidés par la théorie* ; inclure les variables pertinentes pour éviter le biais d'omission.
2. **Estimer par MCO.** $\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$; interpréter chaque $\hat{\beta}_j$ comme un effet *partiel*.
3. **Mesurer l'ajustement.** Utiliser le $\bar{R}^2$ (pas le R^2 brut) pour comparer des modèles ; se méfier d'un R^2 trop élevé (surajustement).
4. **Tester individuellement.** $t = \hat{\beta}_j/\text{SE} \sim t_{n-k-1}$; « non significatif » = pas d'apport *conditionnel* aux autres variables.
5. **Tester conjointement.** F global (H_0 : toutes pentes nulles) ; F conjoint pour un groupe de restrictions ($q = 1 \Rightarrow F = t^2$).
6. **Diagnostiquer la colinéarité.** Calculer les VIF (> 5 = alerte) et examiner la matrice de corrélation des régresseurs.
7. **Enrichir si besoin.** Variables qualitatives ($m-1$ dummies, éviter la trappe), interactions (X_1X_2), non-linéarités (X^2) — sans quitter la linéarité en β.
8. **Vérifier la robustesse et la spécification.** Résidus, Breusch–Pagan, Durbin–Watson, Jarque–Bera ; SE robustes (White/Newey–West) ; arbitrer le compromis biais–variance (AIC/BIC, hors échantillon).

C.6 --- Diagnostic : biais ou précision ?

Problème	Effet sur $\hat{\beta}$	Catégorie	Remède
Variable omise / endogénéité	**Biaisé**	Biais	Inclure / instruments
Hétéroscédasticité	Sans biais	Précision	SE de White
Autocorrélation	Sans biais	Précision	SE de Newey–West
Multicolinéarité	Sans biais	Précision	Retirer / combiner / données
Colinéarité parfaite	Non estimé	Identification	Retirer un régresseur

C.7 --- Les dix pièges classiques

À éviter absolument

(1) Interpréter $\hat{\beta}_j$ comme un effet marginal simple : c'est un effet *partiel* (autres X constants).
(2) Comparer des modèles par le R^2 brut (qui croît toujours) au lieu du $\bar{R}^2$.
(3) Croire que le biais de variable omise survient toujours : il faut *deux* conditions (Z influence Y *et* corrélée à X_j).
(4) Conclure qu'une variable est inutile sur un t faible, alors qu'elle est peut-être seulement *colinéaire*.
(5) Confondre biais (variable omise) et précision (hétéroscédasticité, autocorrélation, colinéarité).
(6) Tester un groupe de coefficients par des tests t séparés au lieu d'un test F conjoint.
(7) Tomber dans la trappe des indicatrices (m dummies + ordonnée $\Rightarrow$ colinéarité parfaite).
(8) Interpréter β_1 isolément en présence d'une interaction (β_1 = effet quand $X_2 = 0$).
(9) Maximiser le R^2 en empilant les régresseurs (surajustement, mauvaise prévision hors échantillon).
(10) Oublier les ddl du cadre multiple : $n-k-1$, pas $n-2$.

C.8 --- Astuces de calcul rapide

- **Degrés de liberté** : $n - k - 1$ pour tous les tests (k = nombre de régresseurs, hors ordonnée).
- **R^2 ajusté** : $\bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}$; il augmente ssi le régresseur ajouté a $|t| > 1$.
- **VIF** : $1/(1 - R_j^2)$; $R_j^2 = 0{,}9 \Rightarrow$ VIF $= 10 \Rightarrow$ SE $\times\sqrt{10} \approx 3{,}2$.
- $F = t^2$: uniquement pour une seule restriction ($q = 1$) — dont le cas $k = 1$ (régression simple).
- **F conjoint** : $\dfrac{(\text{RSS}_c - \text{RSS}_{nc})/q}{\text{RSS}_{nc}/(n-k-1)}$; toujours $\text{RSS}_c \geq \text{RSS}_{nc}$.
- **Dummies** : m modalités $\Rightarrow m - 1$ indicatrices ; le coefficient = écart à la référence.
- **Effet marginal avec interaction** : $\partial Y/\partial X_1 = \beta_1 + \beta_3 X_2$ (dépend de X_2).
- **Effet marginal quadratique** : $\partial Y/\partial X = \beta_1 + 2\beta_2 X$ (dépend de X).
- **Signe du biais d'omission** : signe de (effet de Z sur Y) $\times$ (corrélation Z, X_j).
- **Biais vs précision** : variable omise $\rightarrow$ biais ; hétéro./autocorr./colinéarité $\rightarrow$ précision (SE).

Partie D --- 200 questions à choix multiple

200 questions de style examen, par thème et de difficulté croissante. Une seule réponse correcte. Corrigé commenté en Partie E.

Thème 1 --- Le modèle multiple et l'effet partiel

Q1. Le modèle de régression multiple s'écrit :

- (a) $Y=\beta_0+\beta_1X_1+...+\beta_k\ X_k+\varepsilon$
- (b) $Y=\beta_0+\beta_1X$
- (c) $Y=\Sigma\beta_j\ X_j$ (sans ordonnée)
- (d) $Y=\beta_1X_1X_2$

Q2. Un coefficient β_j en régression multiple mesure :

- (a) l'effet total de X_j
- (b) l'effet de X_j, autres régresseurs constants
- (c) la corrélation X_j–Y
- (d) le R^2

Q3. « Toutes choses égales par ailleurs » signifie :

- (a) l'effet marginal simple
- (b) une corrélation
- (c) l'effet propre de X_j, les autres X neutralisés
- (d) une causalité prouvée

Q4. Le coefficient de X_j en multiple égale la pente simple de Y sur X_j :

- (a) toujours
- (b) jamais
- (c) si le R^2 est élevé
- (d) seulement si X_j est non corrélé aux autres régresseurs

Q5. β_0 représente :

- (a) $E[Y \mid \text{tous les } X = 0]$
- (b) la pente de X_1
- (c) la moyenne de Y
- (d) le résidu moyen

Q6. La régression multiple offre, vs une corrélation :

- (a) un R^2 garanti
- (b) le contrôle statistique (isoler un effet)
- (c) l'absence d'erreur
- (d) la causalité

Q7. Ajouter un régresseur corrélé peut :

- (a) ne jamais rien changer
- (b) toujours augmenter la pente
- (c) changer le signe d'un coefficient (Simpson)
- (d) annuler le R^2

Q8. Dans $R-R_f=\alpha+\beta_1 MKT+\beta_2 SMB+\beta_3 HML+\varepsilon$, β_2 est :

- (a) l'alpha
- (b) le R^2
- (c) la volatilité totale
- (d) l'exposition au facteur taille (à autres facteurs constants)

Q9. La « linéarité » de la régression multiple porte sur :

- (a) les paramètres β
- (b) les régresseurs X
- (c) la variable Y
- (d) les résidus

Q10. Un modèle à k régresseurs estime :

- (a) k paramètres
- (b) k+1 paramètres
- (c) k−1 paramètres
- (d) 2k paramètres

Q11. Les résidus MCO sont orthogonaux :

- (a) au seul X_1
- (b) à Y
- (c) à tous les régresseurs (et à l'ordonnée)
- (d) à aucun

Q12. La « droite » de régression avec deux régresseurs devient :

- (a) une courbe
- (b) un point
- (c) deux droites
- (d) un plan (hyperplan)

Q13. $\hat{Y}=3+1{,}5X_1+0{,}8X_2$. Effet d'une hausse d'une unité de X_1 (X_2 constant) :

- (a) +1,5 sur Y
- (b) +0,8
- (c) +2,3
- (d) +3

Q14. $\hat{Y}=3+1{,}5X_1+0{,}8X_2$. Prédiction pour $X_1=4$, $X_2=5$:

- (a) 10
- (b) 13
- (c) 9
- (d) 7,3

Q15. Omettre une variable pertinente NON corrélée aux régresseurs inclus :

- (a) les biaise fortement
- (b) change leur signe
- (c) ne biaise pas leurs coefficients
- (d) annule le modèle

Q16. Sans terme d'interaction, l'effet de X_1 dépend-il de X_2 ?

- (a) Oui
- (b) seulement si $X_2>0$
- (c) selon le R^2
- (d) Non (effet constant β_1)

Q17. La régression multiple sert l'attribution de performance en :

- (a) décomposant le rendement en contributions de facteurs
- (b) maximisant le R^2
- (c) supprimant l'alpha
- (d) ignorant les facteurs

Q18. Deux personnes de même expérience, l'une avec un an d'études de plus, diffèrent de :

- (a) β_exp
- (b) β_éduc sur le salaire
- (c) la somme des coefficients
- (d) zéro

Q19. Passer d'une régression simple à multiple permet surtout d'éviter :

- (a) l'hétéroscédasticité
- (b) la normalité
- (c) le biais de variable omise
- (d) le calcul du R^2

Q20. L'effet partiel diffère de l'effet marginal simple d'autant plus que :

- (a) n est grand
- (b) le R^2 est faible
- (c) α est petit
- (d) les régresseurs sont corrélés

Thème 2 --- Estimation MCO en dimension multiple

Q21. Les MCO en multiple minimisent :

- (a) la somme des carrés des résidus
- (b) la somme des résidus
- (c) le R^2
- (d) le nombre de régresseurs

Q22. L'estimateur MCO matriciel est :

- (a) $\beta = X^T y$
- (b) $\beta = (X^T X)^{-1} X^T y$
- (c) $\beta = (X^T X) X^T y$
- (d) $\beta = X^{-1} y$

Q23. $X^T X$ est inversible ssi :

- (a) $n > k$
- (b) le R^2 est élevé
- (c) absence de colinéarité parfaite
- (d) les erreurs sont normales

Q24. Combien d'équations normales pour k régresseurs ?

- (a) k
- (b) $k-1$
- (c) n
- (d) $k+1$

Q25. Que valent Σe_i et $\Sigma X_{1i} e_i$ en multiple (avec ordonnée) ?

- (a) 0 tous les deux
- (b) 1 et 0
- (c) n et 0
- (d) non nuls

Q26. L'hyperplan MCO passe par :

- (a) l'origine
- (b) le point moyen $(\bar{x}_1, \ldots, \bar{x}_k, \bar{y})$
- (c) $(0, \ldots, 0, \bar{y})$
- (d) aucun point fixe

Q27. Pourquoi une formule matricielle en multiple ?

- (a) par convention
- (b) pour simplifier
- (c) chaque coefficient dépend de tous les régresseurs et leurs corrélations

- (d) car k=1

Q28. Les valeurs ajustées matricielles sont :

- (a) $\hat{y}=X^{T}y$
- (b) $\hat{y}=y-e$ sans lien
- (c) $\hat{y}=\beta$
- (d) $\hat{y}=X(X^{T}X)^{-1}X^{T}y$ (projection)

Q29. Les résidus représentent géométriquement :

- (a) la composante de y orthogonale aux régresseurs
- (b) la projection de y
- (c) la moyenne de y
- (d) le vecteur des X

Q30. Un exemple de colinéarité parfaite est :

- (a) deux régresseurs peu corrélés
- (b) inclure X, 2X et une ordonnée
- (c) un seul régresseur
- (d) X et X^2

Q31. Ajouter un régresseur parfaitement corrélé à un autre :

- (a) améliore le R^2
- (b) réduit les SE
- (c) empêche l'estimation (non identifié)
- (d) est sans effet

Q32. Les coefficients multiples peuvent être instables à cause de :

- (a) la normalité
- (b) un grand n
- (c) l'homoscédasticité
- (d) la multicolinéarité imparfaite

Q33. Un coefficient négatif inattendu suggère d'abord :

- (a) multicolinéarité ou variable omise
- (b) un bon modèle
- (c) une causalité
- (d) un $R^2=1$

Q34. R−R_f=0,2 %+0,9·MKT+0,5·SMB. Prédiction si MKT=5 %, SMB=2 % :

- (a) 4,7 %
- (b) 5,7 %
- (c) 6,2 %

- (d) 1,1 %

Q35. Contribution du facteur SMB si SMB=2 % (β=0,5) :

- (a) 0,5 %
- (b) 2 %
- (c) 1 %
- (d) 2,5 %

Q36. Les MCO estiment :

- (a) la médiane
- (b) la variance
- (c) le mode
- (d) la moyenne conditionnelle $E[Y|X_1,...,X_k]$

Q37. Combien de degrés de liberté pour les résidus, n obs, k régresseurs ?

- (a) $n-k-1$
- (b) $n-2$
- (c) $n-k$
- (d) $n-1$

Q38. L'erreur-type de la régression en multiple est :

- (a) $\sqrt{(RSS/n)}$
- (b) $\sqrt{(RSS/(n-k-1))}$
- (c) $RSS/(n-k-1)$
- (d) $\sqrt{(TSS/n)}$

Q39. Le diviseur de la variance résiduelle est :

- (a) n
- (b) $n-1$
- (c) $n-k-1$
- (d) $k+1$

Q40. Une colonne de 1 dans X sert à :

- (a) normaliser Y
- (b) augmenter le R^2
- (c) réduire les SE
- (d) estimer l'ordonnée β_0

Thème 3 --- Gauss--Markov et biais de variable omise

Q41. L'hypothèse propre au cadre multiple est :

- (a) l'absence de colinéarité parfaite

- (b) l'homoscédasticité
- (c) l'exogénéité
- (d) la normalité

Q42. Sous Gauss–Markov, les MCO multiples sont :

- (a) biaisés
- (b) BLUE (sans biais, variance minimale)
- (c) non consistants
- (d) toujours normaux

Q43. Le biais de variable omise survient quand une variable Z omise :

- (a) est indépendante de tout
- (b) n'influence que ε
- (c) influence Y ET est corrélée à un régresseur inclus
- (d) égale un régresseur

Q44. Si Z (effet positif sur Y) est positivement corrélée à X_j, le biais sur β_j est :

- (a) négatif
- (b) nul
- (c) imprévisible
- (d) positif (surestimation)

Q45. Si Z (effet positif sur Y) est négativement corrélée à X_j, le biais est :

- (a) négatif (sous-estimation)
- (b) positif
- (c) nul
- (d) doublé

Q46. Omettre une variable pertinente NON corrélée aux régresseurs :

- (a) les biaise
- (b) ne biaise pas leurs coefficients
- (c) change leur signe
- (d) annule le R^2

Q47. L'exogénéité en multiple s'écrit :

- (a) $\mathrm{Var}(\varepsilon)=\sigma^2$
- (b) $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)=0$
- (c) $E[\varepsilon|X_1,\ldots,X_k]=0$
- (d) $E[X]=0$

Q48. On peut parfois prédire le sens du biais car :

- (a) il est toujours positif

- (b) il dépend de n
- (c) il est aléatoire
- (d) il vaut signe(effet de Z sur Y)×signe(corr Z,X_j)

Q49. La normalité des erreurs est requise pour :

- (a) les tests t/F exacts à petit n
- (b) l'absence de biais
- (c) le calcul de β
- (d) le R^2

Q50. Sous endogénéité (variable omise corrélée), β_j est :

- (a) sans biais
- (b) biaisé et non consistant
- (c) BLUE
- (d) efficace

Q51. Le remède au biais de variable omise est :

- (a) des SE robustes
- (b) un plus grand α
- (c) inclure la variable (ou un instrument/proxy)
- (d) le R^2 ajusté

Q52. Régresser un rendement sur le seul marché en omettant le facteur taille (fonds small cap) :

- (a) ne change rien
- (b) améliore la précision
- (c) annule l'alpha
- (d) biaise le bêta de marché

Q53. Endogénéité vs multicolinéarité sur β :

- (a) endogénéité biaise, multicolinéarité gonfle les SE
- (b) les deux biaisent
- (c) les deux gonflent les SE
- (d) aucun effet

Q54. Les MCO multiples sont « linéaires » car β est :

- (a) une fonction de β^2
- (b) une combinaison linéaire des Y_i
- (c) non linéaire en Y
- (d) indépendant de Y

Q55. Sous Gauss–Markov, les β_j sont consistants signifie :

- (a) β_j=β_j à n fini

- (b) variance constante
- (c) $\hat{\beta}_j \to \beta_j$ quand $n \to \infty$
- (d) biais constant

Q56. Contrôler pour un médiateur (canal de l'effet) peut :

- (a) toujours améliorer
- (b) être sans effet
- (c) augmenter le R^2
- (d) biaiser l'interprétation (bad control)

Q57. Omettre une variable pertinente affecte le R^2 en :

- (a) le réduisant
- (b) l'augmentant
- (c) le laissant identique
- (d) le rendant négatif

Q58. Si une variable pertinente n'est pas mesurable, on utilise :

- (a) rien
- (b) une variable proxy corrélée
- (c) une constante
- (d) le R^2

Q59. BLUE tient sous Gauss–Markov :

- (a) seulement si normal
- (b) seulement si $n>30$
- (c) sans hypothèse de normalité
- (d) jamais

Q60. $E[\hat{\beta}_j]=\beta_j$ signifie :

- (a) β_j est biaisé
- (b) β_j est constant
- (c) β_j est nul
- (d) β_j est un estimateur sans biais de l'effet partiel

Thème 4 --- R^2, R^2 ajusté et compromis biais--variance

Q61. Le R^2 brut, quand on ajoute un régresseur :

- (a) ne décroît jamais
- (b) décroît toujours
- (c) reste constant
- (d) devient négatif

Q62. Le R^2 ajusté augmente ssi le régresseur ajouté a :

- (a) un |t|>2
- (b) un |t|>1
- (c) un coefficient positif
- (d) un R^2>0,5

Q63. On compare des modèles de tailles différentes par :

- (a) le R^2 brut
- (b) la pente
- (c) le R^2 ajusté (ou AIC/BIC)
- (d) la corrélation

Q64. R^2=0,8, n=100, k=5. Le R^2 ajusté vaut ≈ :

- (a) 0,8
- (b) 0,82
- (c) 0,75
- (d) 0,79

Q65. Le R^2 ajusté peut-il être négatif ?

- (a) Oui (régresseurs quasi inutiles)
- (b) Non jamais
- (c) seulement si n<10
- (d) seulement si β_1<0

Q66. Le compromis biais–variance oppose :

- (a) biais et corrélation
- (b) sous-spécification (biais) et sur-spécification (variance)
- (c) R^2 et pente
- (d) α et β

Q67. Inclure des régresseurs inutiles :

- (a) biaise $\hat{\beta}$
- (b) améliore la précision
- (c) gonfle la variance sans biaiser β
- (d) est sans effet

Q68. Omettre une variable pertinente corrélée :

- (a) gonfle seulement les SE
- (b) est sans effet
- (c) améliore le $\bar{R}^2$
- (d) biaise $\hat{\beta}$ (biais d'omission)

Q69. R^2=0,75, TSS=400. ESS et RSS valent :

- (a) 300 et 100
- (b) 100 et 300
- (c) 200 et 200
- (d) 375 et 25

Q70. Deux modèles, R^2=0,80 (k=2) et 0,82 (k=8). On préfère a priori :

- (a) toujours k=8
- (b) celui au meilleur R^2 ajusté
- (c) toujours k=2
- (d) celui au plus grand R^2 brut

Q71. Un R^2=0,90 en multiple appelle :

- (a) une confiance totale
- (b) le rejet du modèle
- (c) la méfiance (surajustement possible)
- (d) aucune vérification

Q72. Le critère AIC vaut :

- (a) $n\cdot\ln(RSS/n)+(k+1)\ln n$
- (b) RSS/n
- (c) $1-RSS/TSS$
- (d) $n\cdot\ln(RSS/n)+2(k+1)$

Q73. Le BIC pénalise les paramètres :

- (a) plus que l'AIC (facteur ln n)
- (b) moins que l'AIC
- (c) autant que l'AIC
- (d) pas du tout

Q74. Le surajustement se caractérise par :

- (a) mauvais R^2 partout
- (b) excellent R^2 en échantillon, mauvaise prévision hors échantillon
- (c) bon hors échantillon
- (d) R^2 négatif

Q75. Trois protections contre le surajustement :

- (a) R^2 brut, n, α
- (b) seulement le R^2
- (c) R^2 ajusté, AIC/BIC, validation hors échantillon
- (d) seulement la théorie

Q76. Un régresseur ajouté avec |t|=1 exactement :

- (a) l'augmente
- (b) le diminue
- (c) le rend négatif
- (d) laisse le R^2 ajusté inchangé

Q77. Décider d'ajouter un groupe de régresseurs se fait par :

- (a) un test F conjoint (+ $\bar{R}^2$, hors échantillon)
- (b) le R^2 brut seul
- (c) le signe des coefficients
- (d) la valeur de $\bar{y}$

Q78. Un R^2 élevé garantit-il un bon modèle ?

- (a) Oui
- (b) Non (ni validité, ni causalité, ni prédiction)
- (c) Oui si n grand
- (d) Oui si k grand

Q79. Un modèle parcimonieux offre :

- (a) toujours un R^2 plus élevé
- (b) aucune erreur
- (c) coefficients stables, meilleure généralisation
- (d) plus de biais

Q80. Sur-spécifier introduit :

- (a) du biais, pas de variance
- (b) ni l'un ni l'autre
- (c) une causalité
- (d) de la variance (SE gonflées), pas de biais

Q81. Sous-spécifier introduit :

- (a) du biais (omission), pas de variance excessive
- (b) de la variance seulement
- (c) aucun effet
- (d) un $\bar{R}^2$ plus élevé

Q82. Le R^2 ajusté s'écrit :

- (a) $1-(1-R^2)(n-k-1)/(n-1)$
- (b) $1-(1-R^2)(n-1)/(n-k-1)$
- (c) $R^2/(k+1)$
- (d) $1-RSS/n$

Thème 5 --- Tests de significativité individuelle

Q83. Pour tester H_0:β_j=0, la statistique est :

- (a) z=β_j/σ
- (b) F=β_j
- (c) t=β_j/SE(β*j*) ~ *t*{n−k−1}
- (d) t ~ t_n

Q84. Combien de ddl pour tester un coefficient, n=50, k=4 ?

- (a) 46
- (b) 48
- (c) 50
- (d) 45

Q85. Chaque régresseur supplémentaire :

- (a) retire un degré de liberté
- (b) ajoute un ddl
- (c) ne change pas les ddl
- (d) double les ddl

Q86. « β_j non significatif » signifie :

- (a) X_j sans lien avec Y
- (b) X_j n'apporte pas d'info additionnelle vu les autres variables
- (c) β_j=0 exactement
- (d) le modèle est faux

Q87. Un coefficient significatif en simple devient non significatif en multiple à cause de :

- (a) un plus grand n
- (b) l'homoscédasticité
- (c) un régresseur corrélé ajouté (multicolinéarité)
- (d) la normalité

Q88. n=30, k=3. Valeur critique t bilatérale à 5 % ≈ :

- (a) 1,96
- (b) 2,262
- (c) 1,714
- (d) 2,056

Q89. Pour tester H_0:β_j=1 (et pas 0) :

- (a) t=(β_j−1)/SE(β_j)
- (b) t=β_j/SE
- (c) t=(β_j−0)/SE

- (d) t=1/SE

Q90. Un coefficient a t=1,2 (seuil ≈2,0). Conclusion :

- (a) rejeter
- (b) ne pas rejeter (pas d'effet propre significatif)
- (c) β_j≠0
- (d) accepter H_1

Q91. Un coefficient significatif (t=6) mais valant 0,01 est :

- (a) très important
- (b) non significatif
- (c) peu important (significativité ≠ matérialité)
- (d) biaisé

Q92. À β_j et SE fixés, |t| augmente quand :

- (a) n diminue
- (b) σ augmente
- (c) k augmente
- (d) n augmente

Q93. β_j=1,5, SE=0,3, n=40, k=3. IC à 95 % (t_{36}≈2,03) :

- (a) [0,891 ; 2,109]
- (b) [1,2 ; 1,8]
- (c) [0,9 ; 2,1] via ±1,96
- (d) [1,47 ; 1,53]

Q94. IC à 95 % pour β_j = [0,2 ; 0,8]. β_j diffère-t-il de 0 ?

- (a) Non
- (b) Oui (0 hors IC)
- (c) à la borne
- (d) indéterminé

Q95. β=−0,5 avec t=−3,0 s'interprète :

- (a) effet positif
- (b) non significatif
- (c) effet partiel négatif et significatif
- (d) biaisé

Q96. À côté du t d'un coefficient, rapporter :

- (a) seulement n
- (b) seulement α
- (c) le signe de $\bar{y}$

- (d) l'ampleur du coefficient et son IC

Q97. L'hétéroscédasticité invalide le test t d'un coefficient car :

- (a) elle fausse SE(β_j)
- (b) elle biaise β_j
- (c) elle annule le t
- (d) elle change $\bar{y}$

Q98. Tester un coefficient en unilatéral se justifie quand :

- (a) toujours
- (b) la théorie prédit un signe
- (c) jamais
- (d) si n est petit

Q99. Multiplier X_j par 100 (changement d'unité) affecte le t ?

- (a) Oui, ×100
- (b) Oui, ÷100
- (c) Non (β_j et SE divisés par 100)
- (d) le t devient nul

Q100. Mesurer l'apport d'un régresseur à l'ajustement :

- (a) regarder le R^2 brut seul
- (b) compter les observations
- (c) ignorer le t
- (d) comparer $\bar{R}^2$ avec/sans, ou tester son coefficient

Q101. La significativité d'un effet partiel est :

- (a) conditionnelle au modèle (aux autres régresseurs)
- (b) absolue
- (c) indépendante des autres variables
- (d) toujours vraie

Q102. La statistique t d'un coefficient partiel suit :

- (a) N(0,1) toujours
- (b) t_{n−k−1}
- (c) χ^2
- (d) F

Thème 6 --- Test F global et tests F conjoints

Q103. Le test F global teste :

- (a) $H_0 : \beta_0 = 0$

- (b) $H_0 : R^2=1$
- (c) $H_0 : \beta_1=...=\beta_k=0$
- (d) la normalité

Q104. La statistique F globale vaut :

- (a) $R^2/(1-R^2)$
- (b) $(1-R^2)/R^2$
- (c) $R^2 \cdot n$
- (d) $(R^2/k)/((1-R^2)/(n-k-1))$

Q105. Pour tester q restrictions simultanées :

- (a) F=((RSS_c−RSS_nc)/q)/(RSS_nc/(n−k−1))
- (b) F=RSS_nc/RSS_c
- (c) $F=t^2$
- (d) $F=R^2/k$

Q106. RSS_c=120, RSS_nc=100, q=2, n=50, k=5. F conjoint ≈ :

- (a) 2,2
- (b) 4,4
- (c) 10
- (d) 0,44

Q107. Le test F conjoint avec q=k donne :

- (a) le test t
- (b) F=1
- (c) le test F global
- (d) un test de normalité

Q108. Le test F conjoint avec q=1 donne :

- (a) le F global
- (b) F=0
- (c) un test χ^2
- (d) $F=t^2$ (équivaut au test t)

Q109. Le test F est :

- (a) unilatéral droit (rejet pour grandes valeurs)
- (b) bilatéral
- (c) unilatéral gauche
- (d) sans région de rejet

Q110. Tester $\beta_2=\beta_3=0$ par deux tests t séparés est incorrect car :

- (a) c'est trop lent

- (b) cela ignore leur corrélation et le risque global
- (c) le F est interdit
- (d) les t sont exacts

Q111. F global significatif mais aucun t significatif indique :

- (a) l'homoscédasticité
- (b) un R^2=1
- (c) de la multicolinéarité
- (d) β_0=0

Q112. Tester si un groupe de facteurs sectoriels est pertinent :

- (a) un test t par facteur
- (b) un test χ^2
- (c) le R^2 brut
- (d) un test F conjoint (q = taille du groupe)

Q113. F=8 sur (3,46), valeur critique ≈2,8. Décision :

- (a) rejet (modèle globalement significatif)
- (b) non-rejet
- (c) indéterminé
- (d) β_1=0

Q114. Le F répond à « le modèle explique-t-il Y ? » et les t à :

- (a) « quel est le R^2 ? »
- (b) « quelle variable a un effet propre ? »
- (c) « β_0 est-il nul ? »
- (d) « ε est-il normal ? »

Q115. n=50, k=4. Valeur critique F à 5 % pour le F global ≈ :

- (a) 1,96
- (b) 5,99
- (c) 2,58
- (d) 2,84 pour t

Q116. Le test F conjoint compare :

- (a) deux modèles non liés
- (b) un modèle à lui-même
- (c) des échantillons
- (d) deux modèles emboîtés (contraint niché dans non contraint)

Q117. Pourquoi RSS_c ≥ RSS_nc toujours ?

- (a) imposer des contraintes réduit la liberté d'ajustement

- (b) c'est faux
- (c) car RSS_c=0
- (d) car q=0

Q118. Un test F conjoint sur $\beta_2=\beta_3=0$ non significatif suggère :

- (a) les garder absolument
- (b) retirer X_2 et X_3 (pas d'apport conjoint)
- (c) un $R^2=1$
- (d) une causalité

Q119. Peut-on déduire le F global de la somme des t^2 individuels ?

- (a) Oui toujours
- (b) Oui si k=2
- (c) Non (le F tient compte des corrélations)
- (d) Oui si normal

Q120. Le test F conjoint peut-il tester $\beta_1=\beta_2$ (égalité) ?

- (a) Non, seulement des nullités
- (b) Non, jamais
- (c) Oui mais q=2
- (d) Oui (restriction linéaire, q=1)

Q121. Un F global significatif garantit-il un bon modèle ?

- (a) Non (peut être mal spécifié)
- (b) Oui
- (c) Oui si R^2 élevé
- (d) Oui si n grand

Q122. À R^2 fixé, le F global évolue avec n en :

- (a) diminuant
- (b) augmentant
- (c) restant constant
- (d) s'annulant

Q123. Le numérateur du F conjoint représente :

- (a) la variance totale
- (b) le R^2
- (c) le gain de RSS par restriction (perte d'ajustement/ddl)
- (d) $\hat{\beta}_1$

Q124. Le dénominateur du F conjoint représente :

- (a) celle du contraint

- (b) le R^2
- (c) TSS
- (d) la variance résiduelle du modèle non contraint

Q125. Le test F conjoint généralise :

- (a) le F global (q=k) et le test t (q=1, $F=t^2$)
- (b) seulement le test t
- (c) seulement le F global
- (d) aucun

Q126. Le test de restrictions linéaires imposées se lit sur :

- (a) la baisse du R^2 brut seul
- (b) l'augmentation de RSS du modèle contraint
- (c) le signe de β_0
- (d) la moyenne de Y

Thème 7 --- Multicolinéarité et VIF

Q127. La multicolinéarité désigne :

- (a) une corrélation X–Y forte
- (b) des erreurs corrélées
- (c) une forte corrélation entre régresseurs
- (d) un R^2 nul

Q128. En cas de colinéarité parfaite :

- (a) le R^2 est nul
- (b) les SE chutent
- (c) β est biaisé
- (d) X^TX n'est pas inversible (estimation impossible)

Q129. Le VIF du régresseur X_j vaut :

- (a) $1/(1-R_j^2)$
- (b) $1-R_j^2$
- (c) R_j^2
- (d) $\sqrt{R_j^2}$

Q130. $R_j^2=0{,}9$. Le VIF vaut :

- (a) 9
- (b) 10
- (c) 1,9
- (d) 0,1

Q131. Un VIF de 10 correspond à un facteur sur l'erreur-type de :

- (a) 10
- (b) 100
- (c) $\sqrt{10} \approx 3{,}2$
- (d) 1,0

Q132. Seuil d'alerte usuel du VIF :

- (a) VIF>1
- (b) VIF>0,5
- (c) VIF>100
- (d) VIF>5 (parfois 10)

Q133. La multicolinéarité imparfaite biaise-t-elle β ?

- (a) Non (β reste BLUE)
- (b) Oui
- (c) seulement à petit n
- (d) seulement si k>5

Q134. Trois symptômes de multicolinéarité :

- (a) R^2 nul, biais, SE nulles
- (b) coefficients instables, t faibles malgré F significatif, signes contre-intuitifs
- (c) tout significatif
- (d) aucun symptôme

Q135. Pourquoi la multicolinéarité rend-elle les coefficients imprécis ?

- (a) elle biaise β
- (b) elle réduit n
- (c) les données peinent à attribuer l'effet à un régresseur plutôt qu'à l'autre
- (d) elle change Y

Q136. La multicolinéarité est-elle gênante si le but est la prévision ?

- (a) toujours fatale
- (b) impossible
- (c) améliore la prévision
- (d) Souvent bénigne

Q137. Trois remèdes (objectif interprétation) :

- (a) retirer un régresseur, les combiner (PCA), plus de données
- (b) augmenter α, ignorer, biaiser
- (c) supprimer Y
- (d) aucun

Q138. L'erreur d'interprétation induite par la multicolinéarité :

- (a) surestimer le R^2
- (b) conclure qu'une variable est inutile sur un t faible
- (c) ignorer le F
- (d) biaiser β

Q139. Une simple corrélation par paire suffit-elle à détecter la multicolinéarité ?

- (a) Oui toujours
- (b) Oui si k=2
- (c) Non (elle peut impliquer plusieurs régresseurs)
- (d) Oui si normal

Q140. La PCA aide contre la colinéarité en :

- (a) supprimant Y
- (b) augmentant k
- (c) biaisant β
- (d) remplaçant les régresseurs par des composantes orthogonales

Q141. Colinéarité parfaite vs imparfaite :

- (a) parfaite = estimation impossible ; imparfaite = SE gonflées
- (b) identiques
- (c) parfaite = SE gonflées
- (d) imparfaite = impossible

Q142. Collecter plus de données atténue la multicolinéarité car :

- (a) cela supprime la corrélation
- (b) les SE décroissent ($\propto 1/\sqrt{n}$)
- (c) cela biaise β
- (d) cela augmente le R^2

Q143. Le VIF d'un régresseur non corrélé aux autres vaut :

- (a) 0
- (b) ∞
- (c) 1
- (d) 5

Q144. R_j^2=0,5. Le VIF vaut :

- (a) 1,5
- (b) 0,5
- (c) 4
- (d) 2

Q145. Diagnostiquer la multicolinéarité combine :

- (a) les VIF et la matrice de corrélation des régresseurs
- (b) le seul R^2
- (c) le seul test t
- (d) la moyenne de Y

Q146. Un signe de coefficient contre-intuitif peut venir de :

- (a) un bon ajustement
- (b) la multicolinéarité (ou variable omise)
- (c) un grand n
- (d) l'homoscédasticité

Thème 8 --- Variables indicatrices et interactions

Q147. Une variable indicatrice (dummy) vaut :

- (a) toujours 1
- (b) la moyenne de Y
- (c) 1 si une condition est remplie, 0 sinon
- (d) un nombre continu

Q148. Pour une variable à m modalités, on inclut :

- (a) m indicatrices
- (b) m+1 indicatrices
- (c) une seule
- (d) m−1 indicatrices (une référence)

Q149. La « dummy variable trap » est :

- (a) inclure les m indicatrices ET l'ordonnée (colinéarité parfaite)
- (b) oublier une dummy
- (c) utiliser trop peu de dummies
- (d) une erreur de calcul

Q150. Le coefficient d'une dummy $D \in \{0,1\}$ mesure :

- (a) la pente de X
- (b) l'écart moyen de Y entre D=1 et la référence
- (c) la moyenne de Y
- (d) le R^2

Q151. Éviter la trappe des dummies :

- (a) inclure toutes les dummies
- (b) retirer l'ordonnée toujours

- (c) omettre une modalité (référence), inclure m−1 indicatrices
- (d) doubler les dummies

Q152. Pour quatre secteurs (avec ordonnée), combien de dummies ?

- (a) 4
- (b) 5
- (c) 2
- (d) 3

Q153. Coefficient « secteur bancaire » = +1,2 % (réf : industrie). Interprétation :

- (a) les banques ont un rendement moyen supérieur de 1,2 % à l'industrie
- (b) les banques rendent 1,2 %
- (c) la pente vaut 1,2
- (d) le R^2=1,2

Q154. Changer la modalité de référence :

- (a) change tout
- (b) change les coefficients mais pas les prédictions ni le R^2
- (c) ne change rien
- (d) invalide le modèle

Q155. Tester un effet « avant/après » un événement se fait par :

- (a) deux régressions séparées
- (b) le R^2 brut
- (c) une dummy D=1 après l'événement
- (d) un test de normalité

Q156. Un terme d'interaction est :

- (a) la somme X_1+X_2
- (b) le carré ${X_1}^2$
- (c) le ratio X_1/X_2
- (d) le produit de deux régresseurs (X_1X_2)

Q157. Dans $Y=\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_1X_2+\varepsilon$, l'effet marginal de X_1 est :

- (a) $\beta_1+\beta_3X_2$
- (b) β_1
- (c) β_3
- (d) $\beta_1+\beta_2$

Q158. En présence de $\beta_3X_1X_2$, β_1 seul représente :

- (a) l'effet moyen de X_1
- (b) l'effet de X_1 lorsque X_2=0

- (c) l'effet total
- (d) zéro

Q159. Tester si l'effet d'un facteur diffère selon le régime de marché :

- (a) deux modèles
- (b) le R^2 brut
- (c) croiser une dummy de régime avec le facteur
- (d) un test χ^2

Q160. Modéliser une relation courbe entre X et Y :

- (a) retirer X
- (b) ajouter une dummy
- (c) augmenter n
- (d) ajouter X^2 ($Y=\beta_0+\beta_1X+\beta_2X^2+\varepsilon$)

Q161. Dans $Y=\beta_0+\beta_1X+\beta_2X^2+\varepsilon$, l'effet marginal de X est :

- (a) $\beta_1+2\beta_2X$
- (b) β_1
- (c) β_2
- (d) $2\beta_2$

Q162. Un terme quadratique capte la convexité prix–taux d'une obligation via :

- (a) β_1 seul
- (b) β_2 (courbure), au-delà de la duration β_1
- (c) le R^2
- (d) l'ordonnée

Q163. X^2 et X_1X_2 n'empêchent pas les MCO car :

- (a) ils sont ignorés
- (b) ils annulent le R^2
- (c) le modèle reste linéaire dans les paramètres β
- (d) ils biaisent $\hat{\beta}$

Q164. Tester la significativité d'une interaction :

- (a) test F global obligatoire
- (b) le R^2 brut
- (c) impossible
- (d) test t du coefficient d'interaction β_3

Q165. Permettre intercept ET pente différents entre deux groupes :

- (a) inclure la dummy ET son interaction avec X
- (b) une seule dummy

- (c) seulement X^2
- (d) deux modèles séparés

Q166. Dans $Y=\beta_0+\beta_1X+\beta_2D+\beta_3(D\cdot X)$, la pente pour D=1 est :

- (a) β_1
- (b) $\beta_1+\beta_3$
- (c) β_3
- (d) $\beta_1+\beta_2$

Q167. Traiter une variable ordinale (AAA>AA>A) :

- (a) toujours une seule dummy
- (b) jamais de dummy
- (c) par dummies (flexible) ou score numérique si l'ordre a un sens
- (d) en l'ignorant

Q168. En présence d'interaction X_1X_2, peut-on interpréter β_1 isolément ?

- (a) Oui, effet moyen
- (b) Oui toujours
- (c) Non, $\beta_1=0$
- (d) Non (effet de X_1 quand $X_2=0$)

Q169. Modéliser un effet changeant au-delà d'un seuil :

- (a) une dummy de seuil (éventuellement × X)
- (b) un terme log obligatoire
- (c) supprimer X
- (d) augmenter α

Q170. On centre parfois les variables avant une interaction pour :

- (a) augmenter le R^2
- (b) réduire la multicolinéarité et rendre β_1,β_2 interprétables au point moyen
- (c) biaiser β
- (d) supprimer l'interaction

Thème 9 --- Violations d'hypothèses et robustesse

Q171. La distinction unifiant le diagnostic est :

- (a) grand n vs petit n
- (b) R^2 vs pente
- (c) biais (variable omise) vs précision (hétéro., autocorr., colinéarité)
- (d) α vs β

Q172. L'hétéroscédasticité : effet et remède :

- (a) β biaisé ; instruments
- (b) aucun effet
- (c) supprimer des points
- (d) β sans biais, SE faussées ; SE de White

Q173. L'autocorrélation : effet et remède :

- (a) β sans biais, SE faussées ; SE de Newey–West
- (b) β biaisé ; White
- (c) augmente le R^2
- (d) annule β

Q174. Une variable omise corrélée : effet et remède :

- (a) SE faussées ; White
- (b) β biaisé ; inclure la variable (ou instrument)
- (c) aucun effet
- (d) Newey–West

Q175. L'hétéroscédasticité relève :

- (a) du biais
- (b) des deux
- (c) de la précision (SE), pas du biais
- (d) d'aucun

Q176. La variable omise relève :

- (a) de la précision
- (b) des deux
- (c) d'aucun
- (d) du biais (β faux), pas de la précision

Q177. On rapporte des SE robustes par défaut sur données financières car :

- (a) hétéroscédasticité et autocorrélation y sont la norme
- (b) les données sont normales
- (c) n est petit
- (d) β est biaisé

Q178. Les diagnostics propres au multiple sont :

- (a) seulement le graphe des résidus
- (b) les VIF et la matrice de corrélation des régresseurs
- (c) le seul R^2
- (d) aucun

Q179. En multiple, on trace les résidus contre :

- (a) Y observé
- (b) le temps toujours
- (c) les valeurs ajustées $\hat{Y}$ (et chaque régresseur)
- (d) α

Q180. Le test de Breusch–Pagan détecte :

- (a) l'autocorrélation
- (b) la non-normalité
- (c) la colinéarité
- (d) l'hétéroscédasticité

Q181. Durbin–Watson teste :

- (a) l'autocorrélation d'ordre 1 des résidus
- (b) l'hétéroscédasticité
- (c) la normalité
- (d) la colinéarité

Q182. Jarque–Bera sur les résidus sert à :

- (a) détecter la colinéarité
- (b) tester leur normalité (tests exacts à petit n)
- (c) mesurer le R^2
- (d) tester β_0

Q183. Utiliser des SE robustes modifie-t-il β ?

- (a) Oui, β change
- (b) Oui, le R^2 change
- (c) Non (mêmes MCO ; seules les SE changent)
- (d) Oui, k change

Q184. L'endogénéité est plus grave que l'hétéroscédasticité car :

- (a) elle est plus rare
- (b) elle augmente le R^2
- (c) elle est sans effet
- (d) elle biaise β (non corrigeable par SE robustes)

Q185. Un modèle avec hétéroscédasticité ET variable omise : que faire d'abord ?

- (a) inclure la variable omise (biais), puis SE robustes
- (b) seulement des SE robustes
- (c) ignorer les deux
- (d) supprimer des observations

Q186. Avant d'interpréter t et F en multiple, on examine :

- (a) seulement le R^2
- (b) résidus, VIF et matrice de corrélation
- (c) seulement n
- (d) rien

Thème 10 --- Spécification du modèle et synthèse

Q187. Le compromis biais–variance oppose :

- (a) biais et corrélation
- (b) R^2 et pente
- (c) sous-spécification (biais) et sur-spécification (variance)
- (d) α et β

Q188. L'AIC se définit par :

- (a) $n \cdot \ln(RSS/n) + (k+1) \ln n$
- (b) $1 - RSS/TSS$
- (c) RSS/n
- (d) $n \cdot \ln(RSS/n) + 2(k+1)$

Q189. Le BIC pénalise les paramètres :

- (a) plus que l'AIC (facteur $\ln n$)
- (b) moins que l'AIC
- (c) autant
- (d) pas du tout

Q190. Le premier principe de spécification est :

- (a) maximiser le R^2
- (b) la théorie d'abord (pertinence des variables)
- (c) le data mining
- (d) le plus de régresseurs

Q191. La parcimonie recommande :

- (a) le plus de variables
- (b) le plus grand R^2 brut
- (c) à pouvoir explicatif comparable, le modèle le plus simple
- (d) le plus complexe

Q192. Ne pas exclure une variable pertinente corrélée aux régresseurs car :

- (a) cela réduit le R^2
- (b) cela augmente les SE seulement
- (c) c'est sans effet
- (d) son omission biaise les coefficients inclus

Q193. Juger la qualité prédictive réelle d'un modèle par :

- (a) sa performance hors échantillon
- (b) son R^2 en échantillon
- (c) le nombre de régresseurs
- (d) son AIC seul

Q194. Maximiser le R^2 conduit au surajustement car :

- (a) le R^2 décroît
- (b) empiler les variables fait épouser le bruit
- (c) les SE chutent
- (d) β se stabilise

Q195. Le lien surajustement / tests multiples (chap. 6) :

- (a) aucun lien
- (b) les tests multiples aident
- (c) chercher le meilleur modèle sur les mêmes données produit des relations fallacieuses
- (d) le R^2 est fiable

Q196. Un modèle sur-paramétré en gestion des risques :

- (a) est toujours meilleur
- (b) élimine le risque
- (c) n'a pas d'erreur
- (d) donne une fausse confiance (sous-estimation possible du risque)

Q197. Décider d'ajouter un groupe de régresseurs :

- (a) test F conjoint (+ $\bar{R}^2$, AIC/BIC, hors échantillon)
- (b) R^2 brut seul
- (c) signe des coefficients
- (d) valeur de $\bar{y}$

Q198. Le signal typique de multicolinéarité est :

- (a) F et t tous nuls
- (b) F global significatif mais t individuels faibles
- (c) R^2=0
- (d) β biaisé

Q199. Le chapitre 8 prolonge le 7 en :

- (a) revenant à un régresseur
- (b) supprimant les tests
- (c) généralisant à plusieurs régresseurs (effets partiels, F conjoint, colinéarité, dummies)
- (d) ignorant le R^2

Q200. La régression multiple estime, en une phrase :

- (a) une seule pente
- (b) une corrélation
- (c) une causalité garantie
- (d) les effets partiels de plusieurs facteurs, testés individuellement (t) et conjointement (F)

Partie E --- Corrigé commenté des 200 QCM

Réponse correcte en gras suivie de l'explication. Distribution équilibrée (50 a, 50 b, 50 c, 50 d).

Thème 1 --- Le modèle multiple et l'effet partiel

Q1 — (a) $Y=\beta_0+\beta_1X_1+...+\beta_k X_k+\varepsilon$. k régresseurs, une ordonnée, un terme d'erreur.

Q2 — (b) l'effet de X_j, autres régresseurs constants. Effet partiel (ceteris paribus).

Q3 — (c) l'effet propre de X_j, les autres X neutralisés. Contrôle statistique.

Q4 — (d) seulement si X_j est non corrélé aux autres régresseurs. Sinon les deux diffèrent.

Q5 — (a) E[Y | tous les X = 0]. Souvent une extrapolation.

Q6 — (b) le contrôle statistique (isoler un effet). Neutraliser les autres variables.

Q7 — (c) changer le signe d'un coefficient (Simpson). Paradoxe de Simpson.

Q8 — (d) l'exposition au facteur taille (à autres facteurs constants). Sensibilité propre au facteur SMB.

Q9 — (a) les paramètres β. X^2, X_1X_2 restent estimables par MCO.

Q10 — (b) k+1 paramètres. k pentes + ordonnée.

Q11 — (c) à tous les régresseurs (et à l'ordonnée). Une équation normale par paramètre.

Q12 — (d) un plan (hyperplan). Passe par le point moyen.

Q13 — (a) +1,5 sur Y. Coefficient partiel de X_1.

Q14 — (b) 13. 3+6+4.

Q15 — (c) ne biaise pas leurs coefficients. Seule la précision baisse.

Q16 — (d) Non (effet constant β_1). Il faut X_1X_2 pour une dépendance.

Q17 — (a) décomposant le rendement en contributions de facteurs. β_j × facteur_j + alpha.

Q18 — (b) β_éduc sur le salaire. Effet partiel de l'éducation.

Q19 — (c) le biais de variable omise. Contrôler plusieurs influences.

Q20 — (d) les régresseurs sont corrélés. L'écart mesure le contrôle.

Thème 2 --- Estimation MCO en dimension multiple

Q21 — (a) la somme des carrés des résidus. Même principe qu'en simple.

Q22 — (b) $\hat{\beta}=(X^TX)^{-1}X^Ty$. Encapsule le système d'équations normales.

Q23 — (c) absence de colinéarité parfaite. Aucun régresseur combinaison exacte des autres.

Q24 — (d) k+1. Une par paramètre.

Q25 — (a) 0 tous les deux. Équations normales.

Q26 — (b) le point moyen $(\bar{x}_1,...,\bar{x}_k,\bar{y})$. Généralise $(\bar{x},\bar{y})$.

Q27 — (c) chaque coefficient dépend de tous les régresseurs et leurs corrélations. Système couplé.

Q28 — (d) $\hat{y}=X(X^TX)^{-1}X^Ty$ (projection). Projection de y sur l'espace des régresseurs.

Q29 — (a) la composante de y orthogonale aux régresseurs. $e=(I-H)y$.

Q30 — (b) inclure X, 2X et une ordonnée. 2X = combinaison exacte de X.

Q31 — (c) empêche l'estimation (non identifié). Colinéarité parfaite.

Q32 — (d) la multicolinéarité imparfaite. SE gonflées, sensibilité aux données.

Q33 — (a) multicolinéarité ou variable omise. Examiner VIF et spécification.

Q34 — (b) 5,7 %. 0,2+4,5+1.

Q35 — (c) 1 %. β×facteur.

Q36 — (d) la moyenne conditionnelle E[Y|X$_1$,...,X_k]. Meilleur prédicteur linéaire.

Q37 — (a) n−k−1. n moins k+1 paramètres.

Q38 — (b) $\sqrt{(RSS/(n-k-1))}$. Estime σ, n−k−1 ddl.

Q39 — (c) n−k−1. Degrés de liberté résiduels.

Q40 — (d) estimer l'ordonnée β_0. Terme constant du modèle.

Thème 3 --- Gauss--Markov et biais de variable omise

Q41 — (a) l'absence de colinéarité parfaite. Sinon X^TX non inversible.

Q42 — (b) BLUE (sans biais, variance minimale). Chaque β_j sans biais.

Q43 — (c) influence Y ET est corrélée à un régresseur inclus. Les deux conditions requises.

Q44 — (d) positif (surestimation). Produit des deux signes positif.

Q45 — (a) négatif (sous-estimation). Produit des signes négatif.

Q46 — (b) ne biaise pas leurs coefficients. Seule la précision baisse.

Q47 — (c) E[ε|X$_1$,...,X_k]=0. Erreur non liée à aucun régresseur.

Q48 — (d) il vaut signe(effet de Z sur Y)×signe(corr Z,X_j). La théorie renseigne les signes.

Q49 — (a) les tests t/F exacts à petit n. TCL à grand n.

Q50 — (b) biaisé et non consistant. Exogénéité violée.

Q51 — (c) inclure la variable (ou un instrument/proxy). Aucune correction de SE n'y remédie.

Q52 — (d) biaise le bêta de marché. Facteur taille corrélé, omis.

Q53 — (a) endogénéité biaise, multicolinéarité gonfle les SE. Biais vs précision.

Q54 — (b) une combinaison linéaire des Y$_i$. β=Wy.

Q55 — (c) β_j→β_j quand n→∞. Convergence.

Q56 — (d) biaiser l'interprétation (bad control). La théorie guide les contrôles.

Q57 — (a) le réduisant. Plus de variance inexpliquée.

Q58 — (b) une variable proxy corrélée. Réduit le biais d'omission.

Q59 — (c) sans hypothèse de normalité. H1–H5 suffisent.

Q60 — (d) β_j est un estimateur sans biais de l'effet partiel. Tombe juste en moyenne.

Thème 4 --- R^2, R^2 ajusté et compromis biais--variance

Q61 — (a) ne décroît jamais. Même un régresseur inutile.

Q62 — (b) un |t|>1. Sinon $\bar{R}^2$ décroît.

Q63 — (c) le R^2 ajusté (ou AIC/BIC). Le R^2 brut favorise le plus riche.

Q64 — (d) 0,79. 1−0,2×99/94.

Q65 — (a) Oui (régresseurs quasi inutiles). R^2 faible + k grand.

Q66 — (b) sous-spécification (biais) et sur-spécification (variance). Arbitrage central.

Q67 — (c) gonfle la variance sans biaiser β. SE plus grandes.

Q68 — (d) biaise β (biais d'omission). Sous-spécification.

Q69 — (a) 300 et 100. ESS=R^2·TSS.

Q70 — (b) celui au meilleur R^2 ajusté. $\bar{R}^2$ pénalise k.

Q71 — (c) la méfiance (surajustement possible). Vérifier $\bar{R}^2$ et hors échantillon.

Q72 — (d) n·ln(RSS/n)+2(k+1). Pénalise les paramètres ; minimiser.

Q73 — (a) plus que l'AIC (facteur ln n). Favorise la parcimonie.

Q74 — (b) excellent R^2 en échantillon, mauvaise prévision hors échantillon. Épouse le bruit.

Q75 — (c) R^2 ajusté, AIC/BIC, validation hors échantillon. Pénaliser la complexité.

Q76 — (d) laisse le R^2 ajusté inchangé. Point de bascule.

Q77 — (a) un test F conjoint (+ $\bar{R}^2$, hors échantillon). Comparaison de modèles emboîtés.

Q78 — (b) Non (ni validité, ni causalité, ni prédiction). Ajustement en échantillon seulement.

Q79 — (c) coefficients stables, meilleure généralisation. À pouvoir explicatif comparable.

Q80 — (d) de la variance (SE gonflées), pas de biais. Compromis biais–variance.

Q81 — (a) du biais (omission), pas de variance excessive. Variable omise.

Q82 — (b) 1−(1−R^2)(n−1)/(n−k−1). Pénalise le nombre de régresseurs.

Thème 5 --- Tests de significativité individuelle

Q83 — (c) t=β_j/SE(β*j*) ~ *t*{n−k−1}. Effet partiel significatif ?

Q84 — (d) 45. n−k−1.

Q85 — (a) retire un degré de liberté. ddl = n−k−1.

Q86 — (b) X_j n'apporte pas d'info additionnelle vu les autres variables. Significativité conditionnelle.

Q87 — (c) un régresseur corrélé ajouté (multicolinéarité). SE gonflée, t chute.

Q88 — (d) 2,056. $t_{26;0,975}$.

Q89 — (a) t=(β_j−1)/SE(β_j). On centre sur la valeur testée.

Q90 — (b) ne pas rejeter (pas d'effet propre significatif). |1,2|<2,0.

Q91 — (c) peu important (significativité ≠ matérialité). Ampleur négligeable.

Q92 — (d) n augmente. SE(β_j) décroît.

Q93 — (a) [0,891 ; 2,109]. 1,5±2,03×0,3.

Q94 — (b) Oui (0 hors IC). Dualité test–IC.

Q95 — (c) effet partiel négatif et significatif. À autres variables constantes.

Q96 — (d) l'ampleur du coefficient et son IC. Taille de l'effet partiel.

Q97 — (a) elle fausse SE(β_j). β correct, SE fausse ⟹ SE robustes.

Q98 — (b) la théorie prédit un signe. Latéralité fixée a priori.

Q99 — (c) Non (β_j et SE divisés par 100). Le rapport est inchangé.

Q100 — (d) comparer $\bar{R}^2$ avec/sans, ou tester son coefficient. t significatif = apport propre.

Q101 — (a) conditionnelle au modèle (aux autres régresseurs). Dépend de la spécification.

Q102 — (b) t_{n−k−1}. Student, n−k−1 ddl.

Thème 6 --- Test F global et tests F conjoints

Q103 — (c) $H_0 : \beta_1=...=\beta_k=0$. Aucun régresseur n'explique Y.

Q104 — (d) $(R^2/k)/((1-R^2)/(n-k-1))$. ~ F_{k,n−k−1}.

Q105 — (a) $F=((RSS_c-RSS_nc)/q)/(RSS_nc/(n-k-1))$. Comparaison contraint/non contraint.

Q106 — (b) 4,4. (20/2)/(100/44).

Q107 — (c) le test F global. Modèle contraint = $Y=\beta_0+\varepsilon$.

Q108 — (d) $F=t^2$ (équivaut au test t). Une seule restriction.

Q109 — (a) unilatéral droit (rejet pour grandes valeurs). F≥1 par construction.

Q110 — (b) cela ignore leur corrélation et le risque global. Le F conjoint est correct.

Q111 — (c) de la multicolinéarité. Régresseurs corrélés.

Q112 — (d) un test F conjoint (q = taille du groupe). Nullité simultanée des coefficients.

Q113 — (a) rejet (modèle globalement significatif). 8>2,8.

Q114 — (b) « quelle variable a un effet propre ? ». Global vs individuel.

Q115 — (c) 2,58. F(4,45).

Q116 — (d) deux modèles emboîtés (contraint niché dans non contraint). Perte d'ajustement des contraintes.

Q117 — (a) imposer des contraintes réduit la liberté d'ajustement. Le F mesure si la hausse est significative.

Q118 — (b) retirer X_2 et X_3 (pas d'apport conjoint). Non-rejet.

Q119 — (c) Non (le F tient compte des corrélations). $F=t^2$ seulement en simple.

Q120 — (d) Oui (restriction linéaire, q=1). Toute restriction linéaire.

Q121 — (a) Non (peut être mal spécifié). Au moins un régresseur compte, rien de plus.

Q122 — (b) augmentant. Facteur n−k−1.

Q123 — (c) le gain de RSS par restriction (perte d'ajustement/ddl). (RSS_c−RSS_nc)/q.

Q124 — (d) la variance résiduelle du modèle non contraint. RSS_nc/(n−k−1).

Q125 — (a) le F global (q=k) et le test t (q=1, $F=t^2$). Cadre unifié des restrictions.

Q126 — (b) l'augmentation de RSS du modèle contraint. Perte d'ajustement significative ?

Thème 7 --- Multicolinéarité et VIF

Q127 — (c) une forte corrélation entre régresseurs. Parfaite ou imparfaite.

Q128 — (d) X^TX n'est pas inversible (estimation impossible). Retirer un régresseur redondant.

Q129 — (a) $1/(1-R_j^2)$. $R_j^2 = R^2$ de X_j sur les autres.

Q130 — (b) 10. 1/(1−0,9).

Q131 — (c) $\sqrt{10} \approx 3{,}2$. SE $\propto \sqrt{\text{VIF}}$.

Q132 — (d) VIF>5 (parfois 10). VIF=1 : aucune corrélation.

Q133 — (a) Non (β reste BLUE). Elle gonfle les SE.

Q134 — (b) coefficients instables, t faibles malgré F significatif, signes contre-intuitifs. Perte de précision.

Q135 — (c) les données peinent à attribuer l'effet à un régresseur plutôt qu'à l'autre. Variables quasi confondues.

Q136 — (d) Souvent bénigne. Gêne surtout l'interprétation.

Q137 — (a) retirer un régresseur, les combiner (PCA), plus de données. Ne pas conclure hâtivement à l'inutilité.

Q138 — (b) conclure qu'une variable est inutile sur un t faible. Effet réel mais mal identifié.

Q139 — (c) Non (elle peut impliquer plusieurs régresseurs). Le VIF est plus fiable.

Q140 — (d) remplaçant les régresseurs par des composantes orthogonales. Au prix de l'interprétabilité.

Q141 — (a) parfaite = estimation impossible ; imparfaite = SE gonflées. Deux régimes distincts.

Q142 — (b) les SE décroissent ($\propto 1/\sqrt{n}$). Compense l'inflation.

Q143 — (c) 1. $R_j^2=0$.

Q144 — (d) 2. $1/(1-0{,}5)$.

Q145 — (a) les VIF et la matrice de corrélation des régresseurs. Complété par la comparaison F/t.

Q146 — (b) la multicolinéarité (ou variable omise). Effet mal identifié ou biais.

Thème 8 --- Variables indicatrices et interactions

Q147 — (c) 1 si une condition est remplie, 0 sinon. Information qualitative.

Q148 — (d) m−1 indicatrices (une référence). Sinon colinéarité parfaite.

Q149 — (a) inclure les m indicatrices ET l'ordonnée (colinéarité parfaite). Somme des dummies = 1.

Q150 — (b) l'écart moyen de Y entre D=1 et la référence. À autres variables constantes.

Q151 — (c) omettre une modalité (référence), inclure m−1 indicatrices. Écarts à la référence.

Q152 — (d) 3. 4−1.

Q153 — (a) les banques ont un rendement moyen supérieur de 1,2 % à l'industrie. Écart à la référence.

Q154 — (b) change les coefficients mais pas les prédictions ni le R^2. Choix conventionnel.

Q155 — (c) une dummy D=1 après l'événement. Coefficient = changement moyen.

Q156 — (d) le produit de deux régresseurs (X_1X_2). Effet de X_1 dépendant de X_2.

Q157 — (a) $\beta_1+\beta_3X_2$. Dépend de X_2.

Q158 — (b) l'effet de X_1 lorsque $X_2=0$. Piège d'interprétation.

Q159 — (c) croiser une dummy de régime avec le facteur. Coefficient d'interaction = modulation.

Q160 — (d) ajouter X^2 ($Y=\beta_0+\beta_1X+\beta_2X^2+\varepsilon$). Linéaire en β, non linéaire en X.

Q161 — (a) $\beta_1+2\beta_2X$. Dépend du niveau de X.

Q162 — (b) β_2 (courbure), au-delà de la duration β_1. $Prix=\beta_0+\beta_1 taux+\beta_2 taux^2$.

Q163 — (c) le modèle reste linéaire dans les paramètres β. Nouveaux régresseurs.

Q164 — (d) test t du coefficient d'interaction β_3. β_3 significatif = dépendance.

Q165 — (a) inclure la dummy ET son interaction avec X. $Y=\beta_0+\beta_1X+\beta_2D+\beta_3(D\cdot X)$.

Q166 — (b) $\beta_1+\beta_3$. β_3 = différence de pente.

Q167 — (c) par dummies (flexible) ou score numérique si l'ordre a un sens. Dummies plus flexibles.

Q168 — (d) Non (effet de X_1 quand $X_2=0$). Interpréter les coefficients ensemble.

Q169 — (a) une dummy de seuil (éventuellement × X). Reste linéaire en β.

Q170 — (b) réduire la multicolinéarité et rendre β_1,β_2 interprétables au point moyen. Effets « au centre » plutôt qu'à 0.

Thème 9 --- Violations d'hypothèses et robustesse

Q171 — (c) biais (variable omise) vs précision (hétéro., autocorr., colinéarité). Deux catégories de problèmes.

Q172 — (d) β sans biais, SE faussées ; SE de White. Précision.

Q173 — (a) β sans biais, SE faussées ; SE de Newey–West. HAC, robustes aussi à l'hétéroscédasticité.

Q174 — (b) β biaisé ; inclure la variable (ou instrument). Biais, pas précision.

Q175 — (c) de la précision (SE), pas du biais. SE robustes suffisent.

Q176 — (d) du biais (β faux), pas de la précision. Inclure la variable.

Q177 — (a) hétéroscédasticité et autocorrélation y sont la norme. Protéger l'inférence.

Q178 — (b) les VIF et la matrice de corrélation des régresseurs. En plus des tests du cas simple.

Q179 — (c) les valeurs ajustées $\hat{Y}$ (et chaque régresseur). Nuage sans structure = OK.

Q180 — (d) l'hétéroscédasticité. H_0 : variance constante.

Q181 — (a) l'autocorrélation d'ordre 1 des résidus. ≈ 2 : pas d'autocorrélation.

Q182 — (b) tester leur normalité (tests exacts à petit n). TCL à grand n.

Q183 — (c) Non (mêmes MCO ; seules les SE changent). t, p, IC recalculés.

Q184 — (d) elle biaise β (non corrigeable par SE robustes). Biais vs précision.

Q185 — (a) inclure la variable omise (biais), puis SE robustes. Le biais prime.

Q186 — (b) résidus, VIF et matrice de corrélation. Sinon tests trompeurs.

Thème 10 --- Spécification du modèle et synthèse

Q187 — (c) sous-spécification (biais) et sur-spécification (variance). Arbitrage de spécification.

Q188 — (d) $n \cdot \ln(RSS/n) + 2(k+1)$. Minimiser ; pénalise k.

Q189 — (a) plus que l'AIC (facteur ln n). Favorise la parcimonie.

Q190 — (b) la théorie d'abord (pertinence des variables). Éviter la pêche aveugle.

Q191 — (c) à pouvoir explicatif comparable, le modèle le plus simple. Meilleure généralisation.

Q192 — (d) son omission biaise les coefficients inclus. Biais d'omission.

Q193 — (a) sa performance hors échantillon. Validation croisée.

Q194 — (b) empiler les variables fait épouser le bruit. Excellent en échantillon, mauvais hors.

Q195 — (c) chercher le meilleur modèle sur les mêmes données produit des relations fallacieuses. Faux positifs.

Q196 — (d) donne une fausse confiance (sous-estimation possible du risque). Coefficients instables.

Q197 — (a) test F conjoint (+ $\bar{R}^2$, AIC/BIC, hors échantillon). Modèles emboîtés.

Q198 — (b) F global significatif mais t individuels faibles. Régresseurs corrélés.

Q199 — (c) généralisant à plusieurs régresseurs (effets partiels, F conjoint, colinéarité, dummies). Cadre multifactoriel.

Q200 — (d) les effets partiels de plusieurs facteurs, testés individuellement (t) et conjointement (F). Socle des modèles à facteurs.

Grille récapitulative des réponses

1:a · 2:b · 3:c · 4:d · 5:a · 6:b · 7:c · 8:d · 9:a · 10:b

11:c · 12:d · 13:a · 14:b · 15:c · 16:d · 17:a · 18:b · 19:c · 20:d

21:a · 22:b · 23:c · 24:d · 25:a · 26:b · 27:c · 28:d · 29:a · 30:b

31:c · 32:d · 33:a · 34:b · 35:c · 36:d · 37:a · 38:b · 39:c · 40:d

41:a · 42:b · 43:c · 44:d · 45:a · 46:b · 47:c · 48:d · 49:a · 50:b

51:c · 52:d · 53:a · 54:b · 55:c · 56:d · 57:a · 58:b · 59:c · 60:d

61:a · 62:b · 63:c · 64:d · 65:a · 66:b · 67:c · 68:d · 69:a · 70:b

71:c · 72:d · 73:a · 74:b · 75:c · 76:d · 77:a · 78:b · 79:c · 80:d

81:a · 82:b · 83:c · 84:d · 85:a · 86:b · 87:c · 88:d · 89:a · 90:b

91:c · 92:d · 93:a · 94:b · 95:c · 96:d · 97:a · 98:b · 99:c · 100:d

101:a · 102:b · 103:c · 104:d · 105:a · 106:b · 107:c · 108:d · 109:a · 110:b

111:c · 112:d · 113:a · 114:b · 115:c · 116:d · 117:a · 118:b · 119:c · 120:d

121:a · 122:b · 123:c · 124:d · 125:a · 126:b · 127:c · 128:d · 129:a · 130:b

131:c · 132:d · 133:a · 134:b · 135:c · 136:d · 137:a · 138:b · 139:c · 140:d

141:a · 142:b · 143:c · 144:d · 145:a · 146:b · 147:c · 148:d · 149:a · 150:b

151:c · 152:d · 153:a · 154:b · 155:c · 156:d · 157:a · 158:b · 159:c · 160:d

161:a · 162:b · 163:c · 164:d · 165:a · 166:b · 167:c · 168:d · 169:a · 170:b

171:c · 172:d · 173:a · 174:b · 175:c · 176:d · 177:a · 178:b · 179:c · 180:d

181:a · 182:b · 183:c · 184:d · 185:a · 186:b · 187:c · 188:d · 189:a · 190:b

191:c · 192:d · 193:a · 194:b · 195:c · 196:d · 197:a · 198:b · 199:c · 200:d