FRM® Part I · Quantitative Analysis

Book 2 · Chapitre 9

Regression Diagnostics

Les diagnostics de la régression

Vérifier, détecter, corriger : la fiabilité du modèle

Approfondissement quantitatif complet

Cours illustré · définitions · démonstrations · 200 études de cas · conseils méthodologiques · 200 QCM commentés

Support d'étude — questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel — pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
9.1 — Pourquoi diagnostiquer : hypothèses et conséquences de leur violation . . . 3
9.2 — L'hétéroscédasticité : nature, conséquences et détection . . . 4
9.3 — Les remèdes à l'hétéroscédasticité . . . 4
9.4 — La multicolinéarité approfondie . . . 5
9.5 — Les erreurs de spécification . . . 6
9.6 — Points aberrants, de levier et influents . . . 6
9.7 — La normalité des résidus . . . 7
9.8 — L'autocorrélation des résidus . . . 8
9.9 — Stabilité des coefficients et ruptures structurelles . . . 8
9.10 — Compromis biais–variance et sélection de modèle . . . 9
9.11 — Un protocole de diagnostic complet . . . 10
9.12 — Synthèse : la carte des diagnostics . . . 10

Partie B — 200 études de cas pratiques **12**
Bloc 1 — Pourquoi diagnostiquer : hypothèses et enjeux . . . 12
Bloc 2 — Hétéroscédasticité : nature et détection . . . 13
Bloc 3 — Remèdes à l'hétéroscédasticité et multicolinéarité . . . 15
Bloc 4 — Erreurs de spécification et test RESET . . . 16
Bloc 5 — Points aberrants, de levier et influents . . . 18
Bloc 6 — Normalité des résidus . . . 19
Bloc 7 — Autocorrélation des résidus . . . 20
Bloc 8 — Stabilité des coefficients et test de Chow . . . 22
Bloc 9 — Compromis biais–variance et sélection de modèle . . . 24
Bloc 10 — Protocole de diagnostic et synthèse . . . 25

Partie C — Méthodologie, formulaire et astuces **27**
C.1 — Formulaire des diagnostics . . . 27
C.2 — Le tableau maître : biais vs efficacité vs robustesse . . . 27
C.3 — Carte de décision : quel symptôme, quel diagnostic ? . . . 28
C.4 — Glossaire bilingue . . . 28
C.5 — Le protocole de diagnostic en sept contrôles . . . 29
C.6 — Les dix pièges classiques . . . 29
C.7 — Astuces de calcul rapide . . . 30

Partie D — 200 questions à choix multiple **31**
Thème 1 — Pourquoi diagnostiquer : hypothèses et enjeux . . . 31
Thème 2 — Hétéroscédasticité : nature et détection . . . 34
Thème 3 — Remèdes à l'hétéroscédasticité et multicolinéarité . . . 36
Thème 4 — Erreurs de spécification et test RESET . . . 40
Thème 5 — Points aberrants, de levier et influents . . . 43
Thème 6 — Normalité des résidus . . . 46
Thème 7 — Autocorrélation des résidus . . . 48
Thème 8 — Stabilité des coefficients et test de Chow . . . 51
Thème 9 — Compromis biais–variance et sélection de modèle . . . 55
Thème 10 — Protocole de diagnostic et synthèse . . . 57

Partie E — Corrigé commenté des 200 QCM **61**
Thème 1 — Pourquoi diagnostiquer : hypothèses et enjeux . . . 61
Thème 2 — Hétéroscédasticité : nature et détection . . . 61
Thème 3 — Remèdes à l'hétéroscédasticité et multicolinéarité . . . 62
Thème 4 — Erreurs de spécification et test RESET . . . 63
Thème 5 — Points aberrants, de levier et influents . . . 63
Thème 6 — Normalité des résidus . . . 64

Thème 7 — Autocorrélation des résidus 64
Thème 8 — Stabilité des coefficients et test de Chow 65
Thème 9 — Compromis biais–variance et sélection de modèle 66
Thème 10 — Protocole de diagnostic et synthèse 66
Grille récapitulative des réponses 67

Partie A --- Cours approfondi

Les chapitres 7 et 8 ont estimé des régressions et posé leurs hypothèses. Le chapitre 9 pose la question qui décide de leur fiabilité : **ces hypothèses tiennent-elles vraiment ?** Un modèle mal diagnostiqué peut afficher un R^2 flatteur et des t éclatants tout en étant profondément trompeur — erreurs-types faussées, coefficients biaisés, prévisions dictées par une poignée de points aberrants. Les **diagnostics de régression** sont l'ensemble des outils qui débusquent ces défaillances : c'est la différence entre un analyste qui *lit une sortie* et un analyste qui *sait si on peut lui faire confiance*.

Le chapitre s'organise autour des trois grandes menaces. **L'hétéroscédasticité** et **l'autocorrélation** faussent les erreurs-types sans biaiser les coefficients — problèmes de *précision*, corrigés par des erreurs-types robustes. **Les erreurs de spécification** (variable omise, mauvaise forme fonctionnelle) et **l'endogénéité** biaisent les coefficients eux-mêmes — problèmes de *biais*, corrigés par un meilleur modèle. **Les points aberrants et influents** peuvent dominer l'estimation à eux seuls — un problème de *robustesse*, traité par des mesures d'influence. À cela s'ajoutent la multicolinéarité (précision des coefficients), la non-normalité des résidus (validité des tests) et l'instabilité des paramètres (ruptures structurelles). Pour chacun : sa nature, ses conséquences, sa *détection* formelle, son *remède*.

La règle d'or du diagnostic

Une régression ne se juge jamais sur son seul R^2. Avant d'interpréter le moindre coefficient, l'analyste **examine les résidus** : leur dispersion (hétéroscédasticité ?), leur structure (mauvaise forme ?), leur distribution (normalité ?), leur dépendance (autocorrélation ?), et l'influence de chaque observation (points aberrants ?). Le diagnostic n'est pas une formalité de fin de parcours — c'est la condition de validité de toute inférence. Un modèle non diagnostiqué est un modèle dont on ignore s'il ment.

9.1 --- Pourquoi diagnostiquer : hypothèses et conséquences de leur violation

Chaque hypothèse de Gauss–Markov protège une propriété précise ; savoir laquelle est en jeu oriente tout le diagnostic.

Cartographie des hypothèses et de leurs enjeux

Les hypothèses classiques et la propriété qu'elles garantissent : **exogénéité** ($\mathbb{E}[\varepsilon \mid X] = 0$) $\rightarrow$ **absence de biais** ; **homoscédasticité** et **absence d'autocorrélation** $\rightarrow$ **efficacité** (variance minimale, erreurs-types correctes) ; **normalité des erreurs** $\rightarrow$ **validité exacte des tests** (t, F) à échantillon fini ; **absence de colinéarité parfaite** $\rightarrow$ **identifiabilité** des coefficients.

La distinction cardinale : biais vs efficacité

Violation de l'**exogénéité** $\Rightarrow$ $\hat{\beta}$ **biaisé** (le coefficient lui-même est faux).

Violation de l'**homoscédasticité / autocorrélation** $\Rightarrow$ $\hat{\beta}$ sans biais, mais SE **faussées**.

Pourquoi cette distinction commande tout

Ranger chaque problème dans la bonne catégorie détermine le remède. Un problème de **biais** (variable omise, endogénéité, mauvaise forme) exige de *changer le modèle* : aucune correction d'erreur-type ne rétablira un coefficient faux. Un problème d'**efficacité** (hétéroscédasticité, autocorrélation) se corrige par des *erreurs-types robustes* : le coefficient est bon, seule son incertitude était mal mesurée. Confondre les deux — appliquer des SE robustes à un problème de variable omise — laisse le biais intact et donne une fausse assurance. Tout le chapitre 9 est, au fond, l'art de ce diagnostic différentiel.

Le rôle central des résidus

Les erreurs ε_i sont inobservables, mais les **résidus** $e_i = Y_i - \hat{Y}_i$ en sont l'image empirique. Presque tous les diagnostics reposent sur eux : leur *ampleur* selon X révèle l'hétéroscédasticité, leur *structure* révèle une mauvaise forme fonctionnelle, leur *distribution* révèle la non-normalité, leur *corrélation* révèle l'autocorrélation, et leur combinaison avec le levier révèle les points influents. Savoir lire un graphe de résidus est la compétence diagnostique fondamentale.

9.2 --- L'hétéroscédasticité : nature, conséquences et détection

Première menace, omniprésente en finance : la variance des erreurs qui n'est pas constante.

Hétéroscédasticité

Il y a **hétéroscédasticité** lorsque la variance des erreurs dépend des régresseurs (ou de l'observation) : $\text{Var}(\varepsilon_i \mid X_i) = \sigma_i^2$ non constante, par opposition à l'**homoscédasticité** $\text{Var}(\varepsilon_i) = \sigma^2$.

Conséquences

$\hat{\beta}_{\text{MCO}}$ reste **sans biais** et consistant, mais **n'est plus BLUE** (efficacité perdue).

$\text{SE}(\hat{\beta})$ classiques sont **biaisées** $\Rightarrow$ tests t et F invalides (souvent trop optimistes).

Pourquoi l'hétéroscédasticité est la norme en finance

Les données financières la produisent presque systématiquement : la **volatilité varie dans le temps** (clustering — périodes calmes et agitées alternent), la dispersion des rendements croît avec le niveau de risque, les erreurs de modèles de prix augmentent avec la taille des positions. Conséquence pratique : sur données financières, on suppose l'hétéroscédasticité *par défaut* et l'on rapporte des erreurs-types robustes. L'ignorer conduit à surestimer la significativité (SE sous-estimées) et à conclure à tort qu'un facteur est pertinent.

Détecter l'hétéroscédasticité

Deux approches complémentaires. **Graphique** : tracer les résidus (ou leur carré) contre les valeurs ajustées $\hat{Y}$ ou chaque régresseur ; un motif en **entonnoir** (dispersion croissante ou décroissante) signale l'hétéroscédasticité, un nuage sans structure la dément. **Tests formels** : le test de **Breusch–Pagan** régresse les résidus au carré sur les régresseurs (H_0 : variance constante) ; le test de **White** est plus général (inclut carrés et produits croisés des régresseurs, ne présuppose aucune forme particulière d'hétéroscédasticité). Un rejet de H_0 confirme l'hétéroscédasticité et impose des SE robustes.

9.3 --- Les remèdes à l'hétéroscédasticité

Une fois l'hétéroscédasticité détectée, deux stratégies s'offrent : corriger les erreurs-types, ou re-pondérer l'estimation.

Erreurs-types robustes de White

Les **erreurs-types robustes à l'hétéroscédasticité** (White, ou HC — *heteroskedasticity-consistent*) recalculent la variance des estimateurs sans supposer σ^2 constante. Elles laissent $\hat{\beta}_{\text{MCO}}$ **inchangé** et ne corrigent que les SE (et donc les t, p-valeurs, IC).

Moindres carrés pondérés (WLS/MCG)

Les **moindres carrés pondérés** (WLS) pondèrent chaque observation par l'inverse de sa variance $1/\sigma_i^2$, redonnant plus de poids aux observations les plus précises. Si la forme de l'hétéroscédasticité est connue, WLS est **efficace** (restaure BLUE) ; les MCG (moindres carrés généralisés) en sont la version générale.

White vs WLS — le choix pratique

White (HC) : $\hat{\beta}$ inchangé, SE corrigées $\Rightarrow$ simple, robuste, aucun modèle de σ_i^2 requis.

WLS/MCG : $\hat{\beta}$ ré-estimé, efficace $\Rightarrow$ exige de *connaître* la forme de σ_i^2 (risqué si mal spécifiée).

Pourquoi White domine en pratique

Les erreurs-types de White sont devenues le standard car elles ne demandent **aucune hypothèse** sur la forme de l'hétéroscédasticité — on les rapporte quasi systématiquement sur données financières. WLS peut être plus efficace, mais suppose de *connaître* σ_i^2 : une pondération fondée sur une forme erronée peut aggraver le problème. La règle pragmatique : quand l'objectif est une **inférence valide** (des t fiables), White suffit et ne coûte rien ; quand l'efficacité est cruciale et la structure d'hétéroscédasticité bien comprise, WLS se justifie. Dans les deux cas, le message clé est que $\hat{\beta}_{\text{MCO}}$ restait sans biais — le problème n'a jamais été le coefficient, seulement son erreur-type.

9.4 --- La multicolinéarité approfondie

Introduite au chapitre 8, la multicolinéarité mérite ici un traitement diagnostique complet : mesures, seuils, remèdes.

Multicolinéarité et facteur d'inflation de la variance

La **multicolinéarité** est une forte corrélation linéaire entre régresseurs. On la mesure par le **facteur d'inflation de la variance** :

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

où R_j^2 est le coefficient de détermination de la régression de X_j sur *tous les autres* régresseurs. La **tolérance** est son inverse : $\text{Tol}_j = 1 - R_j^2$.

Seuils et effet sur la précision

$\text{VIF} = 1$: orthogonalité; $\text{VIF} > 5$: alerte; $\text{VIF} > 10$: multicolinéarité sévère.

$\text{SE}(\hat{\beta}_j)$ est multipliée par $\sqrt{\text{VIF}_j}$ par rapport au cas orthogonal.

Le nombre de conditionnement

Au-delà du VIF (qui examine chaque régresseur), le **nombre de conditionnement** κ diagnostique la colinéarité *globale* de la matrice des régresseurs : c'est la racine du rapport de la plus grande à la plus petite valeur propre de $\mathbf{X}^\top\mathbf{X}$. Un κ supérieur à 30 (parfois 20) signale une multicolinéarité problématique impliquant potentiellement *plusieurs* régresseurs à la fois — ce qu'une inspection par paires manquerait. VIF et nombre de conditionnement sont complémentaires : l'un local, l'autre global.

Conséquences et remèdes — rappel structuré

La multicolinéarité imparfaite **ne biaise pas** $\hat{\beta}$ (les MCO restent BLUE) mais **gonfle les erreurs-types**, d'où le triple symptôme : coefficients instables, t individuels faibles malgré un F global significatif, signes parfois contre-intuitifs. Remèdes selon l'objectif : pour la **prévision**, souvent ignorer (le modèle prédit bien) ; pour l'**interprétation**, retirer un régresseur redondant, les combiner (indice, composantes principales), collecter plus de données, ou recourir à des méthodes régularisées (ridge). L'erreur à éviter reste de déclarer une variable inutile sur la seule foi d'un t faible — son effet est peut-être réel, seulement mal identifié faute de variation indépendante.

9.5 --- Les erreurs de spécification

Une régression peut satisfaire toutes les hypothèses de variance et pourtant être fausse par sa forme même : mauvaise fonction, variable manquante.

Erreurs de spécification

Une **erreur de spécification** survient quand le modèle estimé diffère du vrai processus générateur : **variable omise** (régresseur pertinent absent), **variable superflue** (régresseur inutile inclus), ou **forme fonctionnelle incorrecte** (relation supposée linéaire alors qu'elle est courbe, interaction ignorée).

Conséquences selon le type

Variable omise (pertinente, corrélée) $\Rightarrow$ $\hat{\beta}$ **biaisé** (biais d'omission).

Variable superflue $\Rightarrow$ $\hat{\beta}$ sans biais mais **variance accrue** (perte d'efficacité).

Forme incorrecte $\Rightarrow$ $\hat{\beta}$ biaisé et interprétation faussée.

Le test RESET de Ramsey

Le **test RESET** (*Regression Equation Specification Error Test*) détecte les erreurs de forme fonctionnelle. Le principe : ré-estimer le modèle en ajoutant des **puissances des valeurs ajustées** ($\hat{Y}^2$, $\hat{Y}^3$) comme régresseurs supplémentaires ; si ces termes sont *conjointement significatifs* (test F), c'est que le modèle linéaire capture mal la relation — une forme non linéaire ou une variable omise est probable. H_0 : « la spécification est correcte » ; son rejet signale un problème de forme. RESET détecte la non-linéarité et certaines omissions, mais ne dit pas *quelle* variable ou *quelle* forme corrigerait — c'est un test de détection, pas de diagnostic précis.

Sur-spécification vs sous-spécification, l'arbitrage

Les deux erreurs ne se valent pas. **Sous-spécifier** (omettre une variable pertinente) introduit un *biais* — le péché le plus grave, car un coefficient biaisé est irrécupérable sans changer le modèle. **Sur-spécifier** (inclure des variables superflues) ne coûte que de la *variance* (erreurs-types gonflées) — moins grave, mais nuit à la précision et au surajustement. Face au doute, la théorie tranche : inclure les variables que la finance désigne comme pertinentes, exclure celles qu'aucun raisonnement ne justifie. Le compromis biais–variance (§9.10) formalise cet arbitrage.

9.6 --- Points aberrants, de levier et influents

Une régression peut être dominée par une poignée d'observations ; les distinguer est un diagnostic de robustesse essentiel.

Trois notions distinctes

Un **point aberrant** (outlier) a un **résidu** anormalement grand (Y loin de la droite). Un **point à fort levier** (high leverage) a une valeur de X **extrême** (loin de $\bar{X}$), mesurée par le **levier** h_i. Un **point influent** est celui dont le retrait **modifie sensiblement** les estimations — typiquement un point à la fois aberrant *et* à fort levier.

Mesures diagnostiques

Levier $h_i \in [0,1]$, $\sum_i h_i = k+1$, moyenne $\bar{h} = (k+1)/n$; $h_i > 2(k+1)/n$: levier élevé.

Résidu studentisé : $e_i^* = \dfrac{e_i}{s_{(i)}\sqrt{1-h_i}}$; **Distance de Cook** : $D_i = \dfrac{(e_i^*)^2}{k+1} \cdot \dfrac{h_i}{1-h_i}$.

Levier, résidu et influence — les trois combinés

Le levier seul ne suffit pas à faire une observation influente : un point à X extrême mais parfaitement sur la droite (petit résidu) a peu d'influence. Un résidu grand seul ne suffit pas non plus : un point aberrant au centre du nuage (h_i faible) tire peu la pente. C'est leur **combinaison** — grand résidu *et* fort levier — qui crée l'influence, capturée par la **distance de Cook** D_i. Règle usuelle : $D_i > 1$ (ou $D_i > 4/n$) signale un point influent à examiner. En finance, une seule journée de crise (rendement extrême, mouvement de marché extrême) peut ainsi déterminer à elle seule un bêta estimé.

Que faire d'un point influent ?

Ne **jamais** supprimer une observation par simple confort statistique. La démarche : (1) **vérifier** qu'il ne s'agit pas d'une erreur de saisie (auquel cas corriger) ; (2) si la donnée est réelle, se demander si elle relève du *processus étudié* ou d'un régime différent (crise, événement exceptionnel) ; (3) rapporter les résultats **avec et sans** le point, en toute transparence ; (4) envisager des méthodes **robustes** (régression sur médiane, pondération) moins sensibles aux extrêmes. Supprimer un point uniquement parce qu'il gêne relève de la manipulation ; le comprendre relève du métier.

9.7 --- La normalité des résidus

La normalité n'affecte ni le biais ni l'efficacité des MCO, mais conditionne la validité *exacte* des tests à échantillon fini.

Rôle de la normalité

L'hypothèse de **normalité des erreurs** ($\varepsilon_i \sim \mathcal{N}(0,\sigma^2)$) n'est requise ni pour l'absence de biais, ni pour l'efficacité (BLUE tient sans elle). Elle garantit la **validité exacte** des tests t et F à *petit échantillon*. À grand échantillon, le **théorème central limite** rend l'inférence asymptotiquement valide même sans normalité.

Détection

Jarque–Bera : $\text{JB} = \dfrac{n}{6}\left(\hat{S}^2 + \dfrac{(\hat{K}-3)^2}{4}\right) \sim \chi^2_2$ sous H_0 (normalité).

QQ-plot : quantiles des résidus vs quantiles normaux $\Rightarrow$ alignement $=$ normalité.

Normalité en finance : rarement vérifiée, souvent tolérable

Les résidus de modèles financiers sont presque toujours **non normaux** : queues épaisses (kurtosis élevé) et asymétrie, hérités de la non-normalité des rendements. Le test de Jarque–Bera les rejette massivement. Faut-il s'en alarmer ? À **grand échantillon**, non : le TCL protège l'inférence, et les tests t/F restent approximativement valides. À **petit échantillon**, oui : la non-normalité invalide les tests exacts, et l'on privilégie des méthodes robustes ou le bootstrap. Le QQ-plot reste précieux pour *visualiser* la nature de l'écart (queues, asymétrie) que la seule statistique JB résume en un nombre.

9.8 --- L'autocorrélation des résidus

Quand les erreurs sont corrélées entre observations — typique des séries temporelles — les erreurs-types classiques sont faussées.

Autocorrélation

Il y a **autocorrélation** (corrélation sérielle) lorsque $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$ pour $i \neq j$. Elle est **positive** si les erreurs successives tendent à avoir le même signe (persistance), **négative** si elles alternent. Fréquente sur données **temporelles** (inertie économique, variables omises tendancielles, mauvaise forme).

Détection : Durbin–Watson

$$\mathrm{DW} = \frac{\sum_{i=2}^{n}(e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2} \approx 2(1-\hat{\rho}), \qquad \mathrm{DW} \in [0,4].$$

$\mathrm{DW} \approx 2$: pas d'autocorrélation; $\mathrm{DW} < 2$: positive; $\mathrm{DW} > 2$: négative.

Conséquences et remèdes

Comme l'hétéroscédasticité, l'autocorrélation **ne biaise pas** $\hat{\beta}$ (sans biais, consistant) mais **fausse les erreurs-types** — l'autocorrélation *positive* les sous-estime, gonflant artificiellement les t et conduisant à sur-affirmer la significativité. Détection : la statistique de **Durbin–Watson** (autocorrélation d'ordre 1) ou, plus général, le test de **Breusch–Godfrey** (ordres supérieurs). Remède : les erreurs-types de **Newey–West** (HAC — robustes à l'hétéroscédasticité *et* à l'autocorrélation), qui corrigent les SE sans toucher aux coefficients. Sur séries temporelles financières, Newey–West est le standard, comme White l'est en coupe transversale.

Autocorrélation comme symptôme d'un autre mal

Un piège fréquent : l'autocorrélation détectée n'est souvent pas le *vrai* problème, mais le **symptôme** d'une mauvaise spécification. Une variable omise tendancielle ou une forme fonctionnelle incorrecte (linéaire au lieu de courbe) laisse dans les résidus une structure que Durbin–Watson lit comme de l'autocorrélation. Avant de corriger mécaniquement par Newey–West, il faut se demander si le modèle n'est pas simplement mal spécifié : ajouter la variable manquante ou la bonne forme peut faire disparaître l'autocorrélation à la racine. Corriger les SE d'un modèle biaisé ne règle rien.

9.9 --- Stabilité des coefficients et ruptures structurelles

Un modèle suppose des coefficients constants sur toute la période ; cette hypothèse peut échouer si le régime change.

Rupture structurelle et test de Chow

Une **rupture structurelle** survient quand les coefficients changent entre sous-périodes (avant/après une crise, un changement réglementaire). Le **test de Chow** la détecte en comparant le modèle estimé sur l'échantillon *entier* (contraint : mêmes coefficients partout) aux modèles estimés *séparément* sur chaque sous-période (non contraint) :

$$F = \frac{(\text{RSS}_c - \text{RSS}_{nc})/(k+1)}{\text{RSS}_{nc}/(n-2(k+1))} \sim F_{k+1,\, n-2(k+1)}.$$

Le test de Chow en pratique

Le test de Chow est un cas particulier du test F conjoint (chapitre 8) appliqué à l'égalité des coefficients entre deux groupes. RSS_c est la somme des carrés résiduelle du modèle unique sur toutes les données ; $\text{RSS}_{nc} = \text{RSS}_1 + \text{RSS}_2$ celle des deux régressions séparées. Un rejet de H_0 (coefficients égaux) signale une **rupture** : le modèle unique est inadéquat, il faut modéliser les régimes séparément ou introduire des variables indicatrices croisées avec le temps. Exemple : le bêta d'un actif peut différer significativement avant et après un choc de marché — l'estimer sur toute la période mélangerait deux régimes. Limite : le test de Chow exige de *connaître* la date de rupture ; des tests plus avancés (CUSUM, Quandt) la recherchent.

Stabilité et prévision

La stabilité des coefficients est cruciale pour la **prévision** : un modèle dont les paramètres dérivent prédit mal l'avenir, car il extrapole une relation qui n'est plus valable. En gestion des risques, un modèle de VaR calibré sur un régime calme sous-estime le risque quand la volatilité change de régime. D'où l'importance de tester la stabilité (Chow sur des dates candidates, ou estimation par fenêtre glissante) et de re-calibrer les modèles. Un coefficient « significatif » sur l'ensemble d'un historique hétérogène peut n'être qu'un artefact mélangeant plusieurs régimes distincts.

9.10 --- Compromis biais--variance et sélection de modèle

Le diagnostic débouche sur un choix : quel modèle retenir ? La réponse mobilise le compromis biais–variance et des critères de sélection.

Compromis biais–variance et critères d'information

L'erreur de prévision se décompose en **biais**^{2} + **variance** + bruit irréductible. **Sous-ajuster** (modèle trop simple) → biais élevé ; **sur-ajuster** (modèle trop complexe) → variance élevée. Les **critères d'information** arbitrent en pénalisant la complexité :

$$\text{AIC} = n\ln(\text{RSS}/n) + 2(k+1), \qquad \text{BIC} = n\ln(\text{RSS}/n) + (k+1)\ln n \quad \text{(minimiser)}.$$

AIC vs BIC vs validation croisée

$$\text{BIC pénalise plus que l'AIC (facteur } \ln n) \Rightarrow \text{modèles plus parcimonieux.}$$

Validation croisée : estimer sur une partie, évaluer sur l'autre ⇒ mesure directe de la prévision hors échantillon.

Le surajustement, ennemi juré du diagnostic

Le fil rouge du chapitre : un modèle qui maximise le R^2 en échantillon **épouse le bruit** et prévoit mal hors échantillon. Tous les diagnostics convergent vers cette vigilance. Le R^2 ajusté, l'AIC/BIC pénalisent la complexité ; la **validation croisée** la teste directement en réservant des données pour l'évaluation. Le

lien avec le chapitre 6 est profond : chercher exhaustivement le « meilleur » modèle sur les mêmes données garantit de trouver des relations **fallacieuses**, exactement comme multiplier les tests d'hypothèses gonfle les faux positifs. La parcimonie et la validation hors échantillon sont les seules protections fiables — un modèle sur-paramétré au R^2 éclatant est un piège, pas une réussite.

AIC ou BIC : lequel choisir ?

Les deux critères récompensent l'ajustement et pénalisent la complexité, mais avec des philosophies différentes. Le **BIC** (pénalité $\ln n$, plus lourde) vise à identifier le *vrai* modèle et sélectionne des spécifications plus parcimonieuses ; il est cohérent (retrouve le vrai modèle quand $n \to \infty$ si celui-ci est parmi les candidats). L'**AIC** (pénalité 2) vise la meilleure *prévision* et tolère des modèles un peu plus riches ; il est efficace au sens de l'erreur de prévision. En pratique, ils s'accordent souvent ; en cas de désaccord, le choix dépend de l'objectif — explication parcimonieuse (BIC) ou performance prédictive (AIC) — et l'on tranche par validation croisée.

9.11 --- Un protocole de diagnostic complet

Rassemblons les outils en une séquence opérationnelle, à appliquer à toute régression avant d'en tirer des conclusions.

Le protocole en sept contrôles

(1) Forme : graphe résidus vs $\hat{Y}$ $\to$ structure ? (RESET de Ramsey).

(2) Hétéroscédasticité : entonnoir ? (Breusch–Pagan, White) $\to$ SE de White.

(3) Autocorrélation : (séries) Durbin–Watson, Breusch–Godfrey $\to$ SE de Newey–West.

(4) Normalité : Jarque–Bera, QQ-plot $\to$ (petit n) robuste/bootstrap.

(5) Colinéarité : VIF, nombre de conditionnement $\to$ retirer/combiner.

(6) Influence : levier h_i, distance de Cook D_i $\to$ examiner, robuste.

(7) Stabilité : test de Chow, fenêtre glissante $\to$ modéliser les régimes.

L'ordre des priorités

Tous les problèmes ne se valent pas, et l'ordre de traitement importe. **D'abord le biais** : vérifier la spécification (forme, variables omises) — un coefficient biaisé invalide tout le reste, et corriger ses SE ne servirait à rien. **Ensuite la robustesse** : identifier les points influents qui pourraient dominer l'estimation. **Puis l'efficacité** : hétéroscédasticité et autocorrélation, corrigées par SE robustes. **Enfin la précision et la validité** : colinéarité (VIF) et normalité (selon n). Traiter l'efficacité avant le biais — appliquer White à un modèle mal spécifié — donne une fausse assurance sur un modèle fondamentalement faux. Le diagnostic est hiérarchique : le biais prime toujours.

9.12 --- Synthèse : la carte des diagnostics

Problème	Détection	Effet sur $\hat{\beta}$	Remède
Mauvaise forme	RESET, graphe résidus	**Biaisé**	Transformer, ajouter termes
Variable omise	Théorie, résidus	**Biaisé**	Inclure / instrument

Problème	**Détection**	**Effet sur $\widehat{\beta}$**	**Remède**
Hétéroscédasticité	Breusch–Pagan, White	Sans biais, SE fausses	SE de White
Autocorrélation	Durbin–Watson, B–G	Sans biais, SE fausses	SE de Newey–West
Non-normalité	Jarque–Bera, QQ-plot	Aucun (grand n)	Robuste / bootstrap
Multicolinéarité	VIF, cond. number	Sans biais, SE gonflées	Retirer / combiner
Points influents	Levier, Cook D_i	Peut dominer	Examiner / robuste
Rupture structurelle	Test de Chow	Instable	Régimes séparés

Les sept réflexes du chapitre

(1) Ne jamais juger une régression sur son seul R^2 : examiner les résidus *avant* d'interpréter. **(2)** Distinguer *biais* (spécification, variable omise $\rightarrow$ changer le modèle) et *efficacité* (hétéroscédasticité, autocorrélation $\rightarrow$ SE robustes). **(3)** Hétéroscédasticité : détecter (Breusch–Pagan, White), corriger par SE de White ($\widehat{\beta}$ inchangé). **(4)** Autocorrélation : Durbin–Watson (≈ 2 = OK), corriger par Newey–West ; se méfier qu'elle ne cache une mauvaise spécification. **(5)** Colinéarité : VIF (> 5 = alerte, $= 1/(1 - R_j^2)$) et nombre de conditionnement ; gonfle les SE, ne biaise pas. **(6)** Influence : levier h_i, résidus studentisés, distance de Cook ($D_i > 1$) ; ne jamais supprimer un point par confort. **(7)** Stabilité : test de Chow pour les ruptures ; sélection par AIC/BIC et validation croisée ; le biais prime dans l'ordre des priorités.

Partie B --- 200 études de cas pratiques

Chaque cas propose un contexte chiffré, une question et une solution détaillée. VIF, statistiques de Durbin–Watson, distance de Cook, leviers, test de Chow, Jarque–Bera et RESET sont calculés exactement (numpy/scipy). Travaillez crayon en main : cachez la solution, résolvez, comparez.

Bloc 1 --- Pourquoi diagnostiquer : hypothèses et enjeux

Cas 1 — Le rôle des diagnostics. Pourquoi ne jamais juger une régression sur son seul R^2 ?

Solution. Un R^2 élevé peut coexister avec des SE faussées, des coefficients biaisés ou une domination par des points aberrants. Les **diagnostics vérifient la validité** des hypothèses avant toute interprétation.

Cas 2 — Hypothèse et propriété — exogénéité. Quelle propriété l'exogénéité $E[\varepsilon|X]=0$ garantit-elle ?

Solution. L'**absence de biais** de β. Sa violation (variable omise, endogénéité) rend le coefficient lui-même faux.

Cas 3 — Hypothèse et propriété — homoscédasticité. Quelle propriété l'homoscédasticité et l'absence d'autocorrélation garantissent-elles ?

Solution. L'**efficacité** (variance minimale, erreurs-types correctes). Leur violation fausse les SE sans biaiser β.

Cas 4 — Hypothèse et propriété — normalité. Que garantit la normalité des erreurs ?

Solution. La **validité exacte des tests t/F à petit échantillon**. À grand n, le TCL supplée (inférence asymptotiquement valide).

Cas 5 — Hypothèse et propriété — colinéarité. Que garantit l'absence de colinéarité parfaite ?

Solution. L'**identifiabilité** des coefficients : sinon X^TX n'est pas inversible et β n'est pas défini.

Cas 6 — La distinction cardinale. Quelle distinction fondamentale organise tout le diagnostic ?

Solution. **Biais** (β faux : variable omise, endogénéité, mauvaise forme $\Longrightarrow$ changer le modèle) vs **efficacité** (hétéroscédasticité, autocorrélation $\Longrightarrow$ SE robustes).

Cas 7 — Pourquoi la distinction commande le remède. Pourquoi ranger un problème dans « biais » ou « efficacité » détermine-t-il le remède ?

Solution. Un biais exige de **changer le modèle** (aucune SE robuste ne corrige un coefficient faux) ; une perte d'efficacité se corrige par des **SE robustes** (β était bon).

Cas 8 — L'erreur de diagnostic. Quelle erreur commet-on en appliquant des SE robustes à un problème de variable omise ?

Solution. Le **biais reste intact** : on corrige l'incertitude d'un coefficient déjà faux, donnant une fausse assurance.

Cas 9 — Le rôle des résidus. Pourquoi les résidus sont-ils au cœur de presque tous les diagnostics ?

Solution. Ils sont l'**image empirique** des erreurs inobservables : leur ampleur, structure, distribution et corrélation révèlent hétéroscédasticité, mauvaise forme, non-normalité et autocorrélation.

Cas 10 — Résidu vs erreur. Distinguer l'erreur ε_i et le résidu e_i dans le diagnostic.

Solution. ε_i (population, inobservable) est ce qu'on veut diagnostiquer ; $e_i = Y_i - \hat{Y}_i$ (observable) en est l'estimation, sur laquelle s'appuient tous les tests.

Cas 11 — Ce que révèle l'ampleur des résidus. Que révèle une dispersion des résidus variant avec X ?

Solution. De l'**hétéroscédasticité** : la variance des erreurs n'est pas constante (motif en entonnoir).

Cas 12 — Ce que révèle la structure des résidus. Que révèle une structure systématique (courbe) dans les résidus ?

Solution. Une **erreur de forme fonctionnelle** : le modèle linéaire capture mal une relation non linéaire.

Cas 13 — Ce que révèle la distribution des résidus. Que révèle une distribution non normale des résidus ?

Solution. La **non-normalité des erreurs** : queues épaisses ou asymétrie, affectant la validité des tests exacts à petit n.

Cas 14 — Ce que révèle la corrélation des résidus. Que révèle une corrélation entre résidus successifs ?

Solution. De l'**autocorrélation** : les erreurs ne sont pas indépendantes (fréquent sur séries temporelles).

Cas 15 — Diagnostic ≠ formalité. Pourquoi le diagnostic n'est-il pas une simple formalité de fin de parcours ?

Solution. C'est la **condition de validité de toute inférence** : un modèle non diagnostiqué est un modèle dont on ignore s'il ment.

Cas 16 — Biais irrécupérable. Pourquoi un coefficient biaisé est-il « irrécupérable » sans changer le modèle ?

Solution. Le biais est structurel (mauvaise spécification) : aucune correction d'erreur-type ne le supprime. Seul un modèle correct (bonne forme, variable incluse) le corrige.

Cas 17 — Ordre des priorités — principe. Dans quel ordre traiter les problèmes de diagnostic ?

Solution. **Le biais d'abord** (spécification), puis la robustesse (points influents), puis l'efficacité (SE robustes), enfin précision et validité (colinéarité, normalité).

Cas 18 — Fausse assurance. Pourquoi traiter l'efficacité avant le biais est-il dangereux ?

Solution. Cela donne une **fausse assurance** sur un modèle fondamentalement faux : des SE correctes autour d'un coefficient biaisé.

Cas 19 — Les trois grandes menaces. Citer les trois grandes catégories de menaces sur une régression.

Solution. (1) hétéroscédasticité/autocorrélation (**efficacité**) ; (2) spécification/endogénéité (**biais**) ; (3) points aberrants/influents (**robustesse**).

Cas 20 — La règle d'or. Résumer la règle d'or du diagnostic de régression.

Solution. **Examiner les résidus avant d'interpréter** : dispersion, structure, distribution, dépendance, influence — la validité de l'inférence en dépend.

Bloc 2 --- Hétéroscédasticité : nature et détection

Cas 21 — Hétéroscédasticité — définition. Qu'est-ce que l'hétéroscédasticité ?

Solution. La variance des erreurs **n'est pas constante** : $\mathrm{Var}(\varepsilon_i|X_i)=\sigma_i^2$ dépend des régresseurs, par opposition à l'homoscédasticité $\mathrm{Var}(\varepsilon)=\sigma^2$.

Cas 22 — Effet sur β. L'hétéroscédasticité biaise-t-elle β ?

Solution. **Non** : β reste sans biais et consistant, mais **n'est plus BLUE** (efficacité perdue).

Cas 23 — Effet sur les erreurs-types. Quel est l'effet de l'hétéroscédasticité sur les erreurs-types classiques ?

Solution. Elles sont **biaisées** $\Longrightarrow$ tests t et F invalides (souvent trop optimistes, sur-affirmant la significativité).

Cas 24 — Pourquoi omniprésente en finance. Pourquoi l'hétéroscédasticité est-elle la norme sur données financières ?

Solution. La **volatilité varie dans le temps** (clustering), la dispersion croît avec le risque, les erreurs augmentent avec la taille des positions. On la suppose par défaut.

Cas 25 — Détection graphique. Comment détecter graphiquement l'hétéroscédasticité ?

Solution. Tracer les résidus (ou leur carré) contre $\hat{Y}$ ou chaque régresseur : un motif en **entonnoir** (dispersion croissante/décroissante) la signale ; un nuage sans structure la dément.

Cas 26 — Test de Breusch–Pagan. Sur quel principe repose le test de Breusch–Pagan ?

Solution. Il **régresse les résidus au carré sur les régresseurs** ; H_0 : variance constante. Un rejet signale l'hétéroscédasticité.

Cas 27 — Test de White. En quoi le test de White est-il plus général que Breusch–Pagan ?

Solution. Il inclut les **carrés et produits croisés** des régresseurs, ne présupposant aucune forme particulière d'hétéroscédasticité.

Cas 28 — H_0 des tests d'hétéroscédasticité. Quelle est l'hypothèse nulle des tests de Breusch–Pagan et White ?

Solution. H_0 : **homoscédasticité** (variance des erreurs constante). Le rejet conduit à utiliser des SE robustes.

Cas 29 — Conséquence pratique d'ignorer l'hétéroscédasticité. Que risque-t-on en ignorant l'hétéroscédasticité ?

Solution. **Surestimer la significativité** (SE sous-estimées) et conclure à tort qu'un facteur est pertinent (faux positifs).

Cas 30 — Motif en entonnoir croissant. Un graphe de résidus montre une dispersion croissant avec $\hat{Y}$. Diagnostic ?

Solution. **Hétéroscédasticité** : la variance des erreurs augmente avec le niveau prédit. Remède : SE de White.

Cas 31 — Résidus au carré. Pourquoi tracer les résidus au carré (et non les résidus) pour l'hétéroscédasticité ?

Solution. Le carré mesure la **magnitude** (variance) indépendamment du signe : une tendance de e_i^2 selon X révèle directement la variance changeante.

Cas 32 — BLUE perdu. Que signifie « les MCO ne sont plus BLUE » sous hétéroscédasticité ?

Solution. Ils restent linéaires et sans biais, mais **ne sont plus de variance minimale** : un autre estimateur (WLS) serait plus efficace.

Cas 33 — Hétéroscédasticité et taille de position. Pourquoi les erreurs d'un modèle de P&L croissent-elles avec la taille des positions ?

Solution. Une position plus grande amplifie l'effet des mouvements de marché $\Longrightarrow$ **variance des erreurs plus élevée** : hétéroscédasticité typique.

Cas 34 — Test formel vs graphique. Faut-il préférer le test formel ou le graphique pour l'hétéroscédasticité ?

Solution. **Les deux sont complémentaires** : le graphique montre la nature/forme, le test (Breusch–Pagan, White) donne une décision statistique.

Cas 35 — Rejet de Breusch–Pagan. Le test de Breusch–Pagan rejette H_0. Que conclure et que faire ?

Solution. **Hétéroscédasticité confirmée** : les SE classiques sont invalides. Rapporter des SE robustes (White) pour l'inférence.

Cas 36 — Hétéroscédasticité conditionnelle. Qu'est-ce que l'hétéroscédasticité conditionnelle (ARCH) sur séries temporelles ?

Solution. La variance des erreurs dépend des erreurs passées (clustering de volatilité), modélisée par ARCH/GARCH — un cas dynamique d'hétéroscédasticité.

Cas 37 — Non-normalité vs hétéroscédasticité. Hétéroscédasticité et non-normalité sont-elles le même problème ?

Solution. **Non** : l'hétéroscédasticité concerne la **variance** (non constante), la non-normalité la **forme de distribution**. Deux diagnostics distincts, deux remèdes distincts.

Cas 38 — Détecter par sous-groupes. Comment un test compare-t-il la variance entre sous-groupes (Goldfeld–Quandt) ?

Solution. Il divise l'échantillon selon un régresseur, estime la variance résiduelle de chaque moitié, et teste leur **égalité** (test F). Un rapport élevé signale l'hétéroscédasticité.

Cas 39 — Hétéroscédasticité et prévision. L'hétéroscédasticité affecte-t-elle la prévision ponctuelle $\hat{Y}$?

Solution. La **prévision ponctuelle reste sans biais** (β correct), mais les **intervalles de prévision** sont faussés (variance mal estimée). Corriger pour des intervalles valides.

Cas 40 — Résumé hétéroscédasticité. Résumer nature, effet et remède de l'hétéroscédasticité.

Solution. **Nature** : variance des erreurs non constante. **Effet** : β sans biais, SE faussées. **Remède** : SE de White (détection : Breusch–Pagan, White, graphe en entonnoir).

Bloc 3 --- Remèdes à l'hétéroscédasticité et multicolinéarité

Cas 41 — Erreurs-types de White. Qu'est-ce que les erreurs-types robustes de White ?

Solution. Des SE **robustes à l'hétéroscédasticité** (HC) : elles recalculent la variance des estimateurs sans supposer σ^2 constante. β reste **inchangé**, seules les SE (t, p, IC) changent.

Cas 42 — Moindres carrés pondérés (WLS). Qu'est-ce que les moindres carrés pondérés ?

Solution. Ils **pondèrent chaque observation par $1/\sigma_i^2$**, redonnant du poids aux observations les plus précises. Si la forme de σ_i^2 est connue, WLS restaure BLUE (efficacité).

Cas 43 — White vs WLS. Comparer White et WLS.

Solution. **White** : β inchangé, SE corrigées, aucun modèle de σ_i^2 requis (simple, robuste). **WLS** : β ré-estimé, efficace, mais exige de connaître la forme de σ_i^2 (risqué si mal spécifiée).

Cas 44 — Pourquoi White domine. Pourquoi les SE de White sont-elles le standard en pratique ?

Solution. Elles ne demandent **aucune hypothèse** sur la forme de l'hétéroscédasticité : on les rapporte quasi systématiquement, sans risque de mal modéliser σ_i^2.

Cas 45 — Risque de WLS mal spécifié. Quel est le risque d'un WLS fondé sur une forme erronée de σ_i^2 ?

Solution. Une **pondération incorrecte** peut aggraver le problème (SE encore plus faussées). White évite ce risque en ne modélisant pas σ_i^2.

Cas 46 — Le message clé sur β. Sous hétéroscédasticité, le problème est-il le coefficient ou son erreur-type ?

Solution. **Son erreur-type** : β reste sans biais. Le remède (White) ne touche donc pas β, seulement son incertitude mesurée.

Cas 47 — Quand privilégier WLS. Dans quel cas WLS se justifie-t-il malgré tout ?

Solution. Quand l'**efficacité est cruciale** ET que la structure de l'hétéroscédasticité est **bien comprise** (σ_i^2 connu ou bien modélisé).

Cas 48 — MCG généralisés. Qu'est-ce que les moindres carrés généralisés (MCG) ?

Solution. La **généralisation de WLS** traitant à la fois hétéroscédasticité et autocorrélation via une matrice de variance-covariance complète des erreurs.

Cas 49 — Multicolinéarité — VIF. Comment mesure-t-on la multicolinéarité par le VIF ?

Solution. $\text{VIF}_j = 1/(1-R_j^2)$, où R_j^2 est le R^2 de la régression de X_j sur tous les autres régresseurs. $\text{SE}(\beta_j)$ est multipliée par $\sqrt{\text{VIF}_j}$.

Cas 50 — Calcul du VIF et de la tolérance. $R_j^2 = 0{,}75$ (régression de X_j sur les autres). Calculer le VIF et la tolérance.

Solution. $\text{VIF} = 1/(1-0{,}75) = \mathbf{4}$; tolérance $= 1 - R_j^2 = 0{,}25$; SE multipliée par $\sqrt{4} = 2$.

Cas 51 — Calcul du VIF et de la tolérance. $R_j^2 = 0{,}9$ (régression de X_j sur les autres). Calculer le VIF et la tolérance.

Solution. $\text{VIF} = 1/(1-0{,}9) = \mathbf{10}$; tolérance $= 1 - R_j^2 = 0{,}1$; SE multipliée par $\sqrt{10} = 3{,}16$.

Cas 52 — Calcul du VIF et de la tolérance. $R_j^2 = 0{,}95$ (régression de X_j sur les autres). Calculer le VIF et la tolérance.

Solution. $\text{VIF} = 1/(1-0{,}95) = \mathbf{20}$; tolérance $= 1 - R_j^2 = 0{,}05$; SE multipliée par $\sqrt{20} = 4{,}47$.

Cas 53 — Calcul du VIF et de la tolérance. $R_j^2 = 0{,}5$ (régression de X_j sur les autres). Calculer le VIF et la tolérance.

Solution. $\text{VIF} = 1/(1-0{,}5) = \mathbf{2}$; tolérance $= 1 - R_j^2 = 0{,}5$; SE multipliée par $\sqrt{2} = 1{,}41$.

Cas 54 — Tolérance. Qu'est-ce que la tolérance et son lien avec le VIF ?

Solution. Tolérance=$1-R_j^2=1/VIF$: proche de 0 $\Longrightarrow$ forte colinéarité ; proche de 1 $\Longrightarrow$ orthogonalité. Inverse du VIF.

Cas 55 — Seuils du VIF. Quels seuils d'alerte pour le VIF ?

Solution. VIF=1 : orthogonalité ; **VIF>5** : alerte ; **VIF>10** : multicolinéarité sévère ($R_j^2>0,9$).

Cas 56 — Nombre de conditionnement. Qu'est-ce que le nombre de conditionnement et que diagnostique-t-il ?

Solution. $\kappa=\sqrt{(\lambda_{max}/\lambda_{min})}$ des valeurs propres de X^TX : il diagnostique la colinéarité **globale** (plusieurs régresseurs à la fois). $\kappa>30$ signale un problème.

Cas 57 — VIF vs nombre de conditionnement. VIF et nombre de conditionnement sont-ils redondants ?

Solution. **Complémentaires** : le VIF est **local** (un régresseur vs les autres), κ est **global** (l'ensemble de la matrice). κ capte des colinéarités multiples qu'une analyse par paires manquerait.

Cas 58 — Multicolinéarité et biais. La multicolinéarité imparfaite biaise-t-elle β ?

Solution. **Non** : les MCO restent BLUE. Elle **gonfle les erreurs-types** (perte de précision), sans fausser les coefficients.

Cas 59 — Triple symptôme. Citer le triple symptôme de la multicolinéarité.

Solution. Coefficients **instables**, **t individuels faibles** malgré un F global significatif, **signes contre-intuitifs**.

Cas 60 — Remède pour la prévision. La multicolinéarité gêne-t-elle si le but est la prévision ?

Solution. **Souvent non** : le modèle prédit bien malgré des coefficients imprécis. Elle gêne surtout l'**interprétation** des effets partiels.

Cas 61 — Remèdes pour l'interprétation. Citer trois remèdes à la multicolinéarité (objectif interprétation).

Solution. **Retirer** un régresseur redondant, les **combiner** (indice, PCA), **collecter plus de données**, ou régularisation (ridge).

Cas 62 — Régression ridge. Comment la régression ridge traite-t-elle la multicolinéarité ?

Solution. Elle ajoute une **pénalité** sur la taille des coefficients, introduisant un léger biais mais **réduisant fortement la variance** (compromis biais-variance favorable en cas de colinéarité).

Cas 63 — Erreur d'interprétation. Quelle erreur la multicolinéarité induit-elle ?

Solution. Conclure qu'une variable est **inutile** sur un t faible, alors que son effet est réel mais **mal identifié** faute de variation indépendante.

Cas 64 — PCA contre colinéarité. Comment la PCA aide-t-elle contre la colinéarité ?

Solution. Elle remplace les régresseurs corrélés par des **composantes principales orthogonales** (non corrélées), éliminant la colinéarité au prix de l'interprétabilité directe.

Bloc 4 --- Erreurs de spécification et test RESET

Cas 65 — Erreur de spécification — définition. Qu'est-ce qu'une erreur de spécification ?

Solution. Un écart entre le modèle estimé et le vrai processus : **variable omise**, **variable superflue**, ou **forme fonctionnelle incorrecte**.

Cas 66 — Conséquence : variable omise. Quel est l'effet d'une variable omise pertinente et corrélée ?

Solution. **β biaisé** (biais d'omission) : l'effet de la variable omise contamine les coefficients inclus corrélés.

Cas 67 — Conséquence : variable superflue. Quel est l'effet d'inclure une variable superflue ?

Solution. **β reste sans biais** mais la **variance augmente** (SE gonflées) : perte d'efficacité, sans biais.

Cas 68 — Conséquence : forme incorrecte. Quel est l'effet d'une forme fonctionnelle incorrecte ?

Solution. **β biaisé** et interprétation faussée : supposer linéaire une relation courbe déforme les coefficients.

Cas 69 — Test RESET de Ramsey — principe. Sur quel principe repose le test RESET de Ramsey ?

Solution. Ré-estimer le modèle en ajoutant des **puissances des valeurs ajustées** ($\hat{Y}^2$, $\hat{Y}^3$) ; si elles sont conjointement significatives (test F), la spécification est incorrecte.

Cas 70 — H_0 du test RESET. Quelle est l'hypothèse nulle du test RESET ?

Solution. H_0 : **la spécification est correcte** (forme fonctionnelle adéquate). Son rejet signale une non-linéarité ou une omission.

Cas 71 — Ce que RESET détecte. Que détecte le test RESET, et que ne détecte-t-il pas ?

Solution. Il **détecte** la non-linéarité et certaines omissions, mais **ne dit pas** quelle variable ni quelle forme corrigerait (test de détection, pas de diagnostic précis).

Cas 72 — Sur- vs sous-spécification — gravité. Laquelle est plus grave : sous-spécifier ou sur-spécifier ?

Solution. **Sous-spécifier** (variable omise) est plus grave : elle **biaise** (irrécupérable sans changer le modèle). Sur-spécifier ne coûte que de la variance.

Cas 73 — Rôle de la théorie. Comment la théorie aide-t-elle à éviter les erreurs de spécification ?

Solution. Elle désigne les variables **pertinentes** à inclure (éviter l'omission) et celles à exclure (éviter le superflu), guidant la spécification au-delà des seuls critères statistiques.

Cas 74 — Détecter une forme non linéaire. Comment repérer graphiquement une forme fonctionnelle incorrecte ?

Solution. Une **structure systématique** (courbe, ondulation) dans le graphe des résidus contre $\hat{Y}$ ou X : le linéaire ne capte pas tout.

Cas 75 — Corriger une non-linéarité. Comment corriger une forme non linéaire détectée ?

Solution. **Transformer** les variables (log, $\sqrt{}$) ou ajouter des termes (X^2, interactions) : le modèle reste linéaire en β, estimable par MCO.

Cas 76 — Variable omise vs autocorrélation. Pourquoi une variable omise peut-elle se manifester comme de l'autocorrélation ?

Solution. Son effet, absent du modèle, se retrouve dans les résidus ; s'il est structuré (tendanciel), Durbin–Watson le lit comme de l'**autocorrélation** — un symptôme, pas la cause.

Cas 77 — Rejet de RESET. Le test RESET rejette H_0. Que conclure ?

Solution. La **spécification est incorrecte** (non-linéarité ou omission probable). Explorer des transformations, des termes additionnels ou des variables manquantes.

Cas 78 — Le compromis biais-variance en spécification. Comment le compromis biais-variance guide-t-il la spécification ?

Solution. Sous-spécifier $\Longrightarrow$ biais ; sur-spécifier $\Longrightarrow$ variance. La bonne spécification **minimise l'erreur totale** (biais^2+variance), guidée par théorie et critères (AIC/BIC).

Cas 79 — Puissances de $\hat{Y}$. Pourquoi ajouter $\hat{Y}^2$ et $\hat{Y}^3$ dans le test RESET plutôt que des X^2 ?

Solution. $\hat{Y}$ combine tous les régresseurs : ses puissances captent une **non-linéarité générale** sans avoir à spécifier quel régresseur ni quelle forme — un test global de mauvaise spécification.

Cas 80 — Variable superflue et R^2. Ajouter une variable superflue augmente-t-il le R^2 ?

Solution. Le **R^2 brut augmente toujours** (même variable inutile), mais le **R^2 ajusté** peut décroître : signe que la variable n'apporte rien.

Cas 81 — Détecter une variable omise. Comment soupçonner une variable omise pertinente ?

Solution. Signes : résidus **structurés**, coefficients au signe **contre-intuitif**, instabilité selon l'échantillon, et raisonnement théorique (un facteur connu est-il absent ?).

Cas 82 — Proxy pour variable omise. Que faire si une variable pertinente n'est pas mesurable ?

Solution. Utiliser une **variable proxy** corrélée à la variable omise (ex. capitalisation pour la taille), réduisant le biais d'omission.

Cas 83 — Spécification et objectif. La bonne spécification dépend-elle de l'objectif (prévision vs interprétation) ?

Solution. **Oui** : pour l'interprétation, éviter le biais d'omission prime ; pour la prévision, la performance hors échantillon prime (un modèle biaisé mais prédictif peut suffire).

Cas 84 — Résumé spécification. Résumer les trois erreurs de spécification et leurs effets.

Solution. **Variable omise** $\Longrightarrow$ biais ; **variable superflue** $\Longrightarrow$ variance ; **forme incorrecte** $\Longrightarrow$ biais. Détection : RESET, graphe des résidus, théorie.

Bloc 5 --- Points aberrants, de levier et influents

Cas 85 — Trois notions distinctes. Distinguer point aberrant, point à fort levier et point influent.

Solution. **Aberrant** : résidu grand (Y loin de la droite). **Levier** : X extrême (loin de $\bar{x}$), mesuré par h_i. **Influent** : son retrait modifie sensiblement $\hat{\beta}$ (souvent aberrant ET à fort levier).

Cas 86 — Le levier h_i. Qu'est-ce que le levier h_i et quelles sont ses propriétés ?

Solution. $h_i \in [0,1]$ mesure l'éloignement de X_i du centre ; $\Sigma h_i = k+1$, moyenne $\bar{h} = (k+1)/n$. Seuil : $h_i > 2(k+1)/n$ signale un levier élevé.

Cas 87 — Seuil de levier. n=50, k=2 régresseurs. Calculer la moyenne des leviers et le seuil d'alerte.

Solution. $\bar{h} = (k+1)/n = 3/50 = 0{,}06$; seuil $= 2(k+1)/n =$ **0,12** : h_i au-delà signale un levier élevé.

Cas 88 — Seuil de levier. n=100, k=4 régresseurs. Calculer la moyenne des leviers et le seuil d'alerte.

Solution. $\bar{h} = (k+1)/n = 5/100 = 0{,}05$; seuil $= 2(k+1)/n =$ **0,1** : h_i au-delà signale un levier élevé.

Cas 89 — Seuil de levier. n=30, k=1 régresseurs. Calculer la moyenne des leviers et le seuil d'alerte.

Solution. $\bar{h} = (k+1)/n = 2/30 = 0{,}0667$; seuil $= 2(k+1)/n =$ **0,1333** : h_i au-delà signale un levier élevé.

Cas 90 — Résidu studentisé. Qu'est-ce qu'un résidu studentisé et pourquoi l'utiliser ?

Solution. $e_i^* = e_i / (s_{(i)}\sqrt{(1-h_i)})$: un résidu standardisé qui tient compte du levier (et exclut l'observation i de l'estimation de s). Il permet de repérer les vrais aberrants.

Cas 91 — Distance de Cook — définition. Qu'est-ce que la distance de Cook D_i ?

Solution. $D_i = (e_i^{*2}/(k+1)) \cdot (h_i/(1-h_i))$: elle mesure l'**influence globale** d'une observation en combinant résidu et levier. $D_i > 1$ (ou $4/n$) signale un point influent.

Cas 92 — Levier seul ≠ influence. Un point à fort levier est-il toujours influent ?

Solution. **Non** : un point à X extrême mais parfaitement sur la droite (petit résidu) a **peu d'influence**. Il faut levier ET grand résidu pour l'influence.

Cas 93 — Résidu seul ≠ influence. Un point aberrant (grand résidu) est-il toujours influent ?

Solution. **Non** : un aberrant au centre du nuage (h_i faible) tire peu la pente. L'influence exige aussi un levier élevé.

Cas 94 — La combinaison qui crée l'influence. Quelle combinaison rend une observation vraiment influente ?

Solution. **Grand résidu ET fort levier** : c'est leur conjonction, capturée par la distance de Cook, qui domine l'estimation.

Cas 95 — Seuil de la distance de Cook. Quels seuils pour la distance de Cook ?

Solution. **$D_i > 1$** (règle simple) ou **$D_i > 4/n$** (plus sensible) signalent un point influent à examiner.

Cas 96 — Une journée de crise. Comment une seule journée de crise peut-elle déterminer un bêta estimé ?

Solution. Rendement extrême (grand résidu) **et** mouvement de marché extrême (fort levier) : cette observation a une distance de Cook élevée et peut **dominer** la pente à elle seule.

Cas 97 — Que faire d'un point influent — étape 1. Première étape face à un point influent ?

Solution. **Vérifier qu'il ne s'agit pas d'une erreur de saisie** : si oui, corriger la donnée. Ne jamais supprimer par simple confort.

Cas 98 — Que faire d'un point influent — étape 2. Si un point influent est une donnée réelle, que se demander ?

Solution. S'il relève du **processus étudié** ou d'un **régime différent** (crise, événement exceptionnel), ce qui oriente le traitement.

Cas 99 — Transparence. Comment rapporter des résultats sensibles à un point influent ?

Solution. Rapporter les estimations **avec et sans** le point, en toute transparence, plutôt que de supprimer silencieusement.

Cas 100 — Méthodes robustes. Quelle approche réduit la sensibilité aux points influents ?

Solution. Les **méthodes robustes** (régression sur la médiane/LAD, M-estimateurs, pondération) : moins sensibles aux extrêmes que les MCO.

Cas 101 — Supprimer un point — éthique. Peut-on supprimer un point uniquement parce qu'il gêne les résultats ?

Solution. **Non** : cela relève de la **manipulation**. Le comprendre (erreur ? régime ?) et le rapporter relève du métier ; le supprimer par confort le trahit.

Cas 102 — Somme des leviers. Que vaut la somme des leviers Σh_i et qu'en déduit-on ?

Solution. $\Sigma h_i = \mathbf{k+1}$ (nombre de paramètres) : le levier moyen est $(k+1)/n$. Plus n est grand, plus le levier moyen est faible.

Cas 103 — Levier maximal. Que signifie un levier h_i proche de 1 ?

Solution. L'observation a un X **très éloigné** du centre et une influence potentielle maximale : la droite passe presque forcément par ce point.

Cas 104 — Diagnostic d'influence complet. Quels outils combiner pour diagnostiquer l'influence ?

Solution. **Levier h_i** (position en X), **résidus studentisés** (aberrance en Y) et **distance de Cook D_i** (influence globale) — ensemble ils identifient les observations dominantes.

Bloc 6 --- Normalité des résidus

Cas 105 — Rôle de la normalité. L'hypothèse de normalité des erreurs est-elle requise pour l'absence de biais ou l'efficacité ?

Solution. **Ni l'un ni l'autre** : BLUE tient sans normalité. Elle garantit seulement la **validité exacte des tests t/F à petit n**.

Cas 106 — Normalité et grand échantillon. Pourquoi la non-normalité est-elle tolérable à grand échantillon ?

Solution. Le **théorème central limite** rend l'inférence asymptotiquement valide : les tests t/F restent approximativement corrects même sans normalité.

Cas 107 — Test de Jarque–Bera. Comment le test de Jarque–Bera teste-t-il la normalité des résidus ?

Solution. $JB = (n/6)(\hat{S}^2 + (\hat{K}-3)^2/4) \sim \chi^2_2$ sous H_0 (normalité). On rejette pour de grandes valeurs (asymétrie ou kurtosis excessifs).

Cas 108 — Jarque–Bera sur résidus — calcul. Résidus : $\hat{S}=0$, $\hat{K}=3$, $n=300$. Calculer JB et conclure à 5 %.

Solution. $JB = (300/6)(0+0) = \mathbf{0}$; vs $\chi^2_{2;0,95} = 5{,}99$ ($p=1$) $\Longrightarrow$ **non-rejet**.

Cas 109 — Jarque–Bera sur résidus — calcul. Résidus : $\hat{S}=-0{,}5$, $\hat{K}=7$, $n=500$. Calculer JB et conclure à 5 %.

Solution. $JB = (500/6)(0{,}25+4) = \mathbf{354{,}17}$; vs $\chi^2_{2;0,95} = 5{,}99$ ($p=0$) $\Longrightarrow$ **rejet de la normalité**.

Cas 110 — Jarque–Bera sur résidus — calcul. Résidus : $\hat{S}$=0,3, $\hat{K}$=4,5, n=200. Calculer JB et conclure à 5 %.

Solution. JB=(200/6)(0,09+0,562)=**21,75** ; vs $\chi^2_{2;0,95}$=5,99 (p=0) $\Longrightarrow$ **rejet de la normalité**.

Cas 111 — QQ-plot. Qu'est-ce qu'un QQ-plot et comment l'interpréter ?

Solution. Il trace les **quantiles des résidus contre les quantiles normaux** : un alignement sur la diagonale confirme la normalité ; des écarts aux extrémités révèlent des queues épaisses.

Cas 112 — Résidus financiers non normaux. Pourquoi les résidus de modèles financiers sont-ils presque toujours non normaux ?

Solution. Ils héritent de la **non-normalité des rendements** : queues épaisses (kurtosis élevé) et asymétrie. Jarque–Bera les rejette massivement.

Cas 113 — Faut-il s'alarmer de la non-normalité ?. À grand échantillon, la non-normalité des résidus est-elle alarmante ?

Solution. **Non** : le TCL protège l'inférence. À **petit échantillon**, oui : privilégier méthodes robustes ou bootstrap.

Cas 114 — Valeur critique JB. Quelle valeur critique pour le test de Jarque–Bera à 5 % ?

Solution. $\chi^2_{2;0,95}$=**5,99** : JB>5,99 $\Longrightarrow$ rejet de la normalité à 5 %.

Cas 115 — Apport du QQ-plot vs JB. Qu'apporte le QQ-plot que la statistique JB ne donne pas ?

Solution. Il **visualise la nature de l'écart** (queues, asymétrie, points atypiques), là où JB résume tout en un seul nombre.

Cas 116 — Non-normalité et intervalles. La non-normalité affecte-t-elle les intervalles de confiance à petit n ?

Solution. **Oui** : les IC exacts reposent sur la normalité. À petit n non normal, ils sont approximatifs ; le bootstrap offre une alternative.

Cas 117 — Bootstrap. Comment le bootstrap contourne-t-il la non-normalité ?

Solution. Il **rééchantillonne** les données (avec remise) pour estimer empiriquement la distribution des statistiques, sans supposer la normalité.

Cas 118 — Kurtosis des résidus. Qu'indique un excès de kurtosis dans les résidus ?

Solution. Des **queues épaisses** : plus d'observations extrêmes qu'une loi normale. Fréquent en finance ; contribue au rejet de Jarque–Bera.

Cas 119 — Résumé normalité. Résumer le rôle et le diagnostic de la normalité des résidus.

Solution. **Rôle** : validité exacte des tests à petit n (TCL sinon). **Détection** : Jarque–Bera (χ^2_2), QQ-plot. **Remède** (petit n) : robuste, bootstrap.

Cas 120 — Asymétrie des résidus. Qu'indique une asymétrie (skewness) non nulle dans les résidus ?

Solution. Une **distribution non symétrique** des erreurs (pertes/gains d'ampleurs inégales) : contribue au rejet de Jarque–Bera via le terme $\hat{S}^2$.

Bloc 7 --- Autocorrélation des résidus

Cas 121 — Autocorrélation — définition. Qu'est-ce que l'autocorrélation des erreurs ?

Solution. $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)\neq 0$ pour $i\neq j$: les erreurs sont **corrélées entre observations**. Fréquente sur données temporelles.

Cas 122 — Autocorrélation positive vs négative. Distinguer autocorrélation positive et négative.

Solution. **Positive** : erreurs successives de même signe (persistance). **Négative** : erreurs qui alternent de signe.

Cas 123 — Effet sur β. L'autocorrélation biaise-t-elle β ?

Solution. **Non** : β reste sans biais et consistant. Elle **fausse les erreurs-types** (l'autocorrélation positive les sous-estime).

Cas 124 — Statistique de Durbin–Watson. Comment se calcule et s'interprète la statistique de Durbin–Watson ?

Solution. $DW=\Sigma(e_i-e_{i-1})^2/\Sigma e_i^2 \approx 2(1-\hat{\rho})$, $DW\in[0,4]$. **DW≈2** : pas d'autocorrélation ; **<2** : positive ; **>2** : négative.

Cas 125 — Durbin–Watson depuis ρ. L'autocorrélation d'ordre 1 des résidus est $\hat{\rho}=0$. Estimer la statistique de Durbin–Watson.

Solution. $DW\approx 2(1-\hat{\rho})=2(1-0)=\mathbf{2} \Longrightarrow$ autocorrélation **pas d'autocorrélation**.

Cas 126 — Durbin–Watson depuis ρ. L'autocorrélation d'ordre 1 des résidus est $\hat{\rho}=0{,}5$. Estimer la statistique de Durbin–Watson.

Solution. $DW\approx 2(1-\hat{\rho})=2(1-0{,}5)=\mathbf{1} \Longrightarrow$ autocorrélation **positive**.

Cas 127 — Durbin–Watson depuis ρ. L'autocorrélation d'ordre 1 des résidus est $\hat{\rho}=-0{,}3$. Estimer la statistique de Durbin–Watson.

Solution. $DW\approx 2(1-\hat{\rho})=2(1-(-0{,}3))=\mathbf{2{,}6} \Longrightarrow$ autocorrélation **négative**.

Cas 128 — Durbin–Watson depuis ρ. L'autocorrélation d'ordre 1 des résidus est $\hat{\rho}=0{,}8$. Estimer la statistique de Durbin–Watson.

Solution. $DW\approx 2(1-\hat{\rho})=2(1-0{,}8)=\mathbf{0{,}4} \Longrightarrow$ autocorrélation **positive**.

Cas 129 — DW proche de 0. Que signifie une statistique de Durbin–Watson proche de 0 ?

Solution. Une **forte autocorrélation positive** ($\hat{\rho}\approx 1$) : erreurs très persistantes. Les SE classiques sont fortement sous-estimées.

Cas 130 — DW proche de 4. Que signifie une statistique de Durbin–Watson proche de 4 ?

Solution. Une **forte autocorrélation négative** ($\hat{\rho}\approx -1$) : erreurs alternant systématiquement de signe.

Cas 131 — Test de Breusch–Godfrey. En quoi le test de Breusch–Godfrey complète-t-il Durbin–Watson ?

Solution. Il détecte l'autocorrélation d'**ordres supérieurs** (pas seulement l'ordre 1) et fonctionne même avec des régresseurs retardés.

Cas 132 — Erreurs-types de Newey–West. Qu'est-ce que les erreurs-types de Newey–West ?

Solution. Des SE **HAC** (robustes à l'hétéroscédasticité ET à l'autocorrélation) : elles corrigent les SE sans toucher à β. Standard sur séries temporelles.

Cas 133 — Autocorrélation positive et significativité. Pourquoi l'autocorrélation positive conduit-elle à surafirmer la significativité ?

Solution. Elle **sous-estime les erreurs-types** $\Longrightarrow$ t artificiellement grands $\Longrightarrow$ on rejette H_0 trop facilement (faux positifs).

Cas 134 — White vs Newey–West. Quand utiliser White et quand Newey–West ?

Solution. **White** : hétéroscédasticité en coupe transversale. **Newey–West** : hétéroscédasticité ET autocorrélation, typiquement sur séries temporelles.

Cas 135 — Autocorrélation comme symptôme. Pourquoi l'autocorrélation détectée n'est-elle pas toujours le vrai problème ?

Solution. Elle est souvent le **symptôme d'une mauvaise spécification** (variable omise tendancielle, forme incorrecte) : les résidus structurés sont lus comme de l'autocorrélation.

Cas 136 — Corriger à la racine. Avant Newey–West, que faut-il vérifier ?

Solution. Que le modèle n'est pas simplement **mal spécifié** : ajouter la variable manquante ou la bonne forme peut faire disparaître l'autocorrélation à la racine. Corriger les SE d'un modèle biaisé ne règle rien.

Cas 137 — Autocorrélation et séries temporelles. Pourquoi l'autocorrélation est-elle fréquente sur séries temporelles ?

Solution. **Inertie économique** (les chocs persistent), variables omises tendancielles, et mauvaise forme : les erreurs successives se ressemblent.

Cas 138 — DW et régresseurs retardés. Quelle est une limite de Durbin–Watson ?

Solution. Il est **invalide en présence de variable dépendante retardée** parmi les régresseurs ; Breusch–Godfrey est alors préféré.

Cas 139 — Résumé autocorrélation. Résumer nature, effet et remède de l'autocorrélation.

Solution. **Nature** : erreurs corrélées ($\mathrm{Cov}(\varepsilon_i,\varepsilon_j)\neq 0$). **Effet** : β sans biais, SE faussées. **Remède** : Newey–West (détection : Durbin–Watson, Breusch–Godfrey). Vérifier d'abord la spécification.

Cas 140 — Bornes de décision de Durbin–Watson. Pourquoi Durbin–Watson comporte-t-il une zone d'indécision ?

Solution. Ses valeurs critiques dépendent des régresseurs : entre les bornes d_L et d_U, le test est **indéterminé**. En dehors, on conclut à la présence ou à l'absence d'autocorrélation.

Bloc 8 --- Stabilité des coefficients et test de Chow

Cas 141 — Rupture structurelle — définition. Qu'est-ce qu'une rupture structurelle ?

Solution. Un **changement des coefficients** entre sous-périodes (avant/après une crise, un changement réglementaire) : l'hypothèse de coefficients constants échoue.

Cas 142 — Test de Chow — principe. Sur quel principe repose le test de Chow ?

Solution. Comparer le modèle sur l'échantillon **entier** (contraint : mêmes coefficients) aux modèles estimés **séparément** sur chaque sous-période (non contraint).

Cas 143 — Test de Chow — statistique. Donner la statistique du test de Chow.

Solution. F=((RSS_c−RSS_nc)/(k+1))/(RSS_nc/(n−2(k+1))) ~ F_{k+1, n−2(k+1)}, avec RSS_nc=RSS_1+RSS_2.

Cas 144 — Test de Chow — calcul. RSS_c=500 (modèle unique), RSS_1=180, RSS_2=200, n=60, k=2. Calculer la statistique de Chow.

Solution. RSS_nc=180+200=380 ; F=((500−380)/3)/(380/54)=**5,684** sur (3,54) ddl (p=0,0019 $\Longrightarrow$ rupture).

Cas 145 — Test de Chow — calcul. RSS_c=1000 (modèle unique), RSS_1=300, RSS_2=350, n=100, k=3. Calculer la statistique de Chow.

Solution. RSS_nc=300+350=650 ; F=((1000−650)/4)/(650/92)=**12,385** sur (4,92) ddl (p=0 $\Longrightarrow$ rupture).

Cas 146 — Chow comme cas du test F. De quel test général le test de Chow est-il un cas particulier ?

Solution. Du **test F conjoint** (chapitre 8) appliqué à l'**égalité des coefficients** entre deux groupes (sous-périodes).

Cas 147 — RSS contraint vs non contraint (Chow). Que représentent RSS_c et RSS_nc dans le test de Chow ?

Solution. RSS_c : somme des carrés du **modèle unique** sur toutes les données ; RSS_nc=RSS_1+RSS_2 : celle des **deux régressions séparées**.

Cas 148 — Interpréter un rejet de Chow. Le test de Chow rejette H_0. Que conclure et que faire ?

Solution. **Rupture confirmée** : le modèle unique est inadéquat. Modéliser les régimes **séparément** ou introduire des indicatrices croisées avec le temps.

Cas 149 — H_0 du test de Chow. Quelle est l'hypothèse nulle du test de Chow ?

Solution. H_0 : **les coefficients sont égaux** entre les sous-périodes (pas de rupture). Son rejet signale une instabilité.

Cas 150 — Bêta avant/après un choc. Comment le test de Chow s'applique-t-il au bêta d'un actif autour d'un choc ?

Solution. Estimer le bêta avant et après le choc séparément, puis tester leur **égalité** : un rejet indique que le risque systématique a changé de régime.

Cas 151 — Limite du test de Chow. Quelle est la principale limite du test de Chow ?

Solution. Il exige de **connaître la date de rupture** a priori. Des tests plus avancés (CUSUM, Quandt) la **recherchent** endogènement.

Cas 152 — CUSUM et Quandt. Que font les tests CUSUM et de Quandt ?

Solution. Ils **détectent une rupture sans en connaître la date** : CUSUM suit les résidus cumulés, Quandt cherche la date maximisant la statistique de Chow.

Cas 153 — Stabilité et prévision. Pourquoi la stabilité des coefficients est-elle cruciale pour la prévision ?

Solution. Un modèle aux paramètres **dérivants** prédit mal : il extrapole une relation qui n'est plus valable. Recalibrer est nécessaire.

Cas 154 — VaR et changement de régime. Pourquoi un modèle de VaR calibré en régime calme peut-il échouer ?

Solution. Il **sous-estime le risque** quand la volatilité change de régime : les coefficients calibrés sur une période calme ne valent plus en période agitée.

Cas 155 — Artefact de régimes mélangés. Un coefficient « significatif » sur un long historique hétérogène est-il fiable ?

Solution. Pas nécessairement : il peut n'être qu'un **artefact** mélangeant plusieurs régimes distincts. Tester la stabilité (Chow) est essentiel.

Cas 156 — Fenêtre glissante. Qu'est-ce que l'estimation par fenêtre glissante et à quoi sert-elle ?

Solution. Ré-estimer le modèle sur des **fenêtres temporelles mobiles** pour visualiser la **dérive des coefficients** dans le temps — un diagnostic de stabilité.

Cas 157 — Degrés de liberté du test de Chow. Quels sont les degrés de liberté du test de Chow ?

Solution. Numérateur : $\mathbf{k+1}$ (nombre de coefficients testés) ; dénominateur : $\mathbf{n-2(k+1)}$ (deux modèles de k+1 paramètres estimés).

Cas 158 — Indicatrices croisées avec le temps. Comment modéliser une rupture sans estimer deux régressions séparées ?

Solution. Introduire une **dummy de période** et ses **interactions** avec les régresseurs : les coefficients d'interaction captent le changement d'effet entre régimes.

Cas 159 — RSS_c ≥ RSS_nc (Chow). Pourquoi RSS_c ≥ RSS_nc dans le test de Chow ?

Solution. Le modèle contraint (coefficients égaux partout) a **moins de liberté** que deux modèles séparés $\Longrightarrow$ ajustement moindre, RSS plus grande. Le F mesure si l'écart est significatif.

Cas 160 — Rupture connue vs recherchée. Quand utiliser Chow et quand utiliser CUSUM/Quandt ?

Solution. **Chow** : date de rupture **connue** (ex. date d'une crise). **CUSUM/Quandt** : date **inconnue** à rechercher.

Cas 161 — Résumé stabilité. Résumer le diagnostic de stabilité des coefficients.

Solution. **Rupture** : coefficients changeant entre régimes. **Détection** : test de Chow (date connue), CUSUM/Quandt (inconnue), fenêtre glissante. **Remède** : modéliser les régimes séparément ou par interactions temporelles.

Cas 162 — Rupture d'intercept seule. Peut-on tester une rupture affectant seulement l'ordonnée à l'origine ?

Solution. **Oui** : via une dummy de période (intercept différent) sans interactions ; un test t/F sur son coefficient teste ce décalage de niveau.

Cas 163 — Nombre de sous-périodes. Le test de Chow se limite-t-il à deux sous-périodes ?

Solution. Sa forme de base compare **deux** sous-périodes, mais il se généralise à plusieurs points de rupture (via des dummies multiples et un test F conjoint).

Cas 164 — Taille minimale des sous-échantillons. Quelle contrainte de taille impose le test de Chow ?

Solution. Chaque sous-période doit compter **assez d'observations** pour estimer k+1 paramètres ($n_j > k+1$) ; sinon la régression séparée est infaisable.

Bloc 9 --- Compromis biais--variance et sélection de modèle

Cas 165 — Compromis biais-variance. Décomposer l'erreur de prévision selon le compromis biais-variance.

Solution. Erreur = **biais² + variance + bruit irréductible**. Sous-ajuster $\Longrightarrow$ biais élevé ; sur-ajuster $\Longrightarrow$ variance élevée. Minimiser l'erreur totale.

Cas 166 — Critère AIC. Donner la définition et l'usage de l'AIC.

Solution. AIC=n·ln(RSS/n)+2(k+1) : récompense l'ajustement, pénalise la complexité (2 par paramètre). **Minimiser**.

Cas 167 — Critère BIC. Donner la définition et l'usage du BIC.

Solution. BIC=n·ln(RSS/n)+(k+1)·ln n : pénalité plus lourde (ln n par paramètre) $\Longrightarrow$ modèles plus **parcimonieux**. Minimiser.

Cas 168 — AIC vs BIC — philosophie. Quelle différence de philosophie entre AIC et BIC ?

Solution. **BIC** vise le **vrai modèle** (cohérent, parcimonieux) ; **AIC** vise la meilleure **prévision** (tolère plus de complexité). En cas de désaccord, trancher par validation croisée.

Cas 169 — Validation croisée. Qu'est-ce que la validation croisée ?

Solution. Estimer sur une **partie** des données et évaluer sur l'**autre** : une mesure **directe** de la performance de prévision hors échantillon, complémentaire aux critères d'information.

Cas 170 — Surajustement — mécanisme. Pourquoi maximiser le R^2 conduit-il au surajustement ?

Solution. Empiler les régresseurs fait **épouser le bruit** de l'échantillon : excellent R^2 en échantillon, mauvaise prévision hors échantillon.

Cas 171 — Protections contre le surajustement. Citer trois protections contre le surajustement.

Solution. **R^2 ajusté**, **critères AIC/BIC**, et **validation croisée** (ou hors échantillon). La parcimonie protège.

Cas 172 — Lien avec les tests multiples. Quel lien entre surajustement et problème des tests multiples (chapitre 6) ?

Solution. Chercher exhaustivement le « meilleur » modèle sur les mêmes données produit des relations **fallacieuses**, comme multiplier les tests gonfle les faux positifs.

Cas 173 — BIC cohérent. Que signifie que le BIC est « cohérent » ?

Solution. Il **retrouve le vrai modèle** quand $n\to\infty$, si celui-ci figure parmi les candidats. L'AIC ne l'est pas mais est efficace en prévision.

Cas 174 — AIC efficace. En quel sens l'AIC est-il « efficace » ?

Solution. Il minimise asymptotiquement l'**erreur de prévision** : il choisit le modèle qui prédit le mieux, même s'il n'identifie pas le vrai modèle.

Cas 175 — Choisir AIC ou BIC. Comment choisir entre AIC et BIC en pratique ?

Solution. Selon l'**objectif** : explication parcimonieuse $\Longrightarrow$ BIC ; performance prédictive $\Longrightarrow$ AIC. En cas de désaccord, **validation croisée** tranche.

Cas 176 — R^2 ajusté vs AIC/BIC. En quoi l'AIC/BIC vont-ils plus loin que le R^2 ajusté ?

Solution. Le R^2 ajusté pénalise faiblement ($|t|>1$) ; l'AIC/BIC imposent des pénalités **plus explicites et théoriquement fondées** pour la sélection de modèle.

Cas 177 — Danger en gestion des risques. Pourquoi un modèle sur-paramétré est-il dangereux en gestion des risques ?

Solution. Il donne une **fausse confiance** : coefficients instables, mauvaise prévision, sous-estimation possible du risque réel.

Cas 178 — k-fold cross-validation. Qu'est-ce que la validation croisée en k plis (k-fold) ?

Solution. Diviser les données en k blocs, estimer sur k−1 et évaluer sur le bloc restant, en tournant : une estimation robuste de l'erreur de prévision.

Cas 179 — Parcimonie. Pourquoi préférer un modèle parcimonieux ?

Solution. Coefficients plus **stables**, moins de surajustement, meilleure généralisation hors échantillon, interprétation plus claire.

Cas 180 — Résumé sélection de modèle. Résumer les outils de sélection de modèle.

Solution. **Compromis biais-variance** ; critères **AIC** (prévision) et **BIC** (parcimonie) à minimiser ; **validation croisée** pour mesurer directement la prévision hors échantillon.

Bloc 10 --- Protocole de diagnostic et synthèse

Cas 181 — Le protocole en sept contrôles. Énumérer les sept contrôles du protocole de diagnostic.

Solution. (1) forme (RESET) ; (2) hétéroscédasticité (Breusch–Pagan/White) ; (3) autocorrélation (Durbin–Watson) ; (4) normalité (Jarque–Bera) ; (5) colinéarité (VIF) ; (6) influence (Cook) ; (7) stabilité (Chow).

Cas 182 — L'ordre des priorités. Dans quel ordre traiter les problèmes de diagnostic et pourquoi ?

Solution. **Biais d'abord** (spécification), puis **robustesse** (points influents), puis **efficacité** (SE robustes), enfin **précision/validité** (colinéarité, normalité). Le biais prime : il invalide tout le reste.

Cas 183 — Pourquoi le biais prime. Pourquoi traiter le biais avant l'efficacité ?

Solution. Corriger les SE (efficacité) d'un modèle **mal spécifié** (biais) donne une fausse assurance sur un modèle faux. Un coefficient biaisé invalide l'inférence.

Cas 184 — Contrôle 1 — forme. Quel diagnostic pour la forme fonctionnelle, et quel remède ?

Solution. **Graphe des résidus vs $\hat{Y}$ et test RESET** ; remède : transformer les variables, ajouter des termes (X^2, interactions).

Cas 185 — Contrôle 2 — hétéroscédasticité. Quel diagnostic pour l'hétéroscédasticité, et quel remède ?

Solution. **Breusch–Pagan, White, graphe en entonnoir** ; remède : erreurs-types de **White** (β inchangé).

Cas 186 — Contrôle 3 — autocorrélation. Quel diagnostic pour l'autocorrélation, et quel remède ?

Solution. **Durbin–Watson, Breusch–Godfrey** (séries temporelles) ; remède : erreurs-types de **Newey–West**.

Cas 187 — Contrôle 4 — normalité. Quel diagnostic pour la normalité, et quel remède ?

Solution. **Jarque–Bera, QQ-plot** ; remède (petit n) : méthodes **robustes** ou **bootstrap** (à grand n, le TCL supplée).

Cas 188 — Contrôle 5 — colinéarité. Quel diagnostic pour la multicolinéarité, et quel remède ?

Solution. **VIF, nombre de conditionnement** ; remède : retirer/combiner les régresseurs, plus de données, régularisation.

Cas 189 — Contrôle 6 — influence. Quel diagnostic pour les points influents, et quel remède ?

Solution. **Levier h_i, résidus studentisés, distance de Cook** ; remède : examiner (erreur ? régime ?), rapporter avec/sans, méthodes robustes.

Cas 190 — Contrôle 7 — stabilité. Quel diagnostic pour la stabilité, et quel remède ?

Solution. **Test de Chow** (date connue), CUSUM/Quandt (inconnue), fenêtre glissante ; remède : modéliser les régimes séparément.

Cas 191 — Biais vs efficacité — récapitulatif. Classer les problèmes en « biais » et « efficacité ».

Solution. **Biais** : variable omise, mauvaise forme, endogénéité. **Efficacité** : hétéroscédasticité, autocorrélation. (Colinéarité : précision ; influence : robustesse ; normalité : validité des tests.)

Cas 192 — Le fil rouge : surajustement. Quel fil rouge relie tous les diagnostics ?

Solution. La méfiance envers le **surajustement** : un R^2 éclatant en échantillon peut masquer un modèle qui épouse le bruit et prédit mal. Parcimonie et validation hors échantillon protègent.

Cas 193 — Un modèle non diagnostiqué. Que dire d'un modèle non diagnostiqué ?

Solution. C'est un modèle dont on **ignore s'il ment** : R^2 flatteur possible, SE faussées, coefficients biaisés ou dominés par des aberrants. Le diagnostic conditionne la confiance.

Cas 194 — White ou Newey–West — quand ?. White ou Newey–West : lequel selon le contexte ?

Solution. **White** : hétéroscédasticité en **coupe transversale**. **Newey–West** : hétéroscédasticité ET autocorrélation, typiquement en **séries temporelles**.

Cas 195 — Diagnostic différentiel. Pourquoi le chapitre 9 est-il un « diagnostic différentiel » ?

Solution. Il apprend à **distinguer** la nature de chaque problème (biais vs efficacité vs robustesse) pour appliquer le **bon remède** — comme un médecin distingue des symptômes proches.

Cas 196 — Chaîne Ch8 → Ch9. Comment le chapitre 9 prolonge-t-il le chapitre 8 ?

Solution. Il **approfondit et systématise** les problèmes esquissés au Ch8 (hétéroscédasticité, colinéarité, spécification) et ajoute les points influents, la normalité et les ruptures — la boîte à outils complète du diagnostic.

Cas 197 — La démarche de diagnostic. Résumer la démarche complète de diagnostic d'une régression.

Solution. Examiner les résidus ⟶ forme (RESET) ⟶ hétéroscédasticité (White) ⟶ autocorrélation (Newey–West) ⟶ normalité ⟶ colinéarité (VIF) ⟶ influence (Cook) ⟶ stabilité (Chow), en traitant le biais en priorité.

Cas 198 — Détection sans remède mécanique. Pourquoi ne pas corriger mécaniquement chaque diagnostic ?

Solution. Un symptôme (ex. autocorrélation) peut cacher un autre mal (mauvaise spécification) : **comprendre la cause** avant d'appliquer un remède évite de corriger la surface d'un problème profond.

Cas 199 — Transparence et robustesse. Quelle attitude générale le diagnostic recommande-t-il ?

Solution. **Transparence** (rapporter avec/sans points influents, montrer les tests) et **robustesse** (SE robustes, méthodes robustes) — plutôt que de masquer les défauts du modèle.

Cas 200 — La phrase de synthèse du chapitre. Résumer les diagnostics de régression en une phrase.

Solution. Les diagnostics vérifient les hypothèses via les résidus — distinguant biais (spécification $\Longrightarrow$ changer le modèle) et efficacité (hétéroscédasticité, autocorrélation $\Longrightarrow$ SE robustes) — et évaluent influence, normalité et stabilité, car un modèle non diagnostiqué est un modèle dont on ignore s'il ment.

Partie C --- Méthodologie, formulaire et astuces

Condensé de révision : toutes les formules des diagnostics de régression, un glossaire bilingue, le protocole en étapes et les pièges classiques.

C.1 --- Formulaire des diagnostics

Hétéroscédasticité et multicolinéarité

$$\mathrm{VIF}_j = \frac{1}{1-R_j^2}, \quad \mathrm{Tol}_j = 1 - R_j^2, \quad \mathrm{SE}(\hat{\beta}_j) \propto \sqrt{\mathrm{VIF}_j}; \qquad \kappa = \sqrt{\lambda_{\max}/\lambda_{\min}}.$$

Détection hétéroscédasticité : Breusch–Pagan, White $\Rightarrow$ SE de White (HC).

Autocorrélation

$$\mathrm{DW} = \frac{\sum_{i=2}^{n}(e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2} \approx 2(1-\hat{\rho}), \quad \mathrm{DW} \in [0,4]; \qquad \mathrm{DW} \approx 2 : \text{OK}.$$

Détection : Durbin–Watson, Breusch–Godfrey $\Rightarrow$ SE de Newey–West (HAC).

Points influents

$$h_i \in [0,1], \ \sum_i h_i = k+1, \ \text{seuil } h_i > \frac{2(k+1)}{n}; \qquad e_i^* = \frac{e_i}{s_{(i)}\sqrt{1-h_i}}.$$

$$D_i = \frac{(e_i^*)^2}{k+1} \cdot \frac{h_i}{1-h_i} \quad (\text{seuil } D_i > 1 \text{ ou } 4/n).$$

Normalité, spécification et stabilité

$$\mathrm{JB} = \frac{n}{6}\left(\hat{S}^2 + \frac{(\hat{K}-3)^2}{4}\right) \sim \chi^2_2; \qquad \text{RESET : ajouter } \hat{Y}^2, \hat{Y}^3 \ (\text{test } F).$$

$$\text{Chow} : F = \frac{(\mathrm{RSS}_c - \mathrm{RSS}_{nc})/(k+1)}{\mathrm{RSS}_{nc}/(n-2(k+1))} \sim F_{k+1,\, n-2(k+1)}.$$

Sélection de modèle

$$\mathrm{AIC} = n\ln(\mathrm{RSS}/n) + 2(k+1); \qquad \mathrm{BIC} = n\ln(\mathrm{RSS}/n) + (k+1)\ln n \quad (\text{minimiser}).$$

$$\text{Erreur de prévision} = \text{biais}^2 + \text{variance} + \text{bruit irréductible}.$$

C.2 --- Le tableau maître : biais vs efficacité vs robustesse

Problème	Détection	Effet sur $\hat{\beta}$	Remède
Mauvaise forme	RESET, graphe résidus	**Biaisé**	Transformer, ajouter termes
Variable omise	Théorie, résidus	**Biaisé**	Inclure / instrument
Hétéroscédasticité	Breusch–Pagan, White	Sans biais, SE fausses	SE de White

Problème	Détection	Effet sur $\hat{\beta}$	Remède
Autocorrélation	Durbin–Watson, B–G	Sans biais, SE fausses	SE de Newey–West
Non-normalité	Jarque–Bera, QQ-plot	Aucun (grand n)	Robuste / bootstrap
Multicolinéarité	VIF, cond. number	Sans biais, SE gonflées	Retirer / combiner
Points influents	Levier, Cook D_i	Peut dominer	Examiner / robuste
Rupture structurelle	Test de Chow	Instable	Régimes séparés

C.3 --- Carte de décision : quel symptôme, quel diagnostic ?

Symptôme observé	Diagnostic probable	Outil
Résidus en entonnoir	Hétéroscédasticité	Breusch–Pagan, White
Résidus en courbe/structure	Mauvaise forme	RESET de Ramsey
Résidus corrélés (temps)	Autocorrélation	Durbin–Watson
Queues épaisses, QQ courbé	Non-normalité	Jarque–Bera
F significatif, t faibles	Multicolinéarité	VIF, cond. number
Un point domine la pente	Influence	Cook D_i, levier
Coefficients qui dérivent	Instabilité	Chow, fenêtre glissante
Signe contre-intuitif	Colinéarité ou omission	VIF, théorie

C.4 --- Glossaire bilingue

Français	Anglais	Repère
Diagnostic de régression	Regression diagnostics	Vérifier les hypothèses
Hétéroscédasticité	Heteroskedasticity	Var non constante
Homoscédasticité	Homoskedasticity	Var constante
Erreurs-types robustes	Robust standard errors	White, Newey–West
Consistant avec l'hétéroscédasticité	Heteroskedasticity-consistent (HC)	White
Moindres carrés pondérés	Weighted least squares (WLS)	Poids $1/\sigma_i^2$
Moindres carrés généralisés	Generalized least squares (GLS)	Hétéro. + autocorr.
Facteur d'inflation de la variance	Variance inflation factor (VIF)	$1/(1-R_j^2)$
Tolérance	Tolerance	$1-R_j^2$
Nombre de conditionnement	Condition number	$\sqrt{\lambda_{\max}/\lambda_{\min}}$
Erreur de spécification	Specification error	Modèle $\neq$ vrai processus
Test RESET de Ramsey	Ramsey RESET test	Puissances de $\hat{Y}$
Point aberrant	Outlier	Grand résidu
Levier	Leverage	h_i, X extrême
Point influent	Influential point	Retrait modifie $\hat{\beta}$
Distance de Cook	Cook's distance	D_i

Français	Anglais	Repère
Résidu studentisé	Studentized residual	e_i^*
Diagramme quantile-quantile	QQ-plot	Normalité visuelle
Rupture structurelle	Structural break	Coefficients changeants
Test de Chow	Chow test	Égalité de coefficients
Somme cumulée	CUSUM	Rupture, date inconnue
Autocorrélation	Autocorrelation	$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) \neq 0$
Durbin–Watson	Durbin–Watson	$\approx 2(1-\hat{\rho})$
Breusch–Pagan	Breusch–Pagan	Hétéroscédasticité
Breusch–Godfrey	Breusch–Godfrey	Autocorr. ordres sup.
Compromis biais–variance	Bias–variance tradeoff	Sous/sur-ajustement
Validation croisée	Cross-validation	Hors échantillon
Surajustement	Overfitting	Épouse le bruit

C.5 --- Le protocole de diagnostic en sept contrôles

1. **Forme fonctionnelle.** Graphe des résidus contre $\hat{Y}$; test RESET de Ramsey. Si structure $\rightarrow$ transformer, ajouter X^2/interactions. (*Biais*)
2. **Hétéroscédasticité.** Graphe en entonnoir ; Breusch–Pagan, White. Si présente $\rightarrow$ erreurs-types de White. (*Efficacité*)
3. **Autocorrélation.** (Séries temporelles) Durbin–Watson (≈ 2 = OK), Breusch–Godfrey. Si présente $\rightarrow$ Newey–West. (*Efficacité*)
4. **Normalité.** Jarque–Bera, QQ-plot. À petit n non normal $\rightarrow$ robuste/bootstrap ; à grand n, TCL. (*Validité des tests*)
5. **Multicolinéarité.** VIF (> 5 = alerte), nombre de conditionnement. Si sévère $\rightarrow$ retirer/combiner, régularisation. (*Précision*)
6. **Points influents.** Levier h_i, résidus studentisés, distance de Cook ($D_i > 1$). Examiner, rapporter avec/sans, robuste. (*Robustesse*)
7. **Stabilité.** Test de Chow (date connue), CUSUM/Quandt (inconnue), fenêtre glissante. Si rupture $\rightarrow$ régimes séparés. (*Stabilité*)

Ordre des priorités : le *biais* d'abord (forme, omission), puis la *robustesse* (points influents), puis l'*efficacité* (hétéroscédasticité, autocorrélation), enfin la *précision/validité* (colinéarité, normalité). Un coefficient biaisé invalide tout le reste.

C.6 --- Les dix pièges classiques

À éviter absolument

(1) Croire que les SE robustes corrigent le *biais* : elles ne corrigent que l'*efficacité* ($\hat{\beta}$ inchangé).
(2) Penser que l'hétéroscédasticité ou l'autocorrélation *biaisent* $\hat{\beta}$: elles ne faussent que les SE.
(3) Confondre *levier* (X extrême) et *influence* : un fort levier sur la droite (petit résidu) n'est pas influent.
(4) Confondre *résidu grand* et *influence* : un aberrant au centre du nuage tire peu la pente.
(5) Supprimer un point uniquement parce qu'il gêne : manipulation, pas diagnostic.
(6) Corriger mécaniquement l'autocorrélation par Newey–West alors qu'elle cache une *mauvaise spécification*.
(7) Appliquer un WLS fondé sur une forme erronée de σ_i^2, ce qui *aggrave* le problème.

(**8**) Croire que le test RESET *diagnostique* le problème : il le *détecte* seulement (ni quelle variable, ni quelle forme).
(**9**) Appliquer un test de Chow sans *connaître* la date de rupture (utiliser CUSUM/Quandt sinon).
(**10**) S'alarmer de la non-normalité à grand n : le TCL protège l'inférence (problème seulement à petit n).

C.7 --- Astuces de calcul rapide

- **VIF depuis** R_j^2 : $1/(1-R_j^2)$; $R_j^2 = 0{,}9 \Rightarrow \text{VIF} = 10$; $0{,}95 \Rightarrow 20$; $0{,}75 \Rightarrow 4$.
- **Durbin–Watson depuis** $\hat{\rho}$: $\text{DW} \approx 2(1-\hat{\rho})$; $\hat{\rho} = 0 \Rightarrow 2$; $\hat{\rho} = 0{,}5 \Rightarrow 1$; $\hat{\rho} = -0{,}5 \Rightarrow 3$.
- **Seuil de levier** : $2(k+1)/n$; somme des leviers $= k+1$, moyenne $(k+1)/n$.
- **Distance de Cook** : $D_i > 1$ (règle simple) ou $D_i > 4/n$ (sensible) $\Rightarrow$ point influent.
- **Jarque–Bera** : $\sim \chi^2_2$, valeur critique $5{,}99$ à 5 % ; grand JB = queues épaisses ou asymétrie.
- **Chow** : cas du F conjoint ; ddl $(k+1,\ n-2(k+1))$; $\text{RSS}_{nc} = \text{RSS}_1 + \text{RSS}_2$.
- **White vs Newey–West** : coupe transversale $\rightarrow$ White ; série temporelle (autocorr.) $\rightarrow$ Newey–West.
- **AIC vs BIC** : BIC pénalise plus ($\ln n > 2$ dès $n > 7$) $\Rightarrow$ plus parcimonieux ; minimiser les deux.
- **Biais vs efficacité** : variable omise/forme $\rightarrow$ biais (changer le modèle) ; hétéro./autocorr. $\rightarrow$ efficacité (SE robustes).
- **RESET** : ajouter $\hat{Y}^2$, $\hat{Y}^3$; leur significativité conjointe (test F) $\Rightarrow$ mauvaise spécification.

Partie D --- 200 questions à choix multiple

200 questions de style examen, par thème et de difficulté croissante. Une seule réponse correcte. Corrigé commenté en Partie E.

Thème 1 --- Pourquoi diagnostiquer : hypothèses et enjeux

Q1. On ne juge jamais une régression sur son seul :

- (a) R^2
- (b) nombre d'observations
- (c) intercept
- (d) signe de la pente

Q2. L'exogénéité $E[\varepsilon|X]=0$ garantit :

- (a) l'efficacité
- (b) l'absence de biais de $\hat{\beta}$
- (c) la normalité
- (d) l'identifiabilité

Q3. L'homoscédasticité et l'absence d'autocorrélation garantissent :

- (a) l'absence de biais
- (b) la normalité
- (c) l'efficacité (SE correctes)
- (d) l'identifiabilité

Q4. La normalité des erreurs garantit :

- (a) l'absence de biais
- (b) l'efficacité
- (c) l'identifiabilité
- (d) la validité exacte des tests t/F à petit n

Q5. L'absence de colinéarité parfaite garantit :

- (a) l'identifiabilité des coefficients
- (b) l'absence de biais
- (c) l'efficacité
- (d) la normalité

Q6. La distinction cardinale du diagnostic oppose :

- (a) grand n et petit n
- (b) biais et efficacité
- (c) R^2 et pente
- (d) α et β

Q7. Un problème de biais exige :

- (a) des SE robustes
- (b) plus d'observations
- (c) de changer le modèle
- (d) un α plus petit

Q8. Un problème d'efficacité se corrige par :

- (a) changer le modèle
- (b) supprimer des points
- (c) augmenter le R^2
- (d) des erreurs-types robustes

Q9. Appliquer des SE robustes à un problème de variable omise :

- (a) laisse le biais intact (fausse assurance)
- (b) corrige le biais
- (c) améliore β
- (d) est optimal

Q10. Les résidus sont au cœur des diagnostics car :

- (a) ils égalent β
- (b) ils sont l'image empirique des erreurs inobservables
- (c) ils sont toujours nuls
- (d) ils mesurent le R^2

Q11. Une dispersion des résidus variant avec X révèle :

- (a) de l'autocorrélation
- (b) la non-normalité
- (c) de l'hétéroscédasticité
- (d) un biais

Q12. Une structure courbe dans les résidus révèle :

- (a) de l'hétéroscédasticité
- (b) de l'autocorrélation
- (c) la normalité
- (d) une erreur de forme fonctionnelle

Q13. Une distribution non normale des résidus affecte :

- (a) la validité des tests exacts à petit n
- (b) l'absence de biais
- (c) l'efficacité
- (d) l'identifiabilité

Q14. Une corrélation entre résidus successifs révèle :

- (a) de l'hétéroscédasticité
- (b) de l'autocorrélation
- (c) la non-normalité
- (d) un biais

Q15. Le diagnostic est :

- (a) une formalité de fin
- (b) optionnel
- (c) la condition de validité de toute inférence
- (d) sans importance

Q16. Un coefficient biaisé est irrécupérable sans :

- (a) des SE robustes
- (b) plus de données
- (c) un test t
- (d) changer le modèle

Q17. L'ordre de traitement des problèmes commence par :

- (a) le biais (spécification)
- (b) l'efficacité
- (c) la normalité
- (d) la colinéarité

Q18. Traiter l'efficacité avant le biais donne :

- (a) le meilleur modèle
- (b) une fausse assurance sur un modèle faux
- (c) aucun risque
- (d) un R^2 parfait

Q19. Les trois grandes menaces sont :

- (a) R^2, pente, intercept
- (b) α, β, puissance
- (c) hétéro./autocorr. (efficacité), spécification (biais), points influents (robustesse)
- (d) biais uniquement

Q20. La règle d'or du diagnostic est :

- (a) maximiser le R^2
- (b) ignorer les hypothèses
- (c) ajouter des régresseurs
- (d) examiner les résidus avant d'interpréter

Thème 2 --- Hétéroscédasticité : nature et détection

Q21. L'hétéroscédasticité est :

- (a) une variance des erreurs non constante
- (b) une corrélation des erreurs
- (c) une non-normalité
- (d) un biais

Q22. L'hétéroscédasticité biaise-t-elle β ?

- (a) Oui
- (b) Non (sans biais, mais plus BLUE)
- (c) seulement à petit n
- (d) seulement si k>2

Q23. Son effet sur les erreurs-types classiques :

- (a) elles sont exactes
- (b) elles augmentent β
- (c) elles sont biaisées (tests invalides)
- (d) aucun effet

Q24. L'hétéroscédasticité est la norme en finance car :

- (a) les rendements sont constants
- (b) β est biaisé
- (c) les données sont normales
- (d) la volatilité varie dans le temps (clustering)

Q25. Détecter graphiquement l'hétéroscédasticité :

- (a) tracer les résidus contre $\hat{Y}$ (motif en entonnoir)
- (b) compter les observations
- (c) tracer Y contre X seulement
- (d) regarder le R^2

Q26. Le test de Breusch–Pagan :

- (a) compare deux échantillons
- (b) régresse les résidus au carré sur les régresseurs
- (c) teste la normalité
- (d) mesure le levier

Q27. Le test de White est plus général car il inclut :

- (a) seulement l'intercept
- (b) la normalité
- (c) les carrés et produits croisés des régresseurs

- (d) le levier

Q28. L'hypothèse nulle des tests d'hétéroscédasticité est :

- (a) l'hétéroscédasticité
- (b) la normalité
- (c) l'indépendance
- (d) l'homoscédasticité (variance constante)

Q29. Ignorer l'hétéroscédasticité conduit à :

- (a) surestimer la significativité (faux positifs)
- (b) sous-estimer la significativité
- (c) biaiser β
- (d) améliorer le R^2

Q30. Une dispersion croissant avec $\hat{Y}$ signale :

- (a) de l'autocorrélation
- (b) de l'hétéroscédasticité
- (c) la normalité
- (d) un point influent

Q31. On trace les résidus au carré pour l'hétéroscédasticité car :

- (a) c'est plus rapide
- (b) cela normalise Y
- (c) le carré mesure la magnitude indépendamment du signe
- (d) cela réduit le biais

Q32. « Les MCO ne sont plus BLUE » signifie :

- (a) β biaisé
- (b) β non défini
- (c) R^2 nul
- (d) plus de variance minimale (WLS serait plus efficace)

Q33. Les erreurs d'un modèle de P&L croissent avec la taille des positions : c'est :

- (a) de l'hétéroscédasticité
- (b) de l'autocorrélation
- (c) de la colinéarité
- (d) de la non-normalité

Q34. Test formel ou graphique pour l'hétéroscédasticité :

- (a) seulement le test
- (b) les deux, complémentaires
- (c) seulement le graphique

- (d) aucun

Q35. Breusch–Pagan rejette H_0. Que faire ?

- (a) ignorer
- (b) supprimer des points
- (c) rapporter des SE robustes (White)
- (d) augmenter le R^2

Q36. L'hétéroscédasticité conditionnelle (ARCH) désigne :

- (a) une corrélation des X
- (b) une non-normalité
- (c) un biais
- (d) une variance dépendant des erreurs passées

Q37. Hétéroscédasticité et non-normalité sont :

- (a) deux problèmes distincts
- (b) le même problème
- (c) toujours liés
- (d) impossibles ensemble

Q38. Le test de Goldfeld–Quandt :

- (a) teste la normalité
- (b) compare la variance résiduelle de deux sous-groupes
- (c) mesure le levier
- (d) teste l'autocorrélation

Q39. L'hétéroscédasticité affecte la prévision ponctuelle $\hat{Y}$?

- (a) Oui, $\hat{Y}$ biaisé
- (b) aucun effet
- (c) Non ($\hat{Y}$ sans biais), mais les intervalles sont faussés
- (d) $\hat{Y}$ devient nul

Q40. Résumé hétéroscédasticité :

- (a) β biaisé, remède instruments
- (b) aucun effet
- (c) β non défini
- (d) β sans biais, SE faussées, remède SE de White

Thème 3 --- Remèdes à l'hétéroscédasticité et multicolinéarité

Q41. Les erreurs-types de White :

- (a) recalculent les SE sans supposer σ^2 constante (β inchangé)

- (b) ré-estiment β
- (c) supposent σ^2 connu
- (d) biaisent β

Q42. Les moindres carrés pondérés (WLS) :

- (a) suppriment les extrêmes
- (b) pondèrent chaque observation par $1/\sigma_i^2$
- (c) ignorent σ_i^2
- (d) biaisent β

Q43. White vs WLS :

- (a) identiques
- (b) WLS = SE corrigées
- (c) White = β inchangé + SE corrigées ; WLS = β ré-estimé + efficace
- (d) White = β ré-estimé

Q44. Les SE de White dominent en pratique car :

- (a) elles sont plus efficaces
- (b) elles ré-estiment β
- (c) elles suppriment le biais
- (d) elles ne demandent aucune hypothèse sur σ_i^2

Q45. Le risque d'un WLS mal spécifié :

- (a) une pondération incorrecte aggrave le problème
- (b) aucun risque
- (c) β devient biaisé toujours
- (d) le R^2 chute

Q46. Sous hétéroscédasticité, le problème est :

- (a) le coefficient
- (b) l'erreur-type, pas le coefficient
- (c) le R^2
- (d) l'intercept

Q47. WLS se justifie quand :

- (a) toujours
- (b) jamais
- (c) l'efficacité est cruciale ET σ_i^2 bien compris
- (d) si n est petit

Q48. Les moindres carrés généralisés (MCG) traitent :

- (a) seulement l'hétéroscédasticité

- (b) seulement l'autocorrélation
- (c) la non-normalité
- (d) hétéroscédasticité ET autocorrélation

Q49. Le VIF mesure la multicolinéarité par :

- (a) $1/(1-R_j^2)$
- (b) $1-R_j^2$
- (c) R_j^2
- (d) $\sqrt{R_j^2}$

Q50. $R_j^2=0{,}75$. Le VIF vaut :

- (a) 1,33
- (b) 4
- (c) 0,25
- (d) 3

Q51. $R_j^2=0{,}9$. Le VIF vaut :

- (a) 9
- (b) 1,9
- (c) 10
- (d) 0,1

Q52. La tolérance est :

- (a) R_j^2
- (b) VIF^2
- (c) $1+R_j^2$
- (d) $1-R_j^2 = 1/VIF$

Q53. Seuils du VIF :

- (a) VIF>5 alerte, VIF>10 sévère
- (b) VIF>1 alerte
- (c) VIF>0,5 sévère
- (d) VIF>100 alerte

Q54. Le nombre de conditionnement diagnostique :

- (a) un seul régresseur
- (b) la colinéarité globale (plusieurs régresseurs)
- (c) la normalité
- (d) le levier

Q55. VIF et nombre de conditionnement sont :

- (a) redondants

- (b) opposés
- (c) complémentaires (local vs global)
- (d) identiques

Q56. La multicolinéarité imparfaite biaise-t-elle β ?

- (a) Oui
- (b) seulement à petit n
- (c) seulement si k>5
- (d) Non (gonfle les SE)

Q57. Le triple symptôme de la multicolinéarité :

- (a) coefficients instables, t faibles malgré F significatif, signes contre-intuitifs
- (b) R^2 nul, biais, SE nulles
- (c) tout significatif
- (d) aucun

Q58. La multicolinéarité gêne-t-elle la prévision ?

- (a) toujours fatale
- (b) Souvent non (le modèle prédit bien)
- (c) impossible
- (d) améliore la prévision

Q59. La régression ridge traite la colinéarité en :

- (a) supprimant Y
- (b) augmentant k
- (c) ajoutant une pénalité (léger biais, forte baisse de variance)
- (d) biaisant fortement

Q60. L'erreur induite par la multicolinéarité :

- (a) surestimer le R^2
- (b) biaiser β
- (c) ignorer le F
- (d) conclure qu'une variable est inutile sur un t faible

Q61. La PCA aide contre la colinéarité en :

- (a) remplaçant les régresseurs par des composantes orthogonales
- (b) supprimant Y
- (c) augmentant k
- (d) biaisant β

Q62. Collecter plus de données atténue la colinéarité car :

- (a) cela supprime la corrélation

- (b) les SE décroissent en $1/\sqrt{n}$
- (c) cela biaise $\hat{\beta}$
- (d) cela augmente le R^2

Q63. La tolérance proche de 1 indique :

- (a) une forte colinéarité
- (b) un biais
- (c) une orthogonalité (faible colinéarité)
- (d) une non-normalité

Q64. R_j^2=0,95. Le VIF vaut :

- (a) 5
- (b) 0,05
- (c) 19
- (d) 20

Thème 4 --- Erreurs de spécification et test RESET

Q65. Une erreur de spécification est :

- (a) un écart entre modèle estimé et vrai processus
- (b) une erreur de calcul
- (c) un R^2 faible
- (d) une SE élevée

Q66. Une variable omise pertinente et corrélée :

- (a) gonfle seulement les SE
- (b) biaise $\hat{\beta}$ (biais d'omission)
- (c) est sans effet
- (d) améliore le $\bar{R}^2$

Q67. Une variable superflue :

- (a) biaise $\hat{\beta}$
- (b) est sans aucun effet
- (c) laisse $\hat{\beta}$ sans biais mais gonfle la variance
- (d) améliore l'efficacité

Q68. Une forme fonctionnelle incorrecte :

- (a) est sans effet
- (b) gonfle seulement les SE
- (c) améliore le R^2
- (d) biaise $\hat{\beta}$ et fausse l'interprétation

Q69. Le test RESET de Ramsey :

- (a) ajoute des puissances de $\hat{Y}$ ($\hat{Y}^2$, $\hat{Y}^3$) et teste leur significativité
- (b) compare deux échantillons
- (c) teste la normalité
- (d) mesure le levier

Q70. L'hypothèse nulle du test RESET :

- (a) la spécification est incorrecte
- (b) la spécification est correcte
- (c) la variance est constante
- (d) les erreurs sont normales

Q71. Le test RESET détecte mais ne dit pas :

- (a) s'il y a un problème
- (b) le R^2
- (c) quelle variable ni quelle forme corrigerait
- (d) la pente

Q72. La plus grave des erreurs de spécification :

- (a) la sur-spécification
- (b) la variable superflue
- (c) aucune
- (d) la sous-spécification (variable omise, biais)

Q73. La théorie aide à éviter les erreurs de spécification en :

- (a) désignant les variables pertinentes à inclure/exclure
- (b) maximisant le R^2
- (c) augmentant n
- (d) ignorant les résidus

Q74. Repérer graphiquement une forme incorrecte :

- (a) résidus aléatoires
- (b) structure systématique (courbe) dans les résidus
- (c) un R^2 élevé
- (d) un t significatif

Q75. Corriger une non-linéarité :

- (a) supprimer des observations
- (b) augmenter α
- (c) transformer les variables ou ajouter X^2, interactions
- (d) ignorer

Q76. Une variable omise peut se manifester comme :

- (a) de l'hétéroscédasticité toujours
- (b) un R^2=1
- (c) une SE nulle
- (d) de l'autocorrélation (symptôme, pas cause)

Q77. Le test RESET rejette H_0. Conclusion :

- (a) spécification incorrecte (non-linéarité ou omission)
- (b) spécification correcte
- (c) variance constante
- (d) normalité

Q78. Le compromis biais-variance guide la spécification en :

- (a) maximisant le R^2
- (b) minimisant biais^2+variance
- (c) minimisant n
- (d) ignorant la théorie

Q79. On ajoute $\hat{Y}^2$ et $\hat{Y}^3$ (pas des X^2) dans RESET car :

- (a) c'est plus rapide
- (b) cela teste la normalité
- (c) $\hat{Y}$ combine tous les régresseurs (non-linéarité générale)
- (d) cela réduit le biais

Q80. Ajouter une variable superflue augmente le R^2 brut mais :

- (a) le R^2 brut décroît
- (b) le $\bar{R}^2$ augmente toujours
- (c) aucun effet
- (d) le R^2 ajusté peut décroître

Q81. Soupçonner une variable omise :

- (a) résidus structurés, signes contre-intuitifs, théorie
- (b) R^2 élevé
- (c) t significatifs
- (d) SE faibles

Q82. Si une variable pertinente n'est pas mesurable :

- (a) l'ignorer
- (b) utiliser une variable proxy corrélée
- (c) une constante
- (d) le R^2

Q83. La bonne spécification dépend-elle de l'objectif ?

- (a) Non
- (b) seulement du R^2
- (c) Oui (interprétation : éviter le biais ; prévision : hors échantillon)
- (d) seulement de n

Q84. Résumé spécification :

- (a) toutes $\Longrightarrow$ biais
- (b) toutes $\Longrightarrow$ variance
- (c) aucun effet
- (d) omise $\Longrightarrow$ biais, superflue $\Longrightarrow$ variance, forme incorrecte $\Longrightarrow$ biais

Thème 5 --- Points aberrants, de levier et influents

Q85. Un point aberrant (outlier) a :

- (a) un résidu anormalement grand (Y loin de la droite)
- (b) un X extrême
- (c) une influence nulle
- (d) un levier nul par définition

Q86. Un point à fort levier a :

- (a) un résidu grand
- (b) un X extrême (loin de $\bar{x}$)
- (c) une influence garantie
- (d) un Y extrême

Q87. Un point influent est celui dont :

- (a) le résidu est nul
- (b) le X est central
- (c) le retrait modifie sensiblement β
- (d) l'influence est faible

Q88. Le levier h_i vérifie :

- (a) $\Sigma h_i = n$
- (b) $h_i < 0$ possible
- (c) $h_i > 1$ fréquent
- (d) $\Sigma h_i = k+1$, moyenne $(k+1)/n$

Q89. Le seuil de levier élevé est :

- (a) $h_i > 2(k+1)/n$
- (b) $h_i > 1/n$

- (c) $h_i > 0{,}5$ toujours
- (d) $h_i > k$

Q90. Un résidu studentisé tient compte :

- (a) seulement du signe
- (b) du levier (et exclut l'observation de l'estimation de s)
- (c) du R^2
- (d) de l'intercept

Q91. La distance de Cook D_i mesure :

- (a) seulement le résidu
- (b) seulement le levier
- (c) l'influence globale (résidu + levier combinés)
- (d) le R^2

Q92. Un point à fort levier mais sur la droite (petit résidu) :

- (a) est toujours influent
- (b) biaise $\hat{\beta}$
- (c) a un D_i élevé
- (d) a peu d'influence

Q93. Un aberrant au centre du nuage (h_i faible) :

- (a) tire peu la pente
- (b) domine l'estimation
- (c) a un D_i élevé
- (d) est toujours influent

Q94. L'influence est créée par :

- (a) le résidu seul
- (b) la combinaison grand résidu ET fort levier
- (c) le levier seul
- (d) un R^2 élevé

Q95. Seuils de la distance de Cook :

- (a) $D_i > 0{,}1$
- (b) $D_i > 10$
- (c) $D_i > 1$ (ou $4/n$)
- (d) $D_i < 0$

Q96. Une journée de crise peut déterminer un bêta car :

- (a) elle est ignorée
- (b) elle réduit le R^2

- (c) elle biaise toujours
- (d) rendement extrême (résidu) ET marché extrême (levier)

Q97. Première étape face à un point influent :

- (a) vérifier que ce n'est pas une erreur de saisie
- (b) le supprimer
- (c) l'ignorer
- (d) augmenter n

Q98. Si un point influent est réel, se demander :

- (a) s'il faut le doubler
- (b) s'il relève du processus ou d'un régime différent
- (c) le R^2
- (d) la pente

Q99. Rapporter des résultats sensibles à un point influent :

- (a) en le supprimant
- (b) en l'ignorant
- (c) avec et sans le point (transparence)
- (d) sans le mentionner

Q100. Réduire la sensibilité aux points influents :

- (a) maximiser le R^2
- (b) supprimer par confort
- (c) augmenter α
- (d) méthodes robustes (LAD, M-estimateurs, pondération)

Q101. Supprimer un point uniquement parce qu'il gêne :

- (a) relève de la manipulation
- (b) est une bonne pratique
- (c) améliore le modèle
- (d) est neutre

Q102. La somme des leviers Σh_i vaut :

- (a) n
- (b) k+1
- (c) k
- (d) 1

Q103. Un levier h_i proche de 1 signifie :

- (a) X central
- (b) résidu nul

- (c) X très éloigné du centre, influence potentielle maximale
- (d) aucune influence

Q104. Diagnostic d'influence complet :

- (a) le seul R^2
- (b) le seul t
- (c) la moyenne de Y
- (d) levier h_i + résidus studentisés + distance de Cook

Thème 6 --- Normalité des résidus

Q105. La normalité des erreurs est requise pour :

- (a) la validité exacte des tests t/F à petit n
- (b) l'absence de biais
- (c) l'efficacité
- (d) l'identifiabilité

Q106. À grand échantillon, la non-normalité est tolérable grâce :

- (a) à l'homoscédasticité
- (b) au théorème central limite
- (c) au R^2
- (d) à la colinéarité

Q107. Le test de Jarque–Bera sur les résidus :

- (a) compare deux variances
- (b) mesure le levier
- (c) $JB = (n/6)(\hat{S}^2 + (\hat{K}-3)^2/4) \sim \chi^2_2$
- (d) teste l'autocorrélation

Q108. $\hat{S}=0$, $\hat{K}=3$, $n=300$. La statistique JB vaut :

- (a) 5,99
- (b) 300
- (c) 150
- (d) 0

Q109. Le QQ-plot trace :

- (a) les quantiles des résidus contre les quantiles normaux
- (b) Y contre X
- (c) les résidus contre le temps
- (d) le R^2

Q110. Les résidus financiers sont non normaux car :

- (a) ils sont constants
- (b) ils héritent des queues épaisses et de l'asymétrie des rendements
- (c) β est biaisé
- (d) le R^2 est nul

Q111. À grand échantillon, la non-normalité des résidus est :

- (a) fatale
- (b) impossible
- (c) non alarmante (TCL)
- (d) toujours un biais

Q112. Valeur critique du test de Jarque–Bera à 5 % :

- (a) 3,84
- (b) 9,21
- (c) 1,96
- (d) 5,99

Q113. Le QQ-plot apporte, vs la statistique JB :

- (a) la visualisation de la nature de l'écart
- (b) une décision binaire
- (c) le R^2
- (d) la pente

Q114. La non-normalité affecte les IC exacts à petit n :

- (a) non
- (b) oui (le bootstrap offre une alternative)
- (c) seulement à grand n
- (d) jamais

Q115. Le bootstrap contourne la non-normalité en :

- (a) supposant la normalité
- (b) supprimant les extrêmes
- (c) rééchantillonnant pour estimer la distribution empirique
- (d) augmentant α

Q116. Un excès de kurtosis dans les résidus indique :

- (a) une asymétrie
- (b) une variance nulle
- (c) un biais
- (d) des queues épaisses (plus d'extrêmes)

Q117. Une asymétrie (skewness) des résidus indique :

- (a) une distribution non symétrique des erreurs
- (b) des queues épaisses
- (c) une variance constante
- (d) un levier élevé

Q118. $\hat{S}=-0{,}5$, $\hat{K}=7$, n=500. La statistique JB (≈ 354) conduit à :

- (a) ne pas rejeter
- (b) rejeter la normalité
- (c) conclure à la normalité
- (d) un résultat indéterminé

Q119. La normalité affecte-t-elle le biais de β ?

- (a) Oui
- (b) seulement à petit n
- (c) Non (β sans biais sans normalité)
- (d) seulement si k>2

Q120. Résumé normalité :

- (a) rôle = absence de biais
- (b) détection = VIF
- (c) remède = White
- (d) rôle = tests exacts à petit n ; détection = JB, QQ-plot ; remède = robuste/bootstrap

Thème 7 --- Autocorrélation des résidus

Q121. L'autocorrélation des erreurs est :

- (a) $\mathrm{Cov}(\varepsilon_i,\varepsilon_j)\neq 0$ pour $i\neq j$
- (b) $\mathrm{Var}(\varepsilon)$ non constante
- (c) une non-normalité
- (d) un biais

Q122. Autocorrélation positive vs négative :

- (a) l'inverse
- (b) positive = même signe (persistance) ; négative = alternance
- (c) identiques
- (d) sans différence

Q123. L'autocorrélation biaise-t-elle β ?

- (a) Oui
- (b) seulement à petit n
- (c) Non (fausse les SE)

- (d) seulement positive

Q124. La statistique de Durbin–Watson :

- (a) $DW \in [-1,1]$
- (b) $DW = \hat{\rho}$
- (c) $DW > 4$ fréquent
- (d) $DW \approx 2(1-\hat{\rho})$, $DW \in [0,4]$

Q125. $DW = 1{,}0$ correspond à :

- (a) $\hat{\rho} \approx 0{,}5$ (autocorrélation positive)
- (b) $\hat{\rho} \approx 0$
- (c) $\hat{\rho} \approx -0{,}5$
- (d) $\hat{\rho} \approx 1$

Q126. $DW = 2{,}6$ correspond à :

- (a) $\hat{\rho} \approx 0{,}3$
- (b) $\hat{\rho} \approx -0{,}3$ (autocorrélation négative)
- (c) $\hat{\rho} \approx 0$
- (d) $\hat{\rho} \approx -1$

Q127. DW proche de 0 signale :

- (a) pas d'autocorrélation
- (b) une forte négative
- (c) une forte autocorrélation positive
- (d) une non-normalité

Q128. DW proche de 4 signale :

- (a) pas d'autocorrélation
- (b) une forte positive
- (c) un biais
- (d) une forte autocorrélation négative

Q129. Le test de Breusch–Godfrey complète Durbin–Watson en :

- (a) détectant les ordres supérieurs
- (b) testant la normalité
- (c) mesurant le levier
- (d) testant l'hétéroscédasticité

Q130. Les erreurs-types de Newey–West sont :

- (a) robustes à la seule hétéroscédasticité
- (b) HAC (robustes à l'hétéroscédasticité ET l'autocorrélation)
- (c) robustes à la seule autocorrélation

- (d) non robustes

Q131. L'autocorrélation positive conduit à :

- (a) sous-affirmer
- (b) biaiser β
- (c) sur-affirmer la significativité (SE sous-estimées)
- (d) améliorer le R^2

Q132. White ou Newey–West :

- (a) l'inverse
- (b) identiques
- (c) aucun n'existe
- (d) White = coupe transversale ; Newey–West = séries temporelles

Q133. L'autocorrélation détectée n'est pas toujours le vrai problème car :

- (a) elle peut être le symptôme d'une mauvaise spécification
- (b) elle est toujours réelle
- (c) elle biaise β
- (d) elle augmente le R^2

Q134. Avant Newey–West, vérifier :

- (a) le R^2
- (b) que le modèle n'est pas mal spécifié
- (c) le nombre de régresseurs
- (d) la moyenne de Y

Q135. L'autocorrélation est fréquente sur séries temporelles car :

- (a) les données sont normales
- (b) β est biaisé
- (c) inertie économique, variables omises tendancielles
- (d) n est petit

Q136. Une limite de Durbin–Watson :

- (a) invalide à grand n
- (b) toujours indéterminé
- (c) ne mesure rien
- (d) invalide avec variable dépendante retardée

Q137. DW=0,4 indique :

- (a) $\hat{\rho} \approx 0{,}8$ (forte autocorrélation positive)
- (b) $\hat{\rho} \approx 0$
- (c) $\hat{\rho} \approx -0{,}8$

- (d) pas d'autocorrélation

Q138. Corriger les SE d'un modèle biaisé (mal spécifié) :

- (a) règle tout
- (b) ne règle rien (le biais demeure)
- (c) améliore β
- (d) est optimal

Q139. La zone d'indécision de Durbin–Watson vient de :

- (a) une erreur de calcul
- (b) la non-normalité
- (c) valeurs critiques dépendant des régresseurs (bornes d_L, d_U)
- (d) le levier

Q140. Résumé autocorrélation :

- (a) β biaisé, remède instruments
- (b) aucun effet
- (c) β non défini
- (d) β sans biais, SE faussées, remède Newey–West

Thème 8 --- Stabilité des coefficients et test de Chow

Q141. Une rupture structurelle est :

- (a) un changement des coefficients entre sous-périodes
- (b) une hétéroscédasticité
- (c) une non-normalité
- (d) un point aberrant

Q142. Le test de Chow compare :

- (a) deux variances
- (b) le modèle entier (contraint) aux modèles par sous-période (non contraint)
- (c) la normalité
- (d) le levier

Q143. La statistique du test de Chow est :

- (a) un χ^2
- (b) un t
- (c) F=((RSS_c−RSS_nc)/(k+1))/(RSS_nc/(n−2(k+1)))
- (d) RSS_nc/RSS_c

Q144. RSS_c=500, RSS_1=180, RSS_2=200, n=60, k=2. Le F de Chow ≈ :

- (a) 2,84

- (b) 1,90
- (c) 10
- (d) 5,68

Q145. Le test de Chow est un cas du :

- (a) test F conjoint (égalité de coefficients entre groupes)
- (b) test t
- (c) test de normalité
- (d) test d'hétéroscédasticité

Q146. RSS_nc dans le test de Chow vaut :

- (a) RSS du modèle unique
- (b) RSS_1+RSS_2 (deux régressions séparées)
- (c) RSS_1 seulement
- (d) zéro

Q147. Le test de Chow rejette H_0. Que faire ?

- (a) ignorer
- (b) supprimer des points
- (c) modéliser les régimes séparément (ou dummies temporelles)
- (d) augmenter le R^2

Q148. L'hypothèse nulle du test de Chow :

- (a) les coefficients diffèrent
- (b) la variance est constante
- (c) les erreurs sont normales
- (d) les coefficients sont égaux entre sous-périodes

Q149. Appliquer Chow au bêta autour d'un choc :

- (a) tester l'égalité du bêta avant/après
- (b) maximiser le R^2
- (c) supprimer le choc
- (d) ignorer

Q150. La principale limite du test de Chow :

- (a) il est trop lent
- (b) il exige de connaître la date de rupture
- (c) il ne mesure rien
- (d) il biaise $\hat{\beta}$

Q151. Les tests CUSUM et de Quandt :

- (a) testent la normalité

- (b) mesurent le levier
- (c) détectent une rupture sans en connaître la date
- (d) testent l'hétéroscédasticité

Q152. La stabilité est cruciale pour la prévision car :

- (a) cela augmente le R^2
- (b) cela réduit n
- (c) c'est sans effet
- (d) un modèle aux paramètres dérivants prédit mal

Q153. Un modèle de VaR calibré en régime calme :

- (a) sous-estime le risque en régime agité
- (b) surestime toujours
- (c) est robuste
- (d) n'a pas d'erreur

Q154. Un coefficient significatif sur un long historique hétérogène :

- (a) est toujours fiable
- (b) peut être un artefact de régimes mélangés
- (c) prouve la causalité
- (d) a un $R^2=1$

Q155. L'estimation par fenêtre glissante sert à :

- (a) maximiser le R^2
- (b) supprimer les extrêmes
- (c) visualiser la dérive des coefficients dans le temps
- (d) tester la normalité

Q156. Les degrés de liberté du test de Chow :

- (a) $n-2$ et $n-1$
- (b) k et $n-k$
- (c) 1 et n
- (d) numérateur $k+1$, dénominateur $n-2(k+1)$

Q157. Modéliser une rupture sans deux régressions séparées :

- (a) dummy de période + interactions avec les régresseurs
- (b) supprimer une période
- (c) augmenter α
- (d) ignorer

Q158. Pourquoi RSS_c $\geq$ RSS_nc dans le test de Chow ?

- (a) c'est faux

- (b) le modèle contraint a moins de liberté d'ajustement
- (c) car RSS_c=0
- (d) car q=0

Q159. Chow ou CUSUM/Quandt :

- (a) l'inverse
- (b) identiques
- (c) Chow = date connue ; CUSUM/Quandt = date inconnue
- (d) aucun n'existe

Q160. Une rupture affectant seulement l'ordonnée se teste par :

- (a) un test de normalité
- (b) le VIF
- (c) le levier
- (d) une dummy de période (sans interactions)

Q161. Le test de Chow de base compare :

- (a) deux sous-périodes (généralisable à plusieurs)
- (b) une seule période
- (c) toujours dix périodes
- (d) aucune

Q162. Contrainte de taille du test de Chow :

- (a) n_j>1000
- (b) chaque sous-période doit avoir n_j>k+1
- (c) aucune contrainte
- (d) n_j<k

Q163. Une rupture structurelle rend les coefficients :

- (a) biaisés toujours
- (b) non identifiés
- (c) instables (variables selon le régime)
- (d) nuls

Q164. Résumé stabilité :

- (a) rupture = hétéroscédasticité
- (b) détection = VIF
- (c) remède = White
- (d) rupture = coefficients changeants ; détection = Chow/CUSUM ; remède = régimes séparés

Thème 9 --- Compromis biais--variance et sélection de modèle

Q165. L'erreur de prévision se décompose en :

- (a) biais^2 + variance + bruit irréductible
- (b) biais + R^2
- (c) variance seulement
- (d) biais seulement

Q166. Le critère AIC vaut :

- (a) $n\cdot\ln(RSS/n)+(k+1)\ln n$
- (b) $n\cdot\ln(RSS/n)+2(k+1)$
- (c) $1-RSS/TSS$
- (d) RSS/n

Q167. Le critère BIC vaut :

- (a) $n\cdot\ln(RSS/n)+2(k+1)$
- (b) R^2/k
- (c) $n\cdot\ln(RSS/n)+(k+1)\cdot\ln n$
- (d) $1-RSS/n$

Q168. Le BIC pénalise les paramètres :

- (a) moins que l'AIC
- (b) autant
- (c) pas du tout
- (d) plus que l'AIC (facteur $\ln n$)

Q169. La validation croisée :

- (a) estime sur une partie, évalue sur l'autre
- (b) maximise le R^2 en échantillon
- (c) supprime les extrêmes
- (d) teste la normalité

Q170. Maximiser le R^2 conduit au surajustement car :

- (a) le R^2 décroît
- (b) empiler les régresseurs fait épouser le bruit
- (c) les SE chutent
- (d) β se stabilise

Q171. Trois protections contre le surajustement :

- (a) R^2 brut, n, α
- (b) seulement le R^2
- (c) R^2 ajusté, AIC/BIC, validation croisée

- (d) seulement la théorie

Q172. Le lien surajustement / tests multiples :

- (a) aucun lien
- (b) les tests multiples aident
- (c) le R^2 est fiable
- (d) chercher le meilleur modèle sur les mêmes données $\Longrightarrow$ relations fallacieuses

Q173. Le BIC est « cohérent » signifie :

- (a) il retrouve le vrai modèle quand $n \to \infty$
- (b) il maximise le R^2
- (c) il minimise n
- (d) il est toujours faux

Q174. L'AIC est « efficace » signifie :

- (a) il retrouve le vrai modèle
- (b) il minimise l'erreur de prévision asymptotiquement
- (c) il maximise le R^2
- (d) il minimise k

Q175. Choisir entre AIC et BIC :

- (a) toujours AIC
- (b) toujours BIC
- (c) selon l'objectif (prévision : AIC ; parcimonie : BIC)
- (d) au hasard

Q176. AIC/BIC vont plus loin que le R^2 ajusté car :

- (a) ils ignorent la complexité
- (b) ils maximisent le R^2
- (c) ils sont identiques
- (d) pénalités plus explicites et fondées

Q177. Un modèle sur-paramétré en gestion des risques :

- (a) donne une fausse confiance
- (b) est toujours meilleur
- (c) élimine le risque
- (d) n'a pas d'erreur

Q178. La validation croisée en k plis (k-fold) :

- (a) utilise tout l'échantillon pour estimer
- (b) divise en k blocs, estime sur $k-1$, évalue sur 1, en tournant
- (c) supprime des blocs

- (d) teste la normalité

Q179. Préférer un modèle parcimonieux car :

- (a) toujours un R^2 plus élevé
- (b) aucune erreur
- (c) coefficients stables, meilleure généralisation
- (d) plus de biais

Q180. Résumé sélection de modèle :

- (a) maximiser le R^2 brut
- (b) ignorer la complexité
- (c) un seul critère
- (d) biais-variance ; AIC (prévision), BIC (parcimonie) à minimiser ; validation croisée

Thème 10 --- Protocole de diagnostic et synthèse

Q181. Le protocole de diagnostic comprend :

- (a) forme, hétéroscédasticité, autocorrélation, normalité, colinéarité, influence, stabilité
- (b) seulement le R^2
- (c) seulement les tests t
- (d) seulement l'intercept

Q182. L'ordre des priorités est :

- (a) efficacité → biais
- (b) biais → robustesse → efficacité → précision/validité
- (c) normalité en premier
- (d) au hasard

Q183. Le biais prime car :

- (a) c'est plus rapide
- (b) le R^2 augmente
- (c) corriger les SE d'un modèle mal spécifié donne une fausse assurance
- (d) les SE sont exactes

Q184. Diagnostic de la forme et remède :

- (a) VIF ; retirer
- (b) Durbin–Watson ; Newey–West
- (c) Jarque–Bera ; bootstrap
- (d) RESET + graphe des résidus ; transformer/ajouter des termes

Q185. Diagnostic de l'hétéroscédasticité et remède :

- (a) Breusch–Pagan/White ; SE de White

- (b) RESET ; transformer
- (c) Chow ; régimes
- (d) VIF ; retirer

Q186. Diagnostic de l'autocorrélation et remède :

- (a) White ; WLS
- (b) Durbin–Watson/Breusch–Godfrey ; SE de Newey–West
- (c) RESET ; ajouter
- (d) VIF ; combiner

Q187. Diagnostic de l'influence et remède :

- (a) VIF ; retirer
- (b) RESET ; transformer
- (c) levier/Cook ; examiner, robuste
- (d) JB ; bootstrap

Q188. Classer les problèmes : biais vs efficacité :

- (a) l'inverse
- (b) tous biais
- (c) tous efficacité
- (d) biais = omise/forme/endogénéité ; efficacité = hétéro./autocorr.

Q189. Le fil rouge reliant tous les diagnostics :

- (a) la méfiance envers le surajustement
- (b) maximiser le R^2
- (c) ignorer les résidus
- (d) ajouter des régresseurs

Q190. Un modèle non diagnostiqué est :

- (a) toujours fiable
- (b) un modèle dont on ignore s'il ment
- (c) optimal
- (d) sans erreur

Q191. White ou Newey–West selon le contexte :

- (a) l'inverse
- (b) identiques
- (c) White = coupe transversale ; Newey–West = séries temporelles
- (d) aucun

Q192. Le chapitre 9 est un « diagnostic différentiel » car :

- (a) il maximise le R^2

- (b) il ignore les causes
- (c) il supprime les points
- (d) il distingue la nature de chaque problème pour le bon remède

Q193. Pourquoi ne pas corriger mécaniquement chaque diagnostic ?

- (a) un symptôme peut cacher un autre mal (ex. mauvaise spécification)
- (b) c'est plus rapide
- (c) le R^2 augmente
- (d) aucune raison

Q194. Résumé du chapitre 9 :

- (a) maximiser le R^2
- (b) vérifier les hypothèses via les résidus ; distinguer biais et efficacité ; évaluer influence, normalité, stabilité
- (c) un seul test suffit
- (d) ignorer les résidus

Q195. Diagnostic de la colinéarité et remède :

- (a) RESET ; transformer
- (b) Chow ; régimes
- (c) VIF/nombre de conditionnement ; retirer, combiner, régulariser
- (d) JB ; bootstrap

Q196. Diagnostic de la normalité et remède :

- (a) VIF ; retirer
- (b) White ; WLS
- (c) Chow ; régimes
- (d) Jarque–Bera/QQ-plot ; robuste ou bootstrap (petit n)

Q197. Diagnostic de la stabilité et remède :

- (a) test de Chow/CUSUM ; modéliser les régimes séparément
- (b) VIF ; retirer
- (c) RESET ; transformer
- (d) JB ; bootstrap

Q198. La compétence diagnostique fondamentale est :

- (a) mémoriser le R^2
- (b) savoir lire un graphe de résidus
- (c) compter les régresseurs
- (d) ignorer les hypothèses

Q199. Le chapitre 9 prolonge le chapitre 8 en :

- (a) revenant à un régresseur

- (b) supprimant les tests
- (c) approfondissant et systématisant les problèmes esquissés + points influents, normalité, ruptures
- (d) ignorant le R^2

Q200. L'attitude générale recommandée par le diagnostic :

- (a) masquer les défauts
- (b) maximiser le R^2 à tout prix
- (c) supprimer les observations gênantes
- (d) transparence (avec/sans points) et robustesse (SE robustes)

Partie E --- Corrigé commenté des 200 QCM

Réponse correcte en gras suivie de l'explication. Distribution équilibrée (50 a, 50 b, 50 c, 50 d).

Thème 1 --- Pourquoi diagnostiquer : hypothèses et enjeux

Q1 — (a) R^2. Un R^2 élevé peut masquer SE faussées ou biais.

Q2 — (b) l'absence de biais de β. Sa violation biaise le coefficient.

Q3 — (c) l'efficacité (SE correctes). Leur violation fausse les SE.

Q4 — (d) la validité exacte des tests t/F à petit n. TCL à grand n.

Q5 — (a) l'identifiabilité des coefficients. Sinon X^TX non inversible.

Q6 — (b) biais et efficacité. Change le modèle vs SE robustes.

Q7 — (c) de changer le modèle. Aucune SE robuste ne corrige un coefficient faux.

Q8 — (d) des erreurs-types robustes. β était bon.

Q9 — (a) laisse le biais intact (fausse assurance). Erreur de diagnostic.

Q10 — (b) ils sont l'image empirique des erreurs inobservables. Ampleur, structure, distribution, corrélation.

Q11 — (c) de l'hétéroscédasticité. Motif en entonnoir.

Q12 — (d) une erreur de forme fonctionnelle. Le linéaire capte mal.

Q13 — (a) la validité des tests exacts à petit n. TCL à grand n.

Q14 — (b) de l'autocorrélation. Fréquent sur séries temporelles.

Q15 — (c) la condition de validité de toute inférence. Modèle non diagnostiqué = on ignore s'il ment.

Q16 — (d) changer le modèle. Le biais est structurel.

Q17 — (a) le biais (spécification). Le biais prime.

Q18 — (b) une fausse assurance sur un modèle faux. SE correctes autour d'un coefficient biaisé.

Q19 — (c) hétéro./autocorr. (efficacité), spécification (biais), points influents (robustesse). Trois catégories.

Q20 — (d) examiner les résidus avant d'interpréter. Validité de l'inférence.

Thème 2 --- Hétéroscédasticité : nature et détection

Q21 — (a) une variance des erreurs non constante. $\mathrm{Var}(\varepsilon_i|X_i)=\sigma_i^2$ dépend de X.

Q22 — (b) Non (sans biais, mais plus BLUE). Efficacité perdue.

Q23 — (c) elles sont biaisées (tests invalides). Souvent trop optimistes.

Q24 — (d) la volatilité varie dans le temps (clustering). On la suppose par défaut.

Q25 — (a) tracer les résidus contre $\hat{Y}$ (motif en entonnoir). Entonnoir = hétéroscédasticité.

Q26 — (b) régresse les résidus au carré sur les régresseurs. H_0 : variance constante.

Q27 — (c) les carrés et produits croisés des régresseurs. Aucune forme présupposée.

Q28 — (d) l'homoscédasticité (variance constante). Rejet $\Longrightarrow$ SE robustes.

Q29 — (a) surestimer la significativité (faux positifs). SE sous-estimées.

Q30 — (b) de l'hétéroscédasticité. Remède : SE de White.

Q31 — (c) le carré mesure la magnitude indépendamment du signe. Tendance de e_i^2 selon X.

Q32 — (d) plus de variance minimale (WLS serait plus efficace). Restent sans biais.

Q33 — (a) de l'hétéroscédasticité. Variance non constante.

Q34 — (b) les deux, complémentaires. Nature vs décision.

Q35 — (c) rapporter des SE robustes (White). SE classiques invalides.

Q36 — (d) une variance dépendant des erreurs passées. Clustering, modélisé par ARCH/GARCH.

Q37 — (a) deux problèmes distincts. Variance vs forme de distribution.

Q38 — (b) compare la variance résiduelle de deux sous-groupes. Rapport élevé $\Longrightarrow$ hétéroscédasticité.

Q39 — (c) Non ($\hat{Y}$ sans biais), mais les intervalles sont faussés. β correct.

Q40 — (d) β sans biais, SE faussées, remède SE de White. Détection : Breusch–Pagan, White.

Thème 3 --- Remèdes à l'hétéroscédasticité et multicolinéarité

Q41 — (a) recalculent les SE sans supposer σ^2 constante (β inchangé). HC, standard en pratique.

Q42 — (b) pondèrent chaque observation par $1/\sigma_i^2$. Restaurent BLUE si σ_i^2 connu.

Q43 — (c) White = β inchangé + SE corrigées ; WLS = β ré-estimé + efficace. WLS exige de connaître σ_i^2.

Q44 — (d) elles ne demandent aucune hypothèse sur σ_i^2. Robustes, simples.

Q45 — (a) une pondération incorrecte aggrave le problème. White évite ce risque.

Q46 — (b) l'erreur-type, pas le coefficient. β sans biais.

Q47 — (c) l'efficacité est cruciale ET σ_i^2 bien compris. Sinon White suffit.

Q48 — (d) hétéroscédasticité ET autocorrélation. Généralisation de WLS.

Q49 — (a) $1/(1-R_j^2)$. R_j^2 = X_j sur les autres.

Q50 — (b) 4. $1/(1-0{,}75)$.

Q51 — (c) 10. $1/(1-0{,}9)$.

Q52 — (d) $1-R_j^2 = 1/VIF$. Proche de 0 $\Longrightarrow$ forte colinéarité.

Q53 — (a) VIF>5 alerte, VIF>10 sévère. VIF=1 : orthogonalité.

Q54 — (b) la colinéarité globale (plusieurs régresseurs). κ>30 : problème.

Q55 — (c) complémentaires (local vs global). κ capte les colinéarités multiples.

Q56 — (d) Non (gonfle les SE). Les MCO restent BLUE.

Q57 — (a) coefficients instables, t faibles malgré F significatif, signes contre-intuitifs. Perte de précision.

Q58 — (b) Souvent non (le modèle prédit bien). Gêne l'interprétation.

Q59 — (c) ajoutant une pénalité (léger biais, forte baisse de variance). Compromis biais-variance favorable.

Q60 — (d) conclure qu'une variable est inutile sur un t faible. Effet réel mais mal identifié.

Q61 — (a) remplaçant les régresseurs par des composantes orthogonales. Au prix de l'interprétabilité.

Q62 — (b) les SE décroissent en $1/\sqrt{n}$. Compense l'inflation.

Q63 — (c) une orthogonalité (faible colinéarité). $1-R_j^2$ élevé.

Q64 — (d) 20. $1/(1-0{,}95)$.

Thème 4 --- Erreurs de spécification et test RESET

Q65 — (a) un écart entre modèle estimé et vrai processus. Omise, superflue, ou forme incorrecte.

Q66 — (b) biaise β (biais d'omission). Contamine les coefficients inclus.

Q67 — (c) laisse β sans biais mais gonfle la variance. Perte d'efficacité.

Q68 — (d) biaise β et fausse l'interprétation. Linéaire pour une relation courbe.

Q69 — (a) ajoute des puissances de $\hat{Y}$ ($\hat{Y}^2$, $\hat{Y}^3$) et teste leur significativité. Détection de mauvaise forme.

Q70 — (b) la spécification est correcte. Rejet $\Longrightarrow$ non-linéarité/omission.

Q71 — (c) quelle variable ni quelle forme corrigerait. Test de détection, pas de diagnostic précis.

Q72 — (d) la sous-spécification (variable omise, biais). Biais irrécupérable.

Q73 — (a) désignant les variables pertinentes à inclure/exclure. Guide au-delà des statistiques.

Q74 — (b) structure systématique (courbe) dans les résidus. Le linéaire ne capte pas tout.

Q75 — (c) transformer les variables ou ajouter X^2, interactions. Reste linéaire en β.

Q76 — (d) de l'autocorrélation (symptôme, pas cause). Effet structuré dans les résidus.

Q77 — (a) spécification incorrecte (non-linéarité ou omission). Explorer transformations/termes.

Q78 — (b) minimisant biais^2+variance. Sous vs sur-spécification.

Q79 — (c) $\hat{Y}$ combine tous les régresseurs (non-linéarité générale). Test global de mauvaise forme.

Q80 — (d) le R^2 ajusté peut décroître. Signe qu'elle n'apporte rien.

Q81 — (a) résidus structurés, signes contre-intuitifs, théorie. Un facteur connu est-il absent ?

Q82 — (b) utiliser une variable proxy corrélée. Réduit le biais d'omission.

Q83 — (c) Oui (interprétation : éviter le biais ; prévision : hors échantillon). Objectifs distincts.

Q84 — (d) omise $\Longrightarrow$ biais, superflue $\Longrightarrow$ variance, forme incorrecte $\Longrightarrow$ biais. Détection : RESET, résidus, théorie.

Thème 5 --- Points aberrants, de levier et influents

Q85 — (a) un résidu anormalement grand (Y loin de la droite). Aberrance en Y.

Q86 — (b) un X extrême (loin de $\bar{x}$). Mesuré par h_i.

Q87 — (c) le retrait modifie sensiblement β. Souvent aberrant ET à fort levier.

Q88 — (d) $\Sigma h_i = k+1$, moyenne $(k+1)/n$. $h_i \in [0,1]$.

Q89 — (a) $h_i > 2(k+1)/n$. Deux fois la moyenne.

Q90 — (b) du levier (et exclut l'observation de l'estimation de s). Repère les vrais aberrants.

Q91 — (c) l'influence globale (résidu + levier combinés). $D_i > 1$: point influent.

Q92 — (d) a peu d'influence. Levier seul ≠ influence.

Q93 — (a) tire peu la pente. Résidu seul ≠ influence.

Q94 — (b) la combinaison grand résidu ET fort levier. Capturée par Cook.

Q95 — (c) $D_i > 1$ (ou $4/n$). Point influent à examiner.

Q96 — (d) rendement extrême (résidu) ET marché extrême (levier). Distance de Cook élevée.

Q97 — (a) vérifier que ce n'est pas une erreur de saisie. Si erreur, corriger.

Q98 — (b) s'il relève du processus ou d'un régime différent. Crise, événement exceptionnel.

Q99 — (c) avec et sans le point (transparence). Transparence.

Q100 — (d) méthodes robustes (LAD, M-estimateurs, pondération). Moins sensibles aux extrêmes.

Q101 — (a) relève de la manipulation. Le comprendre relève du métier.

Q102 — (b) k+1. Levier moyen $(k+1)/n$.

Q103 — (c) X très éloigné du centre, influence potentielle maximale. La droite passe presque par ce point.

Q104 — (d) levier h_i + résidus studentisés + distance de Cook. Identifient les observations dominantes.

Thème 6 --- Normalité des résidus

Q105 — (a) la validité exacte des tests t/F à petit n. BLUE tient sans elle.

Q106 — (b) au théorème central limite. Inférence asymptotiquement valide.

Q107 — (c) $JB=(n/6)(\hat{S}^2+(\hat{K}-3)^2/4) \sim \chi^2_2$. H_0 : normalité.

Q108 — (d) 0. Résidus parfaitement normaux.

Q109 — (a) les quantiles des résidus contre les quantiles normaux. Alignement = normalité.

Q110 — (b) ils héritent des queues épaisses et de l'asymétrie des rendements. Jarque–Bera les rejette.

Q111 — (c) non alarmante (TCL). À petit n : robuste/bootstrap.

Q112 — (d) 5,99. $\chi^2_{2;0,95}$.

Q113 — (a) la visualisation de la nature de l'écart. Queues, asymétrie, atypiques.

Q114 — (b) oui (le bootstrap offre une alternative). IC exacts reposent sur la normalité.

Q115 — (c) rééchantillonnant pour estimer la distribution empirique. Sans hypothèse de loi.

Q116 — (d) des queues épaisses (plus d'extrêmes). Fréquent en finance.

Q117 — (a) une distribution non symétrique des erreurs. Terme $\hat{S}^2$ de JB.

Q118 — (b) rejeter la normalité. $354 \gg 5{,}99$.

Q119 — (c) Non (β sans biais sans normalité). Concerne les tests, pas le biais.

Q120 — (d) rôle = tests exacts à petit n ; détection = JB, QQ-plot ; remède = robuste/bootstrap. TCL à grand n.

Thème 7 --- Autocorrélation des résidus

Q121 — (a) $Cov(\varepsilon_i,\varepsilon_j)\neq 0$ pour $i\neq j$. Erreurs corrélées entre observations.

Q122 — (b) positive = même signe (persistance) ; négative = alternance. Signes successifs.

Q123 — (c) Non (fausse les SE). β sans biais, consistant.

Q124 — (d) $DW\approx 2(1-\hat{\rho})$, $DW\in[0,4]$. ≈2 : pas d'autocorrélation.

Q125 — (a) $\hat{\rho}\approx 0{,}5$ (autocorrélation positive). $DW=2(1-\rho)$.

Q126 — (b) $\hat{\rho}\approx -0{,}3$ (autocorrélation négative). $DW>2$: négative.

Q127 — (c) une forte autocorrélation positive. $\hat{\rho}\approx 1$, SE fortement sous-estimées.

Q128 — (d) une forte autocorrélation négative. $\hat{\rho}\approx -1$.

Q129 — (a) détectant les ordres supérieurs. Même avec régresseurs retardés.

Q130 — (b) HAC (robustes à l'hétéroscédasticité ET l'autocorrélation). β inchangé.

Q131 — (c) sur-affirmer la significativité (SE sous-estimées). t artificiellement grands.

Q132 — (d) White = coupe transversale ; Newey–West = séries temporelles. Autocorrélation $\Longrightarrow$ Newey–West.

Q133 — (a) elle peut être le symptôme d'une mauvaise spécification. Variable omise, forme incorrecte.

Q134 — (b) que le modèle n'est pas mal spécifié. Corriger à la racine.

Q135 — (c) inertie économique, variables omises tendancielles. Chocs persistants.

Q136 — (d) invalide avec variable dépendante retardée. Breusch–Godfrey préféré.

Q137 — (a) $\hat{\rho}\approx 0{,}8$ (forte autocorrélation positive). $DW = 2(1-0{,}8)$.

Q138 — (b) ne règle rien (le biais demeure). Traiter la cause d'abord.

Q139 — (c) valeurs critiques dépendant des régresseurs (bornes d_L, d_U). Entre les bornes : indéterminé.

Q140 — (d) β sans biais, SE faussées, remède Newey–West. Détection : DW, Breusch–Godfrey.

Thème 8 --- Stabilité des coefficients et test de Chow

Q141 — (a) un changement des coefficients entre sous-périodes. Coefficients constants échoue.

Q142 — (b) le modèle entier (contraint) aux modèles par sous-période (non contraint). Égalité des coefficients.

Q143 — (c) F=((RSS_c−RSS_nc)/(k+1))/(RSS_nc/(n−2(k+1))). $RSS_nc = RSS_1 + RSS_2$.

Q144 — (d) 5,68. $((500-380)/3)/(380/54)$.

Q145 — (a) test F conjoint (égalité de coefficients entre groupes). Restrictions linéaires.

Q146 — (b) RSS_1+RSS_2 (deux régressions séparées). Modèle non contraint.

Q147 — (c) modéliser les régimes séparément (ou dummies temporelles). Rupture confirmée.

Q148 — (d) les coefficients sont égaux entre sous-périodes. Rejet = instabilité.

Q149 — (a) tester l'égalité du bêta avant/après. Le risque systématique a-t-il changé ?

Q150 — (b) il exige de connaître la date de rupture. CUSUM/Quandt la recherchent.

Q151 — (c) détectent une rupture sans en connaître la date. Date endogène.

Q152 — (d) un modèle aux paramètres dérivants prédit mal. Extrapole une relation caduque.

Q153 — (a) sous-estime le risque en régime agité. Changement de régime.

Q154 — (b) peut être un artefact de régimes mélangés. Tester la stabilité.

Q155 — (c) visualiser la dérive des coefficients dans le temps. Diagnostic de stabilité.

Q156 — (d) numérateur k+1, dénominateur n−2(k+1). Deux modèles de k+1 paramètres.

Q157 — (a) dummy de période + interactions avec les régresseurs. Interactions captent le changement d'effet.

Q158 — (b) le modèle contraint a moins de liberté d'ajustement. Le F mesure si l'écart est significatif.

Q159 — (c) Chow = date connue ; CUSUM/Quandt = date inconnue. Selon la connaissance de la rupture.

Q160 — (d) une dummy de période (sans interactions). Décalage de niveau.

Q161 — (a) deux sous-périodes (généralisable à plusieurs). Via dummies multiples.

Q162 — (b) chaque sous-période doit avoir $n_j > k+1$. Sinon régression séparée infaisable.

Q163 — (c) instables (variables selon le régime). Détectée par Chow.

Q164 — (d) rupture = coefficients changeants ; détection = Chow/CUSUM ; remède = régimes séparés. Fenêtre glissante aussi.

Thème 9 --- Compromis biais--variance et sélection de modèle

Q165 — (a) biais² + variance + bruit irréductible. Compromis fondamental.

Q166 — (b) n·ln(RSS/n)+2(k+1). Minimiser ; pénalité 2 par paramètre.

Q167 — (c) n·ln(RSS/n)+(k+1)·ln n. Pénalité ln n ; plus parcimonieux.

Q168 — (d) plus que l'AIC (facteur ln n). Modèles plus parcimonieux.

Q169 — (a) estime sur une partie, évalue sur l'autre. Mesure directe hors échantillon.

Q170 — (b) empiler les régresseurs fait épouser le bruit. Mauvaise prévision hors échantillon.

Q171 — (c) R^2 ajusté, AIC/BIC, validation croisée. La parcimonie protège.

Q172 — (d) chercher le meilleur modèle sur les mêmes données $\Longrightarrow$ relations fallacieuses. Faux positifs.

Q173 — (a) il retrouve le vrai modèle quand $n \to \infty$. Si le vrai modèle est candidat.

Q174 — (b) il minimise l'erreur de prévision asymptotiquement. Meilleure prévision.

Q175 — (c) selon l'objectif (prévision : AIC ; parcimonie : BIC). Validation croisée tranche.

Q176 — (d) pénalités plus explicites et fondées. Sélection de modèle.

Q177 — (a) donne une fausse confiance. Coefficients instables.

Q178 — (b) divise en k blocs, estime sur k−1, évalue sur 1, en tournant. Estimation robuste de l'erreur.

Q179 — (c) coefficients stables, meilleure généralisation. À pouvoir explicatif comparable.

Q180 — (d) biais-variance ; AIC (prévision), BIC (parcimonie) à minimiser ; validation croisée. Outils complémentaires.

Thème 10 --- Protocole de diagnostic et synthèse

Q181 — (a) forme, hétéroscédasticité, autocorrélation, normalité, colinéarité, influence, stabilité. Sept contrôles.

Q182 — (b) biais → robustesse → efficacité → précision/validité. Le biais prime.

Q183 — (c) corriger les SE d'un modèle mal spécifié donne une fausse assurance. Coefficient biaisé invalide tout.

Q184 — (d) RESET + graphe des résidus ; transformer/ajouter des termes. Forme fonctionnelle.

Q185 — (a) Breusch–Pagan/White ; SE de White. β inchangé.

Q186 — (b) Durbin–Watson/Breusch–Godfrey ; SE de Newey–West. Séries temporelles.

Q187 — (c) levier/Cook ; examiner, robuste. Ne jamais supprimer par confort.

Q188 — (d) biais = omise/forme/endogénéité ; efficacité = hétéro./autocorr.. Colinéarité : précision ; influence : robustesse.

Q189 — (a) la méfiance envers le surajustement. Parcimonie et validation.

Q190 — (b) un modèle dont on ignore s'il ment. Le diagnostic conditionne la confiance.

Q191 — (c) White = coupe transversale ; Newey–West = séries temporelles. Autocorrélation $\Longrightarrow$ Newey–West.

Q192 — (d) il distingue la nature de chaque problème pour le bon remède. Comme un médecin.

Q193 — (a) un symptôme peut cacher un autre mal (ex. mauvaise spécification). Comprendre la cause d'abord.

Q194 — (b) vérifier les hypothèses via les résidus ; distinguer biais et efficacité ; évaluer influence, normalité, stabilité. Modèle non diagnostiqué = on ignore s'il ment.

Q195 — (c) VIF/nombre de conditionnement ; retirer, combiner, régulariser. Précision des coefficients.

Q196 — (d) Jarque–Bera/QQ-plot ; robuste ou bootstrap (petit n). TCL à grand n.

Q197 — (a) test de Chow/CUSUM ; modéliser les régimes séparément. Ruptures structurelles.

Q198 — (b) savoir lire un graphe de résidus. Presque tous les diagnostics en dérivent.

Q199 — (c) approfondissant et systématisant les problèmes esquissés + points influents, normalité, ruptures. Boîte à outils complète.

Q200 — (d) transparence (avec/sans points) et robustesse (SE robustes). Plutôt que dissimuler les défauts.

Grille récapitulative des réponses

1:a · 2:b · 3:c · 4:d · 5:a · 6:b · 7:c · 8:d · 9:a · 10:b

11:c · 12:d · 13:a · 14:b · 15:c · 16:d · 17:a · 18:b · 19:c · 20:d

21:a · 22:b · 23:c · 24:d · 25:a · 26:b · 27:c · 28:d · 29:a · 30:b

31:c · 32:d · 33:a · 34:b · 35:c · 36:d · 37:a · 38:b · 39:c · 40:d

41:a · 42:b · 43:c · 44:d · 45:a · 46:b · 47:c · 48:d · 49:a · 50:b

51:c · 52:d · 53:a · 54:b · 55:c · 56:d · 57:a · 58:b · 59:c · 60:d

61:a · 62:b · 63:c · 64:d · 65:a · 66:b · 67:c · 68:d · 69:a · 70:b

71:c · 72:d · 73:a · 74:b · 75:c · 76:d · 77:a · 78:b · 79:c · 80:d

81:a · 82:b · 83:c · 84:d · 85:a · 86:b · 87:c · 88:d · 89:a · 90:b

91:c · 92:d · 93:a · 94:b · 95:c · 96:d · 97:a · 98:b · 99:c · 100:d

101:a · 102:b · 103:c · 104:d · 105:a · 106:b · 107:c · 108:d · 109:a · 110:b

111:c · 112:d · 113:a · 114:b · 115:c · 116:d · 117:a · 118:b · 119:c · 120:d

121:a · 122:b · 123:c · 124:d · 125:a · 126:b · 127:c · 128:d · 129:a · 130:b

131:c · 132:d · 133:a · 134:b · 135:c · 136:d · 137:a · 138:b · 139:c · 140:d

141:a · 142:b · 143:c · 144:d · 145:a · 146:b · 147:c · 148:d · 149:a · 150:b

151:c · 152:d · 153:a · 154:b · 155:c · 156:d · 157:a · 158:b · 159:c · 160:d

161:a · 162:b · 163:c · 164:d · 165:a · 166:b · 167:c · 168:d · 169:a · 170:b

171:c · 172:d · 173:a · 174:b · 175:c · 176:d · 177:a · 178:b · 179:c · 180:d

181:a · 182:b · 183:c · 184:d · 185:a · 186:b · 187:c · 188:d · 189:a · 190:b

191:c · 192:d · 193:a · 194:b · 195:c · 196:d · 197:a · 198:b · 199:c · 200:d