FRM® Part I · Quantitative Analysis

Book 2 · Chapitre 14

Machine Learning Methods

Les méthodes d'apprentissage automatique

Régression régularisée, arbres, ensembles, clustering, ACP et réseaux de neurones

Approfondissement quantitatif maximal

Cours illustré · définitions · démonstrations · 200 études de cas · conseils méthodologiques · 200 QCM commentés

Support d'étude --- questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel --- pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
14.1 — Apprentissage supervisé, non supervisé, et rôle du ML en gestion des risques . . . 3
14.2 — Le compromis biais-variance et le surapprentissage . . . 4
14.3 — Validation croisée et évaluation de modèle . . . 5
14.4 — Régression régularisée : Ridge . . . 6
14.5 — Régression régularisée : Lasso et sélection de variables . . . 7
14.6 — K plus proches voisins (k-NN) . . . 8
14.7 — Arbres de décision . . . 9
14.8 — Méthodes d'ensemble : bagging et forêts aléatoires . . . 10
14.9 — Boosting . . . 12
14.10 — Apprentissage non supervisé : k-means, ACP, et synthèse du chapitre . . . 13

Partie B — 200 études de cas pratiques **14**
Bloc 1 — Apprentissage supervisé, non supervisé, rôle du ML . . . 14
Bloc 2 — Biais-variance et surapprentissage . . . 16
Bloc 3 — Validation croisée et évaluation de modèle . . . 17
Bloc 4 — Régression Ridge . . . 18
Bloc 5 — Régression Lasso et sélection de variables . . . 20
Bloc 6 — K plus proches voisins . . . 21
Bloc 7 — Arbres de décision . . . 22
Bloc 8 — Bagging et forêts aléatoires . . . 23
Bloc 9 — Boosting . . . 25
Bloc 10 — k-means, ACP et synthèse . . . 26

Partie C — Méthodologie, formulaire et astuces **27**
C.1 — Formulaire complet . . . 28
C.2 — Le tableau maître : méthodes, hyperparamètre, biais/variance . . . 29
C.3 — Carte de décision . . . 29
C.4 — Glossaire bilingue . . . 29
C.5 — Protocole complet d'un projet ML en gestion des risques . . . 30
C.6 — Les dix pièges classiques . . . 30
C.7 — Astuces de calcul et de mémorisation pour l'examen . . . 31

Partie F — Étude de cas intégrée : construire un modèle de scoring de bout en bout **31**
F.1 — Contexte et données . . . 31
F.2 — Comparaison de cinq modèles candidats . . . 32
F.3 — Diagnostic de surapprentissage sur le boosting . . . 32
F.4 — Explicabilité et contrainte réglementaire . . . 33
F.5 — Surveillance post-déploiement . . . 33

Partie D — 200 questions à choix multiple **33**
Thème 1 — Apprentissage supervisé, non supervisé, rôle du ML . . . 33
Thème 2 — Biais-variance et surapprentissage . . . 36
Thème 3 — Validation croisée et évaluation de modèle . . . 39
Thème 4 — Régression Ridge . . . 42
Thème 5 — Régression Lasso et sélection de variables . . . 45
Thème 6 — K plus proches voisins . . . 48
Thème 7 — Arbres de décision . . . 51
Thème 8 — Bagging et forêts aléatoires . . . 54
Thème 9 — Boosting . . . 57
Thème 10 — k-means, ACP et synthèse . . . 60

Partie E — Corrigé commenté des 200 QCM **63**
Thème 1 — Apprentissage supervisé, non supervisé, rôle du ML . . . 63

Thème 2 — Biais-variance et surapprentissage 63
Thème 3 — Validation croisée et évaluation de modèle 64
Thème 4 — Régression Ridge 65
Thème 5 — Régression Lasso et sélection de variables 65
Thème 6 — K plus proches voisins 66
Thème 7 — Arbres de décision 67
Thème 8 — Bagging et forêts aléatoires 68
Thème 9 — Boosting 68
Thème 10 — k-means, ACP et synthèse 69

Partie A --- Cours approfondi

Les chapitres précédents ont construit des modèles **spécifiés a priori** : une forme fonctionnelle (linéaire, log-normale) est postulée, puis ses paramètres sont estimés (régression, MLE) ou son comportement simulé (chapitre 13). Le **machine learning** renverse partiellement cette logique : plutôt que d'imposer une forme rigide, on laisse l'algorithme **apprendre la structure** directement à partir des données, au prix d'un contrôle accru sur sa capacité à généraliser. Ce chapitre construit la boîte à outils du praticien du risque : du compromis biais-variance qui gouverne tout apprentissage, à la régularisation (Ridge, Lasso) qui discipline la régression classique, en passant par les arbres, les méthodes d'ensemble (bagging, forêts aléatoires, boosting), jusqu'aux méthodes non supervisées (k-means, ACP) qui structurent des données sans étiquette.

Le fil rouge : apprendre sans mémoriser

Le danger central de tout algorithme de machine learning n'est pas qu'il apprenne trop peu, mais qu'il apprenne **trop bien** les données d'entraînement — au point de mémoriser leur bruit idiosyncratique plutôt que la structure généralisable. Chaque méthode de ce chapitre — régularisation, élagage d'arbre, agrégation d'ensemble, validation croisée — est une réponse différente à ce même problème : comment extraire le signal sans capturer le bruit.

14.1 --- Apprentissage supervisé, non supervisé, et rôle du ML en gestion des risques

Premier jalon : situer le machine learning par rapport à la statistique classique et poser le vocabulaire de base.

Apprentissage supervisé

En **apprentissage supervisé**, l'algorithme dispose d'un ensemble d'observations $(x_i, y_i)_{i=1}^n$ où y_i est une **cible connue** (étiquette), et cherche une fonction f telle que $\widehat{y}_i = f(x_i)$ approxime y_i. On distingue la **régression** (y continue, ex. une perte de portefeuille) et la **classification** (y catégorielle, ex. défaut/non-défaut).

Apprentissage non supervisé

En **apprentissage non supervisé**, aucune cible y n'est fournie : l'algorithme cherche une **structure cachée** dans les seules variables explicatives x_i — des groupes homogènes (clustering, §14.10) ou des directions de variance maximale (ACP, §14.10).

Machine learning vs statistique classique : une différence de priorité, non de nature

La frontière n'est pas nette : la régression linéaire (chapitre 9) est autant un outil statistique classique qu'un algorithme de machine learning supervisé élémentaire. Ce qui distingue la tradition ML est sa **priorité affichée à la prédiction** sur l'inférence : un statisticien classique s'intéresse à la significativité et à l'interprétation d'un coefficient β ; un praticien ML s'intéresse d'abord à la qualité de $\widehat{y}$ sur des données **nouvelles**, quitte à sacrifier l'interprétabilité (une forêt aléatoire de 500 arbres n'a pas de coefficient unique à interpréter).

Pourquoi le machine learning en gestion des risques

Trois usages dominent en pratique. **Scoring de crédit** : classification (défaut/non-défaut) à partir de centaines de variables, où les interactions non linéaires entre variables (revenu, endettement, historique) dépassent ce qu'une régression logistique simple capture bien. **Détection de fraude et d'anomalies** : structure rare et non linéaire, où des méthodes d'ensemble excellent. **Segmentation de clientèle ou de risques** : clustering non supervisé pour regrouper des contreparties ou des positions aux profils de risque similaires, sans définir a priori les catégories.

Les données : entraînement, validation, test

Toute démarche ML rigoureuse partitionne les données disponibles en (au moins) trois sous-ensembles : l'**échantillon d'entraînement** (*training set*) sur lequel le modèle est ajusté ; l'**échantillon de validation** sur lequel les hyperparamètres (ex. le λ d'une régularisation, la profondeur d'un arbre) sont choisis ; l'**échantillon de test**, gardé de côté et consulté une seule fois, pour une estimation non biaisée de la performance finale généralisable. Confondre validation et test — ou pire, ajuster le modèle en observant le test — produit une estimation de performance systématiquement trop optimiste : c'est une forme de **fuite de données** (*data leakage*).

14.2 --- Le compromis biais-variance et le surapprentissage

Le concept unificateur de tout le chapitre : comprendre pourquoi un modèle trop simple et un modèle trop complexe échouent tous deux, pour des raisons opposées.

Biais et variance d'un estimateur de fonction

Pour un modèle $\hat{f}$ estimant la vraie fonction f, l'erreur quadratique attendue sur une nouvelle observation se décompose en :

$$\mathbb{E}\left[(y-\hat{f}(x))^2\right] = \underbrace{\left(\text{Biais}[\hat{f}(x)]\right)^2}_{\text{erreur systématique}} + \underbrace{\text{Var}[\hat{f}(x)]}_{\text{sensibilité aux données}} + \underbrace{\sigma_\varepsilon^2}_{\text{bruit irréductible}} .$$

Décomposition biais-variance

$$\text{Biais}[\hat{f}(x)] = \mathbb{E}[\hat{f}(x)] - f(x), \qquad \text{Var}[\hat{f}(x)] = \mathbb{E}\left[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2\right].$$

Sous-apprentissage et surapprentissage : deux échecs symétriques

Un modèle **trop simple** (ex. une droite pour une relation courbe) a un **biais élevé** : il est systématiquement à côté de la vérité, peu importe les données — c'est le **sous-apprentissage** (*underfitting*). Un modèle **trop complexe** (ex. un polynôme de degré 20 sur 30 points) a une **variance élevée** : il épouse le bruit spécifique de l'échantillon d'entraînement, et change radicalement si on change légèrement les données — c'est le **surapprentissage** (*overfitting*). Le bon modèle minimise la **somme** des deux, pas l'un des deux isolément.

Le symptôme du surapprentissage : l'écart train/test

Le signal diagnostique le plus fiable du surapprentissage est un **écart croissant** entre l'erreur mesurée sur l'échantillon d'entraînement (qui décroît presque toujours quand la complexité augmente) et l'erreur mesurée sur un échantillon de test indépendant (qui décroît puis **remonte** au-delà d'un certain point de complexité). Le point optimal de complexité est celui qui **minimise l'erreur de test**, non l'erreur d'entraînement — une erreur d'entraînement proche de zéro est un signal d'alarme, pas un succès.

Remèdes au surapprentissage

Quatre familles de remèdes reviendront tout au long du chapitre : **régularisation** (pénaliser la complexité, §14.4-14.5) ; **élagage** (limiter la profondeur d'un arbre, §14.7) ; **agrégation** (moyenner plusieurs modèles instables pour réduire la variance sans augmenter le biais, §14.8) ; et **validation croisée** (mesurer honnêtement l'erreur de généralisation pour choisir le bon niveau de complexité, §14.3).

Démonstration

Illustration numérique du compromis biais-variance. Soit une vraie relation $f(x) = 2 + 3x - 0.5x^2$ observée avec un bruit $\varepsilon \sim \mathcal{N}(0,1)$ ($\sigma_\varepsilon^2 = 1$). On ajuste deux modèles sur des échantillons répétés de taille $n = 30$: (i) une droite $\hat{f}_1(x) = a + bx$; (ii) un polynôme de degré 10. Pour le modèle (i), simulé sur 1000 échantillons, le biais moyen au point $x = 5$ atteint typiquement $|\text{Biais}| \approx 3.2$ (la droite ne peut pas épouser la courbure) alors que sa variance reste faible, Var ≈ 0.15 : erreur quadratique totale $\approx 3.2^2 + 0.15 + 1 \approx 11.4$. Pour le modèle (ii), le biais est quasi nul (≈ 0.1) mais la variance explose, Var ≈ 8.7 (le polynôme épouse le bruit spécifique de chaque échantillon) : erreur totale $\approx 0.01 + 8.7 + 1 \approx 9.7$. Un polynôme de degré 2 (la vraie forme) donnerait biais ≈ 0 et variance ≈ 0.4, soit une erreur totale ≈ 1.4 — très inférieure aux deux extrêmes. Ce calcul illustre concrètement pourquoi ni le sous-ajustement ni le surajustement ne minimisent l'erreur totale : le modèle de complexité **intermédiaire**, adaptée à la vraie structure, l'emporte.

14.3 --- Validation croisée et évaluation de modèle

Comment mesurer honnêtement la capacité de généralisation d'un modèle sans gaspiller de données.

Validation croisée à k plis

La **validation croisée à k plis** (*k-fold cross-validation*) partage les données d'entraînement en k sous-ensembles (k souvent égal à 5 ou 10) de taille égale. Pour chaque pli $j = 1, \dots, k$: le modèle est entraîné sur les $k-1$ autres plis, puis évalué sur le pli j laissé de côté. L'erreur de validation croisée est la moyenne des k erreurs obtenues.

Erreur de validation croisée

$$\text{CV}_{(k)} = \frac{1}{k} \sum_{j=1}^{k} \text{Erreur}\left(\hat{f}^{(-j)}, \text{pli } j\right),$$

où $\hat{f}^{(-j)}$ est le modèle entraîné sans le pli j.

Pourquoi la validation croisée plutôt qu'un simple split train/test

Un unique découpage train/test gaspille des données (celles du test ne servent jamais à l'entraînement) et son résultat dépend du hasard du découpage particulier. La validation croisée fait en sorte que **chaque observation serve exactement une fois** de test, ce qui donne une estimation **plus stable** de l'erreur de généralisation, au prix d'un temps de calcul multiplié par k (le modèle est réentraîné k fois).

Métriques d'évaluation : régression vs classification

En régression, l'**erreur quadratique moyenne** (MSE) ou le R^2 hors-échantillon dominent. En classification, la simple **précision** (taux de bonnes classifications) est trompeuse sur des classes déséquilibrées (ex. 2% de défauts) : on lui préfère la **matrice de confusion**, la **sensibilité** (taux de vrais positifs), la **spécificité**, et la courbe **ROC**/aire sous la courbe (AUC), qui restent informatives même quand une classe est rare.

Validation croisée et choix d'hyperparamètre

L'usage le plus fréquent de la validation croisée en pratique n'est pas d'évaluer un modèle final, mais de **choisir un hyperparamètre** : on balaie une grille de valeurs (ex. λ pour Ridge/Lasso, profondeur maximale pour un arbre) et on retient celle qui minimise l'erreur de validation croisée — avant d'évaluer le modèle final, retenu avec cet hyperparamètre, sur l'échantillon de test totalement indépendant.

Exemple travaillé --- validation croisée à 5 plis sur un score de défaut

Un analyste dispose de $n = 500$ contreparties pour calibrer un modèle de score de défaut, et teste trois profondeurs d'arbre candidates. Il découpe les données en $k = 5$ plis de 100 observations chacun. Pour chaque profondeur, il entraîne 5 fois (sur 400 observations, teste sur les 100 restantes) et calcule le taux d'erreur de classification sur chaque pli :
Profondeur 2 : erreurs par pli $= 18\%, 21\%, 19\%, 20\%, 17\% \Rightarrow \text{CV}_{(5)} = (18+21+19+20+17)/5 = 19.0\%$.
Profondeur 5 : erreurs par pli $= 12\%, 14\%, 11\%, 25\%, 13\% \Rightarrow \text{CV}_{(5)} = (12+14+11+25+13)/5 = 15.0\%$ — la valeur 25% sur le 4e pli signale un début d'instabilité (variance entre plis élevée : écart-type ≈ 5.3 points contre ≈ 1.4 point pour la profondeur 2).
Profondeur 10 : erreurs par pli $= 5\%, 22\%, 8\%, 27\%, 6\% \Rightarrow \text{CV}_{(5)} = (5+22+8+27+6)/5 = 13.6\%$, mais un écart-type inter-plis ≈ 9.6 points, largement supérieur — symptôme clair de surapprentissage (§14.2) malgré l'erreur moyenne la plus faible.
Décision : l'analyste retient la profondeur 5, qui offre le meilleur compromis entre erreur moyenne et **stabilité** entre plis, plutôt que la profondeur 10 qui minimise l'erreur moyenne mais au prix d'une variance de généralisation inacceptable pour un usage réglementaire.

14.4 --- Régression régularisée : Ridge

Première réponse concrète au surapprentissage : pénaliser la taille des coefficients d'une régression.

Régression Ridge

La **régression Ridge** modifie l'objectif des moindres carrés ordinaires en ajoutant une pénalité proportionnelle à la **somme des carrés** des coefficients :

$$\hat{\beta}^{\text{Ridge}} = \arg\min_{\beta} \left\{ \sum_{i=1}^{n} (y_i - x_i^{\mathsf{T}}\beta)^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \right\}, \qquad \lambda \geq 0.$$

Rôle du paramètre de régularisation λ

$$\lambda = 0 \Rightarrow \hat{\beta}^{\text{Ridge}} = \hat{\beta}^{\text{MCO}} \quad \text{(aucune pénalité)}.$$

$$\lambda \to \infty \Rightarrow \hat{\beta}^{\text{Ridge}} \to 0 \quad \text{(tous les coefficients écrasés vers zéro)}.$$

Démonstration

Pourquoi la pénalité Ridge réduit-elle la variance ? En présence de **multicolinéarité** (variables explicatives corrélées entre elles), la matrice $X^{\mathsf{T}}X$ des moindres carrés ordinaires devient proche de la singularité, et son inverse $(X^{\mathsf{T}}X)^{-1}$ amplifie fortement le bruit d'échantillonnage — d'où une variance élevée des $\hat{\beta}^{\text{MCO}}$. La solution Ridge s'écrit $\hat{\beta}^{\text{Ridge}} = (X^{\mathsf{T}}X + \lambda I)^{-1}X^{\mathsf{T}}y$: l'ajout de λI « éloigne » la matrice inversée de la singularité, ce qui **stabilise** l'inversion et réduit mécaniquement la variance de l'estimateur, au prix d'un biais introduit (les coefficients sont systématiquement rétrécis vers zéro). Le compromis biais-variance de §14.2 se joue ici explicitement à travers λ.

Ridge ne met jamais un coefficient exactement à zéro

La pénalité quadratique $\sum \beta_j^2$ rétrécit tous les coefficients **proportionnellement**, mais ne les annule jamais exactement (sauf $\lambda \to \infty$) : géométriquement, la région de contrainte $\{\sum \beta_j^2 \leq c\}$ est une hypersphère lisse, sans coin, et le point de tangence avec les courbes de niveau de la somme des carrés résiduels tombe presque toujours dans l'intérieur strict de chaque axe. Ridge est donc un outil de **rétrécissement** (*shrinkage*), pas de **sélection de variables** — contrairement au Lasso (§14.5).

Standardisation, préalable indispensable à Ridge

La pénalité $\sum \beta_j^2$ traite tous les coefficients de façon symétrique, ce qui n'a de sens que si les variables explicatives sont sur une **échelle comparable**. En pratique, on **standardise** systématiquement chaque variable (moyenne nulle, écart-type unitaire, chapitre 4) avant d'appliquer Ridge — sans quoi une variable mesurée en unités « larges » (ex. un encours en millions d'euros) serait arbitrairement moins pénalisée qu'une variable en unités « fines » (ex. un taux en %).

Exemple travaillé --- effet de λ sur des coefficients standardisés

Une régression MCO standardisée de la perte trimestrielle d'un portefeuille sur deux variables macro corrélées (taux directeur x_1, spread de crédit x_2, corrélation $\rho(x_1, x_2) = 0.92$) donne $\hat{\beta}^{\text{MCO}} = (4.8,\ -3.1)$ — des signes contre-intuitifs et une magnitude instable, symptôme classique de multicolinéarité. On calibre Ridge par validation croisée sur une grille $\lambda \in \{0,\ 1,\ 5,\ 10,\ 50\}$:

λ	$\hat{\beta}_1$	$\hat{\beta}_2$	Erreur CV
0	4.80	−3.10	2.40
1	3.20	−1.40	2.05
5	2.10	−0.35	1.78
10	1.55	0.05	1.81
50	0.62	0.58	2.35

L'erreur de validation croisée est minimale à $\lambda = 5$: les deux coefficients deviennent économiquement cohérents (les deux variables contribuent positivement au risque de perte), sans être écrasés à zéro. Au-delà de $\lambda = 10$, l'erreur CV remonte : la pénalité devient trop forte et le modèle sous-ajuste — illustration directe du compromis biais-variance piloté par λ.

14.5 --- Régression régularisée : Lasso et sélection de variables

Une pénalité différente qui, contrairement à Ridge, effectue une véritable sélection de variables.

Régression Lasso

La **régression Lasso** (*Least Absolute Shrinkage and Selection Operator*) remplace la pénalité quadratique de Ridge par une pénalité en **valeur absolue** :

$$\hat{\beta}^{\text{Lasso}} = \arg\min_{\beta} \left\{ \sum_{i=1}^{n} (y_i - x_i^{\mathsf{T}}\beta)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \right\}, \qquad \lambda \geq 0.$$

Ridge vs Lasso — comparaison

Ridge (ℓ_2) : $\sum \beta_j^2 \Rightarrow$ rétrécit tous les coefficients, aucun à zéro exactement.

Lasso (ℓ_1) : $\sum |\beta_j| \Rightarrow$ peut mettre certains coefficients exactement à zéro (sélection).

Pourquoi le Lasso sélectionne des variables : l'intuition géométrique

La région de contrainte du Lasso, $\{\sum |\beta_j| \leq c\}$, est un polytope à **coins** (un losange en dimension 2) — contrairement à l'hypersphère lisse de Ridge. Ces coins tombent exactement sur les axes, là où un ou plusieurs coefficients sont nuls. Comme les courbes de niveau elliptiques de la somme des carrés résiduels ont une probabilité non négligeable de toucher la région de contrainte précisément **en un coin**, le Lasso

produit typiquement des solutions où plusieurs $\hat{\beta}_j$ sont exactement zéro — une **sélection automatique de variables**, utile quand p (le nombre de variables candidates) est grand face à n.

Interprétation en gestion des risques : un modèle parcimonieux

Face à des centaines de variables candidates pour un modèle de scoring ou de prévision de spread de crédit, le Lasso offre un double avantage : un modèle **plus interprétable** (seules les variables retenues, à coefficient non nul, entrent dans le récit du modèle) et un risque de surapprentissage réduit (moins de paramètres effectivement estimés). Le prix à payer : en présence de variables fortement corrélées entre elles, le Lasso tend à n'en retenir **arbitrairement qu'une** du groupe, ce qui peut nuire à la stabilité du modèle d'une exécution à l'autre.

Elastic Net : combiner les deux pénalités

L'**Elastic Net** combine linéairement les deux pénalités, $\lambda \left[\alpha \sum |\beta_j| + (1-\alpha) \sum \beta_j^2\right]$ avec $\alpha \in [0,1]$, pour bénéficier à la fois de la sélection de variables du Lasso et de la meilleure gestion de la colinéarité de Ridge — un compromis utile quand de nombreuses variables candidates sont mutuellement corrélées.

Exemple travaillé --- sélection de variables par le Lasso

Un modèle de spread de crédit dispose de 8 variables candidates standardisées : x_1 (taux directeur), x_2 (inflation), x_3 (VIX), x_4 (croissance du PIB), x_5 (levier sectoriel), x_6 (liquidité de marché), x_7 (notation moyenne du secteur), x_8 (variable bruitée sans lien économique, ajoutée comme test). En balayant λ par validation croisée, la trajectoire des coefficients Lasso évolue ainsi :

Variable	$\lambda = 0.5$	$\lambda = 2$ (optimal CV)	$\lambda = 8$
x_1 (taux)	1.85	1.42	0.61
x_2 (inflation)	0.94	0.51	0
x_3 (VIX)	2.31	1.98	1.10
x_4 (PIB)	-1.20	-0.88	-0.15
x_5 (levier)	0.77	0.33	0
x_6 (liquidité)	0.42	0	0
x_7 (notation)	-1.55	-1.21	-0.70
x_8 (bruit)	0.18	0	0

À $\lambda = 2$ (retenu par validation croisée), le Lasso a déjà annulé x_6 et x_8 — confirmant, pour x_8, sa nature de bruit sans pouvoir prédictif réel. Cinq variables économiquement interprétables restent actives : le modèle final s'écrit sans x_6 et x_8, plus **parcimonieux** et plus robuste que le modèle complet à 8 variables, sans perte significative de performance de validation croisée.

14.6 --- K plus proches voisins (k-NN)

La méthode la plus simple sur le plan conceptuel : prédire à partir de la ressemblance aux observations déjà vues.

k plus proches voisins

L'algorithme des **k plus proches voisins** (*k-Nearest Neighbors*) prédit $\hat{y}$ pour une nouvelle observation x en identifiant les k observations d'entraînement les plus proches de x (selon une distance, souvent euclidienne), puis en prenant la **moyenne** de leurs y (régression) ou le **vote majoritaire** de leurs classes (classification).

Distance euclidienne entre deux observations

$$d(x, x') = \sqrt{\sum_{j=1}^{p} (x_j - x'_j)^2}.$$

k-NN est un algorithme non paramétrique et « paresseux »

Contrairement à Ridge ou Lasso, k-NN n'estime **aucun paramètre** lors de l'entraînement : il se contente de mémoriser les données (apprentissage dit « paresseux », *lazy learning*) et ne fait le travail de calcul qu'au moment de la prédiction, en cherchant les voisins les plus proches. Il fait aussi **aucune hypothèse de forme fonctionnelle** (non paramétrique) : la frontière de décision peut épouser n'importe quelle forme, contrairement à la droite d'une régression logistique.

Le rôle de k : un curseur biais-variance direct

Un k **petit** (ex. $k = 1$) rend la prédiction très sensible au bruit local — variance élevée, frontière de décision très irrégulière, risque de surapprentissage. Un k **grand** (ex. $k = n$, qui revient à prédire la moyenne globale) lisse excessivement — biais élevé, sous-apprentissage. Le choix de k se fait typiquement par validation croisée (§14.3), exactement comme le λ de Ridge/Lasso.

Le fléau de la dimension

k-NN souffre particulièrement du **fléau de la dimension** (*curse of dimensionality*) : quand le nombre de variables explicatives p augmente, les points deviennent tous « également éloignés » les uns des autres dans un espace de grande dimension, et la notion même de « plus proche voisin » perd son pouvoir discriminant. C'est pourquoi k-NN, efficace en petite dimension, se dégrade souvent face à des jeux de données à centaines de variables — motivant un usage combiné avec une réduction de dimension préalable (ACP, §14.10).

Exemple travaillé --- classification k-NN d'une nouvelle contrepartie

Une base de 6 contreparties déjà classées (défaut = D, sain = S) est décrite par deux variables standardisées : ratio d'endettement x_1 et couverture des intérêts x_2.

Contrepartie	x_1	x_2	Classe	$d(x, \text{nouvelle})$
A	1.2	−0.8	D	0.50
B	0.9	−0.5	D	0.64
C	−0.3	1.1	S	2.32
D	−0.6	0.9	S	2.55
E	1.5	−1.2	D	0.92
F	−0.1	0.4	S	1.68

Nouvelle contrepartie à classer : $x = (1.0, -0.6)$. Les distances euclidiennes (calculées ci-dessus) classent A (0.50), B (0.64) et E (0.92) comme les trois plus proches. Avec $k = 3$, le vote majoritaire donne **D, D, D** $\rightarrow$ classification **défaut**, avec une confiance de $3/3 = 100\%$. Avec $k = 5$ (ajout de F et C), le vote devient **D, D, D, S, S** $\rightarrow$ toujours **défaut**, mais avec une confiance réduite à $3/5 = 60\%$ — illustrant concrètement comment l'augmentation de k dilue une décision locale nette vers une prédiction plus lissée.

14.7 --- Arbres de décision

Une méthode qui partitionne récursivement l'espace des variables en régions homogènes, produisant un modèle directement interprétable.

Arbre de décision

Un **arbre de décision** partitionne récursivement l'espace des variables explicatives en régions rectangulaires, par une séquence de règles binaires du type « $x_j \leq s$? ». Chaque **nœud interne** teste une condition sur une variable ; chaque **feuille** (nœud terminal) donne la prédiction — la moyenne des y de la région (régression) ou la classe majoritaire (classification).

Critère de scission — impureté de Gini (classification)

$$G = \sum_{c=1}^{C} \hat{p}_c(1 - \hat{p}_c),$$

où $\hat{p}_c$ est la proportion d'observations de la classe c dans le nœud. $G = 0$ pour un nœud parfaitement pur (une seule classe).

Construire l'arbre : une recherche gloutonne

À chaque nœud, l'algorithme cherche la variable x_j et le seuil s qui **minimisent l'impureté pondérée** des deux nœuds enfants résultants (ou, en régression, la somme des carrés résiduels intra-région). Cette recherche est **gloutonne** (*greedy*) : optimale localement à chaque scission, sans garantie d'optimalité globale sur l'arbre entier — construire l'arbre globalement optimal serait combinatoirement intraitable.

Le surapprentissage d'un arbre non contraint et l'élagage

Un arbre développé jusqu'à ce que chaque feuille soit parfaitement pure **surapprend presque toujours** : il finit par isoler des observations individuelles bruitées. Deux remèdes : arrêter la croissance tôt (profondeur maximale, nombre minimal d'observations par feuille — des hyperparamètres à choisir par validation croisée), ou **élaguer** (*pruning*) un arbre initialement grand en supprimant les branches qui n'améliorent pas l'erreur de validation.

Avantages et limites d'un arbre isolé

Avantages : directement interprétable (on peut lire les règles de décision), gère nativement les interactions non linéaires et les variables catégorielles, aucune hypothèse de distribution. **Limite majeure** : un arbre isolé est **instable** — une petite perturbation des données d'entraînement peut produire une structure d'arbre très différente (variance élevée). C'est précisément cette instabilité que les méthodes d'ensemble (§14.8-14.9) exploitent et corrigent.

Démonstration

Calcul explicite d'un gain de Gini. Un nœud contient 20 contreparties : 12 saines (S), 8 en défaut (D), soit $\hat{p}_S = 0.6$, $\hat{p}_D = 0.4$. Impureté du nœud parent : $G_{\text{parent}} = 1 - (0.6^2 + 0.4^2) = 1 - (0.36 + 0.16) = 0.48$. On teste la scission sur « levier > 1.5 » : le nœud gauche (levier ≤ 1.5) reçoit 14 observations (11 S, 3 D), le nœud droit 6 observations (1 S, 5 D). $G_{\text{gauche}} = 1 - [(11/14)^2 + (3/14)^2] = 1 - (0.617 + 0.046) = 0.337$. $G_{\text{droit}} = 1 - [(1/6)^2 + (5/6)^2] = 1 - (0.028 + 0.694) = 0.278$. Impureté pondérée après scission : $\frac{14}{20}(0.337) + \frac{6}{20}(0.278) = 0.236 + 0.083 = 0.319$. Le **gain de Gini** de cette scission est $0.48 - 0.319 = 0.161$ — une réduction substantielle de l'impureté, ce qui en fait une candidate de scission attractive comparée à une variable alternative dont le gain serait, par exemple, de seulement 0.04.

14.8 --- Méthodes d'ensemble : bagging et forêts aléatoires

Comment transformer l'instabilité d'un arbre isolé en force, en moyennant de nombreux arbres.

Bagging

Le **bagging** (*Bootstrap Aggregating*) génère B échantillons **bootstrap** (tirage avec remise, chapitre 13) des données d'entraînement, entraîne un modèle (souvent un arbre non élagué) sur chacun, puis **moyenne** les B prédictions (régression) ou fait voter les B modèles (classification).

Forêt aléatoire

Une **forêt aléatoire** (*random forest*) applique le bagging à des arbres de décision, avec une variante additionnelle : à **chaque scission** de chaque arbre, seul un sous-ensemble aléatoire de $m < p$ variables (typiquement $m \approx \sqrt{p}$) est considéré comme candidat, plutôt que les p variables entières.

Réduction de variance par moyennage

Si B arbres ont chacun une variance σ^2 et une corrélation moyenne ρ, $\quad \text{Var}\left(\frac{1}{B}\sum_{b=1}^{B}\hat{f}_b\right) = \rho\,\sigma^2 + \frac{1-\rho}{B}\sigma^2.$

Démonstration

Pourquoi la sélection aléatoire de variables à chaque scission (et non le simple bootstrap) est-elle nécessaire ? Si tous les arbres du bagging avaient accès à toutes les variables, ils auraient tendance à choisir, en tête d'arbre, la **même variable dominante** (celle qui réduit le plus l'impureté) — produisant des arbres très **corrélés** entre eux (ρ élevé dans la formule ci-dessus). Or, la formule montre que le gain de variance du moyennage dépend crucialement de ρ : si $\rho \to 1$, moyenner B arbres n'apporte **aucun** bénéfice (Var $\to \sigma^2$), quel que soit B. En forçant chaque scission à ignorer une partie des variables, la forêt aléatoire **décorrèle** les arbres (réduit ρ), ce qui rend le second terme $\frac{1-\rho}{B}\sigma^2$ effectivement réductible en augmentant B — le vrai moteur de la réduction de variance.

Le bagging réduit la variance, pas le biais

Le bagging (et la forêt aléatoire) laisse le **biais individuel** de chaque arbre pratiquement inchangé (moyenner B estimateurs de même biais moyen ne change pas ce biais moyen), mais réduit fortement la **variance** grâce à l'agrégation — exploitant directement la décomposition de §14.2. C'est pourquoi on utilise volontairement des arbres **profonds, non élagués** (biais faible, variance individuelle élevée) comme composants du bagging : c'est l'agrégation, pas l'arbre individuel, qui gère la variance.

Échantillon out-of-bag (OOB)

Chaque échantillon bootstrap laisse de côté, en moyenne, environ $1/e \approx 36.8\%$ des observations originales (celles jamais tirées). Ces observations **out-of-bag** (OOB) pour un arbre donné n'ont pas servi à l'entraîner : elles fournissent une estimation de l'erreur de généralisation **gratuite**, sans nécessiter de validation croisée séparée — un avantage pratique propre au bagging et aux forêts aléatoires.

Exemple travaillé --- gain de variance par agrégation

Une forêt aléatoire de $B = 100$ arbres est comparée à un arbre isolé pour prédire une perte de portefeuille. Chaque arbre individuel a une variance de prédiction estimée $\sigma^2 = 25$ (en unités de perte au carré). Deux scénarios de corrélation inter-arbres sont comparés à l'aide de la formule $\text{Var} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$:
Bagging simple (toutes les variables disponibles à chaque scission, $\rho = 0.65$, arbres fortement corrélés car ils choisissent souvent la même variable dominante en tête d'arbre) : $\text{Var} = 0.65(25) + \frac{0.35}{100}(25) = 16.25 + 0.0875 \approx 16.34$ — à peine inférieur à la variance individuelle de 25.
Forêt aléatoire (sélection aléatoire de $m \approx \sqrt{p}$ variables par scission, $\rho = 0.15$, arbres décorrélés) : $\text{Var} = 0.15(25) + \frac{0.85}{100}(25) = 3.75 + 0.2125 \approx 3.96$ — une réduction de variance de plus de 6 fois par rapport à l'arbre isolé.

Ce calcul quantifie précisément l'intuition de la démonstration ci-dessus : ce n'est pas l'agrégation en soi (le terme en $1/B$, ici quasi négligeable dans les deux cas dès $B = 100$) mais la **décorrélation** des arbres (le terme $\rho\sigma^2$) qui pilote l'essentiel du gain de la forêt aléatoire sur le simple bagging.

14.9 --- Boosting

Une seconde famille de méthodes d'ensemble, radicalement différente dans son principe : construire les modèles séquentiellement plutôt qu'en parallèle.

Boosting

Le **boosting** construit une séquence de modèles **faibles** (souvent des arbres peu profonds, dits *stumps*) de façon **séquentielle** : chaque nouveau modèle est entraîné pour corriger les erreurs (résidus, ou observations mal classées) laissées par l'ensemble des modèles précédents. La prédiction finale est une somme pondérée de tous les modèles faibles.

Boosting additif — forme générale

$$\hat{f}_M(x) = \sum_{m=1}^{M} \nu\, \hat{f}_m(x), \qquad \nu \in (0, 1] \text{ (taux d'apprentissage, } \textit{learning rate}).$$

Bagging vs boosting : parallèle contre séquentiel

Le **bagging** entraîne ses B modèles **indépendamment** et en parallèle (chacun sur son propre échantillon bootstrap), puis les moyenne — son levier est la **réduction de variance**. Le **boosting** entraîne ses modèles **séquentiellement**, chacun ciblant spécifiquement les erreurs du précédent — son levier est la **réduction du biais** : même des modèles faibles individuellement (à peine mieux qu'un tirage aléatoire) peuvent, combinés séquentiellement, produire un ensemble à faible biais.

Le taux d'apprentissage ν : un curseur de régularisation

Le taux d'apprentissage ν contrôle la contribution de chaque modèle faible successif : un ν **petit** (ex. 0.01-0.1) ralentit l'apprentissage mais réduit le risque de surapprentissage (chaque pas est prudent) ; un ν proche de 1 apprend vite mais surapprend plus facilement. En pratique, un ν petit combiné à un grand nombre d'itérations M (choisi par validation croisée) donne généralement les meilleures performances.

Le boosting est plus sensible au surapprentissage et aux valeurs aberrantes que le bagging

Parce qu'il cible explicitement les observations mal prédites, le boosting peut, si M est trop grand ou ν trop élevé, finir par sur-ajuster le bruit ou les valeurs aberrantes (des observations difficiles à prédire attirent une attention disproportionnée itération après itération). Contrairement au bagging, augmenter indéfiniment M n'est donc **pas** toujours bénéfique — le nombre optimal d'itérations doit être calibré, typiquement par un critère d'arrêt anticipé (*early stopping*) sur un échantillon de validation.

Démonstration

Trois itérations de gradient boosting sur une cible simplifiée. On cherche à prédire la perte y de trois positions : $y = (10, 4, 16)$. **Itération 0** : le modèle initial prédit la moyenne, $\hat{f}_0 = (10, 10, 10)$ pour les trois positions (constante). Résidus : $r_0 = (0, -6, 6)$. **Itération 1** : un arbre faible $\hat{f}_1$ est entraîné pour prédire ces résidus ; il apprend approximativement $\hat{f}_1 = (0, -5, 5)$ (arbre simple à deux feuilles). Avec $\nu = 0.5$, la prédiction cumulée devient $\hat{f}_0 + \nu\hat{f}_1 = (10, 7.5, 12.5)$, et les nouveaux résidus sont $r_1 = (0, -3.5, 3.5)$ — l'erreur absolue moyenne est passée de

4 (après itération 0) à 2.33. **Itération 2** : un second arbre apprend $\hat{f}_2 \approx (0, -3, 3)$ sur ces résidus réduits ; la prédiction cumulée devient $(10, 6.0, 14.0)$, résidus $r_2 = (0, -2.0, 2.0)$, erreur absolue moyenne 1.33. Le processus converge géométriquement vers y à mesure que M augmente — illustrant concrètement pourquoi le boosting réduit le **biais** de façon itérative, chaque étape corrigeant ce que la précédente n'a pas capturé, contrairement au bagging qui entraîne tous ses modèles indépendamment sur les données brutes.

14.10 --- Apprentissage non supervisé : k-means, ACP, et synthèse du chapitre

Retour à l'apprentissage non supervisé (§14.1) pour deux outils phares, puis panorama comparatif de l'ensemble des méthodes du chapitre.

k-means

L'algorithme **k-means** partitionne n observations en k groupes (*clusters*) en minimisant la somme des distances au carré entre chaque observation et le **centroïde** (moyenne) de son groupe :

$$\min_{\{C_1,\dots,C_k\}} \sum_{c=1}^{k} \sum_{x_i \in C_c} \|x_i - \mu_c\|^2, \qquad \mu_c = \frac{1}{|C_c|} \sum_{x_i \in C_c} x_i.$$

Analyse en composantes principales (ACP)

L'**analyse en composantes principales** (ACP) transforme p variables corrélées en p nouvelles variables non corrélées (**composantes principales**), ordonnées par variance décroissante expliquée, obtenues comme combinaisons linéaires des variables originales alignées sur les **vecteurs propres** de la matrice de covariance.

Algorithme k-means — deux étapes alternées

Affectation : assigner chaque x_i au centroïde μ_c le plus proche.

Mise à jour : recalculer chaque μ_c comme la moyenne des points qui lui sont affectés.

Répéter jusqu'à convergence (stabilisation des affectations).

k-means : sensibilité à l'initialisation et choix de k

L'algorithme k-means converge vers un **minimum local**, pas nécessairement global : le résultat dépend de l'initialisation aléatoire des centroïdes, d'où la pratique de relancer l'algorithme plusieurs fois avec des initialisations différentes et de retenir la meilleure solution. Le nombre de groupes k n'est pas estimé par l'algorithme : il est choisi *a priori*, souvent via la **méthode du coude** (*elbow method*), qui repère le point où l'ajout d'un groupe supplémentaire cesse de réduire significativement l'inertie intra-groupe.

ACP : réduction de dimension avant apprentissage supervisé

Au-delà de la visualisation, l'ACP sert fréquemment de **prétraitement** : remplacer p variables corrélées par les $k < p$ premières composantes principales (qui capturent l'essentiel de la variance) atténue la multicolinéarité et le fléau de la dimension (§14.6) avant d'appliquer un modèle supervisé — au prix d'une perte d'interprétabilité directe, puisque chaque composante est une combinaison linéaire de toutes les variables originales.

Synthèse : quelle méthode pour quel problème

Face à peu de variables, une relation approximativement linéaire, et un besoin d'interprétabilité : **régression (éventuellement régularisée)**. Face à de nombreuses variables corrélées et un besoin de sélection : **Lasso**.

Face à des interactions complexes et un besoin d'interprétabilité directe : **arbre isolé (peu profond)**. Face à la performance prédictive maximale, interprétabilité secondaire : **forêt aléatoire ou boosting**. Face à des données sans étiquette à structurer : **k-means (groupes) ou ACP (dimensions)**. Aucune hiérarchie absolue : le choix dépend des données, de l'objectif (prédiction vs inférence) et des contraintes réglementaires d'explicabilité (particulièrement strictes en scoring de crédit).

Limites transversales du machine learning en gestion des risques

Trois limites méthodologiques traversent tout le chapitre. **Boîte noire réglementaire** : les modèles complexes (forêts, boosting, réseaux de neurones) sont difficiles à expliquer à un régulateur ou un client refusé de crédit — un enjeu croissant (droit à l'explication). **Stabilité temporelle** : un modèle entraîné sur des données historiques peut se dégrader si la relation sous-jacente change (*concept drift*), nécessitant un réentraînement et une surveillance continue. **Le ML ne remplace pas le jugement de risque** : un modèle prédictif performant en moyenne peut échouer précisément dans les scénarios de queue (crises, régimes inédits) qui intéressent le plus le gestionnaire de risques — d'où la nécessité de le combiner avec les méthodes de stress-testing et de simulation du chapitre 13.

Exemple travaillé --- une itération de k-means et variance expliquée par l'ACP

k-means. Cinq positions de portefeuille sont décrites par (rendement, volatilité) standardisés : $P_1(-1.2,-0.9)$, $P_2(-0.8,-1.1)$, $P_3(0.9,1.0)$, $P_4(1.1,0.7)$, $P_5(0.0,0.1)$. Initialisation avec $k=2$ centroïdes : $\mu_1=(-1.0,-1.0)$, $\mu_2=(1.0,1.0)$. **Étape d'affectation** : P_1,P_2 plus proches de μ_1 ; P_3,P_4 plus proches de μ_2 ; $P_5(0.0,0.1)$: distance à $\mu_1=\sqrt{1.0^2+1.1^2}=1.49$, distance à $\mu_2=\sqrt{1.0^2+0.9^2}=1.35$ $\rightarrow$ affecté à μ_2. **Étape de mise à jour** : $\mu_1=\left(\frac{-1.2-0.8}{2},\frac{-0.9-1.1}{2}\right)=(-1.0,-1.0)$ (inchangé) ; $\mu_2=\left(\frac{0.9+1.1+0.0}{3},\frac{1.0+0.7+0.1}{3}\right)=(0.67,0.60)$. Les affectations restant stables à l'itération suivante, l'algorithme a **convergé** : deux groupes de risque distincts (positions « perdantes corrélées » vs « gagnantes/neutres ») émergent sans étiquette préalable.
ACP. Sur 4 variables macro standardisées, les valeurs propres de la matrice de covariance sont $\zeta=(2.6,\ 0.9,\ 0.4,\ 0.1)$, somme $=4.0$ ($=p$, cohérent pour des données standardisées). Variance expliquée par composante : 65%, 22.5%, 10%, 2.5%. Les deux premières composantes principales cumulent 87.5% de la variance totale : un analyste peut légitimement réduire les 4 variables originales à ces 2 composantes pour un modèle supervisé en aval, avec une perte d'information limitée à 12.5%.

Partie B --- 200 études de cas pratiques

Chaque cas propose une question ciblée et une solution détaillée, couvrant l'ensemble des dix thèmes du cours. Travaillez crayon en main : cachez la solution, résolvez, comparez.

Bloc 1 --- Apprentissage supervisé, non supervisé, rôle du ML

Cas 1 — Apprentissage supervisé, définition. Qu'est-ce que l'apprentissage supervisé ?

Solution. Un algorithme apprend f tel que $\hat{y}_i=f(x_i)$ approxime une cible **connue** y_i, à partir de paires (x_i,y_i).

Cas 2 — Apprentissage non supervisé, définition. Qu'est-ce que l'apprentissage non supervisé ?

Solution. Aucune cible y fournie : l'algorithme cherche une structure cachée (groupes, directions de variance) dans les seules variables x_i.

Cas 3 — Régression vs classification. Distinguer régression et classification en apprentissage supervisé.

Solution. **Régression** : cible y continue. **Classification** : cible y catégorielle (ex. défaut/non-défaut).

Cas 4 — ML vs statistique classique. Quelle est la différence de priorité entre ML et statistique classique ?

Solution. Le ML priorise la **qualité prédictive** hors-échantillon ; la statistique classique priorise l'**inférence** et l'interprétation des coefficients.

Cas 5 — Exemple : forêt aléatoire et interprétabilité. Pourquoi une forêt de 500 arbres est-elle difficile à interpréter comme un coefficient unique ?

Solution. Elle agrège 500 modèles distincts : aucun coefficient unique ne résume la relation globale.

Cas 6 — Scoring de crédit. Pourquoi le ML est-il utile en scoring de crédit ?

Solution. Il capture des **interactions non linéaires** entre centaines de variables, au-delà d'une régression logistique simple.

Cas 7 — Détection de fraude. Pourquoi les méthodes d'ensemble conviennent-elles à la détection de fraude ?

Solution. La fraude est une structure **rare et non linéaire** : les ensembles (forêts, boosting) excellent sur ce type de motif.

Cas 8 — Segmentation de clientèle. Quel type d'apprentissage convient à la segmentation de clientèle sans catégories prédéfinies ?

Solution. L'apprentissage **non supervisé** (clustering, k-means).

Cas 9 — Échantillon d'entraînement. À quoi sert l'échantillon d'entraînement ?

Solution. À **ajuster** les paramètres du modèle.

Cas 10 — Échantillon de validation. À quoi sert l'échantillon de validation ?

Solution. À **choisir les hyperparamètres** (ex. λ, profondeur d'arbre).

Cas 11 — Échantillon de test. Pourquoi l'échantillon de test ne doit-il être consulté qu'une seule fois ?

Solution. Pour obtenir une estimation **non biaisée** de la performance de généralisation.

Cas 12 — Fuite de données. Qu'est-ce que la fuite de données (*data leakage*) ?

Solution. Ajuster le modèle en observant, directement ou indirectement, l'échantillon de test — ce qui biaise optimistement la performance estimée.

Cas 13 — Confondre validation et test. Pourquoi est-il risqué de confondre validation et test ?

Solution. Le modèle finit indirectement calibré sur le test, rendant l'estimation de performance finale trop optimiste.

Cas 14 — La régression linéaire est-elle du ML ? La régression linéaire est-elle un outil ML ou statistique classique ?

Solution. **Les deux** : la frontière n'est pas nette, c'est un algorithme supervisé élémentaire aussi bien qu'un outil statistique classique.

Cas 15 — Cible catégorielle. Un modèle prédisant le défaut ou non d'une contrepartie relève-t-il de la régression ou de la classification ?

Solution. De la **classification** (cible catégorielle binaire).

Cas 16 — Sans étiquette. Un jeu de données de positions de portefeuille sans catégorie de risque prédéfinie appelle quel type d'apprentissage pour les regrouper ?

Solution. **Non supervisé** (clustering).

Cas 17 — Le compromis interprétabilité/performance. Quel compromis le praticien ML accepte-t-il souvent ?

Solution. Sacrifier l'**interprétabilité** au profit de la **performance prédictive**.

Cas 18 — Cible connue pour l'entraînement. Pourquoi le scoring de crédit est-il un problème supervisé ?

Solution. L'historique fournit des défauts **observés** (cible y connue) associés à des variables x.

Cas 19 — Trois usages du ML en gestion des risques. Citer trois usages typiques du ML en gestion des risques.

Solution. **Scoring de crédit, détection de fraude/anomalies, segmentation** de clientèle ou de risques.

Cas 20 — Résumé du positionnement du ML. Résumer en une phrase ce qui distingue fondamentalement supervisé et non supervisé.

Solution. La présence ou l'absence d'une **cible connue** y à prédire.

Bloc 2 --- Biais-variance et surapprentissage

Cas 21 — Décomposition biais-variance. Donner la décomposition de l'erreur quadratique attendue.

Solution. Biais^2 + Variance + bruit irréductible σ_ε^2.

Cas 22 — Définition du biais. Que mesure le biais d'un estimateur de fonction ?

Solution. L'écart systématique $\mathbb{E}[\hat{f}(x)] - f(x)$, indépendant du hasard d'échantillonnage.

Cas 23 — Définition de la variance. Que mesure la variance d'un estimateur de fonction ?

Solution. La sensibilité de $\hat{f}(x)$ au hasard de l'échantillon d'entraînement utilisé.

Cas 24 — Sous-apprentissage. Qu'est-ce que le sous-apprentissage ?

Solution. Un modèle trop simple, à **biais élevé**, systématiquement éloigné de la vérité.

Cas 25 — Surapprentissage. Qu'est-ce que le surapprentissage ?

Solution. Un modèle trop complexe, à **variance élevée**, qui épouse le bruit de l'échantillon d'entraînement.

Cas 26 — Exemple de sous-apprentissage. Une droite ajustée à une relation fortement courbe illustre quel problème ?

Solution. Le **sous-apprentissage** (biais élevé).

Cas 27 — Exemple de surapprentissage. Un polynôme de degré 20 ajusté à 30 points illustre quel problème ?

Solution. Le **surapprentissage** (variance élevée).

Cas 28 — Objectif du bon modèle. Que minimise le modèle optimal en termes de biais et variance ?

Solution. La **somme** des deux (biais^2 + variance), pas l'un isolément.

Cas 29 — Symptôme diagnostique du surapprentissage. Quel est le signal diagnostique le plus fiable du surapprentissage ?

Solution. Un **écart croissant** entre erreur d'entraînement (faible) et erreur de test (qui remonte).

Cas 30 — Erreur d'entraînement proche de zéro. Une erreur d'entraînement proche de zéro est-elle un succès ?

Solution. **Non** : c'est un signal d'alarme de possible surapprentissage.

Cas 31 — Point optimal de complexité. Quel critère détermine le point optimal de complexité d'un modèle ?

Solution. La **minimisation de l'erreur de test** (hors-échantillon), non l'erreur d'entraînement.

Cas 32 — Remède : régularisation. Comment la régularisation combat-elle le surapprentissage ?

Solution. En pénalisant la **complexité** (taille des coefficients).

Cas 33 — Remède : élagage. Comment l'élagage combat-il le surapprentissage d'un arbre ?

Solution. En limitant sa **profondeur** ou en supprimant des branches peu utiles.

Cas 34 — Remède : agrégation. Comment l'agrégation (bagging) combat-elle le surapprentissage ?

Solution. En **moyennant** plusieurs modèles instables pour réduire la variance sans augmenter le biais.

Cas 35 — Remède : validation croisée. Quel rôle joue la validation croisée face au surapprentissage ?

Solution. Elle mesure honnêtement l'erreur de généralisation pour **choisir le bon niveau de complexité**.

Cas 36 — Biais et modèle linéaire simple. Un modèle linéaire simple sur une relation non linéaire a-t-il plutôt un biais ou une variance élevée ?

Solution. Un **biais élevé**.

Cas 37 — Variance et arbre profond. Un arbre de décision très profond (non élagué) a-t-il plutôt un biais ou une variance élevée ?

Solution. Une **variance élevée**.

Cas 38 — Bruit irréductible. Le bruit irréductible σ_ε^2 peut-il être éliminé par un meilleur modèle ?

Solution. **Non** : il est intrinsèque aux données, indépendant du modèle choisi.

Cas 39 — Compromis biais-variance et complexité. Comment évoluent typiquement le biais et la variance quand la complexité du modèle augmente ?

Solution. Le **biais diminue**, la **variance augmente**.

Cas 40 — Synthèse du Bloc 2. Résumer en une phrase le concept unificateur du chapitre.

Solution. Extraire le **signal** sans capturer le **bruit** — équilibrer biais et variance.

Bloc 3 --- Validation croisée et évaluation de modèle

Cas 41 — Validation croisée à k plis, définition. Décrire le principe de la validation croisée à k plis.

Solution. Partager les données en k plis ; entraîner sur $k-1$ plis, évaluer sur le pli restant ; répéter k fois et moyenner.

Cas 42 — Valeurs usuelles de k. Quelles valeurs de k sont les plus courantes en pratique ?

Solution. $k = 5$ ou $k = 10$.

Cas 43 — Avantage vs simple split train/test. Pourquoi préférer la validation croisée à un simple split train/test ?

Solution. Chaque observation sert **exactement une fois** de test : estimation plus stable, moins dépendante du hasard du découpage.

Cas 44 — Coût de la validation croisée. Quel est le principal coût de la validation croisée à k plis ?

Solution. Le modèle doit être **réentraîné k fois** : temps de calcul multiplié par k.

Cas 45 — Métrique de régression. Citer une métrique usuelle pour évaluer un modèle de régression.

Solution. L'**erreur quadratique moyenne** (MSE) ou le R^2 hors-échantillon.

Cas 46 — Précision trompeuse. Pourquoi la simple précision est-elle trompeuse en classification déséquilibrée ?

Solution. Un modèle prédisant toujours la classe majoritaire (ex. « pas de défaut ») affiche une précision élevée sans aucune valeur prédictive.

Cas 47 — Matrice de confusion. Que représente la matrice de confusion ?

Solution. Le croisement des classes **prédites** et **réelles** (vrais/faux positifs, vrais/faux négatifs).

Cas 48 — Sensibilité. Que mesure la sensibilité (taux de vrais positifs) ?

Solution. La proportion de **positifs réels correctement identifiés**.

Cas 49 — Courbe ROC et AUC. Que représente l'aire sous la courbe ROC (AUC) ?

Solution. La capacité globale du modèle à **discriminer** les deux classes, insensible au déséquilibre des classes.

Cas 50 — Usage principal de la validation croisée en pratique. Quel est l'usage le plus fréquent de la validation croisée ?

Solution. **Choisir un hyperparamètre** (ex. λ, profondeur d'arbre, k de k-NN) par balayage de grille.

Cas 51 — Protocole complet. Décrire le protocole complet : validation croisée puis test.

Solution. Choisir l'hyperparamètre par CV sur l'entraînement, puis évaluer le modèle final (avec cet hyperparamètre) sur le test **indépendant**, une seule fois.

Cas 52 — CV et petit échantillon. Pourquoi la validation croisée est-elle particulièrement utile sur un petit échantillon ?

Solution. Elle exploite **toutes** les observations à la fois pour l'entraînement et le test (à tour de rôle), sans en gaspiller.

Cas 53 — Spécificité. Que mesure la spécificité ?

Solution. La proportion de **négatifs réels correctement identifiés** (taux de vrais négatifs).

Cas 54 — Choix de k en CV. Un k de validation croisée égal à n (autant de plis que d'observations) porte quel nom ?

Solution. La validation croisée **leave-one-out** (LOOCV).

Cas 55 — Coût du LOOCV. Quel est l'inconvénient principal du LOOCV ?

Solution. Un coût de calcul très élevé : n réentraînements complets du modèle.

Cas 56 — Erreur de validation croisée, formule. Comment se calcule l'erreur de validation croisée globale ?

Solution. La **moyenne** des k erreurs obtenues sur chaque pli laissé de côté.

Cas 57 — Classe rare en scoring. Le taux de défaut d'un portefeuille est de 2%. Quelle métrique privilégier plutôt que la précision brute ?

Solution. La courbe **ROC/AUC** ou la matrice de confusion complète (sensibilité, spécificité).

Cas 58 — CV et instabilité du découpage. Que corrige la validation croisée par rapport à un split unique ?

Solution. La **dépendance au hasard** du découpage particulier retenu.

Cas 59 — Choix de l'hyperparamètre final. Sur quel critère retient-on la valeur finale d'un hyperparamètre après une grille de validation croisée ?

Solution. Celle qui **minimise l'erreur de validation croisée** moyenne.

Cas 60 — Synthèse du Bloc 3. Résumer en une phrase le rôle de la validation croisée.

Solution. Estimer honnêtement la performance de généralisation et guider le choix des hyperparamètres, sans toucher au test final.

Bloc 4 --- Régression Ridge

Cas 61 — Objectif Ridge. Écrire l'objectif minimisé par la régression Ridge.

Solution. $\sum(y_i - x_i^\top \beta)^2 + \lambda \sum \beta_j^2$.

Cas 62 — Rôle de $\lambda = 0$. Que devient Ridge quand $\lambda = 0$?

Solution. Il coïncide exactement avec les **moindres carrés ordinaires**.

Cas 63 — Rôle de $\lambda \to \infty$. Que devient Ridge quand $\lambda \to \infty$?

Solution. Tous les coefficients sont **écrasés vers zéro**.

Cas 64 — Motivation : multicolinéarité. Pourquoi Ridge est-il utile en présence de multicolinéarité ?

Solution. Il **stabilise** l'inversion de $X^\top X$, proche de la singularité, réduisant la variance des coefficients estimés.

Cas 65 — Solution fermée Ridge. Donner la solution fermée de Ridge.

Solution. $\hat{\beta}^{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$.

Cas 66 — Ridge met-il des coefficients à zéro ? Ridge peut-il annuler exactement un coefficient ?

Solution. **Non** (sauf $\lambda \to \infty$) : la région de contrainte est lisse (hypersphère), sans coin.

Cas 67 — Ridge = shrinkage ou sélection ? Ridge est-il un outil de rétrécissement ou de sélection de variables ?

Solution. De **rétrécissement** (*shrinkage*) uniquement.

Cas 68 — Standardisation préalable. Pourquoi standardiser les variables avant Ridge ?

Solution. La pénalité traite tous les coefficients symétriquement ; sans standardisation, l'échelle des unités biaiserait la pénalisation relative.

Cas 69 — Effet sur le biais. Ridge introduit-il un biais ?

Solution. **Oui** : les coefficients sont systématiquement rétrécis vers zéro, en échange d'une variance réduite.

Cas 70 — Choix de λ. Comment choisir λ en pratique ?

Solution. Par **validation croisée**, en balayant une grille de valeurs.

Cas 71 — Ridge et petit n, grand p. Pourquoi Ridge est-il utile quand $p > n$ (plus de variables que d'observations) ?

Solution. $X^\top X$ est alors **singulière** (non inversible) sans pénalité ; Ridge la rend inversible.

Cas 72 — Comportement des coefficients corrélés. Comment Ridge traite-t-il deux variables fortement corrélées ?

Solution. Il tend à **répartir** le poids entre elles de façon plus équilibrée, plutôt que d'en écraser une arbitrairement.

Cas 73 — Pénalité ℓ_2. Comment nomme-t-on la pénalité de Ridge ?

Solution. Pénalité ℓ_2 (norme euclidienne au carré des coefficients).

Cas 74 — Ridge et interprétabilité. Ridge améliore-t-il l'interprétabilité par réduction du nombre de variables actives ?

Solution. **Non** : toutes les variables restent dans le modèle, avec des coefficients rétrécis.

Cas 75 — Géométrie de la contrainte Ridge. Quelle est la forme géométrique de la région de contrainte $\sum \beta_j^2 \leq c$ en dimension 2 ?

Solution. Un **cercle** (disque), sans coin.

Cas 76 — Ridge et variance de l'estimateur. L'ajout de λI dans l'inversion a quel effet sur la variance de $\hat{\beta}$?

Solution. Il la **réduit**, en éloignant la matrice de la singularité.

Cas 77 — Application : taux de défaut et variables macro corrélées. Un modèle de taux de défaut utilise dix variables macroéconomiques fortement corrélées entre elles. Quelle méthode de régularisation privilégier en premier lieu ?

Solution. **Ridge**, pour stabiliser les coefficients face à la colinéarité, avant d'envisager une sélection.

Cas 78 — Ridge et coefficients tous non nuls. Après ajustement Ridge, combien de coefficients sont généralement exactement nuls sur $p = 50$ variables ?

Solution. **Aucun** (0), sauf cas limite $\lambda \to \infty$.

Cas 79 — Comparaison à MCO en présence de bruit. Pourquoi Ridge généralise-t-il souvent mieux que les MCO sur des données bruitées ?

Solution. Il **réduit la variance** de l'estimateur, au prix d'un léger biais — meilleur compromis en présence de bruit.

Cas 80 — Synthèse du Bloc 4. Résumer en une phrase le principe de Ridge.

Solution. Pénaliser la **somme des carrés** des coefficients pour réduire la variance, sans jamais les annuler.

Bloc 5 --- Régression Lasso et sélection de variables

Cas 81 — Objectif Lasso. Écrire l'objectif minimisé par la régression Lasso.

Solution. $\sum(y_i - x_i^\top\beta)^2 + \lambda\sum|\beta_j|$.

Cas 82 — Pénalité ℓ_1. Comment nomme-t-on la pénalité du Lasso ?

Solution. Pénalité ℓ_1 (somme des valeurs absolues).

Cas 83 — Lasso et sélection de variables. Le Lasso peut-il annuler exactement des coefficients ?

Solution. **Oui** : c'est sa propriété distinctive — sélection automatique de variables.

Cas 84 — Géométrie de la contrainte Lasso. Quelle est la forme de la région de contrainte $\sum|\beta_j| \le c$ en dimension 2 ?

Solution. Un **losange** (polytope à coins).

Cas 85 — Pourquoi les coins produisent des zéros. Pourquoi les coins de la contrainte Lasso produisent-ils des coefficients nuls ?

Solution. Les courbes de niveau elliptiques des résidus ont une probabilité non négligeable de toucher la contrainte **exactement en un coin**, où un ou plusieurs $\beta_j = 0$.

Cas 86 — Lasso vs Ridge, colinéarité. Comment le Lasso traite-t-il un groupe de variables fortement corrélées ?

Solution. Il tend à en retenir **arbitrairement une seule** du groupe, contrairement à Ridge qui les répartit.

Cas 87 — Avantage du Lasso : interprétabilité. Pourquoi le Lasso est-il plus interprétable que Ridge ?

Solution. Seules les variables à **coefficient non nul** entrent dans le récit du modèle.

Cas 88 — Lasso et grand p. Pourquoi le Lasso est-il utile face à des centaines de variables candidates ?

Solution. Il **sélectionne automatiquement** un sous-ensemble parcimonieux, réduisant le risque de surapprentissage.

Cas 89 — Instabilité du Lasso. Quel est un inconvénient du Lasso en présence de variables corrélées ?

Solution. Le choix de la variable retenue dans un groupe corrélé peut être **instable** d'une exécution à l'autre.

Cas 90 — Elastic Net, définition. Qu'est-ce que l'Elastic Net ?

Solution. Une combinaison linéaire des pénalités ℓ_1 et ℓ_2 : $\lambda[\alpha\sum|\beta_j| + (1-\alpha)\sum\beta_j^2]$.

Cas 91 — Motivation de l'Elastic Net. Pourquoi utiliser l'Elastic Net plutôt que le Lasso seul ?

Solution. Pour bénéficier de la **sélection** du Lasso tout en gérant mieux la **colinéarité** comme Ridge.

Cas 92 — Choix de λ pour Lasso. Comment choisir λ pour le Lasso en pratique ?

Solution. Par **validation croisée**, comme pour Ridge.

Cas 93 — Lasso et modèle parcimonieux. Qu'entend-on par modèle « parcimonieux » produit par le Lasso ?

Solution. Un modèle avec **peu de coefficients non nuls** parmi toutes les variables candidates.

Cas 94 — Standardisation et Lasso. La standardisation préalable est-elle nécessaire pour le Lasso ?

Solution. **Oui**, pour la même raison que Ridge : traiter les variables sur une échelle comparable.

Cas 95 — Application : spread de crédit, 300 variables. Un modèle de spread de crédit dispose de 300 variables candidates macro et sectorielles. Quelle méthode privilégier pour obtenir un modèle interprétable et parcimonieux ?

Solution. Le **Lasso** (ou Elastic Net si les variables sont fortement corrélées entre elles).

Cas 96 — Lasso à $\lambda = 0$. Que devient le Lasso quand $\lambda = 0$?

Solution. Il coïncide avec les **moindres carrés ordinaires**.

Cas 97 — Lasso à λ élevé. Que se passe-t-il quand λ du Lasso devient très grand ?

Solution. De plus en plus de coefficients sont **annulés**, jusqu'à un modèle vide (tous nuls).

Cas 98 — Ridge vs Lasso, résumé. Résumer la différence fondamentale entre Ridge et Lasso.

Solution. Ridge **rétrécit sans annuler** ; Lasso peut **annuler et sélectionner**.

Cas 99 — Elastic Net et α. Que représente le paramètre α de l'Elastic Net ?

Solution. Le **poids relatif** entre pénalité ℓ_1 (Lasso) et ℓ_2 (Ridge), $\alpha \in [0, 1]$.

Cas 100 — Synthèse du Bloc 5. Résumer en une phrase l'apport distinctif du Lasso.

Solution. Une pénalité ℓ_1 qui, grâce à sa géométrie à coins, réalise une **sélection automatique de variables**.

Bloc 6 --- K plus proches voisins

Cas 101 — k-NN, principe. Décrire le principe de l'algorithme k-NN.

Solution. Prédire à partir des k observations les plus proches de x : moyenne (régression) ou vote majoritaire (classification).

Cas 102 — Distance usuelle. Quelle distance est la plus couramment utilisée en k-NN ?

Solution. La distance **euclidienne**.

Cas 103 — k-NN, apprentissage paresseux. Pourquoi dit-on que k-NN est un algorithme « paresseux » ?

Solution. Il ne fait **aucun calcul** à l'entraînement (mémorisation des données), tout le travail se fait à la prédiction.

Cas 104 — k-NN, non paramétrique. Pourquoi k-NN est-il dit non paramétrique ?

Solution. Il ne fait aucune hypothèse de **forme fonctionnelle** a priori.

Cas 105 — Effet de k petit. Quel est l'effet d'un k petit (ex. $k = 1$) sur le biais et la variance ?

Solution. **Variance élevée** : très sensible au bruit local, frontière irrégulière.

Cas 106 — Effet de k grand. Quel est l'effet d'un k très grand (proche de n) ?

Solution. **Biais élevé** : lissage excessif, proche de prédire la moyenne globale.

Cas 107 — Choix de k. Comment choisir k en pratique ?

Solution. Par **validation croisée**.

Cas 108 — Fléau de la dimension. Qu'est-ce que le fléau de la dimension pour k-NN ?

Solution. En grande dimension, tous les points deviennent « également éloignés », dégradant la notion de proximité.

Cas 109 — Remède au fléau de la dimension. Quel prétraitement aide k-NN face au fléau de la dimension ?

Solution. Une **réduction de dimension préalable** (ex. ACP).

Cas 110 — k-NN classification vs régression. Comment k-NN produit-il une prédiction en classification ?

Solution. Par **vote majoritaire** des classes des k voisins.

Cas 111 — k-NN et standardisation. Pourquoi standardiser les variables avant k-NN ?

Solution. La distance euclidienne est sensible à l'échelle : une variable à large échelle dominerait sinon le calcul de distance.

Cas 112 — k=1 et surapprentissage. k-NN avec $k = 1$ surapprend-il systématiquement ?

Solution. **Généralement oui** : la prédiction épouse exactement chaque point d'entraînement (variance maximale).

Cas 113 — k-NN, aucun paramètre estimé. Combien de paramètres k-NN estime-t-il lors de l'entraînement ?

Solution. **Aucun** : il mémorise simplement les données.

Cas 114 — Coût de prédiction k-NN. Le coût de calcul de k-NN est-il concentré à l'entraînement ou à la prédiction ?

Solution. À la **prédiction** (recherche des voisins les plus proches).

Cas 115 — k-NN et grandes bases de données. Pourquoi k-NN peut-il être lent sur de très grandes bases de données ?

Solution. Chaque prédiction nécessite de comparer la nouvelle observation à **toutes** les observations d'entraînement.

Cas 116 — k pair en classification binaire. Pourquoi éviter un k pair en classification à deux classes ?

Solution. Pour éviter les **égalités de vote** (ex-aequo) entre les deux classes.

Cas 117 — k-NN et frontière de décision. La frontière de décision de k-NN peut-elle être non linéaire ?

Solution. **Oui**, elle épouse n'importe quelle forme, contrairement à une régression logistique linéaire.

Cas 118 — Application : scoring avec peu de variables. k-NN convient-il bien à un scoring avec seulement 3 variables bien choisies ?

Solution. **Oui** : en faible dimension, la notion de proximité reste discriminante.

Cas 119 — k-NN et variables catégorielles. k-NN gère-t-il nativement des variables catégorielles avec la distance euclidienne standard ?

Solution. **Non directement** : il faut les encoder numériquement (ex. encodage one-hot) au préalable.

Cas 120 — Synthèse du Bloc 6. Résumer en une phrase le principe de k-NN.

Solution. Prédire par **ressemblance** aux observations déjà vues, sans modèle paramétrique explicite.

Bloc 7 --- Arbres de décision

Cas 121 — Arbre de décision, principe. Décrire le principe d'un arbre de décision.

Solution. Partitionner récursivement l'espace des variables par des règles binaires, jusqu'à des feuilles donnant la prédiction.

Cas 122 — Impureté de Gini. Donner la formule de l'impureté de Gini.

Solution. $G = \sum_c \hat{p}_c(1 - \hat{p}_c)$.

Cas 123 — Gini = 0. Que signifie $G = 0$ pour un nœud ?

Solution. Le nœud est **parfaitement pur** (une seule classe présente).

Cas 124 — Construction gloutonne. Pourquoi dit-on que la construction d'un arbre est « gloutonne » ?

Solution. Chaque scission est choisie **optimale localement**, sans garantie d'optimalité globale sur l'arbre entier.

Cas 125 — Critère de scission en régression. Quel critère remplace Gini pour un arbre de régression ?

Solution. La **somme des carrés résiduels** intra-région.

Cas 126 — Arbre non contraint. Que se passe-t-il si un arbre est développé jusqu'à des feuilles parfaitement pures ?

Solution. Il **surapprend** presque toujours (isole des observations bruitées individuelles).

Cas 127 — Hyperparamètres d'arrêt précoce. Citer deux hyperparamètres permettant de limiter la croissance d'un arbre.

Solution. La **profondeur maximale** et le **nombre minimal d'observations par feuille**.

Cas 128 — Élagage. Qu'est-ce que l'élagage (*pruning*) d'un arbre ?

Solution. Supprimer, après coup, les branches d'un arbre initialement grand qui n'améliorent pas l'erreur de **validation**.

Cas 129 — Avantage : interprétabilité. Quel est le principal avantage d'un arbre isolé ?

Solution. Il est **directement interprétable** : les règles de décision se lisent explicitement.

Cas 130 — Interactions non linéaires. Un arbre gère-t-il nativement les interactions entre variables ?

Solution. **Oui**, sans avoir à les spécifier explicitement (contrairement à une régression linéaire).

Cas 131 — Limite majeure d'un arbre isolé. Quelle est la limite majeure d'un arbre de décision isolé ?

Solution. Une forte **instabilité** : petite perturbation des données $\rightarrow$ structure d'arbre très différente (variance élevée).

Cas 132 — Variables catégorielles et arbres. Les arbres gèrent-ils nativement les variables catégorielles ?

Solution. **Oui**, sans nécessiter d'encodage numérique préalable (contrairement à k-NN ou Ridge/Lasso).

Cas 133 — Comment choisir la variable de scission. Comment l'algorithme choisit-il la variable et le seuil à chaque nœud ?

Solution. Ceux qui **minimisent l'impureté pondérée** des deux nœuds enfants résultants.

Cas 134 — Hypothèse de distribution. Un arbre de décision fait-il une hypothèse de distribution des données ?

Solution. **Non**, aucune hypothèse paramétrique de distribution.

Cas 135 — Arbre optimal globalement. La construction gloutonne garantit-elle l'arbre optimal parmi tous les arbres possibles ?

Solution. **Non** : la recherche globalement optimale serait combinatoirement intraitable.

Cas 136 — Motivation des méthodes d'ensemble. Pourquoi l'instabilité d'un arbre isolé motive-t-elle les méthodes d'ensemble ?

Solution. Moyenner plusieurs arbres instables mais peu biaisés **réduit la variance** sans détériorer le biais.

Cas 137 — Feuille terminale. Que représente une feuille d'un arbre de régression ?

Solution. La **moyenne des** y des observations tombées dans cette région.

Cas 138 — Application : règles de crédit lisibles. Un régulateur exige des règles de refus de crédit explicables. Quelle méthode privilégier en premier lieu ?

Solution. Un **arbre de décision peu profond**, directement lisible.

Cas 139 — Profondeur et biais-variance. Comment la profondeur d'un arbre influence-t-elle le compromis biais-variance ?

Solution. Une profondeur **plus grande** réduit le biais mais augmente la variance (et inversement).

Cas 140 — Synthèse du Bloc 7. Résumer en une phrase l'atout et la faiblesse d'un arbre isolé.

Solution. **Interprétable** et flexible, mais **instable** (variance élevée) — d'où les méthodes d'ensemble.

Bloc 8 --- Bagging et forêts aléatoires

Cas 141 — Bagging, principe. Décrire le principe du bagging.

Solution. Générer B échantillons bootstrap, entraîner un modèle sur chacun, puis **moyenner** (ou voter) les B prédictions.

Cas 142 — Forêt aléatoire, spécificité. Qu'ajoute la forêt aléatoire au bagging simple d'arbres ?

Solution. À chaque scission, seul un **sous-ensemble aléatoire** de $m < p$ variables est considéré (typiquement $m \approx \sqrt{p}$).

Cas 143 — Formule de variance du moyennage. Donner la formule de variance d'une moyenne de B modèles corrélés (corrélation ρ).

Solution. $\rho\sigma^2 + \dfrac{1-\rho}{B}\sigma^2$.

Cas 144 — Rôle de $\rho \to 1$. Que se passe-t-il si les arbres du bagging sont tous fortement corrélés ($\rho \to 1$) ?

Solution. Le moyennage n'apporte **aucun bénéfice** de variance, quel que soit B.

Cas 145 — Pourquoi la sélection aléatoire de variables. Pourquoi la forêt aléatoire sélectionne-t-elle aléatoirement les variables à chaque scission ?

Solution. Pour **décorréler** les arbres (réduire ρ), rendant le moyennage effectivement bénéfique.

Cas 146 — Bagging et biais. Le bagging réduit-il le biais ou la variance ?

Solution. La **variance** ; le biais moyen reste globalement inchangé.

Cas 147 — Composants du bagging : arbres profonds. Pourquoi utilise-t-on des arbres profonds non élagués dans le bagging ?

Solution. Ils ont un **biais faible** (variance élevée individuellement) ; c'est l'agrégation qui gère la variance.

Cas 148 — Échantillon out-of-bag. Qu'est-ce que l'échantillon out-of-bag (OOB) ?

Solution. Les observations (environ 36.8%) **non tirées** dans un échantillon bootstrap donné.

Cas 149 — Fraction moyenne OOB. Quelle fraction moyenne des observations est laissée de côté par un tirage bootstrap ?

Solution. Environ $1/e \approx 36.8\%$.

Cas 150 — Utilité de l'OOB. À quoi sert l'erreur out-of-bag ?

Solution. Estimer l'erreur de généralisation **sans validation croisée séparée**.

Cas 151 — Nombre d'arbres B. Augmenter indéfiniment B dans une forêt aléatoire risque-t-il de surapprendre ?

Solution. **Non** (contrairement au boosting) : plus de B ne fait que stabiliser davantage la moyenne.

Cas 152 — Choix de m. Quelle valeur de m (variables candidates par scission) est typique en classification ?

Solution. $m \approx \sqrt{p}$.

Cas 153 — Forêt aléatoire et interprétabilité. Une forêt aléatoire est-elle aussi interprétable qu'un arbre isolé ?

Solution. **Non**, elle perd l'interprétabilité directe (règles lisibles) au profit de la performance.

Cas 154 — Importance des variables. Comment une forêt aléatoire permet-elle malgré tout d'estimer l'importance des variables ?

Solution. Par la **réduction moyenne d'impureté** apportée par chaque variable à travers tous les arbres.

Cas 155 — Bagging appliqué à autre chose que des arbres. Le bagging est-il limité aux arbres de décision ?

Solution. **Non**, il peut s'appliquer à tout modèle instable, mais les arbres profonds y sont particulièrement adaptés.

Cas 156 — Application : détection de fraude. Pourquoi une forêt aléatoire convient-elle bien à la détection de fraude à partir de nombreuses variables transactionnelles ?

Solution. Elle gère les **interactions non linéaires** nombreuses tout en contrôlant la variance par agrégation.

Cas 157 — Corrélation des arbres et bootstrap seul. Le simple bootstrap (sans sélection aléatoire de variables) suffit-il à décorréler fortement les arbres ?

Solution. **Non**, les arbres restent souvent corrélés via la variable dominante — d'où l'ajout de la sélection aléatoire de variables.

Cas 158 — Vote majoritaire. Comment une forêt aléatoire agrège-t-elle ses prédictions en classification ?

Solution. Par **vote majoritaire** des B arbres.

Cas 159 — Forêt aléatoire, coût de calcul. Le calcul d'une forêt aléatoire est-il parallélisable ?

Solution. **Oui**, chaque arbre est entraîné indépendamment — contrairement au boosting séquentiel.

Cas 160 — Synthèse du Bloc 8. Résumer en une phrase le principe des forêts aléatoires.

Solution. Moyenner de nombreux arbres profonds **décorrélés** (par bootstrap et sélection aléatoire de variables) pour réduire la variance.

Bloc 9 --- Boosting

Cas 161 — Boosting, principe. Décrire le principe du boosting.

Solution. Construire une séquence de modèles faibles, chacun corrigeant les **erreurs** des précédents.

Cas 162 — Bagging vs boosting : parallèle ou séquentiel. Le boosting est-il parallèle ou séquentiel ?

Solution. **Séquentiel** (contrairement au bagging, parallèle).

Cas 163 — Levier principal du boosting. Quel est le levier principal du boosting (biais ou variance) ?

Solution. La **réduction du biais**.

Cas 164 — Levier principal du bagging. Quel est le levier principal du bagging (biais ou variance) ?

Solution. La **réduction de la variance**.

Cas 165 — Modèles faibles. Que signifie un « modèle faible » en boosting ?

Solution. Un modèle à peine meilleur qu'un tirage aléatoire (ex. un arbre très peu profond, *stump*).

Cas 166 — Taux d'apprentissage ν. Que contrôle le taux d'apprentissage ν en boosting ?

Solution. La **contribution** de chaque modèle faible successif à la prédiction finale.

Cas 167 — ν petit. Quel est l'effet d'un ν petit ?

Solution. Apprentissage plus lent mais **risque de surapprentissage réduit**.

Cas 168 — Combinaison ν et M. Quelle combinaison donne généralement les meilleures performances en boosting ?

Solution. Un ν **petit** combiné à un grand nombre d'itérations M (choisi par validation croisée).

Cas 169 — Sensibilité aux valeurs aberrantes. Le boosting est-il plus ou moins sensible aux valeurs aberrantes que le bagging ?

Solution. **Plus sensible** : il cible explicitement les observations mal prédites, y compris les aberrantes.

Cas 170 — Augmenter M indéfiniment. Augmenter indéfiniment le nombre d'itérations M en boosting est-il toujours bénéfique ?

Solution. **Non**, contrairement au bagging — risque de surapprentissage au-delà d'un certain M.

Cas 171 — Arrêt anticipé. Qu'est-ce que l'arrêt anticipé (*early stopping*) en boosting ?

Solution. Arrêter les itérations quand l'erreur de **validation** cesse de s'améliorer (voire remonte).

Cas 172 — Forme additive du boosting. Écrire la forme générale de la prédiction finale en boosting.

Solution. $\hat{f}_M(x) = \sum_{m=1}^{M} \nu \, \hat{f}_m(x)$.

Cas 173 — Application : boosting en scoring. Pourquoi le boosting est-il souvent le modèle le plus performant sur des compétitions de scoring de crédit ?

Solution. Sa construction séquentielle réduit fortement le **biais** tout en restant flexible sur les interactions non linéaires.

Cas 174 — Boosting et interprétabilité. Le boosting est-il directement interprétable comme un arbre isolé ?

Solution. **Non** : c'est une somme pondérée de nombreux modèles faibles.

Cas 175 — AdaBoost, principe qualitatif. Comment AdaBoost ajuste-t-il l'importance des observations à chaque itération ?

Solution. Il **augmente le poids** des observations mal classées par les modèles précédents.

Cas 176 — Gradient boosting, principe qualitatif. Sur quoi le *gradient boosting* entraîne-t-il chaque nouveau modèle faible ?

Solution. Sur les **résidus** (erreurs) laissés par l'ensemble des modèles précédents.

Cas 177 — Boosting et parallélisation. Le boosting est-il aussi facilement parallélisable que le bagging ?

Solution. **Non**, sa nature séquentielle (chaque modèle dépend du précédent) limite la parallélisation.

Cas 178 — Choix conjoint des hyperparamètres. Quels hyperparamètres du boosting doit-on typiquement calibrer conjointement par validation croisée ?

Solution. Le **taux d'apprentissage** ν, le **nombre d'itérations** M, et la profondeur des arbres faibles.

Cas 179 — Boosting vs forêt aléatoire, robustesse. Lequel de boosting ou forêt aléatoire est généralement plus robuste au bruit sans réglage soigneux ?

Solution. La **forêt aléatoire**, plus robuste par défaut ; le boosting nécessite un réglage plus soigneux de ν et M.

Cas 180 — Synthèse du Bloc 9. Résumer en une phrase le principe distinctif du boosting.

Solution. Combiner séquentiellement des modèles faibles, chacun corrigeant les erreurs du précédent, pour réduire le **biais**.

Bloc 10 --- k-means, ACP et synthèse

Cas 181 — k-means, objectif. Écrire l'objectif minimisé par k-means.

Solution. $\sum_c \sum_{x_i \in C_c} \|x_i - \mu_c\|^2$ (inertie intra-groupe).

Cas 182 — k-means, les deux étapes. Décrire les deux étapes alternées de l'algorithme k-means.

Solution. **Affectation** (chaque point au centroïde le plus proche) et **mise à jour** (recalcul des centroïdes).

Cas 183 — Convergence de k-means. k-means converge-t-il vers un minimum local ou global ?

Solution. Un minimum **local**, dépendant de l'initialisation.

Cas 184 — Remède à la sensibilité d'initialisation. Comment atténuer la sensibilité de k-means à l'initialisation ?

Solution. Relancer l'algorithme plusieurs fois avec des initialisations différentes, retenir la **meilleure** solution.

Cas 185 — Choix de k, méthode du coude. Qu'est-ce que la méthode du coude pour choisir k ?

Solution. Repérer le point où ajouter un groupe supplémentaire cesse de réduire significativement l'**inertie intra-groupe**.

Cas 186 — ACP, définition. Que produit l'analyse en composantes principales ?

Solution. De nouvelles variables **non corrélées**, combinaisons linéaires des variables originales, ordonnées par variance décroissante.

Cas 187 — ACP, base mathématique. Sur quoi reposent les composantes principales ?

Solution. Les **vecteurs propres** de la matrice de covariance des variables originales.

Cas 188 — ACP comme prétraitement. À quoi sert l'ACP en amont d'un modèle supervisé ?

Solution. Réduire la **dimension** et atténuer la multicolinéarité et le fléau de la dimension.

Cas 189 — Coût de l'ACP en interprétabilité. Quel est le prix payé en utilisant les composantes principales plutôt que les variables originales ?

Solution. Une perte d'**interprétabilité directe** (chaque composante mélange toutes les variables originales).

Cas 190 — Choix de méthode : peu de variables, linéaire. Quelle méthode privilégier face à peu de variables et une relation approximativement linéaire ?

Solution. La **régression** (éventuellement régularisée).

Cas 191 — Choix de méthode : nombreuses variables corrélées, sélection. Quelle méthode privilégier pour sélectionner des variables parmi de nombreuses candidates corrélées ?

Solution. Le **Lasso** (ou Elastic Net).

Cas 192 — Choix de méthode : interprétabilité directe. Quelle méthode privilégier pour des interactions complexes avec besoin d'interprétabilité directe ?

Solution. Un **arbre isolé peu profond**.

Cas 193 — Choix de méthode : performance maximale. Quelle méthode privilégier pour la performance prédictive maximale, interprétabilité secondaire ?

Solution. Une **forêt aléatoire ou du boosting**.

Cas 194 — Choix de méthode : données sans étiquette. Quelle méthode privilégier pour structurer des données sans étiquette ?

Solution. **k-means** (groupes) ou **ACP** (dimensions).

Cas 195 — Limite : boîte noire réglementaire. Pourquoi les modèles complexes posent-ils un défi réglementaire en scoring de crédit ?

Solution. Ils sont difficiles à **expliquer** à un régulateur ou un client refusé (droit à l'explication).

Cas 196 — Limite : dérive de concept. Qu'est-ce que le *concept drift* ?

Solution. La dégradation d'un modèle quand la relation sous-jacente entre x et y **change dans le temps**.

Cas 197 — Limite : queues de distribution. Pourquoi un modèle ML performant en moyenne peut-il échouer en scénario de crise ?

Solution. Il peut mal généraliser aux **régimes inédits** (queues de distribution), justement ceux qui intéressent le gestionnaire de risques.

Cas 198 — ML et stress-testing. Pourquoi combine-t-on ML et simulation (chapitre 13) en gestion des risques ?

Solution. Le ML capture bien les relations moyennes ; la simulation/stress-testing explore les **scénarios de queue** que le ML seul peut manquer.

Cas 199 — Absence de hiérarchie absolue. Existe-t-il une hiérarchie absolue entre toutes les méthodes du chapitre ?

Solution. **Non** : le choix dépend des données, de l'objectif (prédiction vs inférence) et des contraintes d'explicabilité.

Cas 200 — Synthèse générale du chapitre. Résumer en une phrase le fil rouge de tout le chapitre 14.

Solution. Apprendre le **signal** sans mémoriser le **bruit** — chaque méthode est une réponse différente à ce même compromis biais-variance.

Partie C --- Méthodologie, formulaire et astuces

C.1 --- Formulaire complet

Décomposition biais-variance

$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Biais}[\hat{f}(x)]^2 + \text{Var}[\hat{f}(x)] + \sigma_\varepsilon^2.$$

Validation croisée à k plis

$$\text{CV}_{(k)} = \frac{1}{k}\sum_{j=1}^{k} \text{Erreur}(\hat{f}^{(-j)}, \text{pli } j).$$

Ridge

$$\hat{\beta}^{\text{Ridge}} = \arg\min_{\beta} \left\{ \sum_i (y_i - x_i^\top \beta)^2 + \lambda \sum_j \beta_j^2 \right\} = (X^\top X + \lambda I)^{-1} X^\top y.$$

Lasso

$$\hat{\beta}^{\text{Lasso}} = \arg\min_{\beta} \left\{ \sum_i (y_i - x_i^\top \beta)^2 + \lambda \sum_j |\beta_j| \right\}.$$

Elastic Net

$$\hat{\beta}^{\text{EN}} = \arg\min_{\beta} \left\{ \sum_i (y_i - x_i^\top \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + (1-\alpha) \sum_j \beta_j^2 \right] \right\}.$$

Distance euclidienne (k-NN)

$$d(x, x') = \sqrt{\sum_{j=1}^{p} (x_j - x'_j)^2}.$$

Impureté de Gini

$$G = \sum_{c=1}^{C} \hat{p}_c (1 - \hat{p}_c).$$

Réduction de variance par moyennage

$$\text{Var}\left(\frac{1}{B}\sum_{b=1}^{B} \hat{f}_b \right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Boosting additif

$$\hat{f}_M(x) = \sum_{m=1}^{M} \nu\, \hat{f}_m(x), \qquad \nu \in (0, 1].$$

k-means

$$\min_{\{C_1,\ldots,C_k\}} \sum_{c=1}^{k} \sum_{x_i \in C_c} \|x_i - \mu_c\|^2, \qquad \mu_c = \frac{1}{|C_c|} \sum_{x_i \in C_c} x_i.$$

C.2 --- Le tableau maître : méthodes, hyperparamètre, biais/variance

Méthode	Hyperparamètre clé	Effet principal	Cas d'usage typique
Ridge	λ	Réduit variance, jamais de zéro	Multicolinéarité forte
Lasso	λ	Réduit variance, sélection ($\beta = 0$)	Grand p, besoin de sélection
k-NN	k (voisins)	Petit k = variance, grand k = biais	Peu de variables, non linéaire
Arbre isolé	Profondeur max.	Interprétable, instable (variance)	Règles explicables
Forêt aléatoire	B, m	Réduit variance par décorrélation	Performance + robustesse
Boosting	ν, M	Réduit biais, séquentiel	Performance maximale
k-means	k (groupes)	Partition en groupes homogènes	Segmentation non supervisée
ACP	k (composantes)	Réduction de dimension	Prétraitement, colinéarité

C.3 --- Carte de décision

Comment choisir une méthode en situation d'examen

1. Cible y connue ? **Non** → non supervisé (k-means, ACP). **Oui** → étape 2.
2. Besoin d'interprétabilité réglementaire forte ? **Oui** → arbre peu profond ou régression (régularisée si p grand).
3. Beaucoup de variables corrélées, besoin de sélection ? **Oui** → Lasso/Elastic Net.
4. Interactions complexes, performance prioritaire, interprétabilité secondaire ? **Oui** → forêt aléatoire (robustesse) ou boosting (performance maximale, réglage plus fin).
5. Peu de variables, faible dimension, relation possiblement très irrégulière ? **Oui** → k-NN.

C.4 --- Glossaire bilingue

Français	Anglais
Apprentissage supervisé / non supervisé	Supervised / unsupervised learning
Surapprentissage / sous-apprentissage	Overfitting / underfitting
Compromis biais-variance	Bias-variance tradeoff

Français	Anglais
Validation croisée à k plis	k-fold cross-validation
Rétrécissement	Shrinkage
Sélection de variables	Feature selection
Régression Ridge / Lasso	Ridge / Lasso regression
k plus proches voisins	k-Nearest Neighbors (k-NN)
Arbre de décision	Decision tree
Impureté de Gini	Gini impurity
Élagage	Pruning
Ensachage	Bagging (Bootstrap Aggregating)
Forêt aléatoire	Random forest
Amplification / renforcement	Boosting
Échantillon out-of-bag	Out-of-bag sample
Taux d'apprentissage	Learning rate
Arrêt anticipé	Early stopping
Partitionnement en k-moyennes	k-means clustering
Analyse en composantes principales	Principal Component Analysis (PCA)
Fléau de la dimension	Curse of dimensionality
Fuite de données	Data leakage
Dérive de concept	Concept drift

C.5 --- Protocole complet d'un projet ML en gestion des risques

1. **Partition des données** : entraînement / validation / test, en respectant l'ordre chronologique si les données sont temporelles.
2. **Prétraitement** : standardisation, encodage des variables catégorielles, traitement des valeurs manquantes — calculé sur l'entraînement **seul**, puis appliqué au reste (jamais l'inverse, sous peine de fuite de données).
3. **Choix d'un ou plusieurs modèles candidats** en fonction de la carte de décision (C.3).
4. **Calibration des hyperparamètres** par validation croisée sur l'entraînement.
5. **Évaluation finale** sur le test, une seule fois.
6. **Documentation et explicabilité** : conserver les règles ou l'importance des variables pour toute exigence réglementaire.
7. **Surveillance post-déploiement** : suivi de la performance dans le temps pour détecter une dérive de concept.

C.6 --- Les dix pièges classiques

1. Confondre échantillon de validation et de test.
2. Standardiser *avant* le split train/test (fuite de données via les statistiques globales).
3. Interpréter une erreur d'entraînement quasi nulle comme un succès.
4. Oublier que Ridge ne sélectionne jamais de variables.
5. Utiliser $k = 1$ en k-NN sans validation croisée.

6. Laisser un arbre pousser sans contrainte de profondeur.
7. Augmenter indéfiniment M en boosting sans surveiller la validation.
8. Choisir k de k-means sans méthode du coude ni relances multiples.
9. Interpréter directement les composantes de l'ACP comme les variables d'origine.
10. Déployer un modèle ML sans plan de surveillance de la dérive de concept.

C.7 --- Astuces de calcul et de mémorisation pour l'examen

Astuces mnémotechniques

Ridge = cercle, Lasso = losange : la géométrie explique tout — coins (Lasso) $\rightarrow$ zéros ; pas de coin (Ridge) $\rightarrow$ pas de zéro. **Bagging = parallèle = variance ; Boosting = séquentiel = biais** : les deux mots riment avec leur levier (variance/parallèle ont un rythme court, biais/séquentiel une construction progressive). **k petit = k-NN capricieux (variance) ; k grand = k-NN mou (biais)** : $k = 1$ suit chaque point, $k = n$ ne voit que la moyenne. **OOB** $\approx 1/e \approx 37\%$: à retenir comme un chiffre fixe indépendant de n (grand échantillon).

Partie F --- Étude de cas intégrée : construire un modèle de scoring de bout en bout

Cette étude de cas fil rouge applique, sur un scénario unique et réaliste, l'ensemble des méthodes du chapitre — pour donner au lecteur une vision d'ensemble du **protocole complet** d'un projet de machine learning en gestion des risques, au-delà des questions isolées des Parties B et D.

F.1 --- Contexte et données

Une banque souhaite construire un modèle de scoring pour anticiper le défaut à un an d'un portefeuille de 4 000 PME clientes. Elle dispose de 45 variables candidates : ratios financiers (endettement, couverture des intérêts, liquidité, rentabilité), variables sectorielles (croissance du secteur, cyclicité), variables comportementales (incidents de paiement passés, ancienneté de la relation), et variables macroéconomiques (taux directeur, indice de confiance des affaires). Le taux de défaut historique observé est de 3,2% — une **classe fortement déséquilibrée** (§14.3).

Étape 1 --- Partition des données

Les 4 000 observations sont partitionnées chronologiquement : 2 800 PME (dossiers 2019-2022) pour l'**entraînement**, 600 (2023) pour la **validation**, 600 (2024) pour le **test** — un découpage temporel plutôt qu'aléatoire, car les relations de crédit évoluent dans le temps (dérive de concept potentielle, §14.10) et un split aléatoire risquerait une fuite de données (des PME liées entre elles, mêmes secteurs, pourraient apparaître à la fois en entraînement et en test).

Étape 2 --- Prétraitement

Les 45 variables sont **standardisées** (moyenne nulle, écart-type unitaire) sur l'échantillon d'entraînement uniquement, puis les mêmes paramètres de standardisation (moyenne, écart-type calculés sur l'entraînement) sont appliqués à la validation et au test — jamais l'inverse, pour éviter toute fuite de données (§14.1, C.6 piège n°2). Les valeurs manquantes (12% des observations pour la variable « ancienneté sectorielle ») sont imputées par la médiane de l'entraînement.

F.2 --- Comparaison de cinq modèles candidats

Cinq modèles sont calibrés par validation croisée à 5 plis sur l'entraînement, puis évalués sur le test (une seule fois) via l'AUC (§14.3) :

Modèle	Hyperparamètre retenu	AUC test	Commentaire
Régression logistique (MCO)	— (aucune régularisation)	0.71	Coefficients instables (45 variables, certaines corrélées)
Ridge logistique	$\lambda = 3.2$	0.76	Coefficients stabilisés, aucune sélection
Lasso logistique	$\lambda = 1.4$	0.79	18 variables retenues sur 45 (27 annulées)
Forêt aléatoire	$B = 500$, $m = 7$	0.85	Meilleure robustesse, importance des variables disponible
Boosting (gradient)	$\nu = 0.05$, $M = 800$	0.87	Meilleure AUC, mais calibration plus sensible

Lecture du tableau comparatif

La progression de l'AUC ($0.71 \rightarrow 0.87$) suit exactement la logique du chapitre : la régularisation (Ridge, Lasso) corrige l'instabilité de la régression classique ; les méthodes d'ensemble (forêt, boosting) captent des interactions non linéaires (ex. l'effet du levier dépend du secteur) qu'aucune régression, même régularisée, ne peut représenter sans termes d'interaction explicites. Le **Lasso**, bien que moins performant en AUC pure, reste précieux ici : ses 18 variables retenues offrent un sous-ensemble interprétable, utile pour documenter le modèle final auprès du contrôle des risques et du régulateur.

F.3 --- Diagnostic de surapprentissage sur le boosting

Le modèle de boosting, le plus performant sur le test (AUC 0.87), fait l'objet d'un diagnostic supplémentaire de robustesse à l'aide de la courbe d'apprentissage (erreur entraînement vs validation en fonction de M) :

M (itérations)	AUC entraînement	AUC validation
100	0.81	0.80
400	0.89	0.86
800	0.95	0.87
1500	0.99	0.84

Lecture de la courbe d'apprentissage

L'écart entre AUC d'entraînement et AUC de validation — quasi nul à $M = 100$, croissant progressivement — est le **symptôme diagnostique de surapprentissage** décrit en §14.2 : au-delà de $M = 800$, l'AUC de validation **régresse** ($0.87 \rightarrow 0.84$) alors que l'AUC d'entraînement continue de grimper vers 0.99. C'est un cas d'école d'**arrêt anticipé** (§14.9) : $M = 800$ est retenu comme optimum, non $M = 1500$ malgré sa performance d'entraînement supérieure — un piège classique (C.6, piège n°7) que le tableau ci-dessus permet précisément d'éviter.

F.4 --- Explicabilité et contrainte réglementaire

Le comité des risques exige, pour toute décision de refus de crédit automatisée, une justification lisible par le client — une exigence que le modèle de boosting (AUC 0.87, mais boîte noire) ne peut pas satisfaire directement.

Solution retenue : une architecture à deux niveaux

La banque retient une architecture hybride, cohérente avec la synthèse méthodologique de §14.10 : le **boosting** sert de moteur de **scoring interne** (allocation du capital économique, tarification du risque, pilotage du portefeuille), où la performance prédictive prime. Pour toute décision individuelle de refus nécessitant une explication client, un **arbre de décision peu profond** (profondeur 3, entraîné séparément pour approximer les décisions du boosting) fournit une règle lisible (« refusé car endettement $> 65\%$ et couverture des intérêts < 1.2 ») — au prix d'une perte de précision (AUC de l'arbre de substitution ≈ 0.80 contre 0.87), acceptée comme le coût de l'explicabilité réglementaire.

Importance des variables --- forêt aléatoire

L'analyse d'importance des variables de la forêt aléatoire (réduction moyenne d'impureté, §14.8) identifie les cinq variables les plus contributives : couverture des intérêts (18% de l'importance totale), endettement (15%), incidents de paiement passés (13%), liquidité (9%), croissance sectorielle (7%) — cohérentes avec l'intuition du risque de crédit, ce qui rassure sur la plausibilité économique du modèle malgré sa complexité.

F.5 --- Surveillance post-déploiement

Une fois déployé, le modèle est surveillé trimestriellement pour détecter une dérive de concept (§14.10, C.5 étape 7) :

Indicateurs de surveillance retenus

Trois indicateurs sont suivis : (i) la **stabilité de la distribution des scores** (comparaison de la distribution des scores prédits sur le portefeuille courant vs l'échantillon d'entraînement, via un test de stabilité de population) ; (ii) le **taux de défaut réalisé** comparé au taux prédit par tranche de score, trimestre après trimestre ; (iii) la **stabilité de l'importance des variables** d'un réentraînement à l'autre — un changement brutal signalerait une rupture structurelle (ex. choc macroéconomique) nécessitant un réexamen complet du modèle plutôt qu'un simple réajustement.

Synthèse de l'étude de cas intégrée

Ce cas illustre le fil rouge du chapitre de bout en bout : **aucune méthode isolée** n'est suffisante — la régularisation stabilise, les ensembles performent, l'arbre explique, la surveillance protège contre la dérive. Le choix final n'est jamais « la meilleure méthode » dans l'absolu, mais la **combinaison** qui répond simultanément aux contraintes de performance, d'interprétabilité réglementaire et de robustesse dans le temps — exactement la carte de décision de la section C.3, appliquée dans son intégralité.

Partie D --- 200 questions à choix multiple

200 questions de style examen, par thème et de difficulté croissante. Une seule réponse correcte. Corrigé commenté en Partie E.

Thème 1 --- Apprentissage supervisé, non supervisé, rôle du ML

Q1. La simulation de Monte-Carlo est un exemple de méthode :

(a) analytique fermée

(b) historique

(c) numérique par scénarios

(d) déterministe sans hasard

Q2. L'apprentissage supervisé se caractérise par :

(a) l'absence de cible

(b) une cible y connue à prédire

(c) l'absence de variables explicatives

(d) un seul type de modèle possible

Q3. L'apprentissage non supervisé cherche :

(a) à prédire une cible connue

(b) une structure cachée sans cible

(c) à maximiser un R^2 connu

(d) une classification binaire uniquement

Q4. Un modèle de scoring prédisant défaut/non-défaut relève de :

(a) la régression

(b) la classification

(c) le clustering

(d) l'ACP

Q5. Le ML priorise généralement :

(a) l'interprétation des coefficients

(b) la significativité statistique

(c) la performance prédictive hors-échantillon

(d) la simplicité du modèle avant tout

Q6. L'échantillon de validation sert à :

(a) ajuster les paramètres du modèle

(b) choisir les hyperparamètres

(c) évaluer la performance finale une seule fois

(d) remplacer le test

Q7. L'échantillon de test doit être consulté :

(a) à chaque itération d'entraînement

(b) plusieurs fois pour ajuster le modèle

(c) une seule fois, en fin de processus

(d) jamais

Q8. La fuite de données (data leakage) désigne :

(a) un manque de données d'entraînement

(b) une information du test qui influence l'entraînement

(c) une variable non standardisée

(d) un modèle trop simple

Q9. Confondre validation et test entraîne :

(a) une sous-estimation de la performance

(b) une estimation trop optimiste de la performance finale

(c) aucun effet

(d) une réduction du biais

Q10. La régression linéaire est :

(a) uniquement un outil ML

(b) uniquement un outil statistique classique

(c) à la fois un outil statistique et un algorithme supervisé élémentaire

(d) un outil non supervisé

Q11. Le scoring de crédit motive l'usage du ML principalement car :

(a) les données sont rares

(b) des interactions non linéaires entre variables existent

(c) la cible est inconnue

(d) aucune variable n'est disponible

Q12. La détection de fraude est un cas d'usage typique :

(a) de la régression linéaire simple

(b) des méthodes d'ensemble sur structure rare et non linéaire

(c) de l'ACP uniquement

(d) du k-means uniquement pour classer

Q13. La segmentation de clientèle sans catégories prédéfinies relève :

(a) de la régression

(b) de la classification supervisée

(c) de l'apprentissage non supervisé

(d) de la validation croisée

Q14. Un coefficient unique interprétable existe-t-il dans une forêt de 500 arbres ?

(a) Oui, toujours

(b) Non, elle agrège 500 modèles distincts

(c) Oui, mais seulement en régression

(d) Non, car le nombre d'arbres est pair

Q15. Trois familles de méthodes d'estimation de la VaR (rappel chapitre 13) sont :

(a) linéaire, quadratique, cubique

(b) paramétrique, historique, Monte-Carlo

(c) bootstrap, Ridge, Lasso

(d) supervisée, non supervisée, semi-supervisée

Q16. Un modèle prédictif de perte de portefeuille en euros relève de :

(a) la classification

(b) la régression

(c) le clustering

(d) aucune des réponses

Q17. Le compromis principal accepté en ML est :

(a) biais contre coût de calcul

(b) interprétabilité contre performance prédictive

(c) variance contre nombre d'observations

(d) aucun compromis n'existe

Q18. Un historique de défauts observés associés à des variables x permet un problème :

(a) non supervisé

(b) supervisé

(c) aléatoire pur

(d) sans solution

Q19. Trois usages typiques du ML en gestion des risques sont :

(a) scoring, fraude, segmentation

(b) VaR historique, ACP, k-NN uniquement

(c) MCO, GLS, WLS

(d) aucun de ces choix

Q20. Ce qui distingue fondamentalement supervisé et non supervisé est :

(a) le nombre de variables

(b) la présence ou l'absence d'une cible y connue

(c) le type de logiciel utilisé

(d) la taille de l'échantillon

Thème 2 --- Biais-variance et surapprentissage

Q21. La décomposition de l'erreur quadratique attendue comprend :

(a) biais^2 + variance seulement

(b) biais^2 + variance + bruit irréductible

(c) variance uniquement

(d) biais uniquement

Q22. Le biais d'un estimateur de fonction mesure :

(a) sa sensibilité au hasard d'échantillonnage

(b) son écart systématique à la vraie fonction

(c) le nombre de paramètres du modèle

(d) le temps de calcul

Q23. La variance d'un estimateur de fonction mesure :

(a) son écart systématique à la vérité

(b) sa sensibilité à l'échantillon d'entraînement utilisé

(c) le biais du modèle

(d) le bruit irréductible

Q24. Un modèle trop simple souffre typiquement :

(a) de variance élevée

(b) de biais élevé

(c) d'aucun problème

(d) de surapprentissage

Q25. Un modèle trop complexe souffre typiquement :

(a) de biais élevé uniquement

(b) de variance élevée

(c) d'aucun problème

(d) de sous-apprentissage

Q26. Une droite ajustée à une relation fortement courbe illustre :

(a) le surapprentissage

(b) le sous-apprentissage

(c) une variance excessive

(d) un modèle optimal

Q27. Un polynôme de degré 20 sur 30 points illustre :

(a) le sous-apprentissage

(b) le surapprentissage

(c) un biais élevé uniquement

(d) l'absence de variance

Q28. Le modèle optimal minimise :

(a) le biais seul

(b) la variance seule

(c) la somme biais^2 + variance

(d) le nombre de variables uniquement

Q29. Le signal diagnostique le plus fiable de surapprentissage est :

(a) une erreur d'entraînement élevée

(b) un écart croissant entre erreur d'entraînement et erreur de test

(c) une variance nulle

(d) un biais nul

Q30. Une erreur d'entraînement proche de zéro est :

(a) toujours un succès

(b) potentiellement un signal de surapprentissage

(c) toujours un signe de biais élevé

(d) sans rapport avec le surapprentissage

Q31. Le point optimal de complexité minimise :

(a) l'erreur d'entraînement

(b) l'erreur de test (hors-échantillon)

(c) le nombre d'observations

(d) le temps de calcul uniquement

Q32. La régularisation combat le surapprentissage en :

(a) augmentant la complexité

(b) pénalisant la complexité (taille des coefficients)

(c) supprimant les données de test

(d) augmentant la variance

Q33. L'élagage d'un arbre combat le surapprentissage en :

(a) augmentant sa profondeur

(b) limitant sa profondeur ou supprimant des branches

(c) augmentant le nombre de feuilles pures

(d) ignorant la validation

Q34. L'agrégation (bagging) combat le surapprentissage en :

(a) augmentant le biais

(b) moyennant plusieurs modèles instables pour réduire la variance

(c) supprimant les hyperparamètres

(d) augmentant systématiquement la complexité

Q35. La validation croisée combat le surapprentissage en :

(a) mesurant honnêtement l'erreur de généralisation

(b) augmentant artificiellement les données

(c) ignorant les hyperparamètres

(d) supprimant le test

Q36. Un modèle linéaire simple sur une relation non linéaire a plutôt :

(a) une variance élevée

(b) un biais élevé

(c) aucun biais

(d) une variance nulle

Q37. Un arbre très profond non élagué a plutôt :

(a) un biais élevé

(b) une variance élevée

(c) aucune variance

(d) un biais nul et une variance nulle

Q38. Le bruit irréductible σ_ε^2 peut-il être éliminé par un meilleur modèle ?

(a) Oui, toujours

(b) Non, il est intrinsèque aux données

(c) Oui, si le modèle est linéaire

(d) Oui, avec suffisamment de données

Q39. Quand la complexité du modèle augmente typiquement :

(a) le biais et la variance augmentent tous deux

(b) le biais diminue et la variance augmente

(c) le biais augmente et la variance diminue

(d) les deux diminuent

Q40. Le concept unificateur du chapitre 14 est :

(a) maximiser la complexité du modèle

(b) équilibrer biais et variance pour extraire le signal sans le bruit

(c) minimiser uniquement le nombre de variables

(d) ignorer la validation croisée

Thème 3 --- Validation croisée et évaluation de modèle

Q41. La validation croisée à k plis consiste à :

(a) entraîner une seule fois sur tout l'échantillon

(b) partager en k plis, entraîner sur k-1, évaluer sur le pli restant, répéter et moyenner

(c) tester uniquement sur le dernier pli

(d) ignorer les hyperparamètres

Q42. Les valeurs de k les plus courantes en pratique sont :

(a) 2 ou 3

(b) 5 ou 10

(c) 50 ou 100

(d) 1 uniquement

Q43. La validation croisée est préférée à un simple split train/test car :

(a) elle est plus rapide

(b) chaque observation sert une fois de test, réduisant la dépendance au hasard du découpage

(c) elle ne nécessite pas de réentraînement

(d) elle élimine le besoin de test final

Q44. Le principal coût de la validation croisée à k plis est :

(a) une perte de données

(b) un réentraînement k fois du modèle

(c) une perte de précision automatique

(d) aucun coût

Q45. Une métrique usuelle de régression est :

(a) la matrice de confusion

(b) l'erreur quadratique moyenne (MSE)

(c) la courbe ROC

(d) le vote majoritaire

Q46. La simple précision est trompeuse en classification déséquilibrée car :

(a) elle ignore les vrais négatifs uniquement

(b) un modèle prédisant toujours la classe majoritaire affiche une précision élevée sans valeur prédictive

(c) elle est toujours égale à 50%

(d) elle ne peut pas être calculée

Q47. La matrice de confusion croise :

(a) biais et variance

(b) classes prédites et classes réelles

(c) k et lambda

(d) train et test uniquement

Q48. La sensibilité mesure :

(a) la proportion de négatifs réels bien identifiés

(b) la proportion de positifs réels correctement identifiés

(c) le temps de calcul

(d) le nombre de plis k

Q49. L'AUC (aire sous la courbe ROC) mesure :

(a) la capacité de discrimination du modèle entre classes

(b) le nombre d'arbres d'une forêt

(c) le taux d'apprentissage du boosting

(d) la profondeur d'un arbre

Q50. L'usage le plus fréquent de la validation croisée est :

(a) évaluer un modèle déjà finalisé sur le marché

(b) choisir un hyperparamètre par balayage de grille

(c) remplacer l'échantillon d'entraînement

(d) supprimer le besoin de test

Q51. Le protocole complet correct est :

(a) test puis validation puis entraînement

(b) choisir l'hyperparamètre par CV sur l'entraînement, puis évaluer une fois sur le test

(c) entraîner directement sur le test

(d) ignorer la validation croisée si les données sont abondantes

Q52. La validation croisée est utile sur petit échantillon car :

(a) elle réduit le nombre d'observations utilisées

(b) elle exploite toutes les observations à tour de rôle pour l'entraînement et le test

(c) elle élimine le bruit

(d) elle ne nécessite pas de réentraînement

Q53. La spécificité mesure :

(a) la proportion de positifs réels bien identifiés

(b) la proportion de négatifs réels correctement identifiés

(c) le nombre de plis

(d) la taille du test

Q54. k = n en validation croisée correspond à :

(a) k-fold classique

(b) leave-one-out (LOOCV)

(c) bootstrap

(d) aucune méthode connue

Q55. L'inconvénient principal du LOOCV est :

(a) un manque de précision

(b) un coût de calcul très élevé (n réentraînements)

(c) l'impossibilité de le calculer

(d) une variance artificiellement nulle

Q56. L'erreur de validation croisée globale se calcule par :

(a) la somme des k erreurs

(b) la moyenne des k erreurs sur les plis laissés de côté

(c) le maximum des k erreurs

(d) le minimum des k erreurs

Q57. Pour un taux de défaut de 2% dans un portefeuille, il vaut mieux privilégier :

(a) la précision brute uniquement

(b) la courbe ROC/AUC ou la matrice de confusion complète

(c) le R^2 uniquement

(d) aucune métrique particulière

Q58. La validation croisée corrige principalement :

(a) le biais du modèle

(b) la dépendance au hasard du découpage d'un split unique

(c) le nombre de variables explicatives

(d) le taux d'apprentissage du boosting

Q59. La valeur finale d'un hyperparamètre est retenue selon :

(a) le hasard

(b) celle qui minimise l'erreur de validation croisée moyenne

(c) celle qui maximise l'erreur d'entraînement

(d) celle choisie arbitrairement avant tout calcul

Q60. Le rôle central de la validation croisée est de :

(a) remplacer totalement le test final

(b) estimer honnêtement la généralisation et guider le choix des hyperparamètres

(c) augmenter artificiellement la performance affichée

(d) éliminer le besoin de standardisation

Thème 4 --- Régression Ridge

Q61. L'objectif minimisé par Ridge est :

(a) somme des carrés résiduels seule

(b) somme des carrés résiduels + $\lambda\Sigma\beta_j^2$

(c) somme des carrés résiduels + $\lambda\Sigma|\beta_j|$

(d) aucune pénalité

Q62. Quand $\lambda=0$, Ridge devient :

(a) un modèle vide

(b) les moindres carrés ordinaires

(c) une pénalité infinie

(d) un arbre de décision

Q63. Quand $\lambda\to\infty$, Ridge produit :

(a) des coefficients tous écrasés vers zéro

(b) des coefficients infinis

(c) aucun changement

(d) un modèle non supervisé

Q64. Ridge est particulièrement utile en présence de :

(a) données manquantes

(b) multicolinéarité entre variables explicatives

(c) classes déséquilibrées uniquement

(d) cibles catégorielles uniquement

Q65. La solution fermée de Ridge s'écrit :

(a) $(X'X)^{-1}X'y$

(b) $(X'X+\lambda I)^{-1}X'y$

(c) $X'X + \lambda I$

(d) $(X'X-\lambda I)^{-1}X'y$

Q66. Ridge peut-il annuler exactement un coefficient (hors $\lambda \to \infty$) ?

(a) Oui, systématiquement

(b) Non, la région de contrainte est lisse sans coin

(c) Oui, uniquement en classification

(d) Non, car Ridge n'a pas de solution fermée

Q67. Ridge est un outil de :

(a) sélection de variables uniquement

(b) rétrécissement (shrinkage) uniquement

(c) classification uniquement

(d) clustering

Q68. La standardisation préalable à Ridge est nécessaire car :

(a) Ridge ne fonctionne pas sur données numériques

(b) la pénalité traite symétriquement tous les coefficients, sensible à l'échelle des variables

(c) elle élimine le besoin de validation croisée

(d) elle transforme la régression en classification

Q69. Ridge introduit-il un biais dans les estimateurs ?

(a) Non, jamais

(b) Oui, en échange d'une réduction de variance

(c) Oui, mais uniquement en présence de valeurs manquantes

(d) Non, car il est équivalent aux MCO

Q70. Le choix de λ en pratique se fait par :

(a) une valeur fixe arbitraire à 1

(b) validation croisée sur une grille de valeurs

(c) élagage d'arbre

(d) vote majoritaire

Q71. Ridge est utile quand p (variables) est supérieur à n (observations) car :

(a) X'X est singulière sans pénalité et Ridge la rend inversible

(b) cela n'a aucun effet particulier

(c) Ridge devient équivalent au Lasso

(d) cela élimine le bruit irréductible

Q72. Face à deux variables fortement corrélées, Ridge tend à :

(a) annuler l'une des deux arbitrairement

(b) répartir le poids de façon plus équilibrée entre elles

(c) les supprimer toutes les deux

(d) les dupliquer

Q73. La pénalité de Ridge est appelée :

(a) pénalité $\ell 0$

(b) pénalité $\ell 1$

(c) pénalité $\ell 2$

(d) pénalité $\ell \infty$

Q74. Ridge améliore-t-il l'interprétabilité par réduction du nombre de variables actives ?

(a) Oui, systématiquement

(b) Non, toutes les variables restent dans le modèle

(c) Oui, mais uniquement en classification

(d) Non, car Ridge n'estime aucun coefficient

Q75. En dimension 2, la région de contrainte de Ridge ($\Sigma \beta_j{}^2 \leq c$) a la forme :

(a) d'un losange

(b) d'un cercle (disque)

(c) d'un triangle

(d) d'une droite

Q76. L'ajout de λI dans l'inversion de X'X a pour effet de :

(a) augmenter la variance de l'estimateur

(b) réduire la variance en éloignant la matrice de la singularité

(c) annuler tous les coefficients

(d) transformer le problème en classification

Q77. Face à dix variables macroéconomiques fortement corrélées, la méthode à privilégier en premier lieu est :

(a) k-means

(b) Ridge

(c) ACP uniquement, sans régression

(d) aucune régularisation

Q78. Sur 50 variables, combien de coefficients Ridge annule-t-il généralement exactement à zéro ?

(a) Tous

(b) La moitié

(c) Aucun (sauf $\lambda \to \infty$)

(d) Un tiers

Q79. Ridge généralise souvent mieux que les MCO sur données bruitées car :

(a) il élimine tout le bruit

(b) il réduit la variance de l'estimateur au prix d'un léger biais

(c) il augmente systématiquement la variance

(d) il ignore les données bruitées

Q80. Le principe de Ridge se résume par :

(a) pénaliser la somme des carrés des coefficients pour réduire la variance, sans jamais les annuler

(b) annuler systématiquement les coefficients non significatifs

(c) augmenter la complexité du modèle

(d) ignorer la multicolinéarité

Thème 5 --- Régression Lasso et sélection de variables

Q81. L'objectif minimisé par le Lasso est :

(a) somme des carrés résiduels + $\lambda \Sigma \beta_j^2$

(b) somme des carrés résiduels + $\lambda \Sigma |\beta_j|$

(c) somme des carrés résiduels seule

(d) aucune pénalité

Q82. La pénalité du Lasso est appelée :

(a) pénalité $\ell 2$

(b) pénalité $\ell 0$

(c) pénalité $\ell 1$

(d) pénalité $\ell \infty$

Q83. Le Lasso peut-il annuler exactement des coefficients ?

(a) Non, jamais

(b) Oui, c'est sa propriété distinctive de sélection

(c) Oui, mais uniquement en régression logistique

(d) Non, uniquement Ridge le peut

Q84. En dimension 2, la région de contrainte du Lasso ($\Sigma|\beta_j| \leq c$) a la forme :

(a) d'un cercle

(b) d'un losange (polytope à coins)

(c) d'une parabole

(d) d'une droite infinie

Q85. Les coins de la contrainte Lasso produisent des coefficients nuls car :

(a) les courbes de niveau elliptiques touchent souvent la contrainte exactement en un coin

(b) le Lasso n'a pas de solution mathématique

(c) tous les coefficients sont initialisés à zéro

(d) c'est une convention arbitraire

Q86. Face à un groupe de variables fortement corrélées, le Lasso tend à :

(a) répartir équitablement le poids entre elles

(b) en retenir arbitrairement une seule du groupe

(c) les annuler toutes systématiquement

(d) les dupliquer

Q87. Le Lasso est plus interprétable que Ridge car :

(a) il a plus de coefficients non nuls

(b) seules les variables à coefficient non nul entrent dans le récit du modèle

(c) il n'utilise aucune pénalité

(d) il élimine le besoin de standardisation

Q88. Le Lasso est utile face à des centaines de variables candidates car :

(a) il augmente artificiellement le nombre de variables

(b) il sélectionne automatiquement un sous-ensemble parcimonieux

(c) il ignore la validation croisée

(d) il élimine le besoin de données

Q89. Un inconvénient du Lasso en présence de variables corrélées est :

(a) une instabilité du choix de variable retenue d'une exécution à l'autre

(b) une variance toujours nulle

(c) une impossibilité de calcul

(d) un biais toujours nul

Q90. L'Elastic Net combine :

(a) deux pénalités $\ell 1$

(b) les pénalités $\ell 1$ et $\ell 2$

(c) uniquement une pénalité $\ell 2$

(d) aucune pénalité

Q91. L'Elastic Net est motivé par le besoin de :

(a) ignorer la colinéarité

(b) bénéficier de la sélection du Lasso tout en gérant mieux la colinéarité comme Ridge

(c) remplacer totalement Ridge et Lasso

(d) éviter toute régularisation

Q92. Le choix de λ pour le Lasso se fait par :

(a) une valeur fixe universelle

(b) validation croisée

(c) élagage d'arbre uniquement

(d) vote majoritaire

Q93. Un modèle « parcimonieux » produit par le Lasso signifie :

(a) un modèle avec beaucoup de coefficients non nuls

(b) un modèle avec peu de coefficients non nuls parmi les variables candidates

(c) un modèle sans aucune variable

(d) un modèle non supervisé

Q94. La standardisation préalable est-elle nécessaire pour le Lasso ?

(a) Non, jamais nécessaire

(b) Oui, pour la même raison que Ridge

(c) Oui, mais uniquement en classification

(d) Non, car le Lasso ignore l'échelle

Q95. Pour un modèle de spread de crédit avec 300 variables candidates, privilégier :

(a) k-means uniquement

(b) le Lasso (ou Elastic Net si forte colinéarité)

(c) Ridge uniquement, sans jamais envisager Lasso

(d) aucune régularisation

Q96. Quand $\lambda=0$, le Lasso devient :

(a) un modèle vide

(b) les moindres carrés ordinaires

(c) un arbre de décision

(d) un modèle non supervisé

Q97. Quand λ du Lasso devient très grand :

(a) tous les coefficients augmentent

(b) de plus en plus de coefficients sont annulés, jusqu'à un modèle vide

(c) aucun changement ne se produit

(d) le modèle devient non supervisé

Q98. La différence fondamentale entre Ridge et Lasso est :

(a) Ridge sélectionne, Lasso rétrécit sans sélectionner

(b) Ridge rétrécit sans annuler, Lasso peut annuler et sélectionner

(c) les deux sont strictement identiques

(d) Ridge est non supervisé, Lasso est supervisé

Q99. Le paramètre α de l'Elastic Net représente :

(a) le taux d'apprentissage du boosting

(b) le poids relatif entre pénalité $\ell 1$ et $\ell 2$

(c) le nombre de plis de validation croisée

(d) la profondeur maximale d'un arbre

Q100. L'apport distinctif du Lasso se résume par :

(a) une pénalité $\ell 1$ qui réalise une sélection automatique de variables grâce à sa géométrie à coins

(b) une pénalité $\ell 2$ qui rétrécit sans jamais sélectionner

(c) l'absence totale de pénalité

(d) une méthode purement non supervisée

Thème 6 --- K plus proches voisins

Q101. Le principe de k-NN consiste à :

(a) ajuster des coefficients de régression

(b) prédire à partir des k observations les plus proches

(c) construire un arbre de décision

(d) réduire la dimension des données

Q102. La distance la plus courante utilisée en k-NN est :

(a) la distance de Manhattan uniquement

(b) la distance euclidienne

(c) la distance de Mahalanobis uniquement

(d) aucune distance n'est utilisée

Q103. k-NN est dit « paresseux » (lazy learning) car :

(a) il est lent à prédire

(b) il ne fait aucun calcul à l'entraînement, mémorisant simplement les données

(c) il ignore les nouvelles observations

(d) il nécessite une régularisation forte

Q104. k-NN est dit non paramétrique car :

(a) il n'a aucun hyperparamètre

(b) il ne fait aucune hypothèse de forme fonctionnelle a priori

(c) il ne peut pas être utilisé en classification

(d) il nécessite une distribution normale

Q105. Un k petit (ex. k=1) produit typiquement :

(a) un biais élevé

(b) une variance élevée, sensible au bruit local

(c) aucun effet particulier

(d) une prédiction constante

Q106. Un k très grand (proche de n) produit typiquement :

(a) une variance élevée

(b) un biais élevé, lissage excessif

(c) aucun effet particulier

(d) un surapprentissage systématique

Q107. Le choix de k en pratique se fait par :

(a) une valeur fixe universelle égale à 5

(b) validation croisée

(c) élagage d'arbre

(d) vote majoritaire sans calibration

Q108. Le fléau de la dimension pour k-NN désigne :

(a) un manque de mémoire informatique

(b) la perte de pouvoir discriminant de la proximité en grande dimension

(c) l'impossibilité de calculer une distance

(d) un problème propre uniquement à la régression

Q109. Un remède au fléau de la dimension pour k-NN est :

(a) augmenter k indéfiniment

(b) une réduction de dimension préalable (ex. ACP)

(c) ignorer la standardisation

(d) supprimer toutes les variables

Q110. En classification, k-NN produit sa prédiction par :

(a) moyenne des k voisins

(b) vote majoritaire des classes des k voisins

(c) régression linéaire locale obligatoire

(d) élagage d'arbre

Q111. La standardisation avant k-NN est nécessaire car :

(a) la distance euclidienne est sensible à l'échelle des variables

(b) k-NN ne fonctionne pas sur données numériques

(c) elle élimine le besoin de validation croisée

(d) elle transforme la classification en régression

Q112. k-NN avec k=1 surapprend-il généralement ?

(a) Non, jamais

(b) Oui, la prédiction épouse exactement chaque point d'entraînement

(c) Non, car k=1 est toujours optimal

(d) Oui, mais uniquement en régression

Q113. Combien de paramètres k-NN estime-t-il lors de l'entraînement ?

(a) Un grand nombre, comme une régression

(b) Aucun, il mémorise simplement les données

(c) Exactement k paramètres

(d) p paramètres, un par variable

Q114. Le coût de calcul de k-NN est concentré :

(a) à l'entraînement

(b) à la prédiction (recherche des voisins)

(c) également réparti entre les deux

(d) nul dans les deux cas

Q115. k-NN peut être lent sur de très grandes bases car :

(a) chaque prédiction compare la nouvelle observation à toutes les observations d'entraînement

(b) il nécessite un réentraînement à chaque prédiction

(c) il n'existe pas d'implémentation efficace

(d) il ignore les grandes bases par construction

Q116. En classification binaire, il vaut mieux éviter un k pair car :

(a) cela ralentit le calcul

(b) cela peut créer des égalités de vote entre les deux classes

(c) cela viole une contrainte mathématique

(d) cela n'a aucune conséquence

Q117. La frontière de décision de k-NN peut-elle être non linéaire ?

(a) Non, toujours linéaire comme la régression logistique

(b) Oui, elle épouse n'importe quelle forme

(c) Non, uniquement en régression

(d) Oui, mais uniquement avec k=n

Q118. k-NN convient-il bien à un scoring avec seulement 3 variables bien choisies ?

(a) Non, jamais en faible dimension

(b) Oui, la proximité reste discriminante en faible dimension

(c) Non, car k-NN nécessite toujours plus de 50 variables

(d) Oui, mais uniquement en très grande dimension

Q119. k-NN gère-t-il nativement les variables catégorielles avec la distance euclidienne standard ?

(a) Oui, sans aucun traitement

(b) Non, un encodage numérique préalable est nécessaire

(c) Oui, mais uniquement en régression

(d) Non, k-NN ne peut jamais les utiliser

Q120. Le principe de k-NN se résume par :

(a) prédire par ressemblance aux observations déjà vues, sans modèle paramétrique explicite

(b) ajuster une pénalité sur les coefficients

(c) construire une séquence de modèles faibles

(d) réduire la dimension par vecteurs propres

Thème 7 --- Arbres de décision

Q121. Le principe d'un arbre de décision est de :

(a) ajuster une pénalité sur des coefficients

(b) partitionner récursivement l'espace des variables par des règles binaires

(c) mémoriser toutes les observations d'entraînement

(d) calculer une distance euclidienne globale

Q122. L'impureté de Gini se calcule par :

(a) $\Sigma\, \hat{p}c^2$

(b) $\Sigma\, \hat{p}c(1-\hat{p}c)$

(c) $\Sigma\, |\beta_j|$

(d) $\Sigma\, (y-\hat{y})^2$

Q123. Un nœud avec G=0 signifie :

(a) une classe majoritairement présente à 50%

(b) un nœud parfaitement pur, une seule classe présente

(c) une erreur de calcul

(d) un nœud vide

Q124. La construction d'un arbre est dite « gloutonne » car :

(a) chaque scission est choisie optimale localement, sans garantie globale

(b) l'arbre est toujours parfaitement optimal

(c) aucune scission n'est jamais choisie

(d) l'arbre ignore toutes les variables sauf une

Q125. Le critère de scission pour un arbre de régression est :

(a) l'impureté de Gini

(b) la somme des carrés résiduels intra-région

(c) le vote majoritaire

(d) la distance euclidienne

Q126. Un arbre développé jusqu'à des feuilles parfaitement pures :

(a) ne surapprend jamais

(b) surapprend presque toujours en isolant des observations bruitées

(c) est toujours optimal en généralisation

(d) élimine tout biais

Q127. Deux hyperparamètres limitant la croissance d'un arbre sont :

(a) le taux d'apprentissage et λ

(b) la profondeur maximale et le nombre minimal d'observations par feuille

(c) k et m uniquement

(d) α et ν uniquement

Q128. L'élagage (pruning) d'un arbre consiste à :

(a) augmenter sa profondeur maximale

(b) supprimer après coup les branches n'améliorant pas l'erreur de validation

(c) dupliquer les feuilles pures

(d) ignorer la validation croisée

Q129. Le principal avantage d'un arbre isolé est :

(a) sa robustesse extrême au bruit

(b) son interprétabilité directe (règles lisibles)

(c) sa performance toujours supérieure aux ensembles

(d) l'absence totale de variance

Q130. Un arbre gère-t-il nativement les interactions entre variables ?

(a) Non, jamais

(b) Oui, sans avoir à les spécifier explicitement

(c) Non, uniquement en régression linéaire

(d) Oui, mais uniquement avec plus de 100 variables

Q131. La limite majeure d'un arbre isolé est :

(a) un biais toujours élevé

(b) une forte instabilité (variance élevée) face à une perturbation des données

(c) l'impossibilité de gérer les variables catégorielles

(d) l'absence de règles interprétables

Q132. Les arbres gèrent-ils nativement les variables catégorielles ?

(a) Non, un encodage numérique est toujours requis

(b) Oui, sans encodage préalable nécessaire

(c) Non, jamais utilisables avec des catégories

(d) Oui, mais uniquement en régression

Q133. La variable et le seuil de scission à chaque nœud sont choisis pour :

(a) maximiser l'impureté des enfants

(b) minimiser l'impureté pondérée des deux nœuds enfants

(c) maximiser la profondeur de l'arbre

(d) minimiser le nombre d'observations

Q134. Un arbre de décision fait-il une hypothèse de distribution des données ?

(a) Oui, une hypothèse de normalité systématique

(b) Non, aucune hypothèse paramétrique de distribution

(c) Oui, une hypothèse d'indépendance stricte

(d) Non, mais une hypothèse de linéarité

Q135. La construction gloutonne garantit-elle l'arbre globalement optimal ?

(a) Oui, toujours

(b) Non, la recherche globale serait combinatoirement intraitable

(c) Oui, uniquement en classification

(d) Non, uniquement pour les arbres profonds

Q136. L'instabilité d'un arbre isolé motive :

(a) l'abandon complet des arbres

(b) les méthodes d'ensemble (bagging, forêts, boosting)

(c) l'utilisation exclusive de k-NN

(d) l'élimination de la validation croisée

Q137. Une feuille d'un arbre de régression représente :

(a) la classe majoritaire de la région

(b) la moyenne des y des observations de cette région

(c) le coefficient de régression local

(d) l'écart-type des résidus

Q138. Pour des règles de refus de crédit explicables exigées par un régulateur, privilégier :

(a) une forêt aléatoire de 1000 arbres

(b) un arbre de décision peu profond, directement lisible

(c) un réseau de neurones profond

(d) le boosting avec ν élevé

Q139. Une profondeur d'arbre plus grande a pour effet de :

(a) réduire le biais mais augmenter la variance

(b) réduire à la fois le biais et la variance

(c) augmenter le biais sans effet sur la variance

(d) n'avoir aucun effet

Q140. L'atout et la faiblesse d'un arbre isolé se résument par :

(a) interprétable et flexible, mais instable (variance élevée)

(b) non interprétable mais toujours stable

(c) sans aucun avantage particulier

(d) toujours optimal, sans faiblesse

Thème 8 --- Bagging et forêts aléatoires

Q141. Le principe du bagging est de :

(a) entraîner un seul modèle sur toutes les données

(b) générer B échantillons bootstrap, entraîner un modèle sur chacun, puis moyenner

(c) construire des modèles séquentiels corrigeant les erreurs précédentes

(d) réduire la dimension des données

Q142. La forêt aléatoire ajoute au bagging simple d'arbres :

(a) une pénalité $\ell 1$ sur les coefficients

(b) une sélection aléatoire d'un sous-ensemble de variables à chaque scission

(c) un taux d'apprentissage ν

(d) un critère de distance euclidienne

Q143. La formule de variance d'une moyenne de B modèles corrélés (corrélation ρ) est :

(a) $\rho\sigma^2 + (1\text{-}\rho)\sigma^2/B$

(b) σ^2/B uniquement

(c) $\rho\sigma^2$ uniquement

(d) $\sigma^2 \times B$

Q144. Si les arbres du bagging sont fortement corrélés ($\rho \to 1$) :

(a) le moyennage réduit fortement la variance

(b) le moyennage n'apporte aucun bénéfice de variance, quel que soit B

(c) le biais devient nul

(d) la variance devient négative

Q145. La sélection aléatoire de variables en forêt aléatoire sert à :

(a) augmenter la corrélation entre arbres

(b) décorréler les arbres pour rendre le moyennage bénéfique

(c) réduire le nombre d'arbres nécessaires à un seul

(d) éliminer le bootstrap

Q146. Le bagging réduit principalement :

(a) le biais

(b) la variance

(c) le bruit irréductible

(d) le nombre d'observations

Q147. Pourquoi utilise-t-on des arbres profonds non élagués dans le bagging ?

(a) Ils ont un biais faible ; c'est l'agrégation qui gère la variance

(b) Ils réduisent directement la variance individuellement

(c) Ils sont plus rapides à entraîner

(d) Ils éliminent le besoin de bootstrap

Q148. L'échantillon out-of-bag (OOB) désigne :

(a) les observations tirées plusieurs fois

(b) les observations non tirées dans un échantillon bootstrap donné (environ 36.8%)

(c) l'ensemble du jeu de test final

(d) les variables non sélectionnées à une scission

Q149. La fraction moyenne d'observations laissées de côté par un tirage bootstrap est d'environ :

(a) 10%

(b) 36.8% (1/e)

(c) 50%

(d) 90%

Q150. L'erreur out-of-bag sert à :

(a) remplacer entièrement les données d'entraînement

(b) estimer l'erreur de généralisation sans validation croisée séparée

(c) calculer le taux d'apprentissage du boosting

(d) choisir la profondeur maximale uniquement

Q151. Augmenter indéfiniment B dans une forêt aléatoire risque-t-il de surapprendre ?

(a) Oui, systématiquement

(b) Non, contrairement au boosting, cela stabilise davantage la moyenne

(c) Oui, mais uniquement en classification

(d) Non, car B n'a aucun effet

Q152. La valeur typique de m (variables candidates par scission) en classification est :

(a) $m = p$ (toutes les variables)

(b) $m \approx \sqrt{p}$

(c) $m = 1$ uniquement

(d) $m = n$

Q153. Une forêt aléatoire est-elle aussi interprétable qu'un arbre isolé ?

(a) Oui, totalement

(b) Non, elle perd l'interprétabilité directe au profit de la performance

(c) Oui, mais uniquement en régression

(d) Non, car elle n'utilise aucun arbre

Q154. L'importance des variables dans une forêt aléatoire s'estime par :

(a) le hasard

(b) la réduction moyenne d'impureté apportée par chaque variable à travers tous les arbres

(c) le taux d'apprentissage ν

(d) la distance euclidienne moyenne

Q155. Le bagging est-il limité aux arbres de décision ?

(a) Oui, exclusivement

(b) Non, il peut s'appliquer à tout modèle instable, mais les arbres profonds y sont particulièrement adaptés

(c) Oui, uniquement en classification

(d) Non, uniquement aux réseaux de neurones

Q156. Pourquoi une forêt aléatoire convient-elle bien à la détection de fraude ?

(a) Elle ignore les interactions non linéaires

(b) Elle gère les interactions non linéaires nombreuses tout en contrôlant la variance par agrégation

(c) Elle nécessite très peu de données

(d) Elle élimine tout besoin de validation

Q157. Le simple bootstrap (sans sélection aléatoire de variables) suffit-il à décorréler fortement les arbres ?

(a) Oui, totalement suffisant

(b) Non, les arbres restent souvent corrélés via la variable dominante

(c) Oui, car le bootstrap élimine toute variable dominante

(d) Non, car le bootstrap n'affecte pas les arbres

Q158. En classification, une forêt aléatoire agrège ses prédictions par :

(a) moyenne pondérée par le taux d'apprentissage

(b) vote majoritaire des B arbres

(c) élagage final

(d) distance euclidienne minimale

Q159. Le calcul d'une forêt aléatoire est-il parallélisable ?

(a) Non, jamais

(b) Oui, chaque arbre est entraîné indépendamment

(c) Oui, mais uniquement pour moins de 10 arbres

(d) Non, car les arbres dépendent les uns des autres

Q160. Le principe des forêts aléatoires se résume par :

(a) moyenner de nombreux arbres profonds décorrélés pour réduire la variance

(b) construire une séquence de modèles corrigeant les erreurs précédentes

(c) pénaliser la somme des carrés des coefficients

(d) réduire la dimension par vecteurs propres

Thème 9 --- Boosting

Q161. Le principe du boosting est de :

(a) entraîner B modèles indépendants en parallèle

(b) construire une séquence de modèles faibles, chacun corrigeant les erreurs des précédents

(c) réduire la dimension des données

(d) calculer une distance euclidienne globale

Q162. Le boosting est-il parallèle ou séquentiel ?

(a) Parallèle, comme le bagging

(b) Séquentiel

(c) Ni l'un ni l'autre

(d) Aléatoire uniquement

Q163. Le levier principal du boosting est :

(a) la réduction de la variance

(b) la réduction du biais

(c) l'élimination du bruit irréductible

(d) l'augmentation du nombre d'observations

Q164. Le levier principal du bagging est :

(a) la réduction du biais

(b) la réduction de la variance

(c) l'élimination du biais et de la variance simultanément

(d) aucun levier particulier

Q165. Un « modèle faible » en boosting désigne :

(a) un modèle parfaitement précis

(b) un modèle à peine meilleur qu'un tirage aléatoire (ex. un stump)

(c) un modèle non supervisé

(d) un modèle avec zéro biais

Q166. Le taux d'apprentissage ν contrôle :

(a) le nombre de plis de validation croisée

(b) la contribution de chaque modèle faible successif à la prédiction finale

(c) la distance euclidienne entre observations

(d) le nombre de composantes principales

Q167. Un ν petit a pour effet :

(a) un apprentissage plus rapide et un risque de surapprentissage accru

(b) un apprentissage plus lent mais un risque de surapprentissage réduit

(c) aucun effet sur le surapprentissage

(d) une élimination totale du biais

Q168. La meilleure combinaison typique en boosting est :

(a) un ν élevé avec peu d'itérations M

(b) un ν petit combiné à un grand nombre d'itérations M (calibré par CV)

(c) un ν nul avec M infini

(d) aucune combinaison particulière n'est meilleure

Q169. Le boosting est-il plus ou moins sensible aux valeurs aberrantes que le bagging ?

(a) Moins sensible

(b) Plus sensible, car il cible explicitement les observations mal prédites

(c) Également sensible dans tous les cas

(d) Totalement insensible

Q170. Augmenter indéfiniment M en boosting est-il toujours bénéfique ?

(a) Oui, toujours, comme pour B en forêt aléatoire

(b) Non, risque de surapprentissage au-delà d'un certain M

(c) Oui, car M n'a aucune limite pratique

(d) Non, car M ne peut jamais dépasser 10

Q171. L'arrêt anticipé (early stopping) consiste à :

(a) arrêter dès la première itération systématiquement

(b) arrêter les itérations quand l'erreur de validation cesse de s'améliorer

(c) augmenter ν à chaque itération

(d) ignorer la validation croisée

Q172. La forme générale de la prédiction finale en boosting additif est :

(a) une moyenne simple des modèles

(b) $\hat{f}_M(x) = \sum \nu \hat{f}_m(x)$

(c) un vote majoritaire uniquement

(d) une distance euclidienne pondérée

Q173. Pourquoi le boosting est-il souvent très performant en scoring de crédit ?

(a) Sa construction séquentielle réduit fortement le biais tout en restant flexible sur les non-linéarités

(b) Il élimine tout besoin de données

(c) Il est toujours plus rapide que la forêt aléatoire

(d) Il ne nécessite aucune calibration

Q174. Le boosting est-il directement interprétable comme un arbre isolé ?

(a) Oui, totalement

(b) Non, c'est une somme pondérée de nombreux modèles faibles

(c) Oui, mais uniquement avec M=1

(d) Non, car il n'utilise jamais d'arbres

Q175. AdaBoost ajuste l'importance des observations en :

(a) diminuant le poids des observations mal classées

(b) augmentant le poids des observations mal classées par les modèles précédents

(c) ignorant les observations mal classées

(d) supprimant les observations mal classées

Q176. Le gradient boosting entraîne chaque nouveau modèle faible sur :

(a) les données brutes non modifiées

(b) les résidus (erreurs) laissés par l'ensemble des modèles précédents

(c) une sélection aléatoire de variables uniquement

(d) les composantes principales des données

Q177. Le boosting est-il aussi facilement parallélisable que le bagging ?

(a) Oui, totalement

(b) Non, sa nature séquentielle limite la parallélisation

(c) Oui, mais uniquement pour de petits jeux de données

(d) Non, car il n'utilise jamais d'arbres

Q178. Les hyperparamètres à calibrer conjointement en boosting incluent typiquement :

(a) uniquement le nombre de plis k

(b) le taux d'apprentissage ν, le nombre d'itérations M, et la profondeur des arbres faibles

(c) uniquement λ

(d) uniquement le nombre de composantes principales

Q179. Entre boosting et forêt aléatoire, lequel est généralement plus robuste sans réglage soigneux ?

(a) Le boosting, toujours

(b) La forêt aléatoire, plus robuste par défaut

(c) Les deux sont strictement équivalents

(d) Aucun des deux n'est robuste

Q180. Le principe distinctif du boosting se résume par :

(a) combiner séquentiellement des modèles faibles, chacun corrigeant les erreurs du précédent, pour réduire le biais

(b) moyenner des modèles indépendants pour réduire la variance

(c) pénaliser la somme des carrés des coefficients

(d) réduire la dimension par vecteurs propres

Thème 10 --- k-means, ACP et synthèse

Q181. L'objectif minimisé par k-means est :

(a) la somme des distances au carré aux centroïdes (inertie intra-groupe)

(b) la somme des carrés résiduels d'une régression

(c) l'impureté de Gini

(d) le taux d'apprentissage ν

Q182. Les deux étapes alternées de k-means sont :

(a) scission et élagage

(b) affectation (au centroïde le plus proche) et mise à jour (recalcul des centroïdes)

(c) entraînement et validation croisée

(d) bootstrap et vote majoritaire

Q183. k-means converge-t-il vers un minimum local ou global ?

(a) Toujours un minimum global

(b) Un minimum local, dépendant de l'initialisation

(c) Ni l'un ni l'autre, il ne converge jamais

(d) Un minimum global uniquement si k=2

Q184. Pour atténuer la sensibilité de k-means à l'initialisation, on peut :

(a) utiliser un seul lancement systématiquement

(b) relancer l'algorithme plusieurs fois avec des initialisations différentes et retenir la meilleure solution

(c) fixer k=1 uniquement

(d) ignorer la convergence

Q185. La méthode du coude sert à :

(a) choisir k en repérant où l'ajout d'un groupe cesse de réduire significativement l'inertie

(b) calculer la distance euclidienne

(c) choisir λ pour Ridge

(d) calibrer le taux d'apprentissage du boosting

Q186. L'analyse en composantes principales (ACP) produit :

(a) des variables corrélées entre elles

(b) de nouvelles variables non corrélées, ordonnées par variance décroissante

(c) une classification supervisée

(d) un arbre de décision

Q187. Les composantes principales reposent sur :

(a) les vecteurs propres de la matrice de covariance

(b) une régularisation $\ell 1$

(c) un vote majoritaire

(d) une distance de Manhattan

Q188. L'ACP en amont d'un modèle supervisé sert à :

(a) augmenter la dimension des données

(b) réduire la dimension et atténuer la multicolinéarité et le fléau de la dimension

(c) remplacer totalement la validation croisée

(d) éliminer le besoin de standardisation

Q189. Le prix payé en utilisant les composantes principales plutôt que les variables originales est :

(a) une perte d'interprétabilité directe

(b) une augmentation systématique du biais

(c) une perte totale d'information

(d) une réduction du nombre d'observations

Q190. Face à peu de variables et une relation approximativement linéaire, privilégier :

(a) k-means

(b) la régression (éventuellement régularisée)

(c) le boosting uniquement

(d) l'ACP uniquement

Q191. Pour sélectionner des variables parmi de nombreuses candidates corrélées, privilégier :

(a) k-NN

(b) le Lasso (ou Elastic Net)

(c) k-means

(d) l'ACP seule sans régression

Q192. Pour des interactions complexes avec besoin d'interprétabilité directe, privilégier :

(a) un arbre isolé peu profond

(b) un réseau de neurones profond

(c) le boosting avec de nombreuses itérations

(d) k-means

Q193. Pour la performance prédictive maximale, interprétabilité secondaire, privilégier :

(a) une régression linéaire simple

(b) une forêt aléatoire ou du boosting

(c) k-means uniquement

(d) l'ACP seule

Q194. Pour structurer des données sans étiquette, privilégier :

(a) la régression Ridge

(b) k-means (groupes) ou ACP (dimensions)

(c) le boosting

(d) les arbres de décision supervisés

Q195. Les modèles complexes posent un défi réglementaire en scoring de crédit car :

(a) ils sont toujours moins performants

(b) ils sont difficiles à expliquer à un régulateur ou un client refusé

(c) ils nécessitent moins de données

(d) ils éliminent tout risque de biais

Q196. Le concept drift désigne :

(a) une amélioration continue du modèle dans le temps

(b) la dégradation d'un modèle quand la relation sous-jacente entre x et y change dans le temps

(c) un problème uniquement lié au bootstrap

(d) une propriété exclusive des arbres de décision

Q197. Un modèle ML performant en moyenne peut échouer en scénario de crise car :

(a) il généralise toujours parfaitement

(b) il peut mal généraliser aux régimes inédits (queues de distribution)

(c) il élimine tout bruit irréductible

(d) il ignore systématiquement les données historiques

Q198. Le ML et la simulation (chapitre 13) sont combinés en gestion des risques car :

(a) le ML seul suffit toujours en toutes circonstances

(b) le ML capture bien les relations moyennes, la simulation explore les scénarios de queue

(c) la simulation remplace totalement le ML

(d) les deux approches sont incompatibles

Q199. Existe-t-il une hiérarchie absolue entre toutes les méthodes du chapitre 14 ?

(a) Oui, le boosting est toujours optimal

(b) Non, le choix dépend des données, de l'objectif et des contraintes d'explicabilité

(c) Oui, Ridge est toujours optimal

(d) Non, car aucune méthode ne fonctionne jamais

Q200. Le fil rouge du chapitre 14 se résume par :

(a) maximiser systématiquement la complexité du modèle

(b) apprendre le signal sans mémoriser le bruit, chaque méthode répondant au compromis biais-variance

(c) ignorer totalement la validation croisée

(d) utiliser exclusivement des méthodes non supervisées

Partie E --- Corrigé commenté des 200 QCM

Réponse correcte en gras suivie de l'explication. Distribution équilibrée (50 a, 50 b, 50 c, 50 d).

Thème 1 --- Apprentissage supervisé, non supervisé, rôle du ML

Q1 — (c) numérique par scénarios. Elle génère des scénarios aléatoires et lit la distribution empirique.

Q2 — (b) une cible y connue à prédire. Des paires (x,y) sont utilisées pour ajuster f.

Q3 — (b) une structure cachée sans cible. Aucune cible fournie, structure cherchée dans x seul.

Q4 — (b) la classification. Cible catégorielle binaire.

Q5 — (c) la performance prédictive hors-échantillon. Priorité affichée à la prédiction sur l'inférence.

Q6 — (b) choisir les hyperparamètres. Rôle spécifique de sélection d'hyperparamètres.

Q7 — (c) une seule fois, en fin de processus. Pour une estimation non biaisée de la généralisation.

Q8 — (b) une information du test qui influence l'entraînement. Biaise optimistement la performance estimée.

Q9 — (b) une estimation trop optimiste de la performance finale. Le modèle est indirectement calibré sur le test.

Q10 — (c) à la fois un outil statistique et un algorithme supervisé élémentaire. La frontière ML/statistique classique n'est pas nette.

Q11 — (b) des interactions non linéaires entre variables existent. Interactions non linéaires entre centaines de variables.

Q12 — (b) des méthodes d'ensemble sur structure rare et non linéaire. Structure rare et non linéaire, ensembles adaptés.

Q13 — (c) de l'apprentissage non supervisé. Absence de cible = non supervisé.

Q14 — (b) Non, elle agrège 500 modèles distincts. Pas de coefficient unique résumant la relation globale.

Q15 — (b) paramétrique, historique, Monte-Carlo. Rappel du chapitre 13 : trois approches distinctes.

Q16 — (b) la régression. Cible continue = régression.

Q17 — (b) interprétabilité contre performance prédictive. Interprétabilité souvent sacrifiée pour la performance.

Q18 — (b) supervisé. Cible y connue = supervisé.

Q19 — (a) scoring, fraude, segmentation. Scoring de crédit, détection de fraude, segmentation.

Q20 — (b) la présence ou l'absence d'une cible y connue. Critère discriminant central.

Thème 2 --- Biais-variance et surapprentissage

Q21 — (b) biais^2 + variance + bruit irréductible. Trois termes, dont le bruit irréductible.

Q22 — (b) son écart systématique à la vraie fonction. Écart systématique $E[\hat{f}(x)]$-$f(x)$.

Q23 — (b) sa sensibilité à l'échantillon d'entraînement utilisé. Sensibilité au hasard d'échantillonnage.

Q24 — (b) de biais élevé. Sous-apprentissage = biais élevé.

Q25 — (b) de variance élevée. Surapprentissage = variance élevée.

Q26 — (b) le sous-apprentissage. Biais élevé, modèle trop simple.

Q27 — (b) le surapprentissage. Variance élevée, modèle trop complexe.

Q28 — (c) la somme biais^2 + variance. Minimisation conjointe, pas isolée.

Q29 — (b) un écart croissant entre erreur d'entraînement et erreur de test. Erreur de test qui remonte au-delà d'un seuil.

Q30 — (b) potentiellement un signal de surapprentissage. Signal d'alarme, pas un succès automatique.

Q31 — (b) l'erreur de test (hors-échantillon). Critère de généralisation, pas d'ajustement.

Q32 — (b) pénalisant la complexité (taille des coefficients). Pénalise directement la complexité du modèle.

Q33 — (b) limitant sa profondeur ou supprimant des branches. Limite la complexité structurelle de l'arbre.

Q34 — (b) moyennant plusieurs modèles instables pour réduire la variance. Réduction de variance par moyennage.

Q35 — (a) mesurant honnêtement l'erreur de généralisation. Guide le choix du bon niveau de complexité.

Q36 — (b) un biais élevé. Modèle trop rigide = biais élevé.

Q37 — (b) une variance élevée. Modèle flexible = variance élevée.

Q38 — (b) Non, il est intrinsèque aux données. Composante indépendante du modèle choisi.

Q39 — (b) le biais diminue et la variance augmente. Relation inverse classique biais/variance.

Q40 — (b) équilibrer biais et variance pour extraire le signal sans le bruit. Fil rouge de l'ensemble des méthodes du chapitre.

Thème 3 --- Validation croisée et évaluation de modèle

Q41 — (b) partager en k plis, entraîner sur k-1, évaluer sur le pli restant, répéter et moyenner. Chaque pli sert une fois de test.

Q42 — (b) 5 ou 10. Valeurs usuelles en pratique.

Q43 — (b) chaque observation sert une fois de test, réduisant la dépendance au hasard du découpage. Estimation plus stable de la généralisation.

Q44 — (b) un réentraînement k fois du modèle. Temps de calcul multiplié par k.

Q45 — (b) l'erreur quadratique moyenne (MSE). MSE ou R^2 hors-échantillon pour la régression.

Q46 — (b) un modèle prédisant toujours la classe majoritaire affiche une précision élevée sans valeur prédictive. Biais vers la classe majoritaire rare informative.

Q47 — (b) classes prédites et classes réelles. Vrais/faux positifs et négatifs.

Q48 — (b) la proportion de positifs réels correctement identifiés. Taux de vrais positifs.

Q49 — (a) la capacité de discrimination du modèle entre classes. Insensible au déséquilibre des classes.

Q50 — (b) choisir un hyperparamètre par balayage de grille. Sélection d'hyperparamètre principalement.

Q51 — (b) choisir l'hyperparamètre par CV sur l'entraînement, puis évaluer une fois sur le test. Ordre rigoureux CV puis test final unique.

Q52 — (b) elle exploite toutes les observations à tour de rôle pour l'entraînement et le test. Aucune donnée gaspillée.

Q53 — (b) la proportion de négatifs réels correctement identifiés. Taux de vrais négatifs.

Q54 — (b) leave-one-out (LOOCV). Un pli par observation individuelle.

Q55 — (b) un coût de calcul très élevé (n réentraînements). n réentraînements complets nécessaires.

Q56 — (b) la moyenne des k erreurs sur les plis laissés de côté. Moyenne sur l'ensemble des plis.

Q57 — (b) la courbe ROC/AUC ou la matrice de confusion complète. Classe rare = métriques adaptées au déséquilibre.

Q58 — (b) la dépendance au hasard du découpage d'un split unique. Stabilise l'estimation de généralisation.

Q59 — (b) celle qui minimise l'erreur de validation croisée moyenne. Critère de sélection rigoureux par CV.

Q60 — (b) estimer honnêtement la généralisation et guider le choix des hyperparamètres. Rôle méthodologique clé sans se substituer au test.

Thème 4 --- Régression Ridge

Q61 — (b) somme des carrés résiduels + $\lambda\Sigma\beta_j^2$. Pénalité ℓ2 caractéristique de Ridge.

Q62 — (b) les moindres carrés ordinaires. Absence de pénalité = MCO classique.

Q63 — (a) des coefficients tous écrasés vers zéro. Pénalité extrême, rétrécissement total.

Q64 — (b) multicolinéarité entre variables explicatives. Stabilise l'inversion de X'X proche de la singularité.

Q65 — (b) $(X'X+\lambda I)^{-1}X'y$. Ajout de λI avant inversion.

Q66 — (b) Non, la région de contrainte est lisse sans coin. Hypersphère lisse, pas de coin sur les axes.

Q67 — (b) rétrécissement (shrinkage) uniquement. Rétrécit sans jamais sélectionner.

Q68 — (b) la pénalité traite symétriquement tous les coefficients, sensible à l'échelle des variables. Échelles comparables indispensables à la pénalité symétrique.

Q69 — (b) Oui, en échange d'une réduction de variance. Compromis biais-variance explicite.

Q70 — (b) validation croisée sur une grille de valeurs. Optimisation par validation croisée.

Q71 — (a) X'X est singulière sans pénalité et Ridge la rend inversible. Régularisation restaure l'inversibilité.

Q72 — (b) répartir le poids de façon plus équilibrée entre elles. Traitement plus stable que le Lasso pour la colinéarité.

Q73 — (c) pénalité ℓ2. Norme euclidienne au carré des coefficients.

Q74 — (b) Non, toutes les variables restent dans le modèle. Coefficients rétrécis mais tous conservés.

Q75 — (b) d'un cercle (disque). Hypersphère lisse, sans coin.

Q76 — (b) réduire la variance en éloignant la matrice de la singularité. Stabilisation numérique et statistique.

Q77 — (b) Ridge. Stabilise les coefficients face à la colinéarité.

Q78 — (c) Aucun (sauf $\lambda\to\infty$). Rétrécissement sans annulation exacte.

Q79 — (b) il réduit la variance de l'estimateur au prix d'un léger biais. Meilleur compromis biais-variance en présence de bruit.

Q80 — (a) pénaliser la somme des carrés des coefficients pour réduire la variance, sans jamais les annuler. Synthèse du principe central de Ridge.

Thème 5 --- Régression Lasso et sélection de variables

Q81 — (b) somme des carrés résiduels + $\lambda\Sigma|\beta_j|$. Pénalité ℓ1 caractéristique du Lasso.

Q82 — (c) pénalité ℓ1. Somme des valeurs absolues des coefficients.

Q83 — (b) Oui, c'est sa propriété distinctive de sélection. Sélection automatique de variables.

Q84 — (b) d'un losange (polytope à coins). Polytope à coins, contrairement à Ridge.

Q85 — (a) les courbes de niveau elliptiques touchent souvent la contrainte exactement en un coin. Explication géométrique du mécanisme de sélection.

Q86 — (b) en retenir arbitrairement une seule du groupe. Comportement instable en présence de colinéarité forte.

Q87 — (b) seules les variables à coefficient non nul entrent dans le récit du modèle. Sélection = modèle plus lisible.

Q88 — (b) il sélectionne automatiquement un sous-ensemble parcimonieux. Réduit le risque de surapprentissage par sélection.

Q89 — (a) une instabilité du choix de variable retenue d'une exécution à l'autre. Sensibilité de la sélection à la colinéarité.

Q90 — (b) les pénalités $\ell 1$ et $\ell 2$. Combinaison linéaire des deux pénalités.

Q91 — (b) bénéficier de la sélection du Lasso tout en gérant mieux la colinéarité comme Ridge. Combine les avantages des deux approches.

Q92 — (b) validation croisée. Même logique de calibration que pour Ridge.

Q93 — (b) un modèle avec peu de coefficients non nuls parmi les variables candidates. Sélection d'un sous-ensemble restreint.

Q94 — (b) Oui, pour la même raison que Ridge. Échelle comparable indispensable.

Q95 — (b) le Lasso (ou Elastic Net si forte colinéarité). Sélection et parcimonie recherchées.

Q96 — (b) les moindres carrés ordinaires. Absence de pénalité = MCO.

Q97 — (b) de plus en plus de coefficients sont annulés, jusqu'à un modèle vide. Pénalité croissante = sélection de plus en plus stricte.

Q98 — (b) Ridge rétrécit sans annuler, Lasso peut annuler et sélectionner. Synthèse du contraste central entre les deux méthodes.

Q99 — (b) le poids relatif entre pénalité $\ell 1$ et $\ell 2$. Pondération entre Lasso et Ridge.

Q100 — (a) une pénalité $\ell 1$ qui réalise une sélection automatique de variables grâce à sa géométrie à coins. Synthèse du principe central du Lasso.

Thème 6 --- K plus proches voisins

Q101 — (b) prédire à partir des k observations les plus proches. Prédiction par proximité, moyenne ou vote.

Q102 — (b) la distance euclidienne. Distance euclidienne standard.

Q103 — (b) il ne fait aucun calcul à l'entraînement, mémorisant simplement les données. Tout le calcul se fait à la prédiction.

Q104 — (b) il ne fait aucune hypothèse de forme fonctionnelle a priori. Absence d'hypothèse de forme fonctionnelle.

Q105 — (b) une variance élevée, sensible au bruit local. Frontière très irrégulière, forte variance.

Q106 — (b) un biais élevé, lissage excessif. Proche de la moyenne globale, sous-apprentissage.

Q107 — (b) validation croisée. Calibration systématique par CV.

Q108 — (b) la perte de pouvoir discriminant de la proximité en grande dimension. Points également éloignés en haute dimension.

Q109 — (b) une réduction de dimension préalable (ex. ACP). Réduction de dimension comme prétraitement.

Q110 — (b) vote majoritaire des classes des k voisins. Classe majoritaire parmi les voisins.

Q111 — (a) la distance euclidienne est sensible à l'échelle des variables. Échelle affecte directement le calcul de distance.

Q112 — (b) Oui, la prédiction épouse exactement chaque point d'entraînement. Variance maximale, cas extrême.

Q113 — (b) Aucun, il mémorise simplement les données. Apprentissage paresseux, aucun paramètre estimé.

Q114 — (b) à la prédiction (recherche des voisins). Recherche de proximité effectuée à la prédiction.

Q115 — (a) chaque prédiction compare la nouvelle observation à toutes les observations d'entraînement. Coût de recherche proportionnel à n.

Q116 — (b) cela peut créer des égalités de vote entre les deux classes. Risque d'ex-aequo dans le vote majoritaire.

Q117 — (b) Oui, elle épouse n'importe quelle forme. Grande flexibilité de la frontière de décision.

Q118 — (b) Oui, la proximité reste discriminante en faible dimension. Faible dimension = k-NN performant.

Q119 — (b) Non, un encodage numérique préalable est nécessaire. Encodage requis (ex. one-hot) avant usage.

Q120 — (a) prédire par ressemblance aux observations déjà vues, sans modèle paramétrique explicite. Synthèse du principe central de k-NN.

Thème 7 --- Arbres de décision

Q121 — (b) partitionner récursivement l'espace des variables par des règles binaires. Partition récursive jusqu'à des feuilles terminales.

Q122 — (b) Σ p̂c(1-p̂c). Formule standard de l'impureté de Gini.

Q123 — (b) un nœud parfaitement pur, une seule classe présente. Pureté totale du nœud.

Q124 — (a) chaque scission est choisie optimale localement, sans garantie globale. Optimisation locale à chaque étape.

Q125 — (b) la somme des carrés résiduels intra-région. Adaptation du critère au cas continu.

Q126 — (b) surapprend presque toujours en isolant des observations bruitées. Risque élevé de surapprentissage sans contrainte.

Q127 — (b) la profondeur maximale et le nombre minimal d'observations par feuille. Contrôles directs de la complexité de l'arbre.

Q128 — (b) supprimer après coup les branches n'améliorant pas l'erreur de validation. Simplification post-construction basée sur la validation.

Q129 — (b) son interprétabilité directe (règles lisibles). Lisibilité des règles de décision.

Q130 — (b) Oui, sans avoir à les spécifier explicitement. Capture native des interactions non linéaires.

Q131 — (b) une forte instabilité (variance élevée) face à une perturbation des données. Sensibilité élevée aux petites perturbations.

Q132 — (b) Oui, sans encodage préalable nécessaire. Contrairement à k-NN ou Ridge/Lasso.

Q133 — (b) minimiser l'impureté pondérée des deux nœuds enfants. Critère d'optimisation locale de la scission.

Q134 — (b) Non, aucune hypothèse paramétrique de distribution. Méthode non paramétrique, sans hypothèse de loi.

Q135 — (b) Non, la recherche globale serait combinatoirement intraitable. Optimalité locale seulement, pas globale.

Q136 — (b) les méthodes d'ensemble (bagging, forêts, boosting). Moyenner réduit la variance sans détériorer le biais.

Q137 — (b) la moyenne des y des observations de cette région. Prédiction par moyenne locale.

Q138 — (b) un arbre de décision peu profond, directement lisible. Interprétabilité réglementaire prioritaire.

Q139 — (a) réduire le biais mais augmenter la variance. Compromis biais-variance classique lié à la profondeur.

Q140 — (a) interprétable et flexible, mais instable (variance élevée). Synthèse du compromis propre à l'arbre isolé.

Thème 8 --- Bagging et forêts aléatoires

Q141 — (b) générer B échantillons bootstrap, entraîner un modèle sur chacun, puis moyenner. Agrégation de modèles parallèles sur bootstrap.

Q142 — (b) une sélection aléatoire d'un sous-ensemble de variables à chaque scission. Spécificité distinctive de la forêt aléatoire.

Q143 — (a) $\rho\sigma^2 + (1-\rho)\sigma^2/B$. Décomposition classique de la variance agrégée.

Q144 — (b) le moyennage n'apporte aucun bénéfice de variance, quel que soit B. Corrélation élevée annule le bénéfice de l'agrégation.

Q145 — (b) décorréler les arbres pour rendre le moyennage bénéfique. Décorrélation = clé du gain de variance.

Q146 — (b) la variance. Levier principal du bagging.

Q147 — (a) Ils ont un biais faible ; c'est l'agrégation qui gère la variance. Combinaison biais faible individuel + agrégation.

Q148 — (b) les observations non tirées dans un échantillon bootstrap donné (environ 36.8%). Observations laissées de côté par le tirage bootstrap.

Q149 — (b) 36.8% (1/e). Résultat classique lié à 1/e.

Q150 — (b) estimer l'erreur de généralisation sans validation croisée séparée. Estimation gratuite de la performance de généralisation.

Q151 — (b) Non, contrairement au boosting, cela stabilise davantage la moyenne. Différence clé avec le boosting séquentiel.

Q152 — (b) $m \approx \sqrt{p}$. Règle empirique usuelle pour la forêt aléatoire.

Q153 — (b) Non, elle perd l'interprétabilité directe au profit de la performance. Compromis performance/interprétabilité.

Q154 — (b) la réduction moyenne d'impureté apportée par chaque variable à travers tous les arbres. Mesure agrégée sur l'ensemble des arbres.

Q155 — (b) Non, il peut s'appliquer à tout modèle instable, mais les arbres profonds y sont particulièrement adaptés. Principe général applicable à divers modèles instables.

Q156 — (b) Elle gère les interactions non linéaires nombreuses tout en contrôlant la variance par agrégation. Adaptation à la complexité et à la robustesse recherchées.

Q157 — (b) Non, les arbres restent souvent corrélés via la variable dominante. D'où l'ajout de la sélection aléatoire de variables.

Q158 — (b) vote majoritaire des B arbres. Agrégation par vote, comme le bagging classique.

Q159 — (b) Oui, chaque arbre est entraîné indépendamment. Contraste avec la nature séquentielle du boosting.

Q160 — (a) moyenner de nombreux arbres profonds décorrélés pour réduire la variance. Synthèse du principe central des forêts aléatoires.

Thème 9 --- Boosting

Q161 — (b) construire une séquence de modèles faibles, chacun corrigeant les erreurs des précédents. Construction séquentielle et corrective.

Q162 — (b) Séquentiel. Nature séquentielle distinctive du boosting.

Q163 — (b) la réduction du biais. Contraste avec le bagging (variance).

Q164 — (b) la réduction de la variance. Rappel du principe du bagging.

Q165 — (b) un modèle à peine meilleur qu'un tirage aléatoire (ex. un stump). Composant de base typiquement très simple.

Q166 — (b) la contribution de chaque modèle faible successif à la prédiction finale. Pondération de chaque étape du boosting.

Q167 — (b) un apprentissage plus lent mais un risque de surapprentissage réduit. Prudence accrue à chaque itération.

Q168 — (b) un ν petit combiné à un grand nombre d'itérations M (calibré par CV). Compromis optimal validé empiriquement.

Q169 — (b) Plus sensible, car il cible explicitement les observations mal prédites. Ciblage répété des erreurs, y compris aberrantes.

Q170 — (b) Non, risque de surapprentissage au-delà d'un certain M. Différence clé avec le bagging.

Q171 — (b) arrêter les itérations quand l'erreur de validation cesse de s'améliorer. Critère d'arrêt basé sur la performance de validation.

Q172 — (b) $\hat{f}_M(x) = \sum \nu \hat{f}_m(x)$. Somme pondérée par le taux d'apprentissage.

Q173 — (a) Sa construction séquentielle réduit fortement le biais tout en restant flexible sur les non-linéarités. Combinaison flexibilité et réduction de biais.

Q174 — (b) Non, c'est une somme pondérée de nombreux modèles faibles. Perte d'interprétabilité directe, comme les forêts.

Q175 — (b) augmentant le poids des observations mal classées par les modèles précédents. Repondération ciblée sur les erreurs.

Q176 — (b) les résidus (erreurs) laissés par l'ensemble des modèles précédents. Correction séquentielle des résidus.

Q177 — (b) Non, sa nature séquentielle limite la parallélisation. Chaque étape dépend de la précédente.

Q178 — (b) le taux d'apprentissage ν, le nombre d'itérations M, et la profondeur des arbres faibles. Calibration conjointe multi-hyperparamètres.

Q179 — (b) La forêt aléatoire, plus robuste par défaut. Le boosting nécessite un réglage plus fin.

Q180 — (a) combiner séquentiellement des modèles faibles, chacun corrigeant les erreurs du précédent, pour réduire le biais. Synthèse du principe central du boosting.

Thème 10 --- k-means, ACP et synthèse

Q181 — (a) la somme des distances au carré aux centroïdes (inertie intra-groupe). Inertie intra-groupe minimisée par l'algorithme.

Q182 — (b) affectation (au centroïde le plus proche) et mise à jour (recalcul des centroïdes). Algorithme itératif classique de k-means.

Q183 — (b) Un minimum local, dépendant de l'initialisation. Dépendance à l'initialisation aléatoire.

Q184 — (b) relancer l'algorithme plusieurs fois avec des initialisations différentes et retenir la meilleure solution. Pratique standard de robustesse.

Q185 — (a) choisir k en repérant où l'ajout d'un groupe cesse de réduire significativement l'inertie. Heuristique de choix du nombre de groupes.

Q186 — (b) de nouvelles variables non corrélées, ordonnées par variance décroissante. Décorrélation et ordre de variance décroissante.

Q187 — (a) les vecteurs propres de la matrice de covariance. Base mathématique de l'ACP.

Q188 — (b) réduire la dimension et atténuer la multicolinéarité et le fléau de la dimension. Prétraitement classique avant modélisation supervisée.

Q189 — (a) une perte d'interprétabilité directe. Chaque composante mélange toutes les variables d'origine.

Q190 — (b) la régression (éventuellement régularisée). Cas d'usage adapté à la régression classique.

Q191 — (b) le Lasso (ou Elastic Net). Sélection automatique recherchée.

Q192 — (a) un arbre isolé peu profond. Compromis interprétabilité/complexité.

Q193 — (b) une forêt aléatoire ou du boosting. Méthodes d'ensemble pour la performance maximale.

Q194 — (b) k-means (groupes) ou ACP (dimensions). Méthodes non supervisées appropriées.

Q195 — (b) ils sont difficiles à expliquer à un régulateur ou un client refusé. Enjeu du droit à l'explication.

Q196 — (b) la dégradation d'un modèle quand la relation sous-jacente entre x et y change dans le temps. Changement de la relation sous-jacente au cours du temps.

Q197 — (b) il peut mal généraliser aux régimes inédits (queues de distribution). Limite propre aux scénarios extrêmes non représentés.

Q198 — (b) le ML capture bien les relations moyennes, la simulation explore les scénarios de queue. Complémentarité des deux approches.

Q199 — (b) Non, le choix dépend des données, de l'objectif et des contraintes d'explicabilité. Absence de hiérarchie universelle.

Q200 — (b) apprendre le signal sans mémoriser le bruit, chaque méthode répondant au compromis biais-variance. Synthèse générale de l'ensemble du chapitre.
