FRM® Part I · Quantitative Analysis

Book 2 · Chapitre 15

Machine Learning and Prediction

La prédiction par apprentissage supervisé

Régression logistique, encodage, matrice de confusion et réseaux de neurones

Approfondissement quantitatif maximal

Cours illustré · définitions · démonstrations · 200 études de cas · conseils méthodologiques · 200 QCM commentés

Support d'étude --- questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel --- pipeline XeLaTeX

Contents

Partie A — Cours approfondi **3**
15.1 — Le rôle de la régression linéaire et logistique en prédiction . . . 3
15.2 — Encodage des variables catégorielles . . . 3
15.3 — La régression logistique : modèle, fonction logistique et odds . . . 4
15.4 — Estimation par maximum de vraisemblance et interprétation des coefficients . . . 5
15.5 — Régularisation appliquée à la régression logistique . . . 6
15.6 — Matrice de confusion et métriques de classification . . . 6
15.7 — Courbe ROC, AUC et choix de seuil . . . 7
15.8 — Réseaux de neurones : architecture, perceptron et fonctions d'activation . . . 8
15.9 — Entraîner un réseau de neurones : fonction de perte et rétropropagation . . . 9
15.10 — Régression logistique vs réseaux de neurones : comparaison, applications et synthèse . . . 10

Partie B — 200 études de cas pratiques **11**
Bloc 1 — Le rôle de la régression en prédiction . . . 11
Bloc 2 — Encodage des variables catégorielles . . . 12
Bloc 3 — La régression logistique : modèle, sigmoïde, odds . . . 13
Bloc 4 — Estimation par MLE et interprétation . . . 15
Bloc 5 — Régularisation appliquée à la régression logistique . . . 16
Bloc 6 — Matrice de confusion et métriques de classification . . . 17
Bloc 7 — Courbe ROC, AUC et choix de seuil . . . 19
Bloc 8 — Réseaux de neurones : architecture et activation . . . 20
Bloc 9 — Entraîner un réseau de neurones . . . 21
Bloc 10 — Comparaison, applications et synthèse . . . 23

Partie C — Méthodologie, formulaire et astuces **24**
C.1 — Formulaire complet . . . 24
C.2 — Le tableau maître du chapitre . . . 25
C.3 — Carte de décision : classifier en gestion des risques . . . 26
C.4 — Glossaire bilingue . . . 26
C.5 — Protocole complet d'un modèle de classification en gestion des risques . . . 27
C.6 — Les douze pièges classiques . . . 28
C.7 — Astuces de calcul et de mémorisation pour l'examen . . . 28

Partie F — Étude de cas intégrée : de la régression logistique au réseau de neurones **29**
F.1 — Contexte et préparation des données . . . 29
F.2 — Le modèle logistique : estimation et lecture complète . . . 29
F.3 — Évaluation : matrice de confusion, arbitrage de seuil et ROC . . . 30
F.4 — L'extension neuronale : gain réel et coût de complexité . . . 30

Partie D — 200 questions à choix multiple **31**
Thème 1 — Le rôle de la régression en prédiction . . . 31
Thème 2 — Encodage des variables catégorielles . . . 34
Thème 3 — Régression logistique : sigmoïde, odds, logit . . . 37
Thème 4 — Estimation MLE et interprétation des coefficients . . . 40
Thème 5 — Régularisation de la régression logistique . . . 43
Thème 6 — Matrice de confusion et métriques . . . 46
Thème 7 — Courbe ROC, AUC et choix de seuil . . . 49
Thème 8 — Réseaux de neurones : architecture et activation . . . 52
Thème 9 — Entraînement des réseaux de neurones . . . 54
Thème 10 — Comparaison, applications et synthèse . . . 57

Partie E — Corrigé commenté des 200 QCM **60**
Thème 1 — Le rôle de la régression en prédiction . . . 60
Thème 2 — Encodage des variables catégorielles . . . 61

Thème 3 — Régression logistique : sigmoïde, odds, logit 62
Thème 4 — Estimation MLE et interprétation des coefficients 62
Thème 5 — Régularisation de la régression logistique 63
Thème 6 — Matrice de confusion et métriques 63
Thème 7 — Courbe ROC, AUC et choix de seuil 64
Thème 8 — Réseaux de neurones : architecture et activation 65
Thème 9 — Entraînement des réseaux de neurones 65
Thème 10 — Comparaison, applications et synthèse 66

Partie A --- Cours approfondi

Le chapitre 14 a posé le vocabulaire général du machine learning — supervisé/non supervisé, compromis biais-variance, validation croisée — et présenté une famille de modèles (Ridge, Lasso, k-NN, arbres, ensembles, k-means, ACP). Ce chapitre se concentre sur les deux piliers les plus utilisés en pratique pour la **prédiction supervisée** en gestion des risques : la **régression logistique**, extension naturelle de la régression linéaire à une cible catégorielle, et les **réseaux de neurones**, modèles non linéaires universels inspirés (lointainement) du cerveau biologique. Entre les deux, un détour indispensable : comment **encoder** des variables catégorielles pour qu'elles soient exploitables par un modèle numérique, et comment **évaluer** rigoureusement une prédiction de classification via la matrice de confusion et la courbe ROC.

Le fil rouge : de la prédiction d'un nombre à la prédiction d'une catégorie

La régression linéaire (chapitre 9) prédit un nombre continu. Une immense partie des questions de gestion des risques appelle plutôt une catégorie : *cette contrepartie fera-t-elle défaut ?*, *cette transaction est-elle frauduleuse ?*, *ce marché va-t-il monter ou baisser ?*. La régression logistique résout cette transition en douceur — même structure linéaire sous-jacente, transformée pour produire une probabilité. Les réseaux de neurones vont plus loin, empilant plusieurs telles transformations pour capturer des relations non linéaires complexes qu'une seule couche logistique ne peut représenter.

15.1 --- Le rôle de la régression linéaire et logistique en prédiction

Premier jalon : situer la régression, linéaire puis logistique, comme les modèles de prédiction les plus simples et les plus utilisés.

Régression comme outil de prédiction

Utilisée en **prédiction**, la régression linéaire estime $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p$ pour une cible continue. Son usage prédictif diffère de son usage inférentiel (chapitres 7-9) : l'accent porte sur la qualité de $\hat{y}$ pour de **nouvelles** observations (§14.3), pas sur la significativité de chaque $\hat{\beta}_j$.

La limite de la régression linéaire pour une cible binaire

Si $y \in \{0, 1\}$ (défaut/non-défaut), une régression linéaire directe sur y produit des prédictions $\hat{y}$ qui peuvent sortir de l'intervalle $[0, 1]$ — un non-sens pour une probabilité. De plus, la relation entre les variables explicatives et la probabilité de l'événement est rarement linéaire sur tout le domaine : la probabilité doit rester bornée, ce qu'aucune droite ne garantit naturellement. Ces deux limites motivent un modèle dédié : la **régression logistique**.

Régression linéaire de probabilité --- pourquoi elle reste parfois utilisée

Le **modèle de probabilité linéaire** (régression linéaire directement sur une cible binaire) reste parfois employé pour sa simplicité d'interprétation (chaque $\hat{\beta}_j$ se lit comme un effet marginal constant sur la probabilité) et sa rapidité de calcul. Mais ses prédictions hors $[0, 1]$ et son hétéroscédasticité structurelle (la variance de y dépend de sa moyenne pour une variable binaire, chapitre 9) en font un outil d'appoint, supplanté par la régression logistique dès que la précision des probabilités prédites importe.

15.2 --- Encodage des variables catégorielles

Avant tout modèle numérique, une variable catégorielle (secteur d'activité, notation, pays) doit être transformée en variables numériques exploitables.

Encodage par variables indicatrices (*dummy variables*)

Une variable catégorielle à C catégories est représentée par $C-1$ **variables indicatrices** (binaires, 0/1), chacune signalant l'appartenance à une catégorie donnée ; la catégorie omise sert de **référence**, absorbée dans la constante β_0.

Pourquoi $C-1$ et non C indicatrices

$$\text{Avec } C \text{ indicatrices : } \sum_{c=1}^{C} D_c = 1 \text{ toujours} \Rightarrow \text{colinéarité parfaite avec la constante.}$$

Le piège de la trappe des variables indicatrices (*dummy variable trap*)

Inclure les C indicatrices **et** la constante β_0 dans une même régression crée une **colinéarité parfaite** : la somme des C indicatrices vaut toujours 1, exactement comme la colonne de constante — rendant $X^\top X$ non inversible (rappel §14.4). Omettre une catégorie (la référence) résout ce problème : les coefficients des $C-1$ indicatrices restantes s'interprètent alors comme des écarts **par rapport à la catégorie de référence**.

Encodage one-hot vs encodage dummy

L'**encodage one-hot** (une colonne binaire par catégorie, C colonnes, **sans** suppression de référence) est standard en machine learning pur, notamment pour des modèles sans constante explicite ou insensibles à la colinéarité parfaite (arbres, forêts, chapitre 14). L'**encodage dummy** ($C-1$ colonnes, avec référence omise) reste la convention en régression (linéaire ou logistique), où la colinéarité parfaite briserait l'estimation. Le choix dépend donc du modèle en aval, pas d'une règle universelle.

Choix de la catégorie de référence

Le choix de la catégorie de référence est arbitraire sur le plan statistique (les prédictions du modèle sont identiques quel que soit ce choix) mais **n'est pas neutre pour l'interprétation** : choisir comme référence la catégorie la plus fréquente, ou la catégorie « normale » d'un point de vue métier (ex. « secteur non cyclique » comme référence pour des indicatrices sectorielles), facilite la lecture économique des coefficients estimés.

15.3 --- La régression logistique : modèle, fonction logistique et odds

Le cœur du chapitre : comment transformer une combinaison linéaire non bornée en une probabilité valide entre 0 et 1.

Régression logistique

La **régression logistique** modélise la probabilité d'un événement binaire $y=1$ via la **fonction logistique** (sigmoïde) appliquée à une combinaison linéaire des variables explicatives :

$$P(y=1 \mid x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\cdots+\beta_p x_p)}} = \frac{1}{1+e^{-z}}, \qquad z = \beta_0+\beta_1 x_1+\cdots+\beta_p x_p.$$

La fonction logit --- transformation inverse

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = z = \beta_0+\beta_1 x_1+\cdots+\beta_p x_p.$$

Démonstration

Pourquoi la fonction logistique borne-t-elle nécessairement la sortie entre 0 et 1 ? Considérons $z \to -\infty$: $e^{-z} \to +\infty$, donc $P = 1/(1+\infty) \to 0$. Pour $z \to +\infty$: $e^{-z} \to 0$, donc $P \to 1/(1+0) = 1$. Pour $z = 0$: $P = 1/2$. La fonction est strictement croissante en z (sa dérivée $P(1-P) > 0$ partout), garantissant une correspondance bijective entre tout $z \in \mathbb{R}$ et une probabilité $P \in (0,1)$ — exactement la propriété manquante à la régression linéaire directe. Cette construction n'est pas arbitraire : elle découle de la modélisation du **logit** (log des *odds*, ci-dessous) comme fonction linéaire des variables explicatives, puis de l'inversion de cette relation pour retrouver P.

Les *odds* (cote) et le *logit*

Les **odds** (cote) d'un événement de probabilité p sont définies par odds $= p/(1-p)$ — par exemple, $p = 0.75$ donne des odds de 3 (« 3 contre 1 »). Le **logit** est le logarithme des odds, $\ln(p/(1-p))$, et c'est précisément cette quantité que la régression logistique modélise **linéairement** : $\text{logit}(p) = z$. La sigmoïde n'est autre que l'inverse de cette transformation logit.

Non-linéarité de l'effet marginal

Contrairement à la régression linéaire, où β_j est l'effet marginal constant de x_j sur y, l'effet marginal d'x_j sur la **probabilité** $P(y = 1 \mid x)$ en régression logistique **dépend du point** où il est évalué : $\partial P/\partial x_j = \beta_j \cdot P(1-P)$, maximal quand $P = 0.5$ et quasi nul quand P est proche de 0 ou de 1. Un même β_j produit donc un effet différent selon que la contrepartie est déjà très risquée ou très sûre — une richesse d'interprétation propre au modèle logistique.

15.4 --- Estimation par maximum de vraisemblance et interprétation des coefficients

Comment les coefficients β de la régression logistique sont-ils estimés, et comment les lire économiquement.

Estimation par maximum de vraisemblance (MLE)

Les coefficients $\hat{\beta}$ de la régression logistique sont estimés par **maximum de vraisemblance** (chapitre 5) : on choisit les $\hat{\beta}$ qui maximisent la probabilité (vraisemblance) d'observer l'échantillon effectivement obtenu, $L(\beta) = \prod_{i=1}^{n} P(y=1 \mid x_i)^{y_i} \left[1 - P(y=1 \mid x_i)\right]^{1-y_i}$.

Log-vraisemblance et absence de solution fermée

$$\ell(\beta) = \sum_{i=1}^{n} \left\{ y_i \ln P(y=1 \mid x_i) + (1-y_i) \ln \left[1 - P(y=1 \mid x_i)\right] \right\}.$$

Pas de solution fermée : optimisation numérique

Contrairement aux moindres carrés ordinaires (solution fermée $\hat{\beta} = (X^\top X)^{-1} X^\top y$), la maximisation de $\ell(\beta)$ pour la régression logistique n'a **pas de solution analytique fermée** : la non-linéarité de la sigmoïde l'empêche. L'estimation recourt à une optimisation numérique itérative (ex. Newton-Raphson, descente de gradient) qui converge vers le maximum — un premier pont conceptuel vers l'entraînement des réseaux de neurones (§15.9), qui repose sur le même principe d'optimisation itérative.

Interprétation d'un coefficient via l'odds ratio

Exponentier un coefficient, e^{β_j}, donne l'**odds ratio** associé à une augmentation d'une unité de x_j (toutes choses égales par ailleurs) : un odds ratio de 1.5 signifie que les odds de l'événement sont multipliées par

1.5 pour chaque unité supplémentaire de x_j. Un odds ratio > 1 indique un effet qui augmente la probabilité de l'événement ; < 1, un effet qui la diminue ; $= 1$, aucun effet.

Exemple travaillé --- interprétation d'un modèle de défaut

Un modèle de défaut à un an estime $\hat{\beta}_{\text{endettement}} = 0.82$ (endettement standardisé) et $\hat{\beta}_{\text{liquidité}} = -0.55$ (ratio de liquidité standardisé). Odds ratio de l'endettement : $e^{0.82} = 2.27$ — une hausse d'un écart-type de l'endettement multiplie par 2.27 les odds de défaut, toutes choses égales par ailleurs. Odds ratio de la liquidité : $e^{-0.55} = 0.577$ — une hausse d'un écart-type de liquidité **divise** les odds de défaut par $1/0.577 \approx 1.73$. Pour une contrepartie à $z = -2.0$ (probabilité de base $P = 1/(1 + e^{2.0}) = 0.119$), une hausse d'un écart-type d'endettement porte z à $-2.0 + 0.82 = -1.18$, soit $P = 1/(1 + e^{1.18}) = 0.235$ — la probabilité de défaut quasiment double, illustrant concrètement la non-linéarité de l'effet marginal évoquée en §15.3.

15.5 --- Régularisation appliquée à la régression logistique

Les mêmes outils de régularisation du chapitre 14 (Ridge, Lasso) s'appliquent directement à la régression logistique, avec la même logique.

Régression logistique régularisée

La régression logistique régularisée maximise la log-vraisemblance **pénalisée** :

$$\hat{\beta} = \arg\max_{\beta} \left\{ \ell(\beta) - \lambda \sum_{j=1}^{p} \beta_j^2 \right\} \quad \text{(Ridge)} \qquad \text{ou} \qquad \hat{\beta} = \arg\max_{\beta} \left\{ \ell(\beta) - \lambda \sum_{j=1}^{p} |\beta_j| \right\} \quad \text{(Lasso)}.$$

Pourquoi régulariser un modèle de prédiction de défaut

Un modèle de scoring dispose typiquement de dizaines à centaines de variables candidates, potentiellement corrélées (§14.4) — exactement le terrain où Ridge stabilise les coefficients et où Lasso sélectionne un sous-ensemble interprétable (§14.5). La seule différence technique avec le chapitre 14 : la pénalité s'applique désormais à la **log-vraisemblance**, pas à la somme des carrés résiduels — mais l'intuition géométrique (cercle vs losange) et l'effet sur le compromis biais-variance restent **identiques**.

Standardisation, toujours indispensable

Comme pour Ridge/Lasso en régression linéaire (§14.4-14.5), les variables explicatives doivent être **standardisées** avant régularisation logistique — la pénalité étant sensible à l'échelle des coefficients, elle-même déterminée par l'échelle des variables.

15.6 --- Matrice de confusion et métriques de classification

Une fois le modèle estimé, comment juger la qualité de ses prédictions catégorielles — au-delà de la simple précision, trop souvent trompeuse (rappel §14.3).

Matrice de confusion

La **matrice de confusion** croise les classes **prédites** (après application d'un **seuil** de décision, souvent 0.5, à la probabilité prédite) et les classes **réelles** : **vrais positifs** (VP), **faux positifs** (FP), **vrais négatifs** (VN), **faux négatifs** (FN).

Métriques dérivées de la matrice de confusion

$$\text{Exactitude (accuracy)} = \frac{VP + VN}{VP + VN + FP + FN}, \qquad \text{Précision} = \frac{VP}{VP + FP},$$
$$\text{Rappel (sensibilité)} = \frac{VP}{VP + FN}, \qquad F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}.$$

Précision vs rappel : un arbitrage, pas une hiérarchie

La **précision** répond à « parmi les contreparties prédites en défaut, combien le sont réellement ? » — cruciale quand une fausse alerte est coûteuse (ex. refuser un bon client). Le **rappel** répond à « parmi les contreparties réellement en défaut, combien le modèle en a-t-il détecté ? » — crucial quand manquer un vrai défaut est coûteux (ex. perte non couverte). Ces deux objectifs sont **en tension** : abaisser le seuil de décision augmente le rappel mais réduit typiquement la précision, et vice versa. Le score F_1, moyenne harmonique des deux, offre un compromis unique quand aucune des deux erreurs n'est a priori plus coûteuse que l'autre.

Le seuil de décision : un choix, pas une donnée

La probabilité prédite $\hat{P}(y = 1 \mid x)$ est une quantité continue ; la transformer en décision binaire nécessite un **seuil** s (souvent 0.5 par défaut, mais arbitraire). Abaisser s classe davantage d'observations en positif : le rappel augmente (moins de faux négatifs) mais la précision baisse typiquement (plus de faux positifs). Le choix du seuil optimal dépend du **coût relatif** des deux types d'erreur dans le contexte métier — un seuil bas pour la détection de fraude (rater une fraude coûte cher), un seuil potentiellement plus élevé pour l'octroi de crédit à faible marge.

Exemple travaillé --- matrice de confusion sur un portefeuille test

Un modèle de défaut est testé sur 1 000 contreparties, dont 40 en défaut réel (taux de défaut 4%). Au seuil $s = 0.5$: VP $= 25$, FN $= 15$, FP $= 60$, VN $= 900$.
Exactitude $= \frac{25+900}{1000} = 92.5\%$ — élevée, mais trompeuse (§14.3) : un modèle prédisant systématiquement « non-défaut » afficherait déjà 96% d'exactitude sans aucune valeur prédictive.
Précision $= \frac{25}{25+60} = 29.4\%$: sur 100 alertes de défaut émises, seules 29 sont fondées.
Rappel $= \frac{25}{25+15} = 62.5\%$: le modèle détecte 62.5% des défauts réels, en manque 37.5%.
$F_1 = 2 \times \frac{0.294 \times 0.625}{0.294 + 0.625} = 0.40$.
En abaissant le seuil à $s = 0.3$, on obtient typiquement VP$= 33$, FN$= 7$, FP$= 140$, VN$= 820$: rappel $= 33/40 = 82.5\%$ (nette amélioration de la détection), mais précision $= 33/173 = 19.1\%$ (davantage de fausses alertes) — l'arbitrage précision/rappel se lit directement dans ce déplacement.

15.7 --- Courbe ROC, AUC et choix de seuil

Une vision globale de la performance de classification, indépendante d'un seuil particulier.

Courbe ROC

La courbe **ROC** (*Receiver Operating Characteristic*) trace le **taux de vrais positifs** (rappel/sensibilité) en fonction du **taux de faux positifs** (1−spécificité), pour **tous les seuils** $s \in [0, 1]$ possibles.

Aire sous la courbe (AUC)

AUC $\in [0, 1]$: AUC $= 0.5 \Rightarrow$ discrimination aléatoire (pas mieux qu'un tirage), AUC $= 1 \Rightarrow$ discrimination parfaite

Interprétation probabiliste de l'AUC

L'AUC admet une interprétation intuitive : c'est la probabilité que, tirant au hasard une observation positive (en défaut) et une négative (saine), le modèle attribue une probabilité prédite **plus élevée** à l'observation positive. Une AUC de 0.85 signifie que, dans 85% des paires aléatoires (une contrepartie en défaut, une saine), le modèle classe correctement la contrepartie en défaut comme plus risquée.

Pourquoi l'AUC est préférable à l'exactitude sur classes déséquilibrées

L'AUC évalue la capacité de discrimination du modèle **à travers tous les seuils**, sans dépendre d'un seuil arbitraire ni de la prévalence de la classe positive — contrairement à l'exactitude, dont la valeur de référence dépend directement du déséquilibre des classes (rappel §14.3, cas 57). C'est pourquoi l'AUC domine comme métrique de comparaison **entre modèles**, la matrice de confusion à un seuil donné restant l'outil privilégié pour évaluer une **décision opérationnelle** précise.

Choisir un seuil à partir de la courbe ROC

En pratique, un point de la courbe ROC est sélectionné selon le **coût relatif** des deux erreurs (§15.6) : si un faux négatif (défaut manqué) coûte cinq fois plus qu'un faux positif (client refusé à tort), on privilégie un point de la courbe à taux de vrais positifs élevé, quitte à accepter un taux de faux positifs plus élevé — une décision **métier**, non purement statistique.

15.8 --- Réseaux de neurones : architecture, perceptron et fonctions d'activation

Au-delà d'une seule transformation logistique, empiler plusieurs couches de transformations non linéaires pour capturer des relations plus riches.

Perceptron --- unité de base

Un **perceptron** (neurone artificiel) calcule une combinaison linéaire pondérée de ses entrées, puis applique une **fonction d'activation** g non linéaire : $a = g(w_0 + w_1 x_1 + \cdots + w_p x_p) = g(z)$. Un neurone logistique (§15.3) est un perceptron dont g est la fonction sigmoïde.

Réseau de neurones *feedforward*

Un **réseau de neurones** organise des perceptrons en **couches** : une couche d'**entrée** (les variables x), une ou plusieurs couches **cachées** (chacune transformant la sortie de la précédente), et une couche de **sortie** (la prédiction finale). L'information circule dans un sens (entrée $\rightarrow$ sorties), d'où le terme *feedforward*.

Fonctions d'activation usuelles

$$\text{Sigmoïde : } g(z) = \frac{1}{1+e^{-z}} \in (0,1), \qquad \text{ReLU : } g(z) = \max(0,z), \qquad \tanh(z) = \frac{e^{z}-e^{-z}}{e^{z}+e^{-z}} \in (-1,1).$$

Pourquoi une fonction d'activation non linéaire est indispensable

Si chaque couche appliquait une transformation purement **linéaire** (sans fonction g non linéaire), empiler plusieurs couches resterait mathématiquement équivalent à une **unique** couche linéaire (la composition de transformations linéaires est linéaire) — tout le bénéfice de la profondeur s'effondrerait. C'est la non-linéarité de g (sigmoïde, ReLU, tanh) qui permet à un réseau multicouche de représenter des relations bien plus riches qu'une régression logistique à une seule couche.

ReLU : le choix dominant en pratique

La fonction **ReLU** (*Rectified Linear Unit*, $g(z) = \max(0, z)$) domine en pratique pour les couches cachées des réseaux profonds : simple à calculer, sa dérivée constante (1 ou 0) évite le problème de **gradient qui s'évanouit** (*vanishing gradient*) que la sigmoïde et la tanh peuvent provoquer dans les réseaux profonds, où des dérivées proches de zéro se multiplient à travers de nombreuses couches lors de la rétropropagation (§15.9). La couche de **sortie**, elle, conserve souvent une sigmoïde en classification binaire, pour produire une probabilité bornée dans $(0, 1)$.

Un réseau à une couche cachée = une régression logistique généralisée

Un réseau de neurones avec **zéro** couche cachée et une activation sigmoïde en sortie est **exactement** une régression logistique (§15.3) : c'est le cas le plus simple d'un réseau. Ajouter une couche cachée transforme d'abord les variables x en une représentation intermédiaire non linéaire, puis applique la régression logistique sur cette représentation — le réseau **apprend ses propres variables dérivées**, plutôt que de dépendre de variables construites manuellement par l'analyste.

15.9 --- Entraîner un réseau de neurones : fonction de perte et rétropropagation

Comment les poids w d'un réseau de neurones sont-ils appris à partir des données.

Fonction de perte

La **fonction de perte** (*loss function*) mesure l'écart entre la prédiction du réseau et la cible réelle sur l'ensemble d'entraînement. En classification binaire, on utilise typiquement l'**entropie croisée** (*cross-entropy*), l'analogue direct de la log-vraisemblance négative de la régression logistique (§15.4) :

$$\mathcal{L} = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \ln \hat{P}_i + (1 - y_i)\ln(1 - \hat{P}_i)\right].$$

Descente de gradient

La **descente de gradient** ajuste itérativement chaque poids w dans la direction qui réduit le plus la perte : $w \leftarrow w - \eta\dfrac{\partial \mathcal{L}}{\partial w}$, où η est le **taux d'apprentissage** (*learning rate*, à ne pas confondre avec le ν du boosting, §14.9, bien que le rôle soit analogue).

Rétropropagation : calculer efficacement le gradient

La **rétropropagation** (*backpropagation*) est l'algorithme qui calcule efficacement $\partial\mathcal{L}/\partial w$ pour **chaque** poids du réseau, y compris ceux des couches cachées profondément enfouies, en propageant l'erreur de la sortie vers l'entrée via la **règle de dérivation en chaîne** (*chain rule*). Sans cette technique, calculer le gradient d'un réseau à des millions de paramètres serait numériquement intraitable ; la rétropropagation le rend praticable en un nombre d'opérations proportionnel à la taille du réseau.

Le rôle du taux d'apprentissage η

Un η **trop grand** fait « sauter » l'optimisation au-delà du minimum de la fonction de perte, empêchant la convergence (voire la faisant diverger) ; un η **trop petit** converge très lentement, nécessitant un nombre d'itérations prohibitif. Comme pour le taux d'apprentissage du boosting (§14.9), η est calibré par validation croisée (§14.3), souvent avec un **taux décroissant** au fil de l'entraînement (grands pas au début, pas fins en fin d'optimisation, à l'approche du minimum).

Surapprentissage et régularisation d'un réseau de neurones

Un réseau de neurones, avec potentiellement des millions de paramètres, est un candidat naturel au **surapprentissage** (§14.2). Les remèdes incluent : l'**arrêt anticipé** (*early stopping*, §14.9), le **dropout** (désactivation aléatoire d'une fraction des neurones à chaque itération d'entraînement, forçant le réseau à ne pas dépendre excessivement d'un neurone particulier), et une régularisation ℓ_1/ℓ_2 directement sur les poids — exactement l'esprit de Ridge/Lasso (§14.4-14.5), appliqué aux poids du réseau plutôt qu'aux coefficients d'une régression.

15.10 --- Régression logistique vs réseaux de neurones : comparaison, applications et synthèse

Retour d'ensemble sur le chapitre : quand préférer un modèle simple, quand investir dans un réseau de neurones.

Comparaison directe

La **régression logistique** offre une interprétabilité directe (odds ratios, §15.4), une estimation rapide, un risque de surapprentissage limité sur des jeux de données de taille modeste, et une robustesse réglementaire éprouvée (utilisée en scoring de crédit depuis des décennies). Les **réseaux de neurones** offrent une flexibilité représentationnelle bien supérieure (relations non linéaires complexes, interactions automatiquement apprises), au prix d'une interprétabilité quasi nulle, d'un besoin de données bien plus important pour éviter le surapprentissage, et d'une calibration plus délicate (architecture, taux d'apprentissage, régularisation).

Quand un réseau de neurones surpasse-t-il la régression logistique

Le gain d'un réseau de neurones sur une régression logistique est **le plus net** quand (i) le volume de données est important (des milliers à millions d'observations), (ii) la relation sous-jacente comporte des **interactions non linéaires complexes** entre de nombreuses variables (ex. données textuelles, images, séries temporelles à haute fréquence), et (iii) l'interprétabilité directe n'est pas une contrainte réglementaire bloquante. Sur un scoring de crédit classique à quelques dizaines de variables tabulaires, l'écart de performance entre une régression logistique bien régularisée et un réseau de neurones est souvent **modeste**, ne justifiant pas toujours la perte d'interprétabilité.

Applications en gestion des risques

Au-delà du scoring de crédit, la régression logistique et les réseaux de neurones se retrouvent dans : la **détection de fraude** (transactions atypiques, souvent avec des réseaux de neurones sur des volumes massifs de transactions) ; la **prédiction de défaut de contrepartie** en risque de crédit ; le **trading algorithmique** (prédiction de direction de marché à très court terme) ; et l'**analyse de sentiment** sur des données textuelles (rapports financiers, actualités) pour anticiper des mouvements de marché.

Synthèse et lien avec le chapitre 14

Ce chapitre complète directement la boîte à outils du chapitre 14 : là où le chapitre 14 couvrait la régularisation, les arbres, les ensembles et le non supervisé, ce chapitre approfondit le modèle de prédiction **binaire** le plus utilisé (régression logistique) et son extension non linéaire (réseaux de neurones), avec l'appareil d'**évaluation** (matrice de confusion, ROC/AUC) qui s'applique à **tous** les modèles de classification rencontrés jusqu'ici — arbres, forêts, boosting compris. Le fil rouge reste le même : équilibrer flexibilité représentationnelle, interprétabilité et risque de surapprentissage, selon le contexte métier et réglementaire.

Partie B --- 200 études de cas pratiques

Chaque cas propose une question ciblée et une solution détaillée, couvrant l'ensemble des dix thèmes du cours. Travaillez crayon en main : cachez la solution, résolvez, comparez.

Bloc 1 --- Le rôle de la régression en prédiction

Cas 1 — Régression en prédiction, différence avec l'inférence. Quelle est la différence entre usage prédictif et usage inférentiel de la régression ?

Solution. L'usage prédictif priorise la qualité de $\widehat{y}$ sur de **nouvelles** données ; l'usage inférentiel priorise la **significativité** des coefficients.

Cas 2 — Limite de la régression linéaire pour une cible binaire. Pourquoi une régression linéaire directe sur $y \in \{0, 1\}$ pose-t-elle problème ?

Solution. Elle peut produire des prédictions **hors de** $[0, 1]$, incohérentes pour une probabilité.

Cas 3 — Modèle de probabilité linéaire, définition. Qu'est-ce que le modèle de probabilité linéaire ?

Solution. Une régression linéaire appliquée **directement** à une cible binaire, sans transformation logistique.

Cas 4 — Avantage du modèle de probabilité linéaire. Quel est l'avantage principal du modèle de probabilité linéaire ?

Solution. Une interprétation directe : chaque $\widehat{\beta}_j$ est un **effet marginal constant** sur la probabilité.

Cas 5 — Limite structurelle du modèle de probabilité linéaire. Quelle propriété statistique du modèle de probabilité linéaire est structurellement problématique ?

Solution. Une **hétéroscédasticité** intrinsèque : la variance de y dépend de sa moyenne pour une variable binaire.

Cas 6 — Motivation de la régression logistique. Que résout la régression logistique par rapport au modèle de probabilité linéaire ?

Solution. Elle **borne** la prédiction entre 0 et 1 via la fonction sigmoïde.

Cas 7 — Régression et prédiction continue. Quel type de cible la régression linéaire prédit-elle nativement ?

Solution. Une cible **continue**.

Cas 8 — Exemples de cibles binaires en gestion des risques. Citer deux exemples de cibles binaires typiques en gestion des risques.

Solution. **Défaut/non-défaut**, **fraude/non-fraude**.

Cas 9 — Relation linéaire sur tout le domaine. La relation entre variables explicatives et probabilité d'un événement est-elle généralement linéaire sur tout le domaine ?

Solution. **Non**, rarement : la probabilité doit rester bornée, ce qu'une droite ne garantit pas.

Cas 10 — Rapidité du modèle de probabilité linéaire. Pourquoi le modèle de probabilité linéaire reste-t-il parfois utilisé malgré ses limites ?

Solution. Pour sa **simplicité** d'interprétation et sa **rapidité** de calcul.

Cas 11 — Passage du continu au catégoriel. Quel changement conceptuel majeur la régression logistique introduit-elle par rapport à la régression linéaire ?

Solution. Le passage d'une prédiction **numérique continue** à une **probabilité** d'appartenance à une catégorie.

Cas 12 — Cible catégorielle : marché à la hausse ou à la baisse. Un modèle prédisant si un marché va monter ou baisser relève de quel type de régression ?

Solution. La **régression logistique** (cible binaire).

Cas 13 — Coefficient constant vs variable. En régression linéaire, l'effet marginal d'une variable est-il constant ?

Solution. **Oui**, par construction (modèle linéaire).

Cas 14 — Simplicité comme argument de transition. Pourquoi le chapitre présente-t-il la régression logistique comme un prolongement « en douceur » de la régression linéaire ?

Solution. Même structure linéaire sous-jacente ($z = \beta_0 + \dots$), seulement **transformée** pour produire une probabilité.

Cas 15 — Nouvelle observation, régression prédictive. Pourquoi l'usage prédictif de la régression insiste-t-il sur la validation croisée ?

Solution. Car la qualité recherchée est la performance sur des données **nouvelles**, non vues à l'entraînement.

Cas 16 — Modèle prédictif vs modèle causal. Un modèle de prédiction cherche-t-il nécessairement à établir une relation causale ?

Solution. **Non**, il cherche la meilleure prédiction, indépendamment de la causalité.

Cas 17 — Réseaux de neurones, prolongement. Que prolongent les réseaux de neurones par rapport à la régression logistique ?

Solution. Ils empilent plusieurs transformations non linéaires pour capturer des relations plus **complexes**.

Cas 18 — Deux piliers du chapitre 15. Quels sont les deux piliers de prédiction supervisée présentés dans ce chapitre ?

Solution. La **régression logistique** et les **réseaux de neurones**.

Cas 19 — Détour nécessaire du chapitre. Quel détour méthodologique le chapitre introduit-il entre régression logistique et réseaux de neurones ?

Solution. L'**encodage** des variables catégorielles et l'**évaluation** via matrice de confusion.

Cas 20 — Synthèse du Bloc 1. Résumer en une phrase la transition centrale de ce chapitre.

Solution. Passer de la prédiction d'un **nombre** à la prédiction d'une **catégorie**.

Bloc 2 --- Encodage des variables catégorielles

Cas 21 — Encodage dummy, définition. Comment une variable catégorielle à C catégories est-elle encodée en variables indicatrices ?

Solution. Par $C - 1$ **variables binaires** $(0/1)$, la catégorie omise servant de référence.

Cas 22 — Pourquoi $C - 1$ et non C. Pourquoi utilise-t-on $C - 1$ indicatrices plutôt que C ?

Solution. Pour éviter la **colinéarité parfaite** avec la constante (somme des C indicatrices toujours égale à 1).

Cas 23 — Trappe des variables indicatrices. Qu'est-ce que la « trappe des variables indicatrices » (*dummy variable trap*) ?

Solution. Inclure les C indicatrices **et** la constante, rendant $X^\top X$ non inversible.

Cas 24 — Catégorie de référence. Que représente la catégorie omise dans un encodage dummy ?

Solution. La **référence**, absorbée dans la constante β_0.

Cas 25 — Interprétation des coefficients dummy. Comment s'interprète le coefficient d'une variable indicatrice ?

Solution. Comme un **écart par rapport à la catégorie de référence**.

Cas 26 — Encodage one-hot, définition. Qu'est-ce que l'encodage one-hot ?

Solution. Une colonne binaire **par catégorie** (C colonnes), sans suppression de référence.

Cas 27 — One-hot vs dummy : quel modèle pour quel encodage. Quel encodage convient aux arbres et forêts, insensibles à la colinéarité parfaite ?

Solution. L'encodage **one-hot** (ou même l'encodage catégoriel natif, §14.7).

Cas 28 — One-hot vs dummy en régression. Quel encodage est la convention en régression (linéaire ou logistique) ?

Solution. L'encodage **dummy** ($C-1$ colonnes, référence omise).

Cas 29 — Choix de la référence, effet sur les prédictions. Le choix de la catégorie de référence change-t-il les prédictions du modèle ?

Solution. **Non**, les prédictions sont identiques quel que soit ce choix.

Cas 30 — Choix de la référence, effet sur l'interprétation. Le choix de la catégorie de référence change-t-il l'interprétation des coefficients ?

Solution. **Oui** : les coefficients se lisent par rapport à la référence choisie.

Cas 31 — Bon choix de référence. Quel critère pratique guide un bon choix de catégorie de référence ?

Solution. La catégorie la plus **fréquente** ou la plus « normale » d'un point de vue métier.

Cas 32 — Exemple sectoriel. Pour des indicatrices de secteur d'activité, quelle référence facilite souvent la lecture économique ?

Solution. Le **secteur non cyclique**, comme point de comparaison naturel.

Cas 33 — Notation comme variable catégorielle. Une notation de crédit (AAA, AA, A, ...) doit-elle être encodée avant modélisation ?

Solution. **Oui**, sauf si elle est traitée comme une échelle ordinale numérique explicite.

Cas 34 — Colinéarité parfaite et inversibilité. Que se passe-t-il pour $X^\top X$ en cas de trappe des variables indicatrices ?

Solution. Elle devient **non inversible** (singulière).

Cas 35 — Encodage et arbres de décision. Les arbres de décision nécessitent-ils un encodage dummy strict ?

Solution. **Non**, ils gèrent nativement les catégories (rappel §14.7).

Cas 36 — Pays comme variable catégorielle. Comment encoder une variable « pays » à 12 modalités pour une régression logistique ?

Solution. Par **11 indicatrices** dummy, un pays servant de référence.

Cas 37 — Encodage et régularisation. L'encodage dummy affecte-t-il la façon dont Ridge/Lasso pénalisent les coefficients ?

Solution. **Oui**, indirectement : chaque indicatrice reçoit sa propre pénalité, comme toute autre variable.

Cas 38 — Nombre de colonnes après encodage dummy. Une variable à 5 catégories produit combien de colonnes en encodage dummy ?

Solution. **4** colonnes ($C-1$).

Cas 39 — One-hot et colinéarité. L'encodage one-hot pose-t-il un problème de colinéarité parfaite pour un modèle sans constante ?

Solution. **Généralement non**, tant qu'il n'y a pas de terme constant séparé additionné aux C colonnes.

Cas 40 — Synthèse du Bloc 2. Résumer en une phrase l'enjeu de l'encodage catégoriel.

Solution. Transformer une catégorie en variables **numériques** exploitables, sans introduire de colinéarité parasite.

Bloc 3 --- La régression logistique : modèle, sigmoïde, odds

Cas 41 — Fonction logistique, formule. Écrire la fonction logistique (sigmoïde).

Solution. $P(y=1 \mid x) = \dfrac{1}{1+e^{-z}}$.

Cas 42 — Fonction logit, formule. Écrire la fonction logit (inverse de la sigmoïde).

Solution. $\text{logit}(p) = \ln\left(\dfrac{p}{1-p}\right) = z$.

Cas 43 — Sigmoïde à $z = 0$. Que vaut P quand $z = 0$?

Solution. $P = 0.5$.

Cas 44 — Sigmoïde quand $z \to +\infty$. Que devient P quand $z \to +\infty$?

Solution. $P \to 1$.

Cas 45 — Sigmoïde quand $z \to -\infty$. Que devient P quand $z \to -\infty$?

Solution. $P \to 0$.

Cas 46 — Odds, définition. Comment définit-on les odds (cote) d'un événement de probabilité p ?

Solution. $\text{odds} = \dfrac{p}{1-p}$.

Cas 47 — Odds pour p=0.75. Quelles sont les odds pour $p = 0.75$?

Solution. $\text{odds} = 0.75/0.25 = 3$ (« 3 contre 1 »).

Cas 48 — Logit, définition. Qu'est-ce que le logit ?

Solution. Le **logarithme des odds**, $\ln(p/(1-p))$.

Cas 49 — Ce que modélise linéairement la régression logistique. Quelle quantité la régression logistique modélise-t-elle linéairement ?

Solution. Le **logit** de p, pas p directement.

Cas 50 — Sigmoïde et fonction croissante. La fonction sigmoïde est-elle strictement croissante en z ?

Solution. **Oui**, sa dérivée $P(1-P)$ est strictement positive.

Cas 51 — Effet marginal en régression logistique. L'effet marginal $\partial P/\partial x_j$ est-il constant en régression logistique ?

Solution. **Non**, il dépend du point : $\partial P/\partial x_j = \beta_j P(1-P)$.

Cas 52 — Effet marginal maximal. Pour quelle valeur de P l'effet marginal est-il maximal ?

Solution. $P = 0.5$.

Cas 53 — Effet marginal proche des extrêmes. L'effet marginal est-il fort ou faible quand P est proche de 0 ou 1 ?

Solution. **Faible** (quasi nul).

Cas 54 — Correspondance bijective. La fonction logistique établit-elle une correspondance bijective entre $z \in \mathbb{R}$ et $P \in (0,1)$?

Solution. **Oui**.

Cas 55 — Origine de la construction logistique. D'où découle la construction de la fonction logistique ?

Solution. De la modélisation **linéaire du logit**, puis de l'inversion de cette relation.

Cas 56 — Odds ratio =1. Que signifie un odds ratio égal à 1 ?

Solution. **Aucun effet** de la variable sur l'événement.

Cas 57 — Odds ratio >1. Que signifie un odds ratio supérieur à 1 ?

Solution. Un effet qui **augmente** la probabilité de l'événement.

Cas 58 — Sigmoïde, bornes garanties. La sigmoïde garantit-elle des prédictions toujours dans $[0,1]$?

Solution. **Oui**, par construction mathématique.

Cas 59 — Sigmoïde vs droite. Pourquoi une droite ne peut-elle pas garantir cette propriété de bornage ?

Solution. Une fonction linéaire n'est **pas bornée**, elle diverge vers $\pm\infty$.

Cas 60 — Synthèse du Bloc 3. Résumer en une phrase le principe de la régression logistique.

Solution. Modéliser **linéairement le logit** d'une probabilité, puis inverser via la sigmoïde pour obtenir une probabilité bornée.

Bloc 4 --- Estimation par MLE et interprétation

Cas 61 — MLE, principe. Sur quel principe repose l'estimation des coefficients de la régression logistique ?

Solution. Le **maximum de vraisemblance** (MLE).

Cas 62 — MLE, objectif. Que maximise le maximum de vraisemblance ?

Solution. La probabilité (vraisemblance) d'observer l'**échantillon effectivement obtenu**.

Cas 63 — Solution fermée MLE logistique. La régression logistique a-t-elle une solution fermée comme les MCO ?

Solution. **Non**, la non-linéarité de la sigmoïde l'empêche.

Cas 64 — Méthode d'estimation numérique. Comment sont estimés les coefficients de la régression logistique en pratique ?

Solution. Par **optimisation numérique itérative** (ex. Newton-Raphson, descente de gradient).

Cas 65 — Lien avec les réseaux de neurones. Quel pont conceptuel l'estimation MLE de la logistique établit-elle avec les réseaux de neurones ?

Solution. Le même principe d'**optimisation itérative** sous-tend l'entraînement des réseaux de neurones (§15.9).

Cas 66 — Odds ratio, calcul. Comment calcule-t-on l'odds ratio associé à un coefficient β_j ?

Solution. e^{β_j}.

Cas 67 — Interprétation odds ratio = 1.5. Que signifie un odds ratio de 1.5 pour une variable x_j ?

Solution. Les odds de l'événement sont **multipliées par 1.5** pour chaque unité supplémentaire de x_j.

Cas 68 — Odds ratio <1. Que signifie un odds ratio inférieur à 1 ?

Solution. Un effet qui **diminue** la probabilité de l'événement.

Cas 69 — Log-vraisemblance, formule. Écrire la log-vraisemblance de la régression logistique.

Solution. $\ell(\beta) = \sum_i \{y_i \ln P_i + (1 - y_i) \ln(1 - P_i)\}$.

Cas 70 — Coefficient positif, effet. Un coefficient $\hat{\beta}_j > 0$ a quel effet sur la probabilité de l'événement ?

Solution. Il **augmente** la probabilité quand x_j augmente.

Cas 71 — Coefficient négatif, effet. Un coefficient $\hat{\beta}_j < 0$ a quel effet sur la probabilité de l'événement ?

Solution. Il **diminue** la probabilité quand x_j augmente.

Cas 72 — Odds ratio pour $\beta_j = 0$. Que vaut l'odds ratio quand $\beta_j = 0$?

Solution. $e^0 = 1$ (aucun effet).

Cas 73 — Application : endettement, odds ratio de 2.27. Un odds ratio d'endettement de 2.27 signifie quoi concrètement ?

Solution. Une hausse d'un écart-type de l'endettement **multiplie par 2.27** les odds de défaut.

Cas 74 — Application : liquidité, odds ratio de 0.577. Un odds ratio de liquidité de 0.577 signifie quoi concrètement ?

Solution. Une hausse d'un écart-type de liquidité **divise les odds de défaut** par environ 1.73.

Cas 75 — MLE et grands échantillons. Le MLE nécessite-t-il généralement de grands échantillons pour une estimation stable ?

Solution. **Oui**, ses propriétés asymptotiques (consistance, normalité) s'appliquent surtout en grand échantillon.

Cas 76 — Cohérence MLE et loi normale des coefficients. Sous MLE, quelle est la distribution asymptotique des coefficients estimés ?

Solution. Approximativement **normale** (rappel chapitre 5), permettant des tests de significativité classiques.

Cas 77 — Interprétation vs prédiction. L'odds ratio sert-il davantage à l'interprétation ou à la prédiction pure ?

Solution. À l'**interprétation** économique ; la prédiction utilise directement $\hat{P}(y = 1 \mid x)$.

Cas 78 — Coefficient standardisé. Pourquoi standardiser les variables avant de comparer des odds ratios entre elles ?

Solution. Pour rendre les coefficients **comparables** sur une échelle commune (écart-type).

Cas 79 — MLE, itérations. L'algorithme d'optimisation MLE converge-t-il en une seule étape ?

Solution. **Non**, il itère jusqu'à convergence (contrairement à la solution fermée des MCO).

Cas 80 — Synthèse du Bloc 4. Résumer en une phrase comment interpréter un coefficient de régression logistique.

Solution. Via son **odds ratio** e^{β_j}, l'effet multiplicatif sur les odds de l'événement.

Bloc 5 --- Régularisation appliquée à la régression logistique

Cas 81 — Régularisation Ridge logistique, objectif. Écrire l'objectif de la régression logistique régularisée Ridge.

Solution. $\max_\beta \{\ell(\beta) - \lambda \sum \beta_j^2\}$.

Cas 82 — Régularisation Lasso logistique, objectif. Écrire l'objectif de la régression logistique régularisée Lasso.

Solution. $\max_\beta \{\ell(\beta) - \lambda \sum |\beta_j|\}$.

Cas 83 — Différence technique avec le chapitre 14. Quelle est la seule différence technique entre la régularisation de régression linéaire et logistique ?

Solution. La pénalité s'applique à la **log-vraisemblance** plutôt qu'à la somme des carrés résiduels.

Cas 84 — Intuition géométrique conservée. L'intuition géométrique (cercle Ridge, losange Lasso) reste-t-elle valable en logistique régularisée ?

Solution. **Oui**, identique à celle du chapitre 14.

Cas 85 — Pourquoi régulariser un scoring de défaut. Pourquoi un modèle de scoring de défaut à 80 variables bénéficie-t-il de la régularisation ?

Solution. Les variables sont souvent **corrélées** ; Ridge stabilise, Lasso sélectionne.

Cas 86 — Lasso logistique et sélection. Le Lasso logistique peut-il annuler exactement des coefficients ?

Solution. **Oui**, exactement comme en régression linéaire (§14.5).

Cas 87 — Standardisation en logistique régularisée. La standardisation est-elle nécessaire avant régularisation logistique ?

Solution. **Oui**, indispensable, pour les mêmes raisons qu'en régression linéaire régularisée.

Cas 88 — Choix de λ en logistique régularisée. Comment choisit-on λ pour une régression logistique régularisée ?

Solution. Par **validation croisée**, en maximisant une métrique adaptée (ex. AUC).

Cas 89 — Ridge logistique et multicolinéarité. Ridge logistique est-il utile en présence de variables macro fortement corrélées ?

Solution. **Oui**, il stabilise les coefficients exactement comme en régression linéaire.

Cas 90 — Elastic Net logistique. L'Elastic Net s'applique-t-il aussi à la régression logistique ?

Solution. **Oui**, la même combinaison ℓ_1/ℓ_2 s'applique à la log-vraisemblance pénalisée.

Cas 91 — Régularisation et interprétabilité en scoring. La régularisation Lasso améliore-t-elle l'interprétabilité d'un modèle de scoring ?

Solution. **Oui**, en réduisant le nombre de variables actives dans le modèle final.

Cas 92 — $\lambda = 0$ en logistique régularisée. Que devient la régression logistique régularisée quand $\lambda = 0$?

Solution. Elle coïncide avec la régression logistique **classique** (MLE non pénalisé).

Cas 93 — Risque de non convergence en petit échantillon. Un modèle logistique sur peu d'observations et beaucoup de variables risque-t-il un problème particulier ?

Solution. **Oui**, une possible **séparation parfaite** des classes, rendant le MLE non pénalisé instable ou divergent — la régularisation aide à stabiliser l'estimation.

Cas 94 — Séparation parfaite, définition. Qu'est-ce que la séparation parfaite en régression logistique ?

Solution. Une situation où une combinaison des variables prédit **parfaitement** la classe, faisant diverger les coefficients MLE non régularisés.

Cas 95 — Régularisation comme remède à la séparation parfaite. Comment la régularisation aide-t-elle face à la séparation parfaite ?

Solution. Elle **borne** les coefficients, empêchant leur divergence vers l'infini.

Cas 96 — Grille de λ typique. Comment est généralement construite la grille de λ testée en validation croisée ?

Solution. Une grille **logarithmique** (ex. 10^{-3} à 10^{2}), pour couvrir plusieurs ordres de grandeur.

Cas 97 — Application : Lasso logistique en scoring PME. Sur 60 variables candidates pour un scoring PME, quelle méthode privilégier pour un modèle parcimonieux et interprétable ?

Solution. Le **Lasso logistique** (ou Elastic Net si forte colinéarité).

Cas 98 — Comparaison Ridge vs Lasso en contexte logistique. La différence Ridge/Lasso (rétrécissement vs sélection) est-elle préservée en contexte logistique ?

Solution. **Oui**, intégralement.

Cas 99 — Régularisation et validation croisée conjointes. Peut-on calibrer λ ET le seuil de décision simultanément par validation croisée ?

Solution. **Oui**, en pratique on optimise souvent λ sur une métrique indépendante du seuil (ex. AUC), puis le seuil séparément selon les coûts métier.

Cas 100 — Synthèse du Bloc 5. Résumer en une phrase l'apport de la régularisation en régression logistique.

Solution. Stabiliser (Ridge) ou sélectionner (Lasso) les coefficients d'un modèle de classification, exactement comme en régression linéaire.

Bloc 6 --- Matrice de confusion et métriques de classification

Cas 101 — Matrice de confusion, définition. Que croise la matrice de confusion ?

Solution. Les classes **prédites** (après seuil) et les classes **réelles**.

Cas 102 — Les quatre cellules. Citer les quatre cellules de la matrice de confusion en classification binaire.

Solution. **Vrais positifs, faux positifs, vrais négatifs, faux négatifs**.

Cas 103 — Exactitude, formule. Écrire la formule de l'exactitude (accuracy).

Solution. $(VP + VN)/(VP + VN + FP + FN)$.

Cas 104 — Précision, formule. Écrire la formule de la précision.

Solution. $VP/(VP + FP)$.

Cas 105 — Rappel, formule. Écrire la formule du rappel (sensibilité).

Solution. $VP/(VP + FN)$.

Cas 106 — F1, formule. Écrire la formule du score F_1.

Solution. $2 \times \dfrac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$ (moyenne harmonique).

Cas 107 — Précision, question répondue. À quelle question répond la précision ?

Solution. « Parmi les prédictions positives, combien sont **réellement** positives ? »

Cas 108 — Rappel, question répondue. À quelle question répond le rappel ?

Solution. « Parmi les positifs réels, combien le modèle en a-t-il **détecté** ? »

Cas 109 — Précision cruciale, exemple. Dans quel contexte la précision est-elle particulièrement cruciale ?

Solution. Quand une **fausse alerte** est coûteuse (ex. refuser un bon client).

Cas 110 — Rappel crucial, exemple. Dans quel contexte le rappel est-il particulièrement crucial ?

Solution. Quand **manquer un vrai positif** est coûteux (ex. défaut non détecté).

Cas 111 — Précision et rappel, tension. Précision et rappel évoluent-ils toujours dans le même sens quand le seuil change ?

Solution. **Non**, ils sont généralement en **tension**.

Cas 112 — Effet d'un seuil abaissé sur le rappel. Abaisser le seuil de décision a quel effet sur le rappel ?

Solution. Il **augmente** (moins de faux négatifs).

Cas 113 — Effet d'un seuil abaissé sur la précision. Abaisser le seuil de décision a quel effet typique sur la précision ?

Solution. Elle **diminue** typiquement (plus de faux positifs).

Cas 114 — Seuil par défaut. Quel seuil de décision est utilisé par défaut, sauf choix explicite ?

Solution. $s = 0.5$.

Cas 115 — Seuil, nature du choix. Le seuil de décision est-il une donnée du modèle ou un choix de l'analyste ?

Solution. Un **choix**, dépendant du coût relatif des erreurs.

Cas 116 — Exactitude trompeuse, rappel. Pourquoi l'exactitude seule est-elle trompeuse sur des classes déséquilibrées ?

Solution. Un modèle prédisant toujours la classe majoritaire affiche une exactitude élevée **sans valeur prédictive** (rappel §14.3).

Cas 117 — Seuil bas pour la fraude. Pourquoi privilégier un seuil bas en détection de fraude ?

Solution. Car **rater une fraude** (faux négatif) coûte cher — on privilégie le rappel.

Cas 118 — F1 comme compromis. Quand privilégier le score F_1 plutôt que précision ou rappel isolément ?

Solution. Quand **aucune** des deux erreurs n'est a priori plus coûteuse que l'autre.

Cas 119 — Calcul de précision sur un exemple. Avec VP=25 et FP=60, quelle est la précision ?

Solution. $25/(25 + 60) = 29.4\%$.

Cas 120 — Synthèse du Bloc 6. Résumer en une phrase pourquoi la matrice de confusion est indispensable.

Solution. Elle révèle des **informations** (précision, rappel) que l'exactitude seule masque, surtout sur classes déséquilibrées.

Bloc 7 --- Courbe ROC, AUC et choix de seuil

Cas 121 — Courbe ROC, définition. Que trace la courbe ROC ?

Solution. Le **taux de vrais positifs** en fonction du **taux de faux positifs**, pour tous les seuils.

Cas 122 — AUC, borne inférieure. Quelle est la valeur minimale théorique typique de l'AUC pour un modèle informatif ?

Solution. 0.5 (discrimination aléatoire).

Cas 123 — AUC parfaite. Que signifie une AUC de 1 ?

Solution. Une **discrimination parfaite** entre les deux classes.

Cas 124 — Interprétation probabiliste de l'AUC. Comment interpréter probabilistiquement une AUC de 0.85 ?

Solution. Dans 85% des paires aléatoires (un positif, un négatif), le modèle attribue une probabilité plus élevée au **positif**.

Cas 125 — AUC indépendante du seuil. L'AUC dépend-elle d'un seuil de décision particulier ?

Solution. **Non**, elle évalue la performance à travers **tous** les seuils.

Cas 126 — AUC et prévalence. L'AUC dépend-elle de la prévalence de la classe positive ?

Solution. **Non**, contrairement à l'exactitude.

Cas 127 — AUC pour comparer des modèles. L'AUC est-elle privilégiée pour comparer des modèles ou pour évaluer une décision opérationnelle ?

Solution. Pour **comparer des modèles** entre eux.

Cas 128 — Matrice de confusion pour décision opérationnelle. Quel outil est privilégié pour évaluer une décision opérationnelle à un seuil donné ?

Solution. La **matrice de confusion**.

Cas 129 — Choix d'un point sur la courbe ROC. Sur quel critère choisit-on un point précis de la courbe ROC en pratique ?

Solution. Le **coût relatif** des deux types d'erreur dans le contexte métier.

Cas 130 — Coût asymétrique, exemple. Si un faux négatif coûte 5 fois plus qu'un faux positif, quel type de point privilégier sur la courbe ROC ?

Solution. Un point à **taux de vrais positifs élevé**, quitte à accepter plus de faux positifs.

Cas 131 — ROC, axe des abscisses. Que représente l'axe des abscisses de la courbe ROC ?

Solution. Le **taux de faux positifs** (1−spécificité).

Cas 132 — ROC, axe des ordonnées. Que représente l'axe des ordonnées de la courbe ROC ?

Solution. Le **taux de vrais positifs** (rappel/sensibilité).

Cas 133 — ROC d'un modèle aléatoire. À quoi ressemble la courbe ROC d'un modèle sans aucun pouvoir discriminant ?

Solution. À la **diagonale** (AUC = 0.5).

Cas 134 — AUC et classes déséquilibrées. Pourquoi préfère-t-on l'AUC à l'exactitude sur un portefeuille à 2% de défauts ?

Solution. Car l'exactitude est **biaisée** par le déséquilibre, l'AUC ne l'est pas.

Cas 135 — Décision métier vs statistique. Le choix final du seuil de décision est-il une décision purement statistique ?

Solution. **Non**, c'est une décision **métier**, fondée sur les coûts relatifs des erreurs.

Cas 136 — Comparaison de deux modèles par AUC. Un modèle A (AUC=0.82) et un modèle B (AUC=0.79) : lequel discrimine mieux en général ?

Solution. Le modèle **A**, à travers tous les seuils.

Cas 137 — ROC, robustesse au déséquilibre. La courbe ROC reste-t-elle informative même avec une classe rare ?

Solution. **Oui**, c'est l'un de ses principaux avantages.

Cas 138 — Application : détection de fraude, AUC vs seuil. Pour comparer deux algorithmes candidats de détection de fraude avant déploiement, privilégier :

Solution. L'**AUC**, indépendante du seuil final qui sera choisi en production.

Cas 139 — Application : décision d'octroi, seuil. Pour décider d'octroyer ou non un crédit à un seuil précis, privilégier :

Solution. La **matrice de confusion** au seuil retenu.

Cas 140 — Synthèse du Bloc 7. Résumer en une phrase l'apport de la courbe ROC/AUC.

Solution. Évaluer la capacité de discrimination d'un modèle **indépendamment** d'un seuil ou d'une prévalence particuliers.

Bloc 8 --- Réseaux de neurones : architecture et activation

Cas 141 — Perceptron, définition. Que calcule un perceptron ?

Solution. Une **combinaison linéaire pondérée** des entrées, suivie d'une **fonction d'activation** non linéaire.

Cas 142 — Neurone logistique. Un neurone logistique est un perceptron avec quelle fonction d'activation ?

Solution. La fonction **sigmoïde**.

Cas 143 — Couches d'un réseau feedforward. Citer les trois types de couches d'un réseau de neurones feedforward.

Solution. **Entrée, cachée(s), sortie**.

Cas 144 — Sens de circulation de l'information. Dans quel sens circule l'information dans un réseau feedforward ?

Solution. De l'**entrée vers la sortie**, sans boucle.

Cas 145 — Fonction ReLU, formule. Écrire la formule de la fonction ReLU.

Solution. $g(z) = \max(0, z)$.

Cas 146 — Fonction sigmoïde, plage de valeurs. Quelle est la plage de valeurs de la fonction sigmoïde ?

Solution. $(0, 1)$.

Cas 147 — Fonction tanh, plage de valeurs. Quelle est la plage de valeurs de la fonction tanh ?

Solution. $(-1, 1)$.

Cas 148 — Nécessité de la non-linéarité. Pourquoi une fonction d'activation non linéaire est-elle indispensable dans un réseau multicouche ?

Solution. Sans elle, la composition de couches resterait **équivalente à une seule couche linéaire**.

Cas 149 — Composition de fonctions linéaires. La composition de plusieurs transformations linéaires est-elle linéaire ou non linéaire ?

Solution. **Linéaire**.

Cas 150 — ReLU dominante en pratique. Pourquoi ReLU domine-t-elle en pratique pour les couches cachées ?

Solution. Simple à calculer, elle évite le problème de **gradient qui s'évanouit**.

Cas 151 — Gradient qui s'évanouit, définition. Qu'est-ce que le problème du gradient qui s'évanouit ?

Solution. Des dérivées proches de zéro (sigmoïde, tanh saturées) se **multiplient** à travers de nombreuses couches, rendant le gradient quasi nul.

Cas 152 — Activation de la couche de sortie. Quelle activation est souvent conservée en sortie pour une classification binaire ?

Solution. La **sigmoïde**, pour produire une probabilité bornée.

Cas 153 — Réseau sans couche cachée. Un réseau sans couche cachée et activation sigmoïde en sortie équivaut à quel modèle ?

Solution. Une **régression logistique**.

Cas 154 — Apport d'une couche cachée. Qu'apporte l'ajout d'une couche cachée par rapport à une régression logistique simple ?

Solution. Le réseau **apprend ses propres variables dérivées** (représentation intermédiaire non linéaire).

Cas 155 — Poids d'un réseau. Que représentent les poids w d'un réseau de neurones ?

Solution. Les paramètres ajustables de chaque connexion entre neurones, **analogues** aux coefficients β d'une régression.

Cas 156 — ReLU et neurones morts. Un inconvénient potentiel de ReLU est :

Solution. Le phénomène de **neurones morts** (sortie toujours nulle pour $z < 0$, gradient nul, neurone qui cesse d'apprendre).

Cas 157 — Nombre de couches cachées et flexibilité. Un plus grand nombre de couches cachées augmente-t-il la flexibilité représentationnelle du réseau ?

Solution. **Oui**, généralement, au prix d'un risque accru de surapprentissage.

Cas 158 — Réseau feedforward vs récurrent. Un réseau feedforward comporte-t-il des boucles de rétroaction ?

Solution. **Non**, par définition (contrairement à un réseau récurrent).

Cas 159 — Application : image et texte. Pour quel type de données les réseaux de neurones excellent-ils particulièrement par rapport à la régression logistique ?

Solution. Les données **non tabulaires** (images, texte, séries à haute fréquence).

Cas 160 — Synthèse du Bloc 8. Résumer en une phrase l'architecture d'un réseau de neurones.

Solution. Une succession de couches de perceptrons, chacune appliquant une transformation linéaire puis une **activation non linéaire**.

Bloc 9 --- Entraîner un réseau de neurones

Cas 161 — Fonction de perte, rôle. Que mesure la fonction de perte ?

Solution. L'**écart** entre la prédiction du réseau et la cible réelle.

Cas 162 — Entropie croisée, contexte. Dans quel contexte utilise-t-on l'entropie croisée comme fonction de perte ?

Solution. En **classification** (notamment binaire).

Cas 163 — Entropie croisée et log-vraisemblance. L'entropie croisée est-elle liée à la log-vraisemblance de la régression logistique ?

Solution. **Oui**, c'est son analogue direct (négatif).

Cas 164 — Descente de gradient, principe. Décrire le principe de la descente de gradient.

Solution. Ajuster chaque poids dans la direction qui **réduit le plus** la perte, $w \leftarrow w - \eta\, \partial \mathcal{L}/\partial w$.

Cas 165 — Taux d'apprentissage, rôle. Que contrôle le taux d'apprentissage η ?

Solution. La **taille du pas** à chaque mise à jour des poids.

Cas 166 — η trop grand. Quel est l'effet d'un taux d'apprentissage trop grand ?

Solution. L'optimisation peut **diverger** ou osciller sans converger.

Cas 167 — η trop petit. Quel est l'effet d'un taux d'apprentissage trop petit ?

Solution. Une convergence très **lente**, nécessitant de nombreuses itérations.

Cas 168 — Rétropropagation, rôle. Que calcule l'algorithme de rétropropagation ?

Solution. Le **gradient** de la perte par rapport à chaque poids du réseau, y compris les couches profondes.

Cas 169 — Rétropropagation, méthode. Sur quelle règle mathématique repose la rétropropagation ?

Solution. La **règle de dérivation en chaîne** (*chain rule*).

Cas 170 — Nécessité de la rétropropagation. Pourquoi la rétropropagation est-elle indispensable pour un grand réseau ?

Solution. Sans elle, calculer le gradient de millions de paramètres serait **numériquement intraitable**.

Cas 171 — Taux d'apprentissage décroissant. Pourquoi utilise-t-on souvent un taux d'apprentissage décroissant au fil de l'entraînement ?

Solution. Grands pas au début (exploration rapide), pas fins en fin d'entraînement (**convergence précise** près du minimum).

Cas 172 — Surapprentissage des réseaux. Un réseau de neurones à millions de paramètres est-il un candidat naturel au surapprentissage ?

Solution. **Oui**, particulièrement.

Cas 173 — Dropout, définition. Qu'est-ce que le dropout ?

Solution. La **désactivation aléatoire** d'une fraction des neurones à chaque itération d'entraînement.

Cas 174 — Objectif du dropout. Quel est l'objectif du dropout ?

Solution. Empêcher le réseau de dépendre excessivement d'un **neurone particulier**, réduisant le surapprentissage.

Cas 175 — Régularisation des poids. Comment Ridge/Lasso s'appliquent-ils à un réseau de neurones ?

Solution. En pénalisant directement la **norme des poids** (ℓ_1/ℓ_2), exactement comme en régression.

Cas 176 — Arrêt anticipé et réseaux. L'arrêt anticipé (§14.9) s'applique-t-il à l'entraînement des réseaux de neurones ?

Solution. **Oui**, de la même manière qu'en boosting.

Cas 177 — Calibration du taux d'apprentissage. Comment η est-il généralement calibré ?

Solution. Par **validation croisée** (§14.3), comme les autres hyperparamètres du chapitre.

Cas 178 — Analogie avec le boosting. Le taux d'apprentissage η d'un réseau et le taux ν du boosting jouent-ils un rôle analogue ?

Solution. **Oui**, tous deux contrôlent la taille du pas d'ajustement itératif.

Cas 179 — Nombre d'itérations et surapprentissage. Un trop grand nombre d'itérations d'entraînement risque-t-il le surapprentissage d'un réseau ?

Solution. **Oui**, exactement comme pour M en boosting (§14.9).

Cas 180 — Synthèse du Bloc 9. Résumer en une phrase le principe d'entraînement d'un réseau de neurones.

Solution. Ajuster itérativement les poids par **descente de gradient**, le gradient étant calculé efficacement via **rétropropagation**.

Bloc 10 --- Comparaison, applications et synthèse

Cas 181 — Avantage principal de la régression logistique. Quel est l'avantage principal de la régression logistique face à un réseau de neurones ?

Solution. Une **interprétabilité directe** (odds ratios).

Cas 182 — Avantage principal du réseau de neurones. Quel est l'avantage principal d'un réseau de neurones face à la régression logistique ?

Solution. Une **flexibilité représentationnelle** bien supérieure.

Cas 183 — Besoin en données. Lequel des deux modèles nécessite typiquement davantage de données pour éviter le surapprentissage ?

Solution. Le **réseau de neurones**.

Cas 184 — Robustesse réglementaire. Quel modèle bénéficie d'une robustesse réglementaire éprouvée en scoring de crédit ?

Solution. La **régression logistique**.

Cas 185 — Gain net d'un réseau de neurones, conditions. Sous quelles conditions le gain d'un réseau de neurones sur la logistique est-il le plus net ?

Solution. Grand volume de données, **interactions non linéaires complexes**, interprétabilité non bloquante.

Cas 186 — Scoring tabulaire classique. Sur un scoring de crédit à quelques dizaines de variables tabulaires, l'écart de performance réseau vs logistique régularisée est-il généralement large ?

Solution. **Non**, souvent **modeste**.

Cas 187 — Détection de fraude, modèle privilégié. Quel type de modèle est souvent privilégié pour la détection de fraude sur volumes massifs de transactions ?

Solution. Les **réseaux de neurones** (ou méthodes d'ensemble, chapitre 14).

Cas 188 — Analyse de sentiment. Quel type de modèle convient à l'analyse de sentiment sur données textuelles ?

Solution. Les **réseaux de neurones** (traitement du langage naturel).

Cas 189 — Trading algorithmique. Quel usage cite le chapitre pour la prédiction de direction de marché à très court terme ?

Solution. Le **trading algorithmique**.

Cas 190 — Lien entre chapitre 14 et 15. En quoi ce chapitre complète-t-il le chapitre 14 ?

Solution. Il approfondit le modèle de **prédiction binaire** le plus utilisé (logistique) et son extension non linéaire (réseau), avec les outils d'**évaluation** associés.

Cas 191 — Matrice de confusion, portée transversale. La matrice de confusion et la courbe ROC s'appliquent-elles uniquement à la régression logistique ?

Solution. **Non**, à **tout** modèle de classification (arbres, forêts, boosting, réseaux).

Cas 192 — Fil rouge conservé. Quel fil rouge du chapitre 14 reste valable dans ce chapitre ?

Solution. L'équilibre entre **flexibilité**, **interprétabilité** et **risque de surapprentissage**.

Cas 193 — Choix final du modèle. Le choix final entre logistique et réseau dépend-il uniquement de la performance prédictive ?

Solution. **Non**, aussi des contraintes **réglementaires** et du volume de données disponible.

Cas 194 — Interprétabilité quasi nulle. Pourquoi l'interprétabilité d'un réseau de neurones est-elle qualifiée de « quasi nulle » ?

Solution. Ses **millions de poids** interconnectés n'offrent pas d'équivalent direct à un coefficient de régression lisible.

Cas 195 — Réseau et interactions automatiques. Un réseau de neurones nécessite-t-il de spécifier manuellement les termes d'interaction entre variables ?

Solution. **Non**, il les **apprend automatiquement** via ses couches cachées.

Cas 196 — Régression logistique et termes d'interaction. Une régression logistique capture-t-elle nativement les interactions entre variables ?

Solution. **Non**, sauf si elles sont ajoutées explicitement comme variables croisées.

Cas 197 — Calibration plus délicate. Pourquoi la calibration d'un réseau de neurones est-elle plus délicate que celle d'une régression logistique ?

Solution. Elle implique plusieurs hyperparamètres couplés : **architecture, taux d'apprentissage, régularisation**.

Cas 198 — Prédiction de défaut de contrepartie. La prédiction de défaut de contrepartie relève-t-elle des applications typiques de ce chapitre ?

Solution. **Oui**, citée explicitement comme application phare.

Cas 199 — Absence de hiérarchie universelle. Existe-t-il un modèle universellement supérieur entre logistique et réseau de neurones ?

Solution. **Non**, le choix dépend des données, de l'objectif et des contraintes réglementaires.

Cas 200 — Synthèse générale du chapitre 15. Résumer en une phrase le fil rouge de tout le chapitre 15.

Solution. Prédire une **catégorie** plutôt qu'un nombre — de la régression logistique interprétable aux réseaux de neurones flexibles, avec une évaluation rigoureuse (matrice de confusion, ROC/AUC) à chaque étape.

Partie C --- Méthodologie, formulaire et astuces

C.1 --- Formulaire complet

Fonction logistique (sigmoïde)

$$P(y=1 \mid x) = \frac{1}{1+e^{-z}} = \frac{e^{z}}{1+e^{z}}, \qquad z = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Odds et logit

$$\text{odds} = \frac{p}{1-p}, \qquad \text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = z, \qquad \text{odds ratio}(x_j) = e^{\beta_j}.$$

Effet marginal en régression logistique

$$\frac{\partial P}{\partial x_j} = \beta_j \, P(1-P) \qquad \text{(maximal en } P = 0.5\text{, quasi nul aux extrêmes)}.$$

Log-vraisemblance (= entropie croisée négative)

$$\ell(\beta) = \sum_{i=1}^{n} \{y_i \ln P_i + (1 - y_i) \ln(1 - P_i)\}, \qquad \mathcal{L}_{\text{entropie croisée}} = -\frac{1}{n}\,\ell.$$

Régularisation logistique

$$\text{Ridge} : \max_{\beta} \left\{ \ell(\beta) - \lambda \sum_j \beta_j^2 \right\}, \qquad \text{Lasso} : \max_{\beta} \left\{ \ell(\beta) - \lambda \sum_j |\beta_j| \right\}.$$

Métriques de la matrice de confusion

$$\text{Exactitude} = \frac{VP + VN}{n}, \quad \text{Précision} = \frac{VP}{VP + FP}, \quad \text{Rappel} = \frac{VP}{VP + FN}, \quad \text{Spécificité} = \frac{VN}{VN + FP},$$

$$F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \qquad \text{(moyenne harmonique)}.$$

Courbe ROC et AUC

$$\text{ROC : TVP (rappel) en fonction du TFP } (1 - \text{spécificité}), \ \forall\, s \in [0, 1].$$

$$\text{AUC} = P\left(\hat{P}_{\text{positif tiré au hasard}} > \hat{P}_{\text{négatif tiré au hasard}}\right); \quad 0.5 = \text{aléatoire}, \ 1 = \text{parfait}.$$

Perceptron et fonctions d'activation

$$a = g(w_0 + w_1 x_1 + \cdots + w_p x_p) = g(z); \qquad \text{sigmoïde} = \frac{1}{1 + e^{-z}}, \quad \text{ReLU} = \max(0, z), \quad \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}.$$

Descente de gradient

$$w \leftarrow w - \eta \frac{\partial \mathcal{L}}{\partial w} \qquad (\eta = \text{taux d'apprentissage, gradient calculé par rétropropagation}).$$

Encodage catégoriel

$$C \text{ catégories} \Rightarrow C - 1 \text{ indicatrices (dummy, régression)}, \quad C \text{ colonnes (one-hot, arbres/ML)}.$$

C.2 --- Le tableau maître du chapitre

Concept	Quantité clé	Piège classique	Cas d'usage typique
Modèle probabilité linéaire	$\hat{y}$ hors $[0, 1]$ possible	Croire à une vraie probabilité	Approximation rapide, effet marginal constant
Régression logistique	sigmoïde, logit, odds ratio	Lire β_j comme effet sur P	Scoring de crédit, PD

Concept	Quantité clé	Piège classique	Cas d'usage typique
Encodage dummy	$C-1$ indicatrices	Trappe : C indicatrices + constante	Régressions
Encodage one-hot	C colonnes	L'utiliser avec constante en régression	Arbres, forêts, réseaux
MLE logistique	$\ell(\beta)$, itératif	Chercher une solution fermée	Estimation des β
Matrice de confusion	VP, FP, VN, FN	Se fier à l'exactitude seule	Décision à seuil fixé
Précision/Rappel	arbitrage via seuil	Optimiser l'un en ignorant l'autre	Coûts d'erreur asymétriques
ROC/AUC	tous les seuils	Comparer des modèles par exactitude	Comparaison de modèles
Perceptron	$g(z)$ non linéaire	Activation linéaire empilée	Brique du réseau
Rétropropagation	chain rule, $\partial\mathcal{L}/\partial w$	Confondre avec la descente de gradient	Entraînement du réseau
Dropout	désactivation aléatoire	L'appliquer aussi en prédiction	Anti-surapprentissage

C.3 --- Carte de décision : classifier en gestion des risques

Comment choisir et évaluer un classifieur en situation d'examen

1. Cible binaire ? **Oui** $\rightarrow$ régression logistique comme référence de départ (jamais une régression linéaire directe si les probabilités importent).
2. Variables catégorielles présentes ? **Oui** $\rightarrow$ encodage dummy ($C-1$) pour une régression, one-hot ou natif pour arbres/réseaux.
3. Nombreuses variables corrélées ? **Oui** $\rightarrow$ régularisation (Ridge pour stabiliser, Lasso pour sélectionner), après standardisation.
4. Interactions non linéaires complexes et volume de données important ? **Oui** $\rightarrow$ envisager un réseau de neurones (ou les ensembles du chapitre 14) ; sinon, la logistique régularisée suffit souvent.
5. Comparer des modèles candidats ? $\rightarrow$ **AUC** (indépendante du seuil et de la prévalence).
6. Fixer la décision opérationnelle ? $\rightarrow$ **matrice de confusion** au seuil choisi selon les coûts métier (rappel prioritaire si les faux négatifs coûtent cher ; précision prioritaire si les faux positifs coûtent cher).

C.4 --- Glossaire bilingue

Français	Anglais
Régression logistique	Logistic regression
Modèle de probabilité linéaire	Linear probability model
Fonction logistique / sigmoïde	Logistic / sigmoid function
Cote	Odds
Rapport de cotes	Odds ratio
Logit (log des cotes)	Logit (log-odds)
Variable indicatrice	Dummy variable

Français	Anglais
Trappe des variables indicatrices	Dummy variable trap
Encodage one-hot	One-hot encoding
Catégorie de référence	Reference (base) category
Maximum de vraisemblance	Maximum likelihood estimation (MLE)
Séparation parfaite	Perfect separation
Matrice de confusion	Confusion matrix
Vrai/faux positif, vrai/faux négatif	True/false positive, true/false negative
Exactitude	Accuracy
Précision	Precision
Rappel / sensibilité	Recall / sensitivity
Spécificité	Specificity
Score F1	F1 score
Seuil de décision	Decision (classification) threshold
Courbe ROC	ROC curve
Aire sous la courbe	Area under the curve (AUC)
Perceptron / neurone artificiel	Perceptron / artificial neuron
Couche cachée	Hidden layer
Fonction d'activation	Activation function
Unité linéaire rectifiée	Rectified Linear Unit (ReLU)
Réseau à propagation avant	Feedforward neural network
Fonction de perte	Loss function
Entropie croisée	Cross-entropy
Descente de gradient	Gradient descent
Rétropropagation	Backpropagation
Taux d'apprentissage	Learning rate
Gradient qui s'évanouit	Vanishing gradient
Neurone mort	Dead neuron
Abandon (désactivation aléatoire)	Dropout
Arrêt anticipé	Early stopping

C.5 --- Protocole complet d'un modèle de classification en gestion des risques

1. **Partition des données** : entraînement / validation / test (chronologique si données temporelles) — protocole identique au chapitre 14 (C.5).
2. **Encodage des variables catégorielles** : dummy ($C - 1$) pour la régression logistique, one-hot ou natif pour arbres et réseaux ; choix de la référence guidé par le sens métier.
3. **Standardisation** des variables numériques (paramètres calculés sur l'entraînement seul), indispensable avant régularisation ou réseau de neurones.
4. **Modèle de référence** : régression logistique (éventuellement régularisée) — toujours établir cette référence *avant* un modèle complexe, pour quantifier le gain réel de complexité.
5. **Modèles complexes candidats** (réseaux de neurones, ensembles du chapitre 14) si le volume de données et le contexte le justifient.
6. **Comparaison par AUC** en validation croisée ; sélection du modèle et de ses hyperparamètres.

7. **Choix du seuil de décision** selon les coûts métier (précision vs rappel), documenté et justifié.
8. **Évaluation finale** sur le test, une seule fois : AUC + matrice de confusion complète au seuil retenu.
9. **Documentation réglementaire** : odds ratios (logistique) ou modèle de substitution interprétable (si réseau) + surveillance de dérive post-déploiement.

C.6 --- Les douze pièges classiques

1. Régresser linéairement une cible binaire et lire les prédictions comme des probabilités valides.
2. Tomber dans la trappe des variables indicatrices (C indicatrices + constante).
3. Lire un coefficient logistique β_j comme un effet marginal direct sur la probabilité (l'effet dépend de $P(1-P)$).
4. Confondre odds (cote) et probabilité — odds $= 3$ signifie $p = 0.75$, pas $p = 3$.
5. Chercher une solution fermée au MLE logistique.
6. Ignorer la séparation parfaite sur petit échantillon (coefficients divergents).
7. Oublier la standardisation avant régularisation logistique ou réseau de neurones.
8. Juger un classifieur sur classes déséquilibrées à l'exactitude seule.
9. Considérer le seuil 0.5 comme une donnée plutôt qu'un choix de coûts métier.
10. Comparer des modèles via des métriques dépendantes du seuil au lieu de l'AUC.
11. Empiler des couches à activation linéaire en croyant gagner en flexibilité.
12. Confondre rétropropagation (calcul du gradient) et descente de gradient (mise à jour des poids).

C.7 --- Astuces de calcul et de mémorisation pour l'examen

Astuces de calcul rapide

Sigmoïde, points de repère : $z = 0 \to P = 0.50$; $z = 1 \to P \approx 0.73$; $z = 2 \to P \approx 0.88$; $z = -1 \to P \approx 0.27$; $z = -2 \to P \approx 0.12$. Par symétrie, $P(-z) = 1 - P(z)$: mémoriser trois valeurs suffit pour toutes les autres. **Odds $\leftrightarrow$ probabilité** : $p = \text{odds}/(1 + \text{odds})$ — odds de $3 \to p = 3/4$; odds de $1 \to p = 1/2$; odds de $0.25 \to p = 0.2$. **Odds ratio composés** : les effets se multiplient sur l'échelle des odds — deux variables aux odds ratios de 1.5 et 2.0 qui augmentent chacune d'une unité multiplient les odds par $1.5 \times 2.0 = 3.0$ (mais PAS les probabilités).

Astuces mnémotechniques

« PRécision = PRédits » : la précision se calcule sur les *prédits* positifs (dénominateur $VP + FP$) ; le rappel (*recall*) sur les *réels* positifs (dénominateur $VP + FN$). **Seuil bas = filet large** : abaisser le seuil élargit le filet — on attrape plus de vrais positifs (rappel $\uparrow$) mais aussi plus de déchets (précision $\downarrow$). **AUC = concours de paires** : la probabilité de bien classer une paire (un positif, un négatif) tirée au hasard. **Logistique = réseau à zéro couche cachée** : retenir cette équivalence ancre les deux modèles sur le même continuum. **Rétropropagation = messager, gradient descent = décideur** : l'une transporte l'information d'erreur vers chaque poids, l'autre décide du pas de mise à jour.

Attentes GARP à l'examen --- calibrage de l'effort

Les questions d'examen sur ce chapitre sont majoritairement **conceptuelles** : distinguer les encodages, interpréter un odds ratio, lire une matrice de confusion, comparer logistique et réseau de neurones. Les calculs demandés restent courts : convertir odds $\leftrightarrow$ probabilité, calculer précision/rappel/F_1 depuis une matrice de confusion donnée, évaluer la sigmoïde en un point. Aucune rétropropagation manuelle ni descente de gradient chiffrée n'est exigée — l'examen teste la **compréhension des mécanismes** (pourquoi la non-linéarité est indispensable, pourquoi l'AUC résiste au déséquilibre), pas la virtuosité calculatoire.

Partie F --- Étude de cas intégrée : de la régression logistique au réseau de neurones

Cette étude de cas fil rouge applique l'ensemble des concepts du chapitre sur un scénario unique et réaliste — prolongement direct de l'étude intégrée du chapitre 14 (scoring PME), en descendant cette fois dans la mécanique fine du modèle logistique et de son extension neuronale.

F.1 --- Contexte et préparation des données

Une société de gestion souhaite prédire, pour son activité de prêt aux entreprises, la probabilité de défaut à un an de 6 000 emprunteurs corporate. Les variables disponibles : 6 ratios financiers continus (endettement, couverture des intérêts, liquidité, rentabilité, taille, croissance du chiffre d'affaires), et 2 variables catégorielles — le **secteur** (4 modalités : industrie, services, construction, énergie) et la **notation interne** (3 modalités : A, B, C). Taux de défaut observé : 5%.

Étape 1 --- Encodage des variables catégorielles

Pour la régression logistique : le secteur (4 modalités) devient **3 indicatrices** dummy, avec « services » (modalité la plus fréquente, 45% des emprunteurs) comme référence ; la notation (3 modalités) devient **2 indicatrices**, avec « A » comme référence. Le modèle comptera donc $6 + 3 + 2 = 11$ variables explicatives plus la constante. Inclure les 4 indicatrices sectorielles *et* la constante déclencherait la trappe des variables indicatrices (§15.2) : $X^\top X$ singulière, estimation impossible.

Étape 2 --- Standardisation et partition

Les 6 ratios continus sont standardisés sur l'échantillon d'entraînement (4 200 emprunteurs, dossiers les plus anciens) ; les paramètres sont réappliqués à la validation (900) et au test (900). Les indicatrices 0/1 ne sont pas standardisées — une convention courante qui préserve leur interprétation directe.

F.2 --- Le modèle logistique : estimation et lecture complète

La régression logistique Lasso (λ calibré par validation croisée à 5 plis, maximisant l'AUC) retient 7 variables sur 11. Coefficients estimés (variables standardisées) :

Variable	$\hat{\beta}_j$	Odds ratio $e^{\hat{\beta}_j}$	Lecture
Constante	-3.10	—	Niveau de base (réf. : services, notation A)
Endettement	$+0.74$	2.10	+1 é.-t. $\Rightarrow$ odds $\times$ 2.10
Couverture des intérêts	-0.58	0.56	+1 é.-t. $\Rightarrow$ odds $\div$ 1.79
Liquidité	-0.31	0.73	+1 é.-t. $\Rightarrow$ odds $\div$ 1.37
Croissance CA	-0.22	0.80	Effet protecteur modéré
Secteur construction	$+0.65$	1.92	Odds $\times$ 1.92 vs services

Variable	$\hat{\beta}_j$	Odds ratio $e^{\hat{\beta}_j}$	Lecture
Notation B	$+0.88$	2.41	Odds $\times$ 2.41 vs notation A
Notation C	$+1.95$	7.03	Odds $\times$ 7.03 vs notation A

Le Lasso a annulé : rentabilité, taille, secteur industrie, secteur énergie — variables redondantes avec les ratios conservés ou sans pouvoir prédictif marginal.

Calcul complet --- probabilité de défaut d'un emprunteur type

Emprunteur : secteur construction, notation C, endettement $+1.5$ é.-t., couverture -1.0 é.-t., liquidité 0, croissance 0.
$z = -3.10 + 0.74(1.5) - 0.58(-1.0) - 0.31(0) - 0.22(0) + 0.65 + 1.95 = -3.10 + 1.11 + 0.58 + 0.65 + 1.95 = 1.19$.
$P(\text{défaut}) = \dfrac{1}{1 + e^{-1.19}} = \dfrac{1}{1 + 0.304} = 0.767.$
Une probabilité de défaut de **76.7%** — très élevée, cohérente avec le cumul de facteurs aggravants. Contre-point : le même emprunteur en notation A et secteur services aurait $z = 1.19 - 0.65 - 1.95 = -1.41$, soit $P = 1/(1 + e^{1.41}) = 0.196$ — la probabilité chute à 19.6%, illustrant le poids dominant de la notation interne dans le modèle. Vérification par les odds : le passage de (A, services) à (C, construction) multiplie les odds par $7.03 \times 1.92 = 13.5$; odds initiales $= 0.196/0.804 = 0.244$; odds finales $= 0.244 \times 13.5 = 3.29$; $P = 3.29/4.29 = 0.767$ — cohérence parfaite entre les deux chemins de calcul, exactement le type de vérification croisée attendue à l'examen.

F.3 --- Évaluation : matrice de confusion, arbitrage de seuil et ROC

Sur l'échantillon de test (900 emprunteurs, 45 défauts réels), le modèle logistique Lasso atteint une **AUC de 0.83**. Trois seuils candidats sont évalués :

Seuil	VP	FN	FP	VN	Précision	Rappel
$s = 0.50$	18	27	21	834	46.2%	40.0%
$s = 0.20$	32	13	96	759	25.0%	71.1%
$s = 0.10$	40	5	208	647	16.1%	88.9%

Lecture de l'arbitrage

Le comité de crédit estime qu'un défaut non anticipé (FN) coûte en moyenne 8 fois plus qu'un dossier revu inutilement (FP). Coût relatif par seuil (en unités de coût FP) : $s = 0.50$: $27 \times 8 + 21 = 237$; $s = 0.20$: $13 \times 8 + 96 = 200$; $s = 0.10$: $5 \times 8 + 208 = 248$. Le seuil $s = 0.20$ **minimise le coût total** — ni le seuil par défaut (0.50, trop de défauts manqués), ni le seuil ultra-prudent (0.10, submergé de fausses alertes). Ce calcul de coût pondéré est la traduction opérationnelle exacte du principe de §15.6-15.7 : le seuil est une décision économique, pas une constante universelle.

F.4 --- L'extension neuronale : gain réel et coût de complexité

Un réseau de neurones feedforward est ensuite testé : couche d'entrée (11 variables, encodage one-hot complet cette fois — 4 indicatrices secteur + 3 notation, le réseau étant insensible à la colinéarité parfaite), deux couches cachées (16 puis 8 neurones, activation ReLU), sortie sigmoïde. Entraînement par descente de gradient sur l'entropie croisée, $\eta = 0.01$ décroissant, dropout de 20%, arrêt anticipé sur la validation.

Modèle	AUC validation	AUC test	Interprétabilité
Logistique Lasso (7 variables)	0.84	0.83	Odds ratios directs
Réseau 16-8 ReLU (dropout 20%)	0.86	0.85	Quasi nulle
Réseau 64-32 ReLU (sans dropout)	0.91	0.81	Quasi nulle

Trois enseignements du tableau

(i) Le gain du réseau raisonnable est réel mais modeste : +0.02 d'AUC test (0.85 vs 0.83) — typique sur données tabulaires à quelques dizaines de variables (§15.10). **(ii) Le grand réseau sans régularisation surapprend** : AUC validation brillante (0.91) mais AUC test dégradée (0.81), l'écart validation/test signant le surapprentissage exactement comme au chapitre 14 (§14.2) — le dropout et l'arrêt anticipé du réseau intermédiaire ont précisément évité ce piège. **(iii) La décision finale intègre l'explicabilité** : pour un gain de 0.02, le comité conserve la **logistique Lasso** comme modèle réglementaire officiel (odds ratios documentables), le réseau 16-8 servant d'outil de *challenger model* interne pour surveiller si l'écart de performance se creuse au fil des trimestres.

Synthèse de l'étude intégrée

Ce cas condense le chapitre entier : encodage correct (dummy vs one-hot selon le modèle), estimation MLE régularisée, lecture rigoureuse par odds ratios avec vérification croisée des calculs, choix de seuil par coûts pondérés, comparaison de modèles par AUC, diagnostic de surapprentissage par l'écart validation/test, et arbitrage final performance/explicabilité. C'est exactement la chaîne de raisonnement — plus que chaque formule isolée — que l'examen FRM cherche à tester.

Partie D --- 200 questions à choix multiple

200 questions de style examen, par thème et de difficulté croissante. Une seule réponse correcte, positions équilibrées. Corrigé commenté en Partie E.

Thème 1 --- Le rôle de la régression en prédiction

Q1. En usage prédictif, la régression priorise :

(a) la qualité des prédictions sur de nouvelles données

(b) le nombre minimal de variables

(c) le R^2 d'entraînement uniquement

(d) la significativité de chaque coefficient

Q2. Une régression linéaire directe sur une cible binaire peut produire :

(a) uniquement des valeurs dans [0,1]

(b) des prédictions hors de [0,1]

(c) des probabilités exactes

(d) des odds ratios directs

Q3. Le modèle de probabilité linéaire est :

(a) un modèle non supervisé

(b) une régression logistique déguisée

(c) une régression linéaire appliquée directement à une cible binaire

(d) un réseau de neurones simple

Q4. L'avantage principal du modèle de probabilité linéaire est :

(a) sa robustesse à l'hétéroscédasticité

(b) son absence totale de biais

(c) ses prédictions toujours bornées

(d) un effet marginal constant, directement interprétable

Q5. Le modèle de probabilité linéaire souffre structurellement :

(a) d'hétéroscédasticité (variance dépendant de la moyenne)

(b) d'homoscédasticité parfaite

(c) d'un excès de robustesse

(d) d'une absence de coefficients

Q6. La régression logistique résout le problème du bornage grâce à :

(a) une contrainte de positivité sur les coefficients

(b) la fonction sigmoïde

(c) la suppression de la constante

(d) un seuil fixé à 0.5

Q7. La régression linéaire prédit nativement :

(a) une classe binaire

(b) une catégorie

(c) une cible continue

(d) des odds

Q8. Un exemple de cible binaire en gestion des risques est :

(a) la valeur d'un portefeuille en euros

(b) la volatilité annualisée

(c) le niveau d'un indice boursier

(d) le défaut/non-défaut d'une contrepartie

Q9. La relation entre variables explicatives et probabilité d'un événement est généralement :

(a) non linéaire, car la probabilité est bornée

(b) toujours quadratique

(c) constante

(d) linéaire sur tout le domaine

Q10. Le modèle de probabilité linéaire reste parfois utilisé pour :

(a) sa précision supérieure à la logistique

(b) sa simplicité et sa rapidité

(c) son bornage garanti

(d) son absence d'hypothèses

Q11. Le changement conceptuel central du chapitre 15 est :

(a) abandonner la validation croisée

(b) ne plus standardiser les variables

(c) passer d'une prédiction continue à une probabilité de catégorie

(d) supprimer la régression de la boîte à outils

Q12. Prédire si un marché monte ou baisse relève de :

(a) l'ACP

(b) le clustering

(c) la régression linéaire native

(d) la régression logistique

Q13. En régression linéaire, l'effet marginal d'une variable est :

(a) constant par construction

(b) toujours nul

(c) égal à l'odds ratio

(d) variable selon le point

Q14. La régression logistique conserve de la régression linéaire :

(a) l'effet marginal constant

(b) la structure linéaire sous-jacente $z = \beta_0 + \beta_1 x_1 + ...$

(c) la solution fermée des MCO

(d) l'absence de transformation

Q15. L'usage prédictif de la régression s'appuie sur la validation croisée car :

(a) elle supprime le besoin de test

(b) elle élimine le biais

(c) elle mesure la performance sur données non vues

(d) elle augmente le R^2 d'entraînement

Q16. Un modèle de prédiction cherche-t-il nécessairement la causalité ?

(a) Oui, sauf en finance

(b) Non, il ne cherche jamais rien

(c) Oui, toujours

(d) Non, il cherche la meilleure prédiction

Q17. Les réseaux de neurones prolongent la régression logistique en :

(a) empilant plusieurs transformations non linéaires

(b) remplaçant la sigmoïde par une droite

(c) éliminant les poids

(d) supprimant toute non-linéarité

Q18. Les deux piliers de prédiction supervisée du chapitre 15 sont :

(a) k-means et ACP

(b) régression logistique et réseaux de neurones

(c) bootstrap et simulation

(d) Ridge et Lasso uniquement

Q19. Entre logistique et réseaux, le chapitre introduit :

(a) les processus stochastiques

(b) la théorie des jeux

(c) l'encodage catégoriel et la matrice de confusion

(d) les tests d'hypothèses

Q20. La transition centrale du chapitre se résume par :

(a) prédire un nombre plutôt qu'une catégorie

(b) ne plus rien prédire

(c) prédire sans données

(d) prédire une catégorie plutôt qu'un nombre

Thème 2 --- Encodage des variables catégorielles

Q21. Une variable catégorielle à C catégories est encodée en régression par :

(a) C-1 indicatrices

(b) C+1 indicatrices

(c) une seule variable continue

(d) C indicatrices

Q22. On utilise C-1 indicatrices plutôt que C pour éviter :

(a) un manque de données

(b) la colinéarité parfaite avec la constante

(c) un excès de précision

(d) la standardisation

Q23. La trappe des variables indicatrices désigne :

(a) la suppression de la constante

(b) l'oubli d'une catégorie

(c) l'inclusion des C indicatrices avec la constante

(d) l'encodage one-hot des arbres

Q24. La catégorie omise dans un encodage dummy :

(a) reçoit un coefficient nul forcé

(b) est éliminée des données

(c) est perdue pour le modèle

(d) sert de référence, absorbée dans la constante

Q25. Le coefficient d'une indicatrice s'interprète comme :

(a) un écart par rapport à la catégorie de référence

(b) un odds ratio direct sans transformation

(c) une probabilité

(d) un effet absolu indépendant

Q26. L'encodage one-hot utilise :

(a) C-1 colonnes

(b) C colonnes, sans référence omise

(c) une colonne unique

(d) C^2 colonnes

Q27. L'encodage one-hot convient particulièrement :

(a) à aucun modèle

(b) à la régression avec constante

(c) aux arbres et forêts, insensibles à la colinéarité parfaite

(d) aux MCO uniquement

Q28. L'encodage dummy (C-1) est la convention pour :

(a) le clustering

(b) l'ACP

(c) les arbres de décision

(d) la régression linéaire ou logistique

Q29. Le choix de la catégorie de référence change :

(a) l'interprétation des coefficients, pas les prédictions

(b) la structure des données

(c) le nombre d'observations

(d) les prédictions du modèle

Q30. Un bon choix de référence est souvent :

(a) la catégorie la plus rare

(b) la catégorie la plus fréquente ou la plus « normale » métier

(c) une catégorie au hasard

(d) la dernière catégorie alphabétique

Q31. Pour des indicatrices sectorielles, une référence naturelle est :

(a) aucun secteur

(b) le secteur le plus petit

(c) le secteur non cyclique

(d) le secteur le plus risqué

Q32. Une notation de crédit (AAA, AA, ...) doit être :

(a) supprimée systématiquement

(b) utilisée telle quelle comme texte

(c) ignorée

(d) encodée (ou traitée comme échelle ordinale explicite)

Q33. En cas de trappe des variables indicatrices, la matrice $X^{\mathsf{T}}X$ devient :

(a) non inversible (singulière)

(b) diagonale

(c) orthogonale

(d) mieux conditionnée

Q34. Les arbres de décision exigent-ils un encodage dummy strict ?

(a) Oui, toujours

(b) Non, ils gèrent nativement les catégories

(c) Oui, uniquement en régression

(d) Non, ils refusent les catégories

Q35. Une variable « pays » à 12 modalités en régression logistique donne :

(a) 6 indicatrices

(b) 12 indicatrices

(c) 11 indicatrices

(d) 13 indicatrices

Q36. Avec Ridge/Lasso, chaque indicatrice dummy :

(a) est automatiquement annulée

(b) est fusionnée avec la constante

(c) échappe à la pénalité

(d) reçoit sa propre pénalité comme toute variable

Q37. Une variable à 5 catégories produit en encodage dummy :

(a) 4 colonnes

(b) 6 colonnes

(c) 3 colonnes

(d) 5 colonnes

Q38. L'encodage one-hot sans constante séparée pose-t-il un problème de colinéarité parfaite ?

(a) Oui, toujours

(b) Généralement non

(c) Oui, sauf pour les arbres

(d) Non, jamais dans aucun cas

Q39. L'enjeu central de l'encodage catégoriel est :

(a) augmenter la dimension au maximum

(b) réduire le nombre d'observations

(c) rendre les catégories numériquement exploitables sans colinéarité parasite

(d) supprimer les catégories rares

Q40. Les indicatrices $0/1$ sont-elles généralement standardisées ?

(a) Oui, uniquement en logistique

(b) Non, car elles sont continues

(c) Oui, systématiquement

(d) Non, par convention courante, pour préserver leur interprétation

Thème 3 --- Régression logistique : sigmoïde, odds, logit

Q41. La fonction logistique s'écrit :

(a) $P = 1/(1 + e^{-z})$

(b) $P = e^{-z}$

(c) $P = \ln(z)$

(d) $P = z/(1 + z)$

Q42. La fonction logit s'écrit :

(a) $\ln(p)$

(b) $\ln(p/(1-p))$

(c) e^{p}

(d) $\mathrm{p}/(1+\mathrm{p})$

Q43. Quand $z = 0$, la sigmoïde vaut :

(a) 0.73

(b) 0

(c) 0.5

(d) 1

Q44. Quand z tend vers $+\infty$, P tend vers :

(a) $+\infty$

(b) 0

(c) 0.5

(d) 1

Q45. Quand z tend vers $-\infty$, P tend vers :

(a) 0

(b) 0.5

(c) 1

(d) -∞

Q46. Les odds d'un événement de probabilité p sont :

(a) $p(1-p)$

(b) $p/(1-p)$

(c) $(1-p)/p$

(d) $\ln(p)$

Q47. Pour $p = 0.75$, les odds valent :

(a) 0.33

(b) 0.75

(c) 3

(d) 4

Q48. Le logit est :

(a) l'inverse des odds

(b) la racine des odds

(c) le carré des odds

(d) le logarithme des odds

Q49. La régression logistique modélise linéairement :

(a) le logit de p

(b) les odds directement

(c) la variance de p

(d) la probabilité p directement

Q50. La dérivée de la sigmoïde s'écrit :

(a) P^2

(b) $P(1-P)$

(c) 1-P

(d) 1/P

Q51. En régression logistique, l'effet marginal $\partial P/\partial x_j$ vaut :

(a) e^{β_j}

(b) β_j constant

(c) $\beta_j \cdot P(1-P)$

(d) β_j / P

Q52. L'effet marginal est maximal quand :

(a) $P = 1$

(b) $P = 0.25$

(c) $P = 0$

(d) $P = 0.5$

Q53. Quand P est proche de 0 ou 1, l'effet marginal est :

(a) quasi nul

(b) négatif

(c) constant

(d) maximal

Q54. La sigmoïde établit entre $z \in \mathbb{R}$ et $P \in (0,1)$ une correspondance :

(a) partielle

(b) bijective

(c) aléatoire

(d) discontinue

Q55. La construction logistique découle de :

(a) la loi normale

(b) la minimisation des carrés

(c) la modélisation linéaire du logit, puis son inversion

(d) une convention arbitraire sans fondement

Q56. Un odds ratio égal à 1 signifie :

(a) un effet négatif

(b) une erreur de calcul

(c) un effet fort

(d) aucun effet de la variable

Q57. Un odds ratio supérieur à 1 signifie :

(a) un effet qui augmente la probabilité

(b) aucun effet

(c) un coefficient nul

(d) un effet qui diminue la probabilité

Q58. La sigmoïde garantit des prédictions :

(a) parfois hors de [0,1]

(b) toujours dans $(0,1)$

(c) toujours égales à 0.5

(d) non bornées

Q59. Une droite ne peut garantir le bornage car :

(a) elle passe par l'origine

(b) elle est bornée

(c) une fonction linéaire diverge vers $\pm\infty$

(d) elle est toujours croissante

Q60. Le principe de la régression logistique se résume par :

(a) supprimer la constante du modèle

(b) maximiser le R^2

(c) modéliser p directement par une droite

(d) modéliser linéairement le logit puis inverser par la sigmoïde

Thème 4 --- Estimation MLE et interprétation des coefficients

Q61. Les coefficients de la régression logistique sont estimés par :

(a) maximum de vraisemblance

(b) méthode des moments uniquement

(c) calibration graphique

(d) moindres carrés ordinaires

Q62. Le maximum de vraisemblance maximise :

(a) le R^2

(b) la probabilité d'observer l'échantillon obtenu

(c) le nombre de variables

(d) la somme des carrés résiduels

Q63. La régression logistique possède-t-elle une solution fermée ?

(a) Non, sauf en classification

(b) Oui, comme les MCO

(c) Non, la non-linéarité de la sigmoïde l'empêche

(d) Oui, si n est grand

Q64. En pratique, les coefficients logistiques sont obtenus par :

(a) tirage aléatoire

(b) inversion de $X^\top X$

(c) lecture directe des données

(d) optimisation numérique itérative (Newton-Raphson, gradient)

Q65. Le pont conceptuel entre MLE logistique et réseaux de neurones est :

(a) le même principe d'optimisation itérative

(b) l'absence de paramètres

(c) la linéarité partagée

(d) la solution fermée commune

Q66. L'odds ratio associé à β_j se calcule par :

(a) $\ln(\beta_j)$

(b) e^{β_j}

(c) β_j^2

(d) $1/\beta_j$

Q67. Un odds ratio de 1.5 signifie que chaque unité de x_j :

(a) multiplie la probabilité par 1.5

(b) ajoute 1.5 à la probabilité

(c) multiplie les odds par 1.5

(d) divise les odds par 1.5

Q68. Un odds ratio inférieur à 1 traduit :

(a) une absence d'effet

(b) une erreur d'estimation

(c) un effet qui augmente la probabilité

(d) un effet qui diminue la probabilité

Q69. La log-vraisemblance logistique s'écrit :

(a) $\sum\{y \ln P + (1-y)\ln(1-P)\}$

(b) $\sum |\beta|$

(c) $\sum \ln y$

(d) $\sum (y - \hat{y})^2$

Q70. Un coefficient $\hat{\beta}_j > 0$ implique que x_j croissant :

(a) diminue la probabilité de l'événement

(b) augmente la probabilité de l'événement

(c) n'a aucun effet

(d) annule les odds

Q71. Un coefficient $\hat{\beta}_j < 0$ implique que x_j croissant :

(a) est impossible

(b) augmente la probabilité

(c) diminue la probabilité

(d) double les odds

Q72. Quand $\beta_j = 0$, l'odds ratio vaut :

(a) e

(b) -1

(c) 0

(d) 1

Q73. Un odds ratio d'endettement de 2.27 signifie :

(a) les odds de défaut sont multipliées par 2.27 par écart-type supplémentaire

(b) le défaut est certain

(c) l'endettement n'a pas d'effet

(d) la probabilité de défaut double exactement

Q74. Un odds ratio de liquidité de 0.577 signifie que les odds de défaut sont :

(a) multipliées par 1.73

(b) divisées par environ 1.73

(c) inchangées

(d) annulées

Q75. Les propriétés asymptotiques du MLE (consistance, normalité) s'appliquent surtout :

(a) uniquement pour $p > n$

(b) en petit échantillon

(c) en grand échantillon

(d) jamais

Q76. La distribution asymptotique des coefficients MLE est :

(a) exponentielle

(b) binomiale

(c) uniforme

(d) approximativement normale

Q77. L'odds ratio sert principalement à :

(a) l'interprétation économique des effets

(b) le calcul du seuil

(c) la standardisation

(d) la prédiction pure

Q78. Standardiser avant de comparer des odds ratios permet :

(a) d'annuler les coefficients

(b) de rendre les effets comparables par écart-type

(c) d'éviter le MLE

(d) de supprimer les catégories

Q79. L'algorithme d'optimisation MLE converge :

(a) instantanément par formule fermée

(b) en une seule étape

(c) par itérations successives

(d) jamais

Q80. Interpréter un coefficient logistique se fait via :

(a) sa racine carrée

(b) son logarithme

(c) sa valeur brute comme effet sur P

(d) son odds ratio e^{β_j}

Thème 5 --- Régularisation de la régression logistique

Q81. La régression logistique Ridge maximise :

(a) $\ell(\beta) - \lambda \sum \beta_j^2$

(b) $\ell(\beta) - \lambda \sum |\beta_j|$

(c) le R^2 pénalisé

(d) $\ell(\beta)$ sans pénalité

Q82. La régression logistique Lasso maximise :

(a) $\ell(\beta) - \lambda \sum \beta_j^2$

(b) $\ell(\beta) - \lambda \sum |\beta_j|$

(c) $\ell(\beta) + \lambda \sum \beta_j$

(d) la somme des carrés

Q83. La différence technique avec la régularisation du chapitre 14 est :

(a) l'inutilité de la standardisation

(b) une intuition géométrique différente

(c) la pénalité s'applique à la log-vraisemblance, pas aux carrés résiduels

(d) l'absence de λ

Q84. L'intuition géométrique cercle/losange en logistique régularisée est :

(a) inversée

(b) sans objet

(c) invalide

(d) identique à celle du chapitre 14

Q85. Un scoring à 80 variables corrélées bénéficie de la régularisation car :

(a) Ridge stabilise et Lasso sélectionne

(b) elle supprime la validation croisée

(c) elle élimine le MLE

(d) elle augmente le nombre de variables

Q86. Le Lasso logistique peut-il annuler exactement des coefficients ?

(a) Non, jamais

(b) Oui, comme en régression linéaire

(c) Oui, mais seulement la constante

(d) Non, seulement Ridge le peut

Q87. La standardisation avant régularisation logistique est :

(a) utile uniquement pour les arbres

(b) optionnelle

(c) indispensable

(d) interdite

Q88. λ en logistique régularisée se choisit par :

(a) le hasard

(b) le nombre de catégories

(c) une valeur universelle fixe

(d) validation croisée (ex. maximisant l'AUC)

Q89. Ridge logistique face à des variables macro corrélées :

(a) stabilise les coefficients comme en linéaire

(b) annule toutes les variables

(c) supprime la colinéarité des données

(d) est inefficace

Q90. L'Elastic Net s'applique-t-il à la régression logistique ?

(a) Non

(b) Oui, même combinaison $\ell 1/\ell 2$ sur la log-vraisemblance

(c) Uniquement en régression linéaire

(d) Uniquement aux réseaux

Q91. Le Lasso logistique améliore l'interprétabilité en :

(a) augmentant λ à l'infini

(b) ajoutant des variables

(c) réduisant le nombre de variables actives

(d) supprimant les odds ratios

Q92. Quand $\lambda = 0$, la logistique régularisée devient :

(a) une régression linéaire

(b) un réseau de neurones

(c) un modèle vide

(d) la régression logistique classique (MLE non pénalisé)

Q93. La séparation parfaite désigne :

(a) une combinaison de variables prédisant parfaitement la classe, faisant diverger le MLE

(b) une erreur de données

(c) un seuil optimal

(d) un modèle parfaitement calibré

Q94. Face à la séparation parfaite, la régularisation :

(a) aggrave la divergence

(b) borne les coefficients et stabilise l'estimation

(c) est sans effet

(d) supprime les observations

Q95. Le risque de séparation parfaite est le plus élevé :

(a) avec une seule variable binaire équilibrée

(b) en très grand échantillon

(c) sur petit échantillon avec beaucoup de variables

(d) quand λ est grand

Q96. La grille de λ testée en CV est généralement :

(a) réduite à une seule valeur

(b) aléatoire

(c) linéaire de 0 à 1

(d) logarithmique sur plusieurs ordres de grandeur

Q97. Pour un scoring PME parcimonieux sur 60 variables, privilégier :

(a) le Lasso logistique (ou Elastic Net)

(b) k-means

(c) une régression sans encodage

(d) MCO sans pénalité

Q98. La distinction Ridge (rétrécir) / Lasso (sélectionner) en logistique est :

(a) inversée

(b) intégralement préservée

(c) abolie

(d) dépendante du seuil

Q99. λ et le seuil de décision se calibrent :

(a) uniquement par le régulateur

(b) obligatoirement ensemble en une étape

(c) souvent séparément : λ par AUC, seuil par coûts métier

(d) jamais

Q100. L'apport de la régularisation en logistique se résume par :

(a) annuler la sigmoïde

(b) imposer un seuil unique

(c) supprimer la vraisemblance

(d) stabiliser ou sélectionner les coefficients, comme en linéaire

Thème 6 --- Matrice de confusion et métriques

Q101. La matrice de confusion croise :

(a) classes prédites (après seuil) et classes réelles

(b) probabilités et odds

(c) biais et variance

(d) deux modèles concurrents

Q102. Les quatre cellules de la matrice de confusion binaire sont :

(a) seuil, odds, logit, probabilité

(b) VP, FP, VN, FN

(c) biais, variance, bruit, erreur

(d) précision, rappel, F1, AUC

Q103. L'exactitude (accuracy) se calcule par :

(a) $2VP/(2VP + FP + FN)$

(b) $VP/(VP + FP)$

(c) $(VP + VN)/(VP + VN + FP + FN)$

(d) $VP/(VP + FN)$

Q104. La précision se calcule par :

(a) $VN/(VN + FP)$

(b) $(VP + VN)/n$

(c) $VP/(VP + FN)$

(d) $VP/(VP + FP)$

Q105. Le rappel (sensibilité) se calcule par :

(a) $VP/(VP + FN)$

(b) $VN/(VN + FN)$

(c) $FP/(FP + VN)$

(d) $VP/(VP + FP)$

Q106. Le score F1 est :

(a) la moyenne arithmétique de précision et rappel

(b) la moyenne harmonique de précision et rappel

(c) le maximum des deux

(d) leur produit

Q107. La précision répond à la question :

(a) « quel est le seuil optimal ? »

(b) « combien de positifs réels ai-je détectés ? »

(c) « parmi mes prédictions positives, combien sont réellement positives ? »

(d) « quelle est l'exactitude globale ? »

Q108. Le rappel répond à la question :

(a) « quelle est la spécificité ? »

(b) « quel λ choisir ? »

(c) « parmi mes prédictions positives, combien sont correctes ? »

(d) « parmi les positifs réels, combien ai-je détectés ? »

Q109. La précision est particulièrement cruciale quand :

(a) une fausse alerte est coûteuse

(b) les classes sont équilibrées

(c) le seuil vaut 0.5

(d) manquer un positif coûte cher

Q110. Le rappel est particulièrement crucial quand :

(a) une fausse alerte est coûteuse

(b) manquer un vrai positif est coûteux

(c) l'exactitude est élevée

(d) le modèle est linéaire

Q111. Quand le seuil change, précision et rappel :

(a) deviennent égaux

(b) évoluent toujours ensemble

(c) sont généralement en tension

(d) restent constants

Q112. Abaisser le seuil de décision fait typiquement :

(a) monter les deux

(b) baisser les deux

(c) baisser le rappel

(d) monter le rappel et baisser la précision

Q113. Le seuil de décision par défaut est :

(a) 0.50

(b) 0.90

(c) 1.00

(d) 0.10

Q114. Le seuil de décision est fondamentalement :

(a) une donnée du modèle

(b) un choix de l'analyste selon les coûts

(c) une constante réglementaire universelle

(d) le résultat du MLE

Q115. Sur classes déséquilibrées, l'exactitude seule est :

(a) équivalente à l'AUC

(b) la meilleure métrique

(c) trompeuse

(d) toujours nulle

Q116. En détection de fraude, on privilégie souvent :

(a) un seuil de 0.5 strict

(b) aucun seuil

(c) un seuil élevé

(d) un seuil bas (rappel prioritaire)

Q117. Le F1 est privilégié quand :

(a) aucune des deux erreurs n'est a priori plus coûteuse

(b) les faux négatifs dominent

(c) les classes sont parfaitement équilibrées uniquement

(d) les faux positifs coûtent beaucoup plus cher

Q118. Avec VP = 25 et FP = 60, la précision vaut :

(a) 62.5%

(b) 29.4%

(c) 92.5%

(d) 40.0%

Q119. Avec VP = 25 et FN = 15, le rappel vaut :

(a) 25.0%

(b) 29.4%

(c) 62.5%

(d) 92.5%

Q120. La matrice de confusion est indispensable car :

(a) elle calcule les odds ratios

(b) elle choisit λ automatiquement

(c) elle remplace l'AUC

(d) elle révèle précision et rappel que l'exactitude masque

Thème 7 --- Courbe ROC, AUC et choix de seuil

Q121. La courbe ROC trace :

(a) taux de vrais positifs contre taux de faux positifs, pour tous les seuils

(b) exactitude contre seuil

(c) odds contre probabilité

(d) précision contre rappel

Q122. Une AUC de 0.5 correspond à :

(a) une discrimination parfaite

(b) une discrimination aléatoire

(c) un modèle inutilisable mathématiquement

(d) une erreur de calcul

Q123. Une AUC de 1 correspond à :

(a) un seuil de 0.5

(b) une discrimination aléatoire

(c) une discrimination parfaite

(d) un surapprentissage certain

Q124. Une AUC de 0.85 s'interprète comme :

(a) 85% de rappel

(b) 85% de précision

(c) 85% d'exactitude

(d) 85% de chances de classer une paire (positif, négatif) dans le bon ordre

Q125. L'AUC dépend-elle d'un seuil particulier ?

(a) Non, elle intègre tous les seuils

(b) Oui, du seuil optimal

(c) Oui, du seuil réglementaire

(d) Oui, du seuil 0.5

Q126. L'AUC dépend-elle de la prévalence de la classe positive ?

(a) Oui, fortement

(b) Non, contrairement à l'exactitude

(c) Oui, comme toutes les métriques

(d) Uniquement en cas de fraude

Q127. Pour comparer des modèles candidats, on privilégie :

(a) le temps de calcul

(b) l'exactitude

(c) l'AUC

(d) le nombre de variables

Q128. Pour évaluer une décision opérationnelle à seuil fixé, on privilégie :

(a) le R^2

(b) la log-vraisemblance

(c) l'AUC seule

(d) la matrice de confusion

Q129. Un point précis de la courbe ROC se choisit selon :

(a) le coût relatif des deux types d'erreur

(b) le nombre d'observations

(c) la valeur de λ

(d) l'esthétique de la courbe

Q130. Si un faux négatif coûte 5 fois plus qu'un faux positif, on privilégie :

(a) un taux de vrais positifs faible

(b) un point à taux de vrais positifs élevé

(c) le seuil 0.5 strict

(d) l'exactitude maximale

Q131. L'axe des abscisses de la courbe ROC représente :

(a) le seuil

(b) le rappel

(c) le taux de faux positifs (1-spécificité)

(d) la précision

Q132. L'axe des ordonnées de la courbe ROC représente :

(a) la précision

(b) l'exactitude

(c) le taux de faux positifs

(d) le taux de vrais positifs (rappel)

Q133. La courbe ROC d'un modèle sans pouvoir discriminant est :

(a) la diagonale

(b) une horizontale

(c) un point unique

(d) une verticale

Q134. Sur un portefeuille à 2% de défauts, on préfère l'AUC à l'exactitude car :

(a) l'AUC est plus simple

(b) l'exactitude est biaisée par le déséquilibre, pas l'AUC

(c) l'exactitude est toujours nulle

(d) l'AUC dépend du seuil

Q135. Le choix final du seuil est une décision :

(a) toujours égale à 0.5

(b) purement statistique

(c) métier, fondée sur les coûts des erreurs

(d) du modèle lui-même

Q136. Entre un modèle A (AUC 0.82) et B (AUC 0.79), lequel discrimine mieux globalement ?

(a) Ni l'un ni l'autre

(b) Impossible à dire

(c) B

(d) A

Q137. La courbe ROC reste-t-elle informative avec une classe rare ?

(a) Oui, c'est un de ses atouts majeurs

(b) Uniquement si $n > 10000$

(c) Non, sauf pour la fraude

(d) Non, elle s'effondre

Q138. Pour comparer deux algorithmes de détection de fraude avant déploiement :

(a) la matrice de confusion à seuil arbitraire

(b) l'AUC

(c) le taux de convergence

(d) le nombre de couches

Q139. Pour décider d'octroyer un crédit à un seuil précis :

(a) le nombre de variables

(b) l'AUC seule

(c) la matrice de confusion au seuil retenu

(d) la courbe ROC entière

Q140. L'apport central de la ROC/AUC est :

(a) calculer le seuil optimal automatiquement

(b) supprimer la matrice de confusion

(c) remplacer la vraisemblance

(d) évaluer la discrimination indépendamment du seuil et de la prévalence

Thème 8 --- Réseaux de neurones : architecture et activation

Q141. Un perceptron calcule :

(a) une combinaison linéaire pondérée suivie d'une activation non linéaire

(b) un tri des entrées

(c) une distance euclidienne

(d) une moyenne simple des entrées

Q142. Un neurone logistique est un perceptron avec :

(a) une activation ReLU

(b) une activation sigmoïde

(c) aucune activation

(d) une activation linéaire

Q143. Les trois types de couches d'un réseau feedforward sont :

(a) train, validation, test

(b) gauche, centre, droite

(c) entrée, cachée(s), sortie

(d) biais, variance, bruit

Q144. Dans un réseau feedforward, l'information circule :

(a) de la sortie vers l'entrée

(b) aléatoirement

(c) en boucle

(d) de l'entrée vers la sortie, sans boucle

Q145. La fonction ReLU s'écrit :

(a) $\max(0, z)$

(b) $\tanh(z)$

(c) z^2

(d) $1/(1+e^{-z})$

Q146. La plage de valeurs de la sigmoïde est :

(a) $(-1, 1)$

(b) $(0, 1)$

(c) $[0, \infty)$

(d) R entier

Q147. La plage de valeurs de tanh est :

(a) $(0, \infty)$

(b) $(0, 1)$

(c) $(-1, 1)$

(d) $[0, \infty)$

Q148. Sans activation non linéaire, un réseau multicouche équivaut à :

(a) un arbre de décision

(b) une ACP

(c) un réseau plus profond

(d) une seule couche linéaire

Q149. La composition de transformations linéaires est :

(a) linéaire

(b) quadratique

(c) exponentielle

(d) non linéaire

Q150. ReLU domine pour les couches cachées car :

(a) elle est bornée

(b) simple et évite le gradient qui s'évanouit

(c) elle produit des probabilités

(d) elle est différentiable partout

Q151. Le gradient qui s'évanouit survient quand :

(a) le réseau est trop petit

(b) le taux d'apprentissage est trop grand

(c) des dérivées proches de zéro se multiplient à travers les couches

(d) les données sont standardisées

Q152. En classification binaire, la couche de sortie conserve souvent :

(a) tanh

(b) une activation linéaire

(c) ReLU

(d) la sigmoïde

Q153. Un réseau sans couche cachée avec sortie sigmoïde équivaut à :

(a) une régression logistique

(b) une forêt aléatoire

(c) un k-NN

(d) une ACP

Q154. Une couche cachée apporte au réseau :

(a) une solution fermée

(b) l'apprentissage de ses propres variables dérivées

(c) la suppression des poids

(d) la linéarité

Q155. Les poids w d'un réseau sont analogues :

(a) aux seuils

(b) aux observations

(c) aux coefficients β d'une régression

(d) aux catégories

Q156. Un inconvénient potentiel de ReLU est :

(a) son bornage dans $(0, 1)$

(b) sa non-monotonie

(c) sa complexité de calcul

(d) les neurones morts (sortie et gradient nuls pour $z < 0$)

Q157. Plus de couches cachées apporte :

(a) plus de flexibilité, avec risque accru de surapprentissage

(b) une garantie de généralisation

(c) une interprétabilité accrue

(d) moins de flexibilité

Q158. Un réseau feedforward comporte-t-il des boucles de rétroaction ?

(a) Oui, toujours

(b) Non, par définition

(c) Oui, dans les couches cachées

(d) Uniquement en sortie

Q159. Les réseaux excellent particulièrement sur :

(a) les données sans étiquette uniquement

(b) les petites tables de 10 variables

(c) les données non tabulaires (images, texte, haute fréquence)

(d) les régressions à 2 variables

Q160. L'architecture d'un réseau se résume par :

(a) un arbre binaire

(b) une matrice de covariance

(c) une succession de couches linéaires pures

(d) des couches de perceptrons : transformation linéaire puis activation non linéaire

Thème 9 --- Entraînement des réseaux de neurones

Q161. La fonction de perte mesure :

(a) l'écart entre prédiction et cible réelle

(b) le nombre de couches

(c) la vitesse de calcul

(d) la taille du réseau

Q162. En classification binaire, la fonction de perte usuelle est :

(a) l'erreur quadratique uniquement

(b) l'entropie croisée

(c) la valeur absolue

(d) le taux d'exactitude

Q163. L'entropie croisée est liée à :

(a) la matrice de confusion

(b) la variance des poids

(c) la log-vraisemblance logistique (son négatif)

(d) l'AUC

Q164. La descente de gradient met à jour chaque poids selon :

(a) $w \leftarrow w \times \eta$

(b) $w \leftarrow -w$

(c) $w \leftarrow w + \eta\, \partial \mathcal{L} / \partial w$

(d) $w \leftarrow w - \eta\, \partial \mathcal{L} / \partial w$

Q165. Le taux d'apprentissage η contrôle :

(a) la taille du pas de mise à jour

(b) le nombre de neurones

(c) le seuil de décision

(d) le nombre de couches

Q166. Un η trop grand provoque :

(a) une convergence très lente

(b) une divergence ou des oscillations sans convergence

(c) une convergence parfaite

(d) un gradient nul

Q167. Un η trop petit provoque :

(a) une erreur de calcul

(b) une divergence

(c) une convergence très lente

(d) une explosion des poids

Q168. La rétropropagation calcule :

(a) la matrice de confusion

(b) l'AUC

(c) le seuil optimal

(d) le gradient de la perte pour chaque poids, y compris les couches profondes

Q169. La rétropropagation repose sur :

(a) la règle de dérivation en chaîne

(b) le théorème central limite

(c) la décomposition en valeurs propres

(d) la loi des grands nombres

Q170. Sans rétropropagation, calculer le gradient d'un grand réseau serait :

(a) plus rapide

(b) numériquement intraitable

(c) identique

(d) inutile

Q171. Un taux d'apprentissage décroissant permet :

(a) d'augmenter le surapprentissage

(b) d'éviter la standardisation

(c) grands pas au début, pas fins près du minimum

(d) de supprimer la rétropropagation

Q172. Un réseau à millions de paramètres est face au surapprentissage :

(a) indifférent

(b) protégé par sa taille

(c) immunisé

(d) particulièrement exposé

Q173. Le dropout consiste à :

(a) désactiver aléatoirement une fraction des neurones à chaque itération

(b) réduire le taux d'apprentissage

(c) supprimer des couches

(d) supprimer définitivement des neurones

Q174. L'objectif du dropout est :

(a) accélérer le calcul

(b) empêcher la dépendance excessive à un neurone particulier

(c) augmenter la perte

(d) supprimer la sigmoïde

Q175. Ridge/Lasso s'appliquent aux réseaux en pénalisant :

(a) la fonction d'activation

(b) les données

(c) la norme des poids ($\ell 1/\ell 2$)

(d) le nombre de couches

Q176. L'arrêt anticipé s'applique-t-il aux réseaux de neurones ?

(a) Non, jamais

(b) Uniquement sans dropout

(c) Non, uniquement au boosting

(d) Oui, comme en boosting

Q177. η se calibre généralement par :

(a) validation croisée

(b) le nombre de catégories

(c) la taille du test

(d) une valeur universelle de 0.5

Q178. η (réseaux) et ν (boosting) jouent un rôle :

(a) opposé

(b) analogue : taille du pas itératif

(c) identique mathématiquement en tout point

(d) sans rapport

Q179. Trop d'itérations d'entraînement d'un réseau risque :

(a) aucun effet

(b) l'underfitting

(c) le surapprentissage, comme M trop grand en boosting

(d) une convergence parfaite

Q180. L'entraînement d'un réseau se résume par :

(a) un tirage aléatoire des poids

(b) une énumération exhaustive

(c) une solution fermée matricielle

(d) descente de gradient avec gradient calculé par rétropropagation

Thème 10 --- Comparaison, applications et synthèse

Q181. L'avantage principal de la régression logistique sur un réseau est :

(a) son interprétabilité directe (odds ratios)

(b) son besoin accru de données

(c) sa capacité d'interactions automatiques

(d) sa flexibilité supérieure

Q182. L'avantage principal d'un réseau sur la logistique est :

(a) son interprétabilité

(b) sa flexibilité représentationnelle supérieure

(c) sa rapidité d'estimation

(d) sa robustesse réglementaire

Q183. Le modèle nécessitant le plus de données pour éviter le surapprentissage est :

(a) les deux également

(b) la régression logistique

(c) le réseau de neurones

(d) le modèle de probabilité linéaire

Q184. Le modèle à la robustesse réglementaire éprouvée en scoring est :

(a) le k-NN

(b) le clustering

(c) le réseau profond

(d) la régression logistique

Q185. Le gain d'un réseau est le plus net quand :

(a) volume important, interactions complexes, interprétabilité non bloquante

(b) le régulateur exige des odds ratios

(c) les variables sont peu nombreuses

(d) les données sont rares et tabulaires

Q186. Sur un scoring tabulaire à quelques dizaines de variables, l'écart réseau vs logistique régularisée est :

(a) toujours énorme

(b) souvent modeste

(c) toujours nul

(d) imprévisible et immense

Q187. Pour la détection de fraude sur volumes massifs, on privilégie souvent :

(a) l'ACP seule

(b) le modèle de probabilité linéaire

(c) les réseaux de neurones ou ensembles

(d) la régression simple à 2 variables

Q188. Pour l'analyse de sentiment sur données textuelles :

(a) le k-means est optimal

(b) aucun modèle ne s'applique

(c) la régression linéaire suffit

(d) les réseaux de neurones conviennent (traitement du langage)

Q189. La prédiction de direction de marché à très court terme relève de :

(a) le trading algorithmique

(b) la comptabilité

(c) l'audit

(d) l'assurance

Q190. Le chapitre 15 complète le chapitre 14 en approfondissant :

(a) le clustering

(b) la prédiction binaire (logistique) et son extension neuronale, avec l'évaluation

(c) la simulation de Monte-Carlo

(d) les séries temporelles

Q191. La matrice de confusion et la ROC s'appliquent :

(a) aux modèles non supervisés

(b) à la seule régression logistique

(c) à tout modèle de classification (arbres, forêts, boosting, réseaux)

(d) aux seuls réseaux

Q192. Le fil rouge conservé du chapitre 14 est :

(a) supprimer la validation

(b) standardiser sans motif

(c) maximiser la complexité

(d) équilibrer flexibilité, interprétabilité et surapprentissage

Q193. Le choix final entre logistique et réseau dépend :

(a) de la performance, des contraintes réglementaires et du volume de données

(b) du hasard

(c) du langage de programmation

(d) de la performance seule

Q194. L'interprétabilité d'un réseau est quasi nulle car :

(a) il n'a pas de paramètres

(b) ses millions de poids interconnectés n'ont pas d'équivalent à un coefficient lisible

(c) il ne converge jamais

(d) il n'utilise pas de données

Q195. Un réseau apprend les interactions entre variables :

(a) uniquement pour deux variables

(b) seulement si elles sont spécifiées manuellement

(c) automatiquement via ses couches cachées

(d) jamais

Q196. Une régression logistique capture les interactions :

(a) toujours

(b) via la sigmoïde seule

(c) automatiquement

(d) seulement si elles sont ajoutées explicitement comme variables croisées

Q197. La calibration d'un réseau est plus délicate car elle couple :

(a) architecture, taux d'apprentissage et régularisation

(b) seuil et prévalence

(c) odds et logit

(d) deux observations

Q198. La prédiction de défaut de contrepartie est :

(a) hors du champ du chapitre

(b) une application phare du chapitre

(c) réservée au chapitre 13

(d) impossible en pratique

Q199. Existe-t-il un modèle universellement supérieur entre logistique et réseau ?

(a) Oui, selon le langage utilisé

(b) Oui, le réseau toujours

(c) Non, le choix dépend du contexte

(d) Oui, la logistique toujours

Q200. Le fil rouge du chapitre 15 se résume par :

(a) supprimer l'évaluation des modèles

(b) abandonner la régression

(c) prédire un nombre plutôt qu'une catégorie

(d) prédire une catégorie, de la logistique interprétable au réseau flexible, avec évaluation rigoureuse

---

Partie E --- Corrigé commenté des 200 QCM

Réponse correcte suivie de l'explication. Distribution équilibrée (50 a, 50 b, 50 c, 50 d).

Thème 1 --- Le rôle de la régression en prédiction

Q1 — (a) la qualité des prédictions sur de nouvelles données. Performance hors-échantillon avant tout.

Q2 — (b) des prédictions hors de [0,1]. Aucune borne naturelle sur une droite.

Q3 — (c) une régression linéaire appliquée directement à une cible binaire. Définition du linear probability model.

Q4 — (d) un effet marginal constant, directement interprétable. Chaque coefficient se lit comme un effet constant.

Q5 — (a) d'hétéroscédasticité (variance dépendant de la moyenne). $\mathrm{Var}(y) = p(1-p)$ dépend de la moyenne.

Q6 — (b) la fonction sigmoïde. La sigmoïde borne mécaniquement dans $(0, 1)$.

Q7 — (c) une cible continue. Cible continue par construction.

Q8 — (d) le défaut/non-défaut d'une contrepartie. Classification binaire typique.

Q9 — (a) non linéaire, car la probabilité est bornée. Le bornage impose la non-linéarité aux extrêmes.

Q10 — (b) sa simplicité et sa rapidité. Outil d'appoint pragmatique.

Q11 — (c) passer d'une prédiction continue à une probabilité de catégorie. Du nombre à la catégorie.

Q12 — (d) la régression logistique. Cible binaire = logistique.

Q13 — (a) constant par construction. Propriété du modèle linéaire.

Q14 — (b) la structure linéaire sous-jacente $z = \beta_0 + \beta_1 x_1 + \ldots$**.** Même index linéaire, transformé ensuite.

Q15 — (c) elle mesure la performance sur données non vues. Estimation honnête de la généralisation.

Q16 — (d) Non, il cherche la meilleure prédiction. Prédiction $\neq$ causalité.

Q17 — (a) empilant plusieurs transformations non linéaires. Empilement de couches non linéaires.

Q18 — (b) régression logistique et réseaux de neurones. Structure du chapitre.

Q19 — (c) l'encodage catégoriel et la matrice de confusion. Détour méthodologique indispensable.

Q20 — (d) prédire une catégorie plutôt qu'un nombre. Fil rouge du chapitre.

Thème 2 --- Encodage des variables catégorielles

Q21 — (a) C-1 indicatrices. Convention dummy avec référence omise.

Q22 — (b) la colinéarité parfaite avec la constante. La somme des C indicatrices vaut toujours 1.

Q23 — (c) l'inclusion des C indicatrices avec la constante. Colinéarité parfaite, $X^\top X$ singulière.

Q24 — (d) sert de référence, absorbée dans la constante. Rôle de la catégorie de référence.

Q25 — (a) un écart par rapport à la catégorie de référence. Lecture relative à la référence.

Q26 — (b) C colonnes, sans référence omise. Une colonne binaire par catégorie.

Q27 — (c) aux arbres et forêts, insensibles à la colinéarité parfaite. Modèles insensibles à la colinéarité.

Q28 — (d) la régression linéaire ou logistique. Convention en régression.

Q29 — (a) l'interprétation des coefficients, pas les prédictions. Prédictions invariantes, lecture modifiée.

Q30 — (b) la catégorie la plus fréquente ou la plus « normale » métier. Facilite la lecture économique.

Q31 — (c) le secteur non cyclique. Point de comparaison « normal ».

Q32 — (d) encodée (ou traitée comme échelle ordinale explicite). Transformation numérique nécessaire.

Q33 — (a) non inversible (singulière). Conséquence de la colinéarité parfaite.

Q34 — (b) Non, ils gèrent nativement les catégories. Rappel du chapitre 14.

Q35 — (c) 11 indicatrices. $C - 1 = 11$.

Q36 — (d) reçoit sa propre pénalité comme toute variable. Traitement standard par la régularisation.

Q37 — (a) 4 colonnes. $C - 1 = 4$.

Q38 — (b) Généralement non. Le problème vient de la constante additionnelle.

Q39 — (c) rendre les catégories numériquement exploitables sans colinéarité parasite. Synthèse du bloc.

Q40 — (d) Non, par convention courante, pour préserver leur interprétation. Convention préservant la lecture directe.

Thème 3 --- Régression logistique : sigmoïde, odds, logit

Q41 — (a) $P = 1/(1 + e^{-z})$**.** Formule de la sigmoïde.

Q42 — (b) $\ln(p/(1-p))$**.** Log des odds.

Q43 — (c) 0.5. Point central de la sigmoïde.

Q44 — (d) 1. Saturation supérieure.

Q45 — (a) 0. Saturation inférieure.

Q46 — (b) $p/(1-p)$**.** Définition de la cote.

Q47 — (c) 3. $0.75/0.25 = 3$.

Q48 — (d) le logarithme des odds. Définition du logit.

Q49 — (a) le logit de p. Linéarité sur l'échelle du logit.

Q50 — (b) $P(1-P)$**.** Propriété classique, strictement positive.

Q51 — (c) $\beta_j \cdot P(1-P)$**.** Effet dépendant du point d'évaluation.

Q52 — (d) $P = 0.5$**.** $P(1-P)$ maximal en 0.5.

Q53 — (a) quasi nul. Saturation de la sigmoïde.

Q54 — (b) bijective. Fonction strictement croissante et bornée.

Q55 — (c) la modélisation linéaire du logit, puis son inversion. Origine de la sigmoïde en régression.

Q56 — (d) aucun effet de la variable. Multiplier les odds par 1 = inchangé.

Q57 — (a) un effet qui augmente la probabilité. Odds accrues = probabilité accrue.

Q58 — (b) toujours dans $(0, 1)$**.** Bornage par construction.

Q59 — (c) une fonction linéaire diverge vers $\pm\infty$**.** Absence de saturation d'une droite.

Q60 — (d) modéliser linéairement le logit puis inverser par la sigmoïde. Synthèse du mécanisme logistique.

Thème 4 --- Estimation MLE et interprétation des coefficients

Q61 — (a) maximum de vraisemblance. MLE, pas MCO.

Q62 — (b) la probabilité d'observer l'échantillon obtenu. Définition du MLE.

Q63 — (c) Non, la non-linéarité de la sigmoïde l'empêche. Optimisation numérique requise.

Q64 — (d) optimisation numérique itérative (Newton-Raphson, gradient). Méthodes itératives standard.

Q65 — (a) le même principe d'optimisation itérative. Optimisation itérative dans les deux cas.

Q66 — (b) e^{β_j}**.** Exponentielle du coefficient.

Q67 — (c) multiplie les odds par 1.5. Effet multiplicatif sur les odds, pas sur p.

Q68 — (d) un effet qui diminue la probabilité. Odds réduites.

Q69 — (a) $\sum\{y \ln P + (1-y)\ln(1-P)\}$**.** Formule de la log-vraisemblance binaire.

Q70 — (b) augmente la probabilité de l'événement. Signe positif = effet positif sur P.

Q71 — (c) diminue la probabilité. Signe négatif = effet protecteur.

Q72 — (d) 1. $e^0 = 1$, aucun effet.

Q73 — (a) les odds de défaut sont multipliées par 2.27 par écart-type supplémentaire. Lecture multiplicative sur les odds.

Q74 — (b) divisées par environ 1.73. $1/0.577 \approx 1.73$.

Q75 — (c) en grand échantillon. Théorie asymptotique du chapitre 5.

Q76 — (d) approximativement normale. Permet les tests de significativité usuels.

Q77 — (a) l'interprétation économique des effets. La prédiction utilise $\hat{\mathrm{P}}$ directement.

Q78 — (b) de rendre les effets comparables par écart-type. Échelle commune pour la comparaison.

Q79 — (c) par itérations successives. Nature itérative de l'optimisation.

Q80 — (d) son odds ratio e^{β_j}. Synthèse de l'interprétation.

Thème 5 --- Régularisation de la régression logistique

Q81 — (a) $\ell(\beta) - \lambda \sum \beta_j^2$. Log-vraisemblance pénalisée $\ell 2$.

Q82 — (b) $\ell(\beta) - \lambda \sum |\beta_j|$. Log-vraisemblance pénalisée $\ell 1$.

Q83 — (c) la pénalité s'applique à la log-vraisemblance, pas aux carrés résiduels. Même logique, objectif différent.

Q84 — (d) identique à celle du chapitre 14. Ridge rétrécit, Lasso sélectionne, comme avant.

Q85 — (a) Ridge stabilise et Lasso sélectionne. Motivations identiques au chapitre 14.

Q86 — (b) Oui, comme en régression linéaire. Propriété de sélection conservée.

Q87 — (c) indispensable. Pénalité sensible à l'échelle.

Q88 — (d) validation croisée (ex. maximisant l'AUC). Calibration standard par CV.

Q89 — (a) stabilise les coefficients comme en linéaire. Même effet stabilisateur.

Q90 — (b) Oui, même combinaison $\ell 1/\ell 2$ sur la log-vraisemblance. Extension directe.

Q91 — (c) réduisant le nombre de variables actives. Modèle parcimonieux plus lisible.

Q92 — (d) la régression logistique classique (MLE non pénalisé). Pénalité nulle = MLE standard.

Q93 — (a) une combinaison de variables prédisant parfaitement la classe, faisant diverger le MLE. Coefficients non régularisés divergents.

Q94 — (b) borne les coefficients et stabilise l'estimation. Rôle stabilisateur de la pénalité.

Q95 — (c) sur petit échantillon avec beaucoup de variables. Configuration p grand / n petit.

Q96 — (d) logarithmique sur plusieurs ordres de grandeur. Couverture large de l'espace de pénalité.

Q97 — (a) le Lasso logistique (ou Elastic Net). Sélection + interprétabilité.

Q98 — (b) intégralement préservée. Transposition directe du chapitre 14.

Q99 — (c) souvent séparément : λ par AUC, seuil par coûts métier. Deux calibrations à logiques distinctes.

Q100 — (d) stabiliser ou sélectionner les coefficients, comme en linéaire. Synthèse du bloc.

Thème 6 --- Matrice de confusion et métriques

Q101 — (a) classes prédites (après seuil) et classes réelles. Définition de la matrice de confusion.

Q102 — (b) VP, FP, VN, FN. Vrais/faux positifs et négatifs.

Q103 — (c) $(VP + VN)/(VP + VN + FP + FN)$. Proportion de classifications correctes.

Q104 — (d) $VP/(VP + FP)$. Sur les prédits positifs.

Q105 — (a) $VP/(VP+FN)$**.** Sur les positifs réels.

Q106 — (b) la moyenne harmonique de précision et rappel. Moyenne harmonique.

Q107 — (c) « parmi mes prédictions positives, combien sont réellement positives ? ». Qualité des alertes émises.

Q108 — (d) « parmi les positifs réels, combien ai-je détectés ? ». Couverture des positifs réels.

Q109 — (a) une fausse alerte est coûteuse. Coût des faux positifs élevé.

Q110 — (b) manquer un vrai positif est coûteux. Coût des faux négatifs élevé.

Q111 — (c) sont généralement en tension. Arbitrage structurel.

Q112 — (d) monter le rappel et baisser la précision. Filet plus large : plus de détection, plus de fausses alertes.

Q113 — (a) 0.50. Convention par défaut, non obligatoire.

Q114 — (b) un choix de l'analyste selon les coûts. Décision économique.

Q115 — (c) trompeuse. Rappel du piège classique.

Q116 — (d) un seuil bas (rappel prioritaire). Rater une fraude coûte cher.

Q117 — (a) aucune des deux erreurs n'est a priori plus coûteuse. Compromis symétrique.

Q118 — (b) 29.4%. $25/85 = 29.4\,\%$.

Q119 — (c) 62.5%. $25/40 = 62.5\,\%$.

Q120 — (d) elle révèle précision et rappel que l'exactitude masque. Synthèse du bloc.

Thème 7 --- Courbe ROC, AUC et choix de seuil

Q121 — (a) taux de vrais positifs contre taux de faux positifs, pour tous les seuils. Définition de la courbe ROC.

Q122 — (b) une discrimination aléatoire. Pas mieux qu'un tirage au sort.

Q123 — (c) une discrimination parfaite. Séparation parfaite des classes.

Q124 — (d) 85% de chances de classer une paire (positif, négatif) dans le bon ordre. Interprétation probabiliste par paires.

Q125 — (a) Non, elle intègre tous les seuils. Métrique indépendante du seuil.

Q126 — (b) Non, contrairement à l'exactitude. Robustesse au déséquilibre.

Q127 — (c) l'AUC. Comparaison indépendante du seuil.

Q128 — (d) la matrice de confusion. Outil adapté à la décision concrète.

Q129 — (a) le coût relatif des deux types d'erreur. Critère économique métier.

Q130 — (b) un point à taux de vrais positifs élevé. Rappel prioritaire quand FN coûteux.

Q131 — (c) le taux de faux positifs (1-spécificité). Convention de la courbe ROC.

Q132 — (d) le taux de vrais positifs (rappel). Convention de la courbe ROC.

Q133 — (a) la diagonale. AUC = 0.5, diagonale.

Q134 — (b) l'exactitude est biaisée par le déséquilibre, pas l'AUC. Robustesse au déséquilibre des classes.

Q135 — (c) métier, fondée sur les coûts des erreurs. Dimension économique du seuil.

Q136 — (d) A. AUC supérieure = meilleure discrimination globale.

Q137 — (a) Oui, c'est un de ses atouts majeurs. Avantage clé de la ROC.

Q138 — (b) l'AUC. Le seuil final n'étant pas encore fixé.

Q139 — (c) la matrice de confusion au seuil retenu. Évaluation à seuil opérationnel.

Q140 — (d) évaluer la discrimination indépendamment du seuil et de la prévalence. Synthèse du bloc.

Thème 8 --- Réseaux de neurones : architecture et activation

Q141 — (a) une combinaison linéaire pondérée suivie d'une activation non linéaire. Brique de base du réseau.

Q142 — (b) une activation sigmoïde. Sigmoïde comme activation.

Q143 — (c) entrée, cachée(s), sortie. Architecture standard.

Q144 — (d) de l'entrée vers la sortie, sans boucle. Propagation avant, par définition.

Q145 — (a) $\max(0, z)$. Rectified Linear Unit.

Q146 — (b) $(0, 1)$. Probabilité bornée.

Q147 — (c) $(-1, 1)$. Centrée sur zéro.

Q148 — (d) une seule couche linéaire. Composition de linéaires = linéaire.

Q149 — (a) linéaire. Propriété algébrique fondamentale.

Q150 — (b) simple et évite le gradient qui s'évanouit. Dérivée constante (0 ou 1).

Q151 — (c) des dérivées proches de zéro se multiplient à travers les couches. Saturation de sigmoïde/tanh en profondeur.

Q152 — (d) la sigmoïde. Sortie en probabilité bornée.

Q153 — (a) une régression logistique. Cas particulier fondamental.

Q154 — (b) l'apprentissage de ses propres variables dérivées. Représentation intermédiaire apprise.

Q155 — (c) aux coefficients β d'une régression. Paramètres ajustables du modèle.

Q156 — (d) les neurones morts (sortie et gradient nuls pour $z < 0$). Neurone qui cesse d'apprendre.

Q157 — (a) plus de flexibilité, avec risque accru de surapprentissage. Compromis flexibilité/surapprentissage.

Q158 — (b) Non, par définition. Contrairement aux réseaux récurrents.

Q159 — (c) les données non tabulaires (images, texte, haute fréquence). Avantage sur données complexes massives.

Q160 — (d) des couches de perceptrons : transformation linéaire puis activation non linéaire. Synthèse du bloc.

Thème 9 --- Entraînement des réseaux de neurones

Q161 — (a) l'écart entre prédiction et cible réelle. Critère à minimiser.

Q162 — (b) l'entropie croisée. Cross-entropy standard.

Q163 — (c) la log-vraisemblance logistique (son négatif). Analogue direct du MLE logistique.

Q164 — (d) $w \leftarrow w - \eta\, \partial \mathcal{L}/\partial w$. Direction de plus forte réduction de la perte.

Q165 — (a) la taille du pas de mise à jour. Amplitude de chaque itération.

Q166 — (b) une divergence ou des oscillations sans convergence. Sauts au-delà du minimum.

Q167 — (c) une convergence très lente. Nombre d'itérations prohibitif.

Q168 — (d) le gradient de la perte pour chaque poids, y compris les couches profondes. Rôle exact de la backpropagation.

Q169 — (a) la règle de dérivation en chaîne. Chain rule appliquée couche par couche.

Q170 — (b) numériquement intraitable. Justification algorithmique de la backprop.

Q171 — (c) grands pas au début, pas fins près du minimum. Exploration puis convergence fine.

Q172 — (d) particulièrement exposé. Grande capacité = grand risque.

Q173 — (a) désactiver aléatoirement une fraction des neurones à chaque itération. Régularisation par désactivation aléatoire.

Q174 — (b) empêcher la dépendance excessive à un neurone particulier. Robustesse et anti-surapprentissage.

Q175 — (c) la norme des poids ($\ell 1/\ell 2$). Même esprit que le chapitre 14.

Q176 — (d) Oui, comme en boosting. Surveillance de la validation.

Q177 — (a) validation croisée. Hyperparamètre comme les autres.

Q178 — (b) analogue : taille du pas itératif. Analogie conceptuelle entre les deux.

Q179 — (c) le surapprentissage, comme M trop grand en boosting. Parallèle direct avec le boosting.

Q180 — (d) descente de gradient avec gradient calculé par rétropropagation. Synthèse du bloc.

Thème 10 --- Comparaison, applications et synthèse

Q181 — (a) son interprétabilité directe (odds ratios). Lecture économique directe.

Q182 — (b) sa flexibilité représentationnelle supérieure. Relations non linéaires complexes.

Q183 — (c) le réseau de neurones. Nombre de paramètres bien supérieur.

Q184 — (d) la régression logistique. Décennies d'usage réglementaire.

Q185 — (a) volume important, interactions complexes, interprétabilité non bloquante. Conditions cumulatives du gain.

Q186 — (b) souvent modeste. Constat empirique récurrent.

Q187 — (c) les réseaux de neurones ou ensembles. Volume et complexité favorisent les modèles flexibles.

Q188 — (d) les réseaux de neurones conviennent (traitement du langage). Données non tabulaires.

Q189 — (a) le trading algorithmique. Application citée du chapitre.

Q190 — (b) la prédiction binaire (logistique) et son extension neuronale, avec l'évaluation. Position dans le curriculum.

Q191 — (c) à tout modèle de classification (arbres, forêts, boosting, réseaux). Outils d'évaluation transversaux.

Q192 — (d) équilibrer flexibilité, interprétabilité et surapprentissage. Continuité conceptuelle.

Q193 — (a) de la performance, des contraintes réglementaires et du volume de données. Décision multicritère.

Q194 — (b) ses millions de poids interconnectés n'ont pas d'équivalent à un coefficient lisible. Absence de coefficient lisible unique.

Q195 — (c) automatiquement via ses couches cachées. Apprentissage automatique des interactions.

Q196 — (d) seulement si elles sont ajoutées explicitement comme variables croisées. Spécification manuelle nécessaire.

Q197 — (a) architecture, taux d'apprentissage et régularisation. Hyperparamètres multiples et interdépendants.

Q198 — (b) une application phare du chapitre. Application citée explicitement.

Q199 — (c) Non, le choix dépend du contexte. Pas de hiérarchie absolue.

Q200 — (d) prédire une catégorie, de la logistique interprétable au réseau flexible, avec évaluation rigoureuse. Synthèse générale du chapitre.
