FRM® Part I · Quantitative Analysis

Book 2 · Quantitative Analysis

Révision transversale

Synthèse intégrale des 15 chapitres

Probabilités · Distributions · Inférence · Régression · Séries temporelles · Simulation · Machine Learning

Document de révision finale --- 15 chapitres

Fiches de synthèse · définitions · formulaire complet · 210 études de cas transversales · conseils méthodologiques · 210 QCM commentés

Support d'étude --- questions de style examen, originales

(GARP ne publie aucune annale ; aucune question n'est attribuée à une session passée)

Palette navy • orange • steel --- pipeline XeLaTeX

Contents

Partie 0 — Architecture du Book 2 **3**
0.1 — Les cinq blocs logiques . . . 3
0.2 — Les six fils conducteurs transversaux . . . 3
0.3 — Carte des dépendances entre chapitres . . . 4
0.4 — Conventions de notation du Book 2 . . . 5

Partie A — Les 15 fiches de synthèse **6**
Fiche 1 — Fundamentals of Probability . . . 6
Fiche 2 — Random Variables . . . 7
Fiche 3 — Common Univariate Random Variables . . . 7
Fiche 4 — Multivariate Random Variables . . . 8
Fiche 5 — Sample Moments . . . 9
Fiche 6 — Hypothesis Testing . . . 10
Fiche 7 — Linear Regression . . . 11
Fiche 8 — Regression with Multiple Explanatory Variables . . . 11
Fiche 9 — Regression Diagnostics . . . 12
Fiche 10 — Stationary Time Series . . . 13
Fiche 11 — Non-Stationary Time Series . . . 14
Fiche 12 — Measuring Returns, Volatility, and Correlation . . . 15
Fiche 13 — Simulation and Bootstrapping . . . 15
Fiche 14 — Machine Learning Methods . . . 16
Fiche 15 — Machine Learning and Prediction . . . 17

Partie B — Formulaire consolidé du Book 2 **18**
B.1 — Probabilités et variables aléatoires (ch. 1-4) . . . 18
B.2 — Inférence (ch. 5-6) . . . 19
B.3 — Régression (ch. 7-9) . . . 19
B.4 — Séries temporelles et volatilité (ch. 10-12) . . . 19
B.5 — Simulation et machine learning (ch. 13-15) . . . 20

Partie C — Méthodologie et stratégie d'examen **20**
C.1 — Les vingt pièges les plus coûteux du Book 2 . . . 20
C.2 — Les réflexes de résolution par type de question . . . 21
C.3 — Les valeurs numériques à connaître par cœur . . . 21
C.4 — Plan de révision des dernières semaines . . . 22

Partie D — 210 études de cas transversales **22**
Thème 1 — Probabilités, Bayes et variables aléatoires (ch. 1-2) . . . 22
Thème 2 — Distributions et leur choix (ch. 3) . . . 24
Thème 3 — Dépendance, covariance et portefeuille (ch. 4) . . . 26
Thème 4 — Estimation, TCL et propriétés des estimateurs (ch. 5) . . . 27
Thème 5 — Tests d'hypothèses et erreurs de décision (ch. 6) . . . 29
Thème 6 — Régression simple et multiple (ch. 7-8) . . . 30
Thème 7 — Diagnostics et violations d'hypothèses (ch. 9) . . . 32
Thème 8 — Séries temporelles stationnaires et non stationnaires (ch. 10-11) . . . 34
Thème 9 — Rendements, volatilité, corrélation et VaR (ch. 12) . . . 35
Thème 10 — Simulation, bootstrap et machine learning (ch. 13-15) . . . 37

Partie E — 210 QCM d'examen sur le Book 2 **38**
Thème 1 — Fondamentaux de probabilité (ch. 1) . . . 39
Thème 2 — Variables aléatoires et moments (ch. 2) . . . 41
Thème 3 — Lois univariées usuelles (ch. 3) . . . 43
Thème 4 — Lois multivariées et dépendance (ch. 4) . . . 45
Thème 5 — Moments d'échantillon et estimation (ch. 5) . . . 47

Thème 6 — Tests d'hypothèses (ch. 6) . . . 49
Thème 7 — Régression linéaire simple (ch. 7) . . . 51
Thème 8 — Régression multiple (ch. 8) . . . 53
Thème 9 — Diagnostics de régression (ch. 9) . . . 55
Thème 10 — Séries temporelles stationnaires (ch. 10) . . . 57
Thème 11 — Séries non stationnaires (ch. 11) . . . 59
Thème 12 — Rendement, volatilité, corrélation (ch. 12) . . . 61
Thème 13 — Simulation et bootstrap (ch. 13) . . . 63
Thème 14 — Méthodes de machine learning (ch. 14) . . . 65
Thème 15 — ML et prédiction (ch. 15) . . . 67

Partie F — Corrigé commenté des 210 QCM **69**
Thème 1 — Fondamentaux de probabilité (ch. 1) . . . 70
Thème 2 — Variables aléatoires et moments (ch. 2) . . . 70
Thème 3 — Lois univariées usuelles (ch. 3) . . . 70
Thème 4 — Lois multivariées et dépendance (ch. 4) . . . 71
Thème 5 — Moments d'échantillon et estimation (ch. 5) . . . 71
Thème 6 — Tests d'hypothèses (ch. 6) . . . 72
Thème 7 — Régression linéaire simple (ch. 7) . . . 72
Thème 8 — Régression multiple (ch. 8) . . . 73
Thème 9 — Diagnostics de régression (ch. 9) . . . 73
Thème 10 — Séries temporelles stationnaires (ch. 10) . . . 74
Thème 11 — Séries non stationnaires (ch. 11) . . . 74
Thème 12 — Rendement, volatilité, corrélation (ch. 12) . . . 75
Thème 13 — Simulation et bootstrap (ch. 13) . . . 75
Thème 14 — Méthodes de machine learning (ch. 14) . . . 76
Thème 15 — ML et prédiction (ch. 15) . . . 76

Partie 0 --- Architecture du Book 2

Avant toute révision chapitre par chapitre, il est décisif de comprendre **comment les quinze chapitres s'emboîtent**. Le Book 2 n'est pas une collection de sujets indépendants : c'est une progression construite, où chaque bloc fournit les outils du suivant. Une question d'examen mobilise très souvent deux ou trois chapitres simultanément — d'où l'importance de cette vision d'ensemble.

Poids du Book 2 à l'examen

Quantitative Analysis représente **20%** de l'examen FRM Part I, soit environ **20 questions sur 100**. C'est un poids identique à Foundations of Risk Management, et inférieur à Financial Markets and Products (30%) et Valuation and Risk Models (30%). Malgré son nom, le Book 2 comporte une part substantielle de questions **conceptuelles** (interprétation, choix de méthode, diagnostic) et non purement calculatoires — une répartition qu'il faut anticiper dans la préparation.

0.1 --- Les cinq blocs logiques

Bloc	Chapitres	Question centrale et rôle
I. Fondations probabilistes	1 — 4	*Comment décrire l'incertitude ?* Événements, variables aléatoires, distributions usuelles, dépendance entre plusieurs variables. Aucun modèle de risque ne se construit sans ce socle.
II. Inférence statistique	5 — 6	*Que peut-on conclure d'un échantillon ?* Estimation des moments, propriétés des estimateurs, tests d'hypothèses. Le pont entre la théorie (bloc I) et les données réelles.
III. Régression	7 — 9	*Comment relier des variables entre elles ?* Régression simple, multiple, puis diagnostics des hypothèses violées. Le modèle le plus utilisé de toute la finance quantitative.
IV. Dynamique temporelle	10 — 12	*Comment modéliser ce qui évolue dans le temps ?* Séries stationnaires, non stationnaires, puis mesure des rendements, de la volatilité et des corrélations.
V. Méthodes computationnelles	13 — 15	*Que faire quand l'analytique ne suffit plus ?* Simulation et bootstrap, puis machine learning (méthodes, puis prédiction). Les outils modernes du praticien.

0.2 --- Les six fils conducteurs transversaux

Six idées traversent le Book 2 de bout en bout. Les reconnaître transforme une révision fragmentée en compréhension unifiée.

Fil 1 --- Population vs échantillon

Toute la statistique repose sur cette distinction : les **paramètres** (population, inconnus, notés en grec : μ, σ, β, ρ) sont estimés par des **statistiques** (échantillon, calculables, notées avec un chapeau ou en latin : $\bar{x}$, s, $\hat{\beta}$, r). Ce fil part du chapitre 5 (moments d'échantillon), structure les chapitres 6 à 9 (tests, régression) et culmine au chapitre 13 (le bootstrap, qui traite l'échantillon *comme* la population).

Fil 2 --- Le rôle central de la loi normale... et de ses limites

La loi normale (chapitre 3) est omniprésente : par le théorème central limite (chapitre 5), elle justifie les tests (chapitre 6), l'inférence sur les coefficients de régression (chapitres 7-9) et la VaR paramétrique (chapitre 12). Mais le Book 2 insiste tout autant sur ses **échecs** : queues épaisses des rendements financiers, asymétrie, régimes de crise — motivant les distributions alternatives (Student, chapitre 3), les mesures robustes, et les approches par simulation (chapitre 13).

Fil 3 --- Le compromis biais-variance

Explicite au chapitre 14 (machine learning), ce compromis était déjà présent bien avant : le choix du nombre de variables en régression multiple (chapitre 8), le nombre de retards d'un modèle AR (chapitre 10), la fenêtre d'une volatilité glissante (chapitre 12), le degré de lissage d'un estimateur. Partout, la même tension : un modèle trop simple manque le signal, un modèle trop complexe capture le bruit.

Fil 4 --- Hypothèses, violations, remèdes

Le schéma se répète méthodiquement : on pose des hypothèses (Gauss-Markov, chapitre 7), on identifie leurs violations (hétéroscédasticité, autocorrélation, multicolinéarité, chapitre 9), puis on applique des remèdes (erreurs-types robustes, transformation, régularisation). Le même schéma vaut pour la stationnarité (chapitre 11 : tester, puis différencier) et pour les modèles de volatilité (chapitre 12).

Fil 5 --- La dépendance sous toutes ses formes

Corrélation linéaire (chapitre 4), autocorrélation temporelle (chapitre 10), corrélation conditionnelle et dynamique (chapitre 12), colinéarité entre variables explicatives (chapitre 9), corrélation entre arbres d'une forêt (chapitre 14) : la dépendance est mesurée, exploitée, ou combattue selon le contexte — mais toujours au centre.

Fil 6 --- Du modèle fermé au modèle numérique

La progression finale du Book 2 : quand une solution analytique existe (chapitres 1-12), on l'utilise ; quand elle n'existe plus (portefeuilles complexes, options exotiques, distributions inconnues), on simule (chapitre 13) ; quand la forme fonctionnelle elle-même est inconnue, on l'apprend des données (chapitres 14-15). Trois régimes de modélisation, à mobiliser selon le problème.

0.3 --- Carte des dépendances entre chapitres

Chapitre	Prérequis directs	Alimente ensuite
1. Probabilité	—	2, 3, 4 (tout le reste)
2. Variables aléatoires	1	3, 4, 5
3. Lois univariées	2	5, 6, 12, 13
4. Lois multivariées	2, 3	7, 8, 12
5. Moments d'échantillon	3	6, 7, 12
6. Tests d'hypothèses	5	7, 8, 9, 11
7. Régression simple	4, 5, 6	8, 9, 10
8. Régression multiple	7	9, 14, 15
9. Diagnostics	7, 8	10, 11, 12

Chapitre	Prérequis directs	Alimente ensuite
10. Séries stationnaires	7, 9	11, 12
11. Séries non stationnaires	6, 10	12
12. Rendements, volatilité, corrélation	3, 5, 10	13
13. Simulation et bootstrap	3, 5, 12	14
14. Méthodes de ML	8, 9, 13	15
15. ML et prédiction	7, 8, 14	—

Lecture de la carte : les trois chapitres pivots

Trois chapitres concentrent le plus de dépendances entrantes et sortantes — ce sont les **points de passage obligés** de toute révision : le **chapitre 3** (lois univariées), sans lequel ni l'inférence ni la simulation ne fonctionnent ; le **chapitre 6** (tests d'hypothèses), mobilisé dans tous les chapitres de régression et de séries temporelles ; et le **chapitre 7-8** (régression), socle direct des chapitres 9 à 15. Si le temps de révision est limité, ces trois blocs rapportent le plus.

0.4 --- Conventions de notation du Book 2

Symbole	Signification	Remarque
μ, σ^2, σ	Moyenne, variance, écart-type de population	Paramètres inconnus
$\bar{x}$, s^2, s	Moyenne, variance, écart-type d'échantillon	Statistiques calculables
ρ vs r	Corrélation de population vs d'échantillon	Même distinction
β_j vs $\hat{\beta}_j$	Coefficient vrai vs estimé	Le chapeau = estimation
$\mathbb{E}[X]$, $\mathrm{Var}(X)$	Espérance, variance	Opérateurs
ε_i vs e_i	Erreur (non observable) vs résidu (observable)	Distinction cruciale au ch. 9
H_0, H_1	Hypothèse nulle, alternative	Ch. 6
α, p	Seuil de signification, p-valeur	Ne pas confondre
λ	Paramètre de régularisation (ch. 14-15)	Aussi paramètre de Poisson (ch. 3) : le contexte tranche
ϕ, θ	Coefficients AR et MA	Ch. 10-11
$\Phi(\cdot)$	Fonction de répartition normale centrée réduite	À ne pas confondre avec ϕ (AR)

Trois confusions de notation à éliminer avant l'examen

(i) ε **vs** e : l'erreur ε_i est la déviation vraie, inobservable ; le résidu $e_i = y_i - \hat{y}_i$ est son estimation observable. Tous les diagnostics du chapitre 9 se font sur les *résidus*, pour inférer sur les *erreurs*. **(ii)** α **vs** p : α est choisi *avant* le test (5%, 1%) ; la p-valeur est *calculée* à partir des données. On rejette si $p < \alpha$. **(iii)** σ **vs** s **vs erreur-type** : σ est la dispersion de population, s celle de l'échantillon, et l'erreur-type $s/\sqrt{n}$ est la dispersion de la

moyenne d'échantillon — trois quantités différentes, systématiquement confondues sous pression.

Partie A --- Les 15 fiches de synthèse

Chaque fiche suit une structure constante : **l'essentiel** (l'idée directrice), **définitions clés**, **formules**, **pièges**, et **liens transversaux**. À réviser dans l'ordre une première fois, puis à consulter ponctuellement.

Fiche 1 --- Fundamentals of Probability

L'essentiel

Le socle axiomatique de tout le Book 2 : décrire l'incertitude par des **événements** et leurs probabilités, puis **mettre à jour** ces probabilités quand une information nouvelle arrive (Bayes). Sans ce chapitre, aucun modèle de risque n'a de fondement.

Concepts fondamentaux

Un **espace d'événements** est l'ensemble des résultats possibles. Deux événements sont **mutuellement exclusifs** s'ils ne peuvent survenir ensemble ($P(A \cap B) = 0$) ; ils sont **indépendants** si la réalisation de l'un n'informe pas sur l'autre ($P(A \cap B) = P(A)P(B)$). Ces deux notions sont **distinctes** et souvent confondues.

Règles de probabilité

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \qquad \text{(règle d'addition)}$$

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \qquad \text{(probabilité conditionnelle, } P(B) > 0\text{)}$$

$$P(A \cap B) = P(A \mid B)\, P(B) \qquad \text{(règle de multiplication)}$$

Théorème de Bayes

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}, \qquad P(B) = \sum_i P(B \mid A_i) P(A_i) \text{ (probabilité totale).}$$

Pièges classiques

(i) Confondre mutuellement exclusifs et indépendants : deux événements mutuellement exclusifs de probabilité non nulle sont en réalité *fortement dépendants* (si l'un survient, l'autre est impossible). **(ii)** Inverser le conditionnement : $P(A \mid B) \neq P(B \mid A)$ — l'erreur du procureur, source d'erreurs massives en scoring et en détection de fraude. **(iii)** Oublier la probabilité a priori dans Bayes : un test très fiable appliqué à un événement très rare produit majoritairement des faux positifs.

Liens transversaux

→ Ch. 2-4 (variables aléatoires construites sur ces axiomes) ; → Ch. 15 (le raisonnement bayésien éclaire pourquoi la précision d'un classifieur s'effondre sur classes rares : c'est exactement le paradoxe des faux positifs).

Fiche 2 --- Random Variables

L'essentiel

Passer des événements aux **nombres** : une variable aléatoire associe une valeur numérique à chaque résultat, ce qui permet de calculer des espérances, des variances, et donc de *quantifier* le risque.

Fonctions caractérisant une variable aléatoire

La **fonction de masse** (PMF, cas discret) donne $P(X = x)$; la **fonction de densité** (PDF, cas continu) donne une densité dont l'intégrale sur un intervalle donne la probabilité ; la **fonction de répartition** (CDF) donne $F(x) = P(X \leq x)$, définie dans les deux cas et toujours croissante de 0 à 1.

Espérance et variance

$$\mathbb{E}[X] = \sum_i x_i P(x_i) \text{ (discret)}, \qquad \mathbb{E}[X] = \int x f(x)\, dx \text{ (continu)}$$

$$\text{Var}(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

$$\mathbb{E}[aX+b] = a\,\mathbb{E}[X] + b, \qquad \text{Var}(aX+b) = a^2\,\text{Var}(X)$$

Les quatre moments de population

$$\mu = \mathbb{E}[X]\ (1^{\text{er}}), \quad \sigma^2\ (2^{\text{e}}), \quad \text{Asymétrie} = \mathbb{E}\left[\left(\tfrac{X-\mu}{\sigma}\right)^3\right], \quad \text{Kurtosis} = \mathbb{E}\left[\left(\tfrac{X-\mu}{\sigma}\right)^4\right].$$

Pièges classiques

(i) La variance n'est pas linéaire : $\text{Var}(aX+b) = a^2\text{Var}(X)$ — le b disparaît, le a est au carré. **(ii)** Kurtosis vs excès de kurtosis : la normale a une kurtosis de 3, donc un *excès* de 0 ; les rendements financiers ont typiquement un excès positif (queues épaisses). **(iii)** Une densité peut dépasser 1 (ce n'est pas une probabilité) ; c'est l'aire sous la courbe qui est bornée par 1.

Liens transversaux

→ Ch. 3 (lois usuelles) ; → Ch. 5 (les moments d'échantillon estiment ces moments de population) ; → Ch. 12 (l'asymétrie et la kurtosis des rendements motivent les modèles au-delà de la normale).

Fiche 3 --- Common Univariate Random Variables

L'essentiel

Le catalogue des lois de référence : savoir **laquelle utiliser quand**, et connaître leurs paramètres, leurs moments et leurs relations mutuelles.

Loi	Usage typique	Moyenne	Variance
Bernoulli(p)	Défaut oui/non	p	$p(1-p)$
Binomiale(n,p)	Nb de défauts sur n	np	$np(1-p)$
Poisson(λ)	Événements rares/période	λ	λ

Loi	Usage typique	Moyenne	Variance
Uniforme(a,b)	Ignorance, tirage RNG	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normale(μ,σ^2)	Rendements agrégés, TCL	μ	σ^2
Log-normale	Prix d'actifs (>0)	$e^{\mu+\sigma^2/2}$	—
Student-t_ν	Queues épaisses, petits n	0 $(\nu>1)$	$\frac{\nu}{\nu-2}$ $(\nu>2)$
Chi-deux$_\nu$	Tests de variance	ν	2ν
Exponentielle(λ)	Temps d'attente	$1/\lambda$	$1/\lambda^2$

Standardisation et loi normale

$$Z=\frac{X-\mu}{\sigma}\sim\mathcal{N}(0,1);\qquad P(|Z|<1)\approx 68\%,\ P(|Z|<1.96)\approx 95\%,\ P(|Z|<2.58)\approx 99\%.$$

Quantiles unilatéraux usuels : $z_{0.95}=1.645,\quad z_{0.99}=2.326.$

Pièges classiques

(i) Confondre quantile unilatéral et bilatéral : la VaR à 95% utilise 1.645 (unilatéral), pas 1.96 (bilatéral). **(ii)** Confondre normale et log-normale : si $\ln(X)$ est normal, alors X est log-normal — le prix est log-normal, le *rendement log* est normal. **(iii)** Oublier que la Student converge vers la normale quand $\nu\to\infty$, et qu'elle a des queues plus épaisses pour ν petit. **(iv)** Pour la Poisson, moyenne *et* variance valent λ — une propriété testée.

Liens transversaux

→ Ch. 5-6 (la Student sert aux tests en petit échantillon, le chi-deux aux tests de variance) ; → Ch. 12 (VaR paramétrique) ; → Ch. 13 (toute simulation part de tirages uniformes transformés en la loi voulue).

Fiche 4 --- Multivariate Random Variables

L'essentiel

Passer d'une variable à **plusieurs**, et surtout mesurer leur **dépendance** — l'ingrédient qui fait la diversification d'un portefeuille et le risque de concentration.

Covariance et corrélation

$$\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]=\mathbb{E}[XY]-\mu_X\mu_Y$$

$$\rho_{XY}=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}\in[-1,1]$$

Variance d'une combinaison linéaire

$$\mathrm{Var}(aX+bY)=a^2\sigma_X^2+b^2\sigma_Y^2+2ab\,\mathrm{Cov}(X,Y)$$

$$\mathrm{Var}\left(\sum_i w_i X_i\right) = \sum_i \sum_j w_i w_j \,\mathrm{Cov}(X_i, X_j)$$

Pièges classiques

(i) Corrélation nulle n'implique **pas** indépendance (elle ne capte que la dépendance *linéaire*) ; l'inverse est vrai : indépendance ⇒ corrélation nulle. **(ii)** Oublier le facteur 2 dans le terme croisé de la variance d'une somme. **(iii)** Confondre covariance (non bornée, dépend des unités) et corrélation (bornée, sans unité). **(iv)** L'espérance est toujours linéaire ($\mathbb{E}[X+Y] = \mathbb{E}[X] + \mathbb{E}[Y]$, même si dépendantes), la variance ne l'est *pas*.

Liens transversaux

→ Ch. 7-8 (la régression exploite la covariance : $\hat{\beta}_1 = \mathrm{Cov}(X,Y)/\mathrm{Var}(X)$) ; → Ch. 12 (corrélations dynamiques, matrice de covariance de portefeuille) ; → Ch. 14 (décorrélation des arbres dans une forêt aléatoire).

Fiche 5 --- Sample Moments

L'essentiel

Le pont entre théorie et données : estimer les paramètres inconnus à partir d'un échantillon, et comprendre les **propriétés** de ces estimateurs (biais, efficacité, convergence).

Estimateurs et leurs propriétés

$$\bar{x} = \frac{1}{n}\sum_i x_i, \qquad s^2 = \frac{1}{n-1}\sum_i (x_i - \bar{x})^2 \text{ (non biaisé)}$$

$$\mathbb{E}[\bar{x}] = \mu, \qquad \mathrm{Var}(\bar{x}) = \frac{\sigma^2}{n}, \qquad \text{erreur-type} = \frac{s}{\sqrt{n}}$$

Théorème central limite (TCL)

$$\bar{x} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{quand } n \to \infty, \text{ quelle que soit la loi de } X \ (\sigma^2 < \infty).$$

Propriétés d'un bon estimateur

Sans biais : $\mathbb{E}[\hat{\theta}] = \theta$. **Efficace** : variance minimale parmi les estimateurs sans biais. **Convergent** (consistant) : $\hat{\theta} \to \theta$ quand $n \to \infty$. **BLUE** : le meilleur estimateur linéaire sans biais — notion centrale au chapitre 7.

Pièges classiques

(i) Le $n-1$ au dénominateur de s^2 (correction de Bessel) : diviser par n produit un estimateur *biaisé* à la baisse. **(ii)** Confondre σ (dispersion des observations) et $\sigma/\sqrt{n}$ (dispersion de la moyenne) — la seconde décroît avec n, pas la première. **(iii)** Croire que le TCL rend les *données* normales : il concerne la distribution de la *moyenne*, pas des observations individuelles. **(iv)** Un estimateur sans biais n'est pas nécessairement le

meilleur (arbitrage biais-variance, cf. Ridge au ch. 14).

Liens transversaux

→ Ch. 6 (les tests reposent sur l'erreur-type) ; → Ch. 7-9 (propriétés BLUE des MCO) ; → Ch. 13 (le bootstrap estime la distribution d'échantillonnage sans hypothèse de loi) ; → Ch. 14 (le biais-variance revisité).

Fiche 6 --- Hypothesis Testing

L'essentiel

Décider, sous incertitude, si une affirmation sur la population est compatible avec les données observées — et quantifier le risque de se tromper.

Statistique de test et intervalle de confiance

$$t = \frac{\hat{\theta} - \theta_0}{\text{erreur-type}(\hat{\theta})}; \qquad \text{IC à } (1-\alpha) : \hat{\theta} \pm t_{\alpha/2} \times \text{erreur-type}.$$

Notion	Définition	Contrôle
Erreur de type I	Rejeter H_0 vraie (faux positif)	Fixée par α
Erreur de type II	Ne pas rejeter H_0 fausse (faux négatif)	Probabilité β
Puissance	$1-\beta$: détecter un effet réel	Augmente avec n
p-valeur	Probabilité d'observer un résultat au moins aussi extrême si H_0 vraie	Rejeter si $p < \alpha$

Pièges classiques

(i) « Ne pas rejeter H_0 » n'est **pas** « accepter H_0 » : c'est une absence de preuve, pas une preuve d'absence. **(ii)** La p-valeur n'est *pas* la probabilité que H_0 soit vraie — c'est une probabilité *conditionnelle à* H_0 vraie. **(iii)** Significativité statistique $\neq$ importance économique : avec n très grand, un effet minuscule devient significatif. **(iv)** Baisser α réduit le risque de type I mais *augmente* celui de type II — arbitrage inévitable à n fixé.

Liens transversaux

→ Ch. 7-9 (tests de significativité des coefficients, test F global, tests de diagnostic) ; → Ch. 11 (tests de racine unitaire) ; → Ch. 15 (l'arbitrage type I/type II est *exactement* l'arbitrage précision/rappel d'un classifieur — même structure, vocabulaire différent).

Fiche 7 --- Linear Regression

L'essentiel

Le modèle central de toute la finance quantitative : relier une variable expliquée à une variable explicative par une droite estimée en minimisant les carrés des écarts.

Modèle et estimateurs MCO

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i; \qquad \hat{\beta}_1 = \frac{\text{Cov}(x,y)}{\text{Var}(x)} = r_{xy}\frac{s_y}{s_x}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Décomposition de la variance et R^2

$$\underbrace{\sum (y_i - \bar{y})^2}_{SCT} = \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{SCE} + \underbrace{\sum (y_i - \hat{y}_i)^2}_{SCR}; \qquad R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

Hypothèses de Gauss-Markov (MCO = BLUE)

Linéarité des paramètres ; espérance nulle des erreurs ($\mathbb{E}[\varepsilon \mid x] = 0$) ; **homoscédasticité** (variance constante) ; **absence d'autocorrélation** des erreurs ; variable explicative non constante et non corrélée à l'erreur. Sous ces hypothèses, les MCO sont **BLUE**. La normalité des erreurs n'est *pas* nécessaire pour BLUE — elle l'est pour les tests exacts en petit échantillon.

Pièges classiques

(i) En régression simple, $R^2 = r_{xy}^2$ — mais cette égalité *tombe* en régression multiple. **(ii)** Corrélation n'est pas causalité : un R^2 élevé ne prouve aucune relation causale. **(iii)** Confondre erreur ε_i (inobservable) et résidu e_i (calculé). **(iv)** Un R^2 faible n'invalide pas le modèle : en finance, expliquer 5% de la variance des rendements quotidiens peut être très exploitable.

Liens transversaux

→ Ch. 4 (le coefficient s'exprime par la covariance) ; → Ch. 6 (test de significativité de $\hat{\beta}_1$) ; → Ch. 8-9 (extension multiple et diagnostics) ; → Ch. 15 (la régression logistique en est l'extension au cas binaire).

Fiche 8 --- Regression with Multiple Explanatory Variables

L'essentiel

Généraliser la régression à plusieurs variables explicatives, en interprétant chaque coefficient **toutes choses égales par ailleurs**, et en arbitrant entre pouvoir explicatif et parcimonie.

Modèle multiple et R^2 ajusté

$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + \varepsilon_i; \qquad \hat{\beta} = (X^\top X)^{-1} X^\top y$$

$$\bar{R}^2 = 1 - \frac{SCR/(n-k-1)}{SCT/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}$$

Test F de significativité globale

$$F = \frac{SCE/k}{SCR/(n-k-1)} \sim F_{k,\,n-k-1} \quad \text{sous } H_0 : \beta_1 = \cdots = \beta_k = 0.$$

Pièges classiques

(i) Le R^2 ne *peut jamais* baisser quand on ajoute une variable, même sans pertinence — d'où la nécessité du R^2 ajusté, qui peut décroître. **(ii)** Interpréter un coefficient sans le « toutes choses égales par ailleurs » : β_j mesure l'effet de x_j *à autres variables constantes*. **(iii)** Confondre le test t (une variable) et le test F (toutes conjointement) : en présence de multicolinéarité forte, on peut avoir un F significatif avec *aucun* t significatif. **(iv)** Le biais de variable omise : omettre une variable corrélée à la fois à y et à un x inclus biaise le coefficient de ce dernier.

Liens transversaux

→ Ch. 9 (diagnostics, dont la multicolinéarité qui naît ici) ; → Ch. 14 (le R^2 toujours croissant est exactement le problème que Ridge/Lasso et la validation croisée résolvent) ; → Ch. 15 (encodage catégoriel et trappe des indicatrices).

Fiche 9 --- Regression Diagnostics

L'essentiel

Que se passe-t-il quand les hypothèses de Gauss-Markov sont **violées** ? Identifier le problème, comprendre sa conséquence exacte, appliquer le bon remède. Le chapitre le plus « diagnostique » du Book 2.

Problème	Conséquence	Détection	Remède
Hétéroscédasticité	$\hat{\beta}$ reste sans biais, mais erreurs-types biaisées	Test de White, Breusch-Pagan ; graphique des résidus	Erreurs-types robustes (White)
Autocorrélation	Idem : $\hat{\beta}$ sans biais, inférence invalide	Durbin-Watson, Breusch-Godfrey	Erreurs-types Newey-West
Multicolinéarité	$\hat{\beta}$ sans biais mais *instables*, erreurs-types gonflées	VIF élevé ; F significatif sans t significatif	Retirer/combiner variables, Ridge, ACP
Variable omise	$\hat{\beta}$ **biaisé** (biais de spécification)	Théorie économique, résidus structurés	Inclure la variable
Valeurs aberrantes	Influence disproportionnée	Distance de Cook, effet levier	Vérifier, robustifier

Facteur d'inflation de la variance (VIF)

$$\text{VIF}_j = \frac{1}{1-R_j^2}, \qquad R_j^2 = R^2 \text{ de la régression de } x_j \text{ sur les autres explicatives.}$$

$$\text{VIF} > 5 \text{ à } 10 \Rightarrow \text{multicolinéarité préoccupante.}$$

Pièges classiques

(i) L'erreur la plus fréquente : croire que l'hétéroscédasticité ou l'autocorrélation *biaisent* les coefficients. Elles ne le font **pas** — elles invalident les *erreurs-types*, donc les tests. Seule la variable omise (et l'endogénéité) biaise $\hat{\beta}$. **(ii)** La multicolinéarité parfaite empêche l'estimation ; la multicolinéarité forte mais imparfaite la rend seulement instable. **(iii)** Durbin-Watson : une valeur proche de 2 signale l'absence d'autocorrélation d'ordre 1 ; proche de 0, autocorrélation positive ; proche de 4, négative.

Liens transversaux

→ Ch. 10-12 (l'autocorrélation devient l'objet d'étude, non le problème) ; → Ch. 14 (Ridge comme remède structurel à la multicolinéarité) ; → Ch. 12 (l'hétéroscédasticité des rendements devient le sujet des modèles GARCH).

Fiche 10 --- Stationary Time Series

L'essentiel

Modéliser une variable dont la valeur d'aujourd'hui dépend de son propre passé — à condition que ses propriétés statistiques soient **stables dans le temps** (stationnarité).

Stationnarité au sens faible

Une série est **stationnaire au sens faible** si sa **moyenne** et sa **variance** sont constantes dans le temps, et si sa **covariance** entre deux dates ne dépend que de l'écart entre elles (le retard), pas de la date elle-même.

Modèles AR, MA et ARMA

$$\mathrm{AR}(p) : y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

$$\mathrm{MA}(q) : y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

$$\mathrm{AR}(1) \text{ stationnaire} \iff |\phi_1| < 1; \qquad \mathbb{E}[y_t] = \frac{c}{1-\phi_1}, \quad \mathrm{Var}(y_t) = \frac{\sigma_\varepsilon^2}{1-\phi_1^2}.$$

Identification par ACF et PACF

L'**autocorrélogramme** (ACF) et l'autocorrélogramme **partiel** (PACF) permettent d'identifier le modèle : un **AR**(p) présente une PACF qui se coupe nettement après le retard p et une ACF qui décroît progressivement ; un **MA**(q) présente le schéma inverse (ACF coupée après q, PACF décroissante). Les critères d'information (AIC, BIC) départagent ensuite les candidats, le BIC pénalisant plus fortement la complexité.

Pièges classiques

(i) Inverser ACF et PACF dans l'identification — l'erreur la plus courante du chapitre. **(ii)** Croire que la stationnarité concerne les *valeurs* ; elle concerne les *propriétés statistiques*. **(iii)** Oublier la condition $|\phi_1| < 1$: à $\phi_1 = 1$, le processus devient une marche aléatoire (chapitre 11). **(iv)** AIC vs BIC : le BIC sélectionne des modèles plus parcimonieux ; l'AIC privilégie la prédiction.

Liens transversaux

→ Ch. 9 (l'autocorrélation, ici modélisée plutôt que corrigée) ; → Ch. 11 (que faire quand $|\phi_1| = 1$) ; → Ch. 12 (les modèles de volatilité sont des structures autorégressives sur la variance).

Fiche 11 --- Non-Stationary Time Series

L'essentiel

Que faire quand la série **dérive** : tendance, saisonnalité, ou racine unitaire. Détecter la non-stationnarité, la traiter correctement, et éviter le piège de la régression fallacieuse.

Marche aléatoire et différenciation

$$\text{Marche aléatoire : } y_t = y_{t-1} + \varepsilon_t \quad (\phi_1 = 1, \text{ racine unitaire})$$

$$\text{Différenciation d'ordre 1 : } \Delta y_t = y_t - y_{t-1} = \varepsilon_t \quad (\text{stationnaire})$$

$$\text{Marche aléatoire avec dérive : } y_t = \delta + y_{t-1} + \varepsilon_t.$$

Deux types de non-stationnarité, deux remèdes distincts

Une série **stationnaire en tendance** (*trend-stationary*, $y_t = \alpha + \beta t + \varepsilon_t$) se traite en **retirant la tendance déterministe** (régression sur t). Une série **à racine unitaire** (*difference-stationary*) se traite par **différenciation**. Appliquer le mauvais remède est une erreur classique : différencier une série trend-stationary introduit une structure MA artificielle ; retirer une tendance d'une série à racine unitaire ne la rend pas stationnaire.

Régression fallacieuse (*spurious regression*)

Régresser deux séries indépendantes mais toutes deux non stationnaires produit typiquement un R^2 élevé et un t très significatif — **sans aucune relation réelle**. Symptôme diagnostique : un R^2 élevé combiné à un Durbin-Watson très faible. C'est l'un des résultats les plus testés du chapitre. Remède : différencier, ou tester la **cointégration** (si les séries partagent une tendance stochastique commune, la régression en niveaux est alors légitime).

Pièges classiques

(i) Le test de Dickey-Fuller augmenté (ADF) a pour H_0 la **présence** d'une racine unitaire : ne pas rejeter signifie *non-stationnarité*, l'inverse de l'intuition habituelle. **(ii)** Sur-différencier une série déjà stationnaire dégrade le modèle. **(iii)** Confondre saisonnalité (cyclique, période fixe) et tendance (dérive de long terme).

Liens transversaux

→ Ch. 6 (l'ADF est un test d'hypothèse, avec l'inversion piégeuse de H_0) ; → Ch. 12 (les prix sont non stationnaires, les rendements le sont — d'où le travail sur rendements) ; → Ch. 13 (la marche aléatoire est le processus de base simulé).

Fiche 12 --- Measuring Returns, Volatility, and Correlation

L'essentiel

Le chapitre le plus directement opérationnel : comment mesurer correctement un rendement, modéliser une volatilité qui **change dans le temps**, et estimer des corrélations qui se déforment en période de crise.

Rendements

$$\text{Simple} : R_t = \frac{P_t - P_{t-1}}{P_{t-1}}; \qquad \text{Logarithmique} : r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(1 + R_t).$$

Les rendements log s'additionnent dans le temps ; les rendements simples s'agrègent sur un portefeuille.

Volatilité : EWMA et GARCH(1,1)

$$\text{EWMA} : \sigma_t^2 = \lambda\sigma_{t-1}^2 + (1-\lambda)r_{t-1}^2 \quad (\lambda \approx 0.94 \text{ en pratique, RiskMetrics})$$

$$\text{GARCH(1,1)} : \sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta\sigma_{t-1}^2; \quad \text{stationnarité} \iff \alpha + \beta < 1$$

$$\text{Variance de long terme} : \sigma_{LT}^2 = \frac{\omega}{1-\alpha-\beta}.$$

Mise à l'échelle temporelle et VaR paramétrique

$$\sigma_{T \text{ périodes}} = \sigma_{1 \text{ période}}\sqrt{T} \quad (\text{règle de la racine, sous i.i.d.})$$

$$\text{VaR}_\alpha = z_\alpha\, \sigma\, V \quad (\text{position } V, \text{ rendement moyen supposé nul}).$$

Pièges classiques

(i) La règle en $\sqrt{T}$ suppose des rendements **i.i.d.** : en présence d'autocorrélation ou de clustering de volatilité, elle sous-estime ou surestime le risque. **(ii)** EWMA est un cas particulier de GARCH avec $\omega = 0$ et $\alpha + \beta = 1$: il n'a donc *pas* de retour à une variance de long terme. **(iii)** $\alpha + \beta$ proche de 1 signale une forte persistance des chocs de volatilité. **(iv)** Les corrélations *augmentent* typiquement en période de crise — la diversification s'évapore quand on en a le plus besoin.

Liens transversaux

→ Ch. 3 (VaR paramétrique via les quantiles normaux) ; → Ch. 9-10 (GARCH répond à l'hétéroscédasticité par une structure autorégressive) ; → Ch. 13 (quand la VaR paramétrique ne suffit pas : simulation historique ou Monte-Carlo).

Fiche 13 --- Simulation and Bootstrapping

L'essentiel

Quand la solution analytique n'existe pas, on la remplace par un grand nombre de scénarios : **Monte-Carlo** (générer depuis une loi supposée) ou **bootstrap** (rééchantillonner les données observées, sans hypothèse de loi).

Précision d'une estimation Monte-Carlo

$$\text{erreur-type} = \frac{\sigma}{\sqrt{N}} \Rightarrow \text{diviser l'erreur par 2 exige de } \textbf{quadrupler } N.$$

Monte-Carlo vs bootstrap : la distinction décisive

Monte-Carlo génère des scénarios depuis une distribution *supposée connue* (paramétrique) : puissant, mais exposé au risque de modèle si la loi est mal choisie. Le **bootstrap** rééchantillonne *avec remise* les données historiques observées : aucune hypothèse de loi, il capture naturellement les queues épaisses et l'asymétrie présentes dans les données — mais il ne peut générer aucun scénario *plus extrême* que le pire déjà observé, sa limite fondamentale.

Techniques de réduction de variance

Les **variables antithétiques** (utiliser Z et $-Z$) et les **variables de contrôle** (exploiter un actif similaire de valeur analytique connue) réduisent la variance de l'estimateur *sans* augmenter N — améliorant l'efficacité de calcul à précision donnée. L'**échantillonnage stratifié** garantit une couverture représentative de l'espace des scénarios.

Pièges classiques

(i) Croire que doubler N divise l'erreur par 2 (il faut quadrupler). **(ii)** Oublier que le bootstrap **préserve** les propriétés de l'échantillon mais ne les dépasse pas — inadapté aux stress tests de scénarios inédits. **(iii)** Utiliser le bootstrap i.i.d. classique sur des données *autocorrélées* (il faut alors un bootstrap par blocs). **(iv)** Environ $1/e \approx 36.8\%$ des observations sont exclues de chaque tirage bootstrap — résultat réutilisé au chapitre 14 (OOB).

Liens transversaux

→ Ch. 3 (les tirages simulent des lois précises) ; → Ch. 5 (le bootstrap approxime la distribution d'échantillonnage) ; → Ch. 12 (VaR par simulation) ; → Ch. 14 (le bootstrap fonde le bagging et les forêts aléatoires).

Fiche 14 --- Machine Learning Methods

L'essentiel

Laisser l'algorithme **apprendre la structure** plutôt que de l'imposer — au prix d'un contrôle rigoureux du surapprentissage. Le compromis biais-variance devient ici explicite et central.

Décomposition biais-variance et régularisation

$$\mathbb{E}[(y - \hat{f})^2] = \text{Biais}^2 + \text{Var} + \sigma_\varepsilon^2$$

$$\text{Ridge} : \sum (y_i - x_i^\top \beta)^2 + \lambda \sum \beta_j^2; \qquad \text{Lasso} : \sum (y_i - x_i^\top \beta)^2 + \lambda \sum |\beta_j|.$$

Agrégation et validation croisée

$$\text{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2; \qquad \text{CV}_{(k)} = \frac{1}{k}\sum_{j=1}^{k} \text{Erreur}(\hat{f}^{(-j)}, \text{pli } j).$$

Méthode	Levier principal	Point distinctif
Ridge	Réduit la variance	Rétrécit sans jamais annuler (contrainte lisse)
Lasso	Variance + sélection	Annule des coefficients (contrainte à coins)
k-NN	Non paramétrique	Souffre du fléau de la dimension
Arbre	Interprétabilité	Instable (variance élevée)
Bagging / forêt	**Variance** (parallèle)	Décorrélation par tirage de variables
Boosting	**Biais** (séquentiel)	Chaque modèle corrige le précédent
k-means / ACP	Non supervisé	Groupes / réduction de dimension

Pièges classiques

(i) Confondre les leviers : bagging → variance (parallèle) ; boosting → biais (séquentiel). **(ii)** Croire que Ridge sélectionne des variables (il ne le fait jamais). **(iii)** Standardiser *avant* le découpage train/test (fuite de données). **(iv)** Augmenter B en forêt aléatoire ne surapprend pas ; augmenter M en boosting le peut — asymétrie systématiquement testée.

Liens transversaux

→ Ch. 8-9 (Ridge/Lasso répondent à la multicolinéarité et au R^2 toujours croissant) ; → Ch. 13 (le bootstrap fonde le bagging) ; → Ch. 5 (le biais-variance généralise les propriétés des estimateurs) ; → Ch. 15 (application à la classification).

Fiche 15 --- Machine Learning and Prediction

L'essentiel

Prédire une **catégorie** plutôt qu'un nombre : régression logistique (interprétable) et réseaux de neurones (flexibles), avec un appareil d'évaluation rigoureux (matrice de confusion, ROC/AUC) valable pour *tout* classifieur.

Régression logistique

$$P(y=1 \mid x) = \frac{1}{1+e^{-z}}, \quad z = \beta_0 + \beta_1 x_1 + \ldots ; \qquad \text{logit}(p) = \ln\frac{p}{1-p} = z$$

$$\text{odds} = \frac{p}{1-p}; \qquad \text{odds ratio} = e^{\beta_j}; \qquad \frac{\partial P}{\partial x_j} = \beta_j\, P(1-P).$$

Métriques de classification

$$\text{Précision} = \frac{VP}{VP+FP}, \quad \text{Rappel} = \frac{VP}{VP+FN}, \quad F_1 = 2 \cdot \frac{\text{Préc} \times \text{Rap}}{\text{Préc} + \text{Rap}}$$

$$\text{AUC} = P\left(\hat{P}_{\text{positif}} > \hat{P}_{\text{négatif}}\right) : \ 0.5 = \text{aléatoire}, \ 1 = \text{parfait}.$$

Encodage et réseaux de neurones --- l'essentiel à retenir

Encodage : $C-1$ indicatrices en régression (sinon trappe des variables indicatrices et colinéarité parfaite), C colonnes one-hot pour arbres et réseaux. **Réseaux** : perceptron = combinaison linéaire + activation non linéaire ; sans non-linéarité, empiler des couches est inutile (une composition de fonctions linéaires reste linéaire) ; entraînement par descente de gradient, avec gradient calculé par **rétropropagation** ; un réseau sans couche cachée à sortie sigmoïde *est* une régression logistique.

Pièges classiques

(i) Lire β_j comme un effet direct sur la probabilité : l'effet dépend de $P(1-P)$, maximal en $P=0.5$. **(ii)** Confondre odds et probabilité : odds $=3$ signifie $p=0.75$. **(iii)** Juger un classifieur à l'exactitude sur classes déséquilibrées. **(iv)** Traiter le seuil 0.5 comme une donnée : c'est un choix dicté par les coûts relatifs des erreurs. **(v)** Confondre rétropropagation (calcul du gradient) et descente de gradient (mise à jour des poids).

Liens transversaux

$\rightarrow$ Ch. 1 (Bayes explique l'effondrement de la précision sur classes rares) ; $\rightarrow$ Ch. 6 (type I/type II $\equiv$ précision/rappel) ; $\rightarrow$ Ch. 7-8 (extension de la régression) ; $\rightarrow$ Ch. 14 (régularisation, surapprentissage, validation croisée).

Partie B --- Formulaire consolidé du Book 2

Toutes les formules du Book 2 en un seul endroit, organisées par bloc. À parcourir la veille de l'examen.

B.1 --- Probabilités et variables aléatoires (ch. 1-4)

Probabilités

$$P(A\cup B)=P(A)+P(B)-P(A\cap B);\qquad P(A\mid B)=\frac{P(A\cap B)}{P(B)}$$

$$\text{Indépendance : } P(A\cap B)=P(A)P(B);\qquad \text{Bayes : } P(A\mid B)=\frac{P(B\mid A)P(A)}{P(B)}$$

Moments et opérateurs

$$\mathrm{Var}(X)=\mathbb{E}[X^2]-(\mathbb{E}[X])^2;\qquad \mathbb{E}[aX+b]=a\mathbb{E}[X]+b;\qquad \mathrm{Var}(aX+b)=a^2\mathrm{Var}(X)$$

$$\text{Asymétrie}=\mathbb{E}\left[\left(\tfrac{X-\mu}{\sigma}\right)^3\right];\qquad \text{Kurtosis}=\mathbb{E}\left[\left(\tfrac{X-\mu}{\sigma}\right)^4\right]\ (=3 \text{ pour la normale})$$

Dépendance

$$\mathrm{Cov}(X,Y)=\mathbb{E}[XY]-\mu_X\mu_Y;\qquad \rho=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}$$

$$\mathrm{Var}(aX+bY)=a^2\sigma_X^2+b^2\sigma_Y^2+2ab\,\mathrm{Cov}(X,Y)$$

Lois de référence --- moments

Bernoulli : $p,\ p(1-p)$ • Binomiale : $np,\ np(1-p)$ • Poisson : $\lambda,\ \lambda$

Uniforme(a,b) : $\frac{a+b}{2},\ \frac{(b-a)^2}{12}$ • Exponentielle : $\frac{1}{\lambda},\ \frac{1}{\lambda^2}$ • $\chi^2_\nu : \nu,\ 2\nu$

Student $t_\nu : 0,\ \frac{\nu}{\nu-2}\ (\nu>2)$ • Log-normale : $e^{\mu+\sigma^2/2}$

B.2 --- Inférence (ch. 5-6)

Estimation et TCL

$$\bar{x}=\frac{1}{n}\sum x_i; \qquad s^2=\frac{1}{n-1}\sum(x_i-\bar{x})^2; \qquad \text{Var}(\bar{x})=\frac{\sigma^2}{n}$$

$$\text{erreur-type}=\frac{s}{\sqrt{n}}; \qquad \bar{x}\xrightarrow{d}\mathcal{N}\left(\mu,\tfrac{\sigma^2}{n}\right)\ \text{(TCL)}$$

Tests et intervalles

$$t=\frac{\hat{\theta}-\theta_0}{\text{erreur-type}}; \qquad \text{IC}_{1-\alpha}:\hat{\theta}\pm t_{\alpha/2}\times\text{erreur-type}$$

Rejeter H_0 si $p<\alpha$ ou si $|t|>t_{\text{critique}}$; Puissance $=1-\beta$

B.3 --- Régression (ch. 7-9)

Estimateurs et ajustement

$$\hat{\beta}_1=\frac{\text{Cov}(x,y)}{\text{Var}(x)}=r_{xy}\frac{s_y}{s_x}; \qquad \hat{\beta}_0=\bar{y}-\hat{\beta}_1\bar{x}; \qquad \hat{\beta}=(X^\top X)^{-1}X^\top y$$

$$SCT=SCE+SCR; \qquad R^2=\frac{SCE}{SCT}=1-\frac{SCR}{SCT}; \qquad \bar{R}^2=1-(1-R^2)\frac{n-1}{n-k-1}$$

Tests et diagnostics

$$F=\frac{SCE/k}{SCR/(n-k-1)}\sim F_{k,n-k-1}; \qquad \text{VIF}_j=\frac{1}{1-R_j^2}\ (>5\text{–}10\Rightarrow\text{alerte})$$

Durbin-Watson $\approx 2\Rightarrow$ pas d'autocorrélation d'ordre 1

B.4 --- Séries temporelles et volatilité (ch. 10-12)

Modèles de séries

$$\text{AR}(p): y_t=c+\textstyle\sum_{i=1}^{p}\phi_i y_{t-i}+\varepsilon_t; \qquad \text{MA}(q): y_t=\mu+\varepsilon_t+\textstyle\sum_{j=1}^{q}\theta_j\varepsilon_{t-j}$$

$$\text{AR(1) : stationnaire} \iff |\phi_1|<1; \qquad \mathbb{E}[y_t]=\frac{c}{1-\phi_1}; \qquad \text{Var}(y_t)=\frac{\sigma_\varepsilon^2}{1-\phi_1^2}$$

Marche aléatoire : $y_t=y_{t-1}+\varepsilon_t\ (\phi_1=1)\Rightarrow$ différencier : $\Delta y_t=\varepsilon_t$

Rendements, volatilité, VaR

$$r_t = \ln(P_t/P_{t-1}) = \ln(1+R_t); \qquad \sigma_T = \sigma_1\sqrt{T} \text{ (sous i.i.d.)}$$

$$\text{EWMA} : \sigma_t^2 = \lambda\sigma_{t-1}^2 + (1-\lambda)r_{t-1}^2; \qquad \text{GARCH(1,1)} : \sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta\sigma_{t-1}^2$$

$$\text{Stationnarité GARCH} \iff \alpha+\beta<1; \qquad \sigma_{LT}^2 = \frac{\omega}{1-\alpha-\beta}; \qquad \text{VaR}_\alpha = z_\alpha\sigma V$$

B.5 --- Simulation et machine learning (ch. 13-15)

Simulation

$$\text{erreur-type MC} = \frac{\sigma}{\sqrt{N}} \Rightarrow \text{précision} \times 2 \text{ exige } N \times 4$$

Bootstrap : tirage avec remise ; $\approx 1/e \approx 36.8\%$ des observations exclues par tirage

Machine learning

$$\mathbb{E}[(y-\hat{f})^2] = \text{Biais}^2 + \text{Var} + \sigma_\varepsilon^2; \qquad \text{CV}_{(k)} = \frac{1}{k}\sum_j \text{Erreur}(\hat{f}^{(-j)}, j)$$

$$\text{Ridge} : +\lambda\sum\beta_j^2 \text{ (rétrécit)}; \qquad \text{Lasso} : +\lambda\sum|\beta_j| \text{ (sélectionne)}$$

$$\text{Var}\left(\tfrac{1}{B}\textstyle\sum_b \hat{f}_b\right) = \rho\sigma^2 + \tfrac{1-\rho}{B}\sigma^2; \qquad G_{\text{Gini}} = \textstyle\sum_c \hat{p}_c(1-\hat{p}_c)$$

Classification

$$P(y=1\mid x) = \frac{1}{1+e^{-z}}; \qquad \text{logit}(p) = \ln\frac{p}{1-p} = z; \qquad \text{odds ratio} = e^{\beta_j}$$

$$\text{Précision} = \frac{VP}{VP+FP}; \quad \text{Rappel} = \frac{VP}{VP+FN}; \quad F_1 = \frac{2\,\text{Préc}\cdot\text{Rap}}{\text{Préc}+\text{Rap}}$$

$$\text{Descente de gradient} : w \leftarrow w - \eta\frac{\partial\mathcal{L}}{\partial w}$$

Partie C --- Méthodologie et stratégie d'examen

C.1 --- Les vingt pièges les plus coûteux du Book 2

#	Piège	La bonne réponse
1	Mutuellement exclusifs = indépendants	Deux exclusifs sont *fortement dépendants*
2	$P(A\mid B) = P(B\mid A)$	Faux (erreur du procureur)
3	Oublier la probabilité a priori en Bayes	Un test fiable sur événement rare → majorité de faux positifs
4	$\text{Var}(aX+b) = a\text{Var}(X)+b$	$= a^2\text{Var}(X)$
5	Kurtosis = excès de kurtosis	Normale : kurtosis 3, excès 0
6	VaR 95% avec $z = 1.96$	$z = 1.645$ (unilatéral)

#	Piège	La bonne réponse
7	Corrélation nulle $\Rightarrow$ indépendance	Faux ; l'implication inverse est vraie
8	Oublier le facteur 2 dans $\text{Var}(aX + bY)$	$+2ab\,\text{Cov}$
9	Diviser s^2 par n	Diviser par $n - 1$
10	Le TCL rend les données normales	Il concerne la *moyenne*
11	« Ne pas rejeter » = « accepter »	Absence de preuve $\neq$ preuve d'absence
12	p-valeur $= P(H_0 \text{ vraie})$	C'est $P(\text{données} \mid H_0)$
13	$R^2 = r^2$ en régression multiple	Vrai seulement en régression *simple*
14	Hétéroscédasticité biaise $\hat{\beta}$	Elle biaise les *erreurs-types*
15	Ajouter une variable peut baisser R^2	Jamais ; seul $\bar{R}^2$ peut baisser
16	Inverser ACF et PACF	AR : PACF coupée ; MA : ACF coupée
17	ADF : rejeter = racine unitaire	H_0 *est* la racine unitaire
18	Doubler N divise l'erreur MC par 2	Il faut *quadrupler* N
19	Ridge sélectionne des variables	Jamais ; seul le Lasso le fait
20	Bagging réduit le biais	Il réduit la *variance* ; le boosting réduit le biais

C.2 --- Les réflexes de résolution par type de question

Six réflexes qui font gagner du temps

(i) Question sur une probabilité conditionnelle $\rightarrow$ écrire immédiatement la formule de Bayes et identifier a priori, vraisemblance, évidence. **(ii) Question sur une variance de portefeuille** $\rightarrow$ vérifier d'abord si le terme croisé $2ab\,\text{Cov}$ est requis. **(iii) Question de test d'hypothèse** $\rightarrow$ écrire H_0 et H_1 *avant* tout calcul, et vérifier si le test est uni- ou bilatéral. **(iv) Question de régression** $\rightarrow$ identifier si le problème porte sur l'*estimation* (biais) ou sur l'*inférence* (erreurs-types) : cette distinction résout à elle seule la majorité des questions du chapitre 9. **(v) Question de série temporelle** $\rightarrow$ vérifier la stationnarité avant toute autre considération. **(vi) Question de ML** $\rightarrow$ identifier le levier concerné : biais ou variance.

Distinguer les questions calculatoires des questions conceptuelles

Environ la moitié des questions du Book 2 ne demandent *aucun calcul* : elles testent une distinction (biais vs inefficacité, bagging vs boosting), une interprétation (que signifie ce coefficient ?) ou un choix de méthode (quelle approche pour ce problème ?). Repérer immédiatement le type de question évite de chercher un calcul là où il n'y en a pas — une source majeure de perte de temps.

C.3 --- Les valeurs numériques à connaître par cœur

Quantité	Valeur	Usage
z à 90% bilatéral / 95% unilatéral	1.645	VaR 95%, test unilatéral
z à 95% bilatéral	1.96	IC à 95%
z à 99% unilatéral	2.326	VaR 99%
z à 99% bilatéral	2.576	IC à 99%
Kurtosis de la normale	3	Excès de kurtosis $= 0$
$P(\lvert Z\rvert < 1)$	$\approx 68\%$	Règle empirique

Quantité	Valeur	Usage
λ RiskMetrics (EWMA)	0.94 (quotidien)	Volatilité
Fraction exclue par bootstrap	$1/e \approx 36.8\%$	OOB (ch. 13-14)
m typique en forêt aléatoire	$\approx \sqrt{p}$	Décorrélation
Seuil VIF d'alerte	5 à 10	Multicolinéarité
Durbin-Watson sans autocorrélation	≈ 2	Diagnostic
AUC d'un modèle aléatoire	0.5	Référence

C.4 --- Plan de révision des dernières semaines

Séquence recommandée

Semaine 1 — consolidation : parcourir les 15 fiches (Partie A) dans l'ordre, en s'arrêtant sur chaque section « pièges ». Objectif : réactiver, pas apprendre. **Semaine 2 — application** : traiter les 210 études de cas transversales (Partie D) par thème, crayon en main, sans consulter la solution avant d'avoir tenté. **Semaine 3 — conditions d'examen** : traiter les 210 QCM (Partie E) par blocs de 20 chronométrés (90 secondes par question), puis analyser *chaque* erreur en revenant à la fiche concernée. **Dernières 48 heures** : uniquement le formulaire consolidé (Partie B), le tableau des 20 pièges (C.1) et les valeurs numériques (C.3) — aucun contenu nouveau.

Gestion du temps le jour de l'examen

L'examen FRM Part I comporte 100 questions en 4 heures, soit **2.4 minutes par question** en moyenne. Les 20 questions de Quantitative Analysis ne doivent pas consommer davantage : une question de calcul de régression ou de GARCH qui résiste au-delà de 3 minutes doit être marquée et laissée de côté pour un second passage. Le coût d'opportunité est réel : trois minutes perdues sur une question difficile, c'est une question facile non traitée ailleurs.

Partie D --- 210 études de cas transversales

Chaque cas est résolu et commenté. Ils sont volontairement **transversaux** : la résolution mobilise souvent plusieurs chapitres, comme à l'examen. Travaillez crayon en main, en cachant la solution.

Thème 1 --- Probabilités, Bayes et variables aléatoires (ch. 1-2)

Cas 1. Un portefeuille contient deux obligations. P(défaut A)=4%, P(défaut B)=6%, P(les deux)=1%. Quelle est la probabilité qu'au moins une fasse défaut ?

Solution. Règle d'addition : $P(A \cup B) = 0.04 + 0.06 - 0.01 = \mathbf{9}\%$. Ne pas oublier de soustraire l'intersection, sinon on double-compte le scénario conjoint.

Cas 2. Mêmes données. Les deux défauts sont-ils indépendants ?

Solution. Si indépendants, $P(A \cap B)$ vaudrait $0.04 \times 0.06 = 0.24\%$. Or l'énoncé donne 1%, très supérieur : les défauts sont **positivement dépendants** (contagion, facteur de risque commun).

Cas 3. Un test de fraude détecte 95% des fraudes réelles et génère 2% de fausses alertes. Le taux de fraude est de 0.5%. Quelle est la probabilité qu'une transaction alertée soit réellement frauduleuse ?

Solution. Bayes : $P(F \mid A) = \frac{0.95 \times 0.005}{0.95 \times 0.005 + 0.02 \times 0.995} = \frac{0.00475}{0.00475 + 0.0199} = \mathbf{19.3}\%$. Malgré un test très performant, 4 alertes sur 5 sont fausses — le poids écrasant de la faible probabilité a priori.

Cas 4. Dans le cas précédent, comment améliorer le plus efficacement la précision du système ?

Solution. Réduire le **taux de faux positifs** (2%) a bien plus d'impact que d'augmenter la détection (déjà 95%). Passer de 2% à 0.5% de faux positifs porterait la précision à $\frac{0.00475}{0.00475+0.004975} \approx 48.8\%$.

Cas 5. Deux événements sont mutuellement exclusifs et de probabilité non nulle. Sont-ils indépendants ?

Solution. **Non** — ils sont fortement dépendants : $P(A \mid B) = 0$ alors que $P(A) > 0$. La confusion entre exclusivité et indépendance est le piège n°1 du chapitre 1.

Cas 6. X a une moyenne de 8% et un écart-type de 15%. Quelle est la moyenne et l'écart-type de $Y = 3X - 2$?

Solution. $\mathbb{E}[Y] = 3(0.08) - 2 = -1.76$. $\text{Var}(Y) = 9 \times 0.15^2 = 0.2025$, donc $\sigma_Y = 3 \times 0.15 = \mathbf{45}\%$. La constante disparaît de la variance, le coefficient est au carré.

Cas 7. Une variable aléatoire a $\mathbb{E}[X] = 5$ et $\mathbb{E}[X^2] = 34$. Quelle est sa variance ?

Solution. $\text{Var}(X) = 34 - 5^2 = \mathbf{9}$, soit $\sigma = 3$. Formule de raccourci systématiquement testée.

Cas 8. Un rendement a une kurtosis de 6. Quel est son excès de kurtosis et qu'implique-t-il ?

Solution. Excès $= 6 - 3 = \mathbf{3}$, positif : la distribution est **leptokurtique** (queues plus épaisses que la normale). Conséquence pratique : une VaR normale *sous-estimerait* le risque extrême.

Cas 9. Peut-on avoir une densité $f(x) = 2$ en un point ? Est-ce une probabilité ?

Solution. **Oui**, une densité peut dépasser 1 (ex. uniforme sur $[0, 0.5]$ a $f = 2$). Ce n'est **pas** une probabilité : seule l'*aire* sous la courbe est bornée par 1.

Cas 10. Quelle est la différence entre PMF, PDF et CDF ?

Solution. PMF : $P(X = x)$, cas discret. PDF : densité, cas continu (la probabilité en un point exact est nulle). CDF : $F(x) = P(X \leq x)$, définie dans les deux cas, croissante de 0 à 1.

Cas 11. Un gestionnaire affirme : « il y a 95% de chances que ma stratégie soit rentable, donc seulement 5% de risque de perte importante ». Où est l'erreur ?

Solution. Il confond **probabilité** et **sévérité**. Une probabilité de perte de 5% ne dit rien sur l'ampleur de cette perte — c'est exactement pourquoi la VaR (probabilité) est complétée par l'*expected shortfall* (sévérité conditionnelle).

Cas 12. $P(A) = 0.3$, $P(B \mid A) = 0.5$. Que vaut $P(A \cap B)$?

Solution. Règle de multiplication : $P(A \cap B) = P(B \mid A)P(A) = 0.5 \times 0.3 = \mathbf{15}\%$.

Cas 13. Trois analystes indépendants prédisent chacun correctement dans 60% des cas. Quelle est la probabilité qu'ils se trompent tous les trois ?

Solution. $0.4^3 = \mathbf{6.4}\%$. L'indépendance permet la multiplication — hypothèse forte et rarement vraie en pratique (les analystes partagent souvent les mêmes sources).

Cas 14. Pourquoi l'espérance est-elle toujours additive alors que la variance ne l'est pas ?

Solution. $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ **toujours**, même si dépendantes (linéarité de l'opérateur). La variance fait intervenir des produits croisés, d'où le terme de covariance qui ne disparaît que sous indépendance.

Cas 15. Un dérivé paie 100 si un indice dépasse un seuil (probabilité 30%), 0 sinon. Quelle est l'espérance et l'écart-type du paiement ?

Solution. $\mathbb{E} = 100 \times 0.3 = \mathbf{30}$. C'est $100\times$ une Bernoulli(0.3) : Var $= 100^2 \times 0.3 \times 0.7 = 2100$, donc $\sigma = \mathbf{45.8}$. La dispersion dépasse largement la moyenne — typique d'un paiement binaire.

Cas 16. Une banque observe qu'un test de conformité déclenche une alerte pour 8% des dossiers. 90% des dossiers problématiques sont détectés, et 5% des dossiers sains génèrent une alerte. Quel est le taux de dossiers problématiques ?

Solution. Probabilité totale : $0.08 = 0.90p + 0.05(1 - p) \Rightarrow 0.08 = 0.05 + 0.85p \Rightarrow p = \frac{0.03}{0.85} = \mathbf{3.5}\%$.

Cas 17. Pourquoi Bayes est-il pertinent pour comprendre le chapitre 15 (classification) ?

Solution. La précision d'un classifieur, $VP/(VP + FP)$, *est* un calcul bayésien : $P(\text{réellement positif} \mid \text{prédit positif})$. L'effondrement de la précision sur classes rares est le paradoxe des faux positifs, identique au cas 3.

Cas 18. Quelle est la probabilité d'obtenir exactement 2 défauts sur 10 crédits indépendants à 5% de défaut chacun ?

Solution. Binomiale : $\binom{10}{2}(0.05)^2(0.95)^8 = 45 \times 0.0025 \times 0.6634 = \mathbf{7.46}\%$.

Cas 19. Deux événements ont $P(A) = 0.5$, $P(B) = 0.4$, $P(A \cup B) = 0.7$. Sont-ils indépendants ?

Solution. $P(A \cap B) = 0.5 + 0.4 - 0.7 = 0.2$. Sous indépendance, on attendrait $0.5 \times 0.4 = 0.2$. C'est exactement le cas : ils **sont indépendants**.

Cas 20. Un analyste calcule $P(\text{crise} \mid \text{signal})$ mais dispose de $P(\text{signal} \mid \text{crise})$. Que lui manque-t-il ?

Solution. Il lui manque la probabilité **a priori** $P(\text{crise})$ et la probabilité marginale $P(\text{signal})$. Sans elles, l'inversion bayésienne est impossible — inverser directement serait l'erreur du procureur.

Cas 21. Quelle propriété rend la variance non linéaire, et quelle conséquence pratique en découle en gestion de portefeuille ?

Solution. La variance est un opérateur *quadratique*. Conséquence : le risque d'un portefeuille n'est **pas** la somme pondérée des risques individuels — c'est précisément ce qui rend la diversification possible (chapitre 4).

Thème 2 --- Distributions et leur choix (ch. 3)

Cas 22. Un portefeuille de 200 crédits a un taux de défaut individuel de 2%, défauts indépendants. Quelle loi décrit le nombre de défauts, et quels sont ses moments ?

Solution. Binomiale(200, 0.02) : $\mathbb{E} = np = \mathbf{4}$ défauts, Var $= np(1-p) = 3.92$, $\sigma = 1.98$. Avec n grand et p petit, on peut approximer par une Poisson($\lambda = 4$).

Cas 23. Dans le cas précédent, quelle serait la variance sous l'approximation de Poisson, et pourquoi diffère-t-elle ?

Solution. Poisson : Var $= \lambda = \mathbf{4}$, contre 3.92 pour la binomiale. L'écart vient du facteur $(1-p)$: l'approximation est excellente car $p = 2\%$ est petit.

Cas 24. Un actif vaut 100 aujourd'hui. Son rendement log annuel est $\mathcal{N}(8\%, 20\%)$. Le prix futur suit quelle loi ?

Solution. Si le rendement log est normal, le **prix** est **log-normal** — ce qui garantit sa positivité, propriété essentielle pour un prix d'actif.

Cas 25. Quel quantile utiliser pour une VaR à 99% sur un horizon d'un jour ?

Solution. $z_{0.99} = \mathbf{2.326}$ (unilatéral). Utiliser 2.576 (bilatéral) est une erreur classique qui surestime la VaR d'environ 11%.

Cas 26. Un portefeuille de 10 M€ a une volatilité quotidienne de 1.2%. Quelle est sa VaR à 95% sur 1 jour ?

Solution. VaR $= 1.645 \times 0.012 \times 10{,}000{,}000 = \mathbf{197{,}400}$ €.

Cas 27. Même portefeuille : quelle VaR sur 10 jours ?

Solution. Règle de la racine : $197{,}400 \times \sqrt{10} = \mathbf{624{,}230}$ €. Attention : valide seulement sous rendements i.i.d.

Cas 28. Pourquoi la loi de Student est-elle préférée à la normale pour les rendements financiers ?

Solution. Ses **queues plus épaisses** reflètent mieux la fréquence empirique des chocs extrêmes. Plus ν est petit, plus les queues sont épaisses ; quand $\nu \to \infty$, elle converge vers la normale.

Cas 29. Une Student a $\nu = 5$. Quelle est sa variance ?

Solution. $\frac{\nu}{\nu-2} = \frac{5}{3} = \mathbf{1.67}$. Noter que la variance n'existe que si $\nu > 2$, et la moyenne que si $\nu > 1$.

Cas 30. Le nombre de fraudes détectées suit une Poisson de moyenne 3 par mois. Quelle est la probabilité d'en observer exactement 0 en un mois ?

Solution. $P(0) = e^{-3} = \mathbf{4.98}\%$. Rappel : pour la Poisson, moyenne et variance valent toutes deux λ.

Cas 31. Quelle loi utiliser pour modéliser le temps écoulé jusqu'au prochain défaut ?

Solution. La loi **exponentielle**(λ), de moyenne $1/\lambda$. Elle est sans mémoire, hypothèse forte : le risque instantané ne dépend pas de l'ancienneté.

Cas 32. Une variable uniforme sur $[0, 1]$ sert de point de départ à toute simulation. Pourquoi ?

Solution. Par la **transformation inverse** : si $U \sim \mathcal{U}(0, 1)$, alors $F^{-1}(U)$ suit la loi de CDF F. C'est le mécanisme fondamental de génération de toute variable aléatoire (chapitre 13).

Cas 33. Un chi-deux a 10 degrés de liberté. Moyenne et variance ?

Solution. $\mathbb{E} = \nu = \mathbf{10}$, Var $= 2\nu = \mathbf{20}$. Cette loi apparaît dans les tests de variance et les tests de White (chapitre 9).

Cas 34. Quelle différence pratique entre normale et log-normale pour modéliser un prix ?

Solution. La normale autorise des **prix négatifs** (impossible économiquement) ; la log-normale garantit la positivité et produit une asymétrie positive, cohérente avec l'observation.

Cas 35. Pourquoi la loi normale reste-t-elle centrale malgré ses limites empiriques ?

Solution. Par le **TCL** (chapitre 5) : les sommes et moyennes convergent vers elle, quelle que soit la loi sous-jacente. Elle est donc justifiée pour des rendements *agrégés* sur de longues périodes, moins pour des rendements quotidiens.

Cas 36. Un analyste modélise 500 défauts potentiels avec $p = 0.01$. Peut-il utiliser une approximation normale ?

Solution. $np = 5$ et $n(1-p) = 495$. La règle usuelle exige $np > 5$ *et* $n(1-p) > 5$: c'est limite. Une approximation de **Poisson**$(\lambda = 5)$ serait plus appropriée pour un p aussi faible.

Cas 37. Quel est l'intérêt de la standardisation $Z = (X - \mu)/\sigma$?

Solution. Elle ramène toute normale à la normale centrée réduite, permettant l'usage d'une **table unique**. C'est aussi le prérequis de la régularisation (chapitres 14-15) et du k-NN.

Cas 38. Quelle est la probabilité qu'une variable normale s'écarte de plus de 2 écarts-types de sa moyenne ?

Solution. $\approx 4.6\%$ (car $P(|Z| < 1.96) = 95\%$ et $P(|Z| < 2) \approx 95.4\%$). Un événement à 2 écarts-types est donc loin d'être exceptionnel.

Cas 39. Pourquoi les rendements quotidiens sont-ils moins normaux que les rendements annuels ?

Solution. Le TCL agit par agrégation : un rendement annuel est la somme d'environ 250 rendements quotidiens, ce qui *normalise* la distribution. Les rendements quotidiens conservent leurs queues épaisses natives.

Cas 40. Un actif a 60% de chances de monter de 10% et 40% de baisser de 5%. Espérance et écart-type du rendement ?

Solution. $\mathbb{E} = 0.6(10) + 0.4(-5) = \mathbf{4}\%$. $\mathbb{E}[X^2] = 0.6(100) + 0.4(25) = 70$, Var $= 70 - 16 = 54$, $\sigma = \mathbf{7.35}\%$.

Cas 41. Comment choisir entre binomiale et Poisson pour un portefeuille de crédits ?

Solution. Binomiale si n est modeste et p non négligeable (nombre fixe d'expositions). Poisson si les événements sont *rares* et le nombre d'occasions très grand — l'approximation devient excellente quand $n \to \infty$, $p \to 0$, $np = \lambda$ constant.

Cas 42. Quelle loi décrit le rendement d'un portefeuille très diversifié, et pourquoi ?

Solution. Approximativement **normale**, par le TCL appliqué à la somme pondérée de nombreux actifs — *à condition* que leurs corrélations restent modérées. En crise, la corrélation monte et la normalité s'effondre.

Thème 3 --- Dépendance, covariance et portefeuille (ch. 4)

Cas 43. Deux actifs : $\sigma_A = 20\%$, $\sigma_B = 30\%$, $\rho = 0.4$. Quelle est la volatilité d'un portefeuille 50/50 ?

Solution. $\sigma_P^2 = 0.25(0.04) + 0.25(0.09) + 2(0.5)(0.5)(0.4)(0.2)(0.3) = 0.01 + 0.0225 + 0.012 = 0.0445$. $\sigma_P = \mathbf{21.1}\%$ — inférieur à la moyenne pondérée (25%) : c'est le bénéfice de diversification.

Cas 44. Même cas avec $\rho = 1$. Quelle est alors la volatilité ?

Solution. $\sigma_P = 0.5(20) + 0.5(30) = \mathbf{25}\%$, exactement la moyenne pondérée. À corrélation parfaite, **aucun** bénéfice de diversification.

Cas 45. Même cas avec $\rho = -1$. Volatilité ?

Solution. $\sigma_P = |0.5(20) - 0.5(30)| = \mathbf{5}\%$. Corrélation parfaitement négative : diversification maximale. Avec des pondérations bien choisies (60/40), on atteindrait même une volatilité nulle.

Cas 46. Que vaut $\text{Cov}(X, X)$?

Solution. $\text{Cov}(X, X) = \text{Var}(X)$. La variance est un cas particulier de covariance.

Cas 47. La corrélation entre deux actifs est nulle. Sont-ils indépendants ?

Solution. **Non nécessairement**. La corrélation ne capte que la dépendance *linéaire*. Deux variables liées par $Y = X^2$ (avec X symétrique) ont une corrélation nulle mais une dépendance totale.

Cas 48. Un portefeuille contient 3 actifs équipondérés, chacun de volatilité 20%, corrélations mutuelles de 0.3. Volatilité du portefeuille ?

Solution. $\sigma_P^2 = 3(1/9)(0.04) + 6(1/9)(0.3)(0.04) = 0.01333 + 0.008 = 0.02133$. $\sigma_P = \mathbf{14.6}\%$. Noter les 6 termes croisés (3 paires, comptées deux fois).

Cas 49. Que devient la volatilité d'un portefeuille équipondéré de n actifs identiques quand $n \to \infty$?

Solution. Elle tend vers $\sigma\sqrt{\rho}$: le risque *spécifique* disparaît, mais le risque **systématique** (lié à la corrélation moyenne) demeure. Avec $\sigma = 20\%$ et $\rho = 0.3$, la limite est $20\sqrt{0.3} = \mathbf{11}\%$.

Cas 50. Pourquoi préfère-t-on la corrélation à la covariance pour comparer deux paires d'actifs ?

Solution. La covariance dépend des **unités** et de l'échelle des variables ; la corrélation est **normalisée** dans $[-1, 1]$, donc directement comparable.

Cas 51. $\text{Cov}(X, Y) = 0.006$, $\sigma_X = 10\%$, $\sigma_Y = 15\%$. Quelle est la corrélation ?

Solution. $\rho = \frac{0.006}{0.10 \times 0.15} = \frac{0.006}{0.015} = \mathbf{0.4}$.

Cas 52. Un gérant affirme que ses 50 positions le protègent d'une crise. Quel argument du chapitre 4 lui opposer ?

Solution. La diversification élimine le risque spécifique mais **pas** le risque systématique. Pire, les corrélations *augmentent* en crise (chapitre 12) : la protection s'évapore précisément quand elle est nécessaire.

Cas 53. Quel lien existe entre covariance et coefficient de régression ?

Solution. $\hat{\beta}_1 = \frac{\text{Cov}(x,y)}{\text{Var}(x)}$ — la régression (chapitre 7) est une exploitation directe de la covariance du chapitre 4.

Cas 54. Deux actifs de volatilité 25% et 15%, $\rho = 0.6$. Quelle pondération minimise la variance du portefeuille ?

Solution. $w_A^* = \frac{\sigma_B^2 - \rho\sigma_A\sigma_B}{\sigma_A^2 + \sigma_B^2 - 2\rho\sigma_A\sigma_B} = \frac{0.0225 - 0.0225}{0.0625 + 0.0225 - 0.045} = \frac{0}{0.04} = \mathbf{0}$. Tout investir dans B : ici A n'apporte aucun bénéfice de diversification suffisant.

Cas 55. Quelle est la covariance entre un actif et une constante ?

Solution. **Zéro**. Une constante n'a aucune variabilité, donc aucune co-variabilité.

Cas 56. Pourquoi le terme croisé de la variance d'une somme comporte-t-il un facteur 2 ?

Solution. Parce que $\text{Cov}(X, Y)$ et $\text{Cov}(Y, X)$ apparaissent tous deux dans le développement, et sont égaux. Oublier ce facteur sous-estime systématiquement le risque quand $\rho > 0$.

Cas 57. Un portefeuille long/short détient +100 de A et -60 de B, $\sigma_A = 20\%$, $\sigma_B = 25\%$, $\rho = 0.7$. Volatilité en montant ?

Solution. Var $= 100^2(0.04) + 60^2(0.0625) - 2(100)(60)(0.7)(0.2)(0.25) = 400 + 225 - 420 = 205$. $\sigma =$ **14.3** — le short réduit fortement le risque grâce à la corrélation positive.

Cas 58. La matrice de covariance d'un portefeuille de 10 actifs contient combien de paramètres distincts ?

Solution. $\frac{10\times 11}{2} =$ **55** (10 variances + 45 covariances). Ce nombre croît en $O(n^2)$ — d'où le recours aux modèles factoriels et à l'ACP (chapitre 14) pour les grands portefeuilles.

Cas 59. Comment l'indépendance simplifie-t-elle le calcul de la variance d'une somme ?

Solution. Sous indépendance, toutes les covariances sont nulles : $\text{Var}(\sum X_i) = \sum \text{Var}(X_i)$. C'est ce qui fonde la règle en $\sqrt{T}$ du chapitre 12.

Cas 60. Deux stratégies ont chacune un rendement espéré de 8% et une volatilité de 12%, corrélation 0.2. Que gagne-t-on à les combiner à 50/50 ?

Solution. Rendement inchangé (8%), mais $\sigma_P = \sqrt{0.25(144) + 0.25(144) + 2(0.25)(0.2)(144)} = \sqrt{36 + 36 + 14.4} =$ **9.3**%. Même rendement pour 23% de risque en moins — le repas gratuit de la diversification.

Cas 61. Quelle est la corrélation maximale possible entre deux variables, et que signifie-t-elle géométriquement ?

Solution. $\rho = 1$: les deux variables sont liées par une relation **linéaire croissante exacte**, $Y = a + bX$ avec $b > 0$. Les points sont alignés parfaitement.

Cas 62. Un risk manager utilise une corrélation historique de 0.3 estimée en période calme. Quel risque encourt-il ?

Solution. Une **sous-estimation majeure** du risque de portefeuille en crise, où la corrélation peut approcher 0.8-0.9. C'est un risque de modèle classique, motivant les corrélations conditionnelles et les stress tests (chapitres 12-13).

Cas 63. Quelle relation existe entre la décorrélation des arbres (ch. 14) et la diversification de portefeuille (ch. 4) ?

Solution. C'est **la même mathématique** : $\text{Var}(\frac{1}{B}\sum \hat{f}_b) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$ est la formule de variance d'un portefeuille équipondéré. La forêt aléatoire « diversifie » ses arbres exactement comme un gérant diversifie ses positions.

Thème 4 --- Estimation, TCL et propriétés des estimateurs (ch. 5)

Cas 64. Un échantillon de 100 rendements a $\bar{x} = 0.8\%$ et $s = 2\%$. Quelle est l'erreur-type de la moyenne ?

Solution. erreur-type $= \frac{s}{\sqrt{n}} = \frac{2\%}{10} =$ **0.2**%. Noter que $s = 2\%$ décrit la dispersion des *observations*, tandis que 0.2% décrit celle de la *moyenne*.

Cas 65. Dans le cas précédent, quel est l'intervalle de confiance à 95% pour la moyenne ?

Solution. $0.8\% \pm 1.96(0.2\%) = [$**0.41**%, **1.19**%$]$. Comme l'intervalle exclut zéro, la moyenne est significativement positive au seuil de 5%.

Cas 66. Pourquoi divise-t-on par $n-1$ et non par n dans la variance d'échantillon ?

Solution. Correction de Bessel : diviser par n produit un estimateur **biaisé à la baisse**, car les écarts sont mesurés par rapport à $\bar{x}$ (estimée depuis les mêmes données) et non par rapport au vrai μ. Un degré de liberté est consommé.

Cas 67. Que dit exactement le théorème central limite ?

Solution. La distribution de la **moyenne d'échantillon** converge vers une normale quand n croît, *quelle que soit* la loi des observations (à variance finie). Il ne dit **rien** sur la normalité des observations individuelles.

Cas 68. Un analyste a besoin de diviser par 2 l'erreur-type de son estimation. Que doit-il faire ?

Solution. Multiplier n par **4**, puisque l'erreur-type varie en $1/\sqrt{n}$. Le même résultat vaut pour la simulation Monte-Carlo (chapitre 13).

Cas 69. Quelles sont les trois propriétés souhaitables d'un estimateur ?

Solution. **Sans biais** ($\mathbb{E}[\hat{\theta}] = \theta$), **efficace** (variance minimale), **convergent** ($\hat{\theta} \to \theta$ quand $n \to \infty$). Un estimateur peut être biaisé mais convergent, ou sans biais mais très inefficace.

Cas 70. Un estimateur sans biais est-il toujours préférable à un estimateur biaisé ?

Solution. **Non**. Ridge (chapitre 14) est délibérément biaisé mais réduit tellement la variance que son erreur quadratique totale est inférieure. C'est le compromis biais-variance.

Cas 71. Quelle est la différence entre efficacité et convergence ?

Solution. L'**efficacité** compare deux estimateurs à n fixé (variance minimale). La **convergence** décrit un comportement asymptotique ($n \to \infty$). Un estimateur peut être convergent mais inefficace en petit échantillon.

Cas 72. Un échantillon de 25 observations a $\bar{x} = 12$, $s = 5$. Quelle loi utiliser pour l'intervalle de confiance et pourquoi ?

Solution. La loi de **Student** à 24 degrés de liberté, car σ est inconnue et n est petit. Pour $n > 30$, la normale devient une approximation acceptable.

Cas 73. Pourquoi l'écart-type d'échantillon ne diminue-t-il pas quand n augmente, contrairement à l'erreur-type ?

Solution. s estime la dispersion *intrinsèque* de la population, qui ne dépend pas de n. L'erreur-type $s/\sqrt{n}$ mesure la précision de l'*estimation de la moyenne*, qui s'améliore avec plus de données.

Cas 74. Quel est le lien entre le bootstrap (ch. 13) et les moments d'échantillon (ch. 5) ?

Solution. Le bootstrap estime la **distribution d'échantillonnage** d'une statistique par rééchantillonnage, sans hypothèse de loi ni recours au TCL — une alternative empirique à la théorie asymptotique du chapitre 5.

Cas 75. Un échantillon de rendements a une asymétrie de -0.8. Qu'est-ce que cela implique ?

Solution. Asymétrie **négative** : la queue gauche est plus longue — les pertes extrêmes sont plus probables que les gains extrêmes de même ampleur. Une VaR normale sous-estimerait le risque.

Cas 76. Comment tester si un échantillon provient d'une loi normale ?

Solution. Par un test de normalité (Jarque-Bera, fondé sur l'asymétrie et l'excès de kurtosis) ou graphiquement par un QQ-plot. Le rejet de la normalité oriente vers Student, ou vers des méthodes non paramétriques (bootstrap).

Cas 77. Pourquoi le TCL justifie-t-il l'usage de la normale dans les tests, même sur données non normales ?

Solution. Parce que les statistiques de test reposent sur des **moyennes** (ou sommes), dont la distribution converge vers la normale. La non-normalité des données brutes n'invalide donc pas les tests en grand échantillon.

Cas 78. Quelle taille d'échantillon est généralement considérée comme suffisante pour invoquer le TCL ?

Solution. $n \geq 30$ est la règle usuelle, mais elle dépend de l'asymétrie : une loi très asymétrique peut exiger n bien supérieur pour que l'approximation normale soit fiable.

Cas 79. Un estimateur a $\mathbb{E}[\hat{\theta}] = \theta + 2/n$. Est-il biaisé ? Convergent ?

Solution. Il est **biaisé** (le biais vaut $2/n \neq 0$) mais **asymptotiquement sans biais** et convergent, car le biais tend vers 0 quand $n \to \infty$.

Cas 80. Deux estimateurs sans biais ont des variances de 4 et 9. Lequel choisir et quel gain d'information ?

Solution. Celui de variance 4, plus **efficace**. Son erreur-type est 2 contre 3 : à précision égale, il exige environ $(3/2)^2 = 2.25$ fois moins d'observations.

Cas 81. Pourquoi la moyenne d'échantillon est-elle BLUE dans le cadre classique ?

Solution. Elle est le meilleur estimateur **linéaire sans biais** : parmi toutes les combinaisons linéaires des observations sans biais, elle a la variance minimale. Ce résultat préfigure Gauss-Markov (chapitre 7).

Cas 82. Un analyste estime une volatilité sur 20 observations et l'annonce à 3 décimales. Quel est le problème ?

Solution. Une **précision illusoire**. Avec $n = 20$, l'incertitude sur s est considérable ; annoncer trois décimales suggère une précision que les données ne supportent pas. Toujours accompagner une estimation de son erreur-type.

Cas 83. Quel lien entre les quatre moments de population (ch. 2) et leurs estimateurs (ch. 5) ?

Solution. Chaque moment de population (μ, σ^2, asymétrie, kurtosis) a un estimateur d'échantillon correspondant ($\bar{x}$, s^2, asymétrie et kurtosis empiriques). Le chapitre 2 définit la cible, le chapitre 5 fournit l'outil de mesure et ses propriétés.

Cas 84. Pourquoi la kurtosis est-elle particulièrement difficile à estimer précisément ?

Solution. Elle repose sur les écarts à la **puissance 4**, donc dominée par quelques observations extrêmes. Son estimateur a une variance très élevée et exige de grands échantillons pour être fiable.

Thème 5 --- Tests d'hypothèses et erreurs de décision (ch. 6)

Cas 85. Un test donne $t = 2.4$ avec 40 degrés de liberté, seuil 5% bilatéral ($t_{\text{crit}} \approx 2.02$). Conclusion ?

Solution. $|2.4| > 2.02$: on **rejette** H_0. Le résultat est statistiquement significatif au seuil de 5%.

Cas 86. Dans le cas précédent, peut-on conclure que l'effet est économiquement important ?

Solution. **Non**. La significativité statistique ne dit rien sur l'**ampleur** de l'effet. Avec un n très grand, un effet négligeable devient significatif. Il faut examiner la taille du coefficient lui-même.

Cas 87. Une p-valeur vaut 0.03. Que signifie-t-elle exactement ?

Solution. Si H_0 était vraie, il y aurait 3% de chances d'observer un résultat au moins aussi extrême. Elle ne signifie **pas** qu'il y a 3% de chances que H_0 soit vraie — confusion très fréquente.

Cas 88. Un analyste ne rejette pas H_0. Peut-il conclure que H_0 est vraie ?

Solution. **Non**. L'absence de rejet peut résulter d'un manque de **puissance** (échantillon trop petit). Absence de preuve n'est pas preuve d'absence.

Cas 89. Quelle est la conséquence de passer d'un seuil $\alpha = 5\%$ à $\alpha = 1\%$?

Solution. Le risque d'**erreur de type I** diminue (moins de faux rejets), mais celui de **type II** augmente (plus d'effets réels manqués). À n fixé, l'arbitrage est inévitable.

Cas 90. Comment réduire simultanément les erreurs de type I et de type II ?

Solution. En **augmentant la taille de l'échantillon** n — la seule voie qui améliore les deux à la fois, en réduisant l'erreur-type.

Cas 91. Un gestionnaire teste si sa surperformance est réelle. Quelle erreur lui coûte le plus cher ?

Solution. L'**erreur de type I** : conclure à tort qu'il a du talent, et allouer du capital à une stratégie sans valeur. C'est pourquoi les tests de performance utilisent des seuils exigeants.

Cas 92. Quelle est la puissance d'un test, et de quoi dépend-elle ?

Solution. Puissance $= 1 - \beta$: probabilité de détecter un effet réellement présent. Elle croît avec n, avec la taille de l'effet, avec α, et décroît avec la variance des données.

Cas 93. Test unilatéral ou bilatéral pour « le rendement moyen est-il supérieur à zéro ? »

Solution. **Unilatéral** (à droite) : $H_0 : \mu \leq 0$ contre $H_1 : \mu > 0$. La valeur critique à 5% est 1.645, non 1.96 — le test unilatéral est plus puissant si la direction est justifiée a priori.

Cas 94. Quel risque encourt-on à choisir le sens du test après avoir vu les données ?

Solution. Un gonflement du taux réel d'erreur de type I. Choisir la direction *a posteriori* revient de fait à un test bilatéral déguisé, avec un seuil affiché deux fois trop permissif.

Cas 95. Un intervalle de confiance à 95% pour β_1 est $[0.3, 1.1]$. Le coefficient est-il significatif à 5% ?

Solution. **Oui** : l'intervalle exclut zéro, ce qui équivaut exactement à rejeter $H_0 : \beta_1 = 0$ au seuil de 5%. Intervalle et test sont deux faces du même raisonnement.

Cas 96. Le même intervalle est $[-0.2, 1.4]$. Conclusion ?

Solution. L'intervalle **contient** zéro : on ne rejette pas H_0. Le coefficient n'est pas significatif au seuil de 5%, ce qui n'exclut pas un effet réel non détecté.

Cas 97. Pourquoi tester 20 stratégies au seuil de 5% pose-t-il problème ?

Solution. Problème des **tests multiples** : même si aucune stratégie n'a de valeur, on s'attend à environ $20 \times 0.05 = 1$ faux positif. C'est le *data snooping*, source majeure de fausses découvertes en finance.

Cas 98. Comment corriger le problème des tests multiples ?

Solution. Par une correction du seuil (Bonferroni : α/m pour m tests) ou une validation **hors échantillon** — ce dernier réflexe étant précisément celui du machine learning (chapitres 14-15).

Cas 99. Quel est le parallèle exact entre erreurs de type I/II et métriques de classification ?

Solution. Type I = **faux positif** ; type II = **faux négatif**. La puissance $(1-\beta)$ est le **rappel**, et $1-\alpha$ est la **spécificité**. Le chapitre 15 reprend intégralement la structure du chapitre 6, avec un vocabulaire différent.

Cas 100. Un test de significativité d'un coefficient de régression utilise quelle statistique ?

Solution. $t = \hat{\beta}_j / \text{erreur-type}(\hat{\beta}_j)$, comparé à t_{n-k-1}. C'est l'application directe du chapitre 6 au chapitre 7-8.

Cas 101. Pourquoi la p-valeur dépend-elle de la taille de l'échantillon ?

Solution. L'erreur-type décroît en $1/\sqrt{n}$, donc la statistique t croît mécaniquement avec n à effet constant. Avec n suffisant, *tout* effet non nul devient significatif.

Cas 102. Un test rejette H_0 à 5% mais pas à 1%. Comment l'interpréter ?

Solution. La p-valeur est comprise entre 1% et 5% : la preuve est **modérée**. Rapporter la p-valeur exacte est plus informatif que le simple verdict binaire rejet/non-rejet.

Cas 103. Quelle hypothèse teste-t-on avec le test F en régression multiple ?

Solution. $H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$ — la nullité **conjointe** de tous les coefficients de pente. Le rejet signifie que le modèle a un pouvoir explicatif global.

Cas 104. Peut-on avoir un test F significatif sans aucun test t significatif ?

Solution. **Oui** — symptôme classique de **multicolinéarité** (chapitre 9) : les variables expliquent conjointement y, mais leurs contributions individuelles sont indissociables, gonflant les erreurs-types.

Cas 105. Quel est le rôle des degrés de liberté dans un test ?

Solution. Ils déterminent la loi de référence. En régression, $n - k - 1$: chaque paramètre estimé en consomme un. Moins il en reste, plus les valeurs critiques sont exigeantes — pénalisant les modèles surchargés en variables.

Thème 6 --- Régression simple et multiple (ch. 7-8)

Cas 106. Une régression donne $\hat{\beta}_1 = 1.4$ avec une erreur-type de 0.5, $n = 50$. Le coefficient est-il significatif à 5% ?

Solution. $t = 1.4/0.5 = 2.8$, contre une valeur critique ≈ 2.01 (48 ddl). $|2.8| > 2.01$: **significatif**. L'IC à 95% est $1.4 \pm 2.01(0.5) = [0.39, 2.41]$, qui exclut zéro.

Cas 107. Une régression a $SCT = 500$ et $SCR = 150$. Quel est le R^2 ?

Solution. $R^2 = 1 - \frac{150}{500} = \mathbf{0.70}$: le modèle explique 70% de la variance totale de y.

Cas 108. Même régression avec $n = 100$ et $k = 4$ variables. Quel est le R^2 ajusté ?

Solution. $\bar{R}^2 = 1 - (1 - 0.70)\frac{99}{95} = 1 - 0.30(1.0421) = \mathbf{0.6874}$. Toujours inférieur au R^2 brut dès que $k \geq 1$.

Cas 109. Une régression simple donne $r_{xy} = 0.6$. Quel est le R^2 ?

Solution. $R^2 = r^2 = 0.36$. **Attention** : cette égalité ne vaut qu'en régression *simple*. En multiple, R^2 n'est pas le carré d'une corrélation simple.

Cas 110. $\hat{\beta}_1$ vaut 0.8 dans la régression du rendement d'un actif sur celui du marché. Interprétation ?

Solution. C'est le **bêta** de l'actif : pour 1% de hausse du marché, l'actif monte de 0.8% en moyenne. Un bêta inférieur à 1 signale une sensibilité amortie au marché.

Cas 111. Comment obtient-on $\hat{\beta}_1$ à partir de la covariance ?

Solution. $\hat{\beta}_1 = \frac{\text{Cov}(x,y)}{\text{Var}(x)}$. Avec Cov $= 0.0024$ et Var$(x) = 0.003$, on obtient $\hat{\beta}_1 = 0.8$.

Cas 112. Que devient R^2 si l'on ajoute une variable totalement non pertinente ?

Solution. Il **augmente ou reste égal** — jamais il ne baisse. C'est la faiblesse structurelle du R^2 et la raison d'être du R^2 ajusté et de la validation croisée (chapitre 14).

Cas 113. Un modèle passe de $R^2 = 0.62$ à 0.63 en ajoutant 5 variables. Le $\bar{R}^2$ passe de 0.60 à 0.58. Que conclure ?

Solution. Les variables ajoutées n'apportent **pas** assez de pouvoir explicatif pour compenser leur coût en degrés de liberté. Le modèle initial est préférable — le $\bar{R}^2$ tranche là où le R^2 est muet.

Cas 114. Que signifie « toutes choses égales par ailleurs » dans l'interprétation d'un coefficient multiple ?

Solution. $\hat{\beta}_j$ mesure l'effet d'une variation unitaire de x_j sur y **en maintenant constantes toutes les autres variables du modèle**. Cette interprétation devient fragile en cas de forte multicolinéarité.

Cas 115. Quelles sont les hypothèses de Gauss-Markov ?

Solution. Linéarité des paramètres, $\mathbb{E}[\varepsilon \mid x] = 0$, homoscédasticité, absence d'autocorrélation, variabilité de x et absence de corrélation entre x et ε. Sous ces conditions, les MCO sont **BLUE**.

Cas 116. La normalité des erreurs est-elle nécessaire pour que les MCO soient BLUE ?

Solution. **Non**. Elle n'est requise que pour la validité *exacte* des tests t et F en petit échantillon. En grand échantillon, le TCL prend le relais.

Cas 117. Un modèle omet une variable corrélée à la fois à y et à x_1. Quelle est la conséquence ?

Solution. **Biais de variable omise** : $\hat{\beta}_1$ est biaisé, car il capte en partie l'effet de la variable manquante. C'est l'une des rares violations qui biaise les coefficients eux-mêmes.

Cas 118. Quelle est la différence entre erreur ε_i et résidu e_i ?

Solution. L'erreur est la déviation **vraie et inobservable** par rapport à la droite de population ; le résidu $e_i = y_i - \hat{y}_i$ est son estimation **observable**, calculée à partir de la droite estimée. Tous les diagnostics s'appuient sur les résidus.

Cas 119. Un R^2 de 0.04 sur des rendements quotidiens invalide-t-il le modèle ?

Solution. **Non**. En finance haute fréquence, expliquer 4% de la variance peut suffire à générer une stratégie rentable. Le R^2 doit s'apprécier relativement au contexte, pas dans l'absolu.

Cas 120. La régression MCO minimise quelle quantité exactement ?

Solution. La **somme des carrés des résidus** $\sum (y_i - \hat{y}_i)^2$. Le choix du carré (plutôt que la valeur absolue) donne une solution analytique fermée mais rend l'estimateur sensible aux valeurs aberrantes.

Cas 121. Pourquoi la droite de régression passe-t-elle toujours par $(\bar{x}, \bar{y})$?

Solution. C'est une conséquence directe de $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$, qui garantit $\hat{y}(\bar{x}) = \bar{y}$. Propriété utile pour vérifier rapidement un calcul.

Cas 122. Un test F vaut 12.5 avec $k = 3$ et $n = 60$ ($F_{\text{crit}} \approx 2.77$ à 5%). Conclusion ?

Solution. $12.5 > 2.77$: on **rejette** la nullité conjointe. Le modèle a un pouvoir explicatif global significatif, sans que cela garantisse la significativité de chaque variable.

Cas 123. Comment le chapitre 15 étend-il la régression du chapitre 7 ?

Solution. En transformant l'index linéaire $z = \beta_0 + \beta_1 x_1 + \ldots$ par la **sigmoïde**, pour produire une probabilité bornée — la structure linéaire est conservée, seule la sortie change.

Cas 124. Que se passe-t-il si deux variables explicatives sont parfaitement colinéaires ?

Solution. $X^\top X$ devient **singulière** et l'estimation MCO est **impossible**. C'est le cas de la trappe des variables indicatrices (chapitre 15).

Cas 125. Une régression a $SCE = 350$, $SCR = 150$, $k = 2$, $n = 53$. Calculer le test F.

Solution. $F = \frac{350/2}{150/50} = \frac{175}{3} = \mathbf{58.3}$ — très largement significatif.

Cas 126. Pourquoi le R^2 ajusté peut-il devenir négatif ?

Solution. Quand le modèle explique moins que la simple moyenne, compte tenu de la pénalité pour le nombre de variables. Signe d'un modèle très mal spécifié ou trop chargé pour la taille de l'échantillon.

Thème 7 --- Diagnostics et violations d'hypothèses (ch. 9)

Cas 127. Une régression sur données financières présente des résidus dont la dispersion augmente avec le niveau de y. Quel problème et quelle conséquence ?

Solution. **Hétéroscédasticité**. Conséquence : $\hat{\beta}$ reste **sans biais** et convergent, mais les erreurs-types sont biaisées — les tests t et F deviennent invalides.

Cas 128. Quel remède appliquer à l'hétéroscédasticité ?

Solution. Utiliser des **erreurs-types robustes** (White/Huber), qui corrigent l'inférence sans modifier les coefficients. Alternativement, transformer la variable (log) ou utiliser les MCG pondérés.

Cas 129. Des résidus de série temporelle sont positivement autocorrélés. Quelle conséquence sur l'inférence ?

Solution. Les erreurs-types sont **sous-estimées**, donc les statistiques t **gonflées** : on conclut à tort à la significativité. Remède : erreurs-types Newey-West.

Cas 130. Un Durbin-Watson de 0.6 indique quoi ?

Solution. Une **autocorrélation positive** forte des résidus (la valeur de référence sans autocorrélation est 2). Fréquent sur données temporelles mal spécifiées.

Cas 131. Un VIF de 12 pour une variable. Interprétation et action ?

Solution. Multicolinéarité **sévère** (seuil d'alerte 5-10) : la variance du coefficient est gonflée d'un facteur 12. Actions : retirer ou combiner des variables, appliquer Ridge (ch. 14), ou une ACP.

Cas 132. La multicolinéarité biaise-t-elle les coefficients ?

Solution. **Non** — ils restent sans biais. Elle les rend **instables** (forte variance) et gonfle leurs erreurs-types, rendant l'interprétation individuelle peu fiable.

Cas 133. Quelle est la seule violation classique qui biaise réellement $\hat{\beta}$?

Solution. La **variable omise** (et plus généralement l'endogénéité, corrélation entre x et ε). Hétéroscédasticité, autocorrélation et multicolinéarité affectent l'*inférence*, pas l'absence de biais.

Cas 134. Une observation a une distance de Cook de 1.8. Que faire ?

Solution. Elle est **très influente** (seuil d'alerte usuel autour de 1). Vérifier d'abord s'il s'agit d'une erreur de saisie ; sinon, tester la robustesse du modèle avec et sans elle, sans la supprimer arbitrairement.

Cas 135. Un modèle a $R^2 = 0.92$ et un Durbin-Watson de 0.3 sur deux séries de prix. Diagnostic ?

Solution. Signature typique d'une **régression fallacieuse** (chapitre 11) : deux séries non stationnaires régressées en niveaux. La relation apparente est un artefact. Remède : différencier ou tester la cointégration.

Cas 136. Comment détecter l'hétéroscédasticité formellement ?

Solution. Par les tests de **White** ou de **Breusch-Pagan**, qui régressent les résidus au carré sur les variables explicatives. Un graphique des résidus contre $\hat{y}$ fournit un diagnostic visuel rapide.

Cas 137. Pourquoi les données financières sont-elles structurellement hétéroscédastiques ?

Solution. À cause du **clustering de volatilité** : les périodes agitées succèdent aux périodes agitées. C'est précisément ce que modélisent EWMA et GARCH (chapitre 12) — l'hétéroscédasticité y devient l'objet d'étude.

Cas 138. Que faire si la relation entre x et y est manifestement non linéaire ?

Solution. Transformer les variables (log, polynôme), ajouter des termes d'interaction, ou recourir à des modèles non paramétriques (arbres, k-NN, réseaux — chapitres 14-15) qui capturent la non-linéarité sans spécification préalable.

Cas 139. Un analyste ajoute 30 variables à un modèle sur 50 observations. Quels problèmes anticipe-t-on ?

Solution. **Surapprentissage** massif, degrés de liberté quasi épuisés ($n - k - 1 = 19$), multicolinéarité probable, R^2 artificiellement élevé. Solution : régularisation (Lasso) et validation croisée.

Cas 140. Les résidus d'un modèle sont fortement non normaux. Est-ce grave ?

Solution. En **grand échantillon**, non : le TCL valide asymptotiquement les tests. En **petit échantillon**, les tests t et F perdent leur validité exacte — recourir alors au bootstrap (chapitre 13).

Cas 141. Comment distinguer un problème d'hétéroscédasticité d'un problème de spécification ?

Solution. L'hétéroscédasticité produit une dispersion variable des résidus *sans structure systématique de moyenne* ; une mauvaise spécification produit un **motif** dans les résidus (courbure, tendance), révélant une forme fonctionnelle inadéquate.

Cas 142. Que révèle un graphique des résidus en forme de U ?

Solution. Une **non-linéarité non modélisée** : la vraie relation est courbe et le modèle linéaire la manque systématiquement. Remède : ajouter un terme quadratique ou transformer la variable.

Cas 143. Deux variables ont une corrélation de 0.97. Faut-il les garder toutes deux ?

Solution. Rarement. Elles véhiculent quasiment la même information : conserver les deux gonfle les erreurs-types sans gain explicatif. Options : n'en garder qu'une, les combiner (moyenne, ACP), ou appliquer Ridge/Elastic Net.

Cas 144. Pourquoi Ridge est-il présenté comme un remède structurel à la multicolinéarité ?

Solution. En ajoutant λI à $X^\top X$, il **éloigne la matrice de la singularité**, stabilisant l'inversion et réduisant la variance des coefficients — au prix d'un biais accepté.

Cas 145. Un modèle bien spécifié doit-il avoir des résidus imprévisibles ?

Solution. **Oui** : des résidus structurés (autocorrélés, tendanciels, en motif) signalent qu'une information exploitable n'a pas été capturée par le modèle. Le résidu idéal ressemble à un bruit blanc.

Cas 146. Quelle est la conséquence pratique d'utiliser des erreurs-types non robustes en présence d'hétéroscédasticité ?

Solution. On **sur-rejette** ou **sous-rejette** H_0 de façon imprévisible : des variables non pertinentes peuvent apparaître significatives, et l'inverse. Les coefficients restent pourtant corrects — seule la confiance qu'on leur accorde est faussée.

Cas 147. Comment le chapitre 9 se relie-t-il au chapitre 14 ?

Solution. Les problèmes diagnostiqués au chapitre 9 (multicolinéarité, surapprentissage par excès de variables) reçoivent au chapitre 14 des réponses **systématiques** : régularisation, validation croisée, sélection automatique de variables.

Cas 148. Un test de White rejette H_0. Que conclure et que faire ?

Solution. H_0 du test de White est l'**homoscédasticité** : son rejet signale une hétéroscédasticité. Action : recalculer les erreurs-types en version robuste, puis réexaminer les conclusions de significativité.

Thème 8 --- Séries temporelles stationnaires et non stationnaires (ch. 10-11)

Cas 149. Un processus AR(1) a $\phi_1 = 0.85$ et $c = 0.3$. Est-il stationnaire ? Quelle est sa moyenne de long terme ?

Solution. $|0.85| < 1$: **stationnaire**. Moyenne : $\frac{c}{1-\phi_1} = \frac{0.3}{0.15} = \mathbf{2}$.

Cas 150. Même processus avec $\sigma_\varepsilon^2 = 1$. Quelle est sa variance non conditionnelle ?

Solution. $\frac{\sigma_\varepsilon^2}{1-\phi_1^2} = \frac{1}{1-0.7225} = \frac{1}{0.2775} = \mathbf{3.60}$.

Cas 151. Un processus a $\phi_1 = 1$. Que devient-il et comment le traiter ?

Solution. C'est une **marche aléatoire** : non stationnaire, à racine unitaire, variance croissant sans limite. Remède : **différencier** une fois ($\Delta y_t = \varepsilon_t$, stationnaire).

Cas 152. Une ACF décroît lentement et une PACF se coupe nettement après le retard 2. Quel modèle ?

Solution. Un **AR(2)**. Règle : la PACF identifie l'ordre d'un AR ; l'ACF identifie l'ordre d'un MA.

Cas 153. Une ACF se coupe après le retard 1 et une PACF décroît progressivement. Quel modèle ?

Solution. Un **MA(1)** — le schéma exactement inverse du cas précédent.

Cas 154. Le test ADF donne une p-valeur de 0.35. Conclusion ?

Solution. On ne rejette pas H_0, qui est la **présence d'une racine unitaire**. La série est donc considérée comme **non stationnaire**. Attention à l'inversion contre-intuitive de H_0.

Cas 155. Le même test donne une p-valeur de 0.01. Conclusion ?

Solution. On **rejette** la racine unitaire : la série est **stationnaire**, et peut être modélisée en niveaux (ARMA) sans différenciation.

Cas 156. Deux séries de prix indépendantes régressées l'une sur l'autre donnent $R^2 = 0.85$. Que se passe-t-il ?

Solution. **Régression fallacieuse**. Deux séries non stationnaires partagent des tendances stochastiques qui créent une corrélation artificielle. Vérifier le Durbin-Watson (typiquement très bas) et différencier.

Cas 157. Quelle est la différence entre une série trend-stationary et difference-stationary ?

Solution. La première ($y_t = \alpha + \beta t + \varepsilon_t$) devient stationnaire en **retirant la tendance déterministe** ; la seconde (racine unitaire) exige une **différenciation**. Appliquer le mauvais traitement dégrade le modèle.

Cas 158. Que se passe-t-il si on différencie une série déjà stationnaire ?

Solution. **Sur-différenciation** : on introduit une structure MA artificielle et on gonfle la variance du bruit. Le modèle devient plus complexe sans gain.

Cas 159. Pourquoi travaille-t-on sur les rendements plutôt que sur les prix ?

Solution. Les prix sont **non stationnaires** (proches d'une marche aléatoire), les rendements le sont approximativement. Passer aux rendements est une différenciation en log, qui restaure la stationnarité.

Cas 160. AIC et BIC désignent des modèles différents. Lequel choisir ?

Solution. Le **BIC** pénalise plus fortement la complexité et sélectionne un modèle plus parcimonieux ; l'**AIC** privilégie la qualité prédictive. Pour la prévision, l'AIC ; pour l'identification du vrai modèle, le BIC.

Cas 161. Un AR(1) a $\phi_1 = 0.5$. Quelle fraction d'un choc subsiste après 3 périodes ?

Solution. $\phi_1^3 = 0.125$, soit **12.5%**. La persistance décroît géométriquement — d'autant plus lentement que ϕ_1 est proche de 1.

Cas 162. Que signifie la stationnarité au sens faible ?

Solution. Moyenne et variance **constantes** dans le temps, et covariance entre deux dates dépendant **uniquement du décalage**, pas de la date. C'est la condition minimale pour que l'estimation ait un sens.

Cas 163. Une série présente une saisonnalité trimestrielle marquée. Comment la traiter ?

Solution. Par une **différenciation saisonnière** ($y_t - y_{t-4}$ pour des données trimestrielles), l'ajout de variables indicatrices saisonnières, ou un modèle SARIMA.

Cas 164. Quel lien entre autocorrélation au chapitre 9 et au chapitre 10 ?

Solution. Au chapitre 9, c'est un **problème** à corriger (elle invalide l'inférence) ; au chapitre 10, c'est l'**objet même** de la modélisation (elle porte l'information prédictive). Même phénomène, statut opposé.

Cas 165. Comment prévoir avec un AR(1) à horizon h ?

Solution. $\mathbb{E}[y_{t+h} \mid y_t] = \mu + \phi_1^h (y_t - \mu)$: la prévision converge **géométriquement** vers la moyenne de long terme. Au-delà d'un certain horizon, aucune information ne subsiste.

Cas 166. Un processus est-il stationnaire si $\phi_1 = -0.9$?

Solution. **Oui** : la condition est $|\phi_1| < 1$, et $|-0.9| = 0.9 < 1$. Le processus oscille (alternance de signes) mais reste stationnaire.

Cas 167. Que révèle une ACF dont tous les retards restent élevés et décroissent très lentement ?

Solution. Une forte suspicion de **non-stationnarité** (racine unitaire). Il faut passer au test ADF avant toute modélisation ARMA.

Cas 168. Deux séries non stationnaires sont cointégrées. Qu'est-ce que cela change ?

Solution. Une **combinaison linéaire** des deux est stationnaire : la régression en niveaux devient légitime et interprétable comme une relation d'**équilibre de long terme**, et non comme une régression fallacieuse.

Cas 169. Pourquoi la variance d'une marche aléatoire croît-elle avec le temps ?

Solution. $y_t = y_0 + \sum_{i=1}^{t} \varepsilon_i$, donc $\mathrm{Var}(y_t) = t\sigma_\varepsilon^2$: les chocs s'accumulent **sans jamais s'atténuer**. C'est l'opposé exact d'un AR(1) stationnaire, où ils s'estompent.

Cas 170. Un modèle ARMA est ajusté mais ses résidus restent autocorrélés. Que faire ?

Solution. Le modèle est **mal spécifié** : augmenter l'ordre p ou q, vérifier la stationnarité, ou envisager une composante saisonnière. Des résidus bien spécifiés doivent être un bruit blanc.

Thème 9 --- Rendements, volatilité, corrélation et VaR (ch. 12)

Cas 171. Un actif passe de 100 à 108. Rendement simple et rendement log ?

Solution. Simple : $8/100 = \mathbf{8}\%$. Log : $\ln(1.08) = \mathbf{7.696}\%$. Le rendement log est toujours inférieur au rendement simple pour un gain positif.

Cas 172. Pourquoi utiliser les rendements log pour l'agrégation temporelle ?

Solution. Ils s'**additionnent** dans le temps : $r_{0\to 2} = r_1 + r_2$. Les rendements simples se composent multiplicativement, ce qui complique les calculs sur plusieurs périodes.

Cas 173. Pourquoi utiliser les rendements simples pour l'agrégation de portefeuille ?

Solution. Le rendement d'un portefeuille est la **moyenne pondérée** des rendements simples de ses composantes — propriété qui ne vaut **pas** pour les rendements log.

Cas 174. Une volatilité quotidienne de 1.5%. Quelle est la volatilité annuelle (252 jours) ?

Solution. $1.5\% \times \sqrt{252} = 1.5 \times 15.87 = \mathbf{23.8}\%$. Valide sous hypothèse de rendements i.i.d.

Cas 175. Quand la règle en $\sqrt{T}$ échoue-t-elle ?

Solution. En présence d'**autocorrélation** des rendements (elle surestime ou sous-estime selon le signe) ou de **clustering de volatilité**. Elle suppose l'indépendance, rarement vérifiée en pratique.

Cas 176. Un modèle EWMA a $\lambda = 0.94$, $\sigma_{t-1} = 1.2\%$, $r_{t-1} = -3\%$. Quelle est σ_t ?

Solution. $\sigma_t^2 = 0.94(0.012^2) + 0.06(0.03^2) = 0.94(0.000144) + 0.06(0.0009) = 0.0001354 + 0.000054 = 0.0001894$. $\sigma_t = \mathbf{1.376}\%$ — le choc a fait bondir la volatilité.

Cas 177. Un GARCH(1,1) a $\omega = 0.000002$, $\alpha = 0.06$, $\beta = 0.92$. Le processus est-il stationnaire ?

Solution. $\alpha + \beta = 0.98 < 1$: **oui**, stationnaire, mais avec une **persistance très élevée** — les chocs de volatilité mettent longtemps à se dissiper.

Cas 178. Quelle est la variance de long terme de ce GARCH ?

Solution. $\sigma_{LT}^2 = \frac{\omega}{1-\alpha-\beta} = \frac{0.000002}{0.02} = 0.0001$, donc $\sigma_{LT} = \mathbf{1}\%$ par jour, soit environ 15.9% en annualisé.

Cas 179. Quelle différence structurelle entre EWMA et GARCH ?

Solution. EWMA est un GARCH avec $\omega = 0$ et $\alpha + \beta = 1$: il n'a donc **aucun retour à une moyenne de long terme**. GARCH intègre ce retour via ω, ce qui le rend plus adapté aux prévisions à long horizon.

Cas 180. Un portefeuille de 50 M€ a une volatilité quotidienne de 0.9%. VaR à 99% sur 1 jour ?

Solution. $2.326 \times 0.009 \times 50{,}000{,}000 = \mathbf{1{,}046{,}700}$ €.

Cas 181. Pourquoi la VaR paramétrique sous-estime-t-elle souvent le risque réel ?

Solution. Elle suppose la **normalité**, alors que les rendements ont des queues épaisses (excès de kurtosis positif). Les pertes extrêmes sont donc plus fréquentes que le modèle ne le prévoit.

Cas 182. Quelles sont les trois approches d'estimation de la VaR ?

Solution. **Paramétrique** (hypothèse de loi, rapide mais rigide), **historique** (distribution empirique, sans hypothèse mais limitée au passé observé), **Monte-Carlo** (flexible, coûteuse, exposée au risque de modèle).

Cas 183. Que mesure l'expected shortfall par rapport à la VaR ?

Solution. La **perte moyenne conditionnelle** au dépassement de la VaR — elle informe sur la *sévérité* au-delà du seuil, là où la VaR ne donne qu'un quantile. Elle est de plus sous-additive, donc cohérente.

Cas 184. Les corrélations d'un portefeuille passent de 0.3 à 0.75 en crise. Quel effet sur le risque ?

Solution. Une **hausse massive** de la volatilité du portefeuille : le bénéfice de diversification s'effondre. Pour un portefeuille équipondéré à volatilité individuelle 20%, la limite asymptotique passe de $20\sqrt{0.3} = 11\%$ à $20\sqrt{0.75} = 17.3\%$.

Cas 185. Comment mesurer une corrélation qui varie dans le temps ?

Solution. Par des corrélations **glissantes**, un modèle EWMA appliqué aux covariances, ou un modèle **DCC-GARCH** (corrélation conditionnelle dynamique) — extension multivariée du GARCH.

Cas 186. Quel est l'arbitrage dans le choix de la fenêtre d'une volatilité glissante ?

Solution. Fenêtre **courte** : réactive aux changements de régime, mais bruitée (variance élevée). Fenêtre **longue** : stable, mais lente à réagir (biais). C'est le compromis biais-variance du chapitre 14 appliqué à l'estimation de volatilité.

Cas 187. Un GARCH a $\alpha + \beta = 0.999$. Quel diagnostic ?

Solution. Persistance **quasi intégrée** : la variance met extrêmement longtemps à revenir à sa moyenne, et le modèle est proche de la non-stationnarité (IGARCH). Prévisions de long terme peu fiables.

Cas 188. Pourquoi le clustering de volatilité justifie-t-il GARCH plutôt qu'une volatilité constante ?

Solution. Parce qu'il implique une **dépendance temporelle de la variance** : une forte volatilité aujourd'hui prédit une forte volatilité demain. Un modèle à volatilité constante ignore cette information exploitable.

Cas 189. Comment convertir une VaR à 1 jour en VaR à 10 jours ?

Solution. Multiplier par $\sqrt{10} \approx 3.162$ sous hypothèse i.i.d. C'est d'ailleurs l'approche réglementaire simplifiée de Bâle, malgré ses limites reconnues.

Cas 190. Un actif a un rendement log moyen de 0.03% par jour. Rendement annualisé (252 jours) ?

Solution. Les rendements log s'additionnent : $0.03\% \times 252 = \mathbf{7.56}\%$ en log, soit $e^{0.0756} - 1 = \mathbf{7.85}\%$ en rendement simple.

Cas 191. Pourquoi la volatilité s'annualise-t-elle en $\sqrt{T}$ alors que le rendement s'annualise en T ?

Solution. Le rendement cumulé est une **somme**, dont l'espérance croît en T. La variance d'une somme d'i.i.d. croît aussi en T, donc l'**écart-type** croît en $\sqrt{T}$. Conséquence : le ratio de Sharpe croît en $\sqrt{T}$.

Cas 192. Un gérant compare le Sharpe quotidien et annuel de sa stratégie. Quelle relation ?

Solution. $\text{Sharpe}_{\text{annuel}} = \text{Sharpe}_{\text{quotidien}} \times \sqrt{252}$, sous hypothèse i.i.d. — conséquence directe de l'asymétrie d'échelle entre rendement (T) et volatilité ($\sqrt{T}$).

Thème 10 --- Simulation, bootstrap et machine learning (ch. 13-15)

Cas 193. Une simulation Monte-Carlo de 10 000 tirages donne une erreur-type de 0.4. Combien de tirages pour atteindre 0.1 ?

Solution. L'erreur varie en $1/\sqrt{N}$: diviser par 4 exige de multiplier N par 16, soit **160 000** tirages.

Cas 194. Quelle est la différence fondamentale entre Monte-Carlo et bootstrap ?

Solution. Monte-Carlo génère depuis une **loi supposée** (paramétrique, exposé au risque de modèle) ; le bootstrap **rééchantillonne les données observées** (non paramétrique, mais borné par l'historique disponible).

Cas 195. Pourquoi le bootstrap est-il inadapté aux stress tests de scénarios inédits ?

Solution. Il ne peut générer **aucun scénario plus extrême** que le pire déjà observé. Pour explorer l'inédit, il faut du Monte-Carlo paramétrique avec des queues épaisses, ou des scénarios construits à dire d'expert.

Cas 196. Que sont les variables antithétiques et à quoi servent-elles ?

Solution. Utiliser Z *et* $-Z$ dans la même simulation : les erreurs se compensent partiellement, **réduisant la variance** de l'estimateur sans augmenter N — un gain d'efficacité de calcul pur.

Cas 197. Quelle fraction des observations est exclue de chaque échantillon bootstrap ?

Solution. Environ $1/e \approx \mathbf{36.8}\%$ — résultat indépendant de n (pour n grand), directement réutilisé pour l'estimation out-of-bag des forêts aléatoires (chapitre 14).

Cas 198. Des données sont autocorrélées. Quel bootstrap utiliser ?

Solution. Un **bootstrap par blocs**, qui rééchantillonne des séquences contiguës pour préserver la structure de dépendance temporelle. Le bootstrap i.i.d. classique la détruirait.

Cas 199. Un modèle a une erreur d'entraînement de 2% et une erreur de test de 18%. Diagnostic ?

Solution. **Surapprentissage** caractérisé : l'écart massif signale un modèle qui a mémorisé le bruit. Remèdes : régularisation, élagage, agrégation, ou simplification du modèle.

Cas 200. Ridge et Lasso avec λ identique sur 50 variables : combien de coefficients nuls attendre de chacun ?

Solution. Ridge : **aucun** (rétrécissement sans annulation, contrainte lisse). Lasso : **plusieurs** exactement nuls (contrainte à coins) — la sélection automatique de variables.

Cas 201. Un bagging de 500 arbres a $\rho = 0.6$ entre arbres, $\sigma^2 = 20$. Variance de l'ensemble ?

Solution. $\rho\sigma^2 + \frac{1-\rho}{B}\sigma^2 = 0.6(20) + \frac{0.4}{500}(20) = 12 + 0.016 = \mathbf{12.02}$ — à peine mieux que 20. La corrélation élevée neutralise le bénéfice de l'agrégation.

Cas 202. Même cas avec $\rho = 0.1$ (forêt aléatoire). Variance ?

Solution. $0.1(20) + \frac{0.9}{500}(20) = 2 + 0.036 = \mathbf{2.04}$ — une réduction de variance d'un facteur 10 par rapport à l'arbre isolé. C'est la décorrélation, non l'agrégation seule, qui fait la performance.

Cas 203. Bagging et boosting : quel levier pour chacun ?

Solution. Bagging (parallèle) $\rightarrow$ réduction de la **variance**. Boosting (séquentiel) $\rightarrow$ réduction du **biais**. Confondre les deux est le piège le plus testé du chapitre 14.

Cas 204. Augmenter B dans une forêt aléatoire peut-il causer du surapprentissage ?

Solution. **Non** : plus d'arbres ne fait que stabiliser la moyenne. En revanche, augmenter M en **boosting** le peut — asymétrie fondamentale entre les deux approches.

Cas 205. Une régression logistique a $\hat{\beta} = 0.7$ pour l'endettement. Odds ratio et interprétation ?

Solution. $e^{0.7} = \mathbf{2.01}$: chaque unité supplémentaire d'endettement **multiplie par 2** les odds de défaut, toutes choses égales par ailleurs.

Cas 206. Un modèle logistique donne $z = -1.5$. Quelle est la probabilité prédite ?

Solution. $P = \frac{1}{1+e^{1.5}} = \frac{1}{1+4.4817} = \mathbf{18.2}\%$.

Cas 207. Une matrice de confusion donne VP=30, FP=70, FN=20, VN=880. Précision et rappel ?

Solution. Précision $= 30/100 = \mathbf{30}\%$; rappel $= 30/50 = \mathbf{60}\%$. L'exactitude serait $910/1000 = 91\%$ — trompeuse sur une classe rare (5% de positifs).

Cas 208. Dans le cas précédent, calculer le score F_1.

Solution. $F_1 = 2\frac{0.30 \times 0.60}{0.30+0.60} = 2\frac{0.18}{0.90} = \mathbf{0.40}$. La moyenne harmonique pénalise le déséquilibre entre les deux métriques.

Cas 209. Un modèle a une AUC de 0.5. Que conclure ?

Solution. Il ne **discrimine pas mieux qu'un tirage aléatoire**. Sa courbe ROC est la diagonale : aucune valeur prédictive, quel que soit le seuil retenu.

Cas 210. Pourquoi comparer des modèles par AUC plutôt que par exactitude ?

Solution. L'AUC est **indépendante du seuil et de la prévalence** des classes, alors que l'exactitude dépend fortement des deux — rendant toute comparaison entre modèles peu fiable sur classes déséquilibrées.

Cas 211. Un faux négatif coûte 10 fois plus qu'un faux positif. Comment ajuster le seuil ?

Solution. **Abaisser** le seuil de décision pour augmenter le rappel (moins de faux négatifs), en acceptant davantage de faux positifs. Le seuil optimal minimise le coût total pondéré, pas le taux d'erreur brut.

Cas 212. Pourquoi une activation non linéaire est-elle indispensable dans un réseau de neurones ?

Solution. Sans elle, la composition de plusieurs couches linéaires reste **une seule transformation linéaire** : la profondeur n'apporterait rigoureusement aucun pouvoir expressif supplémentaire.

Cas 213. Quel est le lien entre validation croisée (ch. 14) et tests multiples (ch. 6) ?

Solution. Les deux répondent au même danger : **exploiter le hasard des données**. La validation croisée protège contre le surapprentissage comme la correction de Bonferroni protège contre les fausses découvertes.

Cas 214. Un réseau de neurones sans couche cachée avec sortie sigmoïde équivaut à quoi ?

Solution. Exactement à une **régression logistique**. Cette équivalence ancre les deux modèles sur un même continuum : le réseau n'est qu'une logistique enrichie de représentations intermédiaires apprises.

Partie E --- 210 QCM d'examen sur le Book 2

210 questions de style examen couvrant les quinze chapitres, à raison de quatorze par chapitre. Une seule réponse correcte, positions équilibrées. Corrigé commenté en Partie F.

Thème 1 --- Fondamentaux de probabilité (ch. 1)

Q1. Deux événements mutuellement exclusifs vérifient :

(a) $P(A \cap B) = 0$

(b) $P(A \cup B) = P(A)P(B)$

(c) $P(A|B) = P(A)$

(d) $P(A \cap B) = P(A)P(B)$

Q2. Deux événements indépendants vérifient :

(a) $P(A \cap B) = 0$

(b) $P(A \cap B) = P(A)P(B)$

(c) $P(A \cup B) = 0$

(d) A et B sont exclusifs

Q3. Des événements mutuellement exclusifs de probabilités non nulles sont :

(a) sans lien logique

(b) nécessairement indépendants

(c) nécessairement dépendants

(d) toujours équiprobables

Q4. La règle d'addition générale s'écrit :

(a) $P(A \cup B) = P(A)P(B)$

(b) $P(A \cup B) = P(A|B)P(B)$

(c) $P(A \cup B) = P(A) + P(B)$

(d) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Q5. La probabilité conditionnelle P(A|B) vaut :

(a) $P(A \cap B)/P(B)$

(b) $P(A \cap B)/P(A)$

(c) $P(A)P(B)$

(d) $P(A) + P(B)$

Q6. La règle de multiplication s'écrit :

(a) $P(A \cap B) = P(A) + P(B)$

(b) $P(A \cap B) = P(A|B)P(B)$

(c) $P(A \cap B) = P(A)/P(B)$

(d) $P(A \cap B) = P(A \cup B)$

Q7. Le théorème de Bayes permet de :

(a) estimer une variance

(b) calculer une probabilité jointe

(c) inverser le conditionnement

(d) tester une hypothèse

Q8. Dans Bayes, $P(A)$ avant observation s'appelle :

(a) la probabilité a posteriori

(b) l'évidence

(c) la vraisemblance

(d) la probabilité a priori (prior)

Q9. Le piège du taux de base consiste à :

(a) ignorer la probabilité a priori d'un événement rare

(b) confondre variance et écart-type

(c) oublier la règle d'addition

(d) utiliser une loi normale

Q10. La loi des probabilités totales décompose P(B) en :

(a) $P(A \cup B)$

(b) $\sum P(B|A_i)P(A_i)$ sur une partition

(c) $P(B)P(A)$

(d) $P(B|A)/P(A)$

Q11. Le nombre de combinaisons de k éléments parmi n vaut :

(a) $n!/k!$

(b) $n!/(n-k)!$

(c) $n!/[k!(n-k)!]$

(d) n^k

Q12. Le nombre d'arrangements de k éléments parmi n vaut :

(a) n^k

(b) k!

(c) $n!/[k!(n-k)!]$

(d) $n!/(n-k)!$

Q13. Deux événements indépendants conditionnellement à C sont :

(a) pas nécessairement indépendants inconditionnellement

(b) toujours exclusifs

(c) équiprobables

(d) nécessairement indépendants inconditionnellement

Q14. La probabilité de l'événement complémentaire vaut :

(a) $P(A)^2$

(b) $1 - P(A)$

(c) $P(A)$

(d) $1/P(A)$

Thème 2 --- Variables aléatoires et moments (ch. 2)

Q15. Une fonction de masse (PMF) décrit :

(a) un quantile

(b) une variable continue

(c) une variable discrète

(d) une fonction de répartition

Q16. Pour une variable continue, $P(X = x)$ vaut :

(a) 1

(b) la CDF en x

(c) la densité en x

(d) zéro

Q17. La fonction de répartition (CDF) $F(x)$ représente :

(a) $P(X \leq x)$

(b) $P(X > x)$

(c) la densité

(d) $P(X = x)$

Q18. L'espérance d'une variable discrète vaut :

(a) $\max(x)$

(b) $\sum x\, P(X = x)$

(c) $\sum P(X = x)$

(d) $\sum x$

Q19. La variance s'écrit :

(a) $E[X] - E[X^2]$

(b) $E[X]^2 - E[X^2]$

(c) $E[X^2] - (E[X])^2$

(d) $E[X^2] + (E[X])^2$

Q20. Pour a et b constants, $\text{Var}(aX + b)$ vaut :

(a) $a^2\text{Var}(X) + b^2$

(b) $\text{Var}(X)$

(c) $a\,\text{Var}(X) + b$

(d) $a^2\text{Var}(X)$

Q21. Le troisième moment centré normalisé mesure :

(a) l'asymétrie (skewness)

(b) la moyenne

(c) la médiane

(d) l'aplatissement

Q22. Le quatrième moment centré normalisé mesure :

(a) l'asymétrie

(b) le kurtosis (aplatissement)

(c) la variance

(d) la covariance

Q23. Le kurtosis d'une loi normale vaut :

(a) 0

(b) 1

(c) 3

(d) 4

Q24. Une skewness négative indique :

(a) une symétrie parfaite

(b) un kurtosis élevé

(c) une queue à droite plus longue

(d) une queue à gauche plus longue

Q25. Pour $E[aX + bY]$, la linéarité de l'espérance exige :

(a) aucune condition d'indépendance

(b) une distribution normale

(c) une variance finie nulle

(d) l'indépendance de X et Y

Q26. La fonction quantile est :

(a) la dérivée de la CDF

(b) l'inverse de la CDF

(c) le carré de la PDF

(d) l'espérance conditionnelle

Q27. La médiane correspond au quantile :

(a) 0.95

(b) 0.25

(c) 0.50

(d) 0.75

Q28. Pour X et Y indépendantes, $\text{Var}(X + Y)$ vaut :

(a) $\text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$

(b) $\mathrm{Var}(X) \cdot \mathrm{Var}(Y)$

(c) $\mathrm{Var}(X) - \mathrm{Var}(Y)$

(d) $\mathrm{Var}(X) + \mathrm{Var}(Y)$

Thème 3 --- Lois univariées usuelles (ch. 3)

Q29. La loi de Bernoulli décrit :

(a) une expérience binaire à un essai

(b) un temps d'attente

(c) une variable continue

(d) un nombre de succès sur n essais

Q30. La loi binomiale a pour espérance :

(a) n/p

(b) np

(c) $np(1-p)$

(d) p

Q31. La variance de la loi binomiale vaut :

(a) $p(1-p)$

(b) np

(c) $np(1-p)$

(d) n^2p

Q32. La loi de Poisson modélise typiquement :

(a) une durée de vie

(b) un prix d'action

(c) un rendement continu

(d) un nombre d'événements rares sur une période

Q33. Pour la loi de Poisson, espérance et variance valent :

(a) λ et λ

(b) λ^2 et λ

(c) $1/\lambda$ et $1/\lambda^2$

(d) λ et λ^2

Q34. La loi normale est entièrement caractérisée par :

(a) sa seule moyenne

(b) sa moyenne et sa variance

(c) ses quatre premiers moments

(d) son kurtosis

Q35. Le quantile à 95 % (unilatéral) de la loi normale centrée réduite vaut environ :

(a) 2.33

(b) 1.28

(c) 1.645

(d) 1.96

Q36. Le quantile à 99 % (unilatéral) de la loi normale centrée réduite vaut environ :

(a) 2.58

(b) 1.645

(c) 1.96

(d) 2.33

Q37. La loi de Student comparée à la normale possède :

(a) des queues plus épaisses

(b) la même forme exactement

(c) une variance nulle

(d) des queues plus fines

Q38. Quand le nombre de degrés de liberté augmente, la loi de Student :

(a) s'éloigne de la normale

(b) converge vers la loi normale

(c) devient uniforme

(d) devient discrète

Q39. La loi log-normale est utilisée pour modéliser :

(a) des variables binaires

(b) des rendements pouvant être négatifs

(c) des prix strictement positifs

(d) des comptages

Q40. La loi du khi-deux est la somme de :

(a) lois de Poisson

(b) lois exponentielles

(c) variables uniformes

(d) carrés de normales centrées réduites indépendantes

Q41. La loi exponentielle est caractérisée par la propriété :

(a) d'absence de mémoire

(b) de symétrie

(c) de kurtosis nul

(d) de mémoire

Q42. Une distribution à queues épaisses implique, par rapport à la normale :

(a) moins d'événements extrêmes

(b) davantage d'événements extrêmes

(c) aucune différence

(d) une variance infinie systématique

Thème 4 --- Lois multivariées et dépendance (ch. 4)

Q43. La covariance entre X et Y mesure :

(a) la variance de X seule

(b) la force normalisée du lien

(c) la codirectionnalité, en unités produit

(d) la causalité

Q44. La corrélation de Pearson est bornée par :

(a) $[-\infty, \infty]$

(b) $[0, \infty]$

(c) $[0, 1]$

(d) $[-1, 1]$

Q45. Une corrélation nulle implique :

(a) l'absence de relation linéaire seulement

(b) l'absence de toute relation

(c) une covariance infinie

(d) l'indépendance

Q46. Sous normalité conjointe, corrélation nulle implique :

(a) rien de particulier

(b) l'indépendance

(c) une variance nulle

(d) une causalité

Q47. La variance d'un portefeuille à deux actifs vaut :

(a) $\sigma_1^2 + \sigma_2^2$

(b) $w_1^2\sigma_1^2 + w_2^2\sigma_2^2$

(c) $w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + 2w_1w_2\sigma_1\sigma_2\rho$

(d) $w_1\sigma_1 + w_2\sigma_2$

Q48. Le bénéfice de diversification est maximal quand la corrélation vaut :

(a) 0.5

(b) +1

(c) 0

(d) -1

Q49. Avec une corrélation égale à +1, la volatilité du portefeuille est :

(a) la moyenne pondérée des volatilités

(b) inférieure à la moyenne pondérée

(c) toujours maximale à 100 %

(d) nulle

Q50. La corrélation de Spearman mesure :

(a) une relation linéaire

(b) une relation monotone par les rangs

(c) la covariance brute

(d) le kurtosis

Q51. Cov(X, X) est égal à :

(a) 0

(b) 1

(c) Var(X)

(d) $E[X]$

Q52. Pour X et Y indépendantes, Cov(X, Y) vaut :

(a) Var(X)

(b) indéterminé

(c) 1

(d) 0

Q53. L'espérance conditionnelle $E[Y|X]$ représente :

(a) la moyenne de Y sachant la valeur de X

(b) la variance de Y

(c) la corrélation

(d) la médiane de X

Q54. La matrice de covariance d'un portefeuille est nécessairement :

(a) triangulaire

(b) symétrique

(c) antisymétrique

(d) diagonale

Q55. Ajouter un actif faiblement corrélé à un portefeuille tend à :

(a) annuler tout rendement

(b) augmenter la volatilité totale

(c) réduire la volatilité totale

(d) laisser la volatilité inchangée

Q56. La corrélation est invariante par :

(a) toute transformation

(b) permutation aléatoire

(c) transformation non linéaire

(d) transformation linéaire croissante

Thème 5 --- Moments d'échantillon et estimation (ch. 5)

Q57. La moyenne d'échantillon est un estimateur :

(a) sans biais de la moyenne

(b) de la variance

(c) de la médiane uniquement

(d) biaisé de la moyenne

Q58. L'erreur type de la moyenne vaut :

(a) σ/n

(b) $\sigma/\sqrt{n}$

(c) σ^2/n

(d) σ

Q59. Pour diviser l'erreur type par deux, il faut multiplier n par :

(a) 16

(b) 2

(c) 4

(d) 8

Q60. La variance d'échantillon sans biais divise par :

(a) $n+1$

(b) n^2

(c) n

(d) $n-1$

Q61. Le théorème central limite affirme que la moyenne d'échantillon :

(a) tend vers une loi normale quand n croît

(b) est toujours biaisée

(c) a une variance croissante

(d) suit la loi de la population

Q62. Le TCL s'applique :

(a) uniquement si la population est normale

(b) quelle que soit la loi de la population, sous variance finie

(c) seulement pour n < 30

(d) uniquement aux lois discrètes

Q63. Un estimateur convergent (consistant) vérifie :

(a) une espérance nulle

(b) un biais croissant avec n

(c) une convergence en probabilité vers le paramètre

(d) une variance croissante

Q64. Entre deux estimateurs sans biais, on préfère celui :

(a) le plus complexe

(b) le plus ancien

(c) de plus grande variance

(d) de plus faible variance (efficace)

Q65. Un intervalle de confiance à 95 % pour une moyenne (σ connu) s'écrit :

(a) $\bar{x} \pm 1.96\,\sigma/\sqrt{n}$

(b) $\bar{x} \pm 2.58\,\sigma/\sqrt{n}$

(c) $\bar{x} \pm \sigma$

(d) $\bar{x} \pm 1.645\,\sigma/\sqrt{n}$

Q66. Quand σ est inconnu et n petit, on utilise :

(a) la loi normale

(b) la loi de Student

(c) la loi de Poisson

(d) la loi uniforme

Q67. Un intervalle de confiance à 99 % est, par rapport à 95 % :

(a) toujours centré sur zéro

(b) plus étroit

(c) plus large

(d) identique

Q68. Le biais d'un estimateur est défini par :

(a) $\theta - \hat{\theta}$

(b) Var$(\hat{\theta})$

(c) $E[\hat{\theta}]^2$

(d) $E[\hat{\theta}] - \theta$

Q69. L'erreur quadratique moyenne d'un estimateur combine :

(a) biais^2 et variance

(b) aucun des deux

(c) biais seul

(d) variance seule

Q70. La loi des grands nombres garantit que la moyenne d'échantillon :

(a) diverge

(b) converge vers l'espérance

(c) oscille indéfiniment

(d) est toujours normale

Thème 6 --- Tests d'hypothèses (ch. 6)

Q71. L'hypothèse nulle H_0 est celle que l'on :

(a) calcule

(b) cherche à prouver

(c) cherche à rejeter, par défaut maintenue

(d) ignore

Q72. Une erreur de type I consiste à :

(a) accepter H_1 vraie

(b) calculer un mauvais estimateur

(c) ne pas rejeter H_0 fausse

(d) rejeter H_0 vraie

Q73. Une erreur de type II consiste à :

(a) ne pas rejeter H_0 fausse

(b) choisir un mauvais test

(c) augmenter α

(d) rejeter H_0 vraie

Q74. La puissance d'un test vaut :

(a) β

(b) 1-β

(c) α

(d) 1-α

Q75. Réduire α, toutes choses égales par ailleurs :

(a) supprime l'erreur de type I

(b) augmente la puissance

(c) augmente le risque d'erreur de type II

(d) n'a aucun effet

Q76. La p-value représente :

(a) la puissance du test

(b) le seuil α

(c) la probabilité que H_0 soit vraie

(d) la probabilité d'observer une statistique au moins aussi extrême si H_0 est vraie

Q77. On rejette H_0 quand :

(a) p-value $< \alpha$

(b) p-value $= 1$

(c) la statistique vaut zéro

(d) p-value $> \alpha$

Q78. Un test bilatéral à 5 % utilise une valeur critique normale de :

(a) 1.645

(b) 1.96

(c) 2.33

(d) 2.58

Q79. Un test unilatéral à 5 % utilise une valeur critique normale de :

(a) 2.58

(b) 1.28

(c) 1.645

(d) 1.96

Q80. Augmenter la taille d'échantillon, à effet constant :

(a) augmente β

(b) ne change rien

(c) réduit la puissance

(d) augmente la puissance

Q81. La significativité statistique implique-t-elle l'importance économique ?

(a) Non, un effet minuscule peut être significatif si n est grand

(b) Oui, si $p < 0.01$

(c) Non, sauf en régression

(d) Oui, toujours

Q82. Ne pas rejeter H_0 signifie :

(a) H_0 est prouvée vraie

(b) les données sont insuffisantes pour la rejeter

(c) H_1 est fausse

(d) le test est invalide

Q83. Un intervalle de confiance à 95 % contenant zéro implique, pour un test bilatéral à 5 % :

(a) une puissance nulle

(b) le rejet de H_0 : paramètre nul

(c) le non-rejet de H_0 : paramètre nul

(d) une erreur de type I

Q84. La statistique de test se compare à :

(a) la variance de population

(b) la p-value elle-même

(c) la moyenne d'échantillon

(d) une valeur critique issue de la loi sous H_0

Thème 7 --- Régression linéaire simple (ch. 7)

Q85. La méthode des moindres carrés ordinaires minimise :

(a) la somme des carrés des résidus

(b) la variance de X

(c) le nombre de variables

(d) la somme des résidus

Q86. Dans $y = \beta_0 + \beta_1 x + \varepsilon$, le coefficient β_1 mesure :

(a) la valeur de y quand x = 0

(b) la variation attendue de y pour une unité de x

(c) la corrélation

(d) la variance résiduelle

Q87. Le R^2 représente :

(a) la pente

(b) la corrélation entre résidus

(c) la part de variance de y expliquée par le modèle

(d) la variance résiduelle

Q88. En régression simple, le R^2 est égal à :

(a) la pente au carré

(b) 1 moins la pente

(c) la corrélation entre x et y

(d) le carré de la corrélation entre x et y

Q89. L'estimateur MCO est sans biais sous l'hypothèse :

(a) d'exogénéité, $E[\varepsilon|x] = 0$

(b) de normalité des résidus

(c) d'absence d'autocorrélation

(d) d'homoscédasticité

Q90. Le théorème de Gauss-Markov qualifie les MCO de :

(a) meilleur estimateur non linéaire

(b) BLUE : meilleur estimateur linéaire sans biais

(c) estimateur biaisé optimal

(d) estimateur du maximum de vraisemblance

Q91. La normalité des résidus est nécessaire pour :

(a) la linéarité

(b) l'absence de biais des coefficients

(c) l'inférence exacte en petit échantillon

(d) le calcul du R^2

Q92. Un résidu est défini par :

(a) $\hat{y} - y$

(b) $y - x$

(c) $x - \bar{x}$

(d) $y - \hat{y}$

Q93. La statistique t d'un coefficient vaut :

(a) $\hat{\beta}$ divisé par son erreur type

(b) $\hat{\beta}\times$ erreur type

(c) $\hat{\beta}^2$

(d) $\hat{\beta}/n$

Q94. Une pente estimée avec un t-stat de 0.7 est :

(a) significative à 5 %

(b) non significative à 5 %

(c) nécessairement erronée

(d) égale à zéro exactement

Q95. La droite de régression MCO passe toujours par :

(a) le premier point observé

(b) l'origine

(c) le point $(\bar{x}, \bar{y})$

(d) le maximum de y

Q96. La somme des résidus MCO (avec constante) vaut :

(a) la variance

(b) n

(c) 1

(d) 0

Q97. Corrélation élevée entre x et y implique-t-elle causalité ?

(a) Non, jamais nécessairement

(b) Oui, si $R^2 > 0.9$

(c) Oui, en régression seulement

(d) Oui, toujours

Q98. L'erreur type de la régression (SER) mesure :

(a) la pente

(b) la dispersion typique des résidus

(c) le R^2

(d) le nombre d'observations

Thème 8 --- Régression multiple (ch. 8)

Q99. En régression multiple, β_1 mesure l'effet de x_1 :

(a) sur le R^2 seul

(b) brut, sans contrôle

(c) toutes choses égales par ailleurs

(d) sur la variance

Q100. Le R^2 ajusté diffère du R^2 car il :

(a) ignore les résidus

(b) vaut toujours 1

(c) augmente toujours avec les variables

(d) pénalise l'ajout de variables inutiles

Q101. Ajouter une variable non pertinente fait :

(a) monter ou stagner le R^2, mais possiblement baisser le R^2 ajusté

(b) annuler le R^2

(c) diverger les coefficients

(d) baisser le R^2

Q102. Le test F global teste :

(a) un coefficient isolé

(b) la nullité conjointe de tous les coefficients de pente

(c) la normalité

(d) l'homoscédasticité

Q103. La multicolinéarité parfaite rend :

(a) le test F invalide seulement

(b) le R^2 nul

(c) l'estimation MCO impossible (matrice singulière)

(d) les résidus nuls

Q104. La multicolinéarité imparfaite provoque :

(a) un R^2 nul

(b) une hétéroscédasticité

(c) un biais des coefficients

(d) des erreurs types gonflées

Q105. Un symptôme typique de multicolinéarité est :

(a) un R^2 élevé avec des t-stats individuels faibles

(b) un R^2 nul

(c) des résidus autocorrélés

(d) une pente négative

Q106. Le VIF (facteur d'inflation de la variance) mesure :

(a) l'hétéroscédasticité

(b) le degré de multicolinéarité

(c) l'autocorrélation

(d) la normalité

Q107. Omettre une variable pertinente corrélée aux régresseurs cause :

(a) une hétéroscédasticité

(b) une perte de R^2 seulement

(c) un biais de variable omise

(d) une multicolinéarité

Q108. Le nombre de degrés de liberté d'une régression à k régresseurs et une constante vaut :

(a) $k+1$

(b) n

(c) $n-k$

(d) $n-k-1$

Q109. Une variable indicatrice (dummy) pour C catégories nécessite :

(a) $C-1$ indicatrices

(b) une seule variable continue

(c) C+1 indicatrices

(d) C indicatrices

Q110. Un terme d'interaction $x_1 \cdot x_2$ capture :

(a) un effet non linéaire de x_1 seul

(b) un effet de x_1 dépendant du niveau de x_2

(c) l'hétéroscédasticité

(d) l'autocorrélation

Q111. Le R^2 ajusté peut-il être négatif ?

(a) Seulement si $n < 10$

(b) Non, jamais

(c) Oui, si le modèle est très mauvais

(d) Oui, systématiquement

Q112. La comparaison de deux modèles emboîtés se fait par :

(a) un test de Durbin-Watson

(b) un test de White

(c) un test t

(d) un test F partiel

Thème 9 --- Diagnostics de régression (ch. 9)

Q113. L'hétéroscédasticité désigne :

(a) une variance résiduelle non constante

(b) des résidus corrélés

(c) des résidus non normaux

(d) une variance résiduelle constante

Q114. En cas d'hétéroscédasticité, les coefficients MCO restent :

(a) biaisés

(b) sans biais mais inefficaces

(c) nuls

(d) incalculables

Q115. Le remède usuel à l'hétéroscédasticité est :

(a) ignorer le problème

(b) supprimer des observations

(c) utiliser des erreurs types robustes (White)

(d) ajouter des variables au hasard

Q116. Le test de White détecte :

(a) la multicolinéarité

(b) la non-normalité

(c) l'autocorrélation

(d) l'hétéroscédasticité

Q117. L'autocorrélation des résidus est fréquente sur :

(a) des séries temporelles

(b) des données binaires

(c) des variables catégorielles

(d) des données en coupe transversale

Q118. La statistique de Durbin-Watson teste :

(a) l'hétéroscédasticité

(b) l'autocorrélation d'ordre 1

(c) la normalité

(d) la multicolinéarité

Q119. Une valeur de Durbin-Watson proche de 0 indique :

(a) l'absence d'autocorrélation

(b) une hétéroscédasticité

(c) une autocorrélation positive forte

(d) une autocorrélation négative

Q120. En cas d'autocorrélation, les erreurs types MCO sont typiquement :

(a) toujours nulles

(b) surestimées systématiquement

(c) correctes

(d) sous-estimées, gonflant la significativité apparente

Q121. La correction de Newey-West produit des erreurs types robustes à :

(a) l'hétéroscédasticité et l'autocorrélation

(b) la non-linéarité

(c) la normalité

(d) la multicolinéarité seule

Q122. Une observation influente est celle qui :

(a) a un résidu nul

(b) modifie fortement les coefficients si on la retire

(c) est la première de l'échantillon

(d) a une valeur moyenne

Q123. La non-linéarité de la vraie relation cause :

(a) une multicolinéarité

(b) une simple perte d'efficacité

(c) un modèle mal spécifié, aux coefficients biaisés

(d) une hétéroscédasticité mécanique

Q124. Un graphique des résidus en forme d'entonnoir signale :

(a) la multicolinéarité

(b) la normalité

(c) l'autocorrélation

(d) l'hétéroscédasticité

Q125. Un motif cyclique dans les résidus tracés dans le temps signale :

(a) l'autocorrélation

(b) la multicolinéarité

(c) une bonne spécification

(d) l'hétéroscédasticité

Q126. La normalité des résidus affecte principalement :

(a) l'absence de biais des coefficients

(b) la validité de l'inférence en petit échantillon

(c) le calcul du R^2

(d) la linéarité du modèle

Thème 10 --- Séries temporelles stationnaires (ch. 10)

Q127. Une série stationnaire au sens faible possède :

(a) une variance croissante

(b) une racine unitaire

(c) une moyenne et une variance constantes dans le temps

(d) une tendance déterministe

Q128. Un processus AR(1) s'écrit :

(a) $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$

(b) $y_t = t + \varepsilon_t$

(c) $y_t = \varepsilon_t$

(d) $y_t = \varphi y_{t-1} + \varepsilon_t$

Q129. Un processus AR(1) est stationnaire si :

(a) $|\varphi| < 1$

(b) $\varphi = 1$

(c) $\varphi = 0$ uniquement

(d) $|\varphi| > 1$

Q130. Un processus MA(1) s'écrit :

(a) $y_t = \varphi y_{t-1} + \varepsilon_t$

(b) $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$

(c) $y_t = t$

(d) $y_t = y_{t-1} + \varepsilon_t$

Q131. La fonction d'autocorrélation (ACF) d'un AR(1) stationnaire :

(a) est toujours négative

(b) s'annule après le retard 1

(c) décroît géométriquement

(d) est constante

Q132. L'ACF d'un MA(1) :

(a) croît avec le retard

(b) est toujours égale à 1

(c) décroît géométriquement

(d) s'annule au-delà du retard 1

Q133. L'autocorrélation partielle (PACF) d'un AR(1) :

(a) s'annule au-delà du retard 1

(b) est constante

(c) croît

(d) décroît lentement

Q134. Le critère d'information d'Akaike (AIC) sert à :

(a) tester la stationnarité

(b) sélectionner l'ordre du modèle

(c) mesurer l'hétéroscédasticité

(d) calculer la VaR

Q135. Comparé à l'AIC, le critère BIC pénalise la complexité :

(a) pas du tout

(b) moins fortement

(c) plus fortement

(d) de façon identique

Q136. L'espérance à long terme d'un AR(1) stationnaire vaut :

(a) $c\varphi$

(b) $\varphi/(1-c)$

(c) 0 toujours

(d) $c/(1-\varphi)$

Q137. Un bruit blanc possède :

(a) une moyenne nulle, variance constante et autocorrélation nulle

(b) une tendance

(c) une racine unitaire

(d) une autocorrélation forte

Q138. La prévision d'un AR(1) stationnaire à horizon lointain converge vers :

(a) l'infini

(b) la moyenne de long terme

(c) la dernière observation

(d) zéro nécessairement

Q139. La saisonnalité dans une série se traite typiquement par :

(a) le bootstrap

(b) le VIF

(c) des variables indicatrices saisonnières ou une différenciation saisonnière

(d) une régression logistique

Q140. Un modèle ARMA(p, q) combine :

(a) deux tendances

(b) AR et hétéroscédasticité

(c) deux composantes autorégressives

(d) une composante AR et une composante MA

Thème 11 --- Séries non stationnaires (ch. 11)

Q141. Une marche aléatoire $y_t = y_{t-1} + \varepsilon_t$ est :

(a) non stationnaire, à racine unitaire

(b) à moyenne constante nulle

(c) un bruit blanc

(d) stationnaire

Q142. La variance d'une marche aléatoire à l'horizon t :

(a) est constante

(b) croît linéairement avec t

(c) décroît

(d) est nulle

Q143. Le test de Dickey-Fuller augmenté teste :

(a) la multicolinéarité

(b) l'hétéroscédasticité

(c) la présence d'une racine unitaire

(d) la normalité

Q144. Dans le test ADF, l'hypothèse nulle est :

(a) l'absence d'autocorrélation

(b) la normalité

(c) la stationnarité

(d) la présence d'une racine unitaire

Q145. Ne pas rejeter H_0 dans un test ADF suggère :

(a) une série non stationnaire

(b) une hétéroscédasticité

(c) une multicolinéarité

(d) une série stationnaire

Q146. Le remède usuel à une racine unitaire est :

(a) ajouter des variables

(b) différencier la série

(c) augmenter n

(d) appliquer le bootstrap

Q147. Une série intégrée d'ordre 1, notée $I(1)$, devient stationnaire après :

(a) un log seulement

(b) aucune différenciation

(c) une différenciation

(d) deux différenciations

Q148. La régression fallacieuse (spurious regression) survient quand :

(a) les résidus sont normaux

(b) n est petit

(c) deux séries stationnaires sont régressées

(d) deux séries non stationnaires indépendantes sont régressées

Q149. Un signe typique de régression fallacieuse est :

(a) un R^2 élevé avec des résidus fortement autocorrélés

(b) des résidus normaux

(c) un test F non significatif

(d) un R^2 faible

Q150. Deux séries $I(1)$ sont cointégrées si :

(a) leur différence est toujours $I(1)$

(b) une combinaison linéaire des deux est stationnaire

(c) elles sont indépendantes

(d) elles ont même variance

Q151. Le modèle à correction d'erreur (ECM) s'applique à des séries :

(a) binaires

(b) stationnaires uniquement

(c) cointégrées

(d) indépendantes

Q152. Une tendance déterministe se traite par :

(a) le bootstrap

(b) un test de White

(c) une différenciation seulement

(d) l'ajout d'un terme de tendance temporelle

Q153. La différenciation excessive d'une série (surdifférenciation) provoque :

(a) l'introduction d'une structure MA artificielle

(b) la stationnarité garantie sans coût

(c) une racine unitaire

(d) une amélioration systématique

Q154. Les prix d'actifs financiers sont typiquement modélisés comme :

(a) stationnaires en niveau

(b) non stationnaires en niveau, stationnaires en rendement

(c) déterministes

(d) un bruit blanc en niveau

Thème 12 --- Rendement, volatilité, corrélation (ch. 12)

Q155. Le rendement logarithmique se calcule par :

(a) P_t/P_{t-1}

(b) $(P_t - P_{t-1})/P_{t-1}$

(c) $\ln(P_t/P_{t-1})$

(d) $P_t - P_{t-1}$

Q156. L'avantage principal du rendement logarithmique est :

(a) son additivité entre actifs

(b) sa positivité garantie

(c) sa simplicité de lecture

(d) son additivité temporelle

Q157. La règle de la racine carrée du temps convertit la volatilité par :

(a) $\sigma \times \sqrt{T}$

(b) σ / T

(c) $\sigma^2 \times T$

(d) $\sigma \times T$

Q158. La volatilité annualisée à partir d'une volatilité journalière (252 jours) se calcule par :

(a) $\sigma \times 252$

(b) $\sigma \times \sqrt{252}$

(c) $\sigma / 252$

(d) $\sigma^2 \times 252$

Q159. La règle de la racine du temps suppose :

(a) une distribution uniforme

(b) une autocorrélation forte

(c) des rendements i.i.d. sans autocorrélation

(d) une hétéroscédasticité

Q160. Le clustering de volatilité désigne :

(a) une corrélation nulle

(b) une tendance déterministe

(c) une volatilité constante

(d) l'alternance de périodes calmes et agitées

Q161. Le modèle EWMA attribue aux observations récentes :

(a) un poids plus élevé

(b) un poids identique

(c) un poids nul

(d) un poids plus faible

Q162. Dans EWMA, un λ élevé (proche de 1) implique :

(a) une réaction très rapide aux chocs

(b) une réaction lente, forte mémoire

(c) une volatilité nulle

(d) une variance infinie

Q163. Le modèle GARCH(1,1) ajoute à l'EWMA :

(a) une racine unitaire

(b) rien de nouveau

(c) un terme de variance de long terme

(d) une tendance déterministe

Q164. Dans GARCH(1,1), la condition de stationnarité impose :

(a) $\alpha + \beta = 0$

(b) $\alpha > 1$

(c) $\alpha + \beta > 1$

(d) $\alpha + \beta < 1$

Q165. Une valeur $\alpha + \beta$ proche de 1 dans un GARCH indique :

(a) une forte persistance de la volatilité

(b) une variance nulle

(c) une absence de clustering

(d) une persistance faible

Q166. La VaR paramétrique à 99 % pour un portefeuille normal utilise le quantile :

(a) 1.96

(b) 2.33

(c) 2.58

(d) 1.645

Q167. La volatilité implicite est extraite :

(a) du test ADF

(b) de données historiques

(c) des prix d'options observés

(d) du bilan de l'entreprise

Q168. Les corrélations entre actifs tendent, en période de crise, à :

(a) rester strictement constantes

(b) devenir nulles

(c) diminuer fortement

(d) augmenter, réduisant la diversification

Thème 13 --- Simulation et bootstrap (ch. 13)

Q169. La simulation de Monte-Carlo repose sur :

(a) la génération de nombreux scénarios aléatoires

(b) des données historiques uniquement

(c) un modèle déterministe

(d) une formule fermée

Q170. L'erreur d'estimation Monte-Carlo décroît en :

(a) $1/N$

(b) $1/\sqrt{N}$

(c) $1/N^2$

(d) N

Q171. La simulation historique se distingue de Monte-Carlo car elle :

(a) ignore les données

(b) génère des scénarios paramétriques

(c) rééchantillonne les scénarios réellement observés

(d) suppose la normalité

Q172. La limite principale de la simulation historique est :

(a) son hypothèse de normalité

(b) son absence de scénarios

(c) sa complexité de calcul

(d) sa dépendance à la fenêtre historique disponible

Q173. Le bootstrap consiste à rééchantillonner :

(a) avec remise

(b) de façon déterministe

(c) uniquement les valeurs extrêmes

(d) sans remise

Q174. Le bootstrap sert principalement à :

(a) générer des données nouvelles

(b) estimer la distribution d'un estimateur sans hypothèse paramétrique

(c) tester la stationnarité

(d) réduire le biais systématiquement

Q175. La fraction moyenne d'observations exclues d'un échantillon bootstrap vaut environ :

(a) 63.2 %

(b) 10 %

(c) 36.8 %

(d) 50 %

Q176. Les variables antithétiques servent à :

(a) générer des tendances

(b) tester l'autocorrélation

(c) augmenter la variance

(d) réduire la variance de l'estimation Monte-Carlo

Q177. Pour des données temporellement dépendantes, on utilise :

(a) le bootstrap par blocs

(b) aucune méthode de rééchantillonnage

(c) la simulation historique seule

(d) le bootstrap i.i.d. standard

Q178. Le générateur de nombres pseudo-aléatoires garantit :

(a) un vrai hasard physique

(b) la reproductibilité via une graine (seed)

(c) l'absence de motifs

(d) une distribution toujours normale

Q179. Augmenter le nombre de simulations réduit :

(a) l'hétéroscédasticité

(b) le risque de modèle

(c) l'erreur d'échantillonnage Monte-Carlo

(d) le biais de spécification

Q180. Le principal risque de Monte-Carlo est :

(a) l'absence de reproductibilité

(b) la variance nulle

(c) la lenteur de calcul

(d) le risque de modèle : hypothèses distributionnelles erronées

Q181. Pour simuler une variable de loi quelconque à partir d'un uniforme, on utilise :

(a) la transformation inverse de la CDF

(b) le test ADF

(c) la régression

(d) la méthode des moments

Q182. Le stress-testing complète la simulation en :

(a) générant plus de scénarios aléatoires

(b) explorant des scénarios extrêmes spécifiés a priori

(c) réduisant la variance

(d) testant la normalité

Thème 14 --- Méthodes de machine learning (ch. 14)

Q183. Le compromis biais-variance décompose l'erreur en :

(a) biais seul

(b) biais^2 + variance

(c) biais^2 + variance + bruit irréductible

(d) variance seule

Q184. Le surapprentissage se caractérise par :

(a) des erreurs identiques

(b) un biais élevé

(c) une erreur d'entraînement élevée

(d) une erreur d'entraînement faible et une erreur de test élevée

Q185. La validation croisée à k plis sert principalement à :

(a) estimer la généralisation et calibrer les hyperparamètres

(b) supprimer les valeurs aberrantes

(c) tester la normalité

(d) augmenter la taille d'échantillon

Q186. La régression Ridge utilise une pénalité :

(a) ℓ_1 (valeurs absolues)

(b) ℓ_2 (carrés)

(c) ℓ_0

(d) aucune

Q187. La régression Lasso se distingue de Ridge car elle :

(a) ignore la colinéarité

(b) ne pénalise rien

(c) peut annuler exactement des coefficients

(d) augmente les coefficients

Q188. Ridge est particulièrement utile en présence de :

(a) classes déséquilibrées

(b) séries non stationnaires

(c) données manquantes

(d) multicolinéarité forte

Q189. Dans k-NN, un k très petit produit :

(a) une variance élevée

(b) un modèle constant

(c) une frontière linéaire

(d) un biais élevé

Q190. Un arbre de décision isolé souffre principalement :

(a) d'un biais très élevé

(b) d'une forte instabilité (variance)

(c) d'une impossibilité d'interprétation

(d) d'une hypothèse de normalité

Q191. Le bagging réduit principalement :

(a) le nombre de variables

(b) le biais

(c) la variance

(d) le bruit irréductible

Q192. La forêt aléatoire ajoute au bagging :

(a) une pénalité ℓ_1

(b) une différenciation

(c) un taux d'apprentissage

(d) une sélection aléatoire de variables à chaque scission

Q193. Le boosting construit ses modèles :

(a) séquentiellement, chacun corrigeant le précédent

(b) aléatoirement sans ordre

(c) une seule fois

(d) en parallèle et indépendamment

Q194. Contrairement au bagging, augmenter indéfiniment les itérations de boosting :

(a) est toujours bénéfique

(b) risque le surapprentissage

(c) réduit la variance à zéro

(d) n'a aucun effet

Q195. k-means est une méthode :

(a) de test d'hypothèse

(b) supervisée de classification

(c) non supervisée de partitionnement

(d) de régression pénalisée

Q196. L'analyse en composantes principales produit des variables :

(a) binaires

(b) catégorielles

(c) fortement corrélées

(d) non corrélées, ordonnées par variance décroissante

Thème 15 --- ML et prédiction (ch. 15)

Q197. La régression logistique modélise linéairement :

(a) le logit de p

(b) la variance de p

(c) les odds directement

(d) la probabilité p directement

Q198. La fonction logistique garantit des prédictions dans :

(a) $[-1, 1]$

(b) $(0, 1)$

(c) $[0, \infty)$

(d) $\mathbb{R}$ entier

Q199. Les odds d'une probabilité p valent :

(a) $1 - p$

(b) $p(1 - p)$

(c) $p/(1 - p)$

(d) $\ln(p)$

Q200. Pour $p = 0.80$, les odds valent :

(a) 5

(b) 0.25

(c) 0.80

(d) 4

Q201. L'odds ratio associé à un coefficient β vaut :

(a) e^{β}

(b) β^2

(c) $1/\beta$

(d) $\ln(\beta)$

Q202. En régression logistique, l'effet marginal d'une variable sur P est :

(a) constant

(b) dépendant du point, via $P(1 - P)$

(c) toujours nul

(d) égal au coefficient

Q203. Les coefficients logistiques sont estimés par :

(a) bootstrap obligatoire

(b) moindres carrés ordinaires

(c) maximum de vraisemblance, itérativement

(d) méthode graphique

Q204. Une variable catégorielle à C modalités, en régression, s'encode par :

(a) une variable continue

(b) C+1 indicatrices

(c) C indicatrices

(d) $C - 1$ indicatrices

Q205. La précision (precision) se calcule par :

(a) $VP/(VP+FP)$

(b) $VN/(VN+FP)$

(c) $(VP+VN)/n$

(d) $VP/(VP+FN)$

Q206. Le rappel (recall) se calcule par :

(a) $VP/(VP+FP)$

(b) $VP/(VP+FN)$

(c) $VN/(VN+FN)$

(d) $FP/(FP+VN)$

Q207. Abaisser le seuil de décision fait typiquement :

(a) baisser les deux

(b) monter la précision et baisser le rappel

(c) monter le rappel et baisser la précision

(d) monter les deux

Q208. Une AUC de 0.5 correspond à :

(a) une erreur de calcul

(b) un modèle parfait inversé

(c) une discrimination parfaite

(d) une discrimination aléatoire

Q209. L'avantage de l'AUC sur l'exactitude est son indépendance :

(a) du seuil et de la prévalence des classes

(b) des données d'entraînement

(c) du modèle utilisé

(d) du nombre de variables

Q210. Sans fonction d'activation non linéaire, un réseau multicouche équivaut à :

(a) un réseau plus performant

(b) une simple couche linéaire

(c) un arbre de décision

(d) une ACP

Partie F --- Corrigé commenté des 210 QCM

Réponse correcte suivie de l'explication et du renvoi au chapitre concerné.

Thème 1 --- Fondamentaux de probabilité (ch. 1)

Q1 — (a) $P(A \cap B) = 0$**.** Exclusifs : intersection vide. À ne pas confondre avec l'indépendance. (*ch. 1*)

Q2 — (b) $P(A \cap B) = P(A)P(B)$**.** Indépendance = produit des probabilités, pas intersection vide. (*ch. 1*)

Q3 — (c) nécessairement dépendants. Si A survient, B ne peut pas : information maximale, donc dépendance. (*ch. 1*)

Q4 — (d) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$**.** Inclusion-exclusion : on retire le double comptage. (*ch. 1*)

Q5 — (a) $P(A \cap B)/P(B)$**.** Définition, avec P(B)>0. (*ch. 1*)

Q6 — (b) $P(A \cap B) = P(A|B)P(B)$**.** Réécriture directe de la définition conditionnelle. (*ch. 1*)

Q7 — (c) inverser le conditionnement. Passer de P(B|A) à P(A|B). (*ch. 1*)

Q8 — (d) la probabilité a priori (prior). Prior : croyance initiale avant donnée. (*ch. 1*)

Q9 — (a) ignorer la probabilité a priori d'un événement rare. Erreur classique : négliger la rareté du phénomène testé. (*ch. 1*)

Q10 — (b) $\sum P(B|A_i)P(A_i)$ **sur une partition.** Pondération par une partition exhaustive de l'espace. (*ch. 1*)

Q11 — (c) $n!/[k!(n-k)!]$**.** Combinaisons : l'ordre n'importe pas. (*ch. 1*)

Q12 — (d) $n!/(n-k)!$**.** Arrangements : l'ordre compte. (*ch. 1*)

Q13 — (a) pas nécessairement indépendants inconditionnellement. L'indépendance conditionnelle n'implique pas l'indépendance simple. (*ch. 1*)

Q14 — (b) $1 - P(A)$**.** Axiome de normalisation. (*ch. 1*)

Thème 2 --- Variables aléatoires et moments (ch. 2)

Q15 — (c) une variable discrète. PMF pour discret, PDF pour continu. (*ch. 2*)

Q16 — (d) zéro. La probabilité ponctuelle est nulle en continu. (*ch. 2*)

Q17 — (a) $P(X \leq x)$**.** Probabilité cumulée. (*ch. 2*)

Q18 — (b) $\sum x\, P(X = x)$**.** Moyenne pondérée par les probabilités. (*ch. 2*)

Q19 — (c) $E[X^2] - (E[X])^2$**.** Formule de König-Huygens. (*ch. 2*)

Q20 — (d) $a^2\text{Var}(X)$**.** La constante additive ne change pas la dispersion. (*ch. 2*)

Q21 — (a) l'asymétrie (skewness). Skewness = moment d'ordre 3. (*ch. 2*)

Q22 — (b) le kurtosis (aplatissement). Kurtosis = moment d'ordre 4. (*ch. 2*)

Q23 — (c) 3. Excès de kurtosis = kurtosis - 3. (*ch. 2*)

Q24 — (d) une queue à gauche plus longue. Asymétrie négative : pertes extrêmes plus probables. (*ch. 2*)

Q25 — (a) aucune condition d'indépendance. L'espérance est toujours linéaire, même avec dépendance. (*ch. 2*)

Q26 — (b) l'inverse de la CDF. $\text{F}^{-1}(\text{p})$ donne le quantile de niveau p. (*ch. 2*)

Q27 — (c) 0.50. Quantile à 50 %. (*ch. 2*)

Q28 — (d) $\text{Var}(X) + \text{Var}(Y)$**.** La covariance s'annule sous indépendance. (*ch. 2*)

Thème 3 --- Lois univariées usuelles (ch. 3)

Q29 — (a) une expérience binaire à un essai. Un seul essai, succès/échec. (*ch. 3*)

Q30 — (b) np**.** Somme de n Bernoulli indépendantes. (*ch. 3*)

Q31 — (c) $np(1-p)$**.** Variance d'une somme de Bernoulli i.i.d. (*ch. 3*)

Q32 — (d) un nombre d'événements rares sur une période. Comptage d'événements rares (défauts, sinistres). (*ch. 3*)

Q33 — (a) λ et λ. Égalité caractéristique de Poisson. (*ch. 3*)

Q34 — (b) sa moyenne et sa variance. Deux paramètres suffisent. (*ch. 3*)

Q35 — (c) 1.645. 1.645 unilatéral ; 1.96 bilatéral. (*ch. 3*)

Q36 — (d) 2.33. Valeur clé pour la VaR 99 %. (*ch. 3*)

Q37 — (a) des queues plus épaisses. Queues épaisses, adaptées aux petits échantillons. (*ch. 3*)

Q38 — (b) converge vers la loi normale. Convergence asymptotique vers $\mathrm{N}(0,1)$. (*ch. 3*)

Q39 — (c) des prix strictement positifs. Si $\ln(\mathrm{X})$ est normal, $\mathrm{X} > 0$. (*ch. 3*)

Q40 — (d) carrés de normales centrées réduites indépendantes. Base des tests de variance. (*ch. 3*)

Q41 — (a) d'absence de mémoire. Sans mémoire : le passé n'informe pas le futur. (*ch. 3*)

Q42 — (b) davantage d'événements extrêmes. Enjeu central pour la VaR et le risque de queue. (*ch. 3*)

Thème 4 --- Lois multivariées et dépendance (ch. 4)

Q43 — (c) la codirectionnalité, en unités produit. Non normalisée, donc peu interprétable seule. (*ch. 4*)

Q44 — (d) $[-1,1]$. Covariance normalisée par les écarts-types. (*ch. 4*)

Q45 — (a) l'absence de relation linéaire seulement. Piège classique : une relation non linéaire peut subsister. (*ch. 4*)

Q46 — (b) l'indépendance. Cas particulier où l'équivalence tient. (*ch. 4*)

Q47 — (c) $w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + 2w_1w_2\sigma_1\sigma_2\rho$. Formule fondamentale de la diversification. (*ch. 4*)

Q48 — (d) -1. Corrélation parfaitement négative annule le risque en théorie. (*ch. 4*)

Q49 — (a) la moyenne pondérée des volatilités. Aucun bénéfice de diversification. (*ch. 4*)

Q50 — (b) une relation monotone par les rangs. Robuste aux valeurs extrêmes et aux non-linéarités. (*ch. 4*)

Q51 — (c) $\mathrm{Var}(X)$. La covariance d'une variable avec elle-même est sa variance. (*ch. 4*)

Q52 — (d) 0. L'indépendance implique covariance nulle (réciproque fausse). (*ch. 4*)

Q53 — (a) la moyenne de Y sachant la valeur de X. Fondement conceptuel de la régression. (*ch. 4*)

Q54 — (b) symétrique. $\mathrm{Cov(i,j)} = \mathrm{Cov(j,i)}$. (*ch. 4*)

Q55 — (c) réduire la volatilité totale. Principe de diversification. (*ch. 4*)

Q56 — (d) transformation linéaire croissante. Invariance d'échelle et de position. (*ch. 4*)

Thème 5 --- Moments d'échantillon et estimation (ch. 5)

Q57 — (a) sans biais de la moyenne. $E[\bar{X}] = \mu$. (*ch. 5*)

Q58 — (b) $\sigma/\sqrt{n}$. Décroît en racine de n. (*ch. 5*)

Q59 — (c) 4. Racine carrée : facteur 4 sur n. (*ch. 5*)

Q60 — (d) $n-1$. Correction de Bessel. (*ch. 5*)

Q61 — (a) tend vers une loi normale quand n croît. Convergence en loi vers la normale. (*ch. 5*)

Q62 — (b) quelle que soit la loi de la population, sous variance finie. Puissance du TCL : indépendance à la loi d'origine. (*ch. 5*)

Q63 — (c) une convergence en probabilité vers le paramètre. Précision croissante avec la taille d'échantillon. (*ch. 5*)

Q64 — (d) de plus faible variance (efficace). Critère d'efficacité. (*ch. 5*)

Q65 — (a) $\bar{x} \pm 1.96\,\sigma/\sqrt{n}$. Quantile bilatéral à 95 %. (*ch. 5*)

Q66 — (b) la loi de Student. Student corrige l'incertitude sur σ. (*ch. 5*)

Q67 — (c) plus large. Plus de confiance = plus de largeur. (*ch. 5*)

Q68 — (d) $E[\hat{\theta}] - \theta$. Écart systématique à la vraie valeur. (*ch. 5*)

Q69 — (a) biais² et variance. MSE = biais² + variance. (*ch. 5*)

Q70 — (b) converge vers l'espérance. Convergence vers μ quand n croît. (*ch. 5*)

Thème 6 --- Tests d'hypothèses (ch. 6)

Q71 — (c) cherche à rejeter, par défaut maintenue. On rejette ou on ne rejette pas, jamais on ne prouve H_0. (*ch. 6*)

Q72 — (d) rejeter H_0 vraie. Faux positif, de probabilité α. (*ch. 6*)

Q73 — (a) ne pas rejeter H_0 fausse. Faux négatif, de probabilité β. (*ch. 6*)

Q74 — (b) 1-β. Probabilité de détecter un effet réel. (*ch. 6*)

Q75 — (c) augmente le risque d'erreur de type II. Arbitrage structurel entre les deux erreurs. (*ch. 6*)

Q76 — (d) la probabilité d'observer une statistique au moins aussi extrême si H_0 est vraie. Piège majeur : ce n'est PAS $P(H_0 \text{ vraie})$. (*ch. 6*)

Q77 — (a) p-value < α. Règle de décision standard. (*ch. 6*)

Q78 — (b) 1.96. 2.5 % dans chaque queue. (*ch. 6*)

Q79 — (c) 1.645. 5 % dans une seule queue. (*ch. 6*)

Q80 — (d) augmente la puissance. Erreur type plus faible, détection plus aisée. (*ch. 6*)

Q81 — (a) Non, un effet minuscule peut être significatif si n est grand. Distinction essentielle à l'examen. (*ch. 6*)

Q82 — (b) les données sont insuffisantes pour la rejeter. Absence de preuve n'est pas preuve d'absence. (*ch. 6*)

Q83 — (c) le non-rejet de H_0 : paramètre nul. Dualité IC / test d'hypothèse. (*ch. 6*)

Q84 — (d) une valeur critique issue de la loi sous H_0. Règle de décision par valeur critique. (*ch. 6*)

Thème 7 --- Régression linéaire simple (ch. 7)

Q85 — (a) la somme des carrés des résidus. Critère MCO fondamental. (*ch. 7*)

Q86 — (b) la variation attendue de y pour une unité de x. Effet marginal constant. (*ch. 7*)

Q87 — (c) la part de variance de y expliquée par le modèle. Coefficient de détermination. (*ch. 7*)

Q88 — (d) le carré de la corrélation entre x et y. Relation propre à la régression simple. (*ch. 7*)

Q89 — (a) d'exogénéité, $E[\varepsilon|x] = 0$. Condition clé pour l'absence de biais. (*ch. 7*)

Q90 — (b) BLUE : meilleur estimateur linéaire sans biais. Best Linear Unbiased Estimator. (*ch. 7*)

Q91 — (c) l'inférence exacte en petit échantillon. Les MCO restent sans biais sans normalité. (*ch. 7*)

Q92 — (d) $y - \hat{y}$. Écart entre observation et prédiction. (*ch. 7*)

Q93 — (a) $\hat{\beta}$ divisé par son erreur type. Base du test de significativité. (*ch. 7*)

Q94 — (b) non significative à 5 %. $|t| < 1.96$ environ. (*ch. 7*)

Q95 — (c) le point $(\bar{x}, \bar{y})$. Propriété algébrique des MCO. (*ch. 7*)

Q96 — (d) 0. Conséquence de l'inclusion d'une constante. (*ch. 7*)

Q97 — (a) Non, jamais nécessairement. Piège classique de l'examen. (*ch. 7*)

Q98 — (b) la dispersion typique des résidus. Échelle de l'erreur de prédiction. (*ch. 7*)

Thème 8 --- Régression multiple (ch. 8)

Q99 — (c) toutes choses égales par ailleurs. Interprétation ceteris paribus. (*ch. 8*)

Q100 — (d) pénalise l'ajout de variables inutiles. Correction du degré de liberté. (*ch. 8*)

Q101 — (a) monter ou stagner le R^2, mais possiblement baisser le R^2 ajusté. Le R^2 brut ne décroît jamais. (*ch. 8*)

Q102 — (b) la nullité conjointe de tous les coefficients de pente. Significativité d'ensemble du modèle. (*ch. 8*)

Q103 — (c) l'estimation MCO impossible (matrice singulière). Non-inversibilité de $X^\top X$. (*ch. 8*)

Q104 — (d) des erreurs types gonflées. Coefficients instables mais non biaisés. (*ch. 8*)

Q105 — (a) un R^2 élevé avec des t-stats individuels faibles. Signature diagnostique classique. (*ch. 8*)

Q106 — (b) le degré de multicolinéarité. VIF élevé (>5 ou 10) = alerte. (*ch. 8*)

Q107 — (c) un biais de variable omise. Violation de l'exogénéité, biais des coefficients. (*ch. 8*)

Q108 — (d) $n - k - 1$. Observations moins paramètres estimés. (*ch. 8*)

Q109 — (a) $C - 1$ indicatrices. Évite la colinéarité parfaite avec la constante. (*ch. 8*)

Q110 — (b) un effet de x_1 dépendant du niveau de x_2. Modulation d'un effet par une autre variable. (*ch. 8*)

Q111 — (c) Oui, si le modèle est très mauvais. Pénalité pouvant dépasser l'explication. (*ch. 8*)

Q112 — (d) un test F partiel. Test de restrictions jointes. (*ch. 8*)

Thème 9 --- Diagnostics de régression (ch. 9)

Q113 — (a) une variance résiduelle non constante. Violation de l'homoscédasticité. (*ch. 9*)

Q114 — (b) sans biais mais inefficaces. Les erreurs types deviennent invalides. (*ch. 9*)

Q115 — (c) utiliser des erreurs types robustes (White). Correction de l'inférence, pas des coefficients. (*ch. 9*)

Q116 — (d) l'hétéroscédasticité. Test général d'hétéroscédasticité. (*ch. 9*)

Q117 — (a) des séries temporelles. Dépendance temporelle des erreurs. (*ch. 9*)

Q118 — (b) l'autocorrélation d'ordre 1. DW ≈ 2 : pas d'autocorrélation. (*ch. 9*)

Q119 — (c) une autocorrélation positive forte. DW < 2 : autocorrélation positive. (*ch. 9*)

Q120 — (d) sous-estimées, gonflant la significativité apparente. Risque de fausse significativité. (*ch. 9*)

Q121 — (a) l'hétéroscédasticité et l'autocorrélation. HAC : heteroskedasticity and autocorrelation consistent. (*ch. 9*)

Q122 — (b) modifie fortement les coefficients si on la retire. Point de levier à fort impact. (*ch. 9*)

Q123 — (c) un modèle mal spécifié, aux coefficients biaisés. Erreur de spécification fonctionnelle. (*ch. 9*)

Q124 — (d) l'hétéroscédasticité. Dispersion croissante avec la prédiction. (*ch. 9*)

Q125 — (a) l'autocorrélation. Structure temporelle non captée. (*ch. 9*)

Q126 — (b) la validité de l'inférence en petit échantillon. Le TCL sauve l'inférence en grand échantillon. (*ch. 9*)

Thème 10 --- Séries temporelles stationnaires (ch. 10)

Q127 — (c) une moyenne et une variance constantes dans le temps. Plus une autocovariance ne dépendant que du décalage. (*ch. 10*)

Q128 — (d) $y_t = \varphi y_{t-1} + \varepsilon_t$. Autorégressif d'ordre 1. (*ch. 10*)

Q129 — (a) $|\varphi| < 1$. Condition fondamentale de stationnarité. (*ch. 10*)

Q130 — (b) $y_t = \varepsilon_t + \theta\varepsilon_{t-1}$. Moyenne mobile d'ordre 1. (*ch. 10*)

Q131 — (c) décroît géométriquement. Décroissance exponentielle en φ^k. (*ch. 10*)

Q132 — (d) s'annule au-delà du retard 1. Coupure nette : signature du MA. (*ch. 10*)

Q133 — (a) s'annule au-delà du retard 1. Coupure du PACF : signature de l'AR. (*ch. 10*)

Q134 — (b) sélectionner l'ordre du modèle. Arbitrage ajustement / parcimonie. (*ch. 10*)

Q135 — (c) plus fortement. BIC favorise des modèles plus parcimonieux. (*ch. 10*)

Q136 — (d) $c/(1-\varphi)$. Moyenne de long terme du processus. (*ch. 10*)

Q137 — (a) une moyenne nulle, variance constante et autocorrélation nulle. Référence d'absence de structure. (*ch. 10*)

Q138 — (b) la moyenne de long terme. Retour à la moyenne (mean reversion). (*ch. 10*)

Q139 — (c) des variables indicatrices saisonnières ou une différenciation saisonnière. Modélisation explicite du motif périodique. (*ch. 10*)

Q140 — (d) une composante AR et une composante MA. Combinaison des deux structures. (*ch. 10*)

Thème 11 --- Séries non stationnaires (ch. 11)

Q141 — (a) non stationnaire, à racine unitaire. Variance croissante avec le temps. (*ch. 11*)

Q142 — (b) croît linéairement avec t. Absence de retour à la moyenne. (*ch. 11*)

Q143 — (c) la présence d'une racine unitaire. H_0 : racine unitaire (non stationnarité). (*ch. 11*)

Q144 — (d) la présence d'une racine unitaire. Piège fréquent : H_0 = non stationnarité. (*ch. 11*)

Q145 — (a) une série non stationnaire. Il faut alors différencier la série. (*ch. 11*)

Q146 — (b) différencier la série. $\Delta y_t = y_t - y_{t-1}$ devient stationnaire. (*ch. 11*)

Q147 — (c) une différenciation. Définition de l'ordre d'intégration. (*ch. 11*)

Q148 — (d) deux séries non stationnaires indépendantes sont régressées. R^2 élevé et t-stats trompeurs sans lien réel. (*ch. 11*)

Q149 — (a) un R^2 élevé avec des résidus fortement autocorrélés. Combinaison diagnostique caractéristique. (*ch. 11*)

Q150 — (b) une combinaison linéaire des deux est stationnaire. Relation d'équilibre de long terme. (*ch. 11*)

Q151 — (c) cointégrées. Combine dynamique court terme et équilibre long terme. (*ch. 11*)

Q152 — (d) l'ajout d'un terme de tendance temporelle. Distinction tendance déterministe / stochastique. (*ch. 11*)

Q153 — (a) l'introduction d'une structure MA artificielle. Coût de la surdifférenciation. (*ch. 11*)

Q154 — (b) non stationnaires en niveau, stationnaires en rendement. Fondement de l'usage des rendements. (*ch. 11*)

Thème 12 --- Rendement, volatilité, corrélation (ch. 12)

Q155 — (c) $\ln(P_t/P_{t-1})$**.** Additif dans le temps. (*ch. 12*)

Q156 — (d) son additivité temporelle. Les rendements simples sont additifs entre actifs, pas dans le temps. (*ch. 12*)

Q157 — (a) $\sigma \times \sqrt{T}$**.** Valable sous i.i.d. et rendements non autocorrélés. (*ch. 12*)

Q158 — (b) $\sigma \times \sqrt{252}$**.** $\sqrt{252} \approx 15.87$. (*ch. 12*)

Q159 — (c) des rendements i.i.d. sans autocorrélation. Hypothèse souvent violée en pratique. (*ch. 12*)

Q160 — (d) l'alternance de périodes calmes et agitées. Fait stylisé majeur des marchés. (*ch. 12*)

Q161 — (a) un poids plus élevé. Pondération exponentiellement décroissante. (*ch. 12*)

Q162 — (b) une réaction lente, forte mémoire. λ élevé = lissage fort. (*ch. 12*)

Q163 — (c) un terme de variance de long terme. Retour vers une variance moyenne. (*ch. 12*)

Q164 — (d) $\alpha + \beta < 1$**.** Somme des coefficients strictement inférieure à 1. (*ch. 12*)

Q165 — (a) une forte persistance de la volatilité. Chocs de volatilité durables. (*ch. 12*)

Q166 — (b) 2.33. Quantile unilatéral à 99 %. (*ch. 12*)

Q167 — (c) des prix d'options observés. Anticipation de marché, tournée vers l'avenir. (*ch. 12*)

Q168 — (d) augmenter, réduisant la diversification. Effondrement de la diversification au pire moment. (*ch. 12*)

Thème 13 --- Simulation et bootstrap (ch. 13)

Q169 — (a) la génération de nombreux scénarios aléatoires. Distribution empirique construite par tirages. (*ch. 13*)

Q170 — (b) $1/\sqrt{N}$**.** Quadrupler N divise l'erreur par deux. (*ch. 13*)

Q171 — (c) rééchantillonne les scénarios réellement observés. Aucune hypothèse distributionnelle imposée. (*ch. 13*)

Q172 — (d) sa dépendance à la fenêtre historique disponible. Un scénario jamais observé ne peut apparaître. (*ch. 13*)

Q173 — (a) avec remise. Tirage avec remise, taille n conservée. (*ch. 13*)

Q174 — (b) estimer la distribution d'un estimateur sans hypothèse paramétrique. Inférence non paramétrique. (*ch. 13*)

Q175 — (c) 36.8 %. $1/e \approx 36.8$ % (out-of-bag). (*ch. 13*)

Q176 — (d) réduire la variance de l'estimation Monte-Carlo. Technique de réduction de variance. (*ch. 13*)

Q177 — (a) le bootstrap par blocs. Préserve la structure de dépendance. (*ch. 13*)

Q178 — (b) la reproductibilité via une graine (seed). Reproductibilité essentielle en audit. (*ch. 13*)

Q179 — (c) l'erreur d'échantillonnage Monte-Carlo. N ne corrige pas un modèle faux. (*ch. 13*)

Q180 — (d) le risque de modèle : hypothèses distributionnelles erronées. « Garbage in, garbage out ». (*ch. 13*)

Q181 — (a) la transformation inverse de la CDF. $F^{-1}(U)$ suit la loi cible. (*ch. 13*)

Q182 — (b) explorant des scénarios extrêmes spécifiés a priori. Scénarios déterministes sévères et plausibles. (*ch. 13*)

Thème 14 --- Méthodes de machine learning (ch. 14)

Q183 — (c) biais² + variance + bruit irréductible. Trois composantes dont une incompressible. (*ch. 14*)

Q184 — (d) une erreur d'entraînement faible et une erreur de test élevée. Écart train/test croissant. (*ch. 14*)

Q185 — (a) estimer la généralisation et calibrer les hyperparamètres. Chaque pli sert une fois de test. (*ch. 14*)

Q186 — (b) ℓ_2 (carrés). Rétrécit sans annuler. (*ch. 14*)

Q187 — (c) peut annuler exactement des coefficients. Sélection automatique de variables. (*ch. 14*)

Q188 — (d) multicolinéarité forte. Stabilise l'inversion de $X^\top X$. (*ch. 14*)

Q189 — (a) une variance élevée. Sensibilité maximale au bruit local. (*ch. 14*)

Q190 — (b) d'une forte instabilité (variance). Motivation des méthodes d'ensemble. (*ch. 14*)

Q191 — (c) la variance. Moyennage de modèles instables. (*ch. 14*)

Q192 — (d) une sélection aléatoire de variables à chaque scission. Décorrélation des arbres. (*ch. 14*)

Q193 — (a) séquentiellement, chacun corrigeant le précédent. Réduction du biais par correction itérative. (*ch. 14*)

Q194 — (b) risque le surapprentissage. Nécessité de l'arrêt anticipé. (*ch. 14*)

Q195 — (c) non supervisée de partitionnement. Aucune cible fournie. (*ch. 14*)

Q196 — (d) non corrélées, ordonnées par variance décroissante. Réduction de dimension par vecteurs propres. (*ch. 14*)

Thème 15 --- ML et prédiction (ch. 15)

Q197 — (a) le logit de p. Puis inversion par la sigmoïde. (*ch. 15*)

Q198 — (b) $(0, 1)$. Bornage par construction. (*ch. 15*)

Q199 — (c) $p/(1-p)$. Cote de l'événement. (*ch. 15*)

Q200 — (d) 4. $0.80/0.20 = 4$. (*ch. 15*)

Q201 — (a) e^{β}. Effet multiplicatif sur les odds. (*ch. 15*)

Q202 — (b) dépendant du point, via $P(1-P)$. Maximal en $P = 0.5$. (*ch. 15*)

Q203 — (c) maximum de vraisemblance, itérativement. Aucune solution fermée. (*ch. 15*)

Q204 — (d) $C - 1$ indicatrices. Évite la trappe des variables indicatrices. (*ch. 15*)

Q205 — (a) $VP/(VP + FP)$. Sur les prédits positifs. (*ch. 15*)

Q206 — (b) $VP/(VP + FN)$. Sur les positifs réels. (*ch. 15*)

Q207 — (c) monter le rappel et baisser la précision. Arbitrage structurel du seuil. (*ch. 15*)

Q208 — (d) une discrimination aléatoire. Équivalent d'un tirage au sort. (*ch. 15*)

Q209 — (a) du seuil et de la prévalence des classes. Robustesse au déséquilibre des classes. (*ch. 15*)

Q210 — (b) une simple couche linéaire. La composition de linéaires reste linéaire. (*ch. 15*)
